به نام خدا، از خدا و برای خدا

دانشگاه شهید بهشتی تهران

دانشکدهٔ علوم ریاضی

گروه علوم کامپیوتر

پایان‌نامهٔ کارشناسی ارشد

حفظ امنیت داده‌های حساس در پیش‌بینی خودکشی با رویکردی مبتنی بر یادگیری مشارکتی و رمزگذاری همریخت در پردازش زبان طبیعی

نگارش

سجاد رنجبر یزدی

استاد راهنما

سرکار خانم دکتر زیبا اسلامی

شهریور ۱۴۰۵

کلیهٔ حقوق، اعم از چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه، برای دانشگاه شهید بهشتی تهران محفوظ است. نقل مطالب با ذکر مأخذ آزاد است.

تقدیم به مادر و پدر؛

که با کلید محبت، رمز عشق را برایم خوانا کردند.

سپاسگزاری

با درود و ستایش بی‌پایان، سخن را با نام آن یگانهٔ بی‌مانند می‌گشایم که الطاف بی‌حدوحصرش رهگشای گام‌های ناتوان من در این وادی دانش بود و مرا به فرجام این مقصود موفق و مؤید گردانید.

پس از ستایش ایزدی، ارج نهادن به مقام والای استاد فرزانه و راهنمای خویش، سرکار خانم دکتر زیبا اسلامی، برترین فریضهٔ سپاسگزاری است. آن بزرگوار با شکیبایی کم‌مانند، ژرفای بینش و رهنمودهای سودمندشان همواره روشنی‌بخش مسیر این پژوهش بوده‌اند و بی‌یاری خردورزانهٔ ایشان، نگارش این اوراق میسر نمی‌شد. امید که این قلیل بضاعت پاسخی هرچند ناچیز به رنج‌های پیگیر آن استاد گران‌مایه باشد.

در ادامه، مراتب امتنان و سپاس صمیمانهٔ خویش را به داوران گرامی این پایان‌نامه، جناب آقای دکتر هادی فراهانی و جناب آقای دکتر سعید رضا خردپیشه، تقدیم می‌دارم. دقت نظر، ارزیابی علمی و پیشنهادهای ارزشمند ایشان در فرایند داوری، در اصلاح روش پژوهش، روشن‌تر شدن گزارش نتایج و ارتقای کیفیت علمی و نگارشی این پایان‌نامه نقشی بسزا داشته است. از وقتی که با بزرگواری به مطالعه و بررسی این پژوهش اختصاص دادند، صادقانه سپاسگزارم.

بی‌تردید، پیمودن بخش‌های عملی این تحقیق جز با یاری دست‌اندرکاران عرصهٔ سخت‌افزار میسر نبود. از جناب مهندس ناظری، از دانشگاه فردوسی مشهد، که با گشاده‌دستی تجهیزات و زیرساخت‌های سخت‌افزاری لازم را در دسترس اینجانب نهادند، صمیمانه سپاسگزارم. همچنین از جناب مهندس شمس‌آبادی و همسر ایشان، مهندس نازفروش، که در روزگار دانشجویی همواره در گشایش دشواری‌ها و ارائهٔ یاری‌های کارگشا یاور من بودند، از صمیم قلب قدردانی می‌کنم. محبت‌های بی‌چشمداشت این بزرگواران هیچ‌گاه از خاطر نخواهد رفت.

در پایان، بر خود می‌بالم که در این مسیر پرفرازونشیب با بزرگوارانی همسفر بودم که یادشان سرمایهٔ دل است. از درگاه خداوند متعال، دوام تندرستی و فزونی توفیق همگان را مسئلت می‌کنم.

سجاد رنجبر یزدی
شهریور ۱۴۰۵

چکیده

نام و نام خانوادگی: سجاد رنجبر یزدی
رشته: علوم کامپیوتر
دانشگاه: شهید بهشتی
استاد راهنما: دکتر زیبا اسلامی
تعداد کل صفحه‌ها: ۱۰۲

مقطع: کارشناسی ارشد
گرایش: داده‌کاوی
دانشکده: علوم ریاضی
تاریخ: شهریور ۱۴۰۵

عنوان: حفظ امنیت داده‌های حساس در پیش‌بینی خودکشی با رویکردی مبتنی بر یادگیری مشارکتی و رمزگذاری همریخت در پردازش زبان طبیعی

تشخیص نشانه‌های مرتبط با خودکشی از متن، در کنار نیاز به ارزیابی معتبر، با حساسیت بالای اطلاعات سلامت روان روبه‌رو است. این پایان‌نامه تحلیل متن، یادگیری مشارکتی و تجمیع همریختِ احرازاصالت‌شده را در یک چارچوب پژوهشی بررسی می‌کند. مجموعهٔ انگلیسی Suicide Watch با ۰۷۴٬۲۳۲ ردیف خام، پس از حذف تکرار و پاکسازیِ جداگانه، به ۳۸۰٬۱۴۸ نمونهٔ آموزش، ۰۸۶٬۳۷ نمونهٔ اعتبارسنجی و ۳۴۲٬۴۶ نمونهٔ آزمون منجر می‌شود. بازنماییِ صدبعدی Word2Vec درون خط‌لوله و فقط بر آموزش هر تقسیم یاد گرفته می‌شود. چهار خانوادهٔ جنگل تصادفی، درخت تصمیم، XGBoost و رأی‌گیری گاوسی–برنولی مقایسه و مدل و آستانه بر اعتبارسنجی تثبیت می‌شوند. در ارزیابی متمرکز، مدل XGBoostدر آستانهٔ ۳۸.۰، دقت آزمون ۷۰.۹۲ درصد و F_1 کلاس مثبت ۹۲۷۸.۰ را به دست می‌آورد.

در بخش مشارکتی، دادهٔ آموزش با حفظ تقریبی نسبت کلاس‌ها و بدون هم‌پوشانی بین ۱۰، ۲۰، ۵۰ و ۱۰۰ کلاینت تقسیم می‌شود. هر کلاینت بازنمایی و XGBoost مستقل دارد و احتمال‌ها با وزن تعداد نمونهٔ محلی تجمیع می‌شوند. دقت آزمون با آستانهٔ منتخب اعتبارسنجی به‌ترتیب ۵۸٫۹۱، ۹۳٫۹۰، ۳۰٫۸۹ و ۰۰٫۸۷ درصد است. سناریوی ۱۰ کلاینت بر اساس اعتبارسنجی انتخاب شده است؛ برای هر سناریو فقط یک بذر وجود دارد و عدم‌قطعیت بین اجراها برآورد نشده است.

در بخش امنیت، ساختار SBHE-Benaloh امضای Ed25519 را بر محمولهٔ شامل هویت، دور، مقدار یک‌بارمصرف، متن رمز و وزن بررسی می‌کند و سپس فقط مؤلفهٔ رمزشده را تجمیع می‌کند. درستی میانگین به نمایش صحیح و شرط نبود سرریز وابسته است. در بنچمارک ذخیره‌شده با کلید پژوهشی ۲۵۶بیتی، میانگین زمان کل برای ۱۰۰ و ۳۰۰ کلاینت حدود ۰۲٫۱۱۹ و ۶۸٫۲۷۵ میلی‌ثانیه است. این زمان‌ها جدا از آزمایش یادگیری‌اند و اجرای سرتاسریِ رمزگذاری‌شدهٔ طبقه‌بندی را نشان نمی‌دهند. مالکیت کلید خصوصی در سرور، نبود اثبات بازه و محدودیت فضایِ پیام نیز صریحاً در تحلیل اعتماد لحاظ می‌شوند. نتایج، مبنایی برای توسعه و ارزیابی بعدی فراهم می‌کنند و جایگزین اعتبارسنجی بالینی یا تأیید امنیت تولیدی نیستند.

واژگان کلیدی: پردازش زبان طبیعی، تحلیل متن، یادگیری مشارکتی، توزیع طبقه‌بندی‌شده، Word2Vec، انتخاب آستانه، رمزگذاری همریخت، بنالوح، امضای دیجیتال، حریم خصوصی.

فهرست مطالب

سپاسگزاری آ

چکیده ب

مقدمه ۱

۱ در جست‌وجوی نشانه‌ها؛ طرح موضوع و بررسی پیشینهٔ پژوهش ۴

۱-۱ ضرورت انجام پژوهش ۴

۱-۲ نحوهٔ انجام پژوهش ۵

۱-۳ پیشینهٔ پژوهش ۶

۱-۳-۱ تشخیص خطر خودکشی با تحلیل متن و یادگیری ماشین ۶

۱-۳-۲ یادگیری مشارکتی در حوزهٔ سلامت ۷

۱-۳-۳ رمزگذاری همریخت و محاسبات حفظ‌کنندهٔ حریم خصوصی ۷

۱-۳-۴ تجمیع امن و ترکیب آن با یادگیری مشارکتی ۸

۱-۳-۵ جمع‌بندی پیشینه و شکاف پژوهشی ۸

۱-۴ صورت‌بندی پرسش‌ها و دامنهٔ اعتبار ۹

۲ واژه‌ها را بشنو؛ مبانی و ارزیابی تحلیل متن و یادگیری مشارکتی ۱۰

۲-۱ مبانی و تاریخچهٔ پردازش زبان طبیعی ۱۰

۲-۱-۱ وظایف اصلی و پیوند میان آن‌ها ۱۰

۲-۱-۲ سیر تاریخی و تحول روش‌ها ۱۱

۲-۱-۳ از چارچوب عمومی تا آزمایش این پژوهش ۱۱

۲-۲ طراحی آزمایش و آماده‌سازی داده ۱۲

۲-۲-۱ پاکسازی ثابت و جلوگیری از نشت داده ۱۲

۲-۲-۲ واژه‌سازی و دامنهٔ زبانی ۱۴

۲-۳ بردارسازی مبتنی بر Word2Vec ۱۴

۲-۳-۱ تبدیل بردار واژه به بردار سند ۱۵

۲-۳-۲ محل یادگیری بازنمایی و ممیزی واژگان ۱۵
۲-۴ معیارهای ارزیابی و انتخاب مدل ۱۶
۲-۴-۱ سه سطح جداسازی ارزیابی ۱۶
۲-۵ الگوریتم‌های یادگیری ماشین ۱۷
۲-۵-۱ جنگل تصادفی ۱۷
۲-۵-۲ درخت تصمیم ۱۷
۲-۵-۳ تقویت گرادیانی و XGBoost ۱۸
۲-۵-۴ بیز ساده و رأی‌گیری احتمالی ۲۰
۲-۶ نتایج ارزیابی مدل‌ها ۲۰
۲-۶-۱ مقایسه بر اعتبارسنجی ۲۰
۲-۶-۲ ارزیابی نهایی مدل تثبیت‌شده ۲۱
۲-۷ تحلیل حساسیت نسبت به آستانه و خطا ۲۵
۲-۸ یادگیری مشارکتی با توزیع طبقه‌بندی‌شدهٔ داده‌ها ۲۷
۲-۸-۱ مجموعه‌داده و جداسازی ارزیابی ۲۷
۲-۸-۲ تعریف دقیق تخصیص داده به کلاینت‌ها ۲۸
۲-۸-۳ آموزش مستقل بازنمایی و مدل محلی ۲۹
۲-۸-۴ تجمیع خروجی و انتخاب آستانه ۲۹
۲-۸-۵ گزارش مستقل چهار سناریو ۳۰
۲-۸-۶ تحلیل مقایسه‌ای و حدود اعتبار نتایج ۳۱
۲-۸-۷ ارتباط نتیجهٔ مشارکتی با لایهٔ رمزگذاری همریخت ۳۶

۳ سپری از اعداد؛ طراحی بستر تبادل داده و رمزگذاری همریخت ۳۷

۳-۱ رمزگذاری متن ورودی با AES-GCM ۳۷
۳-۱-۱ ضرورت و مبانی تسهیم راز شامیر ۳۸
۳-۱-۲ بازسازی کلید با درونیابی لاگرانژ ۳۸
۳-۱-۳ ویژگی امنیتی و حدود آن ۳۹
۳-۱-۴ جریان کامل پروتکل و مدل تهدید ۳۹
۳-۲ ارسال خروجی کلاینت‌ها با رمزگذاری همریخت ۳۹
۳-۲-۱ رمزگذاری ElGamal ۴۱
۳-۲-۲ رمزگذاری Paillier ۴۱
۳-۲-۳ رمزگذاری Benaloh ۴۲
۳-۲-۴ تعمیم Damgård–Jurik و تخصص $s = 1$ ۴۴
۳-۲-۵ رمزگذاری RSA ۴۵

۳-۳ مقایسهٔ نظری پنج طرح ۴۵
۳-۴ ارزیابی تجربی پیاده‌سازی‌های موجود ۴۶
۳-۴-۱ صحت‌سنجی و تفاوت بار کاری ۴۶
۳-۴-۲ هزینهٔ تولید کلید و رمزگذاری ۴۷
۳-۴-۳ تجمیع، رمزگشایی و زمان کل ۴۷
۳-۴-۴ تأثیر اندازهٔ کلید و حدود نتیجه‌گیری ۴۸

۴ طراحی و پیاده‌سازی تجمیع میانگین وزنیِ احرازاصالت‌شده با SBHE-Benaloh ۵۰
۴-۱ هدف و مرز پروتکل ۵۰
۴-۲ مدل سیستم و نقش اعضا ۵۰
۴-۳ بازنمایی عددی و مدیریت دقت ۵۲
۴-۴ بن‌مایهٔ جبری بنالوح ۵۲
۴-۵ ساختار محموله و پیام امضاشده ۵۳
۴-۶ گام‌های کلاینت و سرور ۵۳
۴-۶-۱ فرایند کلاینت ۵۳
۴-۶-۲ پذیرش محموله در سرور ۵۳
۴-۶-۳ رمزگشایی و شرط ظرفیت پیام ۵۴
۴-۷ اثبات درستی تجمیع ۵۴
۴-۸ تحلیل امنیتی و محدودیت‌های دقیق ۵۵
۴-۸-۱ هویت، تمامیت و بازپخش ۵۵
۴-۸-۲ مرز محرمانگی ۵۵
۴-۸-۳ کلاینت مجاز اما مخرب ۵۵
۴-۸-۴ هزینه، مدیریت کلید و استقرار ۵۵
۴-۹ چرا امضا در متن رمز ضرب نمی‌شود؟ ۵۶
۴-۱۰ ارزیابی عملکردِ ذخیره‌شده ۵۶
۴-۱۱ آزمون‌های کارکردی و مسیرهای توسعه ۵۹
۴-۱۲ جمع‌بندی ۵۹

نتیجه‌گیری کلی و پیشنهادها ۶۰

الف بسته و سرویس واژگان توقف فارسی «دنا» ۶۱
الف-۱ مسئله و دامنهٔ کاربرد ۶۱
الف-۲ کاربرد در نمایش‌های متنی ۶۱
الف-۳ معماری سرویس و قالب داده ۶۲

الف-۴ مدیریت دسترسی، خطا و توسعه ۶۳

ب مسئلهٔ لگاریتم گسسته **۶۴**

ب-۱ تعریف و نقش در رمزنگاری ۶۴

ب-۲ روش گام کوچک-گام بزرگ ۶۴

ب-۳ کاربرد در بنالوح و تفاوت فضای پیام با پارامتر امنیت ۶۵

ج تبادل کلید دیفی-هلمن **۶۶**

ج-۱ ساختار پایه ۶۶

ج-۲ سه فرض متفاوت ۶۶

ج-۳ احراز هویت و حملهٔ مرد میانی ۶۶

د باقیمانده‌های مرکب درجهٔ n **۶۸**

د-۱ تعریف مسئله ۶۸

د-۲ رابطه با رمزگذاری پاییه ۶۸

د-۳ حدود فرض و حملات مرتبط ۶۸

د-۴ پیاده‌سازی و آیندهٔ پارامترها ۶۹

هـ الگوریتم امضای دیجیتال Ed25519 **۷۰**

هـ-۱ منحنی و تولید کلید ۷۰

هـ-۲ تولید امضا ۷۰

هـ-۳ بررسی و رابطهٔ درستی ۷۱

هـ-۴ کاربرد در پروتکل پایان‌نامه ۷۱

فهرست اختصارات **۷۲**

واژه‌نامه **۷۴**

منابع و مآخذ **۷۷**

چکیدهٔ انگلیسی **۸۸**

فهرست تصاویر

۱–۱ جریان مشارکتیِ این آزمایش: آموزش محلی و میانگین وزن‌دار احتمال‌ها با وزن تعداد نمونه . ۶
۱–۲ رابطهٔ سه حوزهٔ پیشینه با مسیرهای ارزیابی پژوهش حاضر ۸

۲–۱ جریان اصلاح‌شدهٔ آزمایش متن؛ جداسازی ارزیابی پیش از یادگیری بازنمایی انجام می‌شود . . ۱۳
۲–۲ جریان پاکسازی و ممیزی نسخهٔ اصلاح‌شده؛ قواعد به برچسب ارزیابی وابسته نیستند ۱۴
۲–۳ جریان جنگل تصادفی و انتخاب آستانه بر اعتبارسنجی در آزمایش اصلاح‌شده ۱۷
۲–۴ فلوچارت مفهومی درخت تصمیم ۱۸
۲–۵ نمای مفهومی آموزش تقویتی XGBoost ۱۹
۲–۶ ساختار رأی‌گیری نرم بیز گاوسی–برنولی روی بازنمایی استانداردشدهٔ سند ۲۱
۲–۷ ماتریس سردرگمی جنگل تصادفی بر اعتبارسنجی، با آستانهٔ منتخب همان بخش ۲۳
۲–۸ ماتریس سردرگمی درخت تصمیم بر اعتبارسنجی، با آستانهٔ منتخب همان بخش ۲۳
۲–۹ ماتریس سردرگمی XGBoost بر اعتبارسنجی ۲۴
۲–۱۰ ماتریس سردرگمی رأی‌گیری بیز گاوسی–برنولی بر اعتبارسنجی ۲۴
۲–۱۱ ماتریس سردرگمی آزمون نهایی برای انتخاب تثبیت‌شدهٔ XGBoost ۲۵
۲–۱۲ منحنی ROC مدل منتخب در آزمون نهایی ۲۶
۲–۱۳ منحنی دقت مثبت–بازیابی مدل منتخب در آزمون نهایی ۲۶
۲–۱۴ تحلیل حساسیت چهار مدل فقط بر اعتبارسنجی؛ خط عمودی آستانهٔ منتخب را نشان می‌دهد . . ۲۷
۲–۱۵ توزیع کلاس‌ها در بخش‌های مشترک و طول متن‌های آموزشی؛ خروجی نوت‌بوک مشارکتی . ۲۸
۲–۱۶ گزارش مستقل ۱۰ کلاینت: ماتریس سردرگمی و منحنی‌های ارزیابی و آستانه ۳۲
۲–۱۷ گزارش مستقل ۲۰ کلاینت با آستانهٔ منتخب ۰٫۵۲ . . . . . ۳۲
۲–۱۸ گزارش مستقل ۵۰ کلاینت با آستانهٔ منتخب ۰٫۵۴ . . . . . ۳۳
۲–۱۹ گزارش مستقل ۱۰۰ کلاینت با آستانهٔ ۰٫۵ . . . . . ۳۳
۲–۲۰ مقایسهٔ معیارهای آزمون سناریوهای مشارکتی بر اساس خروجی ثبت‌شده ۳۴
۲–۲۱ مقایسهٔ منحنی‌های ROC و دقت مثبت–بازیابی آزمون مشترک در چهار سناریو ۳۴
۲–۲۲ مقایسهٔ ماتریس‌های سردرگمی چهار سناریو با آستانه‌های منتخب اعتبارسنجی ۳۵

۳-۱ نمای مفهومی حفاظت از متن ورودی با رمزگذاری متقارن و تسهیم راز؛ کانال امن سهم‌ها و کنترل آستانه از پیش‌شرط‌های طرح‌اند ۴۰
۳-۲ طرح مفهومی رمزگذاری و رمزگشایی الجمال ۴۲
۳-۳ نمای مفهومی پاییه؛ محاسبات متن رمز در پیمانهٔ n^2 انجام می‌شوند ۴۳
۳-۴ نمای مفهومی بنالوح؛ مرتبهٔ فضای پیام و روش لگاریتم گسسته بر هزینهٔ رمزگشایی اثر دارند . . ۴۴
۳-۵ زمان تولید کلید در اجرای ذخیره‌شده؛ مقایسه به همین پیاده‌سازی‌ها محدود است ۴۷
۳-۶ زمان رمزگذاری در خانوادهٔ جمعی؛ ستون‌های اندازه‌گیری‌نشدهٔ خانوادهٔ ضربی با صفر جایگزین نمی‌شوند ۴۸
۳-۷ زمان کل آزمون‌های ذخیره‌شده؛ بار کاری خانواده‌های ضربی و جمعی متفاوت است ۴۹
۳-۸ مقایسهٔ چندمعیارهٔ زمان پیاده‌سازی‌های موجود در نسخهٔ مبنا ۴۹

۴-۱ جریان اجرای SBHE-Benaloh؛ امضای مستقیم پیام بایتی و بررسی محموله پیش از تجمیع مؤلفهٔ رمزشده ۵۱
۴-۲ مقایسهٔ عملکرد زمانی SBHE-Benaloh در اندازه‌های کلید و تعداد کلاینت‌های اجرای ذخیره‌شده ۵۷
۴-۳ مقایسهٔ زمان مرحله‌های پروتکل در پیکربندی‌های ثبت‌شده ۵۸
۴-۴ توزیع هزینهٔ مرحله‌ها با تغییر اندازهٔ کلید؛ واحد زمان در نمودارها مشخص شده است ۵۸
۴-۵ اثر تعداد کلاینت و طول کلید بر هزینهٔ اجرای ذخیره‌شدهٔ پروتکل ۵۹

الف-۱ معماری مفهومی سرویس واژگان توقف فارسی دنا ۶۲

فهرست جداول

۲–۱ مقایسهٔ چهار مدل بر اعتبارسنجی؛ تمام معیارها در مقیاس صفر تا یک‌اند ۲۱
۲–۲ ارزیابی آزمون فقط برای مدل منتخب؛ دو تنظیم آستانه برای همان مدل ۲۱
۲–۳ گزارش برازش و جست‌وجو؛ خط تیره یعنی جست‌وجوی اعتبارسنجی برای آن مدل تعریف نشده است ۲۲
۲–۴ فراپارامترهای منتخب جست‌وجوی تصادفی؛ انتخاب فقط از اعتبارسنجی متقابلِ آموزش . . . ۲۲
۲–۵ پوشش بازنمایی مدل منتخب؛ واژگان فقط از آموزش آموخته شده‌اند ۲۲
۲–۶ شمارش خطاهای مدل منتخب در آزمون، با آستانهٔ تثبیت‌شده ۲۲
۲–۷ توزیع واقعی داده پس از حذف تکرار و پاکسازی در آزمایش مشارکتی ۲۸
۲–۸ اندازه و نسبت کلاس مثبت در دادهٔ محلی؛ تمام ۳۸۰٬۱۴۸ نمونه در هر سناریو دقیقاً یک‌بار استفاده می‌شوند ۲۹
۲–۹ نتایج آزمون با آستانهٔ منتخب اعتبارسنجی؛ معیارها در مقیاس صفر تا یک ۳۰
۲–۱۰ معیارهای مستقل از آستانه، تعداد خطاها و زمان اجرای سناریوهای مشارکتی ۳۰
۲–۱۱ نتایج آزمون با آستانهٔ ثابت ۰٫۵؛ بدون تنظیم جداگانهٔ آستانه برای هر سناریو ۳۰

۳–۱ فضای پیام و نوع همریختی؛ تمام رابطه‌ها در پیمانهٔ فضای پیام تفسیر می‌شوند ۴۵
۳–۲ زمان‌های طرح‌های جمعی برای ۱۰۰ پیام و تجمیع وزن‌دار ۴۶
۳–۳ زمان‌های آزمون ضرب دو پیام؛ رمزگذاری و رمزگشایی جداگانه اندازه‌گیری نشده‌اند . . . ۴۶

۴–۱ میانگین و انحراف معیار زمان کل در فایل خلاصهٔ ذخیره‌شده؛ واحد میلی‌ثانیه ۵۶
۴–۲ میانگین زمان مرحله‌های پروتکل در اجرای ذخیره‌شده؛ واحد میلی‌ثانیه ۵۷

مقدمه

خودکشی یکی از چالش‌های جدی سلامت عمومی است و پیامد آن تنها به یک فرد محدود نمی‌شود؛ خانواده، شبکهٔ اجتماعی و نظام سلامت نیز از آن تأثیر می‌پذیرند. سازمان جهانی بهداشت بر ضرورت پیشگیری، شناسایی نشانه‌های هشدار و دسترسی به حمایت مناسب تأکید می‌کند [۱]. تعامل عوامل روان‌شناختی، اجتماعی، زیستی و محیطی، پیش‌بینی این پدیده را دشوار می‌سازد [۳]. ازاین‌رو هر ابزار محاسباتی باید در کنار این پیچیدگی و محدودیت‌های داده تفسیر شود و جایگزین ارزیابی متخصص تلقی نشود.

گسترش شبکه‌های اجتماعی حجم بزرگی از متن‌های خوداظهاری را در دسترس پژوهشگران قرار داده است. انتخاب واژه، اشاره به تنهایی و ناامیدی، تغییر لحن و شیوهٔ روایت تجربهٔ فردی می‌توانند با وضعیت روانی ارتباط داشته باشند [۶، ۷، ۸، ۹]. پردازش زبان طبیعی و یادگیری ماشین راهی برای تحلیل نظام‌مند این الگوها فراهم می‌کنند. با این حال، متن شبکهٔ اجتماعی معادل پروندهٔ بالینی یا تشخیص قطعی نیست. منبع برچسب، زمان گردآوری، زبان، فرهنگ و تفاوت کاربران می‌توانند اعتبار و تعمیم نتیجه را محدود کنند [۱۰، ۱۱].

در حوزهٔ سلامت روان، حریم خصوصی یک پیش‌شرط اساسی است. متن ممکن است هم‌زمان شامل اطلاعات هویتی، تجربهٔ شخصی، وضعیت درمان و روابط اجتماعی باشد. تمرکز چنین داده‌ای در یک مخزن، سطح مواجهه با خطای دسترسی، افشا و استفادهٔ ثانویه را افزایش می‌دهد. دغدغه‌های اخلاقی و قواعدی مانند GDPR و HIPAA نیز اهمیت تعیین مسئولیت، رضایت، محدودیت استفاده و حفاظت از داده را نشان می‌دهند [۴]. بنابراین افزایش یک معیار پیش‌بینی، بدون توجه به چرخهٔ داده، پاسخ کاملی به مسئله نیست.

یادگیری مشارکتی، با محلی نگه داشتن دادهٔ آموزش و اشتراک مؤلفه‌های مدل یا خروجی‌ها، امکان همکاری میان منابع داده را بررسی می‌کند [۱۵، ۱۶، ۱۷]. این ویژگی می‌تواند نیاز به انتقال متن خام را کاهش دهد، اما به‌خودی‌خود نشت اطلاعات را منتفی نمی‌کند. به‌روزرسانی مدل یا احتمال پیش‌بینی نیز ممکن است حامل اطلاعات حساس باشد. همچنین هویت فرستنده، تمامیت پیام، بازپخش، اعتبار وزن و رفتار عضو مجاز اما مخرب، مسائلی جداگانه‌اند که صرف توزیع آموزش آن‌ها را حل نمی‌کند.

رمزگذاری همریخت اجازه می‌دهد برخی عملیات، از جمله جمع وزن‌دار، در دامنهٔ متن رمز انجام شوند [۱۹، ۲۰، ۲۱، ۲۲]. اگر احتمال‌های خروجی کلاینت‌ها به نمایش صحیح معتبر تبدیل شوند، یک طرح جمعی می‌تواند متن رمزِ مجموع را بدون رمزگشایی جداگانهٔ همهٔ مشارکت‌ها بسازد. امضای دیجیتال نیز می‌تواند اصالت فیلدهای محموله را پیش از پذیرش کنترل کند. با این حال، انجام این دو کار باید با مدل اعتماد روشن همراه باشد: سروری که کلید خصوصی را دارد، صرفاً با انتخاب مسیر برنامهٔ «فقط تجمیع» از توان رمزگشایی منفرد محروم نمی‌شود.

انگیزه و هدف پژوهش

انگیزهٔ اصلی، بررسی هم‌زمان کیفیت تحلیل متن و الزامات حفاظت از تبادل خروجی‌هاست. هدف، توسعهٔ یک ارزیابی قابل‌بازتولید برای انتخاب طبقه‌بند، بررسی اثر تعداد کلاینت‌ها بر خروجی تجمیعی و صورت‌بندی یک لایهٔ احراز اصالت سازگار با جبر جمعی است. این اهداف به سه آزمایش و تحلیل مرتبط، اما متمایز منجر می‌شوند:

۱. مقایسهٔ متمرکزِ خط‌لوله‌های متن با جداسازی آموزش، اعتبارسنجی و آزمون و جلوگیری از یادگیری واژگان از بخش نگه‌داشته‌شده؛

۲. آموزش مدل‌های مستقل محلی با تخصیص طبقه‌بندی‌شدهٔ همهٔ ردیف‌های آموزش در سناریوهای ۱۰، ۲۰، ۵۰ و ۱۰۰ کلاینت و تجمیع احتمال بر اساس اندازهٔ دادهٔ محلی؛

۳. تحلیل و آزمون کارکردیِ تجمیع مجموع صحیح وزن‌دار با بنالوح و بررسی امضای Ed25519 پیش از پذیرش محموله.

پرسش‌ها و فرض‌های قابل بررسی

پرسش نخست این است که با بازنمایی Word2Vec و ارزیابی بدون نشت، چهار خانوادهٔ جنگل تصادفی، درخت تصمیم، XGBoost و رأی‌گیری بیز ساده چه عملکردی بر اعتبارسنجی دارند و انتخاب تثبیت‌شده چه نتیجه‌ای در آزمون می‌دهد. برتری هیچ مدل از پیش به‌عنوان نتیجه فرض نمی‌شود. معیار انتخاب، F_1 کلاس مثبت و قواعد رفع تساوی تعریف‌شده است؛ دقت آزمون برای انتخاب مدل استفاده نمی‌شود.

پرسش دوم به اثر اندازهٔ دادهٔ محلی مربوط است. هنگامی که کل داده ثابت و نسبت کلاس‌ها تقریباً حفظ شود، افزایش تعداد کلاینت چه تغییری در واژگان محلی، پوشش متن و کیفیت احتمال تجمیعی ایجاد می‌کند؟ این پرسش با یک تقسیم طبقه‌بندی‌شدهٔ تقریباً هم‌توزیع بررسی می‌شود. نتیجهٔ آن نباید به سناریوهای غیرهم‌توزیع، تقسیم زمانی یا استقلال واقعی کاربران تعمیم داده شود.

پرسش سوم این است که چگونه می‌توان هویت، تمامیت، دور و یکتایی محموله را پیش از ضرب متن‌های رمز کنترل کرد، بدون آنکه امضا در ساختار جبری بنالوح دخالت کند. درستی مجموع به شرط ظرفیت فضای پیام وابسته است؛ امنیت محموله نیز به ثبت معتبر کلید، محرمانه ماندن کلید امضا و نگهداری وضعیت بازپخش وابسته است. این پیش‌شرط‌ها جزئی از نتیجه‌اند، نه جزئیاتی قابل حذف از گزارش.

روش و اصلاحات ارزیابی

منبع داده، مجموعهٔ انگلیسی Suicide Watch با ۰۷۴٬۲۳۲ ردیف خام است. پس از حذف تکرار خام، ۹۸۱٬۲۳۱ ردیف تقسیم می‌شود. سهم‌های اسمی آموزش، اعتبارسنجی و آزمون ۶۴، ۱۶ و ۲۰ درصدند. پاکسازی و حذف هم‌پوشانیِ ناشی از آن، تعدادهای نهایی را به ۳۸۰٬۱۴۸، ۰۸۶٬۳۷ و ۳۴۲٬۴۶ می‌رساند. این شمارش جایگزین توصیف قبلیِ ۱۴۸٬۴۶۴ نمونه است.

پاکسازی، نفی انگلیسی، اعداد و حروف یونیکد را حفظ می‌کند و فهرست آموخته‌شده‌ای از کلمات توقف ندارد. بازنمایی صدبعدیِ میانگین بردار واژه درون خط‌لوله قرار دارد و در هر تقسیم اعتبارسنجی متقابل فقط روی آموزش همان تقسیم یاد گرفته می‌شود. مدل و آستانه بر اعتبارسنجی جداگانه تثبیت می‌شوند و آزمون نهایی برای آن انتخاب گزارش می‌شود. ابزار فارسی «دنا» به‌عنوان دستاورد جانبی معرفی می‌شود، اما نتایج این مسیر انگلیسی به آن نسبت

داده نمی‌شوند.

در مسیر مشارکتی، هر کلاینت هم بازنمایی و هم طبقه‌بند خود را محلی یاد می‌گیرد. میانگین وزن‌دار احتمال‌ها محاسبه می‌شود؛ وزن درخت‌ها یا مختصات بازنماییِ مستقل میانگین‌گیری نمی‌شوند. به این ترتیب، روش اجراشده با آموزش چنددوره‌ای FedAvg تفاوت دارد. در اجرای ثبت‌شده، سناریوی ۱۰ کلاینت بر اساس F_1 اعتبارسنجی انتخاب می‌شود و دقت آزمون آن با آستانهٔ منتخب ۵۸٫۹۱ درصد است. فقط یک بذر برای هر سناریو وجود دارد؛ عدم‌قطعیت بین اجراها از این داده قابل برآورد نیست.

در مسیر رمزنگاری، طرح‌های جمعی و ضربی ابتدا از نظر جبری تفکیک می‌شوند. سپس SBHE-Benaloh مقدارهای چهاررقم‌اعشاری را به صحیح تبدیل، محمولهٔ دارای وزن و شناسهٔ دور را امضا و پیش از تجمیع اعتبارسنجی می‌کند. نتایج طبقه‌بندی مشارکتی از تجمیع آشکارِ اعشاری و زمان‌های رمزنگاری از بنچمارک‌های عددی جداگانه به دست آمده‌اند؛ سامانهٔ رمزگذاری‌شدهٔ سرتاسریِ طبقه‌بندی در این دو آزمایش اثبات یا اندازه‌گیری نشده است.

سهم پژوهش و محدودیت‌ها

سهم اصلی، کنار هم قرار دادن ارزیابیِ قابل ممیزی، تعریف صریح توزیع دادهٔ کلاینت‌ها و تفکیک نقش احراز اصالت از همریختی است. نتیجهٔ مدل‌ها به‌جایِ اتکا به ارزیابیِ دارای نشت یا مقایسهٔ مجموعه‌های متفاوت، با پروتکل مشخص گزارش می‌شود. نتیجهٔ رمزنگاری نیز به‌جای ادعای محرمانگی مطلق، با شرط ظرفیت و مرز اعتماد سرور بیان می‌شود. معرفی ابزار دنا و مستندسازی خروجی‌ها، بازاستفادهٔ پژوهشی را تسهیل می‌کند.

دادهٔ غیربالینی و انگلیسی، یک بذر در آزمایش مشارکتی، تعداد محدود پیکربندی‌های رمزنگاری و پارامترهای کوچکِ پژوهشی، محدودیت‌های اصلی‌اند. در کلاینت‌های واقعی، ناهمگونی زبان و موضوع، تغییر توزیع زمانی، عدم توازن شدید و نمونه‌های چندگانهٔ یک کاربر می‌توانند نتیجه را تغییر دهند. امضای معتبر نیز راست‌گویی یک عضو مجاز را ثابت نمی‌کند. اثبات بازه، رمزگشایی آستانه‌ای، حریم خصوصی تفاضلی و اثبات دانش صفر در پیاده‌سازی حاضر اجرا نشده‌اند.

ساختار پایان‌نامه

فصل اول ضرورت، روش کلی و پیشینهٔ سه حوزهٔ تحلیل متن، یادگیری مشارکتی و محاسبهٔ همریخت را مرور می‌کند. فصل دوم مبانی پردازش زبان طبیعی، طراحی اصلاح‌شدهٔ ارزیابی، بازنمایی متن، طبقه‌بندها و نتایج متمرکز و مشارکتی را ارائه می‌دهد. فصل سوم به حفاظت از ورودی، تسهیم راز، فرمول‌های پنج خانوادهٔ رمزگذاری و محدودیت مقایسهٔ زمانی آن‌ها اختصاص دارد. فصل چهارم ساختار محموله، درستی و حدود امنیت SBHE-Benaloh و نتایج زمانی ذخیره‌شده را تشریح می‌کند. در پایان، پیوست‌های دنا، لگاریتم گسسته، دیفی–هلمن، باقیماندهٔ مرکب و Ed25519، همراه با اختصارات، واژه‌نامه و منابع آمده‌اند.

فصل ۱

در جست‌وجوی نشانه‌ها؛ طرح موضوع و بررسی پیشینهٔ پژوهش

۱-۱ ضرورت انجام پژوهش

خودکشی یک مسئلهٔ مهم سلامت عمومی با پیامدهای فردی و اجتماعی گسترده است. سازمان جهانی بهداشت در گزارش مورد استناد، شمار سالانهٔ جان‌باختگان را در حدود ۷۰۰ هزار نفر توصیف می‌کند و بر پیشگیری و دسترسی به حمایت تأکید دارد [۱]. این پدیده نتیجهٔ تعامل عوامل ژنتیکی، روان‌شناختی، اجتماعی و محیطی است؛ ازاین‌رو توضیح یا پیش‌بینی آن با یک نشانهٔ منفرد کافی نیست [۳]. شناسایی زودهنگام می‌تواند فرصت مداخله ایجاد کند، اما نیازمند داده و ابزار ارزیابی معتبر است.

اهمیت مسئله در گروه‌های سنی جوان نیز در آمارهای سلامت عمومی دیده می‌شود [۲، ۵]. شکل‌گیری هویت، فشارهای تحصیلی و شغلی، شروع زندگی مستقل و محدودیت مهارت‌های مقابله‌ای می‌توانند بخشی از زمینهٔ آسیب‌پذیری باشند. در کنار آن، ترس از قضاوت و انگ بیماری روانی ممکن است مراجعه به خدمات رسمی را دشوار کند. برخی افراد تجربه‌ها و احساسات خود را در محیط‌های آنلاین بیان می‌کنند؛ این رفتار امکان مطالعهٔ نشانه‌های زبانی را فراهم می‌کند، اما مجوز تفسیر قطعی وضعیت بالینی هر نویسنده نیست [۶، ۷].

شبکه‌های اجتماعی و یادداشت‌های متنی، داده‌هایی با حجم زیاد و ساختار ناهمگون ایجاد می‌کنند. پژوهش‌های زبان‌شناختی به الگوهایی مانند استفاده از ضمیر اول‌شخص، واژگان مرتبط با تنهایی، ناامیدی یا مرگ و تغییر لحن توجه کرده‌اند [۸، ۹]. روش‌های پردازش زبان طبیعی و یادگیری ماشین می‌توانند این الگوها را در چارچوب یک مجموعه‌دادهٔ برچسب‌گذاری‌شده تحلیل کنند. مزیت آن‌ها مقیاس‌پذیری تحلیل است؛ محدودیت آن‌ها نیز وابستگی به تعریف برچسب، بافت، زبان و دادهٔ آموزشی است [۱۰].

مجموعه‌دادهٔ استاندارد و نمایندهٔ همهٔ کاربران به‌سادگی در دسترس نیست. متن‌های شبکهٔ اجتماعی با مصاحبهٔ بالینی تفاوت دارند و نمونه‌گیری از یک بستر خاص می‌تواند سوگیری ایجاد کند. تفاوت فرهنگ، واژگان، سن، زمان و دسترسی کاربران به خدمات نیز بر تعمیم مدل اثر دارد. بنابراین ارزیابی باید همراه با تعریف روشنِ داده، کنترل تکرار، تفکیک کاربران یا متن‌های هم‌پوشان و بیان حدود کاربرد انجام شود. یک عدد دقت بالا، این مسائل را خودکار حل نمی‌کند.

مانع دیگر، حساسیت شدید اطلاعات سلامت روان است [۴]. افشای متن می‌تواند با انگ اجتماعی، تبعیض یا پیامدهای شخصی همراه باشد. قواعدی مانند GDPR و HIPAA نیز اهمیت تعیین هدف، دسترسی مجاز، نگهداری

مسئولانه و رضایت را نشان می‌دهند. نیاز پژوهشگر به دادهٔ متنوع باید با مسئولیت حفاظت از داده و محدودیت استفادهٔ ثانویه سازگار شود. این نیاز، انگیزه‌ای برای بررسی روش‌هایی است که ضرورت جابه‌جایی دادهٔ خام را کاهش می‌دهند.

یادگیری مشارکتی یکی از این مسیرهاست. در شکل‌های رایج آن، آموزش روی دستگاه یا سازمان محلی انجام و اطلاعاتی مانند به‌روزرسانی مدل یا خروجی پیش‌بینی به یک هماهنگ‌کننده فرستاده می‌شود. نوع اطلاعات اشتراکی به طراحی الگوریتم وابسته است. در روش این پایان‌نامه، اشتراک در سطح احتمال پیش‌بینی صورت می‌گیرد و دادهٔ آموزش کلاینت‌ها برای آموزش یک مدل واحد به سرور منتقل نمی‌شود. این طراحی با میانگین‌گیری پارامترهای مدل یکسان نیست.

باقی ماندن دادهٔ آموزش در محل، تنها یکی از لایه‌های حفاظت است. احتمال خروجی و به‌روزرسانی نیز می‌توانند اطلاعاتی حمل کنند؛ مهاجم فعال می‌تواند هویت جعل کند، وزن را تغییر دهد یا یک پیام معتبر را دوباره ارسال کند. در نتیجه، محرمانگی، اصالت، تمامیت و کنترل بازپخش باید به‌صورت جداگانه بررسی شوند. رمزگذاری همریخت، ابزار انجام محاسبه در دامنهٔ رمز و امضای دیجیتال، ابزار بررسی اصالت محموله است؛ هیچ‌کدام جای تمام کنترل‌های سامانه را نمی‌گیرد.

ضرورت پژوهش حاضر از کنار هم قرار گرفتن این نیازها ناشی می‌شود: ارزیابیِ بدون نشت برای تحلیل متن، تعریف دقیق توزیع دادهٔ کلاینت‌ها و سنجش یک روش احراز اصالت سازگار با تجمیع جمعی. هدف، گزارش یک چارچوب پژوهشیِ روشن و قابل ممیزی است. ادعای کاربرد بالینی، محرمانگی مطلق در برابر دارندهٔ کلید یا اجرای اثبات دانش صفر، از آزمایش‌های انجام‌شده نتیجه گرفته نمی‌شود.

۱-۲ نحوهٔ انجام پژوهش

پژوهش حاضر مسئلهٔ تحلیل متن‌های مرتبط با خودکشی را در دو سطح کیفیت پیش‌بینی و حفاظت از تبادل مقادیر عددی بررسی می‌کند. در سطح نخست، یک خط‌لولهٔ قابل‌بازتولید برای پاکسازی متن، یادگیری بازنمایی و مقایسهٔ طبقه‌بندها تعریف می‌شود. در سطح دوم، چند مدل محلی روی زیرمجموعه‌های جداگانهٔ داده آموزش می‌بینند و احتمال‌های خروجی آن‌ها با وزن تعداد نمونه‌های محلی تجمیع می‌شوند. توزیع طبقه‌بندی‌شدهٔ داده، امکان بررسی اثر تعداد کلاینت‌ها را با حفظ تقریبی نسبت کلاس‌ها فراهم می‌کند.

برای مقایسهٔ متمرکز، چهار خانوادهٔ جنگل تصادفی، درخت تصمیم، XGBoost و رأی‌گیری بیز ساده بررسی می‌شوند. مدل و آستانه بر اساس دادهٔ اعتبارسنجی انتخاب می‌شوند و دادهٔ آزمون تا تثبیت انتخاب نهایی کنار گذاشته می‌شود. یادگیری Word2Vec درون خط‌لوله قرار دارد؛ در اعتبارسنجی متقابل، هر بار فقط بخش آموزشیِ همان تقسیم برای یادگیری واژگان و بردارها استفاده می‌شود. این طراحی از ورود واژگان و الگوهای مجموعهٔ ارزیابی به یادگیری بازنمایی جلوگیری می‌کند.

برای آزمایش مشارکتی، سناریوهای ۱۰، ۲۰، ۵۰ و ۱۰۰ کلاینت روی مجموعهٔ آموزش ثابت تعریف شده‌اند. هر کلاینت، Word2Vec و طبقه‌بند خود را فقط روی دادهٔ محلی آموزش می‌دهد. پرسش‌های اعتبارسنجی و آزمون برای همه یکسان‌اند و سرور احتمال کلاس مثبت را با وزن اندازهٔ دادهٔ محلی ترکیب می‌کند. این پیاده‌سازی با میانگین‌گیری وزن درخت‌ها یا الگوریتم FedAvg یکسان نیست؛ واحد اشتراک در آن، احتمال پیش‌بینی است.

لایهٔ امنیتی نیز به‌صورت جداگانه بررسی می‌شود. رمزگذاری متقارن AES-GCM و تسهیم راز شامیر برای توضیح حفاظت از ورودی و مدیریت کلید به کار می‌روند. سپس طرح‌های همریخت جمعی و ضربی مقایسه می‌شوند و ساختار SBHE-Benaloh برای احراز اصالت محموله و تجمیع مجموع وزن‌دار معرفی می‌شود. امضای دیجیتال



شکل ۱-۱: جریان مشارکتیِ این آزمایش: آموزش محلی و میانگین وزن‌دار احتمال‌ها با وزن تعداد نمونه

در کنار متن رمز قرار می‌گیرد و جزئی از ضرب جبری متن‌های رمز نیست. آزمایش زمانی رمزنگاری، آزمایش طبقه‌بندی و اجرای یک سامانهٔ سرتاسری سه مفهوم متفاوت‌اند؛ نتایج هر کدام با حدود اعتبار خود گزارش می‌شوند.

۱-۳ پیشینهٔ پژوهش

۱-۳-۱ تشخیص خطر خودکشی با تحلیل متن و یادگیری ماشین

روش‌های سنتی ارزیابی خطر خودکشی به مصاحبهٔ بالینی، پرسش‌نامه، مشاهده و قضاوت متخصص متکی‌اند. ارزش این روش‌ها در دسترسی به زمینهٔ فردی و تفسیر تخصصی است، اما زمان ارزیابی، دسترسی محدود به متخصص و نبود مشاهدهٔ پیوستهٔ رفتار، کاربرد آن‌ها را در مقیاس وسیع دشوار می‌کند. تحلیل محاسباتی متن برای تکمیل مطالعهٔ نشانه‌ها مطرح شده است؛ جایگاه آن باید از تشخیص بالینی مستقل تفکیک شود.

جی و همکاران در یک مرور جامع، روش‌های یادگیری ماشین و یادگیری عمیق برای تشخیص افکار خودکشی را بررسی کردند. منابع دادهٔ مرورشده شامل پرسش‌نامه‌ها، پرونده‌های سلامت، یادداشت‌ها و محتوای تولیدشده در محیط آنلاین بودند. این تنوع نشان می‌دهد که «تشخیص خودکشی از متن» یک وظیفهٔ یکنواخت با برچسب و شرایط ثابت نیست؛ منبع داده و تعریف هدف باید در کنار معیار مدل گزارش شوند [۱۱].

هکلر و همکاران نیز در مرور نظام‌مند خود به تمرکز پژوهش‌ها بر دادهٔ شبکه‌های اجتماعی، افزایش استفاده از یادگیری عمیق و حرکت از ویژگی‌سازی دستی به استخراج خودکار ویژگی توجه کردند. در عین حال، وابستگی به دادهٔ خوداظهاری، محدودیت تعمیم و نیاز به شناسایی نشانه‌هایی فراتر از گزارش مستقیم فرد، از چالش‌های مطرح‌شده بودند [۱۲]. بنابراین رشد توان بازنمایی مدل، مسئلهٔ اعتبار برچسب و نمایندگی نمونه را حذف نمی‌کند.

انجمن‌هایی مانند Reddit به دلیل وجود متن‌های طولانی و خوداظهاری، منبع متداول پژوهش شده‌اند. مطالعات این حوزه معمولاً زنجیره‌ای از گردآوری، تعریف برچسب، پاکسازی، استخراج ویژگی، آموزش و ارزیابی را اجرا

می‌کنند [۱۳]. مرورهای مرتبط بر نقش الگوهای زبانی و امکان مطالعهٔ نشانه‌های عاطفی تأکید دارند [۱۴]. با این حال، ارزیابی بر یک بستر خاص، گواه موفقیت در زبان یا جامعهٔ دیگری نیست.

بخش مهمی از این ادبیات، داده را در محیط متمرکز در اختیار پژوهشگر قرار می‌دهد. این فرض برای توسعهٔ اولیه ساده است، اما در کاربرد سلامت روان، محدودیت مالکیت، رضایت و محرمانگی ایجاد می‌کند. متون ممکن است اطلاعات شخصی، پزشکی و عاطفی را هم‌زمان حمل کنند. ازاین‌رو افزایش دقت، بدون توجه به محل پردازش و نوع اطلاعات مبادله‌شده، مسئلهٔ حفاظت از داده را کامل پاسخ نمی‌دهد.

۱-۳-۲ یادگیری مشارکتی در حوزهٔ سلامت

مک‌ماهان و همکاران، آموزش مدل از داده‌های توزیع‌شده با به‌روزرسانی‌های محلی و تجمیع را به‌صورت نظام‌مند بررسی کردند [۱۵]. در این چارچوب، دادهٔ خام لازم نیست برای ساخت یک مخزن آموزشی واحد منتقل شود. روش‌های مشخص، در نوع مدل، تعداد دور، شیوهٔ تجمیع و فرض توزیع داده متفاوت‌اند. بنابراین هر پیاده‌سازی که چند کلاینت دارد الزاماً همان الگوریتم FedAvg نیست.

در سلامت دیجیتال، داده‌ها معمولاً در بیمارستان‌ها، مراکز درمانی و سازمان‌های مستقل نگهداری می‌شوند. ریک و همکاران، جدایی این منابع و موانع حقوقی، اخلاقی و سازمانی انتقال داده را از انگیزه‌های مهم یادگیری مشارکتی دانسته‌اند [۱۶]. امکان همکاری بدون متمرکزسازیِ متن خام، یک مزیت بالقوه است؛ در مقابل، سازگاری قالب، کیفیت متفاوت داده و محدودیت ارتباط باید در طراحی لحاظ شوند.

کایروز و همکاران در بررسی جامع خود به ارتباطات، ناهمگونی، حریم خصوصی، امنیت و مقیاس‌پذیری پرداخته‌اند [۱۷]. محلی ماندن آموزش می‌تواند اصل حداقل‌سازی دادهٔ انتقالی را تقویت کند، اما به‌روزرسانی یا خروجی محلی نیز ممکن است اطلاعات حساس حمل کند. حملهٔ استنتاج عضویت، وارون‌سازی مدل یا تحلیل خروجی، نمونه‌هایی از علت نیاز به مدل تهدیدِ صریح‌اند.

کاربرد یادگیری مشارکتی در سلامت روان، از جمله تشخیص افسردگی با مدل‌های زبانی و پست‌های شبکهٔ اجتماعی، نیز بررسی شده است. مطالعهٔ مورد ارجاع، داده‌های مستقل و غیرهم‌توزیع را در چارچوبی برای همکاری منابع داده مطرح می‌کند [۱۸]. این پیشینه، انگیزه‌ای برای سنجش روش‌های توزیع‌شده فراهم می‌کند؛ نتیجهٔ یک وظیفهٔ سلامت روان را نمی‌توان بی‌واسطه به وظیفهٔ دیگر یا به جمعیت بالینی تعمیم داد.

برای مسئلهٔ حاضر، نوع تقسیم کلاینت اهمیت ویژه دارد. تعداد کلاینت، اندازهٔ دادهٔ محلی و نسبت کلاس‌ها باید هم‌زمان گزارش شوند. تقسیم تصادفیِ طبقه‌بندی‌شده برای مطالعهٔ اثر اندازه مناسب است، اما تفاوت واقعی کاربران، موضوع، زبان و زمان را شبیه‌سازی نمی‌کند. بخش مشارکتی این پایان‌نامه، همین محدودهٔ آزمایش را روشن نگه می‌دارد.

۱-۳-۳ رمزگذاری همریخت و محاسبات حفظ‌کنندهٔ حریم خصوصی

ویژگی اصلی رمزگذاری همریخت، سازگاری برخی عملیات بر متن رمز با عملیات مشخص بر پیام است. پاییه یک نمونهٔ مهمِ همریختی جمعی است که امکان ساخت متن رمزِ مجموع را فراهم می‌کند [۱۹]. این تناسب برای آمارگیری و تجمیعِ خروجی‌های عددی مفید است، اما نوع عملیات و فضای پیام باید با تابع مورد نظر سازگار باشند.

معرفی رمزگذاری کاملاً همریخت، چشم‌انداز انجام توابع پیچیده‌تر در دامنهٔ رمز را گسترش داد [۲۰]. با این حال، قابلیت نظریِ محاسبهٔ عمومی با هزینهٔ یک جمع وزن‌دار در یک طرح جزئی همریخت یکسان نیست. انتخاب ابزار باید به تابع، پارامتر امنیت، نمایش عددی و هزینهٔ مورد قبول توجه کند؛ پیچیده‌تر بودن ساختار، به‌تنهایی مزیت عملی

برای هر کاربرد ایجاد نمی‌کند.

مرورهای کاربرد رمزگذاری همریخت در یادگیری ماشین پزشکی و زیست‌اطلاعات، ظرفیت این روش‌ها را برای طبقه‌بندی، تحلیل دادهٔ ژنتیکی و پردازش اطلاعات حساس بررسی کرده‌اند [۲۱]. مرورهای حوزهٔ سلامت نیز تفاوت پردازش بر متن رمز با الگوی «ابتدا رمزگشایی، سپس محاسبه» را برجسته می‌کنند [۲۲]. در عین حال، مشخص بودن دارندهٔ کلید خصوصی و اطلاعاتی که از خروجی نهایی آشکار می‌شود، برای تفسیر محرمانگی ضروری است.

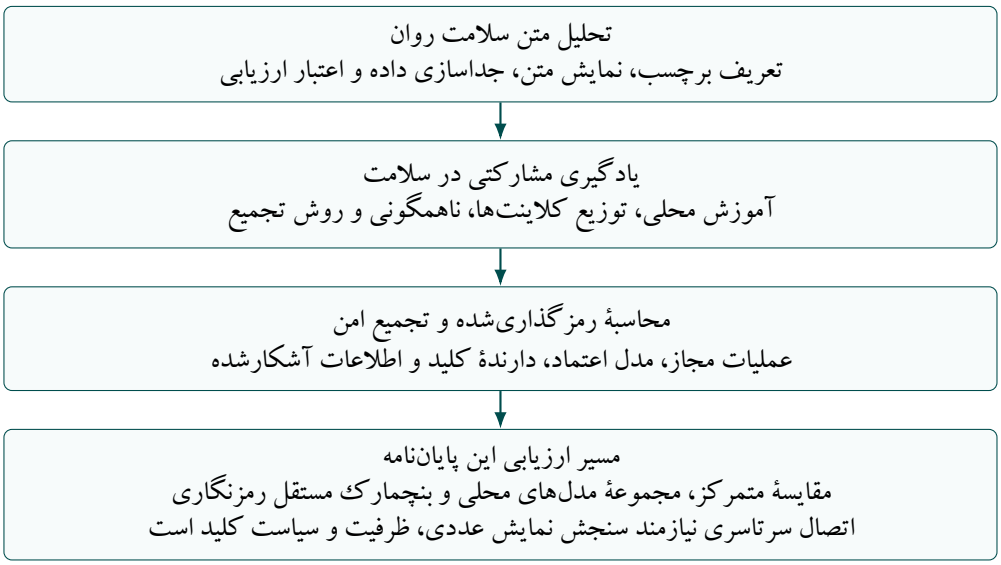
۱-۳-۴ تجمیع امن و ترکیب آن با یادگیری مشارکتی

در تجمیع امن، هدف آن است که تابعی از مشارکت‌ها محاسبه شود و دسترسی به مقادیر منفرد مطابق مدل اعتماد محدود بماند. پروتکل بوناویتز و همکاران نمونه‌ای مهم در یادگیری ماشین حفظ‌کنندهٔ حریم خصوصی است [۱۸۸]. این ادبیات نشان می‌دهد که «سرور هماهنگ‌کننده است» و «سرور باید تمام خروجی‌های منفرد را بداند» دو فرض یکسان نیستند.

روش‌های تجمیع امن ممکن است از تسهیم راز، پوشان‌سازی، رمزگذاری یا ترکیب آن‌ها استفاده کنند. تحمل خروج عضو، تبانی، پایداری وضعیت و اطلاعات آشکارشده از مجموع، در هر طرح متفاوت است. ازاین‌رو یک امضای معتبر یا یک ضرب همریخت، جایگزین تعریف کامل پروتکل و مدل تهدید نمی‌شود. در پیاده‌سازی این پایان‌نامه، سرور کلید خصوصی بنالوح را نگه می‌دارد و این تفاوت با طرح‌های دارای حفاظت در برابر سرور، صریحاً بیان می‌شود.

۱-۳-۵ جمع‌بندی پیشینه و شکاف پژوهشی

سه جریان اصلی در پیشینه دیده می‌شوند: تحلیل زبانیِ نشانه‌های خطر، همکاری منابع داده بدون متمرکزسازی آموزش و محاسبهٔ رمزگذاری‌شده یا تجمیع امن. جریان نخست به نمایش و کیفیت پیش‌بینی، جریان دوم به محل یادگیری و ناهمگونی و جریان سوم به اطلاعات قابل مشاهده و مدل اعتماد می‌پردازد. ارزیابی یک سامانهٔ ترکیبی باید این سه دامنه را به هم مرتبط کند، اما معیارهای آن‌ها را با هم اشتباه نگیرد.



شکل ۱-۲: رابطهٔ سه حوزهٔ پیشینه با مسیرهای ارزیابی پژوهش حاضر

نیاز پژوهشیِ مورد توجه، تعریف یک مسیر قابل ممیزی است: مقایسهٔ مدل با جداسازی درست داده، تعریف دقیق

تخصیص کلاینت، گزارش احتمال تجمیعی و بررسی احراز اصالتِ سازگار با همریختی. این صورت‌بندی، ادعای نخستین ترکیب این حوزه‌ها در تمام ادبیات نیست. سهم این مخزن در پیاده‌سازی، مستندسازی پیش‌شرط‌ها و گزارش نتایج مشخصِ آزمایش‌ها ارزیابی می‌شود.

هدف معماری، کاهش نیاز به انتقال دادهٔ آموزش و بررسی حفاظت از مشارکت‌های عددی است. رسیدن به یک سرویس امنِ سرتاسری مستلزم سازگاری وزن، ظرفیت پیام، کوانتیزه‌سازی، مدیریت هویت و سیاست رمزگشایی است. نتیجهٔ طبقه‌بندی، نتیجهٔ بنچمارک رمزنگاری و تحلیل امنیتی، در ادامهٔ پایان‌نامه با همین تفکیک گزارش می‌شوند.

۱-۴ صورت‌بندی پرسش‌ها و دامنهٔ اعتبار

پرسش نخست این است که با یک روش ارزیابی بدون نشت داده، کدام طبقه‌بند و آستانه بر دادهٔ اعتبارسنجی مناسب‌تر است و عملکرد آن انتخابِ تثبیت‌شده در آزمون چه اندازه است. پرسش دوم اثر کاهش اندازهٔ دادهٔ محلی بر کیفیت پیش‌بینی تجمیع‌شده است. پرسش سوم، هزینه و محدودیت‌های پارامترهای یک پروتکل احراز اصالت و تجمیع همریخت است. هیچ‌یک از این پرسش‌ها به‌تنهایی اثبات نمی‌کند که طبقه‌بند برای تصمیم‌گیری بالینی آماده است یا سرورِ مالک کلید خصوصی از نظر رمزنگاری قادر به رمزگشایی خروجی منفرد نیست.

مدل تهدید، نقش مالک کلید خصوصی، شرط ظرفیت فضای پیام و تفاوت میان صحت امضا و صحت محتوای پیش‌بینی باید صریح بمانند. همچنین، آزمایش هم‌توزیع، جایگزین بررسی ناهمگونی واقعی کاربران، زبان‌ها، سازمان‌ها یا بازه‌های زمانی نیست. این محدودیت‌ها مبنای پیشنهادهای توسعهٔ آتی در پایان پژوهش قرار می‌گیرند.

فصل ۲

واژه‌ها را بشنو؛ مبانی و ارزیابی تحلیل متن و یادگیری مشارکتی

۲-۱ مبانی و تاریخچهٔ پردازش زبان طبیعی

پردازش زبان طبیعی، حوزه‌ای میان‌رشته‌ای از علوم کامپیوتر، هوش مصنوعی و زبان‌شناسی است که تحلیل، درک و تولید زبان انسانی را با روش‌های محاسباتی بررسی می‌کند. زبان تنها دنباله‌ای از نشانه‌ها نیست؛ معنای واژه و جمله به ساختار، بافت، دانش زمینه و گاه هدف گوینده وابسته است. ازاین‌رو تبدیل متن به یک نمایش عددی، همواره با انتخاب‌هایی دربارهٔ اطلاعات حفظ‌شده و اطلاعات ازدست‌رفته همراه است [۲۴، ۲۵].

در تحلیل سلامت روان، این مسئله اهمیت بیشتری دارد. واژهٔ منفرد، نفی، اشاره به خود یا دیگری و ترتیب جمله می‌توانند تفسیر متفاوتی ایجاد کنند. حضور یک واژهٔ مرتبط با خودکشی لزوماً نشان‌دهندهٔ افکار شخصی نویسنده نیست؛ نقل قول، خبر، بحث حمایتی یا تجربهٔ گذشته نیز ممکن است همان واژگان را داشته باشند. بنابراین نتیجهٔ طبقه‌بند باید در دامنهٔ برچسب‌گذاری داده و محدودیت بازنمایی آن تفسیر شود.

۲-۱-۱ وظایف اصلی و پیوند میان آن‌ها

درک زبان طبیعی به استخراج معنا و ساختار از ورودی و تولید زبان طبیعی به ساخت خروجی زبانی می‌پردازد. ورودی می‌تواند متن یا گفتار باشد؛ تشخیص گفتار و تشخیص نوری نویسه‌ها، مسیرهای تبدیل ورودی به متن‌اند، نه تعریف تمام سطوح پردازش زبان. برخی وظایف مهم عبارت‌اند از واژه‌سازی، تحلیل صرفی، برچسب‌گذاری نقش دستوری، تحلیل نحوی، تشخیص موجودیت نامدار، رفع هم‌مرجعی، تحلیل گفتمان، ترجمه و خلاصه‌سازی.

خلاصه‌سازی، نمایش کوتاه‌تری از متن با حفظ اطلاعات مورد نظر ایجاد می‌کند. رفع هم‌مرجعی مشخص می‌کند کدام عبارت‌ها به یک موجودیت اشاره دارند؛ برای نمونه، مرجع یک ضمیر ممکن است تنها از جمله‌های قبل روشن شود. تحلیل گفتمان روابط میان جمله‌ها، رویدادها و نقش آن‌ها در انسجام متن را بررسی می‌کند. ترجمهٔ ماشینی نیز باید علاوه بر واژه‌ها، ساختار و تفاوت کاربرد زبان‌ها را مدیریت کند.

تحلیل صرفی، ساختار واژه و اجزای آن را بررسی می‌کند. برچسب‌گذاری نقش دستوری به هر توکن نقشی مانند اسم یا فعل نسبت می‌دهد. تشخیص موجودیت نامدار، بخش‌هایی مانند نام فرد، سازمان و مکان را شناسایی می‌کند. این وظایف به هم وابسته‌اند؛ برای مثال شناخت موجودیت می‌تواند به رفع هم‌مرجعی کمک کند و تحلیل ساختار

جمله می‌تواند بر تفسیر نفی اثر بگذارد. خط‌لولهٔ یک کاربرد الزاماً همهٔ این مراحل را اجرا نمی‌کند.

در یک معماری پیمانه‌ای، خروجی هر ابزار به ورودی ابزار بعد تبدیل می‌شود. راسپوچر و همکاران نمونه‌ای از استخراج رویداد میان‌زبانی برای انگلیسی، هلندی و ایتالیایی را بررسی کرده‌اند که پردازش پایه، پیوند موجودیت، نقش‌های معنایی و نرمال‌سازی زمانی را به نمایش دانش رویدادمحور متصل می‌کند [۲۶]. چنین معماری‌ای امکان جایگزینی ماژول و پیکربندی خط‌لوله را فراهم می‌کند، اما سازگاری قالب و انباشت خطای مراحل نیز باید بررسی شود.

ابهام می‌تواند واژگانی، نحوی یا وابسته به بافت باشد. یک واژه ممکن است چند معنا داشته باشد و یک جمله بیش از یک ساختار نحوی بپذیرد. روش‌ها می‌توانند ابهام را زود کاهش دهند، چند تفسیر را نگه دارند، با کاربر تعامل کنند یا به تفسیرها وزن احتمالی بدهند [۲۷]. هیچ انتخابی برای همهٔ کاربردها بهترین نیست؛ نگه داشتن تفسیرهای بیشتر هزینه را افزایش می‌دهد و حذف زودهنگام ابهام می‌تواند اطلاعات لازم را از بین ببرد.

۲-۱-۲ سیر تاریخی و تحول روش‌ها

پژوهش‌های ترجمهٔ ماشینی از دهه‌های میانی قرن بیستم، به‌ویژه برای زوج‌زبان‌هایی مانند روسی و انگلیسی، یکی از محرک‌های اولیهٔ این حوزه بودند. گزارش ALPAC در ۱۹۶۶ به کاهش حمایت از بخشی از فعالیت‌های ترجمهٔ ماشینی انجامید؛ با این حال، به معنای پایان تمام پژوهش‌های زبان طبیعی نبود. کاربردهای محدودتر و مطالعات زبان‌شناختی و ادبیِ رایانه‌ای ادامه یافتند [۲۸، ۲۹]. سامانه‌های پرسش‌پاسخ و رابط زبان طبیعی برای پایگاه داده، نمونه‌هایی از پژوهش‌های دامنه‌محور این دوره‌اند [۳۰، ۳۱، ۳۲].

در دههٔ ۱۹۸۰، دستور زبان محاسباتی، معناشناسی، مدل‌سازی دانش و هدف کاربر گسترش یافتند. سامانه‌هایی مانند Core Language Engine و نظریهٔ بازنمایی گفتمان، ابزارهایی برای تحلیل فراتر از واژه و جملهٔ منفرد فراهم کردند [۳۳، ۳۴]. ابزارهای زبانی و ارزیابی‌های برنامه‌های پژوهشی، از جمله Alvey و ARPA، به توسعهٔ روش‌های قابل مقایسه کمک کردند [۳۵، ۳۶، ۳۷]. مدل‌سازی کاربر و تولید متن منسجم نیز به شناخت نقش بافت و ساختار گفتمان افزودند [۳۸، ۳۹، ۴۰].

در دههٔ ۱۹۹۰، روش‌های آماری، استفاده از پیکره و ارزیابی تجربی جایگاه پررنگ‌تری یافتند. رفع ابهام معنایی، استخراج اطلاعات و خلاصه‌سازی از حوزه‌های متأثر از این تحول بودند [۴۱، ۴۲، ۴۳]. در ادامه، بازنمایی‌های توزیعی واژه و سپس مدل‌های عصبی زمینه‌مند امکان یادگیری ویژگی را افزایش دادند [۷۸، ۸۱، ۸۲]. این تحول، نیاز به جداسازی درست دادهٔ آموزش و ارزیابی را کاهش نداد؛ هر بخشی که از پیکره چیزی یاد می‌گیرد می‌تواند منشأ نشت اطلاعات باشد.

۲-۱-۳ از چارچوب عمومی تا آزمایش این پژوهش

در این پایان‌نامه، واژه‌سازی ساده و میانگین بردار Word2Vec انتخاب شده است. این انتخاب تحلیل نحوی یا درک کامل معنا را اجرا نمی‌کند؛ هدف آن ساخت یک بازنمایی فشرده برای مقایسهٔ طبقه‌بندها و آموزش مستقل مدل‌های محلی است. روش‌های TF-IDF، Sentence-BERT و مدل‌های زمینه‌مند، در جایگاه پیشینه و گزینه‌های جایگزین مطرح‌اند و معیارهای آزمایش حاضر به آن‌ها نسبت داده نمی‌شوند.

شکل ۲-۱ ترتیب اجرایی نسخهٔ اصلاح‌شده را نشان می‌دهد. جایگاه تقسیم داده و یادگیری بازنمایی عمداً روشن است: پیکرهٔ آزمون به آموزش واژگان و انتخاب مدل وارد نمی‌شود. ابزار دنا نیز از این مسیر اصلی جداست. بخش‌های بعد، تعریف پاکسازی، ابعاد بازنمایی، فضای جست‌وجوی مدل‌ها و قاعدهٔ انتخاب آستانه را به‌صورت دقیق ارائه

می‌کنند.

۲-۲ طراحی آزمایش و آماده‌سازی داده

مبنای گزارش متمرکز، کد نوت‌بوک finding-the-best-model-fixed.ipynb است [۱۸۳]. مجموعه‌دادهٔ Sui-cide Watch شامل ۰۷۴٬۲۳۲ ردیف خام با دو کلاس non-suicide و suicide است. برچسب‌ها به‌ترتیب به صفر و یک نگاشت می‌شوند. شمارش ردیف‌ها از گزارش بارگذاری، حذف تکرار و جداسازی بخش‌ها به دست می‌آید.

متن‌های تهی و برچسب‌های نامعتبر بررسی می‌شوند. برای تشخیص تکرار خام، نرمال‌سازی سازگاری یونیکد، یکسان‌سازی حالت حروف و فاصله‌ها انجام می‌شود. متن‌های تکراری با برچسب متعارض کنار گذاشته می‌شوند و از هر متن تکراریِ هم‌برچسب فقط یک ردیف باقی می‌ماند. ۹۳ ردیف تکراری خام حذف می‌شود و ۹۸۱٬۲۳۱ ردیف برای تقسیم اولیّه باقی می‌ماند.

تقسیم نخست، ۲۰ درصد را برای آزمون نگه می‌دارد. از ۸۰ درصد توسعه، ۲۰ درصد برای اعتبارسنجی کنار گذاشته می‌شود؛ بنابراین سهم‌های اسمی آموزش، اعتبارسنجی و آزمون ۶۴، ۱۶ و ۲۰ درصد است. بذر تقسیم ۴۲ و روش تقسیم طبقه‌بندی‌شده است. پیش از پاکسازی، تعداد ردیف‌های این سه بخش به‌ترتیب ۴۶۷٬۱۴۸، ۱۱۷٬۳۷ و ۳۹۷٬۴۶ است. پس از پاکسازی و حذف هم‌پوشانی، تعدادهای نهایی به‌ترتیب ۳۸۰٬۱۴۸، ۰۸۶٬۳۷ و ۳۴۲٬۴۶ هستند. جدول ۲-۷ توزیع کلاس‌ها را نشان می‌دهد.

۲-۲-۱ پاکسازی ثابت و جلوگیری از نشت داده

پاکسازی هر متن مستقل از برچسب و دیگر متن‌ها انجام می‌شود. ابتدا کدهای HTML بازگشایی و یونیکد با NFKC نرمال می‌شود. حروف به حالت کوچک تبدیل می‌شوند. نشانه‌های نقل‌قول یکسان‌سازی و برچسب‌های HTML، نشانی وب، نشانی رایانامه و شناسه‌های کاربری با فاصله جایگزین می‌شوند. صورت‌های متداول نفی در انگلیسی پیش از حذف نشانه‌گذاری باز می‌شوند؛ برای نمونه، can’t به can not و won’t به will not تبدیل می‌شود. سپس نویسه‌های غیرواژگانی حذف، زیرخط به فاصله تبدیل و فاصله‌های پیاپی یکسان می‌شوند.

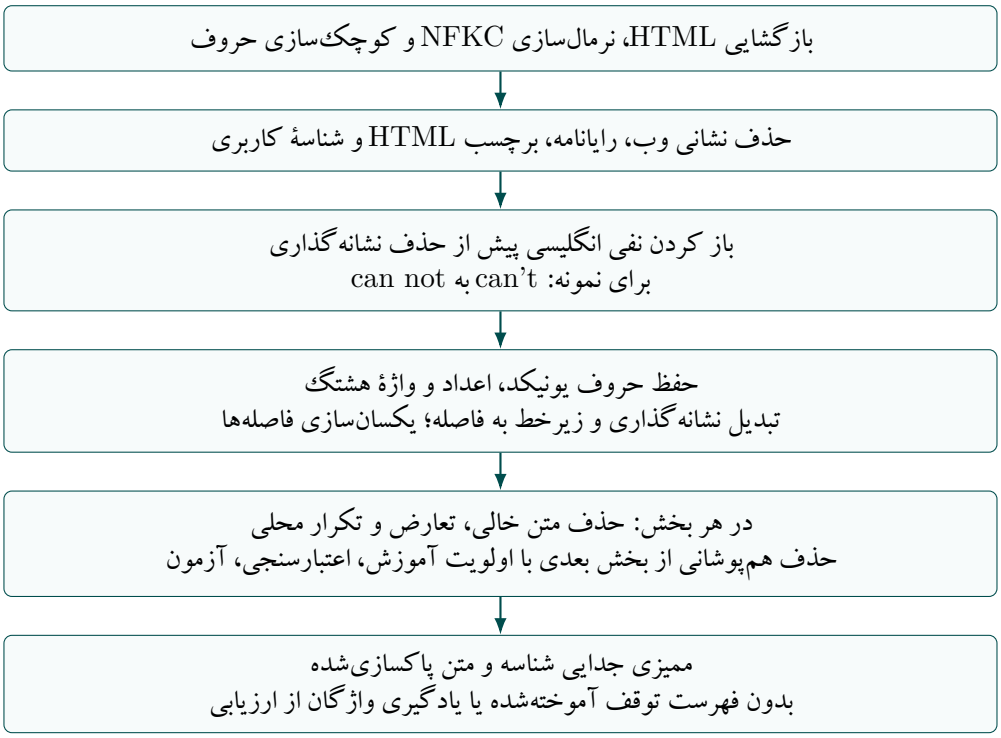
اعداد و حروف یونیکد در پاکسازی حفظ می‌شوند و فهرست آموخته‌شده‌ای از کلمات توقف وجود ندارد. حذف بی‌قید واژهٔ نفی می‌تواند معنای متن را وارونه کند؛ بنابراین فهرست توقف «دنا» در مسیر اصلی این آزمایش فراخوانی نمی‌شود. «دنا» یک ابزار جانبی فارسی است که در پیوست معرفی می‌شود و نتیجهٔ آن نباید با نتیجهٔ آزمایش انگلیسی حاضر یکی فرض شود.

پس از پاکسازی، ترتیب رسیدگی ثابتِ آموزش، اعتبارسنجی و آزمون اعمال می‌شود. متن‌های خالی و تکرارهای محلی حذف می‌شوند؛ اگر پاکسازی باعثِ یکسان شدن متنی با بخش قبلی شود، نمونه از بخش بعدی حذف می‌شود. متن‌های دارای برچسب متعارض تنها در همان بخش بررسی می‌شوند. بدین ترتیب، متن نگه‌داشته‌شدهٔ آزمون سبب حذف یا تغییر نمونهٔ آموزشی نمی‌شود. نبود هم‌پوشانی هم بر اساس شناسهٔ ردیف و هم بر اساس متن پاکسازی‌شده کنترل می‌شود.

شکل ۲-۲ جریان تابع clean_text و ممیزی بخش‌ها را نشان می‌دهد. اعداد و واژه‌های نفی در این مسیر حفظ می‌شوند.



شکل ۲-۱: جریان اصلاح‌شدهٔ آزمایش متن؛ جداسازی ارزیابی پیش از یادگیری بازنمایی انجام می‌شود



شکل ۲-۲: جریان پاکسازی و ممیزی نسخهٔ اصلاح‌شده؛ قواعد به برچسب ارزیابی وابسته نیستند

۲-۲-۲ واژه‌سازی و دامنهٔ زبانی

پس از پاکسازی، رشته بر اساس فاصله به توکن‌ها تقسیم می‌شود. این واژه‌ساز کم‌هزینه و قابل‌بازتولید است، اما تجزیهٔ صرفی، رفع ابهام، تشخیص موجودیت یا مدل‌سازی زیرواژه‌ای انجام نمی‌دهد. خطاهای املایی و تفاوت صورت‌های واژگانی می‌توانند اندازهٔ واژگان را افزایش دهند و واژه‌های کم‌فراوان را از پوشش مدل خارج کنند. یکسان‌سازی فاصله‌ها و نشانه‌ها این مسئله را کاهش می‌دهد، اما جایگزین تحلیل زبانی کامل نیست.

حفظ حروف یونیکد در کد به معنای ارزیابی موفق همهٔ زبان‌ها نیست. دادهٔ این آزمایش انگلیسی است و معیارهای آن نباید به فارسی، عبری یا عربی تعمیم داده شوند. برای چنین ادعایی به پیکرهٔ مستقل، برچسب‌های معتبر و ارزیابی اختصاصی هر زبان نیاز است. این تمایز، مرز میان قابلیت فنی پردازش رشتهٔ یونیکد و شاهد تجربی چندزبانه بودن را روشن می‌کند.

۲-۳ بردارسازی مبتنی بر Word2Vec

Word2Vec یک روش بازنمایی توزیعی واژه‌هاست که روابط هم‌وقوعی واژگان را از پیکره می‌آموزد [۷۸]. به هر واژهٔ w برداری $v_w \in \mathbb{R}^d$ اختصاص می‌یابد. در این پژوهش $d = 100$ است. تمام طبقه‌بندهای این آزمایش ورودی صدبعدی دارند.

در معماری CBOW، واژهٔ هدف از بافت پیش‌بینی می‌شود و در معماری Skip-Gram، واژه‌های بافت از واژهٔ مرکزی پیش‌بینی می‌شوند. پیاده‌سازی حاضر از Skip-Gram با sg=1 استفاده می‌کند. صورت مفهومی تابع هدف

آن را می‌توان چنین نوشت:

$$\max \sum_{t=1}^{T} \sum_{\substack{-c \le j \le c \\ j \neq 0}} \log P(w_{t+j} \mid w_t), \qquad P(w_o \mid w_i) = \frac{\exp(u_{w_o}^{\mathsf{T}} v_{w_i})}{\sum_{w \in V} \exp(u_w^{\mathsf{T}} v_{w_i})}. \tag{۱-۲}$$

این رابطه توضیح مفهومی هدف توزیعی است؛ کتابخانه می‌تواند برای کاهش هزینه از تقریب‌هایی مانند نمونه‌گیری منفی استفاده کند. مدل حاضر شبکهٔ کم‌عمقِ واژه‌محور است و همان مدل زمینه‌مند چندلایهٔ خانوادهٔ Transformer نیست.

پارامترهای بازنمایی عبارت‌اند از پنجرهٔ ۵، حداقل فراوانی ۲، پنج دورهٔ آموزش، یک کارگر و بذر ۴۲ برای مدل متمرکز. پنجره، محدودهٔ بافتی را مشخص می‌کند؛ حداقل فراوانی، واژه‌های بسیار کم‌تکرار را از واژگان کنار می‌گذارد. افزایش ابعاد یا تعداد دوره‌ها می‌تواند هزینهٔ محاسبات و حافظه را افزایش دهد و به‌تنهایی تضمین‌کنندهٔ بهبود طبقه‌بندی نیست.

۲-۳-۱ تبدیل بردار واژه به بردار سند

اگر سند x شامل توکن‌های $w_1, \dots, w_n$ باشد و $I(x)$ مجموعهٔ جایگاه‌های دارای واژهٔ شناخته‌شده در واژگان آموزشی V باشد، نمایش سند برابر است با

$$\phi(x) = \begin{cases} \dfrac{1}{|I(x)|} \displaystyle\sum_{j \in I(x)} v_{w_j}, & |I(x)| > 0, \\ \mathbf{0} \in \mathbb{R}^{100}, & |I(x)| = 0. \end{cases} \tag{۲-۲}$$

مخرج، تعداد توکن‌های شناخته‌شده است؛ تقسیم بر تعداد تمام توکن‌ها با وجود واژه‌های ناشناخته، همان الگوریتم اجراشده نیست. توکن تکرارشده به تعداد وقوع خود در میانگین نقش دارد. طول سند تغییر می‌کند، اما طول بردار نهایی ثابت و برابر ۱۰۰ است.

میانگین‌گیری ترتیب واژه‌ها را در نمایش نهایی حفظ نمی‌کند. دو متن با واژگان مشابه و ترتیب متفاوت ممکن است بردارهای نزدیکی داشته باشند. چندمعنایی واژه‌ها نیز در بازنمایی ایستای واژه به‌صورت کامل حل نمی‌شود. در مقابل، هزینهٔ محاسباتی و حافظه نسبت به بسیاری از مدل‌های جمله‌محور کمتر است و نمایش فشرده برای طبقه‌بندهای درختی و بیزی فراهم می‌شود. انتخاب این روش، یک مبادلهٔ روش‌شناختی است و نباید برتری مطلق آن بر TF-IDF یا Sentence-BERT نتیجه گرفته شود.

۲-۳-۲ محل یادگیری بازنمایی و ممیزی واژگان

توکن‌سازی، MeanWord2Vec و طبقه‌بند در یک شیء Pipeline قرار می‌گیرند. در هر تقسیم اعتبارسنجی متقابل، fit بازنمایی فقط بر متن‌های بخش آموزشی همان تقسیم اجرا می‌شود. متن‌های بخش اعتبارسنجی آن تقسیم صرفاً transform می‌شوند. پس از انتخاب فراپارامترها، مدل نهایی روی آموزش کامل بازبرازش می‌شود. حافظهٔ نهان فقط برای بازاستفاده از تبدیل‌های یکسانِ همان تقسیم است و اجازهٔ استفاده از واژگان بخش نگه‌داشته‌شده را نمی‌دهد.

در پایان، واژگان مدل منتخب با مجموعهٔ توکن‌های آموزش مقایسه می‌شوند. باید $V \subseteq V_{\text{train}}$ و $V \cap (V_{\text{heldout}} \setminus V_{\text{train}}) = \varnothing$ برقرار باشد. پوشش توکن و سهم سندهای کاملاً ناشناخته جداگانه گزارش می‌شوند.

این کنترل، یک آزمون مشخص برای نشت واژگان است؛ جایگزین تمام بررسی‌های ممکن نشت داده یا تعمیم‌پذیری نیست.

۲-۴ معیارهای ارزیابی و انتخاب مدل

کلاس مثبت، برچسب suicide با مقدار یک است. اگر TP و TN تعداد پیش‌بینی‌های صحیح مثبت و منفی و FP و FN تعداد مثبت و منفی کاذب باشند، معیارهای اصلی از روابط زیر محاسبه می‌شوند:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{۲-۳}$$

$$\text{Precision}_+ = \frac{TP}{TP + FP}, \qquad \text{Recall}_+ = \frac{TP}{TP + FN}, \tag{۲-۴}$$

$$F_{1,+} = \frac{2TP}{2TP + FP + FN}, \qquad \text{Specificity} = \frac{TN}{TN + FP}. \tag{۲-۵}$$

در حالت مخرج صفر، مطابق پیاده‌سازی، مقدار صفر گزارش می‌شود. میانگین کلان، میانگین سادهٔ معیار دو کلاس است؛ میانگین وزن‌دار از تعداد نمونهٔ واقعی هر کلاس وزن می‌گیرد. دقت متوازن نیز میانگین بازیابی دو کلاس است. در دادهٔ نامتوازن، دقت کلی به‌تنهایی می‌تواند گمراه‌کننده باشد؛ بنابراین بازیابی و F_1 کلاس مثبت، تعداد خطاها و معیارهای رتبه‌بندی نیز بررسی می‌شوند [۱۱۱، ۱۱۷، ۱۱۸، ۱۱۹].

ROC AUC توان رتبه‌بندی نمونهٔ مثبت بالاتر از نمونهٔ منفی را در دامنه‌ای از آستانه‌ها خلاصه می‌کند. Average Precision یا AP خلاصه‌ای از منحنی دقت مثبت–بازیابی است؛ با مساحت ذوزنقه‌ای هر منحنی دلخواه یکسان فرض نمی‌شود. این معیارها از احتمال‌ها محاسبه می‌شوند، در حالی که دقت، بازیابی، F_1 و ماتریس سردرگمی به آستانه وابسته‌اند.

۲-۴-۱ سه سطح جداسازی ارزیابی

فراپارامترهای درخت تصمیم و XGBoost با جست‌وجوی تصادفی ۱۰ ترکیب و اعتبارسنجی طبقه‌بندی‌شدهٔ سه‌بخشی فقط روی آموزش تنظیم می‌شوند. معیار این جست‌وجو، F_1 کلاس مثبت در آستانهٔ پیش‌فرض طبقه‌بند است. سپس برای هر مدل بازبرازش‌شده، آستانه از ۱۰۱ مقدار صفر تا یک روی اعتبارسنجی مستقل انتخاب می‌شود. در آخر، مدل‌ها با ترتیبِ $F_{1,+}$، $F_{1,\text{macro}}$، ROC AUC و نام مدل رتبه‌بندی می‌شوند. انتخاب نهایی پیش از مشاهدهٔ معیار آزمون تثبیت می‌شود [۱۲۲].

دادهٔ آزمون برای انتخاب بهترین مدل از میان چهار مدل استفاده نمی‌شود. به همین دلیل، جدول مقایسهٔ هر چهار مدل در این نسخه مربوط به اعتبارسنجی است و ارزیابی نهایی آزمون برای مدل منتخب ارائه می‌شود. مقایسهٔ مدل‌ها باید بر مجموعهٔ مشترک و با نقش ارزیابی یکسان انجام شود.

۲-۵ الگوریتم‌های یادگیری ماشین

۲-۵-۱ جنگل تصادفی

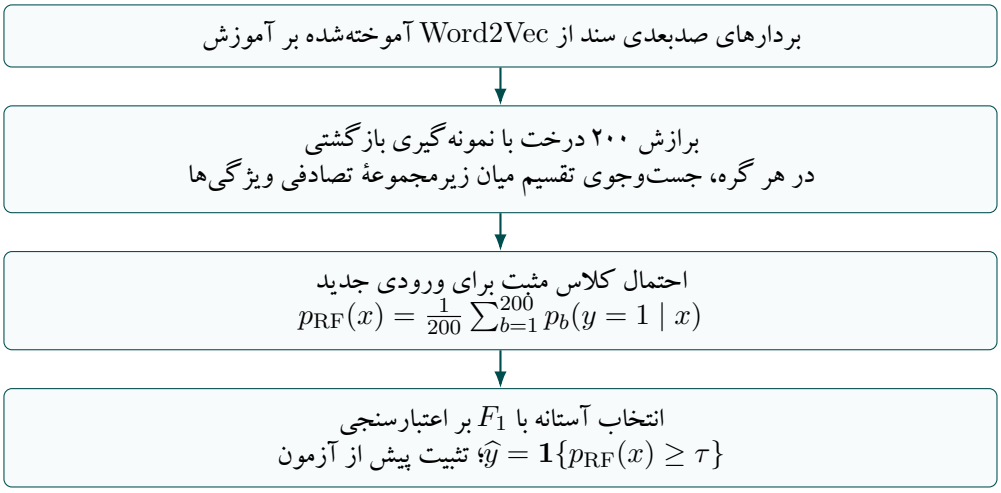
جنگل تصادفی، مجموعه‌ای از درخت‌های تصمیم است که با نمونه‌گیری بازگشتی از آموزش و انتخاب تصادفی زیرمجموعهٔ ویژگی‌ها در گره‌ها، هم‌بستگی خطای درخت‌ها را کاهش می‌دهد. ریشهٔ این روش در ترکیب نمونه‌گیری bootstrap و ایده‌های مجموعه‌مدل است و صورت شناخته‌شدهٔ آن با کار بریمن گسترش یافت [۱۰۳، ۱۰۴، ۱۰۸]. هدف، کاهش واریانس درخت منفرد بدون الزام به ساخت یک مدل خطی است.

اگر درخت b احتمال $p_b(y = 1 \mid x)$ را برآورد کند، احتمال خروجی جنگل با B درخت به‌صورت میانگین آن‌ها محاسبه می‌شود:

$$p_{\mathrm{RF}}(x) = \frac{1}{B} \sum_{b=1}^{B} p_b(y = 1 \mid x), \qquad \widehat{y} = \mathbf{1}\{p_{\mathrm{RF}}(x) \geq \tau\}. \tag{۶-۲}$$

این احتمال لزوماً احتمال بالینیِ کالیبره‌شده نیست. تنظیم آستانه، برچسب خروجی را تغییر می‌دهد و به‌خودی‌خود کالیبراسیون احتمال انجام نمی‌دهد. در نسخهٔ اجراشده، جنگل ۲۰۰ درخت دارد، بذر ۴۲ و تعداد پردازشگر مدل دو است؛ برای آن جست‌وجوی فراپارامتر مستقل تعریف نشده است.

مدل‌های درختی به مقیاس یکسان ویژگی‌ها وابستگی مدل‌های فاصله‌محور را ندارند و می‌توانند برهم‌کنش غیرخطی مختصات بردار سند را یاد بگیرند. در مقابل، تعداد زیاد درخت‌ها هزینهٔ آموزش و حافظه را افزایش می‌دهد؛ شاخص اهمیت ویژگی نیز برای مختصات یک بازنمایی توزیعی، به‌سادگی به واژهٔ توضیح‌پذیر تبدیل نمی‌شود. علاوه بر این، جنگل بر نمونهٔ کوچک محلی ممکن است ساختار معنایی کم‌کیفیت Word2Vec را جبران نکند.



شکل ۲-۳: جریان جنگل تصادفی و انتخاب آستانه بر اعتبارسنجی در آزمایش اصلاح‌شده

۲-۵-۲ درخت تصمیم

درخت تصمیم با تقسیم بازگشتی فضای ویژگی‌ها، مسیر تصمیم هر نمونه را از ریشه به برگ تعیین می‌کند. پژوهش‌های هانت، کوئینلن و چارچوب CART از مبانی تاریخی این خانواده هستند [۱۲۴، ۱۲۵، ۱۲۶، ۱۲۷، ۱۲۸]. در طبقه‌بندی

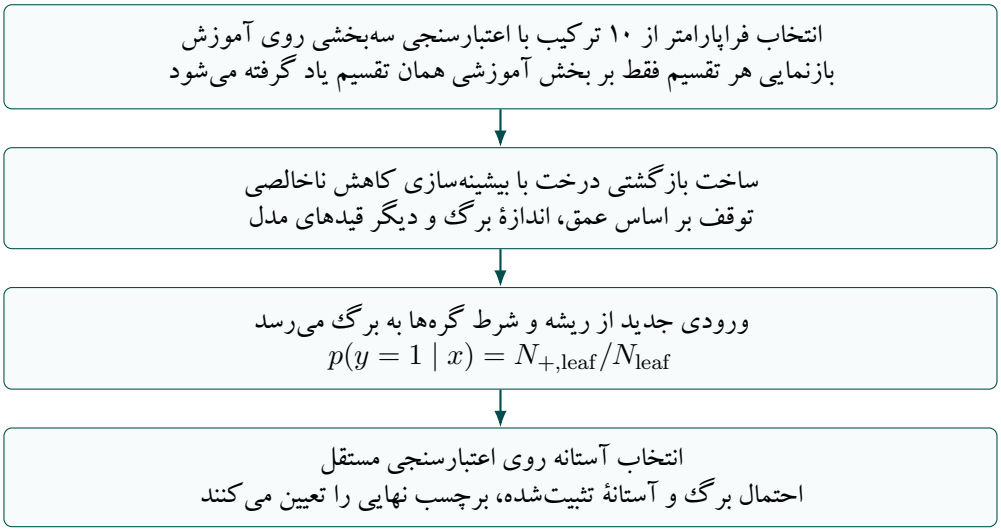
دودویی، احتمال کلاس در برگ از نسبت نمونه‌های آن کلاس در برگ برآورد می‌شود. معیار ناخالصی جینی برای نسبت‌های p_0, p_1 برابر است با

$$G = 1 - p_0^2 - p_1^2, \tag{۲–۷}$$

و آنتروپی به‌صورت $H = -\sum_{c\in\{0,1\}} p_c \log p_c$ تعریف می‌شود. یک تقسیم، کاهش وزن‌دار ناخالصی فرزندان نسبت به والد را بیشینه می‌کند. عمق زیاد و برگ‌های کم‌نمونه می‌توانند به بیش‌برازش منجر شوند؛ محدود کردن عمق یا افزایش حداقل اندازهٔ برگ از راه‌های کنترل آن است [۱۳۷، ۱۳۸].

در نوت‌بوک اصلاح‌شده، معیار از میان gini، entropy و log_loss، عمق از میان ۳، ۵، ۸، ۱۰، ۱۵، ۲۰ و بدون محدودیت، و حداقل تعداد نمونه برای تقسیم از میان ۲، ۵، ۱۰، ۲۰ و ۵۰ انتخاب می‌شود. حداقل اندازهٔ برگ، زیرمجموعهٔ ویژگی‌ها و وزن کلاس نیز جزو فضای جست‌وجو هستند. فقط ۱۰ ترکیب با بذر ثابت جست‌وجو می‌شوند؛ بنابراین این آزمایش، جست‌وجوی جامع تمام ترکیب‌ها نیست. پارامترهای انتخاب‌شده در خروجی اجرای واقعی ثبت می‌شوند.

درخت منفرد قابلیت نمایش مسیر تصمیم دارد، اما وقتی ورودی، مختصات بردار Word2Vec است، تفسیر هر آستانه به یک مفهوم زبانی مشخص نیاز به تحلیل جداگانه دارد. حساسیت درخت به تغییر داده نیز دلیل مناسبی برای گزارش اعتبارسنجی و کنترل اندازهٔ برگ است.



شکل ۲–۴: فلوچارت مفهومی درخت تصمیم

۲–۵–۳ تقویت گرادیانی و XGBoost

XGBoost یک پیاده‌سازی مقیاس‌پذیر از تقویت درختی است که با افزودن پیاپی درخت‌ها، تابع زیان منظم‌شده را کاهش می‌دهد [۱۵۹]. مدل در گام t از رابطهٔ

$$F_t(x) = F_{t-1}(x) + \eta f_t(x) \tag{۲–۸}$$

پیروی می‌کند. برای طبقه‌بندی لجستیک، احتمال خروجی از تبدیل سیگموئید امتیاز به دست می‌آید. هدف کلی

شامل زیان داده و جریمهٔ پیچیدگی درخت‌هاست:

$$\mathcal{L} = \sum_{i=1}^{N} \ell(y_i, F(x_i)) + \sum_{t} \Omega(f_t), \qquad \Omega(f) = \gamma T + \frac{\lambda}{2} \sum_{j=1}^{T} \omega_j^2. \tag{۹-۲}$$

در این رابطه، T تعداد برگ‌ها، ω_j وزن برگ، γ هزینهٔ افزودن برگ و λ ضریب منظم‌سازی است. با تقریب مرتبهٔ دوم زیان و تعریف گرادیان g_i و هسین h_i، اگر I_j مجموعهٔ نمونه‌های برگ j باشد، در حالت جریمهٔ L_2 و نبود جریمهٔ L_1 داریم:

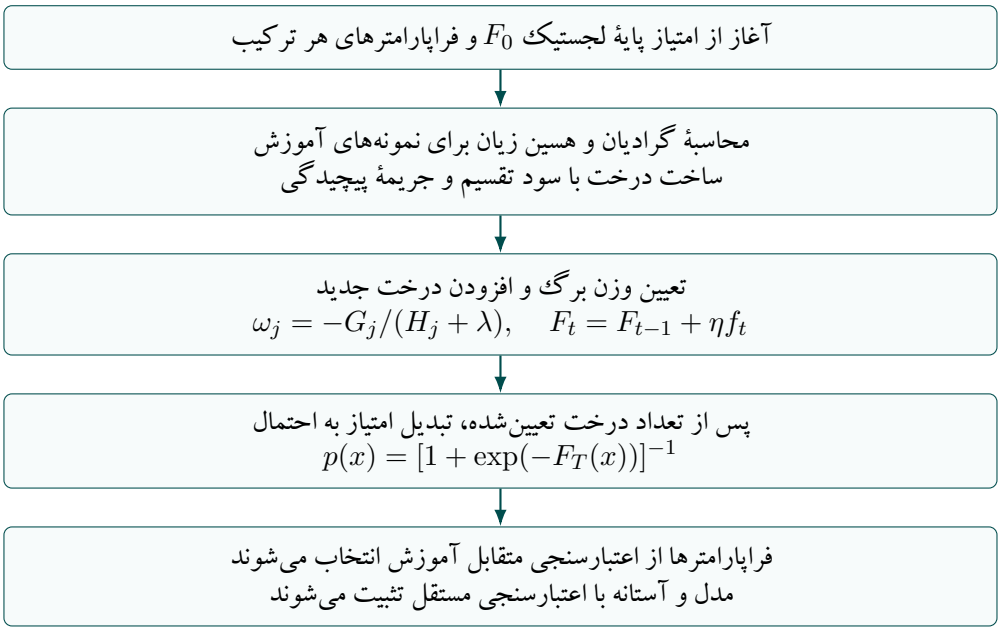
$$G_j = \sum_{i \in I_j} g_i, \qquad H_j = \sum_{i \in I_j} h_i, \qquad \omega_j^{*} = -\frac{G_j}{H_j + \lambda}. \tag{۱۰-۲}$$

سود تقسیم یک برگ به دو فرزند نیز به‌صورت زیر نوشته می‌شود:

$$\text{Gain} = \frac{1}{2} \left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right) - \gamma. \tag{۱۱-۲}$$

این روابط، نقش ساختار درخت و منظم‌سازی را نشان می‌دهند؛ تضمینی برای برتری یک الگوریتم روی هر پیکره ایجاد نمی‌کنند.

در مقایسهٔ متمرکز، عمق درخت از مجموعهٔ ۳، ۵، ۷ و ۱۰، تعداد برآوردگر از ۵۰، ۱۰۰ و ۱۵۰ و نرخ یادگیری از ۰٫۰۵، ۰٫۱ و ۰٫۲ جست‌وجو می‌شود. تابع هدف binary:logistic، معیار داخلی logloss و روش درخت hist است. در سناریوی مشارکتی، پارامترها ثابت و مستقل از این جست‌وجوی متمرکز تعریف شده‌اند؛ این دو تنظیم باید از یکدیگر متمایز بمانند.



شکل ۲-۵: نمای مفهومی آموزش تقویتی XGBoost

۲-۵-۴ بیز ساده و رأی‌گیری احتمالی

در بیز ساده، ویژگی‌ها مشروط به کلاس مستقل فرض می‌شوند. با استفاده از قضیهٔ بیز، قاعدهٔ طبقه‌بندی از رابطهٔ

$$\widehat{y} = \arg\max_{c \in \{0,1\}} P(c) \prod_{j=1}^{d} P(x_j \mid c) \tag{۲-۱۲}$$

به دست می‌آید. این استقلال معمولاً برای مختصات بازنمایی متن دقیقاً برقرار نیست، اما مدل همچنان می‌تواند یک خط مبنای محاسباتی مفید باشد [۱۱۲، ۱۴۲، ۱۷۶]. در GaussianNB، توزیع شرطی هر ویژگی با میانگین و واریانس کلاس مدل می‌شود:

$$P(x_j \mid c) = \frac{1}{\sqrt{2\pi\sigma_{cj}^2}} \exp\!\left(-\frac{(x_j - \mu_{cj})^2}{2\sigma_{cj}^2}\right). \tag{۲-۱۳}$$

در BernoulliNB، هر ویژگی به متغیر دودویی z_j تبدیل می‌شود و سهم آن برابر $q_{cj}^{z_j}(1-q_{cj})^{1-z_j}$ است. هموارسازی لاپلاس از احتمال صفر برای رخدادهای مشاهده‌نشده جلوگیری می‌کند.

بردار میانگین Word2Vec ممکن است مؤلفه‌های منفی داشته باشد؛ بنابراین MultinomialNB مستقیماً مدل مناسبی برای همین ورودی نیست و در نسخهٔ اصلاح‌شده استفاده نمی‌شود. ساختار اجراشده ابتدا StandardScaler را بر آموزش برازش می‌کند، سپس دو مدل گاوسی و برنولی را با رأی‌گیری نرم ترکیب می‌کند:

$$z_j = \frac{x_j - \mu_{j,\text{train}}}{s_{j,\text{train}}}, \qquad p_{\text{vote}}(c \mid x) = \frac{1}{2}\left(p_{\text{G}}(c \mid z) + p_{\text{B}}(c \mid z)\right). \tag{۲-۱۴}$$

برای مدل برنولی، آستانهٔ دودویی‌سازی صفر است و پارامتر هموارسازی یک است. var_smoothing مدل گاوسی برابر 10^{-8} است. استانداردساز درون خط‌لوله و فقط روی آموزش همان تقسیم برازش می‌شود. آستانهٔ تصمیم نهایی روی احتمال رأی‌گیری‌شده اعمال می‌شود و با آستانهٔ دودویی‌سازی ویژگی تفاوت دارد.

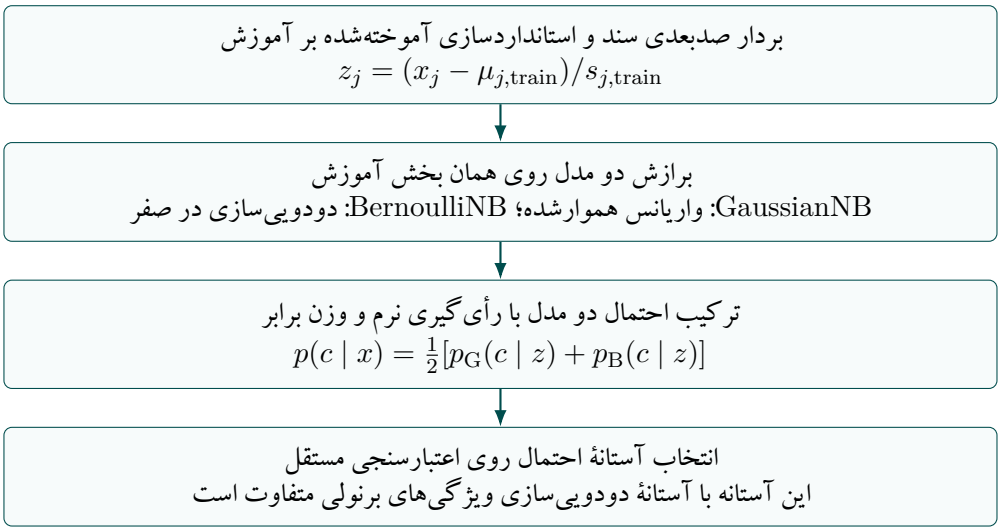
نام این مجموعهٔ دوتایی در گزارش Naive Bayes voting است تا صورت دقیق آزمایش روشن بماند.

۲-۶ نتایج ارزیابی مدل‌ها

نتایج این بخش از اجرای کامل نوت‌بوک اصلاح‌شده روی همان نسخهٔ داده با هش ثبت‌شده به دست آمده‌اند؛ خروجی اجرا، جدول‌های CSV، نمودارها و فرادادهٔ نسخه‌ها در کنار منبع پایان‌نامه بایگانی شده‌اند. نسخه‌های NumPy، pandas، SciPy، scikit-learn، Gensim و XGBoost با نسخه‌های ثبت‌شده در آزمایش مشارکتی همسان‌سازی شده‌اند.

۲-۶-۱ مقایسه بر اعتبارسنجی

جدول ۲-۱ برای تمام چهار مدل از مجموعهٔ اعتبارسنجی مشترک استفاده می‌کند. آستانهٔ هر مدل نیز فقط روی همین بخش انتخاب شده است. این اعداد برآورد نهایی آزمون نیستند و باید در همان نقشِ انتخاب مدل تفسیر شوند. مدل XGBoost با F_1 مثبتِ اعتبارسنجی ۰.۹۳۱۹ در صدر قاعدهٔ رتبه‌بندی قرار گرفته و آستانهٔ ۰.۳۸ پیش از ارزیابی



شکل ۲-۶: ساختار رأی‌گیری نرم بیز گاوسی–برنولی روی بازنمایی استانداردشدهٔ سند

آزمون تثبیت شده است.

جدول ۲-۱: مقایسهٔ چهار مدل بر اعتبارسنجی؛ تمام معیارها در مقیاس صفر تا یک‌اند

مدل	آستانه	دقت کلی	دقت مثبت	بازیابی مثبت	F_1 مثبت	F_1 کلان	ROC AUC
XGBoost	۳۸.۰	۹۳۱۱.۰	۹۲۱۶.۰	۹۴۲۴.۰	۹۳۱۹.۰	۹۳۱۰.۰	۹۸۰۴.۰
جنگل تصادفی	۴۶.۰	۹۱۹۰.۰	۹۱۵۶.۰	۹۲۳۲.۰	۹۱۹۴.۰	۹۱۹۰.۰	۹۷۲۹.۰
درخت تصمیم	۴۸.۰	۸۷۵۹.۰	۸۵۸۴.۰	۹۰۰۷.۰	۸۷۹۰.۰	۸۷۵۸.۰	۹۳۹۸.۰
رأی‌گیری بیز ساده	۶۶.۰	۸۷۲۳.۰	۸۸۰۸.۰	۸۶۱۴.۰	۸۷۱۰.۰	۸۷۲۳.۰	۹۳۶۸.۰

جدول ۲-۲: ارزیابی آزمون فقط برای مدل منتخب؛ دو تنظیم آستانه برای همان مدل

تنظیم	آستانه	دقت کلی	دقت مثبت	بازیابی مثبت	F_1 مثبت	ROC AUC	AP
پیش‌فرض	۵۰.۰	۹۲۸۷.۰	۹۳۰۰.۰	۹۲۷۳.۰	۹۲۸۷.۰	۹۷۹۲.۰	۹۷۸۶.۰
منتخب اعتبارسنجی	۳۸.۰	۹۲۷۰.۰	۹۱۸۳.۰	۹۳۷۵.۰	۹۲۷۸.۰	۹۷۹۲.۰	۹۷۸۶.۰

مقدارهای منتخب جست‌وجو در جدول ۲-۴ آمده‌اند. زمان‌های آموزش یا جست‌وجوی ثبت‌شده شامل بار کاری یکسان نیستند: دو مدل جست‌وجوی اعتبارسنجی متقابل دارند و دو مدل مستقیماً برازش می‌شوند. علاوه بر آن، حافظهٔ نهان برخی تبدیل‌های بازنمایی را بازاستفاده می‌کند. بنابراین این زمان‌ها مستند اجرای آزمایش‌اند و به‌تنهایی رتبه‌بندی منصفانهٔ سرعت ذاتی الگوریتم‌ها ایجاد نمی‌کنند.

۲-۶-۲ ارزیابی نهایی مدل تثبیت‌شده

در آستانهٔ منتخب، مدل XGBoostدقت آزمون ۷۰.۹۲ درصد، دقت مثبت ۹۱۸۳.۰، بازیابی مثبت ۹۳۷۵.۰ و F_1 مثبت ۹۲۷۸.۰ دارد. معیار ROC AUC آن ۹۷۹۲.۰ است. این معیار مستقل از انتخاب یک آستانهٔ ثابت است، اما از همان پیش‌بینی‌های مدل نهایی روی آزمون محاسبه می‌شود. جدول آزمون دو تنظیمِ آستانهٔ ۵۰ و آستانهٔ منتخب

جدول ۲-۳: گزارش برازش و جست‌وجو؛ خط تیره یعنی جست‌وجوی اعتبارسنجی برای آن مدل تعریف نشده است

مدل	بهترین F_1 در جست‌وجوی آموزش	زمان برازش/جست‌وجو (ثانیه)
جنگل تصادفی	–	۰۰۹۸.۷۲۴
درخت تصمیم	۸۷۵۹.۰	۳۸۷۳.۲۰۹۷
XGBoost	۹۲۷۳.۰	۳۹۴۹.۱۳۱۴
رأی‌گیری بیز ساده	–	۶۴۵۴.۴۲

جدول ۲-۴: فراپارامترهای منتخب جست‌وجوی تصادفی؛ انتخاب فقط از اعتبارسنجی متقابلِ آموزش

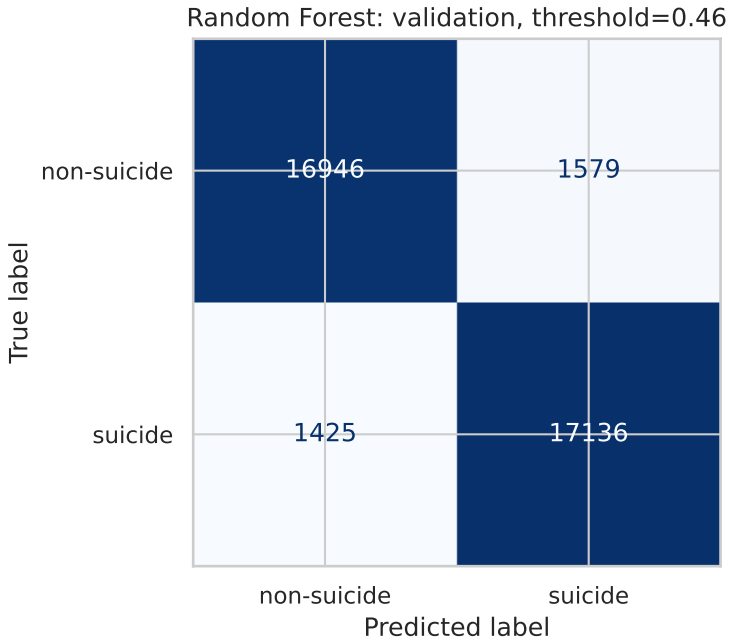
مدل	مقدارهای منتخب
درخت تصمیم	`class_weight`=None, `criterion`=log_loss, `max_depth`=10, `max_features`=None, `min_samples_leaf`=20, `min_samples_split`=50
XGBoost	`learning_rate`=0.2, `max_depth`=10, `n_estimators`=150

جدول ۲-۵: پوشش بازنمایی مدل منتخب؛ واژگان فقط از آموزش آموخته شده‌اند

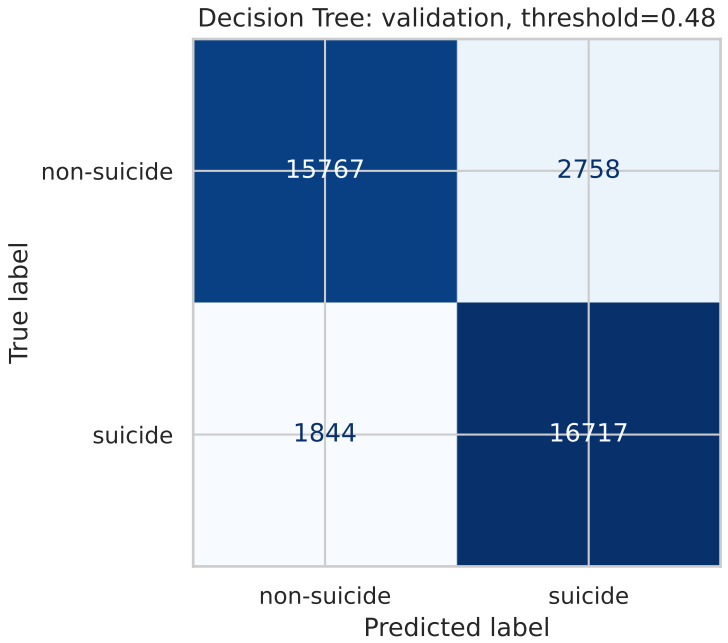
بخش	تعداد سند	پوشش توکن	سند کاملاً ناشناخته	سهم سند ناشناخته
آموزش	۱۴۸۳۸۰	۹۹۶۹.۰	۳۹	۰۰۰۳.۰
اعتبارسنجی	۳۷۰۸۶	۹۹۲۲.۰	۱۳	۰۰۰۴.۰
آزمون	۴۶۳۴۲	۹۹۴۹.۰	۱۵	۰۰۰۳.۰

جدول ۲-۶: شمارش خطاهای مدل منتخب در آزمون، با آستانهٔ تثبیت‌شده

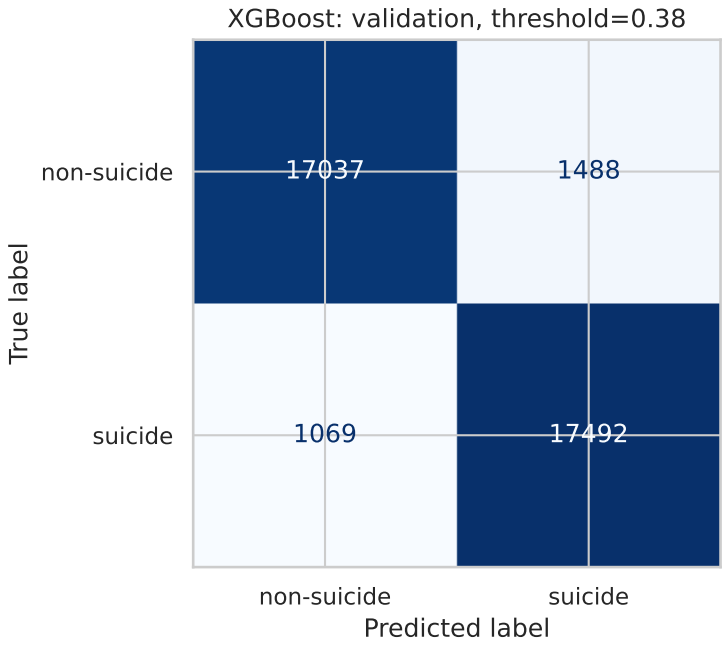
TP	FN	FP	TN
۲۱۷۴۷	۱۴۵۰	۱۹۳۴	۲۱۲۱۱



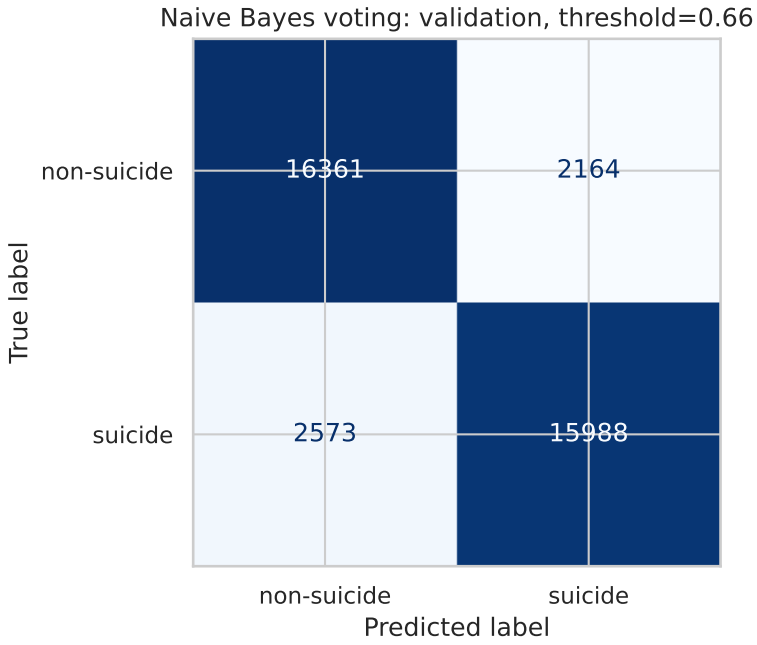
شکل ۲–۷: ماتریس سردرگمی جنگل تصادفی بر اعتبارسنجی، با آستانهٔ منتخب همان بخش



شکل ۲–۸: ماتریس سردرگمی درخت تصمیم بر اعتبارسنجی، با آستانهٔ منتخب همان بخش



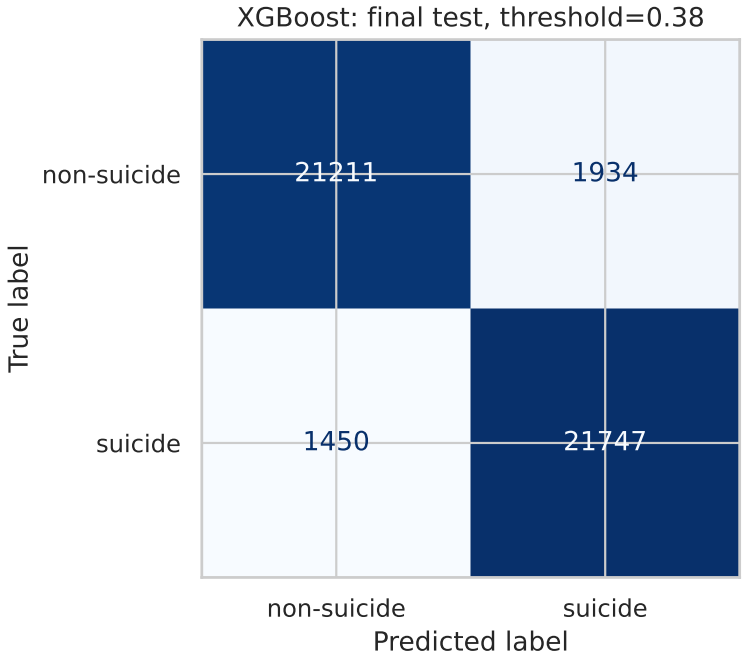
شکل ۲–۹: ماتریس سردرگمی XGBoost بر اعتبارسنجی



شکل ۲–۱۰: ماتریس سردرگمی رأی‌گیری بیز گاوسی–برنولی بر اعتبارسنجی

اعتبارسنجی را برای همان مدل گزارش می‌کند؛ مدل با نگاه به بهتر بودن یکی از اعداد آزمون دوباره انتخاب نشده است.

در همین آزمون، آستانهٔ پیش‌فرض ۵٫۰ دقت ۸۷.۹۲ درصد، F_1 مثبت ۹۲۸۷.۰ و بازیابی مثبت ۹۲۷۳.۰ دارد. بنابراین آستانهٔ منتخب اعتبارسنجی در آزمون، بازیابی را افزایش داده اما دقت کلی و F_1 مثبت را اندکی کاهش داده است. بهینه بودن بر اعتبارسنجی، تضمین بهبود تمام معیارهای آزمون نیست. گزارش هر دو تنظیم، این مبادله را آشکار می‌کند؛ آستانه با نگاه به نتیجهٔ آزمون دوباره انتخاب نشده است.



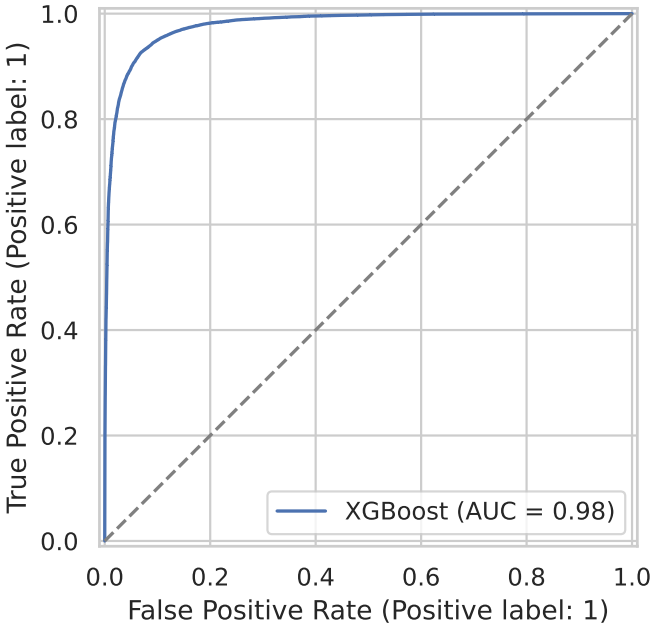
شکل ۲–۱۱: ماتریس سردرگمی آزمون نهایی برای انتخاب تثبیت‌شدهٔ XGBoost

۲–۷ تحلیل حساسیت نسبت به آستانه و خطا

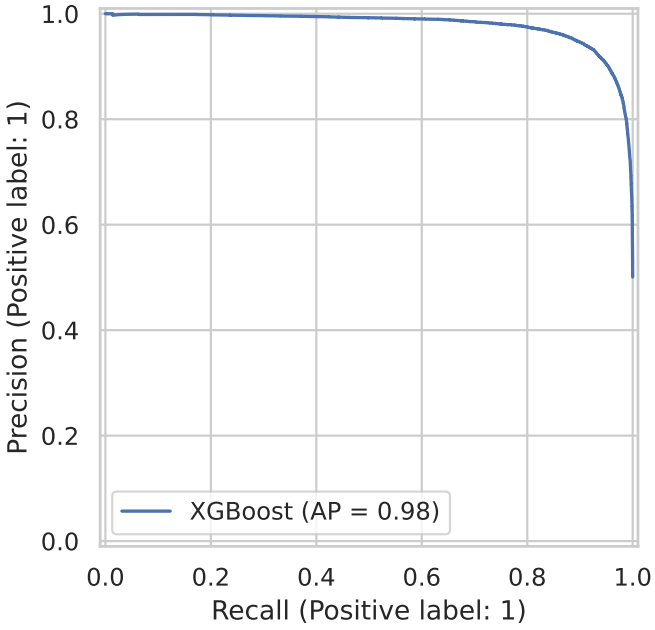
نمودار ۲–۱۴ معیارهای اعتبارسنجی را در دامنهٔ آستانه‌ها نشان می‌دهد. کاهش آستانه معمولاً تعداد مثبت‌های پیش‌بینی‌شده را افزایش می‌دهد و می‌تواند بازیابی را به قیمت مثبت کاذب بیشتر بالا ببرد. افزایش آستانه نیز می‌تواند دقت مثبت را به قیمت منفی کاذب بیشتر تغییر دهد. این مبادله باید با شمارش واقعی خطا و هدف کاربردی بررسی شود؛ «افزایش حساسیت» به معنای بهبود قطعی تمام معیارها نیست.

انتخاب آستانه با کالیبراسیون احتمال تفاوت دارد. در این آزمایش، کالیبراسیون Platt یا isotonic مستقل اجرا نشده و احتمال مدل نباید بی‌واسطه به‌عنوان ریسک بالینی کالیبره‌شده تفسیر شود. منحنی‌های آستانه و شمارش خطا، شواهد مستقیم این اجرا هستند. ارزیابی توزیع خطا در جمعیت‌های دیگر، بوت‌استرپ و سناریوهای تغییر توازن کلاس به آزمایش‌های تکمیلی نیاز دارند.

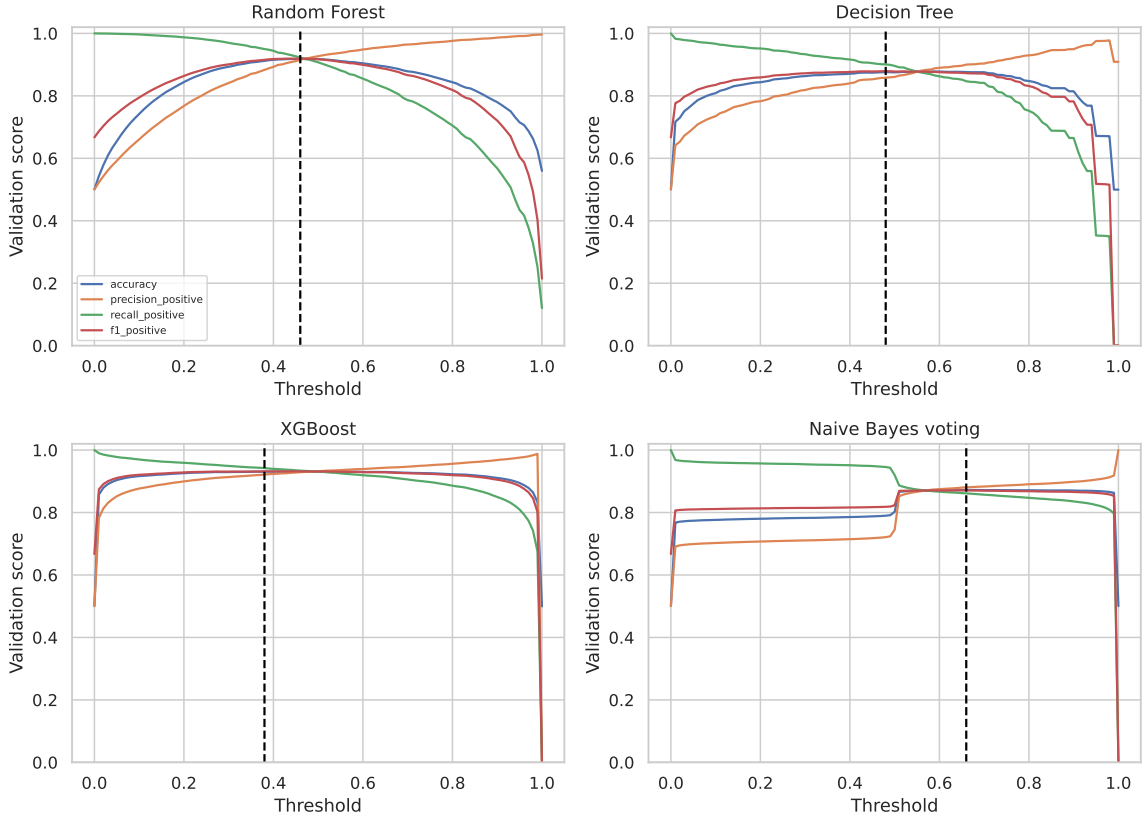
کاهش منفی کاذب در تحلیل خطر اهمیت دارد، اما هزینهٔ مداخله و پیامد مثبت کاذب نیز باید در یک مطالعهٔ بالینی و با رضایت و نظارت مناسب سنجیده شود. پیکرهٔ شبکهٔ اجتماعی و انتخاب آستانهٔ مبتنی بر F_1، به‌تنهایی سیاست تصمیم‌گیری برای فرد واقعی تعریف نمی‌کنند. بررسی کاربران مستقل، دادهٔ بیرونی، چند بذر و فاصلهٔ اطمینان از گام‌های ضروری برای گسترش اعتبار پژوهش است.



شکل ۲-۱۲: منحنی ROC مدل منتخب در آزمون نهایی



شکل ۲-۱۳: منحنی دقت مثبت–بازیابی مدل منتخب در آزمون نهایی



شکل ۲-۱۴: تحلیل حساسیت چهار مدل فقط بر اعتبارسنجی؛ خط عمودی آستانهٔ منتخب را نشان می‌دهد

۲-۸ یادگیری مشارکتی با توزیع طبقه‌بندی‌شدهٔ داده‌ها

در معماری مشارکتی، گزارش تعداد کلاینت‌ها به‌تنهایی برای توصیف آزمایش کافی نیست. تعداد نمونه‌های هر کلاینت، نسبت کلاس‌ها، استقلال داده‌های محلی، محل یادگیری بازنمایی متن و روش تجمیع پیش‌بینی‌ها باید مشخص باشند. در این پژوهش، این موارد بر اساس پیاده‌سازی و خروجی‌های ثبت‌شده در نوت‌بوک federated_xgboost_10_20_50_100.ipynb تعریف می‌شوند [۱۸۴]. تمام اعداد و نمودارهای این بخش از همان اجرای ذخیره‌شده استخراج شده‌اند؛ اعداد جدول‌ها تا چهار رقم اعشار گرد شده‌اند و نباید به‌عنوان دقت بیشتر از خروجی اصلی تفسیر شوند.

۲-۸-۱ مجموعه‌داده و جداسازی ارزیابی

دادهٔ ورودی، مجموعهٔ Suicide Watch با ۰۷۴٬۲۳۲ ردیف و دو ستون اصلی متن و برچسب است. پس از حذف ۹۳ متن خام تکراری، ۹۸۱٬۲۳۱ ردیف باقی می‌ماند. ابتدا ۲۰ درصد داده به آزمون اختصاص می‌یابد؛ سپس ۲۰ درصد بخش توسعه برای اعتبارسنجی کنار گذاشته می‌شود. بنابراین سهم‌های اسمی آموزش، اعتبارسنجی و آزمون به‌ترتیب ۶۴، ۱۶ و ۲۰ درصد است. بذر تصادفی تقسیم برابر ۴۲ است و تقسیم‌ها با حفظ نسبت کلاس انجام می‌شوند.

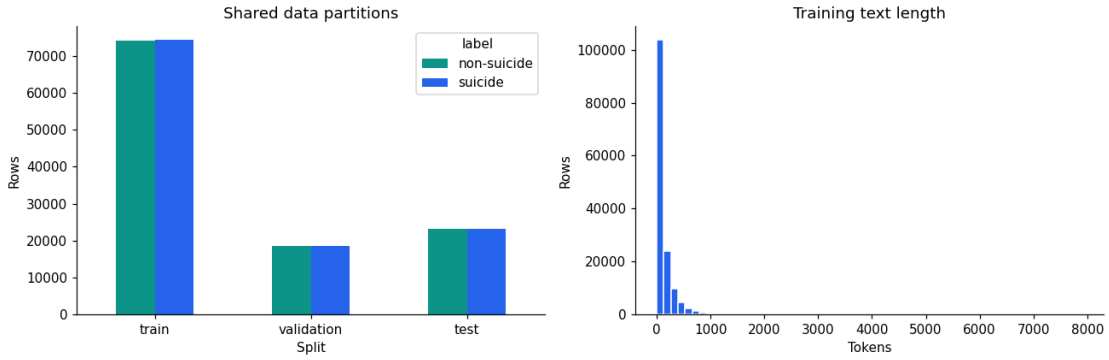
پس از پاکسازی، متن‌های خالی، متن‌های تکراریِ درون هر بخش، متن‌های دارای برچسب متعارض و هم‌پوشانی با بخش‌های قبلی حذف می‌شوند. در نتیجه، تعدادهای نهایی الزاماً برابر حاصل‌ضرب سادهٔ نسبت‌های اسمی در تعداد اولیه نیستند. جدول ۲-۷ تعدادهای واقعی پس از این کنترل‌ها را نشان می‌دهد. در این آزمایش، داده‌ها انگلیسی

هستند؛ ارزیابی چندزبانه یا تعمیم بالینی مستقل انجام نشده است.

جدول ۲-۷: توزیع واقعی داده پس از حذف تکرار و پاکسازی در آزمایش مشارکتی

بخش	غیرخودکشی	خودکشی	مجموع	سهم کلاس مثبت
آموزش	۷۴۱۳۳	۷۴۲۴۷	۱۴۸۳۸۰	۵۰۰۳۸۴.۰
اعتبارسنجی	۱۸۵۲۵	۱۸۵۶۱	۳۷۰۸۶	۵۰۰۴۸۵.۰
آزمون	۲۳۱۴۵	۲۳۱۹۷	۴۶۳۴۲	۵۰۰۵۶۱.۰

مجموعه‌های اعتبارسنجی و آزمون در تمام سناریوها مشترک و از دادهٔ آموزش کلاینت‌ها جدا هستند. کنترل شناسهٔ ردیف و کلید متن خام و پاکسازی‌شده مانع حضور نمونهٔ مشترک در آموزش و ارزیابی می‌شود. برچسب‌های اعتبارسنجی و آزمون در اختیار سرور ارزیابی باقی می‌مانند و وارد تابع آموزش کلاینت نمی‌شوند. با این حال، محتوای پرسش ارزیابی برای محاسبهٔ پیش‌بینی به مدل‌های محلی داده می‌شود؛ این ویژگی با محرمانه ماندن برچسب‌ها و دادهٔ آموزش تفاوت دارد.



شکل ۲-۱۵: توزیع کلاس‌ها در بخش‌های مشترک و طول متن‌های آموزشی؛ خروجی نوت‌بوک مشارکتی

۲-۸-۲ تعریف دقیق تخصیص داده به کلاینت‌ها

اگر D_{tr} مجموعهٔ آموزش با اندازهٔ $N = 148380$ باشد، برای هر سناریوی $K \in \{10, 20, 50, 100\}$، مجموعه‌های محلی $D_1, \ldots, D_K$ به‌گونه‌ای ساخته می‌شوند که

$$\bigcup_{i=1}^{K} D_i = D_{\mathrm{tr}}, \qquad D_i \cap D_j = \varnothing \quad (i \neq j), \qquad \sum_{i=1}^{K} n_i = N, \tag{۱۵-۲}$$

که $n_i = |D_i|$ است. در تابع stratified_client_indices، اندیس‌های هر کلاس به‌طور جداگانه با مولد تصادفی بذر ۴۲ درهم‌ریخته می‌شوند و سپس با numpy.array_split به K بخش تقسیم می‌شوند. هر کلاینت یک بخش از هر کلاس را دریافت می‌کند و در پایان ترتیب ردیف‌های محلی نیز درهم‌ریخته می‌شود.

برای کلاس c با N_c نمونه، تعداد محلی از رابطهٔ زیر پیروی می‌کند:

$$n_{i,c} \in \left\{ \left\lfloor \frac{N_c}{K} \right\rfloor, \left\lceil \frac{N_c}{K} \right\rceil \right\}, \qquad \pi_i = \frac{n_{i,1}}{n_i} \simeq \pi = \frac{74247}{148380}. \tag{۱۶-۲}$$

از آنجا که گرد کردن برای هر کلاس جداگانه انجام می‌شود، اختلاف تعداد کل نمونه‌ها بین دو کلاینت می‌تواند دو نمونه باشد. این روش، یک تقسیم طبقه‌بندی‌شده و تقریباً هم‌توزیع است؛ یک سناریوی non-IID، تقسیم بر اساس کاربر، تقسیم زمانی یا شبیه‌سازی تفاوت واقعی بیمارستان‌ها محسوب نمی‌شود. شباهت نسبت کلاس‌ها نیز به معنای یکسان بودن واژگان و موضوع متن‌های تمام کلاینت‌ها نیست.

جدول ۲-۸: اندازه و نسبت کلاس مثبت در دادهٔ محلی؛ تمام ۳۸۰٬۱۴۸ نمونه در هر سناریو دقیقاً یک‌بار استفاده می‌شوند

کلاینت	کمینهٔ ردیف	میانگین ردیف	بیشینهٔ ردیف	کمینهٔ π_i	بیشینهٔ π_i
۱۰	۱۴۸۳۷	۰.۱۴۸۳۸	۱۴۸۳۹	۵۰۰۳۷۱.۰	۵۰۰۴۰۴.۰
۲۰	۷۴۱۸	۰.۷۴۱۹	۷۴۲۰	۵۰۰۳۳۷.۰	۵۰۰۴۰۴.۰
۵۰	۲۹۶۶	۶.۲۹۶۷	۲۹۶۸	۵۰۰۳۳۷.۰	۵۰۰۵۰۶.۰
۱۰۰	۱۴۸۳	۸.۱۴۸۳	۱۴۸۵	۵۰۰۳۳۷.۰	۵۰۰۶۷۴.۰

۲-۸-۳ آموزش مستقل بازنمایی و مدل محلی

هر کلاینت مدل Word2Vec خود را فقط بر متن‌های آموزشی محلی یاد می‌گیرد. بازنمایی، از نوع Skip-Gram با ابعاد ۱۰۰، پنجرهٔ ۵، حداقل فراوانی ۲، پنج دورهٔ آموزش و یک کارگر است. بردار سند از میانگین بردار واژه‌های شناخته‌شده به دست می‌آید. واژه‌ای که فقط در اعتبارسنجی یا آزمون وجود داشته باشد وارد واژگان یادگرفته‌شده نمی‌شود. اگر تمام واژه‌های سند ناشناخته باشند، نمایش آن بردار صفر خواهد بود.

هر کلاینت یک XGBoost مستقل با ۱۰۰ درخت، عمق بیشینهٔ ۵، نرخ یادگیری ۰٫۱ و روش ساخت درخت hist آموزش می‌دهد. تابع هدف binary:logistic و معیار داخلی logloss است. نسبت نمونه‌گیری سطری و ستونی هر دو یک، مقدار min_child_weight برابر یک و جریمهٔ L_2 برابر یک است. هر مدل یک رشتهٔ پردازشی دارد؛ اجرای ذخیره‌شده حداکثر چهار کلاینت را هم‌زمان شبیه‌سازی کرده است. بذر مدل کلاینت i، با شماره‌گذاری از یک، برابر $42 + 1009i$ است.

این پیاده‌سازی وزن درخت‌ها یا مختصات بردارهای Word2Vec را میانگین نمی‌گیرد. از آنجا که فضای بازنمایی هر کلاینت مستقل آموخته می‌شود، مختصات آن فضاها لزوماً هم‌تراز نیستند. اشتراک پیش‌بینی احتمالی، امکان ترکیب خروجی‌ها را بدون فرض هم‌ترازی این فضاها فراهم می‌کند. بنابراین روش حاضر، در سطح پیاده‌سازی، یک مجموعه‌مدل توزیع‌شده با تجمیع احتمال است و نباید با الگوریتم آموزش گرادیانی چنددوره‌ای FedAvg یکسان معرفی شود.

۲-۸-۴ تجمیع خروجی و انتخاب آستانه

تمام کلاینت‌ها باید به پرسش‌های مشترک و با ترتیب شناسهٔ یکسان پاسخ دهند. برای متن x، کلاینت i احتمال کلاس مثبت $p_i(x)$ را می‌فرستد و سرور با وزن تعداد نمونهٔ آموزشی آن کلاینت محاسبه می‌کند:

$$\alpha_i = \frac{n_i}{\sum_{j=1}^{K} n_j}, \qquad \bar{p}(x) = \sum_{i=1}^{K} \alpha_i p_i(x), \qquad \widehat{y}(x) = \mathbf{1}\{\bar{p}(x) \geq \tau\}. \tag{۲-۱۷}$$

وزن‌ها از اندازهٔ دادهٔ محلی تعیین می‌شوند؛ از دقت آزمون یا برچسب آزمون برای تنظیم وزن استفاده نمی‌شود. نزدیک بودن اندازهٔ کلاینت‌ها باعث می‌شود وزن‌ها تقریباً برابر باشند، اما فرمول واقعی همچنان از n_i استفاده می‌کند.

آستانه از مجموعهٔ $\{0, 0.01, \ldots, 1\}$ و تنها بر اساس بیشترین F_1 کلاس مثبت در اعتبارسنجی انتخاب می‌شود. در تساوی، دقت مثبت بیشتر، نزدیکی بیشتر به ۰٫۵ و سپس آستانهٔ کوچک‌تر ترجیح دارند. پس از تثبیت آستانه، معیارهای آزمون محاسبه می‌شوند. برای تفکیک اثر تغییر تعداد کلاینت از اثر تنظیم آستانه، نتایج با آستانهٔ مشترک ۰٫۵ نیز گزارش می‌شوند. سناریوی پیشنهادی نیز با F_1 اعتبارسنجی انتخاب می‌شود؛ بیشترین دقت آزمون مبنای انتخاب نیست.

جدول ۲-۹: نتایج آزمون با آستانهٔ منتخب اعتبارسنجی؛ معیارها در مقیاس صفر تا یک

کلاینت	آستانه	دقت کلی	دقت مثبت	بازیابی مثبت	F_1 مثبت	F_1 کلان
۱۰	۴۹.۰	۹۱۵۸.۰	۹۱۰۷.۰	۹۲۲۲.۰	۹۱۶۴.۰	۹۱۵۸.۰
۲۰	۵۲.۰	۹۰۹۳.۰	۹۰۹۱.۰	۹۰۹۶.۰	۹۰۹۴.۰	۹۰۹۳.۰
۵۰	۵۴.۰	۸۹۳۰.۰	۸۹۶۳.۰	۸۸۹۱.۰	۸۹۲۷.۰	۸۹۳۰.۰
۱۰۰	۵۰.۰	۸۷۰۰.۰	۸۵۷۸.۰	۸۸۷۴.۰	۸۷۲۴.۰	۸۷۰۰.۰

جدول ۲-۱۰: معیارهای مستقل از آستانه، تعداد خطاها و زمان اجرای سناریوهای مشارکتی

کلاینت	ROC AUC	AP	منفی کاذب	مثبت کاذب	زمان دیواری (ثانیه)
۱۰	۹۷۲۷.۰	۹۷۲۲.۰	۱۸۰۵	۲۰۹۷	۶۳۵۶.۱۰۷
۲۰	۹۶۸۶.۰	۹۶۸۰.۰	۲۰۹۶	۲۱۰۹	۱۴۶۲.۹۱
۵۰	۹۵۸۱.۰	۹۵۸۲.۰	۲۵۷۲	۲۳۸۶	۴۶۴۰.۹۸
۱۰۰	۹۴۳۵.۰	۹۴۵۰.۰	۲۶۱۲	۳۴۱۲	۸۷۷۰.۱۰۱

جدول ۲-۱۱: نتایج آزمون با آستانهٔ ثابت ۰٫۵؛ بدون تنظیم جداگانهٔ آستانه برای هر سناریو

کلاینت	دقت کلی	دقت مثبت	بازیابی مثبت	F_1 مثبت	F_1 کلان
۱۰	۹۱۶۳.۰	۹۱۳۵.۰	۹۱۹۹.۰	۹۱۶۷.۰	۹۱۶۳.۰
۲۰	۹۰۹۲.۰	۹۰۵۰.۰	۹۱۴۶.۰	۹۰۹۸.۰	۹۰۹۲.۰
۵۰	۸۹۲۳.۰	۸۸۵۷.۰	۹۰۱۰.۰	۸۹۳۳.۰	۸۹۲۲.۰
۱۰۰	۸۷۰۰.۰	۸۵۷۸.۰	۸۸۷۴.۰	۸۷۲۴.۰	۸۷۰۰.۰

۲-۸-۵ گزارش مستقل چهار سناریو

۲-۸-۵-۱ سناریوی ۱۰ کلاینت

هر کلاینت به‌طور میانگین ۸۳۸٬۱۴ نمونه دارد. F_1 مثبت اعتبارسنجی در آستانهٔ منتخب ۰٫۴۹ برابر ۰٫۹۱۹۸ است و این مقدار، سناریوی ۱۰ کلاینت را بر اساس قاعدهٔ اعتبارسنجی به گزینهٔ پیشنهادی تبدیل می‌کند. در آزمون، دقت کلی ۰٫۹۱۵۸ و بازیابی مثبت ۰٫۹۲۲۲ به دست آمده است. ماتریس سردرگمی با ترتیب سطر و ستون «غیرخودکشی، خودکشی» برابر است با

$$\begin{pmatrix} 21048 & 2097 \\ 1805 & 21392 \end{pmatrix}. \tag{۲-۱۸}$$

افزایش بازیابی نسبت به آستانهٔ ۵٫۰ با افزایش مثبت کاذب همراه است. این مبادله نباید به‌عنوان بهبود هم‌زمان تمام معیارها بیان شود. میانگین اندازهٔ واژگان محلی ۲٫۶۱۸٬۱۷ واژه و میانگین پوشش توکن‌های آزمون حدود ۹۸۶۰٫۰ است.

۲-۸-۵-۲ سناریوی ۲۰ کلاینت

میانگین دادهٔ محلی به ۴۱۹٬۷ ردیف کاهش می‌یابد. آستانهٔ منتخب ۵۲٫۰ و F_1 مثبت اعتبارسنجی ۹۱۳۴٫۰ است. دقت آزمون ۹۰۹۳٫۰ و F_1 مثبت آزمون ۹۰۹۴٫۰ است. در این سناریو، ۰۹۶٬۲ منفی کاذب و ۱۰۹٬۲ مثبت کاذب ثبت شده‌اند. نسبت به سناریوی ۱۰ کلاینت، کاهش حجم دادهٔ محلی با کاهش اندازهٔ واژگان محلی به میانگین ۲۵٫۴۳۰٬۱۲ همراه است. زمان دیواری ۱۴۶۲٫۹۱ ثانیه بوده، اما زمان یک اجرای منفرد برای استنتاج قانون قطعی سرعت کافی نیست.

۲-۸-۵-۳ سناریوی ۵۰ کلاینت

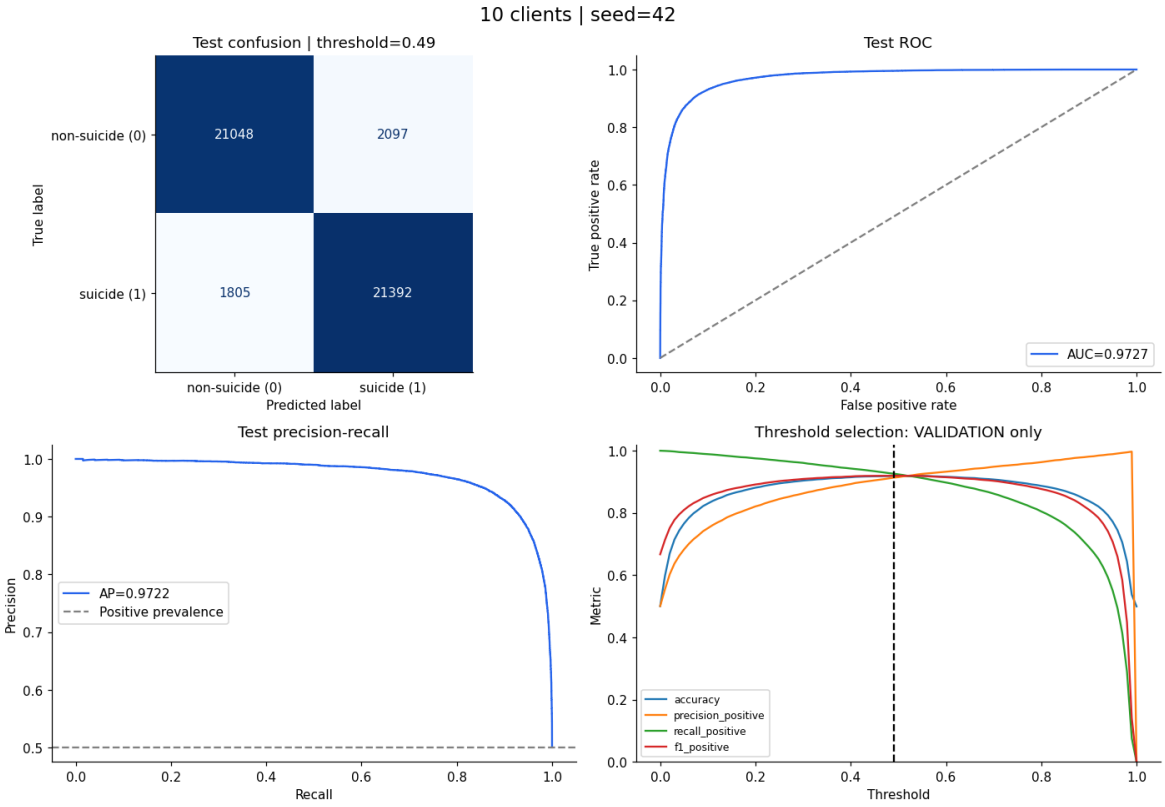
میانگین دادهٔ محلی ۶٫۹۶۷٬۲ ردیف و آستانهٔ منتخب ۵۴٫۰ است. F_1 مثبت اعتبارسنجی ۸۹۴۵٫۰ و دقت آزمون ۸۹۳۰٫۰ به دست آمده‌اند. در آزمون، بازیابی مثبت ۸۸۹۱٫۰ و F_1 مثبت ۸۹۲۷٫۰ است. تعداد منفی‌های کاذب به ۵۷۲٬۲ می‌رسد. میانگین اندازهٔ واژگان محلی ۵۶٫۶۵۴٬۷ است. افزایش آستانه نسبت به ۵٫۰ دقت مثبت را افزایش داده، اما بازیابی مثبت و F_1 مثبت آزمون را اندکی کاهش داده است؛ انتخاب آستانه همچنان پیش از دیدن نتایج آزمون انجام شده است.

۲-۸-۵-۴ سناریوی ۱۰۰ کلاینت

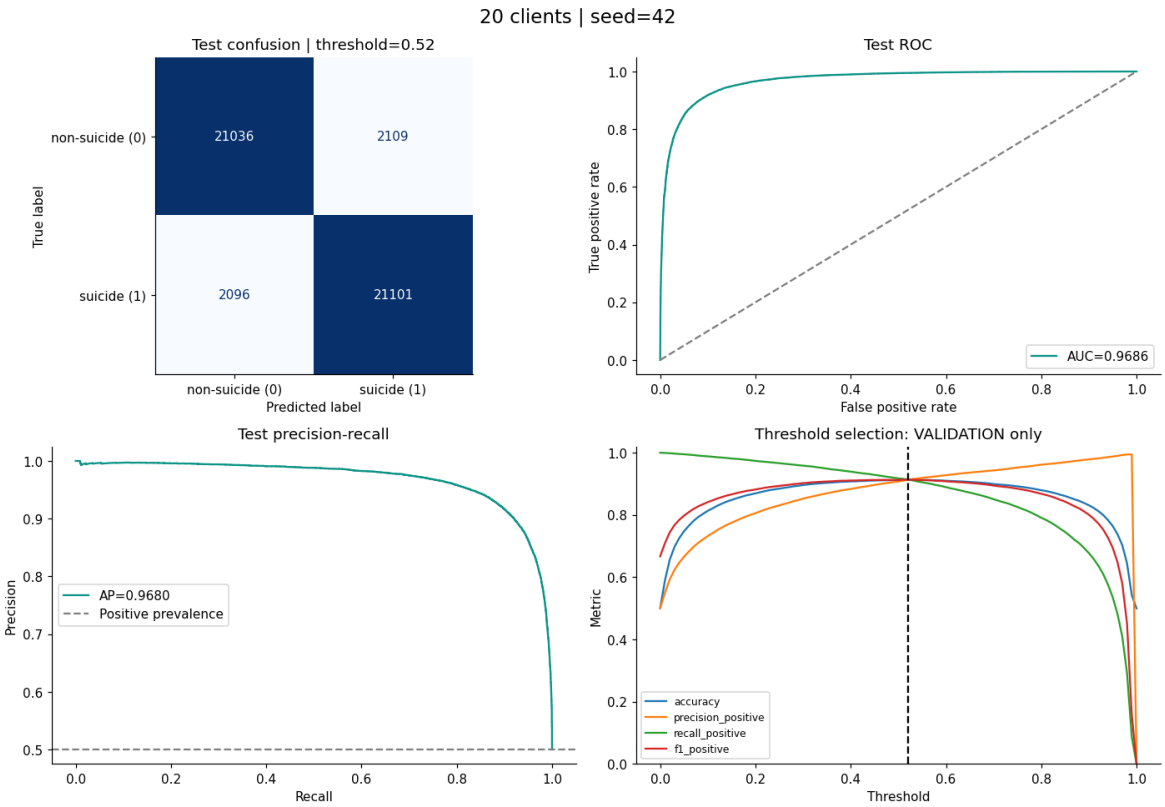
هر کلاینت به‌طور میانگین ۸٫۴۸۳٬۱ نمونه دارد. آستانهٔ اعتبارسنجی همان ۵٫۰ است و بنابراین دو تنظیم آستانه نتیجهٔ یکسانی دارند. F_1 مثبت اعتبارسنجی ۸۷۳۷٫۰ و دقت آزمون ۸۷۰۰٫۰ است. بازیابی مثبت ۸۸۷۴٫۰ و دقت مثبت ۸۵۷۸٫۰ است. تعداد مثبت کاذب ۴۱۲٬۳ و تعداد منفی کاذب ۶۱۲٬۲ است. میانگین اندازهٔ واژگان محلی به ۱۳٫۱۹۲٬۵ کاهش یافته است. در نتیجه، حفظ نسبت تقریباً یکسان کلاس‌ها به‌تنهایی برای حفظ کیفیت مدل‌های محلی در اندازه‌های کوچک کافی نبوده است.

۲-۸-۶ تحلیل مقایسه‌ای و حدود اعتبار نتایج

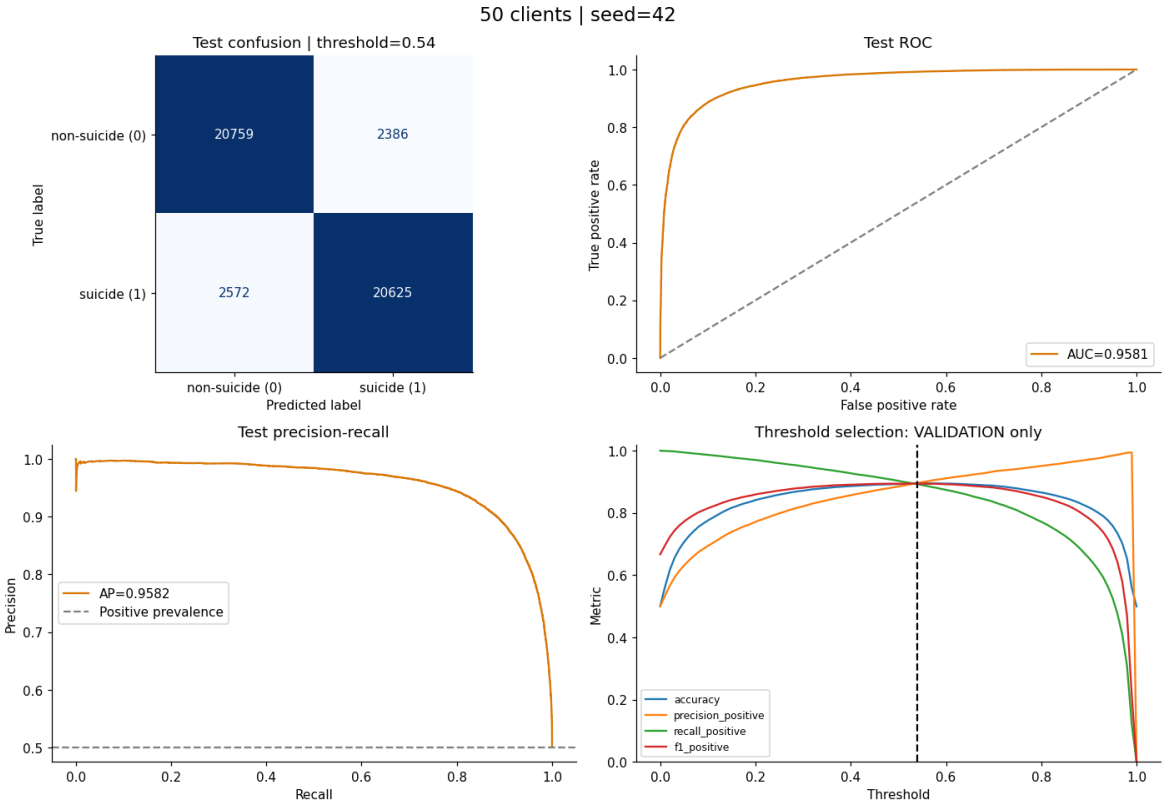
با ثابت ماندن کل دادهٔ آموزش، افزایش تعداد کلاینت‌ها، حجم دادهٔ محلی هر مدل و اندازهٔ واژگان محلی آن را کاهش می‌دهد. در اجرای ثبت‌شده، دقت آزمون با آستانهٔ منتخب از ۹۱۵۸٫۰ در ۱۰ کلاینت به ۸۷۰۰٫۰ در ۱۰۰ کلاینت می‌رسد؛ افتی برابر ۵۸٫۴ واحد درصد. F_1 مثبت نیز از ۹۱۶۴٫۰ به ۸۷۲۴٫۰ کاهش می‌یابد. افت ROC AUC از ۹۷۲۷٫۰ به ۹۴۳۵٫۰ نشان می‌دهد که تفاوت صرفاً ناشی از آستانه نیست. با این حال، این مشاهده به همین طراحی، مجموعه‌داده، پارامترها و بذر محدود است و یک حکم کلی دربارهٔ تمام روش‌های یادگیری مشارکتی محسوب نمی‌شود.



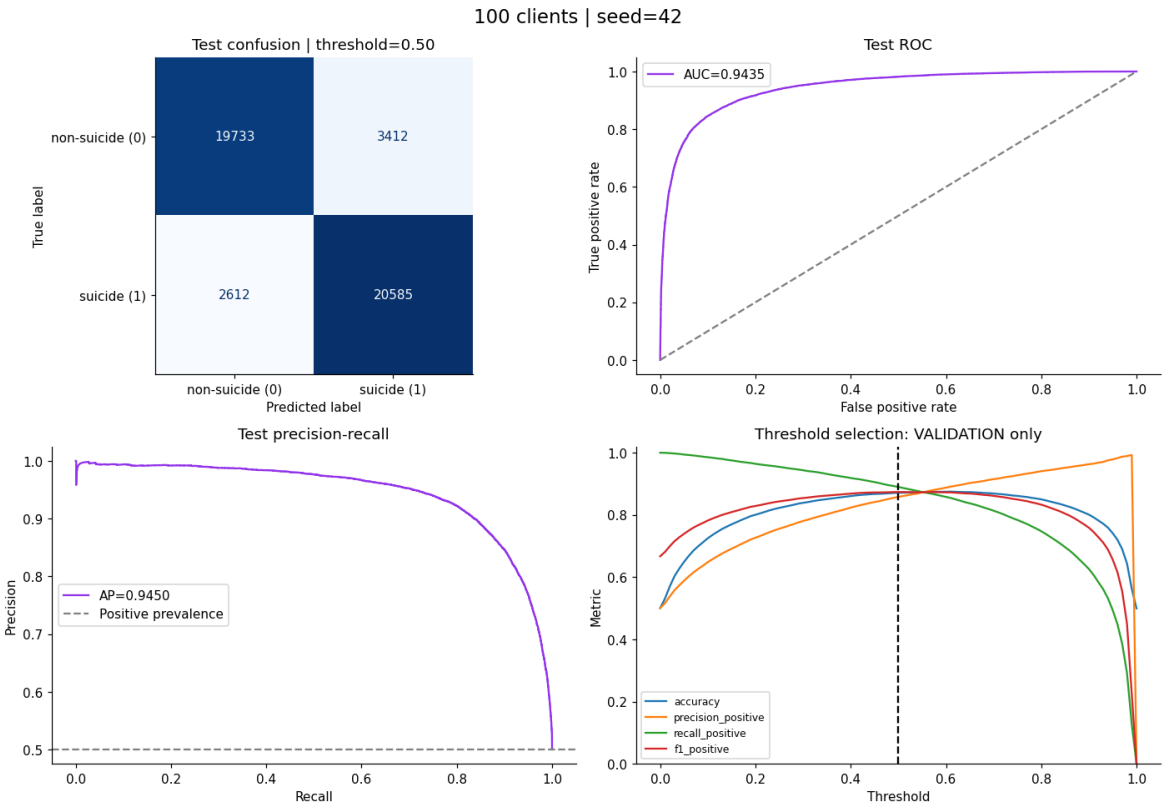
شکل ۲–۱۶: گزارش مستقل ۱۰ کلاینت: ماتریس سردرگمی و منحنی‌های ارزیابی و آستانه



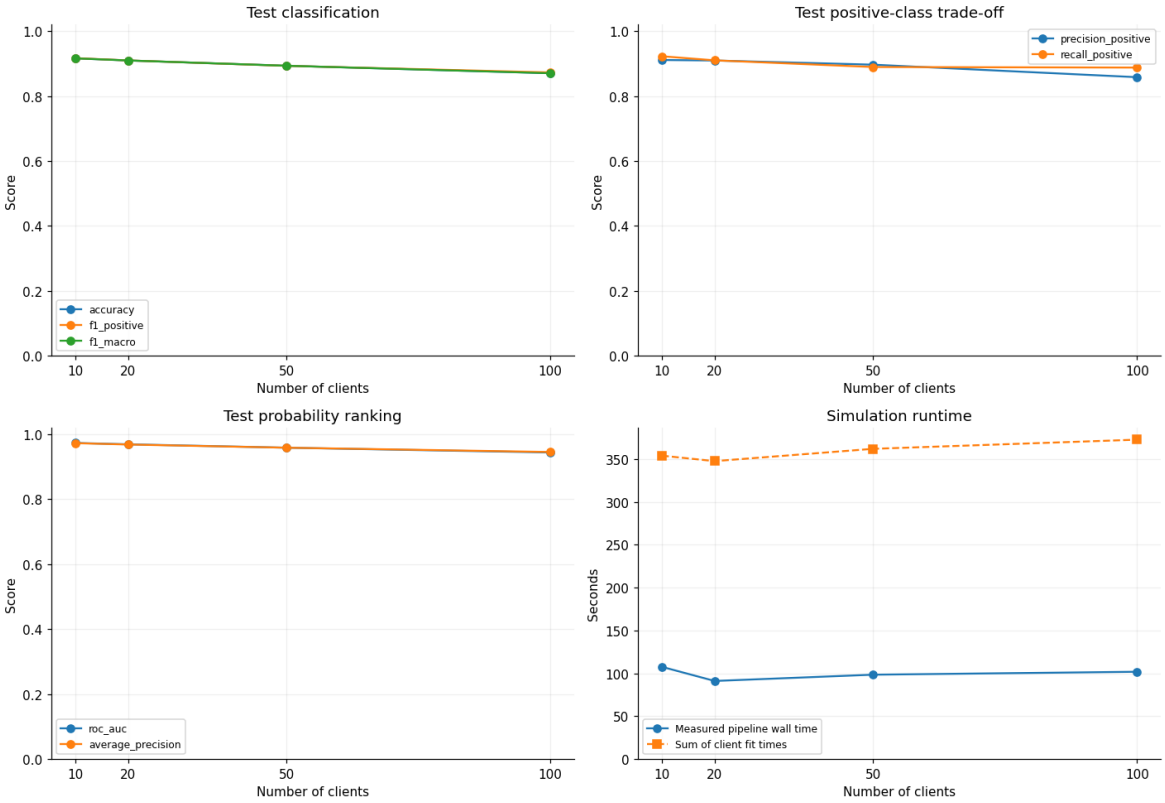
شکل ۲–۱۷: گزارش مستقل ۲۰ کلاینت با آستانهٔ منتخب ۰٫۵۲



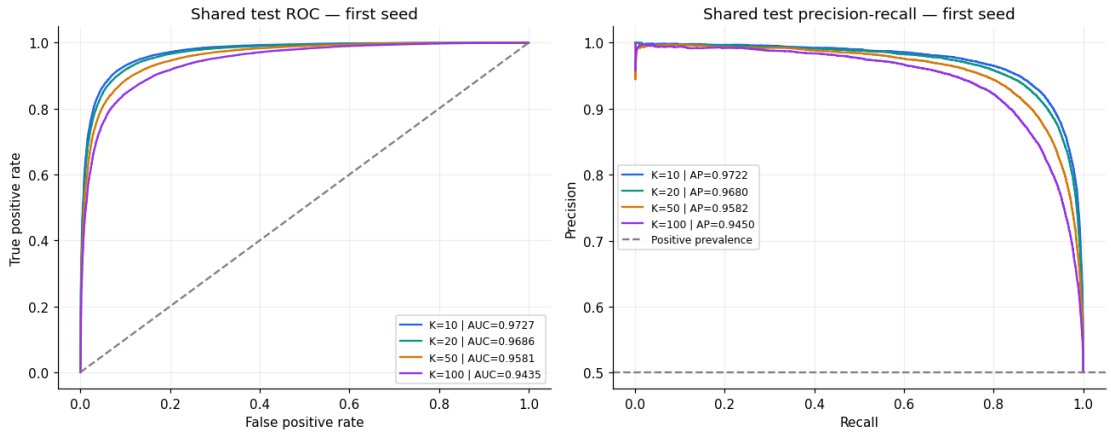
شکل ۲–۱۸: گزارش مستقل ۵۰ کلاینت با آستانهٔ منتخب ۰٫۵۴



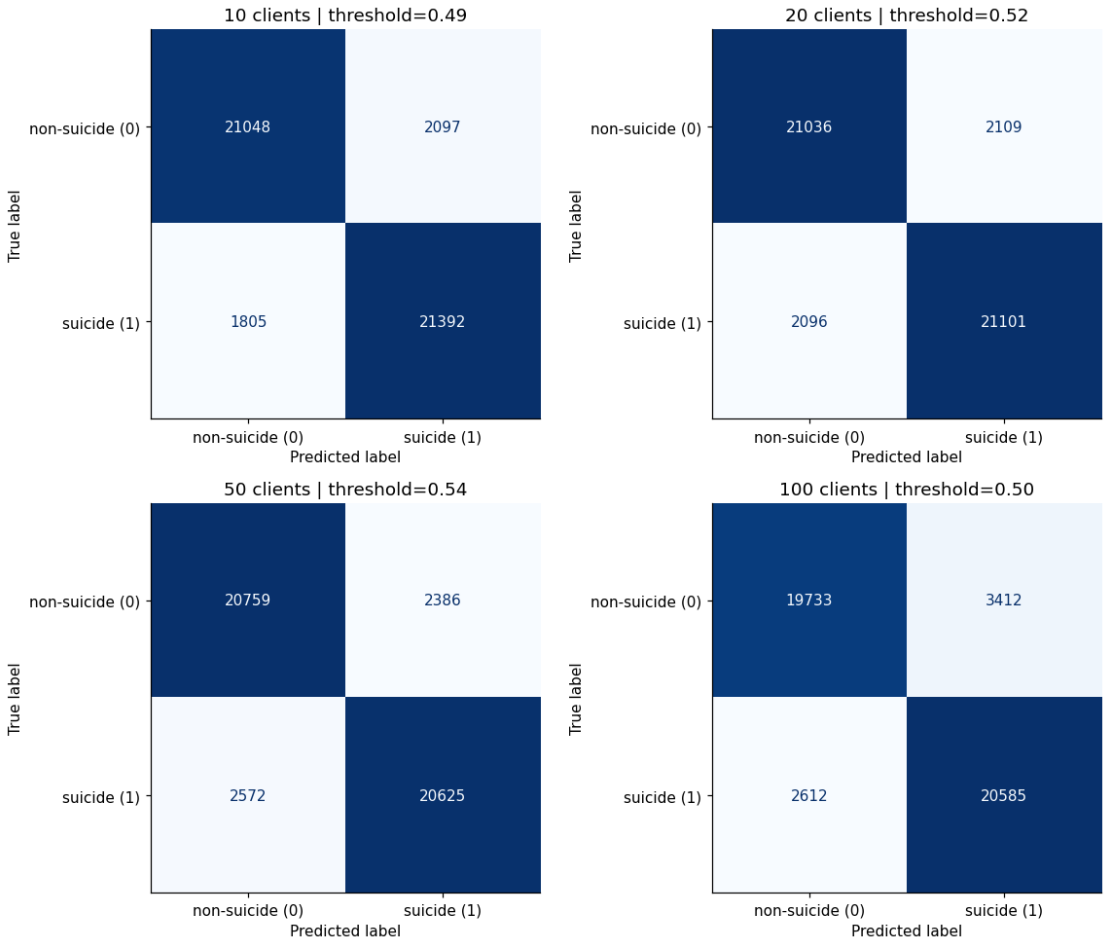
شکل ۲–۱۹: گزارش مستقل ۱۰۰ کلاینت با آستانهٔ ۰٫۵



شکل ۲–۲۰: مقایسهٔ معیارهای آزمون سناریوهای مشارکتی بر اساس خروجی ثبت‌شده



شکل ۲–۲۱: مقایسهٔ منحنی‌های ROC و دقت مثبت–بازیابی آزمون مشترک در چهار سناریو



شکل ۲-۲۲: مقایسهٔ ماتریس‌های سردرگمی چهار سناریو با آستانه‌های منتخب اعتبارسنجی

برای هر سناریو فقط یک بذر، یعنی ۴۲، اجرا شده است. بنابراین انحراف معیار بین اجراها، فاصلهٔ اطمینان تجربی و آزمون معنی‌داری بین سناریوها در دسترس نیست. گزارش عددی دقت نباید با قطعیت آماری یا ارزیابی بالینی اشتباه شود. این داده‌ها از متن‌های شبکهٔ اجتماعی به دست آمده‌اند و برچسب متنی لزوماً معادل تشخیص بالینی خطر فرد نیست.

مقایسه با مدل متمرکز نیز باید با توجه به تنظیم‌ها انجام شود. مدل متمرکزِ منتخب، ۱۵۰ درخت، عمق ۱۰ و نرخ یادگیری ۲٫۰ دارد؛ مدل‌های محلی این بخش ۱۰۰ درخت، عمق ۵ و نرخ یادگیری ۱٫۰ دارند. بازنمایی متمرکز بر کل آموزش و بازنمایی‌های محلی بر بخش‌های جدا یاد گرفته می‌شوند. بنابراین اختلاف میان دقت ۷۰.۹۲ درصد مدل متمرکز و ۵۸٫۹۱ درصد سناریوی ۱۰ کلاینت، اثر خالصِ توزیع داده یا رمزگذاری را اندازه نمی‌گیرد. برایِ تفکیک علت‌ها به آزمایش کَنترل‌شده با تنظیم‌های همسان نیاز است.

۲-۸-۷ ارتباط نتیجهٔ مشارکتی با لایهٔ رمزگذاری همریخت

تجمیع احتمال در رابطهٔ (۲-۱۷) در نوت‌بوک با اعداد اعشاری و به‌صورت آشکار انجام شده است. فصل‌های بعد، سازوکار رمزگذاری و احراز اصالت همین نوع تجمیع عددی را تشریح می‌کنند؛ خروجی‌های این نوت‌بوک به‌تنهایی آزمایش یک سامانهٔ سرتاسری رمزگذاری‌شده نیستند. زمان‌های جدول ۲-۱۰ نیز زمان آموزش و پیش‌بینی مشارکتی‌اند و نباید با زمان رمزنگاری جمع شوند یا به‌عنوان زمان امنِ سرتاسری گزارش شوند.

در صورت استفاده از وزن صحیح $w_i = n_i$ و مقیاس $S = 10^4$، برای جلوگیری از بازگشت پیمانه‌ای در Benaloh باید

$$r > S \sum_i w_i = 10^4 \times 148380 = 1483800000 \tag{۲-۱۹}$$

برقرار باشد. پارامتر $r = 10000019$ در بنچمارک کوچک رمزنگاری برای این مجموع وزن کفایت نمی‌کند. اتصال عملی این دو آزمایش به انتخاب پارامتر پیام بزرگ‌تر، بررسی هزینهٔ رمزگشایی و اندازه‌گیری اثر کوانتیزه‌سازی نیاز دارد. نرمال‌سازی وزن‌ها به اعداد صحیح کوچک‌تر نیز یک تقریب تازه ایجاد می‌کند و بدون ارزیابی نمی‌توان آن را معادل وزن‌دهی اصلی دانست. این تمایز، مرز میان نتایج یادگیری و نتایج لایهٔ امنیت را روشن نگه می‌دارد.

فصل ۳

سپری از اعداد؛ طراحی بستر تبادل داده و رمزگذاری همریخت

آزمایش فصل قبل نشان داد که می‌توان دادهٔ آموزش را میان کلاینت‌ها تقسیم و احتمال‌های خروجی مدل‌های محلی را تجمیع کرد. این جداسازی به‌خودی‌خود امنیت کانال یا محرمانگی خروجی منفرد را تضمین نمی‌کند. برای تحلیل لایهٔ تبادل داده، باید میان حفاظت از متن ورودی، مدیریت کلید، اصالت پیام و محاسبه بر متن رمز تمایز گذاشت. در این فصل، ابتدا رمزگذاری احرازاصالت‌شده و تسهیم راز، سپس پنج طرح همریخت و در پایان نتایج بنچمارک موجود بررسی می‌شوند.

در معماری مفهومی، سرور یک متن پرسش مشترک را برای پیش‌بینی در اختیار کلاینت‌ها قرار می‌دهد. هر کلاینت از مدل محلی خود احتمال کلاس مثبت را محاسبه می‌کند. تجمیع جمعی این احتمال‌ها به طرحی با همریختی جمعی نیاز دارد؛ همریختی ضربی به‌تنهایی میانگین وزنی مورد نظر را محاسبه نمی‌کند. همچنین، انتشار کلید عمومی باید به هویت معتبر متصل باشد؛ عمومی بودن کلید، نیاز به اصالت‌سنجی آن را از میان نمی‌برد.

۳-۱ رمزگذاری متن ورودی با AES-GCM

AES یک رمز بلوکی متقارن است؛ حالت GCM آن رمزگذاری احرازاصالت‌شده با دادهٔ مرتبط را فراهم می‌کند [۱۸۶]. کلید نشست ۲۵۶بیتی K با مولد تصادفی امن سیستم‌عامل تولید می‌شود. برای هر پیام، مقدار یک‌بارمصرف N، معمولاً با طول ۹۶ بیت، باید تحت همان کلید تکرار نشود. رابطهٔ رمزگذاری به‌صورت

$$(C, T) = \mathrm{Enc}_{\text{AES-GCM}}(K, N, M, A) \tag{۳-۱}$$

است. M متنِ تبدیل‌شده به بایت، A دادهٔ مرتبط احرازاصالت‌شده، C متن رمز و T برچسب احراز اصالت است. دادهٔ مرتبط می‌تواند شناسهٔ پروتکل، دور یا نسخه را شامل شود؛ این داده رمز نمی‌شود، اما تغییر آن باید اعتبار برچسب را از بین ببرد.

در رمزگشایی، گیرنده باید پیش از استفاده از متن، برچسب را اعتبارسنجی کند:

$$\mathrm{Dec}_{\text{AES-GCM}}(K,N,C,A,T)=\begin{cases}M, & \text{برچسب معتبر باشد،}\\ \perp, & \text{در غیر این صورت.}\end{cases} \tag{۲-۳}$$

اعتبارسنجی ناموفق باید به رد پیام بینجامد. تصادفی بودن nonce نیاز به کنترل احتمال برخورد و سیاست تعویض کلید را حذف نمی‌کند. استفادهٔ مجدد از یک nonce با همان کلید می‌تواند امنیت GCM را به‌شدت تضعیف کند. در اینجا «اصالت» به معنای معتبر بودن پیام نسبت به دارندهٔ کلید مشترک است و با هویت غیرقابل‌انکار یک فرستندهٔ مشخص یکسان نیست.

۳-۱-۱ ضرورت و مبانی تسهیم راز شامیر

طرح شامیر امکان تعریف سیاست آستانه‌ای برای دسترسی به یک راز را فراهم می‌کند [۱۸۵]. در طرح (t,n)، راز به n سهم تقسیم می‌شود؛ هر t سهم معتبر برای بازسازی کافی است و کمتر از t سهم، در مدل ایده‌آل، اطلاعاتی دربارهٔ راز نمی‌دهد. انتخاب $t=n$ همکاری تمام اعضا را لازم می‌کند، اما تحمل خروج یا خرابی یک عضو را کاهش می‌دهد. انتخاب $t<n$ دسترس‌پذیری بیشتری فراهم می‌کند و هم‌زمان مجموعهٔ کوچک‌تری را برای بازسازی مجاز می‌سازد.

راز صحیح s باید در میدان $\mathbb{F}_p$ قرار گیرد. برای بازنمایی یک کلید ۲۵۶بیتی، انتخاب عدد اول $p=2^{521}-1$ ظرفیت کافی دارد. ضرایب $a_1,\dots,a_{t-1}$ مستقل و یکنواخت در میدان انتخاب می‌شوند و

$$f(X)=s+\sum_{j=1}^{t-1}a_jX^j \pmod p. \tag{۳-۳}$$

برای نقاط متمایز و ناصفر $x_i\in\mathbb{F}_p$، سهم عضو i برابر (x_i,y_i) با $y_i=f(x_i)$ است. می‌توان $x_i=i$ را برای $1\le i\le n<p$ برگزید. عمومی بودن مختصهٔ x_i مشکلی ایجاد نمی‌کند؛ مؤلفهٔ y_i باید محرمانه و اصالت‌سنجی‌شده به گیرنده برسد.

۳-۱-۲ بازسازی کلید با درونیابی لاگرانژ

اگر I مجموعهٔ t عضو مشارکت‌کننده باشد، راز از ارزیابی چندجمله‌ای در صفر بازیابی می‌شود:

$$s=f(0)=\sum_{i\in I}y_i\ell_i(0) \pmod p, \tag{۴-۳}$$

$$\ell_i(0)=\prod_{\substack{j\in I\\ j\neq i}}\frac{-x_j}{x_i-x_j} \pmod p. \tag{۵-۳}$$

تقسیم در این رابطه به معنای ضرب در وارون پیمانه‌ای است. تمایز نقاط تضمین می‌کند مخرج‌ها ناصفر باشند. یک چندجمله‌ای با درجهٔ حداکثر $t-1$ با t نقطه به‌طور یکتا تعیین می‌شود؛ بنابراین بازسازی درست، همان جملهٔ ثابت اولیه را به دست می‌دهد.

برای نمونه، در پیکربندی $(t,n)=(5,5)$، چهار سهم برای تعیین راز کافی نیست؛ در پیکربندی $(3,5)$، هر

سه سهم معتبر امکان بازسازی را دارند. این تفاوت صرفاً یک انتخاب عددی نیست؛ سیاست اعتماد و دسترس‌پذیری سامانه را تعریف می‌کند. افزودن سهم‌های بیشتر از حد آستانه، بدون اعتبارسنجی سهم‌ها، از خرابکاری یک عضو جلوگیری نمی‌کند؛ تسهیم راز قابل‌راستی‌آزمایی مسئله‌ای جداگانه است.

۳-۱-۳ ویژگی امنیتی و حدود آن

در مدل شامیر با ضرایب یکنواخت، برای هر مقدار فرضی راز و هر مجموعهٔ کمتر از t سهم، ضرایبی سازگار وجود دارد. ازاین‌رو مشاهدهٔ آن سهم‌ها توزیع راز را تغییر نمی‌دهد؛ این یک ویژگی اطلاعاتی است و به محدود بودن توان محاسباتی مهاجم وابسته نیست. در مقابل، امنیت AES-GCM محاسباتی و وابسته به پارامترها و استفادهٔ صحیح از کلید و nonce است.

تسهیم راز به این معنا نیست که کلید هیچ‌گاه به‌طور کامل در اختیار هیچ موجودیتی قرار نمی‌گیرد. سرور تولیدکننده از ابتدا کلید را می‌داند و گیرندهٔ مجاز پس از بازسازی نیز کلید کامل را در اختیار دارد. اگر هدف، جلوگیری از افشای کلید حتی هنگام استفاده باشد، به پروتکل محاسبهٔ آستانه‌ای یا سخت‌افزار و مدل اعتماد دیگری نیاز است. همچنین، ارسال تمام سهم‌ها روی یک مسیر قابل‌شنود، حفاظت آستانه‌ای را در برابر شنودگر همان مسیر بی‌اثر می‌کند.

۳-۱-۴ جریان کامل پروتکل و مدل تهدید

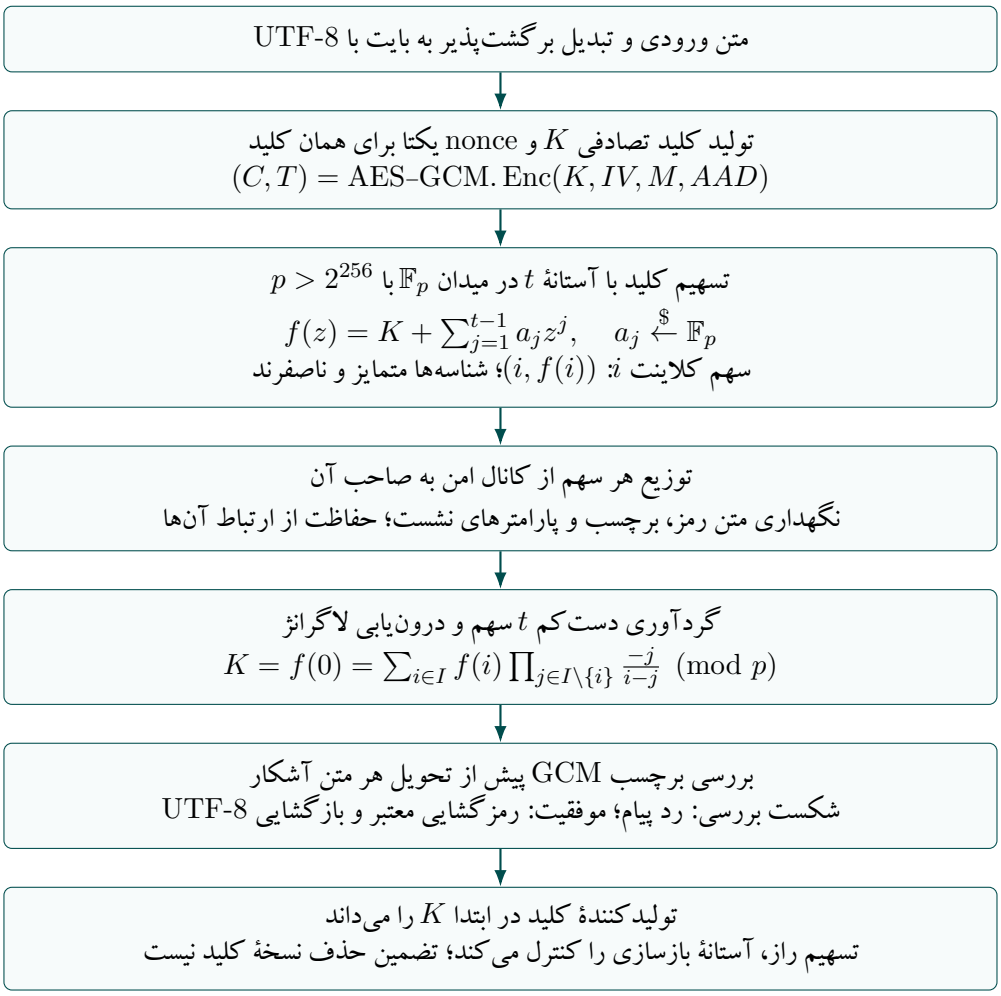
جریان مفهومی از دریافت رشتهٔ ورودی، تبدیل UTF-8، تولید کلید و nonce، رمزگذاری و تولید برچسب، ایجاد سهم‌ها، توزیع امن سهم‌ها، گردآوری تعداد کافی، بازسازی کلید، بررسی برچسب و تبدیل بایت‌های معتبر به متن تشکیل می‌شود. در تمام مراحل، قالب پیام، شناسهٔ دور و ارتباط میان متن رمز و سهم‌های همان نشست باید روشن باشند.

شنودگر شبکه بدون کلید یا تعداد کافی سهم نباید به متن برسد. مهاجم فعال ممکن است پیام، سهم یا شناسهٔ نشست را تغییر دهد؛ برچسب GCM فقط بخش‌های تحت پوشش خود را کنترل می‌کند و برای سهم‌های نامعتبر به کنترل جداگانه نیاز است. تبانی t عضو برای بازسازی، نقض طرح نیست؛ دقیقاً همان سیاست مجاز طرح آستانه‌ای است. افشای کلید در حافظهٔ گیرنده، نشت کانال جانبی، بازیابی پس از خرابی و ثبت‌نشدن مناسب nonce نیز خارج از تضمین جبری شامیر هستند.

ارزیابی سادهٔ چندجمله‌ای برای n سهم، $O(nt)$ عملیات میدان و بازسازی مستقیم با t سهم، $O(t^2)$ عملیات میدان دارد. رمزگذاری متقارن نسبت به طول پیام خطی است. این مرتبه‌ها، تحلیل الگوریتمی‌اند؛ زمان دیواری واقعی به کتابخانه، طول پیام، سخت‌افزار و هزینهٔ شبکه وابسته است. در نتایج عددی این پایان‌نامه، زمان رمزنگاری همریخت و زمان آموزش مدل به‌طور جداگانه گزارش می‌شوند.

۳-۲ ارسال خروجی کلاینت‌ها با رمزگذاری همریخت

فرض کنید تابع مورد نظر، مجموع یا میانگین وزنی مقادیر عددی باشد. طرح همریخت جمعی اجازه می‌دهد از متن‌های رمز، متن رمزِ مجموع ساخته شود. طرح همریخت ضربی، متن رمزِ حاصل‌ضرب را تولید می‌کند. این دو خاصیت نباید با هم جابه‌جا شوند. علاوه بر این، انجام عملیات روی متن رمز، به‌خودی‌خود احراز هویت، کنترل وزن، جلوگیری از بازپخش یا صحت ورودی اعلام‌شده را تأمین نمی‌کند.



شکل ۳-۱: نمای مفهومی حفاظت از متن ورودی با رمزگذاری متقارن و تسهیم راز؛ کانال امن سهم‌ها و کنترل آستانه از پیش‌شرط‌های طرح‌اند

۳-۲-۱ رمزگذاری ElGamal

طرح الجمال در سال ۱۹۸۵ بر پایهٔ ساختار گروهی و لگاریتم گسسته معرفی شد [۱۷۸]. در گروه چرخه‌ای مناسب $G = \langle g \rangle$ با مرتبهٔ q، کلید خصوصی x به‌طور تصادفی انتخاب و کلید عمومی $h = g^x$ محاسبه می‌شود. پیام باید عضوی از G باشد. برای تصادف تازهٔ k داریم:

$$PK = (G, q, g, h), \qquad SK = x, \tag{۳-۶}$$

$$\mathrm{Enc}(m; k) = (c_1, c_2) = (g^k, mh^k), \qquad \mathrm{Dec}(c_1, c_2) = c_2(c_1^x)^{-1}. \tag{۳-۷}$$

عملیات در گروه انجام می‌شوند؛ در نمایش پیمانه‌ای، ضرب و وارون در پیمانهٔ عدد اول مربوط محاسبه می‌شوند. درستی مستقیم است، زیرا $h^k = g^{xk}$ و $c_1^x = g^{kx}$، پس عامل تصادفی حذف می‌شود.

اگر $C_1 = \mathrm{Enc}(m_1; k_1)$ و $C_2 = \mathrm{Enc}(m_2; k_2)$ باشند، ضرب مؤلفه‌ای آن‌ها می‌دهد:

$$C_1 \odot C_2 = (g^{k_1+k_2}, m_1 m_2 h^{k_1+k_2}) = \mathrm{Enc}(m_1 m_2; k_1 + k_2). \tag{۳-۸}$$

بنابراین خاصیت اصلی این صورت از الجمال، ضربی است. رمز کردن توان یک مولد می‌تواند صورت جمعی برای مقادیر محدود ایجاد کند، اما رمزگشایی آن به بازیابی توان و محدودیت‌های اضافی نیاز دارد؛ این تبدیل، همان طرح ضربی بنچمارک حاضر نیست.

امنیت معنایی صورت استاندارد الجمال به فرض مناسب DDH در گروه انتخاب‌شده وابسته است. صرف بزرگ بودن عدد اول یا انتخاب یک مولد، این فرض را برای هر گروه دلخواه برقرار نمی‌کند. نسخهٔ پایه نیز تغییرپذیر است و حفاظت در برابر متن رمز انتخاب‌شده را خودکار فراهم نمی‌کند. تولید گروه، اعتبارسنجی اعضا، تصادف تازه و حفاظت از کلید خصوصی برای کاربرد عملی ضروری‌اند.

۳-۲-۲ رمزگذاری Paillier

پایهٔ طرح پاییه، ساختار باقیمانده‌های مرکب است [۱۷۹]. دو عدد اول متمایز p, q انتخاب، $n = pq$ و $\lambda = \mathrm{lcm}(p-1, q-1)$ محاسبه می‌شوند. تابع $L(u) = (u-1)/n$ برای $u \equiv 1 \pmod{n}$ تعریف می‌شود. عنصر $g \in \mathbb{Z}_{n^2}^*$ باید به‌گونه‌ای انتخاب شود که مقدار زیر وجود داشته باشد:

$$\mu = \left[L(g^\lambda \bmod n^2)\right]^{-1} \pmod{n}. \tag{۳-۹}$$

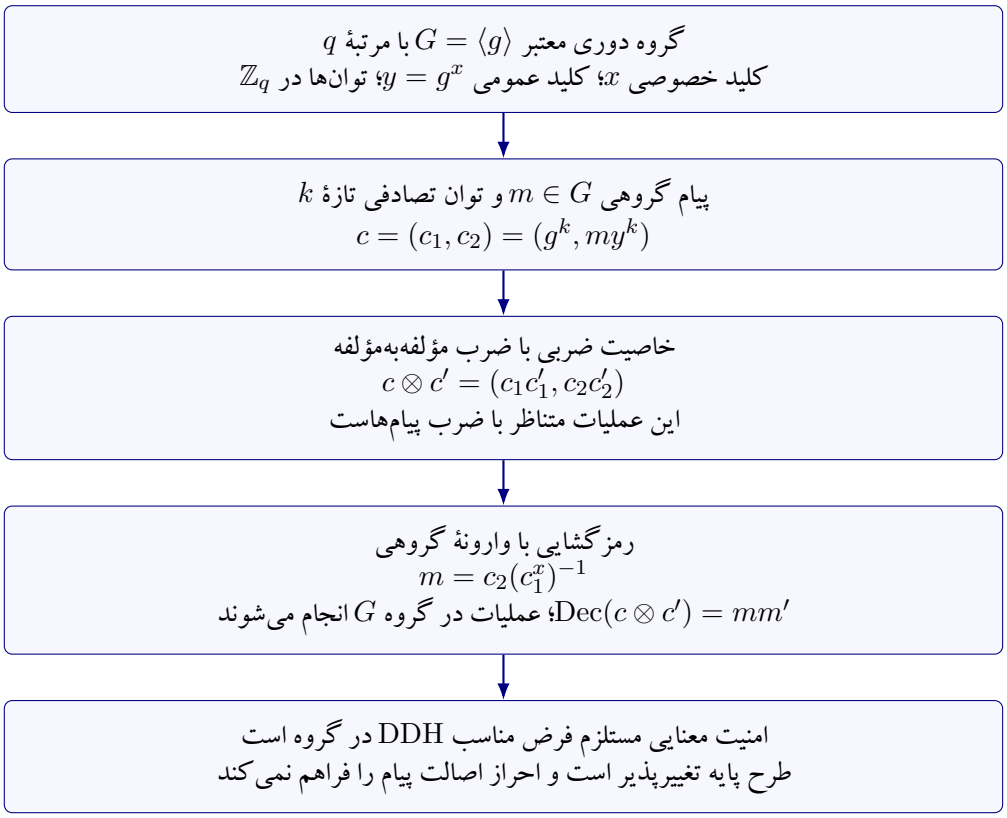
کلید عمومی (n, g) و کلید خصوصی (λ, μ) است. برای $m \in \mathbb{Z}_n$ و تصادف مستقل $u \in \mathbb{Z}_n^*$، رابطه‌های رمزگذاری و رمزگشایی عبارت‌اند از

$$c = g^m u^n \pmod{n^2}, \tag{۳-۱۰}$$

$$m = L(c^\lambda \bmod n^2)\mu \pmod{n}. \tag{۳-۱۱}$$

انتخاب متداول $g = n + 1$، در صورت برقرار بودن شرایط وارون‌پذیری، محاسبات را ساده می‌کند. نقش تصادف u این است که رمزگذاری یک پیام ثابت هر بار همان متن رمز را تولید نکند.

درستی از حذف عامل تصادفی پس از توان‌رسانی و خطی شدن توان g در تابع L حاصل می‌شود. اگر $c_i =$



شکل ۳-۲: طرح مفهومی رمزگذاری و رمزگشایی الجمال

$g^{m_i} u_i^n$ باشد، داریم:

$$c_1 c_2 = g^{m_1+m_2}(u_1 u_2)^n \pmod{n^2}, \tag{۱۲-۳}$$

$$\mathrm{Dec}(c_1 c_2) = m_1 + m_2 \pmod{n}, \qquad \mathrm{Dec}(c^w) = wm \pmod{n}. \tag{۱۳-۳}$$

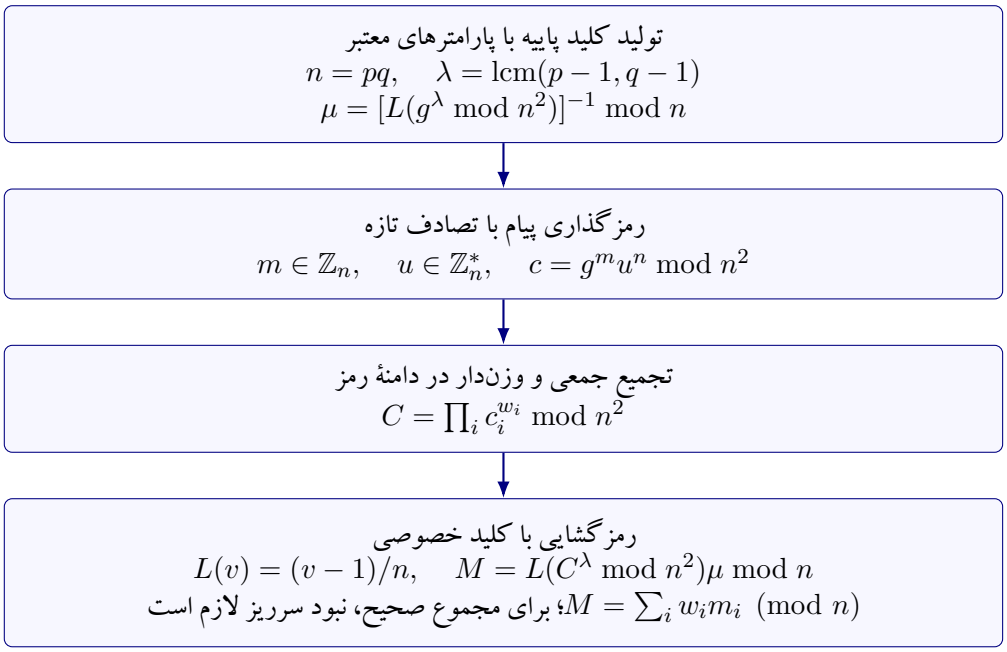
توان w در دامنهٔ رمز معادل ضرب در عدد آشکار w در دامنهٔ پیام است؛ به این ترتیب مجموع وزن‌دار بدون رمزگشایی تک‌تک پیام‌ها ساخته می‌شود. اگر هدف، مجموع صحیحِ معمول باشد، نه مجموع پیمانه‌ای، باید پیش از عملیات از نبود سرریز اطمینان حاصل شود.

پاییه برای تجمیع جمعی مناسب است، اما امضای فرستنده، سیاست وزن و کنترل بازپخش را فراهم نمی‌کند. نسخهٔ پایه با وجود امنیت تحت فرض مربوط، در برابر هر نوع مهاجم فعال مصون نیست. تبدیل‌های عمومیِ مقاوم در برابر متن رمز انتخاب‌شده نیز لزوماً خاصیت همریختی مورد نیاز را حفظ نمی‌کنند؛ افزودن یک لایهٔ امنیتی باید با هدف جبری طرح سازگار بررسی شود.

۳-۲-۳ رمزگذاری Benaloh

طرح بنالوح فضای پیام بلوکی $\mathbb{Z}_r$ را به کار می‌گیرد [۱۸۰]. برای صورت متداول، اعداد اول به‌گونه‌ای انتخاب می‌شوند که

$$r \mid (p-1), \qquad \gcd\left(r, \frac{p-1}{r}\right) = 1, \qquad \gcd(r, q-1) = 1. \tag{۱۴-۳}$$



شکل ۳-۳: نمای مفهومی پایه؛ محاسبات متن رمز در پیمانهٔ n^2 انجام می‌شوند

تعویض نام p و q این ساختار را تغییر نمی‌دهد؛ پیاده‌سازی مخزن، شرط بخش‌پذیری را بر عامل دیگر اعمال می‌کند. با $n = pq$ و $\varphi(n) = (p-1)(q-1)$، باید $y \in \mathbb{Z}_n^*$ به‌گونه‌ای انتخاب شود که $a = y^{\varphi(n)/r} \bmod n$ دارای مرتبهٔ دقیق r باشد. وقتی r اول است، شرط $a \neq 1$ همراه با شرایط پارامترها کافی است. برای r مرکب، بررسی عامل‌های اولِ مرتبه نیز لازم است.

کلید عمومی (n, y, r) و مادهٔ خصوصی شامل عوامل n است. رمزگذاری پیام $m \in \{0, \ldots, r-1\}$ با تصادف $u \in \mathbb{Z}_n^*$ چنین تعریف می‌شود:

$$c = y^m u^r \pmod n. \tag{۱۵-۳}$$

برای رمزگشایی، مقدار $b = c^{\varphi(n)/r} \bmod n$ محاسبه می‌شود. چون $u^{\varphi(n)} \equiv 1 \pmod n$، داریم

$$b = a^m \pmod n. \tag{۱۶-۳}$$

بازیابی m یک لگاریتم گسسته در زیرگروه با مرتبهٔ معلوم r است. برای فضای پیام کوچک، جدول کامل قابل استفاده است؛ پیاده‌سازی حاضر از baby-step/giant-step با هزینهٔ زمانی و حافظهٔ مرتبهٔ $O(\sqrt{r})$ استفاده می‌کند. کوچک بودن فضای پیام یک انتخاب محاسباتی مهم است و افزایش آن بدون اندازه‌گیری هزینهٔ رمزگشایی مجاز نیست.

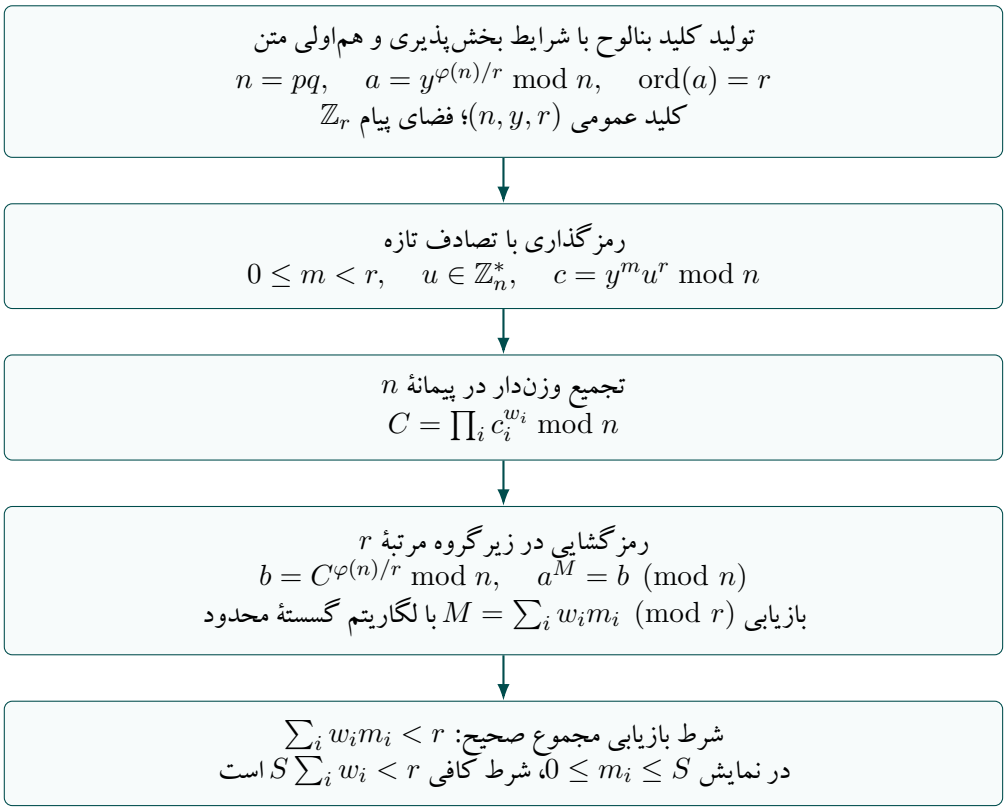
خاصیت جمعی از ضرب متن‌های رمز نتیجه می‌شود:

$$c_1 c_2 = y^{m_1+m_2}(u_1 u_2)^r \pmod n, \tag{۱۷-۳}$$

$$\mathrm{Dec}(c_1 c_2) = m_1 + m_2 \pmod r, \qquad \mathrm{Dec}(c^w) = wm \pmod r. \tag{۱۸-۳}$$

در بنچمارک موجود، $r = 10000019$ است. این مقدار برای نمایش چهاررقم اعشار و مجموع وزن محدود مناسب

است، اما برای وزن‌های صحیحِ برابر تعداد تمام نمونه‌های محلی فصل قبل کافی نیست. شرط ظرفیت در رابطهٔ (۲–۱۹) و فصل بعد صریحاً بررسی می‌شود.



شکل ۳–۴: نمای مفهومی بنالوح؛ مرتبهٔ فضای پیام و روش لگاریتم گسسته بر هزینهٔ رمزگشایی اثر دارند

۳–۲–۴ تعمیم Damgård–Jurik و تخصص $s = 1$

دامگارد–یوریک فضای پیام پاییه را با پارامتر $s \ge 1$ گسترش می‌دهد [۱۸۱]. در صورت متداول، پیام در $\mathbb{Z}_{n^s}$ و متن رمز در $\mathbb{Z}_{n^{s+1}}^*$ قرار دارد:

$$c = (1+n)^m u^{n^s} \pmod{n^{s+1}}. \tag{۳–۱۹}$$

خاصیت جمعی در فضای بزرگ‌تر حفظ می‌شود: $\mathrm{Dec}(c_1 c_2) = m_1 + m_2 \pmod{n^s}$. با این حال، تعمیم مستقیمِ رمزگشایی پاییه با همان $L(u) = (u-1)/n$ برای هر s درست نیست. جمله‌های مرتبهٔ بالاترِ بسط دوجمله‌ای باید لحاظ شوند:

$$(1+n)^a \equiv \sum_{j=0}^{s} \binom{a}{j} n^j \pmod{n^{s+1}}. \tag{۳–۲۰}$$

اگر L_s وارون نگاشت $a \mapsto (1+n)^a$ در زیرگروه مناسب و پیمانهٔ n^s باشد، رمزگشایی را در شرایط معتبر پارامترها می‌توان به‌صورت $m = L_s(c^\lambda)\lambda^{-1} \pmod{n^s}$ نوشت. محاسبهٔ L_s به استخراج مرحله‌ای رقم‌های توان نیاز دارد؛ این نماد همان تقسیم سادهٔ تابع L در پاییه نیست.

برای $s = 1$، جمله‌های بالاتر حذف و رمزگشایی به صورت پاییه کاهش می‌یابد. کد و بنچمارک فعلی مخزن صریحاً همین تخصص $s = 1$ را پشتیبانی می‌کنند. بنابراین زمان‌های گزارش‌شده، شاهد اجرای نسخهٔ عمومی برای $s > 1$ نیستند. مزیت نظری فضای پیامِ قابل‌تنظیم، بدون پیاده‌سازی و آزمون نسخهٔ عمومی نباید به‌عنوان قابلیت اندازه‌گیری‌شده معرفی شود.

۳-۲-۵ رمزگذاری RSA

طرح RSA با انتخاب $n = pq$ و توان‌های e, d که $ed \equiv 1 \pmod{\varphi(n)}$ باشند تعریف می‌شود [۱۸۲]. توان e باید نسبت به $\varphi(n)$ اول باشد. در صورت پایه و بدون لایهٔ رمزگذاری احتمالی داریم:

$$PK = (n, e), \quad SK = (n, d), \qquad c = m^e \pmod{n}, \qquad m = c^d \pmod{n}. \tag{۲۱-۳}$$

برای پیام‌های نسبتاً اول با n، قضیهٔ اویلر درستی را نشان می‌دهد؛ برای حالت کلی نیز استدلال پیمانهٔ p و q و قضیهٔ باقیماندهٔ چینی نتیجه را برقرار می‌کند. این تفکیک مانع کاربرد نادرست قضیهٔ اویلر بر هر پیام دلخواه می‌شود.

نسخهٔ پایه همریختی ضربی دارد:

$$\mathrm{Dec}(c_1 c_2) = m_1 m_2 \pmod{n}, \qquad \mathrm{Dec}(c^w) = m^w \pmod{n}. \tag{۲۲-۳}$$

رابطهٔ دوم، ضرب wm نیست. بنابراین نمی‌توان با توان‌رسانی متن رمز RSA همان مجموع وزن‌دار مورد نیاز را محاسبه کرد. همچنین textbook RSA قطعی و فاقد امنیت معنایی لازم برای رمزگذاری کاربردی است. طرح‌های امنی مانند RSA-OAEP لایهٔ رمزگذاری متفاوتی دارند و خاصیت ضربی سادهٔ نسخهٔ پایه را برای این کاربرد حفظ نمی‌کنند.

۳-۳ مقایسهٔ نظری پنج طرح

جدول ۳-۱: فضای پیام و نوع همریختی؛ تمام رابطه‌ها در پیمانهٔ فضای پیام تفسیر می‌شوند

طرح	سال	فضای پیام	نتیجهٔ ضرب متن‌های رمز
ElGamal	۱۹۸۵	گروه G	$m_1 m_2$
Benaloh	۱۹۹۴	$\mathbb{Z}_r$	$m_1 + m_2$
Paillier	۱۹۹۹	$\mathbb{Z}_n$	$m_1 + m_2$
Damgård–Jurik	۲۰۰۱	$\mathbb{Z}_{n^s}$	$m_1 + m_2$
textbook RSA	۱۹۷۸	$\mathbb{Z}_n$	$m_1 m_2$

انتخاب طرح به تابع مورد نیاز وابسته است. برای میانگین وزنیِ خروجی مدل، یک جمع وزن‌دار لازم است؛ ازاین‌رو پاییه، بنالوح و تخصص جمعی دامگارد–یوریک تناسب جبری دارند. برای عملیات ضربی، الجمال و صورت پایهٔ RSA رفتار متفاوتی ارائه می‌کنند. هیچ‌یک از این خواص به‌تنهایی گواه امنیت عملی کل سامانه نیست. سطح امنیت، اصالت پارامترها، مدیریت کلید، مدل مهاجم و صحت پیاده‌سازی نیز باید بررسی شوند.

۳-۴ ارزیابی تجربی پیاده‌سازی‌های موجود

منبع عددی این بخش فایل Crypto/results/benchmark_all.csv است. این فایل ۱۵ ردیف، شامل پنج طرح در سه اندازهٔ ۲۵۶، ۵۱۲ و ۱۰۲۴ بیت دارد. نتایج، زمان‌های همان اجرای ذخیره‌شده‌اند؛ اندازه‌گیری جدید روی سخت‌افزار یکسان یا میانگین چند تکرار برای این فایل ادعا نمی‌شود. واحد تمام زمان‌های این بخش میلی‌ثانیه است.

۳-۴-۱ صحت‌سنجی و تفاوت بار کاری

در هر ۱۵ ردیف، وضعیت homomorphic_test برابر PASS و خطا صفر است. برای طرح‌های جمعی، آزمون شامل رمزگذاری ۱۰۰ مقدار با مقیاس چهاررقم اعشار، تجمیع با وزن صحیح و مقایسهٔ میانگین بازسازی‌شده با مقدار آشکار است. برای RSA و الجمال، آزمون، ضرب دو مقدار ۷ و ۱۱ و بازیابی ۷۷ است. در این دو طرح، weighted_average برابر NOT_APPLICABLE است؛ این وضعیت شکست آزمون نیست و همچنین موفقیت در محاسبهٔ میانگین وزنی را نشان نمی‌دهد.

بار کاری دو خانواده برابر نیست. مقدار «۱۰۰ کلاینت» در فرادادهٔ ردیف‌های ضربی نباید به‌عنوان رمزگذاری و رمزگشایی ۱۰۰ پیام در آن ردیف‌ها تفسیر شود. زمان‌های رمزگذاری و رمزگشایی آن‌ها در CSV جداگانه اندازه‌گیری نشده‌اند. علامت خط تیره در جدول‌ها همین نبود اندازه‌گیری را بیان می‌کند و مقدار صفر نیست. مقایسهٔ مستقیم زمان کل این دو نوع آزمون برای رتبه‌بندی هم‌ارز امنیت یا توان عملیاتی معتبر نیست.

جدول ۳-۲: زمان‌های طرح‌های جمعی برای ۱۰۰ پیام و تجمیع وزن‌دار

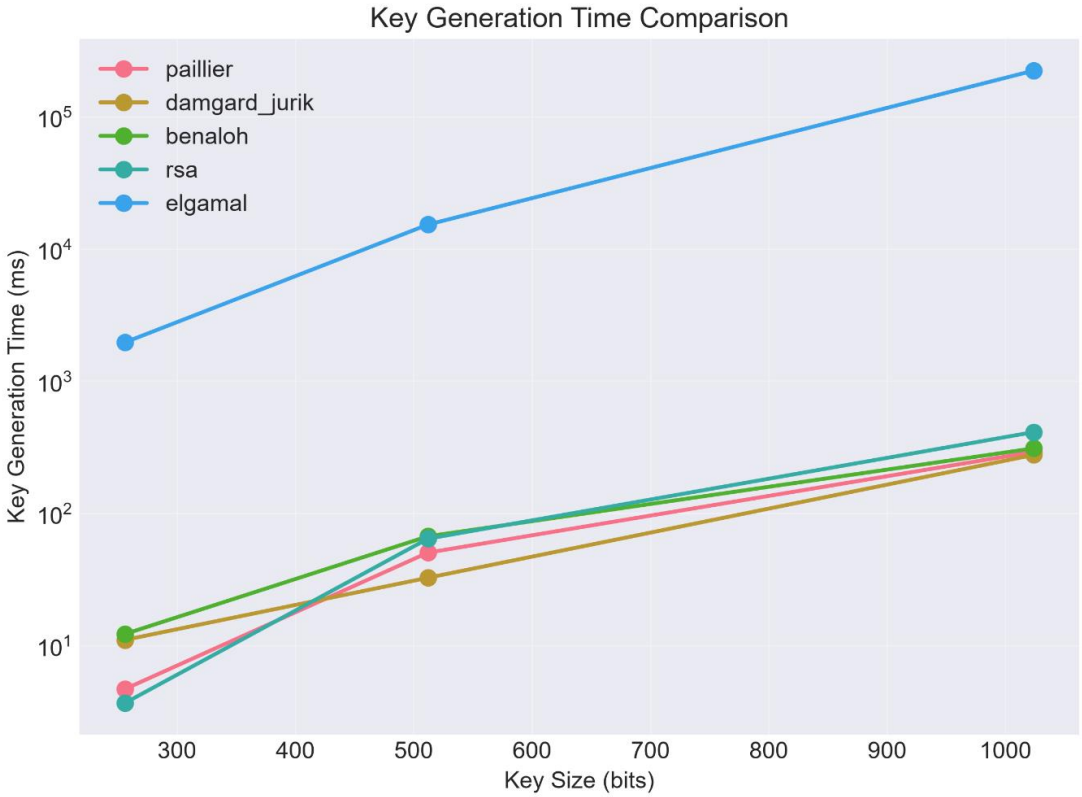
طرح	بیت	تولید کلید	رمزگذاری	تجمیع/آزمون	رمزگشایی	کل
Paillier	۲۵۶	۶۷۷۱.۴	۹۴۹۱.۱۱۹	۶۷۶۰.۱	۲۷۰۵.۱	۵۷۲۷.۱۲۷
Damgård–Jurik ($s = 1$)	۲۵۶	۰۱۶۲.۱۱	۶۵۲۶.۱۱۹	۱۵۸۸.۱	۹۳۹۹.۰	۷۶۷۵.۱۳۲
Benaloh	۲۵۶	۲۰۶۲.۱۲	۹۵۱۱.۷	۵۴۵۸.۰	۱۰۲۳.۲	۸۰۵۴.۲۲
Paillier	۵۱۲	۳۹۸۴.۵۰	۴۰۶۱.۷۳۰	۳۲۴۴.۴	۷۵۱۱.۶	۸۸۰۰.۷۹۱
Damgård–Jurik ($s = 1$)	۵۱۲	۵۲۸۱.۳۲	۰۴۰۷.۶۹۶	۳۲۴۷.۶	۸۳۶۸.۷	۷۳۰۳.۷۴۲
Benaloh	۵۱۲	۰۰۷۰.۶۷	۴۱۸۸.۲۳	۴۷۵۲.۱	۴۴۳۱.۵	۳۴۴۱.۹۷
Paillier	۱۰۲۴	۱۶۸۸.۲۹۲	۳۷۵۱.۳۸۱۹	۷۰۶۹.۱۱	۳۵۷۱.۴۳	۶۰۷۹.۴۱۶۶
Damgård–Jurik ($s = 1$)	۱۰۲۴	۹۶۴۰.۲۷۶	۵۰۰۸.۳۱۷۶	۹۱۴۷.۱۱	۸۵۱۹.۳۱	۲۳۱۴.۳۴۹۷
Benaloh	۱۰۲۴	۴۱۵۴.۳۱۰	۱۰۹۴.۴۵	۳۱۵۰.۳	۹۲۷۲.۱۶	۷۶۷۰.۳۷۵

جدول ۳-۳: زمان‌های آزمون ضرب دو پیام؛ رمزگذاری و رمزگشایی جداگانه اندازه‌گیری نشده‌اند

طرح	بیت	تولید کلید	رمزگذاری	تجمیع/آزمون	رمزگشایی	کل
RSA	۲۵۶	۶۶۷۱.۳	–	۵۳۴۰.۰	–	۲۰۱۱.۴
ElGamal	۲۵۶	۲۷۴۱.۱۹۶۵	–	۴۸۸۸.۲	–	۷۶۲۹.۱۹۶۷
RSA	۵۱۲	۲۴۶۶.۶۴	–	۳۸۱۴.۲	–	۶۲۸۰.۶۶
ElGamal	۵۱۲	۷۷۱۲.۱۵۲۹۷	–	۳۶۹۵.۱۱	–	۱۴۰۷.۱۵۳۰۹
RSA	۱۰۲۴	۰۶۸۰.۴۱۲	–	۰۸۰۵.۱۰	–	۱۴۸۵.۴۲۲
ElGamal	۱۰۲۴	۳۹۳۴.۲۲۴۰۷۹	–	۵۱۱۱.۳۵	–	۹۰۴۵.۲۲۴۱۱۴

۳-۴-۲ هزینهٔ تولید کلید و رمزگذاری

در اجرای ذخیره‌شده، تولید کلید الجمال بخش بزرگی از زمان آن طرح را تشکیل می‌دهد. این مشاهده به روش تولید پارامتر و آزمون مولد در همین کد مربوط است؛ به معنای غیرقابل‌استفاده بودن تمام پیاده‌سازی‌های الجمال نیست. در کاربردی که گروه استاندارد از پیش اعتبارسنجی شده و چند بار استفاده می‌شود، سهم این هزینه می‌تواند متفاوت باشد. برای سایر طرح‌ها نیز تعداد دفعات تولید کلید و امکان بازاستفادهٔ امن از آن بر زمان مؤثر هر پرسش اثر دارد.



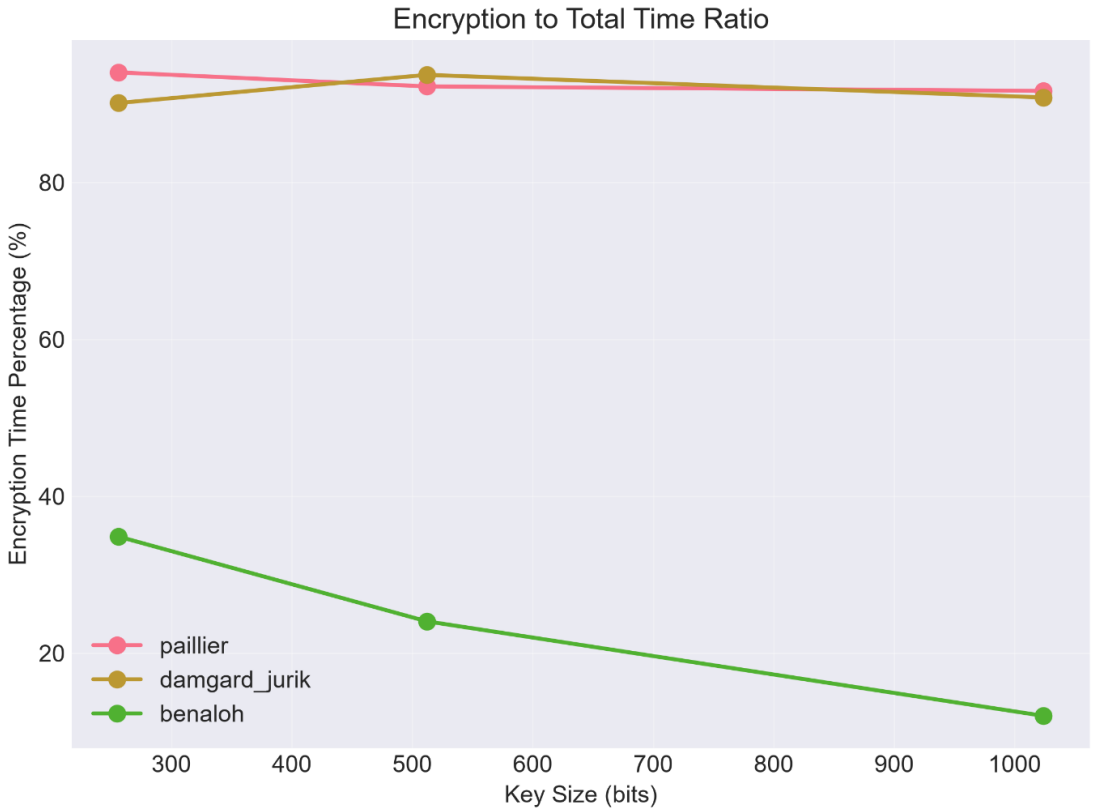
شکل ۳-۵: زمان تولید کلید در اجرای ذخیره‌شده؛ مقایسه به همین پیاده‌سازی‌ها محدود است

رمزگذاری هر کلاینت در طرح‌های جمعی چند توان‌رسانی پیمانه‌ای دارد. افزایش طول پیمانه معمولاً هزینهٔ محاسبات و اندازهٔ متن رمز را افزایش می‌دهد. تفاوت زمانی بنالوح و پاییه در این آزمایش با تفاوت پیمانه‌ها، توان‌ها و فضای پیام مرتبط است، اما یک اجرای محدود علت‌سنجی قطعی همهٔ این عوامل را ممکن نمی‌کند. در بنالوح، انتخاب r بر رمزگشایی نیز اثر مستقیم دارد و باید همراه با ظرفیت مجموع وزن سنجیده شود.

۳-۴-۳ تجمیع، رمزگشایی و زمان کل

تجمیع جمعی با ضرب توان‌دار متن‌های رمز انجام می‌شود. تعداد کلاینت‌ها، طول پیمانه و اندازهٔ وزن‌ها بر آن اثر دارند. یک رمزگشایی نهایی می‌تواند از رمزگشایی همهٔ پیام‌ها کم‌هزینه‌تر باشد، اما این کاهش تعداد عملیات به‌تنهایی محرمانگی در برابر دارندهٔ کلید خصوصی را اثبات نمی‌کند. در بنالوح، حل لگاریتم گسستهٔ محدود، بخش مشخصی از رمزگشایی است؛ در پاییه، توان‌رسانی و اعمال تابع L انجام می‌شود.

زمان کل در دادهٔ طرح‌های جمعی جمع زمان تولید کلید، رمزگذاری، تجمیع و رمزگشایی است. برای نمونه، در کلید ۲۵۶بیتی، این زمان برای پاییه ۵۷۲۷٫۱۲۷، برای تخصص دامگارد–یوریک ۷۶۷۵٫۱۳۲ و برای بنالوح ۸۰۵۴٫۲۲ میلی‌ثانیه است. زمان کم‌تر بنالوح در این تنظیم نباید مستقل از فضای پیام محدود، روش رمزگشایی و سطح امنیت



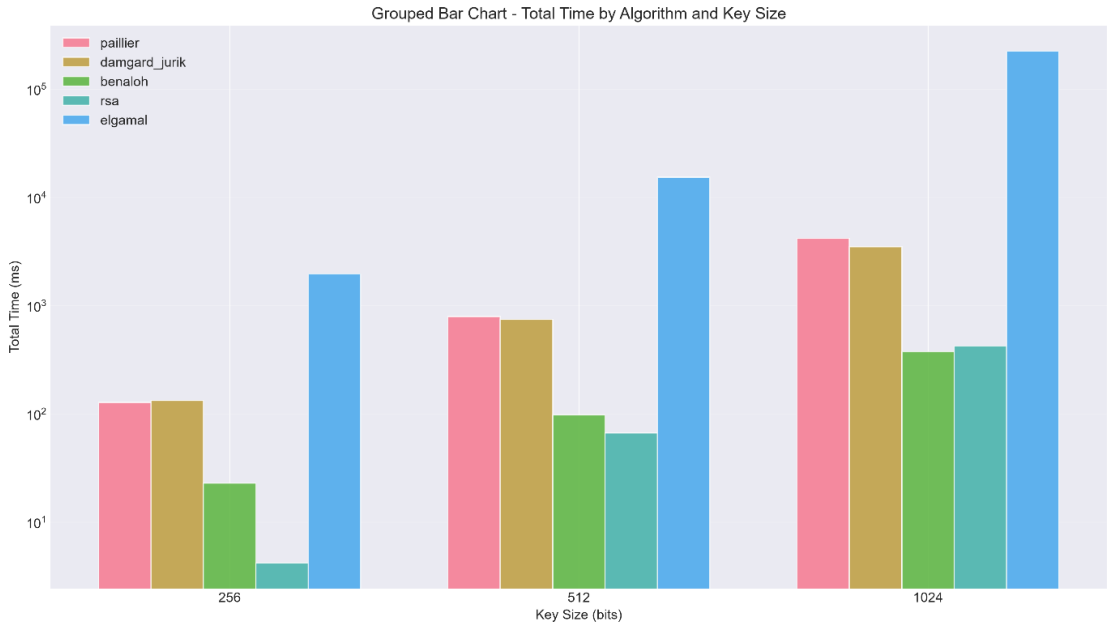
شکل ۳–۶: زمان رمزگذاری در خانوادهٔ جمعی؛ ستون‌های اندازه‌گیری‌نشدهٔ خانوادهٔ ضربی با صفر جایگزین نمی‌شوند

تفسیر شود. شکل‌های ۳–۷ و ۳–۸ داده‌های ثبت‌شده را نمایش می‌دهند.

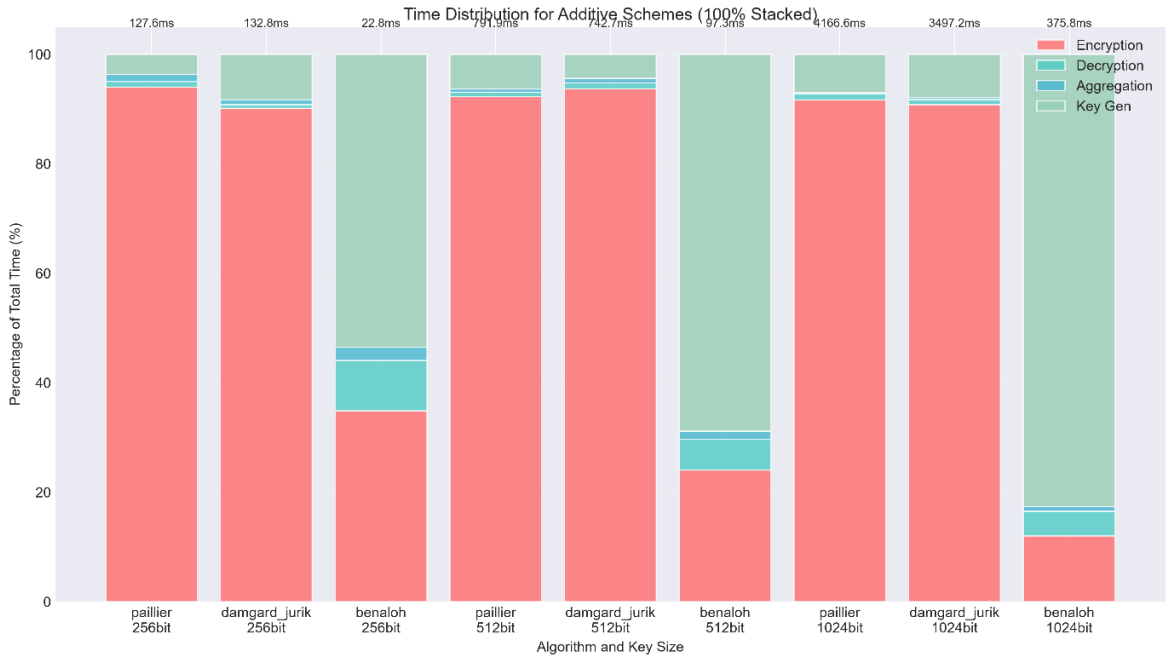
۳–۴–۴ تأثیر اندازهٔ کلید و حدود نتیجه‌گیری

اندازه‌های ۲۵۶، ۵۱۲ و ۱۰۲۴ بیت در این بنچمارک، پارامترهای آموزشی و پژوهشی‌اند و تأیید امنیت تولیدی محسوب نمی‌شوند. یک طول بیت یکسان نیز لزوماً امنیت معادل در تمام خانواده‌ها ایجاد نمی‌کند. انتخاب پارامتر عملی باید بر اساس استاندارد جاری، طول عمر محرمانگی و تحلیل مستقل انجام شود.

برای سنجش دقیق‌تر، زمان تولید پارامتر باید از زمان هر پرسش جدا، بار کاری دو خانواده یکسان‌سازی، تکرارها و سخت‌افزار ثبت و بازهٔ عدم‌قطعیت گزارش شود. روش‌های بهینهٔ توان‌رسانی، موازی‌سازی و استفاده از کتابخانهٔ رمزنگاری ممیزی‌شده از مسیرهای توسعه‌اند. تعمیم دامگارد–یوریک برای $s > 1$ نیز پیش از گزارش کارایی به پیاده‌سازی صحیح و آزمون‌های مستقل نیاز دارد. در این پایان‌نامه، تناسب جبری بنالوح با جمع وزن‌دار، مبنای بررسی پروتکل احراز اصالت‌شدهٔ فصل بعد است؛ رتبهٔ زمانی این اجرای محدود، ادعای برتری امنیتی عمومی ایجاد نمی‌کند.



شکل ۳-۷: زمان کل آزمون‌های ذخیره‌شده؛ بار کاری خانواده‌های ضربی و جمعی متفاوت است



شکل ۳-۸: مقایسهٔ چندمعیارهٔ زمان پیاده‌سازی‌های موجود در نسخهٔ مبنا

فصل ۴

طراحی و پیاده‌سازی تجمیع میانگین وزنیِ احرازاصالت‌شده با SBHE-Benaloh

۴-۱ هدف و مرز پروتکل

در یک سامانهٔ چندکلاینتی، علاوه بر محاسبهٔ مجموع وزن‌دار، باید مشخص باشد هر مشارکت از کدام هویت مجاز آمده، در مسیر تغییر نکرده و متعلق به دور جاری است. خاصیت همریختی به‌تنهایی این نیازها را پاسخ نمی‌دهد. ساختار SBHE-Benaloh در این مخزن، متن رمز بنالوح را با امضای Ed25519 روی یک محمولهٔ مشخص همراه می‌کند. امضا پیش از ورود متن رمز به تجمیع بررسی می‌شود و در عملگر جبری متن رمز ضرب نمی‌شود.

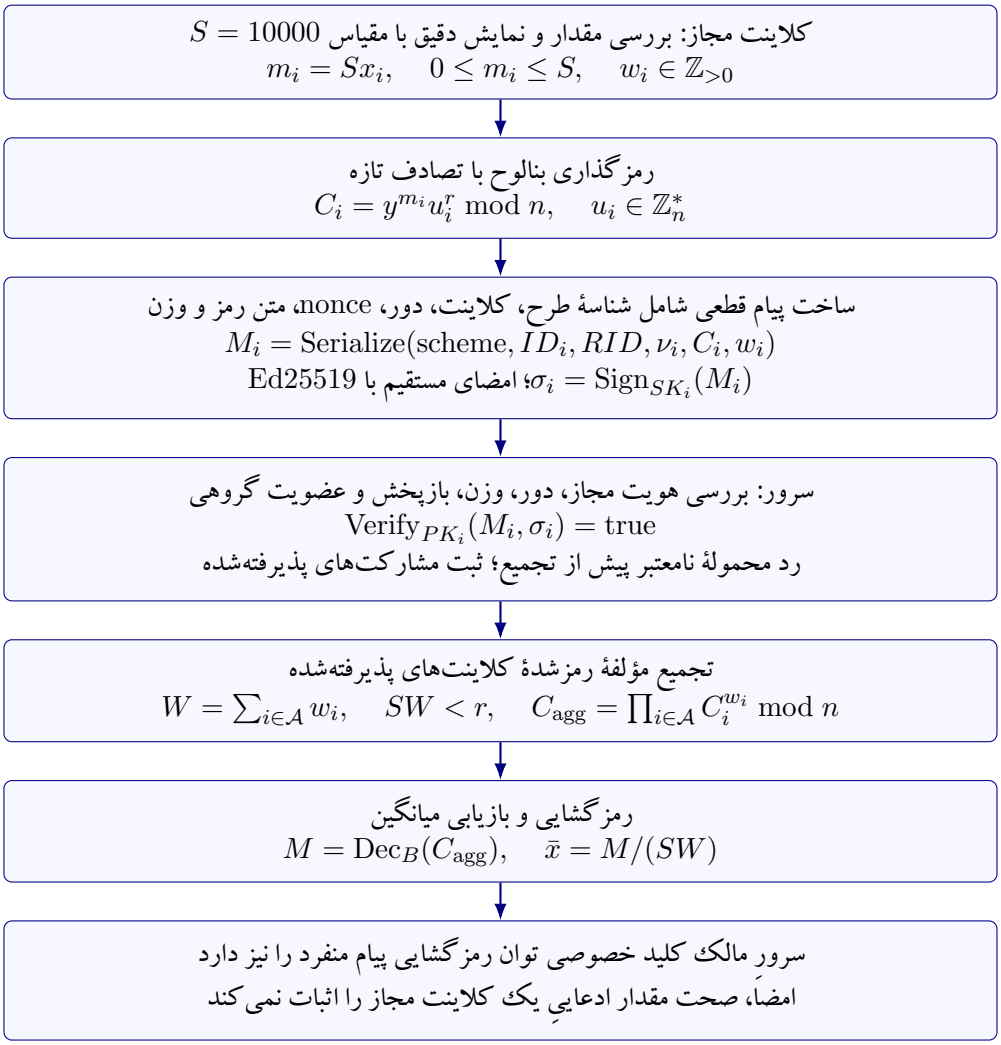
این طرح در سطح کد، یک پوشش احراز اصالت برای تجمیع همریخت است؛ ادعای یک سازوکار استانداردِ مستقل signcryption با اثبات امنیت ترکیبی در یک مدل رسمی مطرح نمی‌شود. همچنین سرور در پیاده‌سازیِ حاضر مالک کلید خصوصی بنالوح است. او طبق مسیر برنامه فقط مجموع را رمزگشایی می‌کند، اما از نظر رمزنگاری قادر به رمزگشایی یک متن رمز منفرد نیز هست. در نتیجه، محرمانگی در برابر شنودگرِ فاقد کلید با محرمانگی در برابر سرورِ دارندهٔ کلید یکسان نیست.

۴-۲ مدل سیستم و نقش اعضا

سرور یک کلید بنالوح تولید و کلید عمومی (n, y, r) را منتشر می‌کند. هر کلاینت i یک شناسهٔ یکتا ID_i و جفت کلید امضای (SK_i, PK_i) دارد. پیش از مشارکت، ارتباط معتبر میان شناسه و کلید عمومی امضا باید در فهرست مجاز سرور ثبت شود. جایگزینی کلید یک هویت مجاز توسط مهاجم، این پیش‌فرض را نقض می‌کند و با بررسی جبری امضا قابل جبران نیست.

هر پیام به شناسهٔ دور RID و یک مقدار یک‌بارمصرف ν_i متصل است. مقدار ورودی کلاینت $x_i \in [0, 1]$ و وزن آن $w_i \in \mathbb{Z}_{>0}$ است. در آزمایش‌های کوچک، مقدارها دادهٔ عددی آزمایشی هستند. برای کاربرد مشارکتی، x_i می‌تواند نسخهٔ کوانتیزه‌شدهٔ احتمال خروجی مدل باشد و w_i تعداد نمونهٔ محلی یا وزن صحیحِ تعریف‌شدهٔ دیگری باشد؛ صحت این تفسیر به سیاست سامانه وابسته است.

فهرست اعضای مجاز، سیاست تعیین دور، نگهداری کلید خصوصی و پایداری دفتر nonce جزو مدل عملیاتی‌اند. این مؤلفه‌ها باید جدا از الگوریتم بنالوح تعریف شوند. در نسخهٔ فعلی، فهرست کلیدها و مجموعهٔ nonceهای



شکل ۴-۱: جریان اجرای SBHE-Benaloh: امضای مستقیم پیام بایتی و بررسی محموله پیش از تجمیع مؤلفهٔ رمزشده

مصرف‌شده در حافظهٔ شیء سرور نگهداری می‌شوند؛ بازیابی پس از راه‌اندازی مجدد به ذخیره‌سازی پایدار و سیاست دور نیاز دارد.

۴-۳ بازنمایی عددی و مدیریت دقت

بنابراین که فضای پیام بنالوح صحیح است، ضریب مقیاس $S = 10^4$ تعریف می‌شود. در مسیر فعلی کد، x_i باید حداکثر چهار رقم اعشار داشته باشد تا

$$m_i = S x_i \in \{0, \dots, S\} \tag{۱-۴}$$

بدون گرد کردن پنهان محاسبه شود. برای نمونه، 0.7314 به عدد صحیح 7314 تبدیل می‌شود. تابع encode_value ورودیِ دارای اعشار بیشتر، مانند 0.12345، و مقدار خارج از بازه را رد می‌کند. استفاده از Decimal، هدف نمایش و تقسیم اعشاری را روشن می‌کند و جایگزین کردن تصادفیِ قالب اعشاری با عدد دودویی را کاهش می‌دهد.

احتمال خروجی طبقه‌بند لزوماً چهاررقم‌اعشاری نیست. بنابراین اتصال مستقیم نوت‌بوک به این تابع، بدون تعریف مرحلهٔ تبدیل، معتبر نیست. اگر سیاستی صریح برای گرد کردن به نزدیک‌ترین مقدار چهاررقمی تعریف شود و q_i خروجی آن باشد، آنگاه $|q_i - x_i| \le 1/(2S)$ و برای وزن‌های مثبت داریم:

$$\left| \frac{\sum_i w_i q_i}{W} - \frac{\sum_i w_i x_i}{W} \right| \le \frac{1}{2S}, \qquad W = \sum_i w_i. \tag{۲-۴}$$

این کران مربوط به میانگین است. اگر احتمال تجمیعی به آستانهٔ طبقه‌بندی نزدیک باشد، حتی همین خطای کوچک می‌تواند برچسب را تغییر دهد. در این پایان‌نامه، دقت‌های مشارکتیِ فصل قبل حاصل محاسبهٔ آشکارِ اعشاری‌اند؛ برابری برچسب‌ها پس از این تبدیل اندازه‌گیری نشده است.

۴-۴ بن‌مایهٔ جبری بنالوح

کلاینت برای تصادف تازهٔ $u_i \in \mathbb{Z}_n^*$ محاسبه می‌کند:

$$C_i = y^{m_i} u_i^r \pmod{n}. \tag{۳-۴}$$

ضرب متن‌های رمز متناظر با جمع پیام‌ها و توان‌رسانی به وزن آشکار متناظر با ضرب پیام در وزن است. برای کلاینت‌های پذیرفته‌شدهٔ $\mathcal{A}$، نتیجهٔ تجمیع برابر است با

$$C_{\mathrm{agg}} = \prod_{i \in \mathcal{A}} C_i^{w_i} \pmod{n}. \tag{۴-۴}$$

امضای دیجیتال هیچ تغییری در این رابطه ایجاد نمی‌کند. پارامتر r باید با بیشینهٔ مجموع صحیح سازگار باشد؛ اندازهٔ پیمانهٔ رمز n و اندازهٔ فضای پیام r دو پارامتر با نقش متفاوت‌اند.

۴-۵ ساختار محموله و پیام امضاشده

محمولهٔ کلاینت به‌صورت زیر تعریف می‌شود:

$$E_i = (ID_i, RID, \nu_i, C_i, w_i, \sigma_i). \tag{۴-۵}$$

پیام بایتی M_i از نمایش قطعیِ شناسهٔ طرح و مؤلفه‌های محموله ساخته می‌شود:

$$M_i = \mathrm{Serialize}(\mathrm{scheme}, ID_i, RID, \nu_i, C_i, w_i), \qquad \sigma_i = \mathrm{Sign}_{SK_i}(M_i). \tag{۴-۶}$$

در کد، Serialize با JSON دارای کلیدهای مرتب‌شده، جداکننده‌های بدون فاصله، تبدیل متن رمز به رشتهٔ ده‌دهی و کدگذاری UTF-8 انجام می‌شود. شناسهٔ نسخهٔ طرح SBHE-Benaloh-Ed25519-v1 نیز در پیام امضاشده حضور دارد. این صورت دقیق با نوشتن مبهمِ چسباندن رشته‌ها تفاوت دارد؛ مرز فیلدها باید برای فرستنده و گیرنده یکسان باشد.

پیاده‌سازی، بایت‌های همین پیام را مستقیماً به Ed25519.sign می‌دهد. رابطهٔ اجراشده، امضای دستیِ $H(M_i)$ یا گونهٔ Ed25519ph نیست؛ هش داخلیِ الگوریتم Ed25519 در تعریف خود الگوریتم انجام می‌شود [۱۸۷].

وزن باید داخل پیام امضاشده باشد؛ در غیر این صورت مهاجم می‌تواند با نگه داشتن متن رمز و امضای آن، وزن را عوض کند. شناسهٔ دور، پیام را به یک اجرا متصل می‌کند و nonce امکان تشخیص استفادهٔ مجدد همان مشارکت را می‌دهد. امضای تمام این فیلدها، تغییر برون‌زاد را قابل تشخیص می‌کند، اما ادعای کلاینت دربارهٔ درست بودن وزن را به‌تنهایی اثبات نمی‌کند.

۴-۶ گام‌های کلاینت و سرور

۴-۶-۱ فرایند کلاینت

کلاینت ابتدا مقدار و وزن را بررسی، مقدار مجاز را با مقیاس S به صحیح تبدیل و آن را با کلید عمومی معتبر بنالوح رمز می‌کند. سپس nonce تازه می‌سازد، پیام قطعی را از فیلدهای مشخص تشکیل می‌دهد و با کلید خصوصی خود امضا می‌کند. در پایان محمولهٔ کامل را می‌فرستد. تصادف رمزگذاری و nonce دو نقش متفاوت دارند و یکی جایگزین دیگری نیست.

۴-۶-۲ پذیرش محموله در سرور

سرور باید پیش از تجمیع، موارد زیر را بررسی کند:

۱. شناسهٔ دورِ محموله با دور مورد انتظار برابر باشد.

۲. شناسهٔ کلاینت در فهرست مجاز وجود داشته باشد.

۳. وزن مطابق قالب، صحیح و مثبت باشد؛ سیاست کاربرد دربارهٔ مقدار مجاز وزن نیز جداگانه اعمال شود.

۴. سه‌تایی (ID_i, RID, ν_i) قبلاً مصرف نشده باشد.

۵. امضا با کلید ثبت‌شده و همان بایت‌های قطعیِ پیام معتبر باشد.

۶. متن رمز در دامنهٔ گروه قرار گیرد: $0 < C_i < n$ و $\gcd(C_i, n) = 1$.

محمولهٔ نامعتبر نباید در حاصل‌ضرب وارد شود. تابع accept_and_aggregate همچنین مشارکت تکراری یک شناسه در همان فراخوانیِ دسته‌ای را رد می‌کند. این کنترل درون یک دسته با سیاست «فقط یک مشارکت از هر کلاینت در تمام عمر یک دور» یکسان نیست؛ برای سیاست دوم باید وضعیت دور در کل سامانه نگهداری شود.

ثبت nonceهای مصرف‌شده در کد پس از اعتبارسنجی دسته و ساخت تجمیع انجام می‌شود. این ترتیب از مصرف شدن بخشی از شناسه‌ها در یک دستهٔ ناموفق جلوگیری می‌کند. در یک سرور هم‌زمانِ واقعی، بررسی و ثبت باید در برابر رقابت دو درخواست نیز اتمی باشد؛ ساختار درون‌حافظه‌ای یک نمونهٔ پژوهشی، به‌تنهایی این نیاز استقرار را حل نمی‌کند.

۴-۶-۳ رمزگشایی و شرط ظرفیت پیام

برای مجموع وزن $W > 0$ و مجموع صحیح $M = \sum_{i \in \mathcal{A}} w_i m_i$، پس از رمزگشایی داریم:

$$\bar{x} = \frac{M}{SW}. \tag{۴-۷}$$

چون فضای پیام پیمانه‌ای است، شرط کافیِ تضمین نبود سرریز برای $0 \le m_i \le S$ چنین است:

$$SW < r. \tag{۴-۸}$$

با $r = 10000019$ و $S = 10000$، مجموع وزن صحیح حداکثر ۱۰۰۰ مجاز است. شرط فوق در مسیر تجمیع کد کنترل می‌شود و عبور از ظرفیت باید با خطا متوقف شود. کوچک بودن تعداد کلاینت‌ها به‌تنهایی کافی نیست؛ مجموع وزن‌ها تعیین‌کننده است. برای وزن‌های تعداد نمونهٔ آزمایش مشارکتی، ظرفیت لازم در رابطهٔ (۲-۱۹) بسیار بزرگ‌تر است.

۴-۷ اثبات درستی تجمیع

فرض می‌شود همهٔ ورودی‌های پذیرفته‌شده پیام‌های معتبر در بازهٔ تعریف‌شده‌اند و شرط (۴-۸) برقرار است. با جایگذاری متن رمز کلاینت در رابطهٔ تجمیع:

$$C_{\text{agg}} = \prod_{i \in \mathcal{A}} (y^{m_i} u_i^r)^{w_i} \pmod{n} \tag{۴-۹}$$

$$= y^{\sum_i w_i m_i} \left(\prod_i u_i^{w_i} \right)^r \pmod{n} \tag{۴-۱۰}$$

$$= \mathrm{Enc}_B\left(\sum_i w_i m_i \right). \tag{۴-۱۱}$$

در نتیجه، رمزگشایی مجموع صحیح را در پیمانهٔ r به دست می‌دهد. از آنجا که $0 \le M \le SW < r$، نتیجهٔ پیمانه‌ای همان مجموع صحیحِ مورد نظر است. تقسیم بر SW می‌دهد:

$$\frac{\mathrm{Dec}_B(C_{\mathrm{agg}})}{SW} = \frac{\sum_i w_i (S x_i)}{SW} = \frac{\sum_i w_i x_i}{\sum_i w_i}. \tag{۱۲-۴}$$

این اثبات، درستی جبری را تحت پیش‌شرط‌های ورودی نشان می‌دهد؛ نشان نمی‌دهد کلاینت مخرب الزاماً همان احتمالِ حاصل از مدل خود را رمز کرده است. برای این ادعای قوی‌تر، گواه محاسبه یا کنترل اعتماد دیگری لازم است.

۸-۴ تحلیل امنیتی و محدودیت‌های دقیق

۱-۸-۴ هویت، تمامیت و بازپخش

با فرض محرمانه ماندن کلید امضا و ثبت معتبر کلید عمومی، مهاجم بیرونی نباید بتواند برای شناسهٔ مجاز محمولهٔ تازهٔ معتبر بسازد. تغییر متن رمز، وزن، شناسه، دور یا nonce بایت‌های پیام را تغییر می‌دهد و باید بررسی امضا را ناموفق کند. کنترل دور و دفتر مصرف nonce نیز از پذیرش دوبارهٔ همان پیام جلوگیری می‌کنند. پایداری و هماهنگی آن دفتر در استقرار واقعی جزو پیش‌فرض‌هاست.

۲-۸-۴ مرز محرمانگی

متن رمز، مقدار منفرد را از طرف فاقد کلید خصوصی پنهان می‌کند، در چارچوب فرض امنیتی و انتخاب پارامتر معتبر. با این حال، مالک کلید خصوصی توان رمزگشایی متن منفرد را دارد. مشاهدهٔ میانگین نهایی نیز ممکن است با دانش جانبی یا در گروه‌های بسیار کوچک اطلاعاتی دربارهٔ مشارکت‌کننده آشکار کند. بنابراین این ساختار نه حریم خصوصی تفاضلی است و نه یک طرح رمزگشایی آستانه‌ایِ اجراشده.

۳-۸-۴ کلاینت مجاز اما مخرب

امضای معتبر فقط نشان می‌دهد محموله با کلید ثبت‌شده تولید شده است. کلاینت مجاز می‌تواند مقدار یا وزن نادرست را امضا کند. کنترل عضویت $C_i \in \mathbb{Z}_n^*$ ثابت نمی‌کند پیام رمزشده در بازهٔ $[0, S]$ قرار دارد. کنترل بازه در تابع محلی، در برابر کلاینتی که آن تابع را دور بزند کافی نیست. اثبات بازه، اتصال وزن به شمارش دادهٔ تأییدشده، مقاومت در برابر مسموم‌سازی مدل و صحت استنتاج، در نسخهٔ فعلی پیاده‌سازی نشده‌اند.

۴-۸-۴ هزینه، مدیریت کلید و استقرار

امضاهای Ed25519 در این پیاده‌سازی جداگانه بررسی می‌شوند و با ضرب متن‌های رمز تجمیع نمی‌شوند. هزینهٔ اعتبارسنجی با تعداد مشارکت‌ها رشد می‌کند. افشای کلید خصوصی یک عضو، جایگزینی کلید در رجیستری، ضعف تصادف، نشت کانال جانبی و حذف وضعیت بازپخش، هر یک پیش‌فرضی جداگانه را نقض می‌کنند. اندازه‌های کوچک کلید در آزمایش زمان، پارامتر امنیتی تولیدی نیستند. برای کاربرد عملی باید از کتابخانه‌ها و پارامترهای ممیزی‌شده و مدل تهدید مستقل استفاده شود.

۹-۴ چرا امضا در متن رمز ضرب نمی‌شود؟

یک ترکیب ساده‌انگارانه ممکن است $C' = C\sigma \pmod n$ را پیشنهاد کند. امضای Ed25519 عضو دارای همان نقش جبری در فضای پیام بنالوح نیست؛ ضرب چنین عاملی می‌تواند رابطهٔ رمزگشایی را خراب کند و هیچ قاعدهٔ معتبر احراز اصالتی نیز ایجاد نمی‌کند. در ساختار حاضر، محموله یک زوج صرفاً جبریِ دو عضو هم‌نوع نیست؛ مجموعه‌ای از فیلدهای دارای معناست. عملیات همریخت فقط بر مؤلفهٔ C_i انجام می‌شود و σ_i پیش‌شرط پذیرش همان مؤلفه و وزن آن است.

این جداسازی امکان استفاده از همان قانون جمعی بنالوح را حفظ می‌کند، اما به‌تنهایی اثبات امنیت ترکیبیِ همهٔ لایه‌ها نیست. ثبت هویت، قالب قطعی، جداسازی دامنهٔ نسخه، انتخاب دور و وضعیت بازپخش، بخش‌های ضروری تحلیل کامل‌اند.

۱۰-۴ ارزیابی عملکردِ ذخیره‌شده

منبع این بخش فایل‌های تفصیلی و خلاصهٔ Benaloh_signcryption/results با تاریخ ثبت‌شدهٔ 20260823_180220 است. زمان‌های موجود، آمار اجرای ذخیره‌شده‌اند و به‌عنوان اجرای مجدد روی محیط فعلی معرفی نمی‌شوند. کد demo.py به‌صورت پیش‌فرض ۹ پیکربندیِ سه اندازهٔ کلید و سه تعداد کلاینت و ۱۰۰ تکرار را تعریف می‌کند؛ فایل خلاصه، شمارش مستقل تکرارهای خام یا مشخصات کامل سخت‌افزار را ثبت نمی‌کند. بنابراین برای بازسازی دقیق زمان‌ها باید فرادادهٔ اجرای جدید نیز ذخیره شود.

جدول ۴-۱: میانگین و انحراف معیار زمان کل در فایل خلاصهٔ ذخیره‌شده؛ واحد میلی‌ثانیه

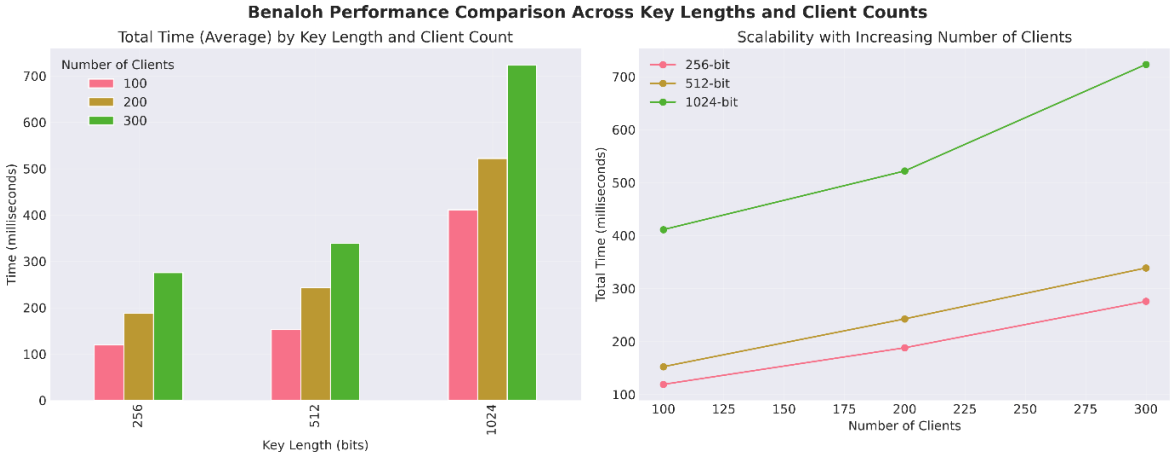
بیت	کلاینت	میانگین کل	انحراف معیار
۲۵۶	۱۰۰	۰۲۴۳.۱۱۹	۵۰۲۶.۳۱
۲۵۶	۲۰۰	۰۸۴۶.۱۸۸	۰۴۹۰.۱۲
۲۵۶	۳۰۰	۶۸۲۰.۲۷۵	۶۸۸۵.۱۱
۵۱۲	۱۰۰	۴۱۳۷.۱۵۲	۱۵۲۰.۳۰
۵۱۲	۲۰۰	۶۲۱۶.۲۴۲	۳۶۶۸.۱۷
۵۱۲	۳۰۰	۷۹۳۷.۳۳۸	۴۳۷۶.۲۰
۱۰۲۴	۱۰۰	۲۴۰۳.۴۱۱	۸۲۵۱.۱۰۱
۱۰۲۴	۲۰۰	۹۲۰۸.۵۲۱	۵۲۵۵.۸۵
۱۰۲۴	۳۰۰	۱۴۴۱.۷۲۳	۷۷۸۲.۱۳۵

در اندازهٔ ۲۵۶ بیت، میانگین زمان کل برای ۱۰۰، ۲۰۰ و ۳۰۰ کلاینت به‌ترتیب ۰۲۴۳٫۱۱۹، ۰۸۴۶٫۱۸۸ و ۶۸۲۰٫۲۷۵ میلی‌ثانیه است. رشد تعداد کلاینت از ۱۰۰ به ۳۰۰، هزینهٔ رمزگذاری و اعتبارسنجی/تجمیع را افزایش می‌دهد. در ۵۱۲ بیت، زمان‌های متناظر ۴۱۳۷٫۱۵۲، ۶۲۱۶٫۲۴۲ و ۷۹۳۷٫۳۳۸ میلی‌ثانیه و در ۱۰۲۴ بیت، ۲۴۰۳٫۴۱۱، ۹۲۰۸٫۵۲۱ و ۱۴۴۱٫۷۲۳ میلی‌ثانیه ثبت شده‌اند. این اعداد به پیکربندی‌های همین فایل محدودند و زمان پاسخ شبکه، آموزش مدل یا استنتاج متن را شامل نمی‌شوند.

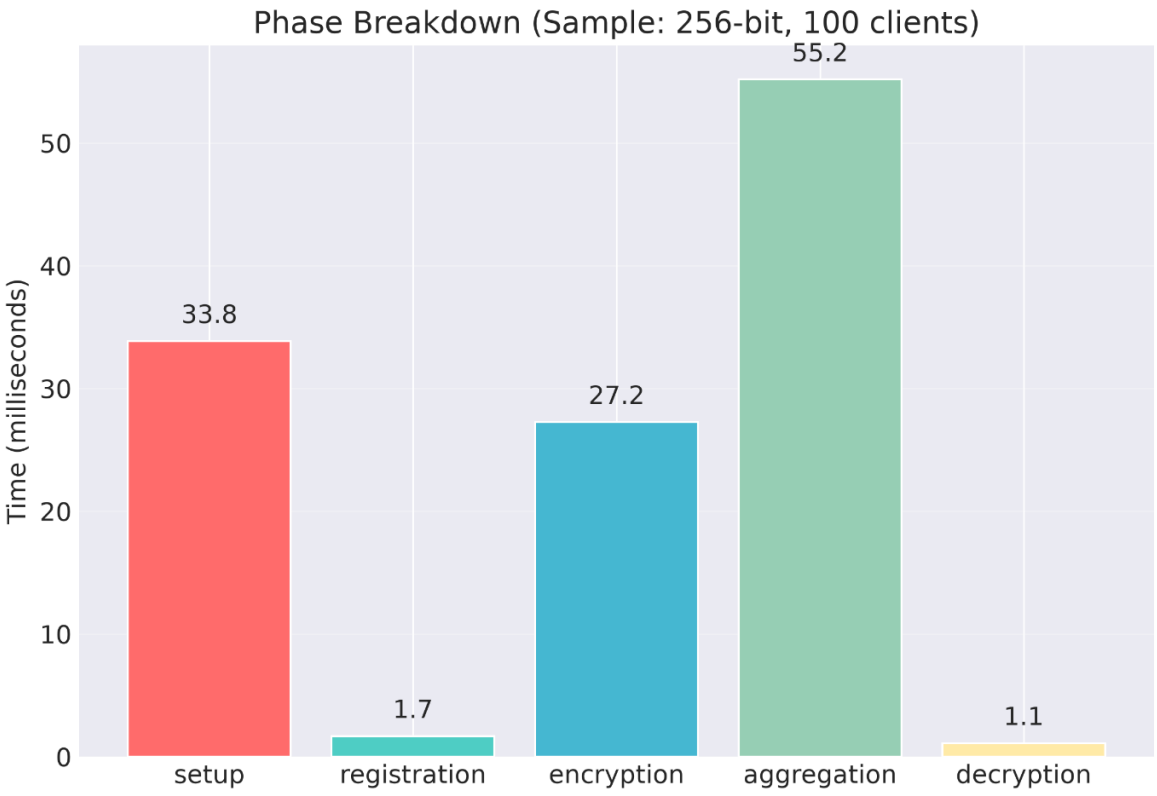
برای ۱۰۰ کلاینت در ۲۵۶ بیت، میانگین زمان آماده‌سازی ۸۴۳۳٫۳۳، ثبت هویت ۶۶۱۸٫۱، رمزگذاری ۲۴۳۷٫۲۷، تجمیع و بررسی محموله‌ها ۱۶۸۵٫۵۵ و رمزگشایی ۰۸۷۱٫۱ میلی‌ثانیه است. اختلاف جزئی جمع زمان مرحله‌ها با زمان کل می‌تواند از سربار بخش‌های اندازه‌گیری‌نشده و گرد کردن ناشی شود؛ نباید با تغییر اعداد دادهٔ اصلی پنهان شود. سهم قابل‌توجه تجمیع/بررسی نشان می‌دهد هزینهٔ پروتکل فقط ضرب چند عدد نیست.

جدول ۴-۲: میانگین زمان مرحله‌های پروتکل در اجرای ذخیره‌شده؛ واحد میلی‌ثانیه

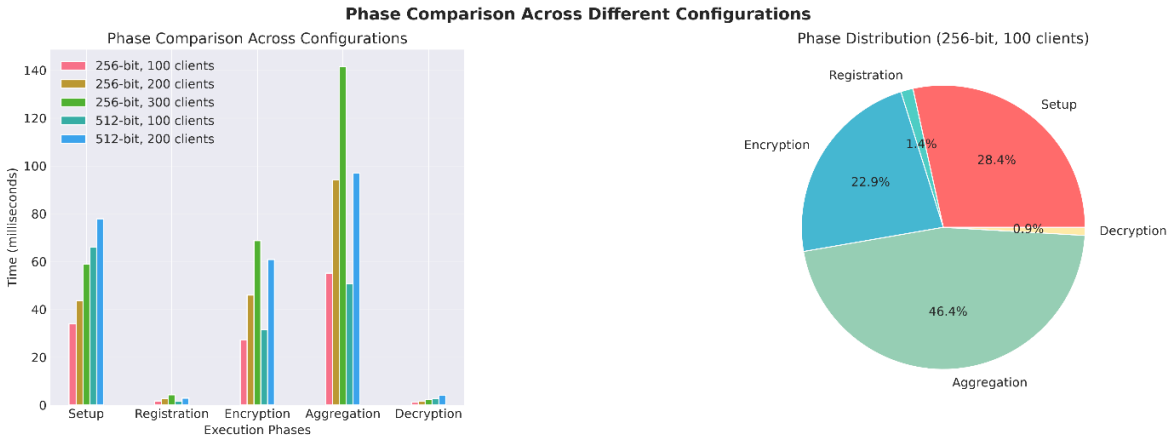
بیت	کلاینت	آماده‌سازی	ثبت هویت	رمزگذاری	تجمیع/بررسی	رمزگشایی
۲۵۶	۱۰۰	۸۴۳۳.۳۳	۶۶۱۸.۱	۲۴۳۷.۲۷	۱۶۸۵.۵۵	۰۸۷۱.۱
۲۵۶	۲۰۰	۶۹۲۵.۴۳	۷۴۸۰.۲	۹۳۰۲.۴۵	۱۷۱۸.۹۴	۵۳۲۲.۱
۲۵۶	۳۰۰	۹۸۵۹.۵۸	۲۳۰۷.۴	۶۸۷۰.۶۸	۵۳۱۹.۱۴۱	۲۴۶۵.۲
۵۱۲	۱۰۰	۰۳۲۷.۶۶	۵۶۵۷.۱	۴۳۹۵.۳۱	۵۹۹۸.۵۰	۷۶۶۱.۲
۵۱۲	۲۰۰	۹۱۷۲.۷۷	۸۰۶۲.۲	۸۴۲۱.۶۰	۹۹۹۶.۹۶	۰۵۶۴.۴
۵۱۲	۳۰۰	۴۱۰۵.۹۲	۱۳۹۵.۴	۹۸۳۰.۹۱	۹۲۸۸.۱۴۴	۳۰۱۸.۵
۱۰۲۴	۱۰۰	۵۹۵۵.۲۹۳	۴۰۳۰.۱	۰۴۵۶.۵۳	۴۵۴۲.۵۲	۷۴۲۱.۱۰
۱۰۲۴	۲۰۰	۶۵۴۵.۲۹۲	۸۵۲۹.۲	۳۲۸۹.۱۰۷	۴۹۲۹.۱۰۴	۵۸۱۷.۱۴
۱۰۲۴	۳۰۰	۸۹۳۰.۳۵۲	۵۹۲۷.۴	۰۴۱۵.۱۷۷	۳۴۹۳.۱۶۸	۲۵۷۶.۲۰



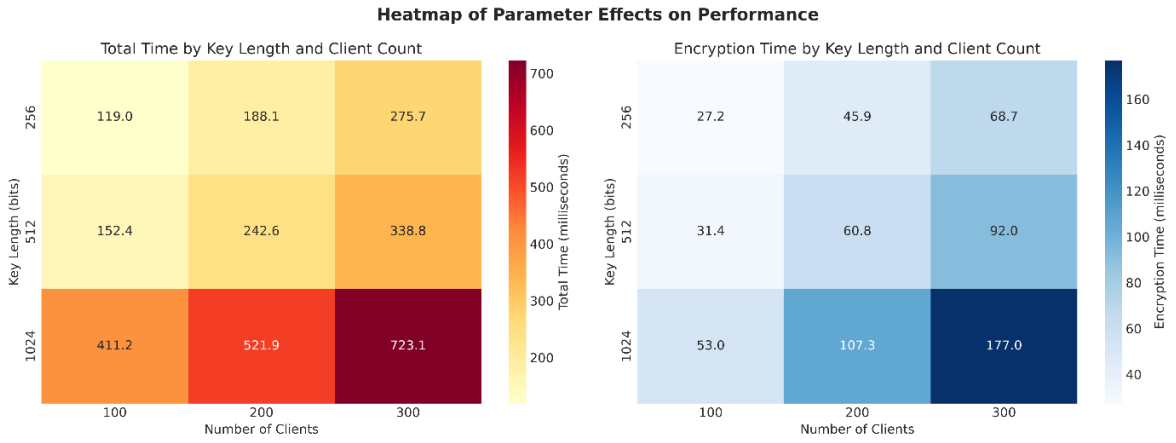
شکل ۴-۲: مقایسهٔ عملکرد زمانی SBHE-Benaloh در اندازه‌های کلید و تعداد کلاینت‌های اجرای ذخیره‌شده



شکل ۴-۳: مقایسهٔ زمان مرحله‌های پروتکل در پیکربندی‌های ثبت‌شده



شکل ۴-۴: توزیع هزینهٔ مرحله‌ها با تغییر اندازهٔ کلید؛ واحد زمان در نمودارها مشخص شده است



شکل ۴-۵: اثر تعداد کلاینت و طول کلید بر هزینهٔ اجرای ذخیره‌شدهٔ پروتکل

افزایش طول کلید، هزینهٔ توان‌رسانی‌های پیمانه‌ای را افزایش می‌دهد. تعداد کلاینت نیز تعداد رمزگذاری‌ها و بررسی امضاها را بیشتر می‌کند؛ در مقابل، رمزگشاییِ نهایی یک تجمیع است. با این حال، شکل رشد باید از دادهٔ چند اجرای کنترل‌شده بررسی شود؛ سه نقطهٔ اندازهٔ کلید برای نسبت دادن قانون پیچیدگی دقیق کافی نیست. همچنین طول کلید و ظرفیت پیام دو محور مستقل‌اند و کوچک بودن زمان، سطح امنیت مناسب را اثبات نمی‌کند.

۴-۱۱ آزمون‌های کارکردی و مسیرهای توسعه

مجموعهٔ آزمون موجود، رمزگذاری و رمزگشایی، مجموع وزن‌دار، میانگین احرازاصالت‌شده، رد عضو غیرمجاز، رد تغییر وزن و متن رمز، رد بازپخش، رد دور نادرست و کنترل دقت اعشاری را بررسی می‌کند. هر نه آزمون در آماده‌سازی محیط اجرا و موفق شدند. این نتیجه، شاهد مشخص کارکردهای آزموده‌شده است؛ اثبات رسمی امنیت، آزمون استقرار شبکه یا پوشش همهٔ ورودی‌های مخرب نیست.

برای توسعه، رمزگشایی آستانه‌ای می‌تواند اعتماد به مالک منفرد کلید را کاهش دهد؛ چنین تغییری به طراحی و تحلیل جداگانه نیاز دارد. رجیستری مبتنی بر گواهی، وضعیت پایدار دور و nonce، سیاست وزنِ قابل‌راستی‌آزمایی، اثبات بازه و سنجش هزینهٔ پیام بزرگ‌تر از نیازهای اتصال به سناریوی مشارکتی‌اند. امضاهای تجمیع‌پذیر مانند BLS نیز یک گزینهٔ پژوهشی‌اند، اما انتخاب آن‌ها بدون مدل تهدید، مقابله با کلید نامعتبر و سنجش هزینهٔ تأیید، بهبود رایگان و قطعی محسوب نمی‌شود.

۴-۱۲ جمع‌بندی

دستاورد این فصل، صورت‌بندی و پیاده‌سازی قابل‌آزمونِ احراز اصالت محموله پیش از تجمیع همریخت است. درستی میانگین به اعتبار ورودی و نبود سرریز وابسته است؛ احراز اصالت، صحت معنایی پیش‌بینی را ثابت نمی‌کند؛ و مالکیت کلید خصوصی، مرز محرمانگی در برابر سرور را تعیین می‌کند. نتایج عددی نشان می‌دهند این ساختار در تنظیم‌های پژوهشیِ ثبت‌شده قابل اجراست. تبدیل آن به سامانهٔ بالینی یا سرویس امنِ تولیدی، به ارزیابی و توسعهٔ بیشتری نیاز دارد.

نتیجه‌گیری کلی و پیشنهادها

این پژوهش سه لایهٔ مرتبط را با دامنهٔ ادعای مشخص بررسی کرد. در ارزیابی متمرکز، با یادگیری بازنمایی فقط درون آموزش هر تقسیم و انتخاب مدل و آستانه بر اعتبارسنجی، مدل XGBoost انتخاب شد. دقت آزمون آن ۷۰.۹۲ درصد و F_1 کلاس مثبت آن ۹۲۷۸.۰ است. مقایسهٔ هر چهار مدل بر اعتبارسنجی و ارزیابی نهایی فقط برای انتخاب تثبیت‌شده گزارش شده است.

در لایهٔ مشارکتی، تقسیم طبقه‌بندی‌شدهٔ ۳۸۰٬۱۴۸ نمونهٔ آموزش، استفادهٔ دقیقاً یک‌باره از هر ردیف و حفظ تقریبی نسبت کلاس‌ها را روشن کرد. با افزایش تعداد کلاینت‌ها از ۱۰ به ۱۰۰، میانگین دادهٔ محلی از ۸۳۸٬۱۴ به ۸٫۴۸۳٬۱ ردیف و دقت آزمون با آستانهٔ منتخب از ۵۸٫۹۱ به ۰۰٫۸۷ درصد کاهش یافت. سناریوی ۱۰ کلاینت بر اساس اعتبارسنجی پیشنهاد شد. این مشاهده به یک بذر و یک طراحی تقریباً هم‌توزیع محدود است و نیاز به تکرار و بررسی ناهمگونی واقعی را از میان نمی‌برد.

در لایهٔ امنیت، احراز اصالت محموله پیش از تجمیع با قانون جمعی بنالوح سازگار شد. امضا، وزن، شناسهٔ دور و مقدار یک‌بارمصرف را به متن رمز متصل می‌کند؛ درستیِ میانگین نیز با فرض ورودی معتبر و شرط ظرفیت اثبات می‌شود. در مقابل، مالکیت کلید خصوصی در سرور، صحتِ معنایی خروجی عضو مجاز و پایداری وضعیت بازپخش از مرزهای مهم اعتماد هستند. این نسخه، محلی ماندن داده، محرمانگی کانال، حفاظت در برابر سرور و صحت پیش‌بینی را یک تضمین واحد نمی‌نامد.

برای اتصال عملی نتایج یادگیری به رمزنگاری، باید تبدیل چهاررقم‌اعشاری، پارامتر پیام سازگار با مجموع وزن واقعی، هزینهٔ رمزگشایی و اثر تغییر برچسب در نزدیکی آستانه اندازه‌گیری شوند. ارزیابی چند بذر و چند پیکره، تقسیم مبتنی بر کاربر و زمان، سناریوهای غیرهم‌توزیع، ارزیابی بیرونی و بررسی کالیبراسیون از اولویت‌های بخش یادگیری‌اند. رمزگشایی آستانه‌ای، اثبات بازه، سیاست وزن قابل‌راستی‌آزمایی، مدیریت کلید و ثبت پایدار دورها نیز از اولویت‌های بخش امنیت‌اند. نتایج حاضر یک پایهٔ پژوهشیِ قابل ممیزی فراهم می‌کنند و برای کاربرد بالینی یا استقرار امنِ تولیدی به اعتبارسنجی مستقل نیاز دارند.

پیوست الف

بسته و سرویس واژگان توقف فارسی «دنا»

الف-۱ مسئله و دامنهٔ کاربرد

دادهٔ متنی خام پیش از مدل‌سازی معمولاً به نرمال‌سازی، واژه‌سازی، کنترل نویز و انتخاب نمایش عددی نیاز دارد. در برخی کاربردها، واژه‌های بسیار پرتکرار سهم کمی در تمایز موضوع دارند و حذف آن‌ها می‌تواند حجم واژگان و هزینهٔ پردازش را کاهش دهد. چنین واژه‌هایی «واژگان توقف» نامیده می‌شوند. ارزش اطلاعاتی آن‌ها به مسئله وابسته است؛ واژه‌ای که در جست‌وجوی موضوعی کم‌اثر است ممکن است در تحلیل عاطفه، نفی یا تشخیص افکار خودکشی اهمیت داشته باشد.

در فارسی، شکل‌های مختلف «ی» و «ک»، فاصله و نیم‌فاصله، صورت‌های پیوسته و جدا و تفاوت شیوهٔ نگارش، استفاده از فهرست واژگان را پیچیده می‌کنند. برای کاهش نیاز به گردآوری تکراریِ فهرست‌ها، ابزار «دنا» در مسیر این پژوهش به‌عنوان یک بسته و رابط برنامه‌نویسی برای دسترسی به واژگان توقفِ فارسی معرفی شده است. نام آن از کوه دنا گرفته شده است. معرفی این ابزار، شاهد ارزیابی چندزبانهٔ طبقه‌بند نیست و در مسیر اصلی نوت‌بوک اصلاح‌شده نیز فهرست دنا فراخوانی نمی‌شود.

الف-۲ کاربرد در نمایش‌های متنی

در روش‌هایی مانند کیسهٔ واژگان، شمارش توکن و TF-IDF، حذف واژه‌های بسیار عمومی می‌تواند تعداد ستون‌های ماتریس تنک را کاهش دهد. اگر $f_{w,d}$ فراوانی واژهٔ w در سند d، N تعداد اسناد و df_w تعداد اسناد حاوی آن واژه باشد، یک صورت سادهٔ وزن‌دهی عبارت است از

$$\mathrm{tfidf}(w,d) = f_{w,d} \log \frac{N}{df_w}. \tag{الف-۱}$$

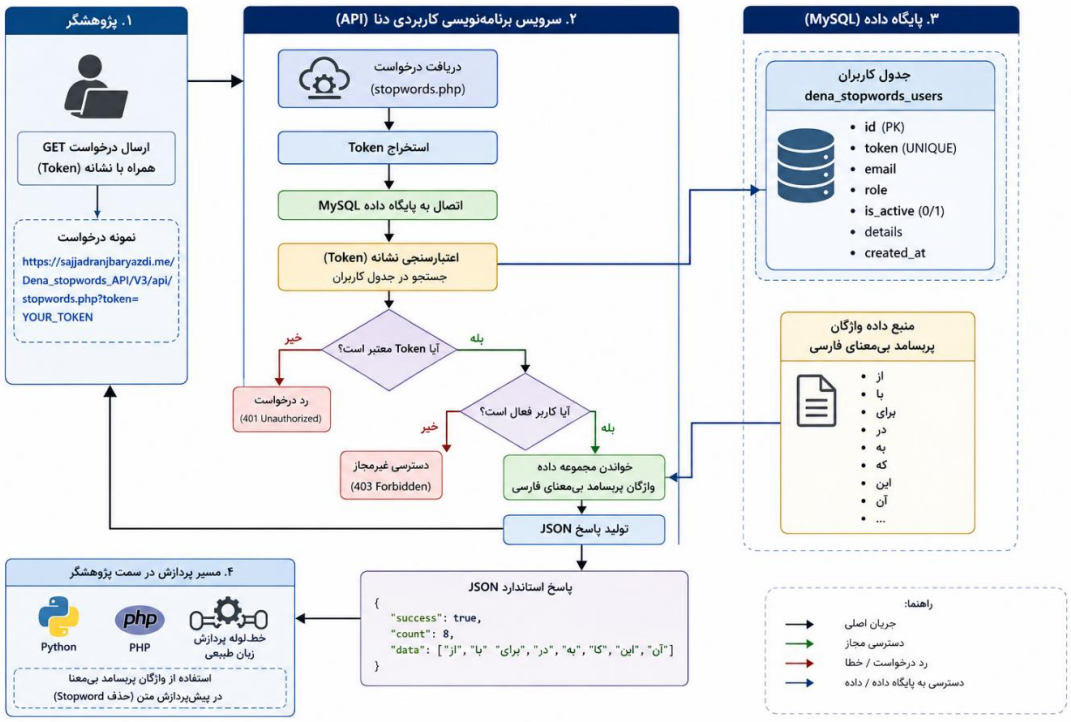
کتابخانه‌ها ممکن است از هموارسازی، تعریف متفاوت فراوانی و نرمال‌سازی بردار استفاده کنند؛ فرمول دقیقِ اجرا باید متناسب با همان پیاده‌سازی گزارش شود. فهرست توقف نیز باید با نرمال‌سازی و واژه‌ساز یکسان سازگار باشد؛ یکسان نبودن صورت «می‌شود» و «میشود» می‌تواند حذف واژه را نامنظم کند.

در داده‌های سلامت روان، حذف ضمیر اول‌شخص، واژهٔ نفی یا واژه‌ای مرتبط با کنش فرد ممکن است اطلاعات مهم را از بین ببرد. بنابراین استفادهٔ خودکار از یک فهرست عمومی بدون سنجش اعتبارسنجی توصیهٔ روش‌شناختی این

پژوهش نیست. نوت‌بوک اصلاح‌شده نفی انگلیسی را حفظ می‌کند و بازنمایی را درون تقسیم آموزش یاد می‌گیرد؛ نتایج آن نباید به خط‌لولهٔ متفاوتِ مبتنی بر حذف توقف نسبت داده شود.

الف-۳ معماری سرویس و قالب داده

در طرح مستندشدهٔ دنا، سرویس وب یک فهرست نگهداری‌شده را از طریق رابط HTTP/JSON در اختیار برنامهٔ کاربر قرار می‌دهد. کلاینت پس از بررسی پاسخ، آرایهٔ واژه‌ها را دریافت و به مجموعهٔ محلی تبدیل می‌کند. جداسازی لایهٔ نگهداری فهرست از کد تحلیل، امکان به‌روزرسانی یکپارچه و کنترل نسخه را فراهم می‌کند. برای یک آزمایش قابل‌بازتولید، تاریخ یا نسخه و هش فهرست استفاده‌شده باید همراه نتایج ثبت شود؛ تغییر فهرست در میانهٔ مقایسهٔ مدل‌ها می‌تواند ورودی آزمایش را تغییر دهد.



شکل الف-۱: معماری مفهومی سرویس واژگان توقف فارسی دنا

نشانی مستندشده در نسخهٔ مبنا چنین است:

`https://sajjadranjbaryazdi.me/Dena_stopwords_API/V3/api/stopwords.php`

مثال زیر صورت استفادهٔ توصیف‌شده در آن نسخه را نشان می‌دهد. مقدار نشانه صرفاً جای‌نگهدارِ مثال است و یک اعتبارنامهٔ واقعی نیست. این پایان‌نامه از درج نشانهٔ شخصی یا نتیجهٔ ادعاییِ یک درخواست اجرانشده خودداری می‌کند.

```
import requests

API_URL = (
    "https://sajjadranjbaryazdi.me/"
    "Dena_stopwords_API/V3/api/stopwords.php"
)
TOKEN = "YOUR_TOKEN"  # Supply securely in an actual application.
```

```
response = requests.get(API_URL, params={"token": TOKEN}, timeout=20)
response.raise_for_status()
payload = response.json()
stopwords = set(payload["data"])

def remove_stopwords(tokens):
    return [token for token in tokens if token not in stopwords]
```

پاسخ باید از نظر کد وضعیت، نوع داده و وجود فیلد مورد انتظار بررسی شود. خطای ارتباطی نباید بی‌صدا به یک فهرست خالی تبدیل شود؛ چنین رفتاری دو اجرای ظاهراً یکسان را با پیش‌پردازش متفاوت روبه‌رو می‌کند. برای اجرای آفلاین نیز می‌توان نسخهٔ مشخصی از فهرست را محلی نگه داشت و همان نسخه را در کل آزمایش به کار برد.

الف-۴ مدیریت دسترسی، خطا و توسعه

تفکیک نشانهٔ کاربران، محدودسازی نرخ، امکان غیرفعال‌سازی و استفاده از HTTPS از اجزای معماری توصیف‌شده‌اند. کدهای وضعیت متداول شامل ۲۰۰ برای موفقیت، ۴۰۱ برای احراز اصالت ناموفق، ۴۰۳ برای دسترسی غیرمجاز و ۴۰۵ برای روش درخواست نامجاز هستند. در استفادهٔ عملی، فرستادن نشانه در نشانی درخواست می‌تواند آن را در تاریخچه یا گزارش‌های میانی ثبت کند؛ انتخاب روش انتقال اعتبارنامه باید با قابلیت واقعی سرور و سیاست نگهداری گزارش سازگار باشد.

افزودن نسخه‌بندی فهرست، مستندات قالب، نمونهٔ پاسخ معتبر، کنترل نرمال‌سازی و آزمون‌های کوچک برای تفاوت‌های نوشتاری از مسیرهای توسعهٔ ابزار است. این پیوست مشخصات و کاربرد توصیف‌شده را بازسازی می‌کند؛ دسترس‌پذیری زندهٔ سرویس و کارایی آن به‌عنوان بخشی از آزمایش طبقه‌بندی این پایان‌نامه سنجیده نشده است.

پیوست ب

مسئلهٔ لگاریتم گسسته

ب-۱ تعریف و نقش در رمزنگاری

در گروه چرخه‌ای متناهی $G = \langle g \rangle$ با مرتبهٔ q، اگر $h = g^x$ معلوم باشد، مسئلهٔ لگاریتم گسسته یافتن $x \in \mathbb{Z}_q$ است:

$$\mathrm{DLP}(g, h): \qquad g^x = h. \tag{ب-۱}$$

توان‌رسانی با الگوریتم مربع‌کردن و ضرب در تعداد لگاریتمیِ عملیات گروه انجام می‌شود؛ یافتن وارون این نگاشت، بسته به ساختار و اندازهٔ گروه، می‌تواند دشوار باشد. دشواریِ صرفاً به تعداد بیت وابسته نیست. مرتبهٔ گروه، اندازهٔ بزرگ‌ترین عامل اول مرتبه و نمایش گروه بر الگوریتم‌های حمله اثر می‌گذارند.

جست‌وجوی ساده تا q مقدار، هزینهٔ $O(q)$ دارد. روش baby-step/giant-step با زمان و حافظهٔ $O(\sqrt{q})$ و روش‌های تصادفی مانند Pollard rho با حافظهٔ کمتر، مبادلهٔ دیگری فراهم می‌کنند. اگر مرتبه به عامل‌های کوچک تجزیه شود، روش Pohlig–Hellman مسئله را به زیرمسئله‌ها کاهش می‌دهد. بنابراین انتخاب گروه با مرتبهٔ نامناسب می‌تواند امنیت را کاهش دهد، حتی اگر پیمانه در ظاهر بزرگ باشد.

ب-۲ روش گام کوچک–گام بزرگ

با $m = \lceil \sqrt{q} \rceil$، نمای مجهول را به صورت $x = im + j$ می‌نویسیم. جدول گام کوچک شامل g^j برای $0 \le j < m$ ساخته می‌شود. سپس برای iهای متوالی، مقدار $h(g^{-m})^i$ با جدول مقایسه می‌شود. هر برخورد معتبر می‌دهد:

$$hg^{-im} = g^j \quad \Longrightarrow \quad x = im + j \pmod{q}. \tag{ب-۲}$$

بهتر است جواب بازیابی‌شده دوباره در رابطهٔ $g^x = h$ بررسی شود. عملیات وارون نیازمند معتبر بودن عضو گروه است. این الگوریتم در زیرگروه چرخه‌ایِ متناظر با رمزگشایی بنالوح نیز قابل استفاده است؛ الزاماً به میدان اول محدود نیست، اما مرتبه و عملیات گروه باید درست مشخص شوند.

ب-۳ کاربرد در بنالوح و تفاوت فضای پیام با پارامتر امنیت

در بنالوح، پس از اعمال توان خصوصی، رابطهٔ $a^m = b \pmod n$ در زیرگروهی با مرتبهٔ r به دست می‌آید. کوچک انتخاب شدن r باعث می‌شود این لگاریتم گسسته برای رمزگشای مجاز قابل حل باشد. این مسئله با شکستن مستقیم متن رمز توسط کسی که عوامل n را نمی‌داند یکسان نیست؛ توان خصوصی، متن رمز را به مسئلهٔ محدودِ قابل حل تبدیل می‌کند.

در عین حال، بزرگ کردن r برای افزایش ظرفیت مجموع وزن، هزینهٔ همین حل را بالا می‌برد. بنابراین انتخاب r باید هم قید $SW < r$ و هم حافظه و زمان رمزگشایی را رعایت کند. تغییر مقیاس اعشاری یا وزن‌ها نیز این مبادله را تغییر می‌دهد. این تحلیل، دلیل ضرورت بازآزمایی پارامترها هنگام اتصال بنچمارک کوچک به کلاینت‌های دارای وزن تعداد نمونه است.

الگوریتم شور روی رایانهٔ کوانتومی مناسب، تهدیدی برای خانواده‌های متکی بر لگاریتم گسسته و تجزیه است. بزرگ کردن طول کلید این طرح‌های کلاسیک به‌تنهایی آن‌ها را پساکوانتومی نمی‌کند. زمان‌بندی عملی چنین تهدیدی به منابع و فناوری وابسته است و از بنچمارک کوچک این پایان‌نامه قابل استنتاج نیست.

پیوست ج

تبادل کلید دیفی–هلمن

ج-۱ ساختار پایه

دیفی–هلمن امکان رسیدن دو طرف به یک راز مشترک را بدون ارسال خود راز فراهم می‌کند. در گروه مناسب $G = \langle g \rangle$ با مرتبهٔ q، طرف اول $a \in \mathbb{Z}_q$ و طرف دوم $b \in \mathbb{Z}_q$ را تصادفی انتخاب می‌کنند. پیام‌های عمومی $A = g^a$ و $B = g^b$ ردوبدل می‌شوند. طرفین سپس محاسبه می‌کنند:

$$K_A = B^a = g^{ba} = g^{ab} = A^b = K_B. \tag{ج-۱}$$

مقدار گروهی مشترک معمولاً مستقیماً کلید AES نیست؛ باید با تابع استخراج و گسترش کلید و اطلاعات زمینهٔ پروتکل به کلیدهای نشست مناسب تبدیل شود. تعیین نقش طرفین، نسخهٔ پروتکل و پیام‌های نشست در این زمینه از اشتباه گرفتن نشست‌ها جلوگیری می‌کند.

ج-۲ سه فرض متفاوت

مسئلهٔ لگاریتم گسسته، بازیابی a از g و g^a است. مسئلهٔ محاسباتی دیفی–هلمن یا CDH، محاسبهٔ g^{ab} از g, g^a, g^b است. مسئلهٔ تصمیمی دیفی–هلمن یا DDH، تشخیص سازگاری سه‌تایی g^a, g^b, g^c با شرط $c = ab \pmod q$ است. این سه تعریف نباید یک فرض واحد تلقی شوند. حل لگاریتم گسسته به حل CDH کمک می‌کند، اما دشوار بودن لگاریتم گسسته به‌تنهایی دشواری DDH را برای هر گروه ثابت نمی‌کند.

در رمزگذاری الجمال، مهاجم با مؤلفه‌هایی مرتبط با همین ساختار مواجه است. انتخاب گروه با خاصیت مناسب و اعتبارسنجی عضو ورودی، پیش‌شرط تحلیل امنیتی است. استفاده از کل گروه ضربی با زیرگروه‌های نامناسب می‌تواند نشانه‌هایی دربارهٔ پیام یا نما آشکار کند؛ اندازهٔ بزرگ پیمانه جایگزین بررسی ساختار گروه نیست.

ج-۳ احراز هویت و حملهٔ مرد میانی

نسخهٔ پایهٔ دیفی–هلمن هویت طرف مقابل را ثابت نمی‌کند. مهاجم فعال می‌تواند مقدار عمومی خود را به هر طرف بدهد و دو راز جداگانه با آن‌ها ایجاد کند. هر طرف در این حالت یک راز مشترک با مهاجم دارد، نه لزوماً با طرف

مورد نظر. برای جلوگیری از این حمله، پیام‌های تبادل باید به هویت معتبر، گواهی یا امضای معتبر و متن کامل نشست متصل شوند.

کلیدهای موقتی، در صورت حذف امن و طراحی درست پروتکل، می‌توانند محرمانگی پیشرو فراهم کنند. این ویژگی از صرف نوشتن رابطهٔ (ج-۱) نتیجه نمی‌شود و به نحوهٔ احراز هویت و نگهداری کلیدها وابسته است. بررسی عضو نامعتبر، گروه کوچک، تصادف ضعیف و بازیابی کلید از حافظه نیز جزو تحلیل استقرار است.

این پیوست، مبنای نظری مرتبط با تبادل کلید و الجمال را توضیح می‌دهد. اجرای نوت‌بوک‌های طبقه‌بندی یا امضای محمولهٔ بنالوح به این معنا نیست که یک نشست شبکه‌ای دیفی–هلمنِ احرازاصالت‌شده در همان آزمایش اجرا شده است.

پیوست د

باقیمانده‌های مرکب درجهٔ n

د-۱ تعریف مسئله

اگر $n = pq$ حاصل‌ضرب دو عدد اول باشد، یک عضو $z \in \mathbb{Z}_{n^2}^*$ باقیماندهٔ درجهٔ n است هرگاه عضوی u وجود داشته باشد که

$$z = u^n \pmod{n^2}. \qquad (د-۱)$$

مسئلهٔ تصمیمی باقیماندهٔ مرکب، تشخیص عضویت یک عنصر در این زیرگروه است. دشواری این مسئله، از مبانی تحلیل رمزگذاری پاییه است [۱۷۹]. دانستن عوامل n ابزارهای محاسبهٔ ساختار گروه و حل مسئله را فراهم می‌کند؛ با این حال، نباید بدون اثبات، دشواری این فرض را معادل دقیق دشواری تجزیه دانست.

د-۲ رابطه با رمزگذاری پاییه

در متن رمز $c = g^m u^n \pmod{n^2}$، مؤلفهٔ g^m پیام را در کلاس باقیمانده قرار می‌دهد و u^n تصادفی‌سازی در زیرگروه مربوط ایجاد می‌کند. با اعمال توان خصوصی λ، مؤلفهٔ تصادفی حذف می‌شود. برای $g = 1 + n$، بسط دوجمله‌ای در پیمانهٔ n^2 می‌دهد:

$$(1+n)^a \equiv 1 + an \pmod{n^2}, \qquad L((1+n)^a \bmod n^2) = a \pmod{n}. \qquad (د-۲)$$

بنابراین اگر شرایط وارون‌پذیری برقرار باشند، اعمال L و ضرب در وارون مناسب، پیام را بازمی‌گرداند. در فضای بزرگ‌تر دامگارد–یوریک، جمله‌های مرتبهٔ دوم و بالاتر باقی می‌مانند؛ همین نکته علت نادرست بودن تعمیم بی‌واسطهٔ فرمول سادهٔ پاییه برای تمام s است.

د-۳ حدود فرض و حملات مرتبط

طرح جمعی ذاتاً اجازهٔ تغییر متن رمز با یک عملگر جبری را می‌دهد. این ویژگی برای محاسبه لازم است، اما به معنای مقاومت خودکار در برابر حملهٔ فعال یا متن رمز انتخاب‌شده نیست. احراز اصالت محموله، سیاست پذیرش، جلوگیری

از بازپخش و محدود کردن دسترسی به رمزگشا باید در مدل کاربردی بررسی شوند.

استفاده از یک تبدیل عمومی برای دستیابی به امنیت قوی‌تر نیز لزوماً همریختی را حفظ نمی‌کند؛ در بسیاری از تبدیل‌ها، تغییر جبری متن رمز باعث نامعتبر شدن لایهٔ اضافه می‌شود. ازاین‌رو طراحی امنِ یک سامانهٔ محاسباتی نیازمند سازگاری لایهٔ احراز اصالت با تابع مورد نیاز است. در ساختار فصل چهارم، امضا پیش از تجمیع بررسی می‌شود و مؤلفهٔ امضا در جبر پایهٔ رمز دخالت داده نمی‌شود.

د-۴ پیاده‌سازی و آیندهٔ پارامترها

تولید تصادف امن، کنترل نسبتاً اول بودن، بررسی عضو معتبر و نگهداری محرمانهٔ عوامل پیمانه، بخش‌های ضروری پیاده‌سازی‌اند. نشت کانال جانبی یا افشای یکی از عوامل می‌تواند فرض ریاضیِ مدل ایده‌آل را بی‌اثر کند. انتخاب اعداد اول امن ممکن است برای برخی ساختارهای گروهی مفید باشد، اما جایگزینِ کامل شرایط معتبر پارامترهای هر طرح نیست.

توانایی کوانتومیِ کافی برای تجزیهٔ n، طرح‌های متکی بر این خانوادهٔ ساختارها را تهدید می‌کند. اندازه‌های آزمایشی این پایان‌نامه برای نتیجه‌گیری دربارهٔ مقاومت بلندمدت مناسب نیستند. پژوهش دربارهٔ ساختارهای پساکوانتومی و ارزیابی هزینهٔ محاسباتی آن‌ها یک مسیر مستقل برای توسعهٔ سامانه‌های حساس است.

پیوست هـ

الگوریتم امضای دیجیتال Ed25519

هـ-۱ منحنی و تولید کلید

Ed25519 گونه‌ای مشخص از EdDSA است که بر منحنی ادواردز روی میدان با مشخصهٔ $p = 2^{255} - 19$ تعریف می‌شود [۱۸۷]. معادلهٔ منحنی عبارت است از

$$-x^2 + y^2 = 1 + dx^2y^2, \qquad d = -\frac{121665}{121666} \pmod{p}. \tag{هـ-۱}$$

نقطهٔ پایهٔ B زیرگروه با مرتبهٔ اول

$$\ell = 2^{252} + 27742317777372353535851937790883648493 \tag{هـ-۲}$$

را تولید می‌کند و هم‌عامل منحنی ۸ است. این مرتبه با مشخصهٔ میدان تفاوت دارد؛ نماها در پیمانهٔ ℓ و مختصات در میدان $\mathbb{F}_p$ بررسی می‌شوند.

از یک بذر خصوصی ۳۲بایتی z، خروجی $h = \mathrm{SHA512}(z)$ محاسبه می‌شود. بخش نخست با عملیات تعیین‌شدهٔ clamping به اسکالر خصوصی a و بخش دوم به پیشوند محرمانهٔ h_{prefix} تبدیل می‌شود. کلید عمومی، کدگذاری نقطهٔ $A = [a]B$ است. جزئیات ترتیب بایت، کدگذاری نقطه و قیود بیت‌ها بخشی از استاندارد هستند و نباید با پیاده‌سازی دستیِ تقریباً مشابه جایگزین شوند.

هـ-۲ تولید امضا

برای پیام بایتی M، اسکالر موقت و نقطهٔ امضا چنین محاسبه می‌شوند:

$$r = \mathrm{SHA512}(h_{\mathrm{prefix}} \| M) \bmod \ell, \tag{هـ-۳}$$

$$R = [r]B, \tag{هـ-۴}$$

$$k = \mathrm{SHA512}(\mathrm{enc}(R) \| \mathrm{enc}(A) \| M) \bmod \ell, \tag{هـ-۵}$$

$$s = (r + ka) \bmod \ell. \tag{هـ-۶}$$

امضا شامل کدگذاری R و s است و مجموعاً ۶۴ بایت دارد. قطعی بودن این ساختار، نیاز به حفاظت از بذر و پیشوند محرمانه را حذف نمی‌کند. استفادهٔ نادرست از همان مواد کلید در گونه‌ای ناسازگار می‌تواند پیش‌فرض‌های امنیتی را تغییر دهد.

هـ-۳ بررسی و رابطهٔ درستی

در توضیح جبریِ زیرگروه معتبر، بررسی امضا به رابطهٔ

$$[s]B = R + [k]A \tag{هـ-۷}$$

متکی است، زیرا

$$R + [k]A = [r]B + [ka]B = [r + ka]B = [s]B. \tag{هـ-۸}$$

در بررسی بایتی واقعی، صحت کدگذاری، محدودهٔ اسکالر و ملاحظات هم‌عامل نیز اهمیت دارند. صورت‌های استانداردِ بررسی می‌توانند رابطهٔ ضرب‌شده در هم‌عامل را به کار ببرند؛ این جزئیات در استاندارد و کتابخانهٔ معتبر تعریف می‌شوند. رابطهٔ جبری ساده، مجوز پذیرفتن هر رشتهٔ بایتی به‌عنوان نقطهٔ معتبر نیست.

هـ-۴ کاربرد در پروتکل پایان‌نامه

در مخزن، کتابخانهٔ cryptography عملیات Ed25519 را انجام می‌دهد. پیامِ ورودی کتابخانه همان خروجی قطعیِ canonical_message است. این پیام شامل شناسهٔ طرح، کلاینت، دور، nonce، متن رمز و وزن است؛ امضای مستقل هر فیلد یا امضای یک هش دستیِ متفاوت انجام نمی‌شود.

این لایه از دستکاری برون‌زاد محموله و جعل هویت در چارچوب فرض‌های کلید جلوگیری می‌کند، اما محرمانگی متن را فراهم نمی‌کند. در مقابل، رمزگذاری بنالوح نیز به‌تنهایی هویت فرستنده را ثابت نمی‌کند. ترکیب درست نقش‌ها، بدون ضرب امضا در متن رمز، علت اصلی تفکیک دو مؤلفه در فصل چهارم است.

فهرست اختصارات

اختصار	عبارت کامل	معادل فارسی
NLP	Natural Language Processing	پردازش زبان طبیعی
ML	Machine Learning	یادگیری ماشین
FL	Federated Learning	یادگیری مشارکتی
HE	Homomorphic Encryption	رمزگذاری همریخت
PHE	Partially Homomorphic Encryption	رمزگذاری جزئی همریخت
FHE	Fully Homomorphic Encryption	رمزگذاری کاملاً همریخت
EDA	Exploratory Data Analysis	تحلیل اکتشافی داده
TF-IDF	Term Frequency–Inverse Document Frequency	بسامد واژه–بسامد معکوس سند
SBERT	Sentence-BERT	بازنمایی جمله مبتنی بر BERT
BERT	Bidirectional Encoder Representations from Transformers	بازنمایی دوسویهٔ رمزگذارها از مبدل‌ها
ROC	Receiver Operating Characteristic	مشخصهٔ عملکرد گیرنده
AUC	Area Under the Curve	سطح زیر منحنی
AP	Average Precision	میانگین دقت مثبت
API	Application Programming Interface	رابط برنامه‌نویسی کاربردی
AES	Advanced Encryption Standard	استاندارد رمزنگاری پیشرفته
GCM	Galois/Counter Mode	حالت گالوا/شمارنده
AEAD	Authenticated Encryption with Associated Data	رمزگذاری احرازاصالت‌شده با دادهٔ مرتبط
CSPRNG	Cryptographically Secure Pseudorandom Number Generator	مولد اعداد شبه‌تصادفی امن رمزنگاری
RSA	Rivest–Shamir–Adleman	طرح کلید عمومی RSA
PKI	Public Key Infrastructure	زیرساخت کلید عمومی
SHA	Secure Hash Algorithm	الگوریتم درهم‌سازی امن
JSON	JavaScript Object Notation	نشانه‌گذاری اشیای جاوااسکریپت
GPU	Graphics Processing Unit	واحد پردازش گرافیکی
FPGA	Field-Programmable Gate Array	آرایهٔ دروازه‌ای قابل‌برنامه‌ریزی میدانی
OOV	Out-of-Vocabulary	خارج از واژگان
BLS	Boneh–Lynn–Shacham	خانوادهٔ امضای دیجیتال BLS

اختصار	عبارت کامل	معادل فارسی
SBHE	Signed-Benaloh Homomorphic Encryption	بنالوح همریخت با محمولهٔ امضاشده
DENA	DENA Stopword Package	بستهٔ واژگان توقف دنا
IID	Independent and Identically Distributed	مستقل و هم‌توزیع
DLP	Discrete Logarithm Problem	مسئلهٔ لگاریتم گسسته
CDH	Computational Diffie–Hellman	دیفی–هلمن محاسباتی
DDH	Decisional Diffie–Hellman	دیفی–هلمن تصمیمی
DCR	Decisional Composite Residuosity	باقیماندهٔ مرکب تصمیمی
CV	Cross-Validation	اعتبارسنجی متقابل

واژه‌نامه

واژهٔ فارسی	معادل انگلیسی	تعریف
پردازش زبان طبیعی	Natural Language Processing	تحلیل، درک و تولید زبان انسانی با روش‌های محاسباتی.
یادگیری مشارکتی	Federated Learning	چارچوب یادگیری با دادهٔ آموزشی توزیع‌شده و بدون انتقال ضروریِ متن خام به یک مخزن مرکزی.
رمزگذاری همریخت	Homomorphic Encryption	رمزگذاری دارای عملگرهایی که با برخی محاسبات روی پیام سازگارند.
پیش‌پردازش	Preprocessing	مجموعهٔ عملیات آماده‌سازی داده پیش از مدل‌سازی.
پاکسازی متن	Text Cleaning	کنترل نویز و یکسان‌سازی اجزای متن با قواعد مشخص.
واژه‌سازی	Tokenization	تقسیم متن به واحدهای واژگانی یا زیرواژگانی.
بردارسازی	Vectorization	تبدیل متن به نمایش عددی قابل استفاده برای مدل.
بردار ویژگی	Feature Vector	بردار عددی نمایانگر یک نمونه.
مدل پیش‌آموزش‌دیده	Pre-trained Model	مدلی که پیش از کاربرد جاری روی دادهٔ دیگری آموزش یافته است.
ماتریس تنک	Sparse Matrix	ماتریسی که بخش بزرگی از عناصر آن صفر است.
بیش‌برازش	Overfitting	یادگیری بیش از حد الگوهای خاص آموزش و کاهش تعمیم به دادهٔ جدید.
طبقه‌بندی	Classification	انتساب نمونه به کلاس‌های تعریف‌شده.
طبقه‌بند	Classifier	مدل یا الگوریتم انجام‌دهندهٔ طبقه‌بندی.
جنگل تصادفی	Random Forest	مجموعه‌ای از درخت‌ها با تصادفی‌سازی نمونه‌ها و ویژگی‌ها.
درخت تصمیم	Decision Tree	مدلی با تقسیم بازگشتی فضای ویژگی‌ها و تصمیم‌گیری در برگ‌ها.
تقویت گرادیانی	Gradient Boosting	افزودن پیاپی مدل‌ها برای کاهش تابع زیان.
ایکس‌جی‌بوست	XGBoost	پیاده‌سازی مقیاس‌پذیر تقویت درختی با منظم‌سازی.
بیز ساده	Naive Bayes	طبقه‌بندی احتمالی با فرض استقلال شرطی ویژگی‌ها.
طبقه‌بند رأی‌دهنده	Voting Classifier	ترکیب خروجی چند طبقه‌بند برای تصمیم نهایی.
رأی‌گیری نرم	Soft Voting	ترکیب احتمال‌های خروجی چند مدل.

واژهٔ فارسی	معادل انگلیسی	تعریف
آستانهٔ تصمیم	Decision Threshold	حدی که احتمال خروجی را به برچسب تبدیل می‌کند.
تنظیم آستانه	Threshold Tuning	انتخاب آستانه بر دادهٔ مجازِ انتخاب مدل، بدون تنظیم روی آزمون نهایی.
دقت کلی	Accuracy	نسبت پیش‌بینی‌های صحیح به کل نمونه‌ها.
دقت مثبت	Precision	نسبت مثبت درست به تمام نمونه‌های مثبت پیش‌بینی‌شده.
بازیابی	Recall	نسبت مثبت درست به تمام نمونه‌های مثبت واقعی.
نمرهٔ اف‌یک	F1-score	میانگین هارمونیک دقت مثبت و بازیابی.
منحنی گیرنده	ROC Curve	نمایش نرخ مثبت درست در برابر نرخ مثبت کاذب با تغییر آستانه.
ماتریس سردرگمی	Confusion Matrix	جدول شمارش برچسب واقعی در برابر پیش‌بینی.
مثبت کاذب	False Positive	نمونهٔ منفی که مثبت پیش‌بینی شده است.
منفی کاذب	False Negative	نمونهٔ مثبت که منفی پیش‌بینی شده است.
متن اصلی	Plaintext	داده در دامنهٔ پیام پیش از رمزگذاری.
متن رمز	Ciphertext	خروجی الگوریتم رمزگذاری.
کلید عمومی	Public Key	کلید منتشرشده برای عملیات عمومیِ رمزگذاری یا بررسی امضا.
کلید خصوصی	Private Key	مادهٔ محرمانهٔ لازم برای رمزگشایی یا تولید امضا.
رمزگذاری	Encryption	تبدیل پیام به متن رمز با کلید و الگوریتم معین.
رمزگشایی	Decryption	بازیابی پیام از متن رمز با مادهٔ کلید مجاز.
امضای دیجیتال	Digital Signature	سازوکار تأیید اصالت و تمامیت پیام نسبت به کلید عمومی معتبر.
احراز هویت	Authentication	بررسی ارتباط موجودیت یا پیام با هویت معتبر.
تمامیت داده	Data Integrity	امکان تشخیص تغییر غیرمجاز داده در مدل تهدید تعریف‌شده.
محرمانگی	Confidentiality	حفاظت از اطلاعات در برابر طرف‌های غیرمجاز طبق مدل اعتماد.
تجمیع امن	Secure Aggregation	محاسبهٔ تابع تجمیعی با حفاظت مشخص از مشارکت‌های منفرد؛ حدود اعتماد باید صریح باشند.
حملهٔ بازپخش	Replay Attack	ارسال دوبارهٔ یک پیام معتبر برای پذیرش ناخواستهٔ مجدد.
تسهیم راز شامیر	Shamir Secret Sharing	تقسیم راز با قابلیت بازسازی از تعداد آستانه‌ای سهم.
درونیابی لاگرانژ	Lagrange Interpolation	بازسازی چندجمله‌ای از نقاط متمایز و ارزیابی آن.
میدان متناهی	Finite Field	ساختار جبری متناهی با جمع، ضرب و وارون عناصر ناصفر.
رمزگذاری گالوا/شمارنده	AES-GCM	رمزگذاری متقارن احرازاصالت‌شده با دادهٔ مرتبط.

واژهٔ فارسی	معادل انگلیسی	تعریف
مقدار یک‌بارمصرف	Nonce	مقداری برای استفادهٔ یکتا در زمینهٔ مشخصِ کلید یا پروتکل.
بنالوح	Benaloh Cryptosystem	طرح کلید عمومی با فضای پیام بلوکی و همریختی جمعی.
پاییه	Paillier Cryptosystem	طرح کلید عمومی جمعی مبتنی بر باقیمانده‌های مرکب.
دامگارد–یوریک	Damgaard–Jurik Cryptosystem	تعمیم پاییه با فضای پیام قابل‌تنظیم.
الجمال	ElGamal Cryptosystem	رمزگذاری گروهی که در صورت پایه همریختی ضربی دارد.
آراس‌ای	RSA	خانوادهٔ کلید عمومی مبتنی بر ساختار پیمانهٔ مرکب؛ نسخهٔ پایه قطعی است.
میانگین وزنی	Weighted Average	مجموع حاصل‌ضرب مقدارها و وزن‌ها تقسیم بر مجموع وزن‌ها.
نمایش نقطه‌ثابت	Fixed-Point Representation	بازنمایی مقدار اعشاری با عدد صحیح و ضریب مقیاس معلوم.
ضریب مقیاس	Scaling Factor	ضریب نگاشت مقدار اعشاری به نمایش صحیح.
سرریز فضای پیام	Message-Space Overflow	بزرگ شدن مجموع صحیح تا حدی که نتیجهٔ پیمانه‌ای با مجموع مطلوب متفاوت شود.
دنا	DENA Stopword Package	ابزار و سرویس واژگان توقف فارسی معرفی‌شده در پیوست.
اعتبارسنجی	Validation Set	دادهٔ جدا از آموزش برای انتخاب مدل یا آستانه.
آزمون نهایی	Test Set	دادهٔ کنارگذاشته‌شده برای ارزیابی انتخابِ تثبیت‌شده.
نشت داده	Data Leakage	ورود اطلاعات بخش ارزیابی به مرحله‌ای که باید فقط از آموزش یاد بگیرد.
کوانتیزه‌سازی	Quantization	نگاشت مقدار پیوسته به مجموعه‌ای گسسته با سیاست تبدیل مشخص.
کالیبراسیون احتمال	Probability Calibration	سازگاری احتمال برآوردی با فراوانی رخداد؛ با تنظیم آستانه یکسان نیست.

کتاب‌نامه

[1] World Health Organization. (2021). Suicide worldwide in 2019: Global health estimates. Geneva: WHO.

[2] Centers for Disease Control and Prevention (CDC). (2022). Leading Causes of Death Reports, 2020. National Vital Statistics System.

[3] Turecki, G., & Brent, D. A. (2016). Suicide and suicidal behaviour. The Lancet, 387(10024), 1227-1239.

[4] Blease, C., Torous, J., & Hagmann, C. (2020). Ethical challenges in the use of digital data for mental health research. The Lancet Digital Health, 2(8), e386-e387.

[5] Glenn, C. R., et al. (2020). Adolescent suicide risk and the developmental context. Annual Review of Clinical Psychology, 16, 397-422.

[6] Niederkrotenthaler, T., et al. (2020). Association of suicidal ideation and behavior with social media use. JAMA Network Open, 3(10), e2021398.

[7] Twenge, J. M., et al. (2018). Increases in depression and suicide among US adolescents. Clinical Psychological Science, 6(1), 3-17.

[8] Coppersmith, G., et al. (2018). Natural language processing in mental health. ACM Computing Surveys, 51(5), 1-36.

[9] Gunnarsson, K. F., et al. (2021). Linguistic markers of suicidal ideation: A systematic review. Journal of Affective Disorders, 295, 1205-1217.

[10] Shatte, A. B. R., et al. (2019). Machine learning in mental health: A scoping review. JMIR Mental Health, 6(11), e13316.

[11] Ji, S., Pan, S., Li, X., Cambria, E., Long, G., & Huang, Z. (2021). Suicidal ideation detection: A review of machine learning methods and applications. IEEE Transactions on Computational Social Systems, 8(1), 214–226.

[12] Heckler, W. F., de Carvalho, J. V., & Barbosa, J. L. V. (2021). Machine learning for suicidal ideation identification: A systematic literature review. Computers in Human Behavior, 120, 106807.

[13] Leveraging Reddit for suicidal ideation detection: A review of machine learning and natural language processing techniques. (2022).

[14] Sheng, Z. (2024). Suicidal ideation detection on social media using machine learning: A review. Applied and Computational Engineering, 71, 58–63.

[15] McMahan, B., Moore, E., Ramage, D., Hampson, S., & Arcas, B. A. y. (2017). Communication-efficient learning of deep networks from decentralized data. Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, 54, 1273–1282.

[16] Rieke, N., Hancox, J., Li, W., et al. (2020). The future of digital health with federated learning. NPJ Digital Medicine, 3, 119.

[17] Kairouz, P., McMahan, H. B., Avent, B., et al. (2021). Advances and open problems in federated learning. Foundations and Trends in Machine Learning, 14(1–2), 1–210.

[18] Khalil, S. S., Abdelsalam, N., Spruit, M., et al. (2024). Federated learning for privacy-preserving depression detection with multilingual language models in social media posts. Frontiers in Digital Health.

[19] Paillier, P. (1999). Public-key cryptosystems based on composite degree residuosity classes. In Advances in Cryptology—EUROCRYPT '99, 223–238.

[20] Gentry, C. (2009). A fully homomorphic encryption scheme. Stanford University.

[21] Wood, A., Najarian, K., & Kahrobaei, D. (2021). Homomorphic encryption for machine learning in medicine and bioinformatics. ACM Computing Surveys, 53(4).

[22] A systematic review of homomorphic encryption and its contributions in healthcare industry. (2022).

[23] Lee, C. H., Lim, K. H., & Eswaran, S. (2025). A comprehensive survey on secure healthcare data processing with homomorphic encryption: Attacks and defenses. Discover Public Health, 22, 137.

[24] Khurana, D., Koli, A., Khatter, K., & Singh, S. (2021). Natural Language Processing: State of The Art, Current Trends and Challenges.

[25] Chomsky, N. (1965). Aspects of the Theory of Syntax. Cambridge, MA: MIT Press.

[26] Rospocher, M., van Erp, M., Vossen, P., Fokkens, A., Aldabe, I., Rigau, G., Soroa, A., Ploeger, T., & Bogaard, T. (2016). Building event-centric knowledge graphs from news. Web Semantics: Science, Services and Agents on the World Wide Web, In Press.

[27] Shemtov, H. (1997). Ambiguity management in natural language generation. Stanford University.

[28] Hutchins, W. J. (1986). Machine translation: past, present, future (p. 66). Chichester: Ellis Horwood.

[29] Hutchins, W. J. (Ed.). (2000). Early years in machine translation: memoirs and biographies of pioneers (Vol. 97). John Benjamins Publishing.

[30] Green Jr., B. F., Wolf, A. K., Chomsky, C., & Laughery, K. (1961, May). Baseball: an automatic question-answerer. In Papers presented at the May 9-11, 1961, western joint IRE-AIEE-ACM computer conference (pp. 219-224). ACM.

[31] Woods, W. A. (1978). Semantics and quantification in natural language question answering. Advances in computers, 17, 1-87.

[32] Hendrix, G. G., Sacerdoti, E. D., Sagalowicz, D., & Slocum, J. (1978). Developing a natural language interface to complex data. ACM Transactions on Database Systems (TODS), 3(2), 105-147.

[33] Wilks, Y., & Fass, D. (1992). "The SRI Core Language Engine." In Natural Language Processing Systems. Springer-Verlag.

[34] Kamp, H., & Reyle, U. (1993). From Discourse to Logic: Introduction to Model-theoretic Semantics of Natural Language, Formal Logic and Discourse Representation Theory. Kluwer Academic Publishers.

[35] Briscoe, T., Grover, C., Boguraev, B., & Carroll, J. (1987). "The Alvey Natural Language Tools." In Proceedings of the 3rd Conference of the European Chapter of the Association for Computational Linguistics, pp. 139-148.

[36] Young, S., & Chase, L. (1998). "Speech Recognition and Understanding: The DARPA Program." In Proceedings of the IEEE, 86(5), pp. 1267-1283.

[37] Sundheim, B., & Chinchor, N. (1993). "Survey of the Message Understanding Conferences." In Proceedings of the Workshop on Human Language Technology, pp. 56-60.

[38] Kobsa, A., & Wahlster, W. (Eds.). (1989). User Models in Dialog Systems. Springer-Verlag.

[39] Cohen, P. R., Morgan, J., & Pollack, M. E. (Eds.). (1990). Intentions in Communication. MIT Press.

[40] McKeown, K. R. (1985). Text Generation: Using Discourse Strategies and Focus Constraints to Generate Natural Language Text. Cambridge University Press.

[41] Small, S. L., Cottrell, G. W., & Tanenhaus, M. K. (Eds.). (1988). Lexical Ambiguity Resolution: Perspectives from Psycholinguistics, Neuropsychology, and Artificial Intelligence. Morgan Kaufmann.

[42] Manning, C. D., & Schütze, H. (1999). Foundations of Statistical Natural Language Processing. MIT Press.

[43] Mani, I., & Maybury, M. T. (Eds.). (1999). Advances in Automatic Text Summarization. MIT Press.

[44] Kilgarriff, A., & Grefenstette, G. (2003). Introduction to the special issue on the web as corpus. Computational Linguistics, 29(3), 333-347.

[45] Haddi, E., Liu, X., & Shi, Y. (2013). The role of text pre-processing in sentiment analysis. Procedia Computer Science, 17, 26-32.

[46] Kaur, A., & Gupta, V. (2020). A comprehensive survey on text preprocessing techniques for natural language processing. ACM Computing Surveys, 52(4), 1-36.

[47] Aljuaid, H., et al. (2020). Importance of preprocessing in Arabic text classification. IEEE Access, 8, 205230-205243.

[48] Loper, E., & Bird, S. (2002). NLTK: The natural language toolkit. Proceedings of the ACL-02 Workshop on Effective Tools and Methodologies for Teaching NLP, 63-70.

[49] Kowsari, K., et al. (2019). Text classification algorithms: A survey. Information, 10(4),

[50] Eisner, B., et al. (2019). Emoji-based sentiment analysis. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing, 2345-2350.

[51] Fridkin, S., & M. (2020). Challenges in multilingual NLP for low-resource languages. Journal of Artificial Intelligence Research, 68, 245-298.

[52] Shamsfard, M., & S. (2019). Persian text normalization: A comprehensive approach. Language Resources and Evaluation, 53(2), 267-295.

[53] Karimi, S., et al. (2020). Challenges in Persian text processing. ACM Transactions on Asian and Low-Resource Language Information Processing, 19(3), 1-25.

[54] Wilbur, J., & S. (2019). Stop word removal in natural language processing. Journal of Computational Linguistics, 45(1), 127-152.

[55] Vijayarani, S., & J. (2020). Performance analysis of text preprocessing techniques. International Journal of Advanced Computer Science and Applications, 11(6), 345-352.

[56] Manning, C. D., & Schütze, H. (1999). Foundations of statistical natural language processing. MIT Press.

[57] Jurafsky, D., & Martin, J. H. (2023). Speech and language processing (3rd ed.). Stanford University.

[58] Coppersmith, G., et al. (2018). Natural language processing in mental health. ACM Computing Surveys, 51(5), 1-36.

[59] Loper, E., & Bird, S. (2002). NLTK: The natural language toolkit. Proceedings of the ACL-02 Workshop on Effective Tools and Methodologies for Teaching NLP, 63-70.

[60] Bird, S., Klein, E., & Loper, E. (2009). Natural language processing with Python. O'Reilly Media.

[61] Kaur, A., & Gupta, V. (2020). A comprehensive survey on text preprocessing techniques for natural language processing. ACM Computing Surveys, 52(4), 1-36.

[62] Sennrich, R., Haddow, B., & Birch, A. (2016). Neural machine translation of rare words with subword units. Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, 1715-1725.

[63] Liu, Y., et al. (2021). Efficient text preprocessing for large-scale NLP. Journal of Big Data, 8(1), 1-18.

[64] Fridkin, S., & M. (2020). Challenges in multilingual NLP for low-resource languages. Journal of Artificial Intelligence Research, 68, 245-298.

[65] Gunnarsson, K. F., et al. (2021). Linguistic markers of suicidal ideation: A systematic review. Journal of Affective Disorders, 295, 1205-1217.

[66] Vijayarani, S., & J. (2020). Performance analysis of text preprocessing techniques. International Journal of Advanced Computer Science and Applications, 11(6), 345-352.

[67] Zhang, C., et al. (2021). Privacy-preserving machine learning: A survey. ACM Computing Surveys, 54(7), 1-36.

[68] Haddi, E., Liu, X., & Shi, Y. (2013). The role of text pre-processing in sentiment analysis. Procedia Computer Science, 17, 26-32.

[69] Shamsfard, M., & S. (2019). Persian text normalization: A comprehensive approach. Language Resources and Evaluation, 53(2), 267-295.

[70] Karimi, S., et al. (2020). Challenges in Persian text processing. ACM Transactions on Asian and Low-Resource Language Information Processing, 19(3), 1-25.

[71] Aljuaid, H., et al. (2020). Importance of preprocessing in Arabic text classification. IEEE Access, 8, 205230-205243.

[72] Eskandari, M., & M. (2021). Spelling correction and spacing in Persian language. Journal of Language Resources and Evaluation, 55(1), 45-68.

[73] Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513-523.

[74] Kowsari, K., et al. (2019). Text classification algorithms: A survey. Information, 10(4),

[75] Devlin, J., et al. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT, 4171-4186.

[76] Manning, C. D., & Schütze, H. (1999). Foundations of statistical natural language processing. MIT Press.

[77] Bengio, Y., et al. (2003). A neural probabilistic language model. Journal of Machine Learning Research, 3, 1137-1155.

[78] Mikolov, T., et al. (2013). Efficient estimation of word representations in vector space. arXiv:1301.3781.

[79] Coppersmith, G., et al. (2018). Natural language processing in mental health. ACM Computing Surveys, 51(5), 1-36.

[80] Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. Proceedings of EMNLP-IJCNLP, 3982-3992.

[81] Vaswani, A., et al. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30, 5998-6008.

[82] Devlin, J., et al. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT, 4171-4186.

[83] Wang, W., et al. (2020). MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. Advances in Neural Information Processing Systems, 33, 5776-5788.

[84] Loper, E., & Bird, S. (2002). NLTK: The natural language toolkit. Proceedings of the ACL-02 Workshop, 63-70.

[85] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

[86] Thakur, N., et al. (2021). Augmented SBERT: Data augmentation method for improving bi-encoders. Proceedings of EACL, 141-152.

[87] Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513-523.

[88] Jones, K. S. (1972). A statistical interpretation of term specificity and its application in retrieval. Journal of Documentation, 28(1), 11-21.

[89] Ramos, J. (2003). Using TF-IDF to determine word relevance in document queries. Proceedings of the First Instructional Conference on Machine Learning, 242, 29-48.

[90] Liu, Y., et al. (2019). RoBERTa: A robustly optimized BERT pretraining approach. arXiv:1907.11692.

[91] Peters, M. E., et al. (2018). Deep contextualized word representations. Proceedings of NAACL-HLT, 2227-2237.

[92] He, Q., et al. (2021). Transformer-based models for suicide risk detection. Journal of Biomedical Informatics, 118, 103793.

[93] Strubell, E., et al. (2019). Energy and policy considerations for deep learning in NLP. Proceedings of ACL, 3645-3650.

[94] Conneau, A., et al. (2020). Unsupervised cross-lingual representation learning at scale. Proceedings of ACL, 8440-8451.

[95] Manning, C. D., et al. (2008). Introduction to information retrieval. Cambridge University Press.

[96] Vijayarani, S., & J. (2020). Performance analysis of text preprocessing techniques. International Journal of Advanced Computer Science and Applications, 11(6), 345-352.

[97] Aljuaid, H., et al. (2020). Importance of preprocessing in Arabic text classification. IEEE Access, 8, 205230-205243.

[98] Kowsari, K., et al. (2019). Text classification algorithms: A survey. Information, 10(4),

[99] Haddi, E., Liu, X., & Shi, Y. (2013). The role of text pre-processing in sentiment analysis. Procedia Computer Science, 17, 26-32.

[100] Kaur, A., & Gupta, V. (2020). A comprehensive survey on text preprocessing techniques for natural language processing. ACM Computing Surveys, 52(4), 1-36.

[101] Zhang, C., et al. (2021). Privacy-preserving machine learning: A survey. ACM Computing Surveys, 54(7), 1-36.

[102] Reimers, N., & Gurevych, I. (2020). Making monolingual sentence embeddings multilingual using knowledge distillation. Proceedings of EMNLP, 4512-4525.

[103] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.

[104] Ho, T. K. (1995). Random decision forests. Proceedings of the 3rd International Conference on Document Analysis and Recognition, 278-282.

[105] Amit, Y., & Geman, D. (1997). Shape quantization and recognition with randomized trees. Neural Computation, 9(7), 1545-1588.

[106] Biau, G., & Scornet, E. (2016). A random forest guided tour. Test, 25(2), 197-227.

[107] Fawagreh, K., Gaber, M. M., & Elyan, E. (2014). Random forests: from early developments to recent advancements. Systems Science & Control Engineering, 2(1), 602-609.

[108] Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer.

[109] Dietterich, T. G. (2000). Ensemble methods in machine learning. Multiple Classifier Systems, 1-15.

[110] Provost, F., & Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media.

[111] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263-1284.

[112] Zhang, H. (2004). The optimality of Naive Bayes. Proceedings of FLAIRS 2004.

[113] GHOST: Adjusting the Decision Threshold to Handle Imbalanced Data in Machine Learning. (2021). PubMed (NIH).

[114] Risk-Aware Calibration and Interpretable Baselines for Mental Health Text Classification. (2026). IEEE Xplore.

[115] Ding et al. (2024). Hyper-parameters setting for machine learning models. PeerJ Computer Science, 10, e2248.

[116] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321-357.

[117] Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861-874.

[118] Davis, J., & Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. Proceedings of the 23rd International Conference on Machine Learning, 233-240.

[119] Sokolova, M., Japkowicz, N., & Szpakowicz, S. (2006). Beyond accuracy, F-score and ROC: a family of discriminant measures for performance evaluation. AI 2006: Advances in Artificial Intelligence, 1015-1021.

[120] Machine Learning-Based Classification of Suicidal Ideation in Tweets. (2025). IEEE Xplore.

[121] Bazrafshan, M., & Sayehmiri, K. (2024). Predicting suicidal behavior outcomes: an analysis of key factors and machine learning models. BMC Psychiatry, 24, 123.

[122] Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. Journal of Machine Learning Research, 11, 2079-2107.

[123] López, V., Fernández, A., García, S., Palade, V., & Herrera, F. (2013). An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. Information Sciences, 250, 113-141.

[124] Safavian, S. R., & Landgrebe, D. (1991). A survey of decision tree classifier methodology. IEEE Transactions on Systems, Man, and Cybernetics, 21(3), 660-674.

[125] Hunt, E. B., Marin, J., & Stone, P. J. (1966). Experiments in Induction. Academic Press.

[126] Quinlan, J. R. (1986). Induction of decision trees. Machine Learning, 1(1), 81-106.

[127] Quinlan, J. R. (1993). C4.5: Programs for Machine Learning. Morgan Kaufmann.

[128] Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (1984). Classification and Regression Trees. CRC Press.

[129] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

[130] Mitchell, T. M. (1997). Machine Learning. McGraw-Hill.

[131] Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques. Morgan Kaufmann.

[132] Rokach, L., & Maimon, O. (2005). Decision trees. In Data Mining and Knowledge Discovery Handbook, 165-192.

[133] Witten, I. H., Frank, E., & Hall, M. A. (2011). Data Mining: Practical Machine Learning Tools and Techniques. Morgan Kaufmann.

[134] Loh, W. Y. (2011). Classification and regression trees. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 1(1), 14-23.

[135] Caruana, R., & Niculescu-Mizil, A. (2006). An empirical comparison of supervised learning algorithms. Proceedings of the 23rd International Conference on Machine Learning, 161-168.

[136] Wu, X., et al. (2008). Top 10 algorithms in data mining. Knowledge and Information Systems, 14(1), 1–37.

[137] Dietterich, T. G. (1995). Overfitting and undercomputing in machine learning. ACM Computing Surveys, 27(3), 326-327.

[138] Esposito, F., Malerba, D., & Semeraro, G. (1997). A comparative analysis of methods for pruning decision trees. IEEE Transactions on Pattern Analysis and Machine Intelligence, 19(5), 476-491.

[139] Zadrozny, B., & Elkan, C. (2001). Obtaining calibrated probability estimates from decision trees and naive Bayesian classifiers. Proceedings of the 18th International Conference on Machine Learning, 609-616.

[140] Provost, F., & Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media.

[141] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263-1284.

[142] Zhang, H. (2004). The optimality of Naive Bayes. Proceedings of FLAIRS 2004.

[143] Liu, W., Chawla, S., Cieslak, D. A., & Chawla, N. V. (2011). A robust decision tree algorithm for imbalanced data sets. Proceedings of the 2011 SIAM International Conference on Data Mining, 766-777.

[144] Risk-Aware Calibration and Interpretable Baselines for Mental Health Text Classification. (2026). IEEE Xplore.

[145] Sokolova, M., Japkowicz, N., & Szpakowicz, S. (2006). Beyond accuracy, F-score and ROC: a family of discriminant measures for performance evaluation. AI 2006: Advances in Artificial Intelligence, 1015-1021.

[146] Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861-874.

[147] GHOST: Adjusting the Decision Threshold to Handle Imbalanced Data in Machine Learning. (2021). PubMed (NIH).

[148] López, V., Fernández, A., García, S., Palade, V., & Herrera, F. (2013). An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. Information Sciences, 250, 113-141.

[149] Bazrafshan, M., & Sayehmiri, K. (2024). Predicting suicidal behavior outcomes: an analysis of key factors and machine learning models. BMC Psychiatry, 24, 123.

[150] Haghish, E. F., et al. (2023). Reconsidering False Positives in Machine Learning Binary Classification Models of Suicidal Behavior. Current Psychology, 43, 10117-10121.

[151] Alasmari, M. J. (2022). Ensemble Learning and XGBoost: A Comprehensive Review. SACM - United Kingdom.

[152] Gulati, J. (2025). Algorithm Showdown: Logistic Regression vs. Random Forest vs. XGBoost on Imbalanced Data. MachineLearningMastery.com.

[153] Text-Based Mental Health Detection Using Stacking Ensemble Approach with Hybrid Machine Learning and Deep Learning Models. (2026). IEEE Xplore.

[154] Artificial intelligence approach for predicting suicide-related behaviour in emergency departments. (2026). Scientific Reports (Nature).

[155] Mienye, I. D., & Sun, Y. (2022). A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. IEEE Access, 10, 99129-99149.

[156] ParaBoostForest Hybrid Parallel Boosting for Imbalanced Learning. (2025). GitHub.

[157] Wang, H. (2026). UEDU: Mental health distress signal detection in student writing. GitHub.

[158] Anchor rules from XGBoost model for suicide prediction. (2024). NIH/PMC.

[159] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD.

[160] XGBoost training and threshold optimization. (2026). Imperial College London GitLab.

[161] Early detection of mental health on social media using a hybrid Bi-LSTM–XGBoost model. (2026). Scientific Reports (Springer), 16, 20582.

[162] Garuda – Garba Rujukan Digital. (2026). Systematic Literature Review of Naive Bayes Algorithm for Data Classification in Indonesia.

[163] Garuda – Garba Rujukan Digital. (2025). Twitter Sentiment Analysis on the Iran-Israel Conflict Using the Naïve Bayes Classification Algorithm.

[164] National Institutes of Health (NIH). (2018). Potential use of text classification tools as signatures of suicidal behavior: A proof-of-concept study using Virginia Woolf's personal writings. PLoS ONE, 13(10), e0204820.

[165] IEEE Xplore. (2026). Comparative Analysis of Naïve Bayes Algorithms for Lecturer Performance Classification.

[166] MDPI. (2024). Detecting Suicidal Ideations in Online Forums with Textual and Psycholinguistic Features. Applied Sciences, 14(21), 9911.

[167] Journal of Computer Science and Information Technology. (2025). Twitter Sentiment Analysis on the Iran-Israel Conflict Using the Naïve Bayes Classification Algorithm.

[168] OUCI. (2023). Ensemble Learning for Email Classification using Voting Classifier. Expert Systems with Applications.

[169] Journal of Nnamdi Azikiwe University. (2026). An Improved Multinomial Naïve Bayes Algorithm with Laplace Smoothing for News Classification.

[170] GitHub. (2023). Suicide Detection using Naive Bayes Classification.

[171] GitHub. (2025). Ensemble Learning Voting Classifier using Naive Bayes.

[172] Virascience. (2015). A Survey Paper On Naive Bayes Classifier For Multi-Feature Based Text Mining.

[173] Nauki i Tekhniki. (2024). Review of methods for semantic text classification.

[174] Czech Academy of Sciences. (2023). Spam Detection Using Ensemble Learning.

[175] Stack Overflow. (2015). Naive Bayes Text Classification Laplace Smoothing.

[176] Zhang, H. (2004). The optimality of Naive Bayes. Proceedings of the Seventeenth International Florida Artificial Intelligence Research Society Conference (FLAIRS 2004).

[177] Eskandari, M., & M. (2021). Spelling correction and spacing in Persian language. Journal of Language Resources and Evaluation, 55(1), 45-68.

[178] ElGamal, T. (1985). A Public Key Cryptosystem and a Signature Scheme Based on Discrete Logarithms. IEEE Transactions on Information Theory, 31(4), 469–472.

[179] Paillier, P. (1999). Public-Key Cryptosystems Based on Composite Degree Residuosity Classes. EUROCRYPT 1999, LNCS 1592, 223–238.

[180] Benaloh, J. (1994). Dense Probabilistic Encryption. Selected Areas in Cryptography

[181] Damgård, I., & Jurik, M. (2001). A Generalisation, a Simplification and Some Applications of Paillier's Probabilistic Public-Key System. PKC 2001, LNCS 1992, 119–136.

[182] Rivest, R. L., Shamir, A., & Adleman, L. (1978). A Method for Obtaining Digital Signatures and Public-Key Cryptosystems. Communications of the ACM, 21(2), 120–126.

[183] Ranjbar Yazdi, S. Corrected model-comparison notebook, `finding-the-best-model-fixed.ipynb`. Source and measured outputs archived with this thesis. `https://github.com/Sajjad-s-presentations/My-master-s-thesis/blob/presentation/Notebooks/finding-the-best-model-fixed.ipynb`.

[184] Ranjbar Yazdi, S. Federated XGBoost experiments with 10, 20, 50 and 100 clients. Archived executed notebook and extracted result tables. `https://github.com/Sajjad-s-presentations/My-master-s-thesis/blob/presentation/Notebooks/federated_xgboost_10_20_50_100.ipynb`.

[185] Shamir, A. (1979). How to Share a Secret. Communications of the ACM, 22(11), 612–613. doi:10.1145/359168.359176.

[186] Dworkin, M. (2007). Recommendation for Block Cipher Modes of Operation: Galois/Counter Mode (GCM) and GMAC. NIST Special Publication 800-38D. doi:10.6028/NIST.SP.800-38D.

[187] Josefsson, S., & Liusvaara, I. (2017). Edwards-Curve Digital Signature Algorithm (EdDSA). RFC 8032. doi:10.17487/RFC8032.

[188] Bonawitz, K., et al. (2017). Practical Secure Aggregation for Privacy-Preserving Machine Learning. Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security, 1175–1191. doi:10.1145/3133956.3133982.

Abstract

Text-based analysis of suicide-related signals requires both valid evaluation and careful treatment of sensitive mental-health information. This thesis examines text classification, distributed probability aggregation, and authenticated homomorphic weighted aggregation. The English Suicide Watch dataset contains 232,074 raw records. Deduplication, stratified splitting, and partition-aware cleaning yield 148,380 training, 37,086 validation, and 46,342 test records. A 100-dimensional Word2Vec representation is learned inside each training fold. Random Forest, Decision Tree, XGBoost, and Gaussian–Bernoulli soft voting are compared on validation data. The model and threshold are frozen before final test evaluation. The centralized evaluation selects XGBoost, with threshold 0.38, test accuracy 92.70 percent, and positive-class F1 of 0.9278.

The distributed experiment assigns every training record exactly once using class-stratified, approximately IID partitions for 10, 20, 50, and 100 clients. Each client learns its own Word2Vec and XGBoost model. Predictions are combined by a sample-count-weighted mean, rather than by averaging independently learned tree parameters or embedding coordinates. Archived test accuracies at validation-selected thresholds are 91.58, 90.93, 89.30, and 87.00 percent, respectively. The 10-client scenario is selected using validation F1. Only one seed is available per scenario; across-run uncertainty is not estimated.

The SBHE-Benaloh implementation verifies an Ed25519 signature over a deterministic transcript containing identity, round, nonce, ciphertext, and weight before aggregation. The signature is kept outside the ciphertext algebra. Correctness requires an explicit fixed-point representation and sufficient plaintext-space capacity. Archived 256-bit research-key benchmarks report mean total times of approximately 119.02 and 275.68 milliseconds for 100 and 300 clients. These are separate cryptographic benchmarks, not end-to-end encrypted classification measurements. The analysis explicitly distinguishes the private-key-owning server from external observers and documents the absence of range proofs and threshold decryption. The findings support further research and do not establish clinical readiness or production cryptographic security.

Keywords: Natural language processing; distributed learning; stratified partitioning; Word2Vec; threshold selection; homomorphic encryption; Benaloh; digital signatures; privacy.



Shahid Beheshti University

Faculty of Mathematical Sciences

Department of Computer Science

M.Sc. Thesis

Securing Sensitive Data in Suicide Prediction with a Federated Learning and Homomorphic Encryption Approach in Natural Language Processing

By

Sajjad Ranjbar Yazdi

Supervisor

Dr. Ziba Eslami

September 2026