به نام خدا، از خدا و برای خدا

دانشگاه شهید بهشتی تهران

دانشکده علوم ریاضی

گروه علوم کامپیوتر

پایان‌نامه کارشناسی ارشد

عنوان

حفظ امنیت داده‌های حساس در پیش‌بینی خودکشی با رویکردی مبتنی بر یادگیری مشارکتی و رمزگذاری هم‌ریخت در پردازش زبان طبیعی

نگارش

سجاد رنجبر یزدی

استاد راهنما

سرکار خانم دکتر زیبا اسلامی

شهریور ماه سال ۱۴۰۵

کلیه حقوق اعم از چاپ و کثیر، نسخه‌برداری، ترجمه، اقتباس و... از این پایان‌نامه برای دانشگاه شهید بهشتی تهران محفوظ است. نقل مطالب با ذکر ماخذ آزاد است.

تقدیم به مادر و پدر ؛

که با کلید محبت، رمز عشق را برایم خوانا کردند.

سپاس گزاری...

با درود و ستایشِ بی‌پایان، سخن را با نامِ آن یگانه بی‌مانند می‌گشایم که الطافِ بی‌حدّ و حصرش، رهگشایِ گام‌های ناتوانِ من در این وادیِ دانش بود و مرا به فرجامِ این مقصود، موفّق و مؤیّد گردانید.

پس از ستایشِ ایزدی، ارج نهادن به مقامِ والای استادِ فرزانه و راهنمایِ خویش، سرکارِ خانمِ دکتر زیبا اسلامی، برترین فریضه سپاسگزاری است. آن بزرگوار با شکیباییِ کم‌مانند و ژرفایِ بینش و رهنمودهایِ سودمندشان، همواره روشنایی‌بخشِ مسیرِ این پژوهش بوده‌اند و بیمِ یاریِ خردورزانه ایشان، نگارشِ این اوراق میسّر نمی‌گشت. امید که این قلیلِ بضاعت، پاسخی هرچند ناچیز به رنج‌هایِ پیگیرِ آن استادِ گرانمایه باشد.

در ادامه، مراتبِ امتنانِ خویش را به حضورِ جنابِ آقایِ دکتر فراهانی، از چهره‌های علمیِ دانشگاهِ تربیت مدرس، تقدیم می‌دارم. وقتی که ایشان با کَرَم، در اختیارِ این پژوهش نهادند و مشاوره‌هایِ تخصّصیشان، سهمی بسزا در غنایِ علمیِ این پایان‌نامه ایفا کرد، از لطف و مساعدتِ صمیمانه ایشان، صادقانه سپاسگزارم.

بی‌تردید، پیمودنِ بخش‌هایِ عَمَلیِ این تحقیق، جز با یاریِ دست‌اندرکارانِ عرصه سخت‌افزار، میسّر نمی‌بود. بدینگونه، از جنابِ مهندس ناظری، از دانشگاه فردوسی مشهد، که با گشاده‌دستی و بزرگ‌منشی، تجهیزات و زیرساخت‌هایِ سخت‌افزاریِ لازم را در دسترسِ اینجانب نهادند، صمیمانه‌ترین سپاس‌ها را دارم. همچنین، از جنابِ مهندس شمس‌آبادی و همسرِ ایشان، مهندس نازفروش، که در روزگارِ دانشجویی، همواره یاورِ من در گشایشِ دشواری‌ها و ارائه یاری‌هایِ کارگشا بودند، از تهِ جان سپاسگزارم. محبّت‌هایِ بی‌چشمداشتِ این بزرگواران، هیچ‌گاه از خاطر نخواهد رفت.

و در پایان، بر خود می‌بالم که در این مسیرِ پرفرازونشیب، با بزرگوارانی همسفر بودم که یادشان، سرمایه دل است. از درگاهِ خداوندِ متعال، دوامِ تندرستی و فزونیِ توفیقِ همگان را مسئلت می‌نمایم.

سجاد رنجبر یزدی

شهریور ماه ۱۴۰۵

نام خانوادگی دانشجو: رنجبر یزدی **نام:** سجاد

عنوان: حفظ امنیت داده‌های حساس در پیش‌بینی خودکشی با رویکردی مبتنی بر یادگیری مشارکتی و رمزگذاری هم‌ریخت در پردازش زبان طبیعی

استاد راهنما: سرکار خانم دکتر زیبا اسلامی

مقطع تحصیلی: کارشناسی ارشد **رشته:** علوم کامپیوتر **گرایش:** داده‌کاوی

دانشگاه: شهید بهشتی **دانشکده:** علوم ریاضی

تاریخ فارغ‌التحصیلی: شهریور۰۵ **تعداد صفحه:**

واژگان کلیدی:

پردازش زبان طبیعی، تشخیص خطر خودکشی، تحلیل متون، یادگیری ماشین، یادگیری فدرال، یادگیری مشارکتی، یادگیری غیرمتمرکز، رمزگذاری هم‌ریخت، Paillier، Benaloh، Damgård–Jurik، حریم خصوصی، سلامت روان دیجیتال، Sentence-BERT، Naive Bayes، XGBoost، Random Forest.

چکیده:

خودکشی به عنوان یک بحران جدی در حوزهی سلامت جهانی، سالانه جان صدها هزار نفر را میگیرد و علی‌رغم ماهیت قابل‌پیش‌گیری آن، فقدان نظام‌های کارآمد برای غربالگری زودهنگام و نیز چالش‌های مرتبط با حریم خصوصی داده‌های روان‌شناختی، موانع عمدهای بر سر راه مداخلات به‌موقع ایجاد کرده است. این پایان‌نامه با هدف ارائهی یک چارچوب نوین و امن برای پیش‌بینی خطر خودکشی، رویکردی چندلایه را طراحی و پیاده‌سازی می‌کند که در آن، پردازش زبان طبیعی (NLP) با یادگیری مشارکتی و رمزگذاری هم‌ریخت تلفیق شده است. در گام نخست، با پیاده‌سازی خط‌لوله‌ای جامع برای پاک‌سازی و بردارسازی متون چندزبانه (فارسی، انگلیسی و عبری) و با بهره‌گیری از مدل Word۲Vec ، داده‌های دیتاستی با ۴۶۴,۱۴۸ نمونه، برای آموزش الگوریتم‌های یادگیری ماشین آماده‌سازی شد. مقایسه‌ی عملکرد چهار الگوریتم اصلی(Random Forest، XGBoost ،Decision Tree و Naive Bayes) بر اساس معیارهای دقت، Recall ،Precision و F۱-score نشان داد که مدل XGBoost با دقت ۹۳.۶۳٪ و Recall و F۱-score معادل ۰.۹۴ برای کلاس خودکشی، عملکرد برتری نسبت به سایر مدل‌ها دارد. در گام دوم، برای تأمین امنیت تبادل اطلاعات در معماری مشارکتی، یک پروتکل دو لایه طراحی شد. لایه‌ی اول، از رمزنگاری متقارن AES-۲۵۶ در حالت GCM برای رمزگذاری متن ورودی و از طرح تسهیم راز شامیر برای توزیع امن کلید میان کلاینت‌ها استفاده می‌کند. لایه‌ی دوم، که هسته‌ی نوآوری پژوهش را تشکیل می‌دهد، پروتکل SBHE-Benaloh نام دارد و امکان تجمیع امن و احرازهویت‌شده‌ی میانگین وزنی خروجی‌های کلاینت‌ها را فراهم می‌آورد. این پروتکل با ترکیب رمزگذاری هم‌ریخت جمعی Benaloh و امضای دیجیتال Ed۲۵۵۱۹، ضمن حفظ محرمانگی داده‌های فردی، اصالت فرستنده، تمامیت داده و مقاومت در برابر حملات بازپخش را نیز تضمین می‌کند. نتایج پیاده‌سازی نشان می‌دهد که در اندازه‌ی کلید ۲۵۶ بیتی، زمان کل پردازش برای ۱۰۰ کلاینت حدود ۱۱۹ میلی‌ثانیه و برای ۳۰۰ کلاینت حدود ۲۷۶ میلی‌ثانیه است که بیانگر کارایی و مقیاس‌پذیری مناسب طرح است. این چارچوب با ارائه‌ی راهکاری جامع برای پل زدن میان نیاز به دقت در تشخیص و الزامات حیاتی حریم خصوصی، گامی مؤثر در جهت تحقق "سلامت روان دیجیتال امن" برداشته و مسیری عملی برای کاربردهای بالینی هوش مصنوعی در بسترهای غیرمتمرکز و حساس به حریم خصوصی ترسیم می‌کند.

فهرست عناوین

مقدمه..... ۲۰

فصل اول: طرح موضوع و بررسی پیشینه پژوهش..... ۲۷

- ۱-۱ ضرورت انجام پژوهش..... ۲۸
- ۱-۲ نحوه انجام پژوهش..... ۳۰
- ۱-۳ پیشینه پژوهش..... ۳۲
  - ۱-۳-۱ تشخیص خطر خودکشی با استفاده از پردازش زبان طبیعی و یادگیری ماشین..... ۳۲
  - ۱-۳-۲ یادگیری فدرال و یادگیری غیرمتمرکز در حوزه سلامت..... ۳۳
  - ۱-۳-۳ رمزگذاری هم‌ریخت و یادگیری ماشین حفظ‌کننده حریم خصوصی..... ۳۴
  - ۱-۳-۴ جمع‌بندی پیشینه و شکاف پژوهشی..... ۳۶

فصل دوم: واژه‌ها را بشنو؛ بنیان‌های نظری پردازش زبان طبیعی در جستجوی افکار خودکشی..... ۳۸

- ۲-۱ پردازش زبان طبیعی..... ۴۰
- ۲-۲ تاریخچه..... ۴۱
- ۲-۳ نحوه پیاده‌سازی..... ۴۲
  - ۲-۳-۱ مجموعه دادگان..... ۴۴
  - ۲-۳-۲ پیش پردازش و پاکسازی مجموعه دادگان..... ۴۵
  - ۲-۳-۳ توکن‌سازی؛ گام بنیادین در پردازش زبان طبیعی..... ۴۸
  - ۲-۳-۴ بردارسازی؛ پل ارتباطی بین زبان انسان و ماشین..... ۵۰
  - ۲-۳-۵ بردارسازی مبتنی برWord۲Vec ۵۱
  - ۲-۳-۶ معیارهای ارزیابی عملکرد مدل‌ها..... ۵۷
- ۲-۴ الگوریتم‌های یادگیری ماشین..... ۵۸
  - ۲-۴-۱ مبانی نظری و تاریخچه الگوریتم جنگل تصادفی..... ۵۸
  - ۲-۴-۲ مبانی نظری و تاریخچه الگوریتم درخت تصمیم..... ۶۳

- ۲-۴-۳ مبانی نظری و تاریخچه الگوریتم XGBoost ۶۹
- ۲-۴-۴ تاریخچه و مبانی نظری الگوریتم Naive Bayes ۷۵
- ۲-۴-۵ نتیجه‌گیری ۸۲
- ۲-۵ آنالیز حساسیت ۸۴

فصل سوم: سپری از اعداد؛ طراحی و پیاده‌سازی بستر امن تبادل داده با بهره‌گیری از رمزگذاری هم‌ریخت ۹۱

- ۳-۱ رمزگذاری متن ورودی با استفاده از AES-GCM ۹۲
  - ۳-۱-۱ ضرورت و مبانی طرح تسهیم راز شامیر ۹۳
  - ۳-۱-۲ بازسازی کلید با درون‌یابی لاگرانژ ۹۳
  - ۳-۱-۳ ویژگی‌های امنیتی بنیادین ۹۴
  - ۳-۱-۴ جریان کامل پروتکل ۹۵
  - ۳-۱-۵ مدل تهدید و تحلیل پیچیدگی محاسباتی، امنیت و آسیب‌پذیری‌ها ۹۷
- ۳-۲ ارسال اطلاعات از کلاینت‌ها به مت سرور به کمک رمزگذاری هم‌ریخت ۹۷
  - ۳-۲-۱ رمزگذاری ElGamal ۹۸
  - ۳-۲-۲ رمزگذاری Paillier ۱۰۱
  - ۳-۲-۳ رمزگذاری Benaloh ۱۰۴
  - ۳-۲-۴ رمزگذاری Damgård–Jurik ۱۰۷
  - ۳-۲-۵ رمزگذاری RSA ۱۰۹
- ۳-۳ مقایسه کلی پنج طرح ۱۱۱
  - ۳-۳-۱ صحت‌سنجی و یکپارچگی هم‌ریختی ۱۱۳
  - ۳-۳-۲ تحلیل عمیق زمان تولید کلید ۱۱۳
  - ۳-۳-۳ واکاوی زمان رمزگذاری ۱۱۴
  - ۳-۳-۴ بررسی زمان رمزگشایی ۱۱۸
  - ۳-۳-۵ تحلیل زمان کل و مقایسه‌ی نهایی ۱۱۹

فصل چهارم: طراحی و پیاده‌سازی پروتکل تجمیع میانگین وزنیِ محرمانه و احرازهویت‌شده(SBHE-Benaloh) ۱۲۱

- ۴-۱ پروتکل تجمیع میانگین وزنیِ محرمانه و احرازهویت‌شده..... ۱۲۲
- ۴-۲ مدل سیستم و اعضا آن..... ۱۲۳
- ۴-۳ بازنمایی عددی و مدیریت دقت..... ۱۲۴
- ۴-۴ مبانی رمزنگاری..... ۱۲۵
- ۴-۵ ساختار پروتکل SBHE-Benaloh ۱۲۶
- ۴-۶ تشریح کامل گام‌های پروتکل..... ۱۲۷
- ۴-۷ اثبات درستی طرح..... ۱۲۹
- ۴-۸ تحلیل جامع امنیتی..... ۱۳۰
- ۴-۹ تمایز اساسی SBHE با رویکردهای ترکیبی ساده‌انگارانه..... ۱۳۱
- ۴-۱۰ چشم‌انداز آینده و مسیرهای بهبود..... ۱۳۱
- ۴-۱۱ جمع‌بندی..... ۱۳۲

پیوست‌ها..... ۱۳۹

- پیوست ۲-الف: پکیج کلمات توقف دنا..... ۱۴۰
- پیوست ۳-الف: مسئله لگاریتم گسسته(Discrete Logarithm Problem) ۱۴۵
- پیوست ۳-ب: پروتکل تبادل کلید دفی-هلمن..... ۱۴۷
- پیوست ۳-ج: مسئله باقیمانده‌های مرکب درجه‌ی n ۱۵۰
- پیوست ۴-الف الگوریتم امضای دیجیتال Ed۲۵۵۱۹ ..... ۱۵۴

فهرست اختصارات..... ۱۵۶
واژه‌نامه..... ۱۵۸
منابع..... ۱۶۲

فهرست شکل‌ها

شکل ۱-۱	مدل یادگیری مشارکتی	۳۰
شکل ۱-۲	پیشینه پژوهش	۳۶
شکل ۲-۱	طرح‌واره گام‌های اصلی تشخیص خطر خودکشی از طریق تحلیل متون	۴۳
شکل ۲-۲	طرح‌واره پاکسازی دادگان	۴۶
شکل ۲-۳	فلوچارت الگوریتم جنگل تصادفی	۵۹
شکل ۲-۴	ماتریس سردرگمی جنگل تصادفی	۶۲
شکل ۲-۵	فلوچارت الگوریتم درخت تصمیم	۶۴
شکل ۲-۶	ماتریس سردرگمی درخت تصمیم	۶۸
شکل ۲-۷	فلوچارت الگوریتمXG-Boost	۶۹
شکل ۲-۸	ماتریس سردرگمیXG-Boost	۷۴
شکل ۲-۹	مدل بیز	۷۵
شکل ۲-۱۰	ماتریس سردرگمی مدل بیز	۸۱
شکل ۲-۱۱	تحلیل حساسیت (نمودار مربوط به آستانه اطمینان)	۸۶
شکل ۲-۱۲	ناحیه بحرانی (نمودار توزیع خطا بر اساس احتمال)	۸۹
شکل ۳-۱	رویه رمزگذاری متن ارسالی از سرور به کلاینت‌ها	۹۶

فهرست شکل‌ها

شکل ۳-۲	طرح رمزگذاری الجمال	۱۰۰
شکل ۳-۳	طرح رمزگذاری Pillier	۱۰۳
شکل ۳-۴	طرح رمزگذاری Benaloh	۱۰۶
شکل ۳-۵	روند تغییرات زمان تولید کلید بسته به سایز کلید	۱۱۴
شکل ۳-۶	روند تغییرات زمان رمزگذاری بسته به اندازه کلید	۱۱۵
شکل ۳-۷	نمودار میله زمان کل اجرای طرح‌ها بسته به سایز کلید	۱۱۷
شکل ۳-۸	مقایسه عملکرد زمانی کلیه طرح‌ها	۱۲۰
شکل ۴-۱	طرح Signed-Benaloh Homomorphic Encryption	۱۲۳
شکل ۴-۲	عملکرد زمانی طرح بسته به طول کلید و تعداد کلاینت‌ها	۱۳۴
شکل ۴-۳	عملکرد زمانی گام‌های طرح با کلید ۲۵۶ بیت	۱۳۵
شکل ۴-۴	سهم هر گام از طرح در زمان کل اجرا بسته به طول کلید	۱۳۶
شکل ۴-۵	تاثیر تعداد کلاینت‌ها و طول کلد بر زمان کل اجرا	۱۳۷
شکل ۵-۱	معماری کلی سرویس دنا	۱۴۲

فهرست جداول

جدول ۲-۱	نتایج ارزیابی مدل جنگل تصادفی	۶۲
جدول ۲-۲	نتایج ارزیابی مدل درخت تصمیم	۶۸
جدول ۲-۳	نتایج ارزیابی مدلXGBoost	۷۴
جدول ۲-۴	نتایج ارزیابی مدلNaive Bayes	۸۱
جدول ۲-۵	خلاصه عملکرد چهار الگوریتم یادگیری ماشین	۸۳
جدول ۳-۱	مقایسه کلی پنج طرح رمزگذاری هم‌ریخت	۱۱۲

مقدمه

خودکشی به عنوان یکی از مهم‌ترین چالش‌های حوزه‌ی سلامت عمومی، نه تنها یک تراژدی فردی، بلکه بحرانی عمیق در نظام سلامت جهانی محسوب می‌شود. داده‌های سازمان جهانی بهداشت (WHO) حاکی از آن است که سالانه حدود ۷۰۰ هزار نفر بر اثر خودکشی جان خود را از دست می‌دهند و این پدیده در زمره‌ی ده علت اصلی مرگ در تمامی گروه‌های سنی قرار دارد [۱]. با این حال، آنچه این معضل را از سایر علل مرگ متمایز می‌کند، ماهیت قابل‌پیش‌گیری آن است. به‌گونه‌ای که سازمان جهانی بهداشت بر لزوم تدوین برنامه‌های ملی برای کاهش یک‌سوم موارد خودکشی تا سال ۲۰۳۰ تأکید کرده است [۱]. برخلاف بسیاری از بیماری‌های مزمن، خودکشی اغلب نتیجه‌ی تعامل پیچیده‌ای از عوامل ژنتیکی، روان‌شناختی، اجتماعی و محیطی است که در صورت تشخیص به‌موقع، قابل مداخله است [۳]. اما چالش اساسی در این میان، نه کمبود روش‌های درمانی، که نبود نظام‌های کارآمد برای غربالگری زودهنگام و کاهش انگ اجتماعی پیرامون بیماری‌های روانی است. بسیاری از قربانیان، ماه‌ها پیش از اقدام، نشانه‌های هشداردهنده‌ای از خود بروز می‌دهند که اغلب توسط خانواده، دوستان و حتی متخصصان مراقبت‌های اولیه نادیده گرفته می‌شود [۴]

آمارهای مرکز کنترل و پیشگیری از بیماری‌های ایالات متحده (CDC) نشان می‌دهد که خودکشی در میان گروه سنی ۱۰ تا ۳۴ سال، به دومین علت مرگ و میر تبدیل شده است [۲]؛ رقمی که بیانگر بحرانی خاموش در بستر خانواده‌ها، مدارس و دانشگاه‌هاست. این بازه‌ی سنی که مصادف با شکل‌گیری هویت، فشارهای تحصیلی و شغلی، و آغاز زندگی مستقل است، به دلیل شکنندگی روانی و فقدان مهارت‌های مقابله‌ای، بیش از سایر گروه‌ها در معرض افکار خودکشی قرار دارد [۵]. متأسفانه، جوانان به دلیل ترس از قضاوت همسالان یا برچسب "بیمار روانی"، کمتر از خدمات درمانی رسمی استفاده می‌کنند و در عوض، به فضاهای ناشناس آنلاین یا شبکه‌های اجتماعی پناه می‌برند تا بار روانی خود را به اشتراک بگذارند [۶]. این رفتار، اگرچه از یک سو بیانگر گریز از انگ اجتماعی است، از سوی دیگر فرصتی بی‌نظیر برای رصد دیجیتال علائم هشداردهنده فراهم می‌آورد، چرا که جوانان امروزی بیش از هر گروه سنی دیگری، زندگی خود را در فضای مجازی ثبت می‌کنند[۷]

با گسترش بی‌سابقه‌ی استفاده از شبکه‌های اجتماعی، حجم عظیمی از داده‌های متنی در دسترس محققان قرار گرفته است که می‌تواند منعکس‌کننده‌ی وضعیت روانی کاربران باشد [۸]. پژوهش‌های اخیر در حوزه‌ی روان‌شناسی زبان‌شناختی نشان داده که الگوهای زبانی مانند استفاده‌ی مکرر از ضمایر اول‌شخص مفرد، واژگان مرتبط با تنهایی، ناامیدی یا مرگ، و حتی تغییر در لحن نوشتار، می‌تواند با دقت قابل‌توجهی پیش‌بینی‌کننده‌ی افکار خودکشی باشد [۹]. به همین دلیل، روش‌های یادگیری ماشین و پردازش زبان طبیعی به ابزاری قدرتمند برای غربالگری غیرتهاجمی و بلادرنگ تبدیل شده‌اند [۱۰]. با این حال، آنچه این روش‌ها را با چالش اساسی مواجه می‌کند، نبود داده‌های استاندارد و برچسب‌گذاری‌شده‌ی بالینی است؛ زیرا داده‌های سلامت روان، ذاتاً ناهمگون، زمینه‌مند و وابسته به فرهنگ و زبان هستند و به‌سادگی قابل جمع‌آوری در مقیاس وسیع نمی‌باشند.

مهم‌ترین مانع در مسیر توسعه‌ی ابزارهای هوش‌مصنوعی برای تشخیص خودکشی، چالش‌های اخلاقی و حریم خصوصی است [۴]. اطلاعات مربوط به سلامت روان، در زمره‌ی حساس‌ترین داده‌های شخصی محسوب می‌شوند و افشای آنها می‌تواند به انگ اجتماعی، تبعیض شغلی، محرومیت از بیمه و حتی آسیب‌های روانی جبران‌ناپذیری منجر شود. قوانینی چون GDPR در اروپا و HIPAA

در آمریکا، دسترسی به این داده‌ها را با محدودیت‌های شدید مواجه ساخته‌اند و هرگونه اشتراک‌گذاری نیازمند رضایت آگاهانه‌ی پیچیده‌ای است که در عمل، بسیاری از پژوهش‌ها را با بن‌بست روبه‌رو می‌کند. از سوی دیگر، محققان با دوراهی اساسی روبرو هستند: از یک سو، برای ساخت مدل‌های دقیق یادگیری عمیق به داده‌ی انبوه و متنوع نیاز دارند و از سوی دیگر، جمع‌آوری این داده‌ها بدون نقض حریم خصوصی تقریباً غیرممکن است. این معضل، به ویژه در کشورهای درحال‌توسعه که سیستم‌های ثبت داده‌ی سلامت روان ضعیف‌تری دارند و چارچوب‌های قانونی شفافی برای داده‌های سلامت وجود ندارد، بسیار حادتر می‌شود.

در این میان، یادگیری مشارکتی که نخستین بار توسط تیم گوگل در سال ۲۰۱۶ معرفی شد، به عنوان یک پارادایم انقلابی در یادگیری ماشین، راهگشای بسیاری از این محدودیت‌ها شده است. برخلاف روش‌های سنتی که داده‌ها را در یک سرور مرکزی جمع‌آوری می‌کنند، در یادگیری مشارکتی، الگوریتم‌ها به صورت محلی بر روی دستگاه‌های کاربران (مانند گوشی‌های هوشمند) یا سرورهای بیمارستان‌ها آموزش می‌بینند و تنها پارامترهای مدل (وزن‌های عصبی) به سرور مرکزی ارسال می‌شوند و خود داده‌های خام هرگز دستگاه را ترک نمی‌کنند. این رویکرد، نه تنها حریم خصوصی افراد را به طور بنیادین حفظ می‌کند، بلکه امکان بهره‌مندی از داده‌های توزیع‌شده در مراکز متعدد را بدون نیاز به اشتراک‌گذاری فیزیکی آنها فراهم می‌آورد. به عبارت فنی‌تر، می‌توان از دانش نهفته در متن‌های منتشرشده در شبکه‌های اجتماعی یا یادداشت‌های درمانی، بدون اینکه حتی یک بار محتوای آنها از دستگاه کاربر خارج شود، برای تشخیص خطر خودکشی استفاده کرد و این دقیقاً همان نقطه‌ی تلاقی اخلاق و فناوری است.

با این حال، خود یادگیری مشارکتی نیز در برابر حملات پیشرفته‌ی مبتنی بر استنباط و بازسازی داده آسیب‌پذیر است و ممکن است اطلاعات حساس از روی پارامترهای مدل یا گرادیان‌های به‌اشتراک‌گذاشته‌شده بازسازی گردد. به همین دلیل، پژوهش حاضر بر آن است تا با تلفیق یادگیری مشارکتی با روش‌های قدرتمند رمزنگاری نظیر رمزگذاری هم‌ریخت که امکان انجام محاسبات بر روی داده‌های رمزگذاری‌شده را فراهم می‌کند، و اثبات‌های دانش صفر که صحت محاسبات را بدون افشای ورودی‌ها تضمین می‌نمایند، سطح امنیت و حریم خصوصی را به میزان چشمگیری افزایش دهد. این ترکیب، تضمین می‌نماید که حتی سرور مرکزی و مهاجمان فرضی نیز به محتوای داده‌ها دسترسی نخواهند داشت و در عین حال، دقت مدل در تشخیص افکار خودکشی کاهش نخواهد یافت [۲۲]. بدین ترتیب، گامی اساسی در جهت تحقق "سلامت روان دیجیتال امن" برداشته می‌شود؛ جایی که نه تنها دقت تشخیص افزایش می‌یابد، بلکه اعتماد کاربران به سیستم‌های هوشمند جلب شده، انگ اجتماعی مرتبط با درمان کاهش یافته و موانع اخلاقی فراروی تحقیقات آینده در این حوزه‌ی حساس برطرف می‌گردد.

انگیزه‌ی اصلی این پژوهش، ریشه در دو نیاز حیاتی دارد: نخست، نیاز به ابزارهای دقیق و غیرتهاجمی برای غربالگری خطر خودکشی که بتوانند در بسترهای دیجیتال و با حجم عظیم داده‌های متنی عمل کنند؛ و دوم، نیاز به چارچوبی که حریم خصوصی و امنیت داده‌های روان‌شناختی را به عنوان یک پیش‌شرط بنیادین، نه یک افزونه، در نظر بگیرد. در واقع، این پژوهش در پاسخ به این سوال اساسی شکل گرفته است که «چگونه می‌توان از قدرت پردازش زبان طبیعی و یادگیری ماشین برای تشخیص زودهنگام خودکشی بهره برد، بدون آنکه حریم خصوصی، امنیت و اعتماد کاربران قربانی دقت بالاتر شود؟»

هدف نهایی این پژوهش، فراتر از ارائه‌ی یک مدل با دقت بالا، طراحی و پیاده‌سازی یک چارچوب جامع و امن است که شامل سه مؤلفه‌ی اصلی می‌باشد:

۱ .یک خط‌لوله‌ی کارآمد برای پیش‌پردازش و تحلیل متون چندزبانه (فارسی، انگلیسی، عبری) و استخراج ویژگی‌های معنادار از آنها.

۲ .یک مدل یادگیری ماشین بهینه‌شده و مقیاس‌پذیر برای طبقه‌بندی متون خطرناک، که در یک معماری یادگیری مشارکتی قابلیت پیاده‌سازی داشته باشد.

۳ .یک پروتکل رمزنگاری نوین برای تبادل امن داده‌ها و تجمیع محرمانه و احرازهویت‌شده‌ی نتایج، که از حملات مختلف در محیط‌های توزیع‌شده مصون باشد.

پژوهش حاضر در پی پاسخگویی به پرسش‌های اساسی زیر است:

- پرسش اول (دقت و کارایی) :الگوریتم‌های یادگیری ماشین مبتنی بر یادگیری گروهی نظیر XGBoost و Random Forest با چه سطحی از دقت، حساسیت و ویژگی‌بودن می‌توانند متون مرتبط با افکار خودکشی را در میان حجم عظیمی از داده‌های متنی تشخیص دهند و کدام یک از این الگوریتم‌ها، با توجه به ماهیت مسئله، عملکرد برتری ارائه می‌دهد؟
- پرسش دوم (امنیت و محرمانگی) :چگونه می‌توان با تلفیق رمزگذاری هم‌ریخت (به‌ویژه طرح‌های جمعی مانند Benaloh و Paillier) با یادگیری مشارکتی، یک پروتکل کارآمد و امن برای تجمیع اطلاعات حساس کلاینت‌ها طراحی کرد که ضمن حفظ محرمانگی داده‌های فردی، از تمامیت و اصالت داده‌های ارسالی نیز اطمینان حاصل نماید و در برابر حملاتی نظیر بازپخش، جعل هویت و دستکاری داده، مقاوم باشد؟
- پرسش سوم (کارایی و مقیاس‌پذیری) :معماری ترکیبی پیشنهادی (شامل آموزش غیرمتمرکز مدل و پروتکل رمزنگاری) تا چه اندازه از کارایی و مقیاس‌پذیری برخوردار است و چگونه می‌توان با تنظیم پارامترهایی مانند اندازه‌ی کلید رمزنگاری و تعداد کلاینت‌ها، به تعادل مطلوبی میان سطح امنیت و زمان پاسخ‌دهی سیستم دست یافت؟

بر اساس پیشینه و مبانی نظری، فرضیه‌های اصلی این پژوهش به شرح زیر مطرح می‌شوند:

- فرضیه اول :الگوریتم XGBoost به دلیل ساختار مبتنی بر تقویت گرادیانی و توانایی بالای آن در مدل‌سازی روابط غیرخطی و پیچیده بین ویژگی‌های متنی، عملکرد طبقه‌بندی (به ویژه از نظر Recall و F۱-Score برای کلاس هدف) بهتری نسبت به الگوریتم‌های سنتی‌تر مانند جنگل تصادفی، درخت تصمیم و بیز ساده ارائه می‌دهد.
- فرضیه دوم :پروتکل پیشنهادی SBHE-Benaloh ، با ترکیب رمزگذاری هم‌ریخت Benaloh و امضای دیجیتال Ed۲۵۵۱۹، می‌تواند به طور همزمان نیازهای متضاد محرمانگی، احراز هویت، تمامیت و مقاومت در برابر بازپخش را بدون تخریب خاصیت هم‌ریختی یا تحمیل سربار محاسباتی غیرقابل‌قبول، تأمین کند.

- فرضیه سوم :با انتخاب بهینه‌ی پارامترهای امنیتی (مانند اندازه‌ی کلید رمزنگاری و پارامترهای طرح شامیر)، می‌توان به تعادل مناسبی میان امنیت و کارایی دست یافت، به‌گونه‌ای که سیستم حتی با افزایش تعداد کلاینت‌ها تا چند صد عدد، زمان پاسخ‌دهی مناسبی (زیر چند ثانیه) داشته باشد و برای کاربردهای نیمه‌بلادرنگ قابل استفاده باشد.

روش‌شناسی این پژوهش از ترکیبی از رویکردهای کمی و تجربی، با تأکید بر طراحی سیستم و ارزیابی عملکرد، تشکیل شده است. این پژوهش در چهار مرحله‌ی اصلی انجام شده است:

مرحله‌ی اول: پیاده‌سازی خط‌لوله‌ی پردازش زبان طبیعی

در این مرحله، یک خط‌لوله‌ی چندلایه و پیکربندی‌پذیر برای پاک‌سازی و نرمال‌سازی متون خام طراحی شد که شامل گام‌هایی نظیر حذف نویزهای متنی (آدرس‌ها، ایموجی‌ها، اعداد)، نرمال‌سازی کاراکترهای فارسی، اصلاح فاصله‌گذاری و توکن‌سازی بر اساس فضای سفید است. برای تبدیل متن به نمایش عددی، از مدل Word۲Vec با معماری Skip-Gram و ابعاد ۱۰۰ استفاده شد که بر روی پیکره‌ی پژوهشی آموزش داده شد. این انتخاب، تعادلی میان قدرت نمایش معنایی و هزینه‌ی محاسباتی برقرار می‌کند.

مرحله‌ی دوم: آموزش و ارزیابی مدل‌های یادگیری ماشین

در این مرحله، چهار الگوریتم اصلی یادگیری ماشین شامل XGBoost ، Random Forest، Decision Treeو Naive Bayes(در سه توزیع مختلف) بر روی یک دیتاست متوازن (۴۶۴,۱۴۸ ردیف) آموزش داده شدند. با به‌کارگیری تکنیک‌های اعتبارسنجی متقابل و بهینه‌سازی فراپارامترها، عملکرد مدل‌ها بر اساس معیارهایAccuracy ، Precision، Recall، F۱-score و AUC-ROC مقایسه گردید. برای مواجهه با چالش داده‌های نامتوازن، تنظیم آستانه‌ی تصمیم‌گیری نیز مورد بررسی قرار گرفت.

مرحله‌ی سوم: طراحی و پیاده‌سازی لایه‌ی امنیت انتقال داده

برای تأمین امنیت در معماری یادگیری مشارکتی، یک پروتکل دو لایه طراحی شد. لایه‌ی اول، امنیت انتقال متن ورودی از سرور به کلاینت‌ها را با استفاده از AES-۲۵۶-GCM و طرح تسهیم راز شامیر تضمین می‌کند. لایه‌ی دوم، پروتکل نوآورانه‌ی SBHE-Benaloh است که برای تجمیع امن و احرازهویت‌شده‌ی خروجی‌های کلاینت‌ها طراحی شده است.

مرحله‌ی چهارم: ارزیابی عملکرد پروتکل امنیتی

پروتکل SBHE-Benaloh با سه اندازه‌ی کلید مختلف (۲۵۶، ۵۱۲ و ۱۰۲۴ بیت) و در سناریوهایی با تعداد کلاینت‌های متفاوت (۱۰۰، ۲۰۰، ۳۰۰) پیاده‌سازی و ارزیابی شد. معیارهای ارزیابی شامل زمان‌های تفکیکیSetup ، Encryption، Aggregationو Decryption بوده و تأثیر تغییر پارامترها بر کارایی کلی سیستم مورد بررسی قرار گرفت.

نوآوری‌های این پژوهش را می‌توان در چند سطح طبقه‌بندی کرد:

- نوآوری در سطح معماری :ارائه‌ی یک چارچوب ترکیبی و جامع که برای اولین بار سه حوزه‌ی پردازش زبان طبیعی، یادگیری مشارکتی و رمزگذاری هم‌ریخت را برای حل یک مسئله‌ی حساس سلامت‌محور (پیش‌بینی خودکشی) یکپارچه می‌سازد. این معماری، به جای تمرکز بر یک مؤلفه، مسئله را به صورت سیستمی و از منظر چرخه‌ی کامل تبادل داده (از ورودی کاربر تا خروجی نهایی) حل می‌کند.
- نوآوری در سطح پروتکل امنیتی :(SBHE-Benaloh) طراحی و پیاده‌سازی یک پروتکل جدید با نام-SBHE Benalohکه با ترکیب هوشمندانه‌ی رمزگذاری هم‌ریخت Benaloh و امضای دیجیتالEd۲۵۵۱۹ ، برای اولین بار امکان تجمیع امن و احرازهویت‌شده‌ی میانگین وزنی را در یک محیط توزیع‌شده فراهم می‌آورد. تفکیک کامل لایه‌های رمزنگاری و احراز هویت در این پروتکل، یک نوآوری مهم محسوب می‌شود که از تخریب خاصیت هم‌ریختی جلوگیری می‌کند.
- نوآوری در حوزه‌ی ابزارسازی زبان فارسی :در مسیر پیاده‌سازی این پژوهش، به دلیل کمبود ابزارهای استاندارد در زبان فارسی، بسته‌ی واژگان توقف‌پذیر "دنا (DENA) "توسعه و به صورت رایگان و از طریق یک API در اختیار جامعه‌ی پژوهشی قرار گرفته است. این بسته که شامل فهرستی جامع از stopwords فارسی است، می‌تواند به عنوان یک زیرساخت برای پروژه‌های آتی NLP در زبان فارسی مورد استفاده قرار گیرد.
- نوآوری در حوزه‌ی پیاده‌سازی و ارزیابی عملی :در این پژوهش، علاوه بر تحلیل‌های نظری و شبیه‌سازی، تمامی مؤلفه‌های سیستم به صورت عملی پیاده‌سازی و با استفاده از معیارهای کمی دقیق ارزیابی شده‌اند. نتایج این ارزیابی‌ها در قالب جداول و نمودارهای تفسیری ارائه شده است که می‌تواند راهنمای عملی برای انتخاب پارامترهای بهینه در کاربردهای مشابه باشد.

قلمروی این پژوهش از چند منظر قابل تعریف است:

- قلمروی موضوعی :این پژوهش بر روی مسئله‌ی پیش‌بینی خطر خودکشی از طریق تحلیل متون متمرکز است و سایر جنبه‌های سلامت روان را پوشش نمی‌دهد. همچنین، معماری امنیتی طراحی‌شده صرفاً برای تجمیع میانگین وزنی در یک ساختار مشارکتی با یک سرور مرکزی معتبر تعریف شده است.
- قلمروی داده‌ای :پژوهش بر روی یک دیتاست برچسب‌گذاری‌شده‌ی غیربالینی که ترکیبی از متون چندزبانه است، انجام شده است. مدل‌ها و پروتکل برای داده‌های متنی با حداکثر چهار رقم اعشار طراحی شده و داده‌های ساختاریافته یا غیرمتنی را شامل نمی‌شود.

مهم‌ترین محدودیت‌های این پژوهش عبارتند از:

۱ .وابستگی به فرض وجود کانال امن اولیه برای ثبت کلیدها :پروتکل SBHE-Benaloh فرض می‌کند که فرآیند ثبت اولیه‌ی کلیدهای عمومی کلاینت‌ها در سرور، از طریق یک کانال امن و قابل اعتماد انجام شده است.

۲. محدودیت فضای پیام در رمزگذاری Benaloh: از آنجا که محاسبات بر روی فضای متناهی انجام می‌شود، مجموع وزن‌دار داده‌های کلاینت‌ها نباید از مقدار r فراتر رود. این محدودیت، تعداد کلاینت‌ها یا وزن‌های قابل قبول در هر دور را محدود می‌سازد. $\mathbb{Z}_r$

۳ .عدم قابلیت تجمیع امضاها :برخلاف متن‌های رمز Benaloh که قابلیت تجمیع دارند، امضاهای Ed۲۵۵۱۹ به صورت جداگانه تأیید می‌شوند که این می‌تواند در سیستم‌های با تعداد بسیار زیاد کلاینت، یک گلوگاه محاسباتی باشد.

۴ .وابستگی به مدل تهدید فرضی :ارزیابی امنیتی بر اساس مدل تهدید تعریف‌شده در پژوهش انجام شده است و برای کاربردهای عملی با سناریوهای تهدید پیچیده‌تر، نیاز به تحلیل امنیتی عمیق‌تر است.

این پایان‌نامه در چهار فصل اصلی تنظیم شده است. در فصل اول، با عنوان "طرح موضوع و بررسی پیشینه پژوهش"، ضمن تبیین ضرورت انجام پژوهش و بیان مسئله، مروری جامع بر سه حوزه‌ی مرتبط با پژوهش (تشخیص خودکشی با NLP و ML، یادگیری مشارکتی و رمزگذاری هم‌ریخت) ارائه شده و شکاف پژوهشی که این تحقیق به آن می‌پردازد، مشخص می‌گردد. فصل دوم، با عنوان "واژه‌ها را بشنو؛ بنیان‌های نظری پردازش زبان طبیعی در جستجوی افکار خودکشی"، به بررسی مبانی نظری و پیاده‌سازی عملی خط‌لوله‌ی پردازش زبان طبیعی، از پاک‌سازی داده تا بردارسازی و آموزش مدل‌ها می‌پردازد و نتایج حاصل از مقایسه‌ی الگوریتم‌های مختلف یادگیری ماشین را ارائه می‌دهد. فصل سوم، با عنوان "سپری از اعداد؛ طراحی و پیاده‌سازی بستر امن تبادل داده با بهره‌گیری از رمزگذاری هم‌ریخت"، به مبانی ریاضی و پیاده‌سازی لایه‌های امنیتی پروتکل، از جمله رمزگذاری AES-GCM، طرح اشتراک‌گذاری شامیر و بررسی تطبیقی پنج طرح رمزگذاری هم‌ریخت Benaloh، Paillier، ElGamal، Damgård-Jurik و RSA می‌پردازد. در فصل چهارم، با عنوان "طراحی و پیاده‌سازی پروتکل تجمیع میانگین وزنیِ محرمانه و احرازهویت‌شده (SBHE-Benaloh)"، پروتکل اصلی پیشنهادی به تفصیل معرفی، تحلیل امنیتی و ارزیابی عملکرد شده و نتایج

حاصل از پیاده‌سازی در سناریوهای مختلف ارائه می‌گردد. در پایان، پیوست‌های مربوط به پکیج واژگان توقف "دنا" (پیوست ۲-الف) و مبانی ریاضی مسئله لگاریتم گسسته، پروتکل Diffie-Hellman و مسئله باقیمانده‌های مرکب (پیوست‌های ۳-الف، ۳-ب و ۳-ج) به همراه واژه‌نامه و فهرست منابع آورده شده است.

فصل اول

در جستجوی نشانه‌ها؛ طرح موضوع و بررسی پیشینه پژوهش

" جایی که سخن هست، امید به نجات نیز هست؛ اگر بتوانیم کلمات را بشنویم، می‌توانیم به کمک بیاییم"

سیسرو، فیلسوف رومی

۱-۱ ضرورت انجام پژوهش

خودکشی نه تنها یک تراژدی فردی، بلکه بحرانی عمیق در نظام سلامت جهانی محسوب می‌شود که سالانه حدود ۷۰۰ هزار قربانی می‌گیرد [۱] و در زمره‌ی ده علت اصلی مرگ در تمامی گروه‌های سنی قرار دارد. با این حال، آنچه این پدیده را از سایر علل مرگ متمایز می‌کند، ماهیت قابل‌پیش‌گیری آن است؛ به‌گونه‌ای که سازمان جهانی بهداشت بر لزوم تدوین برنامه‌های ملی برای کاهش یک‌سوم موارد خودکشی تا سال ۲۰۳۰ تأکید کرده است [۱]. برخلاف بسیاری از بیماری‌های مزمن، خودکشی اغلب نتیجه‌ی تعامل پیچیده‌ای از عوامل ژنتیکی، روان‌شناختی، اجتماعی و محیطی است که در صورت تشخیص به‌موقع، قابل مداخله است[۳]. اما چالش اساسی در این میان، نه کمبود روش‌های درمانی، که نبود نظام‌های کارآمد برای غربالگری زودهنگام و کاهش انگ اجتماعی پیرامون بیماری‌های روانی است. به‌گونه‌ای که بسیاری از قربانیان، ماه‌ها پیش از اقدام، نشانه‌های هشداردهنده‌ای از خود بروز می‌دهند که اغلب توسط خانواده، دوستان و حتی متخصصان مراقبت‌های اولیه نادیده گرفته می‌شود.[۴]

آمارهای مرکز کنترل و پیشگیری از بیماری‌های ایالات متحده (CDC) نشان می‌دهد که خودکشی در میان گروه سنی ۱۰ تا ۳۴ سال، به دومین علت مرگ و میر تبدیل شده است [۲]؛ رقمی که بیانگر بحرانی خاموش در بستر خانواده‌ها، مدارس و دانشگاه‌هاست. این بازه‌ی سنی که مصادف با شکل‌گیری هویت، فشارهای تحصیلی و شغلی، و آغاز زندگی مستقل است، به دلیل شکنندگی روانی و فقدان مهارت‌های مقابله‌ای، بیش از سایر گروه‌ها در معرض افکار خودکشی قرار دارد [۵]. متأسفانه، جوانان به دلیل ترس از قضاوت همسالان یا برچسب "بیمار روانی"، کمتر از خدمات درمانی رسمی استفاده می‌کنند و در عوض، به فضاهای ناشناس آنلاین یا شبکه‌های اجتماعی پناه می‌برند تا بار روانی خود را به اشتراک بگذارند [۶]. این رفتار، اگرچه از یک سو بیانگر گریز از انگ اجتماعی است، از سوی دیگر فرصتی بی‌نظیر برای رصد دیجیتال علائم هشداردهنده فراهم می‌آورد، چرا که جوانان امروزی بیش از هر گروه سنی دیگری، زندگی خود را در فضای مجازی ثبت می‌کنند.[۷]

با گسترش بی‌سابقه‌ی استفاده از شبکه‌های اجتماعی، حجم عظیمی از داده‌های متنی در دسترس محققان قرار گرفته است که می‌تواند منعکس‌کننده‌ی وضعیت روانی کاربران باشد [۸]. پژوهش‌های اخیر در حوزه‌ی روان‌شناسی زبان‌شناختی نشان داده که الگوهای زبانی مانند استفاده‌ی مکرر از ضمایر اول‌شخص مفرد، واژگان مرتبط با تنهایی، ناامیدی یا مرگ، و حتی تغییر در لحن نوشتار، می‌تواند با دقت قابل‌توجهی پیش‌بینی‌کننده‌ی افکار خودکشی باشد [۹]. به همین دلیل، روش‌های یادگیری ماشین و پردازش زبان طبیعی به ابزاری قدرتمند برای غربالگری غیرتهاجمی و بلادرنگ تبدیل شده‌اند [۱۰]. با این حال، آنچه این روش‌ها را با چالش اساسی مواجه می‌کند، نبود داده‌های استاندارد و برچسب‌گذاری‌شده‌ی بالینی است؛ زیرا داده‌های سلامت روان، ذاتاً ناهمگون، زمینه‌مند و وابسته به فرهنگ و زبان هستند و به‌سادگی قابل جمع‌آوری در مقیاس وسیع نمی‌باشند.

مهم‌ترین مانع در مسیر توسعه‌ی ابزارهای هوش‌مصنوعی برای تشخیص خودکشی، چالش‌های اخلاقی و حریم خصوصی است [۴]. اطلاعات مربوط به سلامت روان، در زمره‌ی حساس‌ترین داده‌های شخصی محسوب می‌شوند و افشای آنها می‌تواند به انگ اجتماعی،

تبعیض شغلی، محرومیت از بیمه و حتی آسیب‌های روانی جبران‌ناپذیری منجر شود. قوانینی چون GDPR در اروپا و HIPAA در آمریکا، دسترسی به این داده‌ها را با محدودیت‌های شدید مواجه ساخته‌اند و هرگونه اشتراک‌گذاری نیازمند رضایت آگاهانه‌ی پیچیده‌ای است که در عمل، بسیاری از پژوهش‌ها را با بن‌بست روبه‌رو می‌کند. از سوی دیگر، محققان با دوراهی اساسی روبرو هستند: از یک سو، برای ساخت مدل‌های دقیق یادگیری عمیق به داده‌ی انبوه و متنوع نیاز دارند و از سوی دیگر، جمع‌آوری این داده‌ها بدون نقض حریم خصوصی تقریباً غیرممکن است. این معضل، به ویژه در کشورهای درحال‌توسعه که سیستم‌های ثبت داده‌ی سلامت روان ضعیف‌تری دارند و چارچوب‌های قانونی شفافی برای داده‌های سلامت وجود ندارد، بسیار حادتر می‌شود.

در این میان، یادگیری مشارکتی[۱] که نخستین بار توسط تیم گوگل در سال ۲۰۱۶ معرفی شد، به عنوان یک پارادایم انقلابی در یادگیری ماشین، راهگشای بسیاری از این محدودیت‌ها شده است. برخلاف روش‌های سنتی که داده‌ها را در یک سرور مرکزی جمع‌آوری می‌کنند، در یادگیری مشارکتی، الگوریتم‌ها به صورت محلی بر روی دستگاه‌های کاربران (مانند گوشی‌های هوشمند) یا سرورهای بیمارستان‌ها آموزش می‌بینند و تنها پارامترهای مدل (وزن‌های عصبی) به سرور مرکزی ارسال می‌شوند و خود داده‌های خام هرگز دستگاه را ترک نمی‌کنند. این رویکرد، نه تنها حریم خصوصی افراد را به طور بنیادین حفظ می‌کند، بلکه امکان بهره‌مندی از داده‌های توزیع‌شده در مراکز متعدد را بدون نیاز به اشتراک‌گذاری فیزیکی آنها فراهم می‌آورد. به عبارت فنی‌تر، می‌توان از دانش نهفته در متن‌های منتشرشده در شبکه‌های اجتماعی یا یادداشت‌های درمانی، بدون اینکه حتی یک بار محتوای آنها از دستگاه کاربر خارج شود، برای تشخیص خطر خودکشی استفاده کرد و این دقیقاً همان نقطه‌ی تلاقی اخلاق و فناوری است.

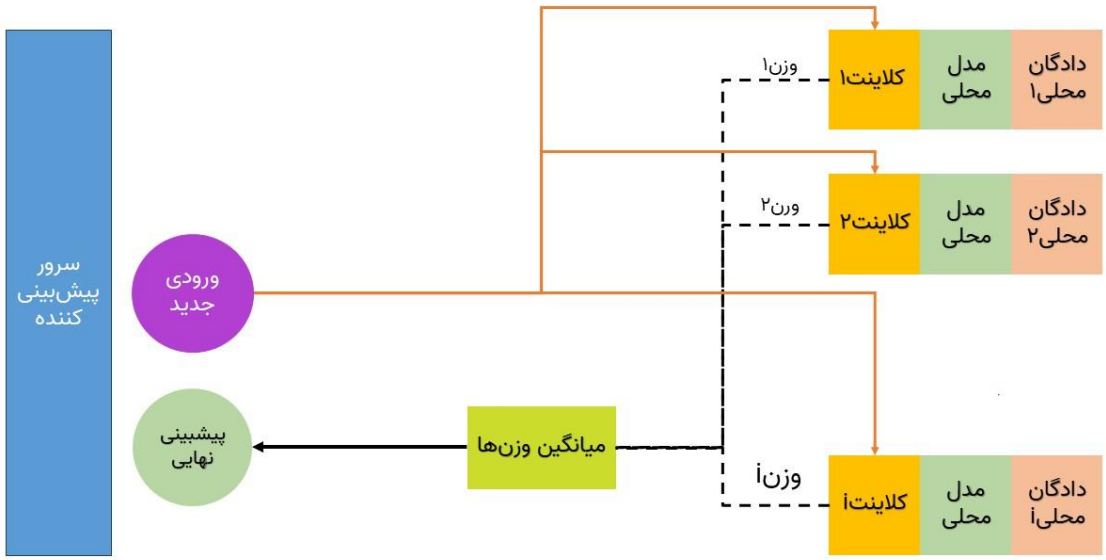
با این حال، خود یادگیری مشارکتی نیز در برابر حملات پیشرفته‌ی مبتنی بر استنباط[۲] و بازسازی داده[۳] آسیب‌پذیر است و ممکن است اطلاعات حساس از روی پارامترهای مدل یا گرادیان‌های به‌اشتراک‌گذاشته‌شده بازسازی گردد. به همین دلیل، پژوهش حاضر بر آن است تا با تلفیق یادگیری مشارکتی با روش‌های قدرتمند رمزنگاری نظیر رمزگذاری هم‌ریخت که امکان انجام محاسبات بر روی داده‌های رمزگذاری‌شده را فراهم می‌کند، و اثبات‌های دانش صفر[۴] که صحت محاسبات را بدون افشای ورودی‌ها تضمین می‌نمایند، سطح امنیت و حریم خصوصی را به میزان چشمگیری افزایش دهد. این ترکیب، تضمین می‌نماید که حتی سرور مرکزی و مهاجمان فرضی نیز به محتوای داده‌ها دسترسی نخواهند داشت و در عین حال، دقت مدل در تشخیص افکار خودکشی کاهش نخواهد یافت [۲۲]. بدین ترتیب، گامی اساسی در جهت تحقق "سلامت روان دیجیتال امن" برداشته می‌شود؛ جایی که نه تنها دقت تشخیص افزایش می‌یابد، بلکه اعتماد کاربران به سیستم‌های هوشمند جلب شده، انگ اجتماعی مرتبط با درمان کاهش یافته و موانع اخلاقی فراروی تحقیقات آینده در این حوزه‌ی حساس برطرف می‌گردد .

---

۱. Federated Learning
۲. Inference Attacks
۳. Data Reconstruction
۴. Zero-Knowledge Proofs

۱-۲ نحوه انجام پژوهش

پژوهش حاضر با هدف طراحی و پیاده‌سازی سامانه‌ای نوین برای پیش‌بینی خطر خودکشی بر اساس تحلیل متون کاربران، از رویکرد یادگیری مشارکتی بهره گرفته است. در این چارچوب، به‌جای تمرکز بر یک پایگاه داده متمرکز، از توزیع داده‌ها میان چندین کلاینت مستقل استفاده می‌شود. هر کلاینت، که در حقیقت نمایانگر یک نهاد یا سازمان دارای داده‌های روان‌شناختی محلی است، مدل یادگیری ماشین خود را بر اساس داده‌های بومی آموزش می‌دهد. این ساختار غیرمتمرکز، ضمن حفظ استقلال داده‌ها، بستری را فراهم می‌آورد که در آن پیش‌بینی‌کننده مرکزی (سرور) بدون دسترسی مستقیم به داده‌های خام، قادر به دریافت برآوردهای احتمالی از هر کلاینت بوده و با ترکیب آن‌ها، به یک پیش‌بینی نهایی دست یابد.



شکل ۱-۱: مدل یادگیری مشارکتی

با این حال، چالش اصلی در چنین معماری توزیع‌شده‌ای، مسئله حفظ حریم خصوصی و امنیت انتقال اطلاعات است. با توجه به حساسیت بالای داده‌های روان‌شناختی و مصاحبه‌های بالینی، هرگونه افشای ناخواسته یا رهگیری اطلاعات می‌تواند پیامدهای جبران‌ناپذیری برای مراجعان به همراه داشته باشد. از این‌رو، در این پژوهش، فرض بر این است که وجود یک کانال امن ارتباطی همواره میسر نیست و بنابراین، تمامی تبادلات داده‌ای میان سرور و کلاینت‌ها باید با استفاده از پروتکل‌های رمزنگاری پیشرفته محافظت شود. این الزام، نه‌تنها جنبه‌ای فنی، بلکه جنبه‌ای اخلاقی و حقوقی نیز دارد و رعایت آن برای کسب اعتبار علمی و عملیاتی سامانه ضروری است

.

در گام نخست از فرایند ارتباطی، ورودی متنی کاربر توسط سرور رمزگذاری شده و به همراه یک امضای دیجیتال معتبر برای تمامی کلاینت‌ها ارسال می‌گردد. این امضا، که با استفاده از کلید خصوصی سرور ایجاد می‌شود، هویت فرستنده را تأیید کرده و از بروز حملات جعل هویت جلوگیری می‌نماید. نکته مهم آن‌که در طراحی این پروتکل، برای کاهش هزینه‌های محاسباتی و افزایش

کارایی، عملیات رمزگذاری و امضادهی به‌صورت هم‌زمان و یکپارچه بر روی داده‌ها اعمال می‌شود؛ به‌گونه‌ای که فرایندهای تفکیک‌شده رمزگذاری و امضازنی، در یک مرحله ترکیبی انجام می‌پذیرند. این رویکرد، ضمن حفظ امنیت، از پیچیدگی‌های اضافی کاسته و زمان پاسخ‌دهی سامانه را به میزان قابل‌توجهی کاهش می‌دهد.

پس از دریافت بسته اطلاعاتی توسط هر کلاینت، ابتدا صحت امضای دیجیتال بررسی می‌شود. در صورت احراز اعتبار، متن با استفاده از کلید متقارن یا نامتقارن توافق‌شده، رمزگشایی شده و در اختیار مدل یادگیری ماشین محلی قرار می‌گیرد. هر کلاینت، با بهره‌گیری از دیتاست بومی خود که شامل نمونه‌هایی از متون روان‌شناختی با برچسب‌های خطر خودکشی است، احتمال خطر را به‌صورت یک عدد بین صفر و یک محاسبه می‌کند. این خروجی، که بیانگر درجه شدت خطر در متن ورودی است، مجدداً توسط کلاینت رمزگذاری شده و برای سرور ارسال می‌شود.

چالش بعدی، نحوه ترکیب خروجی‌های دریافتی از کلاینت‌ها در سمت سرور است. در حالت عادی، سرور مجبور است هر خروجی را به‌طور جداگانه رمزگشایی کند، سپس میانگین وزنی آن‌ها را محاسبه نماید. این فرایند، نه‌تنها زمان‌بر است، بلکه سرور را در معرض دید مستقیم نسبت به مقادیر خام هر کلاینت قرار می‌دهد که خود می‌تواند نقض حریم خصوصی تلقی گردد. برای رفع این نقیصه، در این پژوهش از رمزگذاری هم‌ریخت[۱] استفاده شده است. این نوع رمزنگاری، امکان انجام عملیات جبری (همانند جمع و ضرب) را بر روی داده‌های رمزگذاری‌شده، بدون نیاز به رمزگشایی آن‌ها، مطابق رابطه زیر فراهم می‌آورد. بدین ترتیب، سرور قادر خواهد بود تا عمل میانگین‌گیری وزنی را مستقیماً روی خروجی‌های رمز شده کلاینت‌ها اعمال کند و در نهایت، تنها یک بار نتیجه نهایی را رمزگشایی نماید. این روش، ضمن کاهش چشمگیر هزینه‌های محاسباتی، امنیت داده‌ها را در بالاترین سطح ممکن حفظ کرده و وابستگی به کلیدهای رمزگشایی متعدد را از بین می‌برد.

$$Dec(Enc(m_1) \odot Enc(m_2)) = m_1 \oplus m_2$$

در مجموع، معماری پیشنهادی در این پژوهش، با تلفیق یادگیری مشارکتی و رمزگذاری هم‌ریخت، راهکاری کارآمد، امن و مقیاس‌پذیر برای پیش‌بینی خطر خودکشی فراهم می‌آورد که در عین بهره‌مندی از توان محاسباتی توزیع‌شده، حریم خصوصی کاربران و کلاینت‌ها را به‌صورت کامل تأمین می‌کند. این رویکرد، گامی مؤثر در جهت کاربردهای بالینی هوش مصنوعی در بسترهای غیرمتمرکز و حساس به حریم خصوصی به شمار می‌رود و می‌تواند الگویی برای سیستم‌های مشابه در حوزه‌های سلامت روان باشد.

---

۱. Homomorphic Encryption

۱-۳ پیشینه پژوهش

۱-۳-۱ تشخیص خطر خودکشی با استفاده از پردازش زبان طبیعی و یادگیری ماشین

خودکشی یکی از مهم‌ترین چالش‌های حوزه سلامت عمومی و سلامت روان محسوب می‌شود و شناسایی زودهنگام افرادی که در معرض خطر قرار دارند، از اهمیت بالایی برخوردار است. روش‌های سنتی ارزیابی خطر خودکشی عمدتاً بر مصاحبه‌های بالینی، پرسش‌نامه‌های استاندارد، ارزیابی روان‌شناختی و قضاوت متخصصان متکی هستند. اگرچه این روش‌ها از نظر بالینی ارزشمندند، وابستگی آن‌ها به حضور متخصص، زمان‌بر بودن فرایند ارزیابی و محدودیت دسترسی به اطلاعات رفتاری فرد در خارج از محیط درمانی، موجب شده است پژوهشگران به استفاده از روش‌های محاسباتی و هوش مصنوعی برای شناسایی نشانه‌های خطر خودکشی توجه بیشتری نشان دهند. در این میان، تحلیل خودکار متون و محتوای زبانی افراد به یکی از محورهای مهم پژوهش در زمینه تشخیص افکار خودکشی تبدیل شده است.

در یک مطالعه مروری جامع، روش‌های یادگیری ماشین و یادگیری عمیق برای تشخیص افکار خودکشی را بررسی شده و داشنمندان نشان دادند که داده‌های مورد استفاده در این حوزه از منابع مختلفی مانند پرسش‌نامه‌ها، پرونده‌های سلامت، یادداشت‌های خودکشی و محتوای تولیدشده توسط کاربران در محیط‌های آنلاین تشکیل می‌شود. این پژوهش نشان داد که تحلیل ویژگی‌های زبانی و محتوایی متون می‌تواند اطلاعات ارزشمندی درباره نشانه‌های مرتبط با افکار خودکشی فراهم کند و روش‌های یادگیری ماشین، به‌ویژه در تحلیل محتوای آنلاین، ظرفیت مناسبی برای خودکارسازی بخشی از فرایند شناسایی خطر دارند.[۱۱]

در ادامه این مسیر، هکلر و همکاران یک مرور نظام‌مند از پژوهش‌های انجام‌شده در زمینه شناسایی افکار خودکشی با استفاده از یادگیری ماشین ارائه کردند. آن‌ها پس از بررسی مجموعه گسترده‌ای از مطالعات، نشان دادند که بخش قابل توجهی از پژوهش‌های موجود بر داده‌های شبکه‌های اجتماعی و تحلیل زبان افراد متمرکز بوده‌اند. یافته‌های این مطالعه همچنین حاکی از افزایش استفاده از روش‌های یادگیری عمیق در تحلیل متون و حرکت حوزه از روش‌های مبتنی بر ویژگی‌سازی دستی به سمت روش‌های خودکار استخراج ویژگی است. با وجود این، نویسندگان بر چالش‌هایی نظیر تعمیم‌پذیری مدل‌ها، وابستگی به داده‌های خوداظهاری و ضرورت توسعه مدل‌هایی که بتوانند بدون اتکا به گزارش مستقیم فرد، نشانه‌های خطر را شناسایی کنند، تأکید کرده‌اند[۱۲]

یکی از منابع مهم داده برای این نوع مطالعات، شبکه‌های اجتماعی و انجمن‌های آنلاین است. کاربران در این محیط‌ها ممکن است افکار، هیجانات، مشکلات شخصی و تجربیات روان‌شناختی خود را در قالب متن بیان کنند. به همین دلیل، محتوای تولیدشده در این بسترها می‌تواند به‌عنوان منبعی برای استخراج نشانه‌های زبانی مرتبط با سلامت روان مورد استفاده قرار گیرد. مطالعات انجام‌شده درباره استفاده از Reddit برای تشخیص افکار خودکشی نیز نشان داده‌اند که این محیط به‌طور گسترده در پژوهش‌های مرتبط با تشخیص خودکار افکار خودکشی مورد استفاده قرار گرفته است و پژوهشگران از مراحل مختلفی شامل گردآوری و برچسب‌گذاری داده، پیش‌پردازش متن، استخراج ویژگی، آموزش مدل و ارزیابی برای ساخت سامانه‌های تشخیص خودکار استفاده کرده‌اند.[۱۳]

همچنین Sheng در بررسی خود از کاربرد یادگیری ماشین برای تشخیص افکار خودکشی در شبکه‌های اجتماعی، بر نقش روزافزون پردازش زبان طبیعی در تحلیل محتوای متنی تأکید کرده است. بر اساس این مطالعه، الگوریتم‌های یادگیری ماشین و شبکه‌های عصبی می‌توانند با تحلیل الگوهای زبانی، نشانه‌هایی را که در متن کاربران با افکار یا رفتارهای خودآسیب‌رسان ارتباط دارند شناسایی کنند. این مطالعات زمینه را برای توسعه سامانه‌های هشدار زودهنگام فراهم کرده‌اند؛ با این حال، همزمان با افزایش توانایی مدل‌ها، مسئله حفاظت از داده‌های بسیار حساس مورد استفاده در این سامانه‌ها نیز به یک چالش اساسی تبدیل شده است [۱۴].

در مجموع، پیشینه موجود نشان می‌دهد که استفاده از NLP و یادگیری ماشین برای تشخیص خطر خودکشی از نظر علمی رویکردی تثبیت‌شده و رو به رشد است؛ اما بخش قابل توجهی از این مطالعات در محیط‌هایی انجام شده‌اند که داده‌ها به‌صورت متمرکز در اختیار پژوهشگر یا سرور قرار می‌گیرند. این مسئله در حوزه سلامت روان اهمیت ویژه‌ای دارد، زیرا متن‌های روان‌شناختی، مصاحبه‌های بالینی و محتوای مربوط به افکار خودکشی می‌توانند حاوی اطلاعات هویتی، پزشکی و عاطفی بسیار حساسی باشند. بنابراین، افزایش دقت تشخیص بدون توجه همزمان به مسئله مالکیت و محرمانگی داده‌ها نمی‌تواند راهکاری کامل برای استفاده عملی از این فناوری در محیط‌های واقعی محسوب شود.

۱-۳-۲ یادگیری مشارکتی و یادگیری غیرمتمرکز در حوزه سلامت

یکی از مهم‌ترین راهکارهای پیشنهادی برای کاهش نیاز به انتقال داده‌های خام، یادگیری مشارکتی است. ایده اصلی یادگیری فدرال آن است که داده‌ها در محل تولید خود باقی بمانند و فرایند یادگیری به جای انتقال داده‌های خام به یک مخزن مرکزی، با استفاده از مدل‌ها یا به‌روزرسانی‌های محلی انجام شود. McMahan و همکاران این مفهوم را به‌صورت نظام‌مند معرفی کردند و نشان دادند که می‌توان مدل مشترکی را از طریق آموزش محلی روی دستگاه‌ها و سپس تجمیع به‌روزرسانی‌های محلی ایجاد کرد، بدون آنکه داده‌های آموزشی خام به سرور مرکزی منتقل شوند. این پژوهش یکی از مبانی اصلی توسعه یادگیری فدرال مدرن محسوب می‌شود و نشان داد که این رویکرد می‌تواند در شرایطی با داده‌های نامتوازن و غیرهم‌توزیع نیز مورد استفاده قرار گیرد [۱۵].

اهمیت این ایده در حوزه سلامت بیش از بسیاری از حوزه‌های دیگر است؛ زیرا داده‌های پزشکی معمولاً در سازمان‌های مختلف، بیمارستان‌ها، مراکز درمانی و مؤسسات پژوهشی نگهداری می‌شوند و به دلایل حقوقی، اخلاقی و سازمانی امکان انتقال آزادانه آن‌ها وجود ندارد. ریک و همکاران در بررسی کاربرد یادگیری فدرال در سلامت دیجیتال بیان کردند که داده‌های پزشکی در بسیاری از موارد در «سیلوهای داده» جداگانه قرار دارند و نگرانی‌های مربوط به حریم خصوصی و مالکیت داده، مانع از استفاده کامل از این منابع در آموزش مدل‌های یادگیری ماشین می‌شود. از دیدگاه این پژوهشگران، یادگیری فدرال می‌تواند راهکاری برای ایجاد همکاری میان مؤسسات مختلف بدون نیاز به متمرکزسازی داده‌های خام فراهم کند.[۱۶]

کایروز و همکاران نیز در یک مطالعه جامع، ابعاد مختلف یادگیری فدرال، از جمله روش‌های آموزش، ارتباطات، ناهمگونی داده‌ها، حریم خصوصی، امنیت و مقیاس‌پذیری را بررسی کردند. از دیدگاه آنان، یادگیری فدرال صرفاً یک روش توزیع‌شده برای آموزش مدل نیست، بلکه چارچوبی است که می‌تواند اصل حداقل‌سازی جمع‌آوری داده را تقویت کند؛ با این حال، باقی ماندن داده‌ها در کلاینت به‌تنهایی به معنای تأمین کامل حریم خصوصی نیست. به بیان دیگر، حتی اگر داده خام هرگز سرور را ترک نکند، اطلاعات موجود در به‌روزرسانی‌های مدل یا خروجی‌های ارسالی نیز ممکن است در معرض حملات مختلف قرار گیرد[۱۷].

این موضوع در کاربردهای سلامت روان اهمیت مضاعفی دارد. خلیل و همکاران کاربرد یادگیری فدرال را برای تشخیص افسردگی با استفاده از مدل‌های زبانی چندزبانه و پست‌های شبکه‌های اجتماعی بررسی کردند. این مطالعه نشان داد که می‌توان مدل‌های پردازش زبان طبیعی را در یک ساختار فدرال به کار گرفت و در عین حفظ توزیع داده‌ها، به عملکرد قابل قبول دست یافت. نویسندگان همچنین نشان دادند که یادگیری فدرال می‌تواند برای داده‌های مستقل و نیز داده‌هایی با ساختار غیرهم‌توزیع مورد استفاده قرار گیرد و از این طریق میان نیاز به آموزش مدل‌های قدرتمند و حساسیت داده‌های سلامت روان تعادل برقرار کند[۱۸]

با وجود این مزایا، یادگیری فدرال به‌تنهایی نمی‌تواند تمامی تهدیدهای امنیتی را برطرف کند. سرور فدرال همچنان ممکن است به به‌روزرسانی‌ها یا خروجی‌های ارسالی کلاینت‌ها دسترسی داشته باشد و در شرایط خاص، اطلاعات حساس از روی همین مقادیر قابل استنتاج باشد. همچنین حملاتی مانند استنتاج عضویت، وارون‌سازی مدل و استخراج اطلاعات از به‌روزرسانی‌ها نشان می‌دهند که «عدم انتقال داده خام» با «حریم خصوصی مطلق» یکسان نیست. بنابراین، ادبیات جدید حوزه یادگیری فدرال به سمت ترکیب این چارچوب با تکنیک‌های تکمیلی حفاظت از حریم خصوصی، از جمله تجمیع امن، حریم خصوصی تفاضلی و رمزگذاری هم‌ریخت، حرکت کرده است.

۱-۳-۳ رمزگذاری هم‌ریخت و یادگیری ماشین حفظ‌کننده حریم خصوصی

رمزگذاری هم‌ریخت یکی از مهم‌ترین فناوری‌های رمزنگاری برای محاسبات حفظ‌کننده حریم خصوصی است. ویژگی اصلی این خانواده از الگوریتم‌ها آن است که امکان انجام برخی عملیات محاسباتی بر روی متن رمز را فراهم می‌کند، به‌گونه‌ای که نتیجه پس از رمزگشایی با نتیجه عملیات متناظر بر داده‌های اصلی سازگار باشد Paillier .با معرفی یک سامانه رمزنگاری احتمالی مبتنی بر مسئله باقی‌مانده کامپوزیت[۱] ، یکی از طرح‌های مهم رمزنگاری با خاصیت هم‌ریخت جمعی را ارائه کرد. ویژگی جمع‌پذیری این طرح امکان محاسبه مجموع مقادیر رمزگذاری‌شده را بدون افشای مقادیر اصلی فراهم می‌کند و از همین رو، برای سناریوهایی که هدف، تجمیع امن مقادیر عددی کلاینت‌ها است، اهمیت ویژه‌ای دارد.[۱۹]

---

۱. Composite Residuosity

تحول مهم‌تر در این حوزه با معرفی رمزگذاری کاملاً هم‌ریخت[1] توسط Gentry ایجاد شد. ایده اصلی در رمزگذاری کاملاً هم‌ریخت این است که محاسبات پیچیده‌تری را بتوان بدون رمزگشایی داده انجام داد. این قابلیت چشم‌انداز جدیدی برای پردازش امن داده‌های حساس ایجاد کرد و بعدها در حوزه‌هایی مانند یادگیری ماشین، سلامت و تحلیل داده‌های پزشکی مورد توجه قرار گرفت.[۲۰]

Wood، Najarian و Kahrobaei در یک مطالعه مروری در *ACM Computing Surveys* کاربرد رمزگذاری هم‌ریخت در یادگیری ماشین پزشکی و بیوانفورماتیک را بررسی کردند. آنان نشان دادند که رمزگذاری هم‌ریخت می‌تواند امکان اجرای الگوریتم‌های یادگیری ماشین بر داده‌های رمزگذاری‌شده را فراهم کند و کاربردهایی نظیر طبقه‌بندی داده‌های پزشکی، یادگیری خصوصی و تحلیل داده‌های ژنتیکی را پوشش دهد. این پژوهش همچنین نشان می‌دهد که رمزگذاری هم‌ریخت از نظر مفهومی با نیازهای حوزه سلامت سازگاری بالایی دارد، زیرا در بسیاری از کاربردهای پزشکی لازم است داده بدون آشکارشدن محتوای خام آن مورد پردازش قرار گیرد .[۲۱]

مرور نظام‌مند دیگری که در زمینه کاربرد رمزگذاری هم‌ریخت در صنعت سلامت انجام شده است نیز تأکید می‌کند که تفاوت اساسی این فناوری با رمزگذاری متعارف در قابلیت پردازش مستقیم روی داده رمزگذاری‌شده است. در رمزنگاری معمول، برای انجام محاسبه باید ابتدا داده رمزگشایی شود؛ در حالی که رمزگذاری هم‌ریخت امکان اجرای محاسبات مشخصی را در دامنه رمز فراهم می‌کند و در نتیجه می‌تواند سطح مواجهه داده‌های حساس با محیط محاسباتی را کاهش دهد.[۲۲]

تجمیع امن و ترکیب یادگیری فدرال با رمزنگاری

یکی دیگر از رویکردهای مرتبط با مسئله پژوهش حاضر، مفهوم تجمیع امن[2] است. در این روش، هدف آن است که سرور بتواند مجموع یا تابعی از خروجی‌های کلاینت‌ها را محاسبه کند، بدون آنکه مقدار منفرد هر کلاینت برای سرور آشکار شود . Bonawitz و همکاران یک پروتکل تجمیع امن برای یادگیری ماشین حفظ‌کننده حریم خصوصی ارائه کردند که امکان تجمیع مقادیر تولیدشده توسط کاربران را بدون افشای مقادیر منفرد فراهم می‌کند. اهمیت این رویکرد در یادگیری فدرال آن است که حتی اگر سرور مسئول تجمیع باشد، نباید الزاماً به هر به‌روزرسانی محلی به‌صورت جداگانه دسترسی داشته باشد.[۲۳]

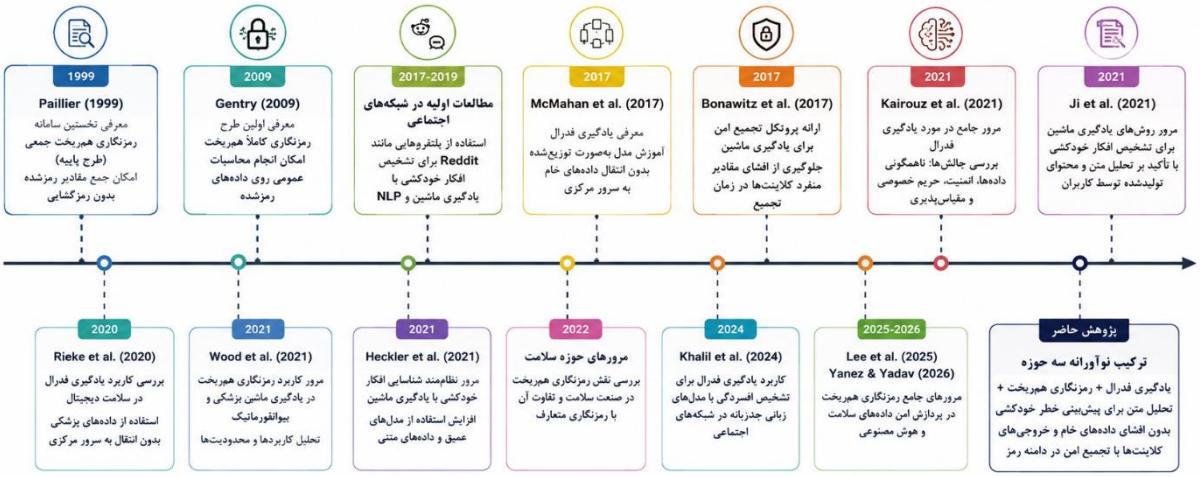
---

۱. Fully Homomorphic Encryption

۲. Secure Aggregation

۱-۳-٤ جمع‌بندی پیشینه و شکاف پژوهشی

بررسی مطالعات پیشین نشان می‌دهد که سه جریان پژوهشی مهم به‌صورت موازی توسعه یافته‌اند. جریان نخست، استفاده از پردازش زبان طبیعی و یادگیری ماشین برای تشخیص خودکار افکار و خطر خودکشی از متن است که نشان داده است ویژگی‌های زبانی می‌توانند برای شناسایی نشانه‌های خطر مورد استفاده قرار گیرند (۱، ۲). جریان دوم، یادگیری فدرال است که با انتقال فرایند یادگیری به محل نگهداری داده، امکان همکاری میان چند منبع داده بدون متمرکزسازی داده‌های خام را فراهم می‌کند.[۱۵,۱۶] جریان سوم نیز شامل تکنیک‌های رمزنگاری و محاسبات حفظ‌کننده حریم خصوصی، به‌ویژه رمزگذاری هم‌ریخت و تجمیع امن، است که تلاش می‌کنند حتی اطلاعات مبادله‌شده میان کلاینت و سرور را نیز در برابر افشای غیرمجاز محافظت کنند[۱۹, ۲۱]



شکل ۱-۲ پیشینه پژوهش

با وجود پیشرفت قابل توجه در هر یک از این حوزه‌ها، ترکیب همزمان آن‌ها برای مسئله پیش‌بینی خطر خودکشی بر مبنای متن، به‌ویژه در معماری‌ای که داده‌ها در اختیار چند کلاینت مستقل قرار دارند و سرور نباید به مقادیر خام خروجی کلاینت‌ها دسترسی داشته باشد، همچنان زمینه مناسبی برای پژوهش محسوب می‌شود. بخش زیادی از مطالعات تشخیص خودکشی بر افزایش دقت مدل‌های یادگیری ماشین و یادگیری عمیق تمرکز داشته‌اند، در حالی که مطالعات یادگیری فدرال در سلامت بیشتر بر تشخیص بیماری‌ها و وظایف عمومی سلامت روان متمرکز بوده‌اند. از سوی دیگر، پژوهش‌های رمزگذاری هم‌ریخت در سلامت نیز عمدتاً بر حفاظت از پرونده‌های پزشکی، ژنومیک، تصویربرداری و یادگیری ماشین عمومی تمرکز کرده‌اند.

از این منظر، نوآوری اصلی پژوهش حاضر را می‌توان در همگرایی تحلیل متنی خطر خودکشی، یادگیری غیرمتمرکز و حفاظت رمزگذاری‌شده از خروجی‌های مدل جست‌وجو کرد. در معماری پیشنهادی، داده‌های متنی حساس در سطح کلاینت پردازش می‌شوند، مدل محلی احتمال خطر را تولید می‌کند و خروجی عددی کلاینت پیش از ارسال به سرور در قالب رمزگذاری‌شده قرار می‌گیرد. سپس سرور به‌جای مشاهده مقادیر خام و انجام میانگین‌گیری پس از رمزگشایی تک‌تک خروجی‌ها، قادر است عملیات تجمیع مورد نیاز را در دامنه رمز انجام دهد و تنها نتیجه نهایی را بازیابی کند. این معماری در واقع تلاش می‌کند فاصله میان دو نیاز

ظاهراً متعارض را کاهش دهد: از یک سو، نیاز به همکاری چند منبع داده برای افزایش قابلیت یادگیری و از سوی دیگر، ضرورت جلوگیری از متمرکزسازی و افشای اطلاعات حساس روان‌شناختی.

بنابراین، بر مبنای پیشینه موجود می‌توان استدلال کرد که مسیر پژوهشی از «تشخیص خودکشی با یادگیری ماشین» به سمت «تشخیص خودکشی حفظ‌کننده حریم خصوصی» در حال حرکت است. در چنین چارچوبی، صرف نگهداری داده در کلاینت کافی نیست و باید امنیت ارتباطات، محرمانگی خروجی‌های محلی و نحوه تجمیع نتایج نیز در طراحی سامانه لحاظ شود. ترکیب یادگیری فدرال با رمزگذاری هم‌ریخت، همانند رویکرد بررسی‌شده در پژوهش حاضر، می‌تواند یکی از مسیرهای قابل توجه برای توسعه سامانه‌های هوشمند سلامت روان باشد که ضمن استفاده از ظرفیت یادگیری ماشین، الزامات محرمانگی داده‌های حساس را نیز در معماری خود لحاظ می‌کنند.

فصل دوم

واژه‌ها را بشنو؛ بنیان‌های نظری پردازش زبان طبیعی در جستجوی افکار خودکشی

" زبان، آیینه‌ی تمام‌نمای ذهن انسان است؛ هر آنچه در اعماق روان می‌گذرد، در لابه‌لای واژگان و ساختارهای زبانی، ردپایی بر جای می‌گذارد".

نوآم چامسکی (زبان‌شناس و فیلسوف)

پردازش زبان طبیعی[1] به عنوان یکی از پیشروترین و میان‌رشته‌ای‌ترین حوزه‌های هوش مصنوعی، پلی استوار میان پیچیدگی‌های زبان انسانی و توانمندی‌های محاسباتی ماشین‌ها ایجاد کرده است. این حوزه با هدف بنیادین درک، تفسیر و تولید زبان‌های انسانی توسط رایانه‌ها، نه‌تنها به دنبال تسهیل تعامل انسان و ماشین است، بلکه به عنوان پنجره‌ای نوین برای شناخت عمیق‌تر لایه‌های پنهان ارتباطات انسانی عمل می‌کند. در عصر کنونی که حجم عظیمی از داده‌های متنی در بسترهای گوناگون از شبکه‌های اجتماعی گرفته تا پرونده‌های الکترونیک سلامت تولید می‌شود، استخراج دانش و الگوهای معنادار از این انبوه داده‌ها به چالشی حیاتی و در عین حال فرصتی بی‌نظیر برای پژوهشگران حوزه‌های علوم کامپیوتر، زبان‌شناسی، روان‌شناسی و پزشکی تبدیل شده است.

فصل دوم این پایان‌نامه با هدف تدوین چارچوبی نظری و مرور نظام‌مند بر پژوهش‌های پیشین، به‌عنوان سنگ بنای علمی پژوهش حاضر، به تبیین مبانی و مفاهیم بنیادین در دو حوزه اصلی می‌پردازد: پردازش زبان طبیعی و کاربردهای آن در تشخیص خودکشی از روی داده‌های متنی. این فصل، ضمن مرور سیر تکاملی این حوزه‌ها از نظریه‌های اولیه زبان‌شناسی ساختاری تا کاربردهای نوین یادگیری ماشین و مدل‌های عمیق، به تشریح چالش‌های اساسی زبان انسانی نظیر ابهام‌زدایی و وابستگی به بافت، و نیز نقش خط‌لوله‌های پیش‌پردازش در آماده‌سازی داده‌های خام و نویزی برای تحلیل‌های ماشینی خواهد پرداخت.

در ادامه، با عنایت به حساسیت و اهمیت ویژه موضوع تشخیص خودکشی، این فصل به بررسی نظام‌مند پژوهش‌های انجام‌شده در زمینه استفاده از الگوریتم‌های مختلف یادگیری ماشین از جمله جنگل تصادفی[2]، درخت تصمیم[3]، ایکس‌جی بوست[4] و دسته‌بندهای مبتنی بر بیز ساده خواهد پرداخت. در این مسیر، مفاهیم کلیدی همچون مهندسی ویژگی‌ها، استراتژی‌های مواجهه با داده‌های نامتوازن، اهمیت کالیبراسیون آستانه تصمیم[6] و رویکردهای ترکیبی مورد بحث و واکاوی قرار می‌گیرند. همچنین، راه‌حل‌های عملی و بومی‌سازی‌شده‌ای مانند توسعه پکیج واژگان توقف‌پذیر فارسی «دنا» و تحلیل حساسیت مدل‌ها، به عنوان بخشی از نوآوری‌های عملی پژوهش مطرح خواهند شد.

به‌طور کلی، فصل پیش‌رو، نه‌تنها به‌عنوان مرجعی برای شناخت پیشینه و نظریه‌های بنیادین عمل می‌کند، بلکه با نگاهی نقادانه، نقاط قوت و کاستی‌های رویکردهای پیشین را آشکار ساخته و مسیر روشنی را برای طراحی و پیاده‌سازی چارچوب نوین پیشنهادی در فصول بعدی ترسیم می‌نماید. این مرور جامع، پایه‌های علمی لازم برای درک انتخاب‌های روش‌شناختی و تفسیر نتایج پژوهش را فراهم آورده و از این طریق، به اعتبار و کارایی دستاوردهای این پایان‌نامه در حوزه حساس تشخیص زودهنگام افکار خودکشی از طریق تحلیل متون می‌افزاید.

---

۱. Natural Language Processing(NLP)
۲. Random Forest
۳. Decision Tree
۴. XG-Boost
۵. Naive Bayes
۶. Threshold Tuning

۲-۱ پردازش زبان طبیعی

پردازش زبان طبیعی شاخه‌ای میان‌رشته‌ای از هوش مصنوعی و زبان‌شناسی است که به توانایی رایانه‌ها در درک، تفسیر و تولید زبان‌های انسانی می‌پردازد. هدف غایی این حوزه، تسهیل تعامل میان انسان و رایانه و تحقق رویای دیرین ارتباط با ماشین‌ها به زبان طبیعی است، به‌گونه‌ای که کاربران بدون نیاز به فراگیری زبان‌های برنامه‌نویسی پیچیده، بتوانند با سیستم‌ها به گفتگو بپردازند. یک زبان را می‌توان به عنوان نظامی از نمادها و قواعدی تعریف کرد که برای انتقال اطلاعات به کار می‌روند و NLP در تلاش است تا این نظام پیچیده را برای ماشین‌ها قابل فهم سازد. این حوزه عمدتاً به دو بخش اصلی درک زبان طبیعی و تولید زبان طبیعی تقسیم می‌شود که به‌ترتیب وظیفه درک مفاهیم نهفته در متن و تولید متنی مفهوم و طبیعی را بر عهده دارند.[۲۴]

از نخستین زبان‌شناسانی که در قرن بیستم به تدوین نظریه‌های نحوی پرداخت و انقلابی بنیادین در این حوزه پدید آورد، می‌توان به نوآم چامسکی اشاره کرد[۲۵]. به‌طورکلی، وظایف مرتبط با NLP در دو سطح طبقه‌بندی می‌شوند: سطح بالاتر که شامل تشخیص گفتار است و سطح پایین‌تر که به پردازش زبان نوشتاری می‌پردازد. از جمله وظایف رایج در این حوزه می‌توان به خلاصه‌سازی خودکار، حل هم‌مرجعی، تحلیل گفتمان، ترجمه ماشینی، قطعه‌بندی صرفی، تشخیص موجودیت‌های نام‌دار، تشخیص نوری کاراکترها و برچسب‌گذاری نقش‌های دستوری اشاره کرد. شماری از این وظایف کاربردهایی مستقیم در دنیای واقعی دارند، از جمله ترجمه ماشینی، تشخیص موجودیت‌های نام‌دار و تشخیص نوری کاراکترها.

خلاصه‌سازی خودکار با تولید خلاصه‌ای خوانا و مفهوم از یک مجموعه‌متن، اطلاعاتی فشرده یا دقیق از آن متن به‌دست می‌دهد. حل هم‌مرجعی به شناسایی ارجاع‌های موجود در یک جمله یا پیکره‌ای بزرگ‌تر می‌پردازد و مشخص می‌کند کدام واژه‌ها به یک موجودیت یکسان اشاره دارند. تحلیل گفتمان وظیفه شناسایی ساختار گفتمان در متون پیوسته را بر عهده دارد. ترجمه ماشینی یعنی تبدیل خودکار متن از یک زبان انسانی به زبانی دیگر. قطعه‌بندی صرفی به تجزیه واژگان به تکواژهای سازنده و تشخیص کلاس هر تکواژ اشاره دارد. تشخیص موجودیت‌های نام‌دار جریان متن را بررسی کرده و مشخص می‌کند کدام بخش‌های آن به نام‌های خاص تعلق دارند. تشخیص نوری کاراکترها تصویر متن چاپ‌شده را دریافت و معادل متنی آن را بازمی‌گرداند. برچسب‌گذاری نقش‌های دستوری نیز برای هر واژه جمله، نقش نحوی آن را معین می‌کند. هرچند این وظایف آشکارا به‌شدت به‌هم وابسته‌اند، اما برای سهولت اغلب به‌طور مجزا در نظر گرفته می‌شوند. برخی از آنها، مانند خلاصه‌سازی خودکار و حل هم‌مرجعی، به‌عنوان زیروظایفی در خدمت حل مسائل بزرگ‌تر عمل می‌کنند. هدف نهایی پردازش زبان طبیعی، تجمیع یک یا چند تخصص در قالب یک الگوریتم یا سیستم است که بتواند تعامل پیچیده‌ای با زبان انسان داشته باشد.

راسپوچر و همکارانش [۲۶] سامانه‌ای پیمانه‌ای برای استخراج رویدادهای میان‌زبانی از متون انگلیسی، هلندی و ایتالیایی ارائه دادند که در آن برای هر زبان خط‌لوله‌ای جداگانه به‌کار گرفته شده است. این سیستم شامل مجموعه‌ای پیمانه‌ای از ابزارهای چندزبانه NLP است که ماژول‌هایی را برای پردازش پایه، به‌همراه وظایف پیشرفته‌تری همچون پیوند موجودیت‌های نام‌دار در سطح

میان‌زبانی، برچسب‌گذاری نقش‌های معنایی و نرمال‌سازی زمانی، یکپارچه می‌کند. از این رو، چارچوب میان‌زبانی امکان تفسیر رویدادها، کنشگران، مکان‌ها، زمان و نیز روابط میان آنها را فراهم می‌سازد. خروجی هر یک از این خط‌لوله‌ها به‌عنوان ورودی سامانه‌ای در نظر گرفته شده است که نمودارهای دانش رویدادمحور تولید می‌کند. همگی ماژول‌ها مانند لوله‌های یونیکس عمل می‌کنند: ورودی استاندارد را دریافت، بر روی آن حاشیه‌نویسی انجام، و خروجی استاندارد تولید می‌کنند که به نوبهٔ خود ورودی ماژول بعدی خواهد بود. این خط‌لوله‌ها بر اساس معماری داده‌محور ساخته شده‌اند تا امکان تطبیق و جایگزینی ماژول‌ها فراهم باشد. افزون بر این، معماری پیمانه‌ای امکان پیکربندی‌های گوناگون و توزیع پویا را نیز میسر می‌سازد.

بیشتر پژوهش‌های حوزه پردازش زبان طبیعی توسط دانشمندان رایانه انجام می‌شود، اما متخصصانی از حوزه‌های دیگر همچون زبان‌شناسان، روان‌شناسان و فیلسوفان نیز به این عرصه علاقه نشان داده‌اند. یکی از جنبه‌های شگفت‌انگیز NLP این است که به درک ما از زبان انسان می‌افزاید. این حوزه با نظریه‌ها و فنون گوناگونی پیوند دارد که همگی به مسئله ارتباط با رایانه‌ها به زبان طبیعی می‌پردازند. ابهام، یکی از چالش‌های اساسی زبان طبیعی است که معمولاً در سطح نحوی بروز می‌کند و خود شامل زیروظایف واژگانی و صرفی (مطالعه واژگان و فرایندهای واژه‌سازی) می‌شود. هر یک از این سطوح می‌توانند مبدأ ابهاماتی باشند که تنها با در نظر گرفتن کل جمله قابل رفع‌اند. برای حل این ابهامات، روش‌های گوناگونی پیشنهاد شده است، از جمله کمینه‌سازی ابهام، نگهداشت ابهام، رفع ابهام تعاملی و وزن‌دهی به ابهام [۲۷]. برخی پژوهشگران رویکرد نگهداشت ابهام را برگزیده‌اند (مانند: شمتوف، ۱۹۹۷ [۲۸]؛ امِل و دورنا، ۱۹۹۸ [۲۹]؛ نایت و لانگکیلد، ۲۰۰۰[۳۰]). این رویکردها به هدفی نزدیک به رویکرد آخر اشاره دارند: دامنه وسیعی از ابهامات را پوشش می‌دهند و عنصری آماری در بطن خود دارند.

۲-۲ تاریخچه

در اواخر دهه ۱۹۴۰، اگرچه هنوز اصطلاحی به نام "ترجمه ماشینی" وجود نداشت، اما کار بر روی آن آغاز شده بود. تحقیقات آن دوران عمدتاً معطوف به زبان‌های روسی و انگلیسی بود، هرچند از زبان‌هایی همچون چینی نیز در این حوزه استفاده می‌شد [۳۱]. با این حال، گزارش ALPAC در سال ۱۹۶۶ تقریباً به تمامی پژوهش‌های ترجمه ماشینی و پردازش زبان طبیعی پایان داد، چرا که نتیجه گرفته بود این فناوری به جایی نمی‌رسد. با وجود این، اندکی بعد، برخی سیستم‌های عملیاتی ترجمه ماشینی موفق شدند خروجی‌هایی در اختیار مشتریان خود قرار دهند [۳۲]. در همین احوال، کاربرد رایانه‌ها در مطالعات ادبی و زبانی نیز پا گرفته بود.

در اوایل دهه ۱۹۸۰، نظریه دستور زبان محاسباتی به حوزه‌ای بسیار پویا تبدیل شد؛ حوزه‌ای که با منطق‌های معنایی، توانایی دانش در مواجهه با باورها و نیات کاربر، و کارکردهایی چون تأکید و مضمون‌پردازی گره خورده بود. تا پایان این دهه، پردازشگرهای جملهٔ همه‌منظوره و توانمندی مانند موتور زبان Cor از مؤسسه SRI [۳۳] و نظریه بازنمایی گفتمان [۳۴] ابزارهایی در اختیار پژوهشگران قرار دادند تا بتوانند گفتمان‌های گسترده‌تر را در چارچوبی دستوری–منطقی مداقه کنند. این دوران، دوران شکوفایی جامعهٔ پژوهشی بود. منابع کاربردی، دستورنامه‌ها، ابزارها و تحلیلگران نحوی همگی در دسترس قرار گرفتند. (برای نمونه ابزارهای زبان طبیعی Alvey کنفرانس‌های ARPA [۳۵]) در زمینهٔ تشخیص گفتار و درک پیام (استخراج اطلاعات)، افزون بر پرداختن

به وظایف خاص خود، بر ارزیابی دقیق و نظام‌مند نیز تأکید داشتند و روندی را بنیان نهادند که در دهۀ ۱۹۹۰ به یکی از ویژگی‌های اصلی این حوزه بدل شد [۳۶][۳۷]. تحقیقات در زمینۀ مدل‌سازی کاربر [۳۸] نیز یکی از رشته‌های پژوهشی پررنگ بود و ساختار گفتمان در خدمت همین هدف قرار می‌گرفت [۳۹]. در همان زمان، مک‌کیون نشان داد که از طرحواره‌های بلاغی می‌توان برای تولید متنی استفاده کرد که هم از نظر زبانی منسجم باشد و هم از حیث ارتباطی کارآمد.[۴۰]

برخی پژوهش‌ها در حوزه‌یNLP ، موضوعات کلیدی آینده را ترسیم کردند؛ از جمله ابهام‌زدایی معنایی واژگان [۴۱] و همچنین شبکه‌های احتمالاتی که به پردازش زبان طبیعی رنگی آماری بخشیدند. کار بر روی واژگان نیز جهت‌گیری مشابهی داشت. در دهۀ ۱۹۹۰، پردازش زبان آماری به موضوعی محوری تبدیل شد [۴۲]؛ چراکه نه تنها تحلیلگران داده را به خود مشغول ساخت، بلکه حوزه‌هایی نظیر استخراج اطلاعات و خلاصه‌سازی خودکار نیز مورد توجه جدی قرار گرفتند.[۴۳]

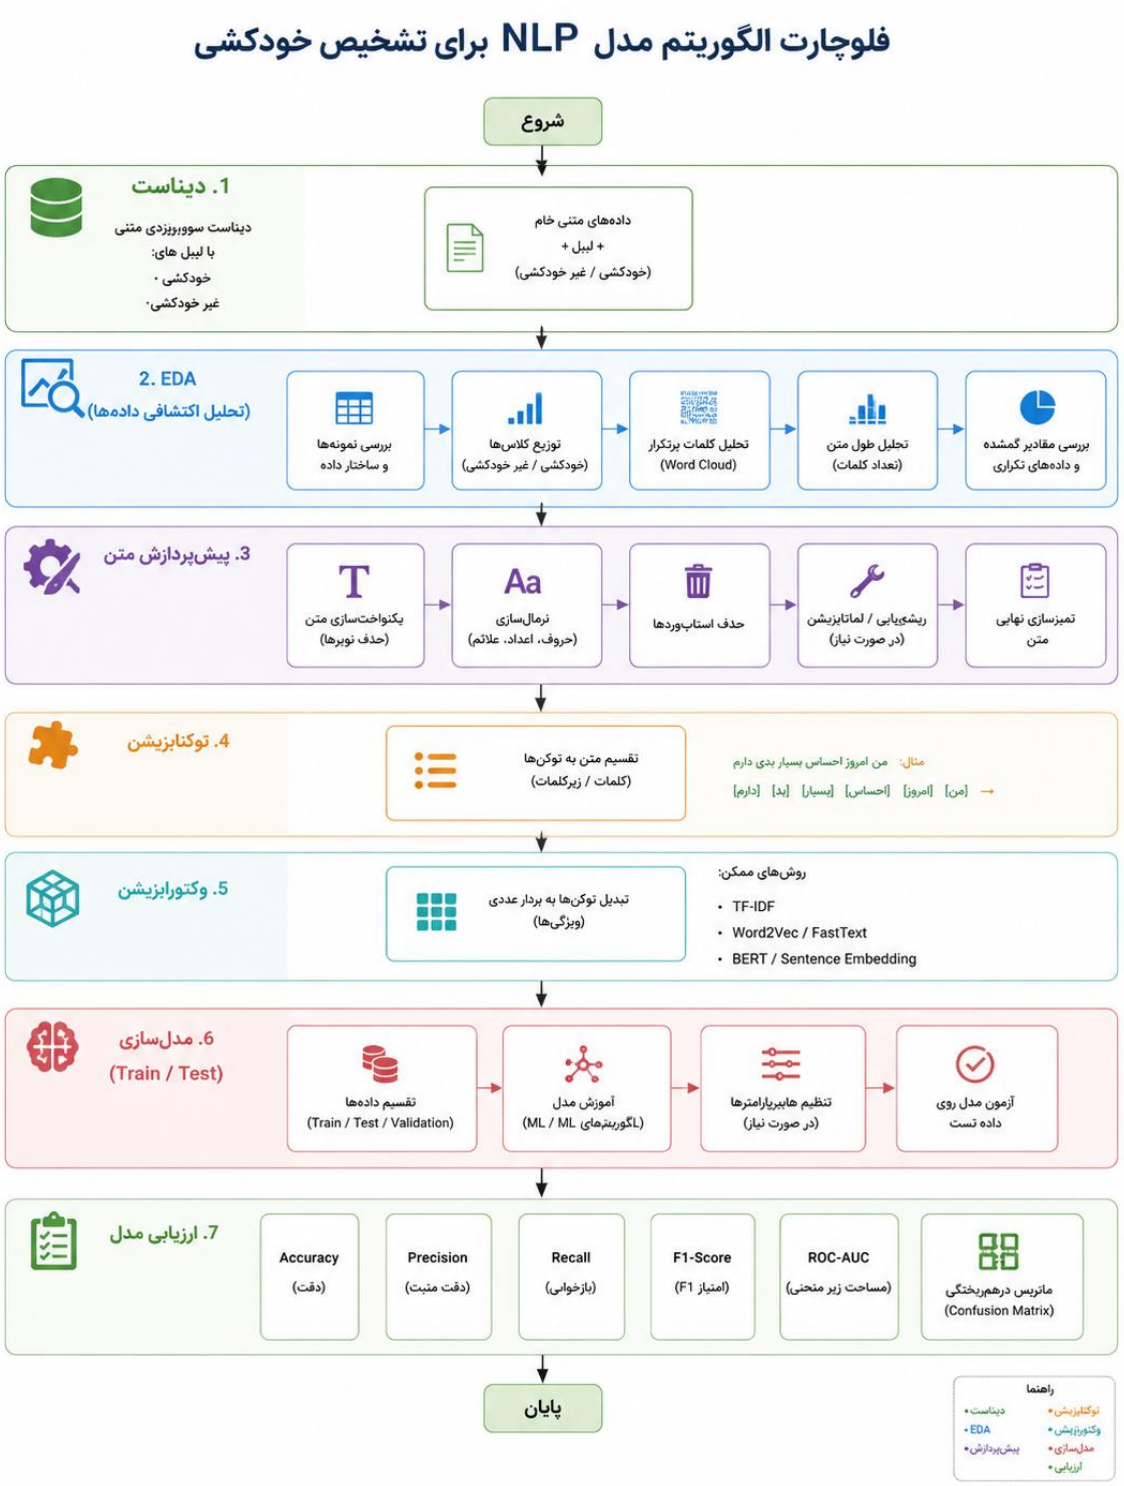
۲-۳ نحوه پیاده‌سازی

در این پژوهش، روشی مشتمل بر هفت گام اساسی برای تشخیص میزان خطر خودکشی از طریق تحلیل متون به کار گرفته شده است. نمای کلی این مراحل در شکل۲-۱ ارائه گردیده است. گام نخست، شامل انتخاب یک پایگاه داده برچسب‌گذاری‌شده[۱] است. در ادامه، تحلیل اکتشافی داده‌ها[۲] انجام می‌شود که در آن عواملی نظیر وجود رکوردهای تکراری، شاخص‌های آماری، رکوردهای گم‌شده[۳] و توزیع کلاس‌ها بررسی می‌گردند. گام بعدی به پیش‌پردازش داده‌ها اختصاص دارد؛ در این مرحله، واژگان پربسامد اما کم‌معنا[۴] شناسایی و متن‌ها نرمال‌سازی می‌شوند.

اگرچه برای داده‌های انگلیسی کتابخانه‌ها و بسته‌های نرم‌افزاری متعددی به‌صورت رایگان در دسترس پژوهشگران است، اما در حوزۀ زبان فارسی، کمبود چنین ابزارهایی کاملاً محسوس است. ازاین‌رو، در مسیر اجرای این پروژه، بسته‌ای جامع برای حذف واژگان توقف‌پذیر تدوین و به‌صورت رایگان در اختیار تمامی پژوهشگران قرار گرفته است. این بسته، با الهام از قلۀ زیبای دنا[۱] در مرکز ایران، «دنا» نام‌گذاری شده است.

---

۱. Labeled dataset
۲. Exploratory Data Analysis(EDA)
۳. Missing values
۴. Stop words



شکل۲-۱

پس از این مرحله، نوبت به توکن‌سازی داده‌ها[۲] می‌رسد؛ در این گام، جملات به واحدهای کوچک‌تر یا توکن‌ها تجزیه می‌شوند. به‌منظور به‌کارگیری این توکن‌ها در الگوریتم‌های یادگیری ماشین، باید آن‌ها را به بردارهای عددی متناسب با ساختار الگوریتم‌ها تبدیل کرد. با انجام این تبدیل، می‌توان الگوریتم‌های مختلف یادگیری ماشین را بر روی داده‌ها آموزش داده و نتایج حاصل را

استخراج نمود. در مرحلهٔ آموزش مدل‌ها، داده‌ها به دو بخش آموزش و آزمون تقسیم می‌شوند؛ سپس با استفاده از اعتبارسنجی متقابل[۳]، مدل‌ها آموزش دیده و خروجی‌ها تولید می‌شوند. در گام پایانی، به‌منظور مقایسهٔ عملکرد مدل‌ها، ارزیابی جامعی صورت می‌گیرد که در آن معیارهایی همچون دقت[۴]، پوشش[۵]، نمرهٔ F1، سطح زیر منحنی و ماتریس درهم‌ریختگی[۶] مورد استفاده قرار می‌گیرند.

۲-۳-۱ مجموعه دادگان

یک مجموعه داده، مجموعه‌ای ساختاریافته از اطلاعات مربوط به یک دامنه خاص است. در پردازش زبان طبیعی، مجموعه داده‌ها معمولاً از محتوای متنی تشکیل شده‌اند که مدل‌های یادگیری ماشین برای استخراج بینش‌های معنادار، آنها را پردازش می‌کنند. این مجموعه داده‌ها عموماً به دو نوع تقسیم می‌شوند: برچسب‌گذاری‌شده و بدون برچسب. یک مجموعه داده برچسب‌گذاری‌شده شامل یک دسته یا برچسب از پیش تعریف‌شده برای هر نقطه داده است، به عنوان مثال، ورودی‌های متن ممکن است به عنوان "خودکشی" یا "غیرخودکشی" حاشیه‌نویسی شوند، که اغلب توسط برچسب‌گذاران انسانی انجام می‌شود. مطالعه ما از یک مجموعه داده برچسب‌گذاری‌شده شامل ۴۶۴۱۴۸ ردیف داده متنی و حاشیه‌نویسی‌های مربوطه آنها استفاده می‌کند[۴۴]. این انتخاب با یادگیری نظارت‌شده، یک الگوی اصلی در یادگیری ماشین که برای آموزش مؤثر مدل به چنین نمونه‌هایی متکی است، همسو است. در غیاب داده‌های برچسب‌گذاری‌شده، عملکرد پیش‌بینی‌کننده به طور قابل توجهی مختل و بسیار کمتر قابل اعتماد خواهد بود.

---

۱. DENA
۲. Tokenization
۳. cross-validation
۴. Precision
۵. Recall
۶. Confusion Matrix

۲-۳-۲ پیش پردازش و پاکسازی مجموعه دادگان

در حوزه‌ی پردازش زبان طبیعی، کیفیت داده‌های ورودی به مراتب مهم‌تر از پیچیدگی الگوریتم‌های به‌کاررفته است و این اصل طلایی با عنوان "Garbage In, Garbage Out" در ادبیات پژوهشی شناخته می‌شود [۴۵]. داده‌های متنی استخراج‌شده از شبکه‌های اجتماعی، پیام‌رسان‌ها یا جلسات مشاوره‌ی آنلاین، ذاتاً ناهمگون، نویزی و آکنده از عناصر غیرزبانی نظیر نشانه‌های HTML، آدرس‌های اینترنتی، ایمیل‌ها، ایموجی‌ها، اعداد و علائم نگارشی هستند که همگی می‌توانند عملکرد مدل‌های یادگیری ماشین را به شدت مختل کنند[۴۶]. پاک‌سازی داده به عنوان نخستین و حساسترین گام در چرخه‌ی تحلیل متن، نه تنها حجم داده را کاهش داده و سرعت پردازش را افزایش می‌دهد، بلکه با حذف نویزهای زبانی و استانداردسازی نوشتار، زمینه‌ساز استخراج ویژگی‌های معنادار و افزایش دقت تشخیص در وظایف حساسی همچون شناسایی افکار خودکشی می‌شود [۴۷]. به ویژه در داده‌های چندزبانه (چندزبانگی) که ترکیبی از انگلیسی، فارسی و عبری هستند، وجود نویزهای متعدد می‌تواند الگوهای زبانی ظریف مرتبط با بحران روانی را تحت‌الشعاع قرار دهد و ضرورت یک خط‌لوله‌ی پاک‌سازی جامع و سفارشی‌شده را دوچندان می‌سازد [۴۸]. طرح واره کلی این فرآیند در شکل ۲-۲ آمده است.

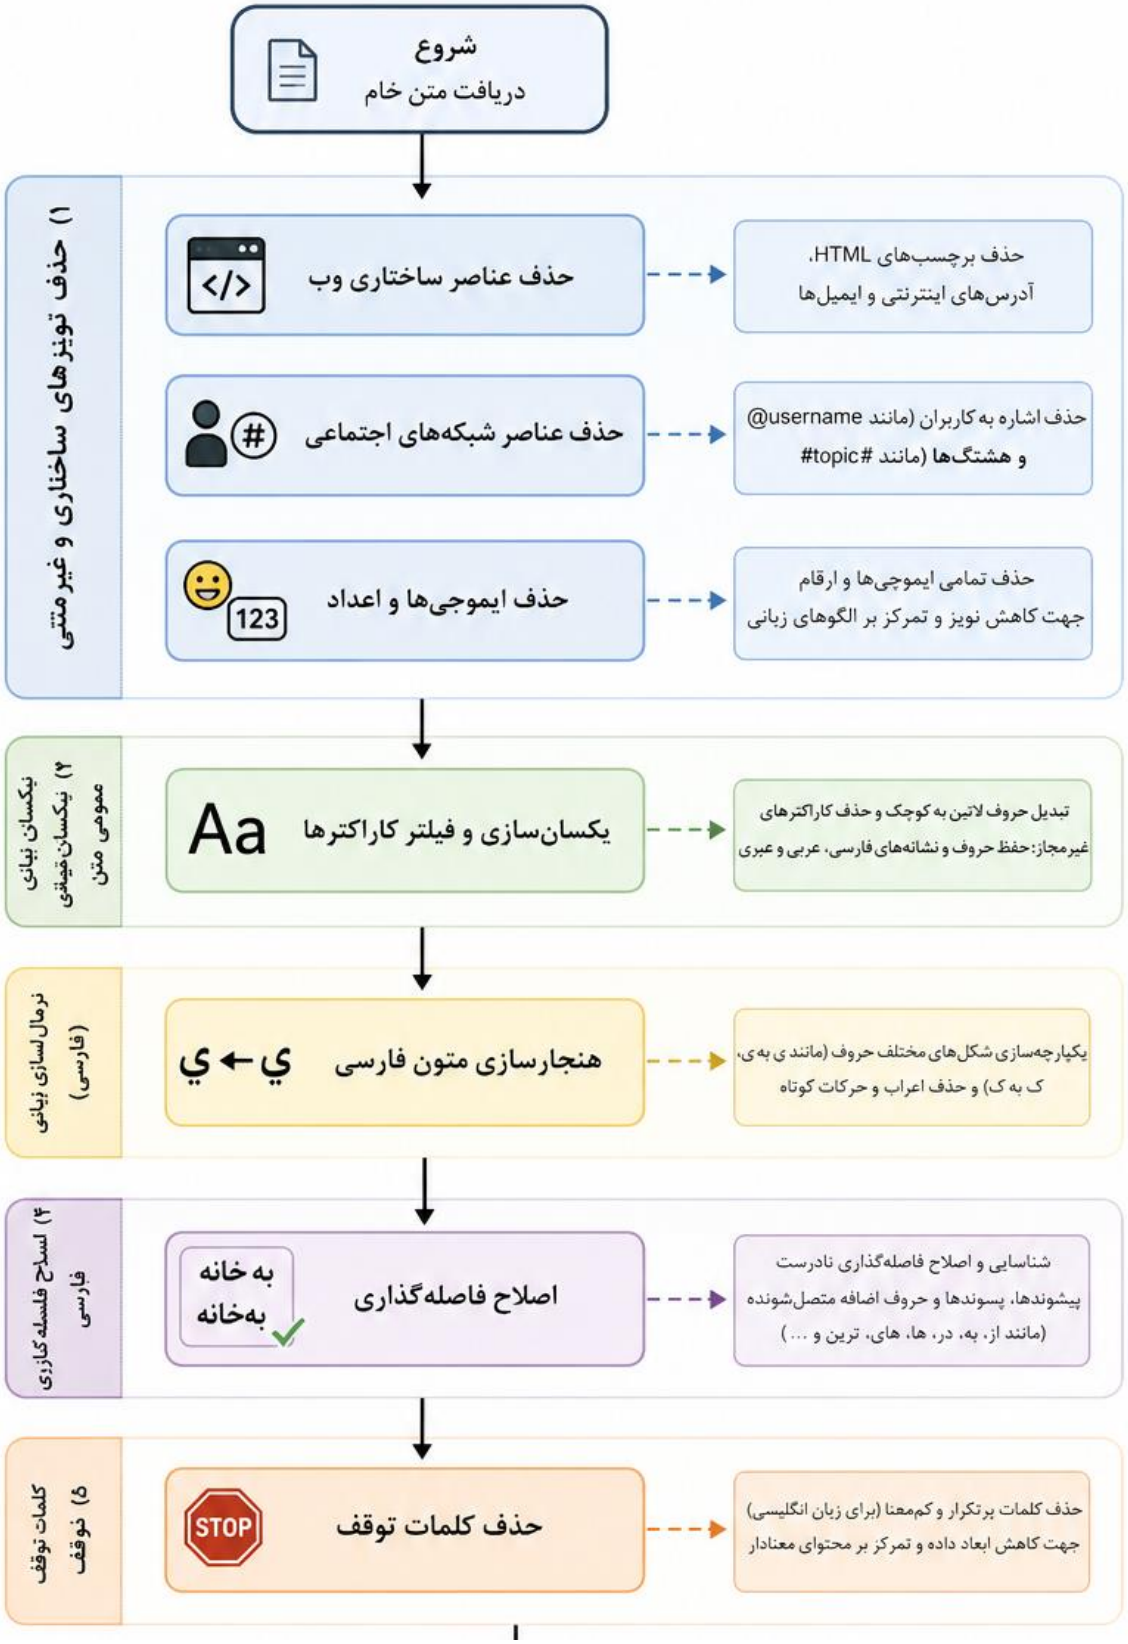
در پژوهش حاضر، یک خط‌لوله‌ی پاک‌سازی چندلایه[1] پیاده‌سازی شده است که به‌صورت گام‌به‌گام، انواع نویزها و عناصر نامطلوب موجود در داده‌های متنی را شناسایی و حذف می‌کند. این خط‌لوله به‌گونه‌ای طراحی شده است که مراحل مختلف پاک‌سازی بتوانند به‌صورت مستقل فعال یا غیرفعال شوند. این ویژگی، انعطاف‌پذیری مناسبی را در مواجهه با انواع مختلف داده‌های متنی فراهم می‌سازد و به پژوهشگر اجازه می‌دهد متناسب با ماهیت و ساختار دیتاست، ترکیب مناسبی از عملیات پیش‌پردازش را انتخاب نماید. در ادامه، مراحل مختلف این فرایند به تفکیک تشریح می‌شوند.

در مرحله‌ی بعد، نشانه‌های مربوط به تعاملات شبکه‌های اجتماعی، شامل اشاره به کاربران و هشتگ‌ها، از متن حذف می‌شوند. این عناصر معمولاً برای نمایش ساختار ارتباطی یا دسته‌بندی محتوای شبکه‌های اجتماعی به کار می‌روند و الزاماً اطلاعات مستقیمی درباره وضعیت روان‌شناختی نویسنده ارائه نمی‌کنند. حذف این موارد از ایجاد توکن‌های کم‌اهمیت و افزایش ابعاد غیرضروری فضای ویژگی جلوگیری می‌کند .[۵۰]

در ادامه، ایموجی‌ها و ارقام موجود در متن حذف می‌شوند. ایموجی‌ها در داده‌های مورد استفاده‌ی پژوهش، به‌عنوان عناصر غیرزبانی در نظر گرفته شده‌اند و در چارچوب پیش‌پردازش حاضر ارزش تشخیصی مستقیمی برای طبقه‌بندی موردنظر ندارند. همچنین ارقام با هدف کاهش تنوع واژگانی و حذف اطلاعات غیرضروری از متن کنار گذاشته می‌شوند. این مرحله موجب می‌شود فرایند استخراج ویژگی بیشتر بر ساختار و محتوای واژگانی متن متمرکز شود .[۵۱]

---

۱. Multi-layer Cleaning Pipeline



شکل ۲-۲: طرح‌واره پاکسازی دادگان

پس از حذف نویزهای سطحی، عملیات پاک‌سازی زبانی بر روی متن انجام می‌شود. در این مرحله، حروف لاتین به شکل کوچک تبدیل شده و کاراکترهای غیرمجاز حذف یا با فاصله جایگزین می‌شوند. در عین حال، دامنه‌ی کاراکترهای مورد استفاده به‌گونه‌ای تعریف شده است که حروف و نشانه‌های مربوط به زبان‌های فارسی، عربی و عبری نیز حفظ شوند. این رویکرد برای پردازش یک دیتاست چندزبانه اهمیت ویژه‌ای دارد؛ زیرا از ورود نویسه‌های نامعتبر، علائم غیرضروری و ایجاد توکن‌های فاقد معنای مشخص جلوگیری می‌کند .[۵۲]

در مرحله‌ی بعد، گونه‌های مختلف نوشتاری حروف فارسی و عربی به یک شکل استاندارد تبدیل می‌شوند. برای نمونه، شکل‌های متفاوت حروف «ی» و «ک» که ممکن است در داده‌های متنی با نویسه‌های عربی یا فارسی ثبت شده باشند، به صورت یکسان بازنمایی می‌شوند. همچنین اعراب و حرکات کوتاه حذف می‌شوند؛ زیرا این نشانه‌ها در متون غیررسمی، به‌ویژه محتوای تولیدشده در فضای مجازی، به‌صورت نامنظم استفاده شده و می‌توانند موجب افزایش تنوع ظاهری کلمات یکسان شوند. این مرحله باعث کاهش پراکندگی واژگانی و افزایش یکپارچگی داده‌ها پیش از استخراج ویژگی می‌شود .[۵۳]

یکی دیگر از مراحل پیش‌پردازش، اصلاح فاصله‌گذاری در متون فارسی است. در این مرحله، الگوهای رایج مربوط به فاصله‌گذاری نادرست میان اجزای واژه، پیشوندها، پسوندها و برخی عناصر زبانی شناسایی و اصلاح می‌شوند. در داده‌های تولیدشده توسط کاربران، به‌ویژه در محیط‌های غیررسمی و شبکه‌های اجتماعی، ممکن است برخی اجزای واژه به‌صورت چسبیده، جدا یا با فاصله‌گذاری نامتعارف نوشته شوند. اصلاح این ناهماهنگی‌ها موجب می‌شود واحدهای واژگانی با دقت بیشتری شناسایی شده و فرایند قطعه‌بندی و استخراج ویژگی با خطای کمتری انجام گیرد .[۵۴]

در مرحله‌ی نهایی پاک‌سازی زبانی، کلمات توقف پرتکرار زبان انگلیسی از متن حذف می‌شوند. این کلمات، مانند حروف اضافه، افعال کمکی و برخی واژگان دستوری، اگرچه از نظر ساختاری در جمله اهمیت دارند، معمولاً اطلاعات تمایزبخش محدودی برای مسئله‌ی طبقه‌بندی موردنظر فراهم می‌کنند. حذف آن‌ها می‌تواند تعداد ویژگی‌های کم‌اهمیت را کاهش داده و مدل را بیشتر بر واژگان دارای محتوای معنایی و عاطفی متمرکز نماید؛ از جمله واژگان مرتبط با ناامیدی، تنهایی، مرگ و سایر مفاهیم مرتبط با خطر خودکشی .[۵۵]

شایان ذکر است که در پیاده‌سازی حاضر، مجموعه‌ی کلمات توقف تنها برای زبان انگلیسی در نظر گرفته شده است. بنابراین، با توجه به ماهیت چندزبانه‌ی دیتاست، توسعه‌ی این بخش و افزودن مجموعه‌های مناسب از کلمات توقف برای زبان‌های فارسی و عبری می‌تواند یکی از مسیرهای بهبود در پژوهش‌های آتی باشد. البته حذف کلمات توقف باید با احتیاط انجام گیرد؛ زیرا برخی واژگان دستوری، بسته به مسئله‌ی مورد مطالعه و روش استخراج ویژگی، ممکن است حاوی اطلاعات زمینه‌ای یا نحوی مفیدی باشند.

در نهایت، پس از اعمال تمامی مراحل پیش‌پردازش بر روی دیتاست، شاخص‌های آماری مربوط به فرایند پاک‌سازی محاسبه می‌شوند. این ارزیابی شامل بررسی تعداد نمونه‌های موجود، مقایسه‌ی میانگین طول متون پیش و پس از پاک‌سازی و نمایش نمونه‌هایی از متن خام و نسخه‌ی پاک‌شده‌ی آن است. هدف از این مرحله، علاوه بر بررسی میزان کاهش نویز، اطمینان از آن است که فرایند پاک‌سازی موجب حذف ناخواسته‌ی اطلاعات معنادار و حیاتی نشده باشد .[۵۶]از این رو، ارزیابی کمی و کیفی

خروجی، به‌عنوان بخشی ضروری از فرایند پیش‌پردازش در نظر گرفته شده است و امکان بررسی میزان اثربخشی و صحت خط‌لوله‌ی پاک‌سازی را پیش از ورود داده‌ها به مراحل بعدی تحلیل و مدل‌سازی فراهم می‌سازد.

۲-۳-۳ توکن‌سازی؛ گام بنیادین در پردازش زبان طبیعی

توکن‌سازی به عنوان نخستین و یکی از حیاتی‌ترین مراحل پیش‌پردازش در هر سیستم پردازش زبان طبیعی شناخته می‌شود و هدف آن، شکستن رشته‌ی متنی پیوسته به واحدهای کوچک‌تر و معنادار به نام توکن است [۵۷]. این واحدها می‌توانند کلمات، نشانه‌های نگارشی، اعداد یا حتی زیرواژه‌ها باشند و نحوه‌ی انتخاب آنها، تأثیر مستقیمی بر عملکرد کلی مدل‌های یادگیری ماشین دارد، چرا که توکن‌ها، ورودی اصلی شبکه‌های عصبی را تشکیل می‌دهند [۵۸]. انتخاب روش توکن‌سازی مناسب، به ویژه در داده‌های چندزبانه و حساس مانند متون مرتبط با سلامت روان، از اهمیت دوچندانی برخوردار است؛ زیرا توکن‌سازی نادرست می‌تواند الگوهای زبانی ظریف مرتبط با افکار خودکشی (مانند استفاده‌ی مکرر از ضمایر اول‌شخص یا واژگان ناامیدی) را مخدوش سازد و دقت تشخیص را به شدت کاهش دهد [۵۹].

روش توکن‌سازی فضای سفید[۱] که در ادبیات پژوهشی با عناوینی نظیر "روش مبتنی بر فاصله" یا "حالت پیش‌فرض" نیز شناخته می‌شود، یکی از ابتدایی‌ترین و در عین حال پرکاربردترین روش‌های توکن‌سازی در پردازش زبان طبیعی است [۶۰]. این روش، رشته‌ی متنی ورودی را بر اساس کاراکترهای فاصله و گاهی شکست‌های خط و تب به بخش‌های مجزا تقسیم می‌کند و هر بخش را به عنوان یک توکن در نظر می‌گیرد [۶۱]. پیاده‌سازی این روش در زبان‌های برنامه‌نویسی مختلف، بسیار ساده و شهودی است و در پایتون، متد استاندارد `split()` بر روی رشته‌ها دقیقاً همین عملکرد را ارائه می‌دهد. در پژوهش حاضر، از این روش با عنوان توکن‌سازی فضای سفید استفاده شده است که با دریافت متن پاک‌سازی‌شده از مرحله‌ی قبل، آن را بر اساس فاصله‌ها شکسته و لیستی از توکن‌ها را بازمی‌گرداند؛ بدون آنکه هیچ گونه پیچیدگی زبانی، صرفی یا نحوی را در نظر بگیرد [۶۲].

با وجود روش‌های پیشرفته‌تر توکن‌سازی مانند توکن‌سازهای مبتنی بر قاعده[۲]، مبتنی بر دیکشنری[۳] یا مدل‌های زیرواژه‌ای[۴]، انتخاب روش توکن‌ساز فضای سفید در این پژوهش از چند منظر حائز اهمیت است. نخست، سرعت اجرای بسیار بالا: این روش با پیچیدگی زمانی $O(n)$ که n طول متن است، هیچ گونه بار محاسباتی اضافی بر روی خط‌لوله‌ی پردازش تحمیل نمی‌کند و امکان پردازش بلادرنگ داده‌های حجیم شبکه‌های اجتماعی را فراهم می‌آورد [۶۳].

---

۱. Whitespace Tokenizer
۲. Rule-based
۳. Dictionary-based
۴. Subword

دوم، استقلال از زبان و فرهنگ: برخلاف روش‌های مبتنی بر قاعده که نیازمند دانش عمیق زبانی و ساختارهای نحوی زبان‌های هدف هستند، توکن‌ساز فضای سفید بدون هیچ گونه وابستگی به زبان خاصی عمل می‌کند و این ویژگی در داده‌های چندزبانه‌ی پژوهش (شامل فارسی، عربی، عبری و انگلیسی) که ترکیبی از نوشتارهای متفاوت با قواعد نگارشی گوناگون هستند، یک مزیت انکارناپذیر محسوب می‌شود [۶۴]. سوم، شفافیت و تفسیرپذیری: توکن‌های حاصل از این روش، دقیقاً معادل کلمات طبیعی موجود در متن هستند و این امر، تحلیل‌های زبان‌شناختی بعدی و بررسی ویژگی‌های واژگانی مرتبط با خودکشی (مانند فراوانی کلمات منفی یا ضمایر) را بسیار تسهیل می‌کند [۶۵].

همانند هر روش دیگری، توکن‌ساز فضای سفید دارای مجموعه‌ای از مزایا و معایب است که آگاهی از آنها برای تفسیر صحیح نتایج پژوهش ضروری است. از جمله مزایای اصلی می‌توان به موارد زیر اشاره کرد:

۱. پیاده‌سازی فوق‌العاده ساده که نیاز به کتابخانه‌های پیچیده یا مدل‌های زبانی حجیم را برطرف می‌سازد [۶۶].
۲. هزینه‌ی محاسباتی ناچیز که آن را برای محیط‌های با منابع محدود و دیتاست‌های بسیار بزرگ ایده‌آل می‌سازد [۶۷].
۳. حفظ کامل ساختار ظاهری کلمات که امکان استخراج ویژگی‌های سطح کلمه[۱] را بدون هیچ گونه تغییری در نگارش اصلی فراهم می‌کند [۶۸].

با این حال، معایب قابل‌توجهی نیز بر این روش مترتب است:

۱. ناتوانی در تشخیص مرزهای کلمات در زبان‌های به هم‌چسبیده مانند فارسی که در آنها حروف اضافه و پسوندها اغلب به‌صورت چسبیده نوشته می‌شوند و این امر منجر به توکن‌های طولانی و بی‌معنا می‌گردد [۶۹].
۲. حساسیت به نویزهای نگارشی به گونه‌ای که علائم نگارشی چسبیده به کلمات (مانند "خودکشی؟" یا "ناامید!") را به عنوان بخشی از توکن در نظر می‌گیرد و این مسئله می‌تواند ویژگی‌های زبانی را مخدوش سازد [۷۰].
۳. ناتوانی در مدیریت کلمات مرکب و چندجزئی که در زبان‌های انگلیسی و فارسی رایج هستند و به عنوان یک توکن واحد تلقی می‌شوند، در حالی که از نظر معنایی، اجزای تشکیل‌دهنده‌ی آنها اهمیت دارند [۷۱].

---

۱. Word-level Features

با توجه به معایب ذکرشده، در خط‌لوله‌ی پردازش این پژوهش، راهکارهایی برای کاهش اثرات منفی توکن‌ساز فضای سفید در نظر گرفته شده است. نخست، مرحله‌ی پیشین پاک‌سازی داده‌ها (که به تفصیل شرح داده شد)، با حذف علائم نگارشی، ایموجی‌ها و نویزهای مختلف، تا حد زیادی مشکل چسبیدگی علائم به کلمات را برطرف می‌سازد. دوم، تابع `correct_persian_spacing` که در مرحله‌ی پاک‌سازی پیاده‌سازی شده، فاصله‌گذاری نادرست در زبان فارسی را تصحیح می‌کند و تا حد امکان از تشکیل توکن‌های چسبیده و بی‌معنا جلوگیری می‌نماید [۷۲]. سوم، در مرحله‌ی استخراج ویژگی، توکن‌های حاصل با استفاده از روش‌های آماری و مبتنی بر وزن‌دهی (مانند TF-IDF) پردازش می‌شوند که تأثیر توکن‌های نادرست و کم‌تکرار را به طور خودکار کاهش می‌دهند [۷۳].

با این تدابیر، اگرچه روش توکن‌ساز فضای سفید به تنهایی برای زبان‌های پیچیده‌ای مانند فارسی کافی نیست، اما در ترکیب با یک خط‌لوله‌ی پیش‌پردازش قدرتمند، می‌تواند عملکردی قابل قبول و از نظر محاسباتی به‌صرفه ارائه دهد [۷۴]. در نهایت، پیشنهاد می‌شود در پژوهش‌های آتی، عملکرد این روش با روش‌های پیشرفته‌تری مانند توکن‌سازهای مبتنی بر مدل‌های زبانی (مانند BERT Tokenizer) مقایسه شود تا تأثیر انتخاب روش توکن‌سازی بر دقت تشخیص خودکشی به صورت تجربی مورد ارزیابی قرار گیرد [۷۵].

۲-۳-٤ بردارسازی[۱]؛ پل ارتباطی بین زبان انسان و ماشین

پس از انجام مراحل پیش‌پردازش و توکن‌سازی، یکی از مهم‌ترین مراحل در سامانه‌های یادگیری ماشین مبتنی بر متن، تبدیل داده‌های زبانی به نمایش‌های عددی قابل پردازش برای الگوریتم‌های یادگیری ماشین است. این فرآیند که با عنوان **بردارسازی** یا **نمایش برداری متن** شناخته می‌شود، نقش واسط میان ساختار کیفی و پیچیده زبان طبیعی و فضای عددی مورد نیاز الگوریتم‌های یادگیری ماشین را ایفا می‌کند [۷۷]. از آنجا که الگوریتم‌های یادگیری ماشین قادر به پردازش مستقیم واژه‌ها و ساختارهای زبانی نیستند، لازم است هر متن به مجموعه‌ای از مقادیر عددی تبدیل شود تا روابط موجود میان نمونه‌های مختلف در یک فضای ویژگی قابل محاسبه باشد.[۷۸]

در ساده‌ترین حالت، می‌توان هر واژه را به یک شناسه عددی تبدیل کرد؛ با این حال، چنین نگاشتی هیچ‌گونه اطلاعاتی درباره شباهت معنایی یا روابط میان واژگان ارائه نمی‌دهد. ازاین‌رو، روش‌های پیشرفته‌تر بردارسازی تلاش می‌کنند واژه‌ها و متون را در یک فضای برداری نمایش دهند، به‌گونه‌ای که واژگانی که در بافت‌های مشابه به کار می‌روند، در این فضا نیز دارای نمایش‌های نزدیک‌تری باشند [۷۹]. چنین نمایش‌هایی زمینه را برای محاسبه شباهت میان متون، استخراج ویژگی‌های زبانی و استفاده از داده‌های متنی در مدل‌های طبقه‌بندی فراهم می‌کنند.[۸۰]

---

۱. Vectorization

در پژوهش حاضر، پس از بررسی روش‌های مختلف نمایش متن، روش Word۲Vec به‌عنوان روش اصلی بردارسازی انتخاب شده است. دلیل این انتخاب، ایجاد تعادلی مناسب میان توانایی استخراج روابط معنایی، هزینه محاسباتی، اندازه فضای ویژگی و تناسب با حجم و ماهیت داده‌های پژوهش است.

۲-۳-۵ بردارسازی مبتنی بر Word۲Vec

Word۲Vec یکی از روش‌های شناخته‌شده در حوزه نمایش توزیعی کلمات است که توسط Mikolov و همکاران معرفی شد و تحول مهمی در روش‌های نمایش برداری واژگان ایجاد کرد. ایده اصلی این روش بر این فرض استوار است که کلماتی که در بافت‌های مشابه ظاهر می‌شوند، دارای نمایش‌های برداری مشابهی خواهند بود .بنابراین، برخلاف روش‌های صرفاً آماری مانند TF-IDF، Word۲Vec می‌تواند بخشی از روابط معنایی میان واژگان را از طریق الگوهای هم‌وقوعی آنها در پیکره آموزشی یاد بگیرد.[۸۱]

در این روش، هر واژه w به یک بردار عددی با ابعاد ثابت نگاشت می‌شود:

$$w \rightarrow v_w \in \mathbb{R}^d$$

که در پژوهش حاضر مقدار $d = ۱۰۰$ در نظر گرفته شده است. بنابراین، خروجی Word۲Vec برای هر واژه یک بردار ۱۰۰ بعدی است.

نمایش برداری یادگرفته‌شده توسط Word۲Vec حاصل آموزش یک شبکه عصبی کم‌عمق بر روی توالی واژگان موجود در پیکره است. برخلاف روش‌های مبتنی بر Transformer ، این مدل دارای معماری عمیق و چندلایه نیست و در نتیجه فرآیند آموزش و تولید بردار آن از نظر محاسباتی سبک‌تر است.[۸۲]

دو معماری اصلی برای Word۲Vec معرفی شده است:

۱. CBOW[۱] که تلاش می‌کند واژه هدف را بر اساس واژگان اطراف آن پیش‌بینی کند؛

۲. Skip-Gram که برعکس، با استفاده از واژه هدف تلاش می‌کند واژگان موجود در بافت اطراف آن را پیش‌بینی نماید .

در پژوهش حاضر، معماری Skip-Gram با تنظیم پارامتر sg=۱ انتخاب شده است. این انتخاب به این معناست که مدل به جای پیش‌بینی یک واژه بر اساس زمینه، تلاش می‌کند رابطه میان هر واژه و واژگان مجاور آن را یاد بگیرد. این ویژگی می‌تواند برای یادگیری روابط میان واژگان، به‌خصوص در پیکره‌هایی که اندازه آنها متوسط است، مفید باشد.[۸۳]

---

۱. Continuous Bag of Words

همچنین، پارامتر window=۵ در مدل مورد استفاده قرار گرفته است. این پارامتر تعیین می‌کند که مدل در هنگام یادگیری روابط واژگان، تا پنج واژه در اطراف واژه هدف را به‌عنوان زمینه در نظر بگیرد. بنابراین، یادگیری بردار هر واژه صرفاً بر اساس خود آن واژه انجام نمی‌شود، بلکه روابط آن با واژگان پیرامونی نیز در فرآیند آموزش وارد می‌شود.

به‌صورت مفهومی، هدف Word۲Vec را می‌توان به شکل زیر بیان کرد:

$$P(w_c \mid w_t)$$

که در آن w_t واژه هدف و w_c یکی از واژگان موجود در بافت اطراف آن است. مدل تلاش می‌کند پارامترهای برداری خود را به‌گونه‌ای تنظیم کند که احتمال مشاهده واژگان زمینه در کنار واژه هدف افزایش یابد.[۸۴]

یکی از مسائل اساسی استفاده از Word۲Vec در طبقه‌بندی متن این است که Word۲Vec در حالت پایه، برای هر واژه یک بردار تولید می‌کند، در حالی که مدل طبقه‌بندی در مرحله بعد به یک بردار ثابت برای هر سند نیاز دارد.

فرض کنیم سند d شامل n واژه باشد:

$$d = \{w_۱, w_۲, \dots, w_n\}$$

و بردار Word۲Vec مربوط به هر واژه برابر باشد با:

$$v_{w_i} \in \mathbb{R}^{۱۰۰}$$

برای تبدیل مجموعه این بردارها به یک بردار واحد برای کل سند، در پژوهش حاضر از میانگین‌گیری برداری استفاده شده است:

$$v_d = \frac{۱}{n} \sum_{i=۱}^{n} v_{w_i}$$

در نتیجه، صرف‌نظر از اینکه یک سند دارای چند واژه باشد، خروجی نهایی همیشه یک بردار ۱۰۰بعدی خواهد بود:

$$d \rightarrow v_d \in \mathbb{R}^{۱۰۰}$$

این روش که معمولاً با عنوان جاسازی کلمه-معنی[۱] واژگان شناخته می‌شود، یک روش ساده و مؤثر برای تبدیل تعبیه کردن[۲]های سطح واژه به سطح سند است.

---

۱. Mean Word Embedding
۲. Embedding

در این تابع ابتدا بردار هر واژه‌ای که در واژگان Word۲Vec وجود داشته باشد استخراج می‌شود. سپس، بردارهای حاصل در امتداد تمام واژگان سند میانگین‌گیری می‌شوند. بنابراین، ترتیب دقیق واژگان در مرحله تشکیل بردار نهایی سند مستقیماً حفظ نمی‌شود، اما اطلاعات توزیعی و معنایی آموخته‌شده برای واژگان در نمایش نهایی باقی می‌ماند.

در صورتی که هیچ‌یک از واژگان سند در واژگان مدل موجود نباشد، یک بردار صفر با ابعاد ۱۰۰ تولید می‌شود تا ساختار ثابت ماتریس ویژگی‌ها حفظ گردد.

در نهایت، با اعمال تابع مذکور بر تمام نمونه‌ها، ماتریس ویژگی X ایجاد می‌شود:

$$X = \begin{bmatrix} v_{d_1} \\ v_{d_2} \\ \vdots \\ v_{d_N} \end{bmatrix} \in \mathbb{R}^{N \times 100}$$

که در آن N تعداد نمونه‌های موجود در مجموعه داده و ۱۰۰ تعداد ویژگی‌های نهایی هر نمونه است.[۸۶]

بنابراین، خروجی این مرحله برخلاف TF-IDF که معمولاً ماتریسی با تعداد ویژگی بسیار زیاد و ساختار اسپارس ایجاد می‌کند، یک ماتریس متراکم با ابعاد $N \times 100$ خواهد بود. این ویژگی از نظر حافظه و هزینه محاسباتی برای مراحل بعدی یادگیری ماشین اهمیت قابل‌توجهی دارد.[۸۷]

در کنار تولید ماتریس ویژگی X، متغیر هدف yنیز باید به فرم عددی تبدیل شود. در پژوهش حاضر، ستون class شامل برچسب‌های کیفی مربوط به طبقات مسئله است. برای تبدیل این برچسب‌ها به مقادیر عددی از LabelEncoder موجود در کتابخانه scikit-learn استفاده شده است. تابع fit_transform ابتدا طبقات موجود در متغیر هدف را شناسایی کرده و سپس برای هر طبقه یک مقدار عددی اختصاص می‌دهد. برای مثال، اگر دو طبقه موجود باشند، آنها به مقادیر صفر و یک نگاشت خواهند شد.

در نتیجه:

$$y_i \in \{0, 1\}$$

خواهد بود و متغیر هدف با قالب مورد نیاز الگوریتم‌های طبقه‌بندی سازگار می‌شود. همچنین، نگاشت ایجادشده توسط LabelEncoder قابل مشاهده است و با استفاده از inverse_transform می‌توان مقادیر عددی پیش‌بینی‌شده را مجدداً به برچسب‌های متنی اولیه بازگرداند.[۸۸]

انتخاب روش بردارسازی در این پژوهش صرفاً بر اساس پیچیدگی یا جدیدتر بودن یک الگوریتم انجام نشده است؛ بلکه تناسب روش با هدف پژوهش، حجم داده، منابع محاسباتی و ماهیت مسئله طبقه‌بندی متن مورد توجه قرار گرفته است.

در نسخه اولیه طراحی پژوهش، دو روش در دو انتهای طیف قرار داشتند Sentence-BERT :به‌عنوان یک روش عمیق و مبتنی بر Transformer و TF-IDF به‌عنوان یک روش آماری و بسیار ساده. بررسی این دو رویکرد نشان می‌دهد که هر یک دارای مزایا و محدودیت‌های مشخصی هستند.[۸۹،۹۰]

الف) محدودیت استفاده از Sentence-BERT

Sentence-BERT و مدل‌های مشابه مبتنی بر Transformer قادرند نمایش‌های معنایی قدرتمندی از جمله و متن ایجاد کنند. مکانیزم Self-Attention به این مدل‌ها اجازه می‌دهد روابط پیچیده میان بخش‌های مختلف متن را در نظر بگیرند و در بسیاری از مسائل NLP عملکرد بسیار مطلوبی ارائه کنند.[۹۱]

با این حال، این توانایی با هزینه محاسباتی بیشتری همراه است. تولید embedding برای حجم زیادی از متن نیازمند اجرای شبکه عصبی عمیق و محاسبات ماتریسی قابل‌توجه است. این مسئله به‌ویژه زمانی اهمیت پیدا می‌کند که هدف پژوهش اجرای آزمایش‌های متعدد با چندین الگوریتم طبقه‌بندی و تقسیم‌بندی‌های مختلف داده باشد.[۹۲]

علاوه بر این، در پژوهش حاضر داده‌ها چندزبانه هستند و استفاده از یک مدل Transformer خاص می‌تواند وابستگی قابل‌توجهی به زبان، حوزه متنی و کیفیت مدل از پیش‌آموزش‌دیده ایجاد کند [۹۳]. بنابراین، اگرچه Sentence-BERT از نظر توانایی استخراج ویژگی‌های معنایی بسیار قدرتمند است، اما پیچیدگی آن برای نیاز فعلی پژوهش بیش از حد مورد نیاز ارزیابی شد.

به عبارت دیگر، مسئله اصلی این نبود که Sentence-BERT روش ضعیفی است؛ برعکس، قدرت آن یکی از دلایل اصلی هزینه بالاتر آن است .هدف پژوهش یافتن روشی بود که با هزینه محاسباتی کمتر، اطلاعات معنایی قابل قبولی را حفظ کند.

ب) محدودیت استفاده از TF-IDF

در طرف دیگر، TF-IDF یک روش بسیار ساده، سریع و قابل‌تفسیر است که بر اساس فراوانی واژگان در سند و میزان پراکندگی آنها در کل پیکره، وزن هر واژه را تعیین می‌کند.[۹۴]

فرمول کلی آن را می‌توان به صورت زیر بیان کرد:

$$TFIDF(t,d,D) = TF(t,d) \times IDF(t,D)$$

که در آن TF میزان حضور واژه t در سند d و IDF میزان تمایزدهندگی آن واژه در کل مجموعه اسناد را نشان می‌دهد.[۹۵]

مزیت مهم TF-IDF ، هزینه محاسباتی پایین آن است. با این حال، این روش فاقد یک مدل یادگیری معنایی از روابط میان واژگان است. برای مثال، واژه‌هایی مانند «ناامیدی»، «یأس» و «بی‌انگیزگی» ممکن است از نظر مفهومی به یکدیگر مرتبط باشند، اما TF-IDF بدون اطلاعات معنایی خارجی، صرفاً آنها را به‌عنوان ویژگی‌های مستقلی در نظر می‌گیرد.[۹۶]

از طرف دیگر، افزایش تعداد واژگان باعث می‌شود تعداد ویژگی‌های ماتریس TF-IDF نیز افزایش یابد. بنابراین، برای یک مجموعه داده متنی با واژگان متنوع، ماتریسی با ابعاد بالا و اغلب بسیار پراکنده ایجاد می‌شود [۹۷]. چنین ساختاری می‌تواند هزینه ذخیره‌سازی و پردازش را افزایش داده و استفاده از برخی الگوریتم‌های یادگیری ماشین را پیچیده‌تر کند.[۹۸]

بررسی این دو روش نشان می‌دهد که Sentence-BERT و TF-IDF عملاً دو انتهای متفاوت یک طیف را نشان می‌دهند.

از یک سو، Sentence-BERT دارای توانایی معنایی بسیار بالا و پیچیدگی محاسباتی قابل‌توجه است؛ از سوی دیگر، TF-IDF دارای پیچیدگی بسیار پایین اما توانایی محدود در یادگیری روابط معنایی است.

Word۲Vecدر این میان یک نقطه تعادل ایجاد می‌کند:

TF-IDF ⟶ Word۲Vec ⟶ Sentence-BERT

از نظر مفهومی، TF-IDFعمدتاً به این پرسش پاسخ می‌دهد که: "کدام واژه در این سند مهم‌تر است؟" در حالی که Word۲Vecعلاوه بر حضور واژه، تلاش می‌کند یاد بگیرد: "این واژه از نظر کاربرد و بافت زبانی به چه واژه‌هایی شبیه است؟" و Sentence-BERT یک گام فراتر رفته و می‌تواند: "معنای کل جمله در بافت آن چیست؟" را مدل‌سازی کند.

بنابراین، Word۲Vec برای پژوهش حاضر یک راه‌حل میانی از نظر پیچیدگی و قدرت نمایش محسوب می‌شود. این روش، برخلافTF-IDF ، قادر به یادگیری نمایش توزیعی واژگان است و در عین حال، برخلاف مدل‌های مبتنی برTransformer ، به معماری عمیق و محاسبات سنگین وابسته نیست.[۹۹]

مهم‌ترین دلایل انتخاب Word۲Vec را می‌توان به شرح زیر بیان کرد:

- در پژوهش حاضر هر سند در نهایت با یک بردار ۱۰۰بعدی نمایش داده می‌شود. بنابراین، ماتریس ویژگی دارای ابعاد مشخص و نسبتاً کوچک $N \times ۱۰۰$است. این موضوع می‌تواند فرآیند آموزش الگوریتم‌های طبقه‌بندی را ساده‌تر و سریع‌تر کند.
- Word۲Vec به جای اختصاص یک ویژگی مستقل و بدون ارتباط معنایی به هر واژه، بردارهایی را بر اساس بافت استفاده از واژگان یاد می‌گیرد. در نتیجه، واژه‌هایی که در زمینه‌های مشابه استفاده می‌شوند، می‌توانند در فضای برداری دارای موقعیت‌های نزدیک‌تری باشند [۱۰۰].
- Word۲Vecیک شبکه عصبی کم‌عمق است و در مقایسه با مدل‌های مبتنی برTransformer ، منابع محاسباتی بسیار کمتری برای آموزش و تولید embedding نیاز دارد.[۱۰۱]
- یکی از ویژگی‌های مهم پیاده‌سازی حاضر این است که Word۲Vec مستقیماً بر روی متون موجود در دیتاست پژوهش آموزش داده می‌شود. بنابراین، فضای برداری تولیدشده به الگوهای زبانی موجود در همین پیکره وابسته است و برخلاف استفاده مستقیم از یک مدل embedding از پیش‌آموزش‌دیده، نیازمند اتکا به دامنه آموزشی خارجی نیست.

- در این پژوهش لازم است مراحل مختلف طبقه‌بندی و ارزیابی مدل‌ها با هزینه محاسباتی قابل‌کنترل انجام شوند. استفاده از embedding های ۱۰۰بعدی Word۲Vec امکان اجرای سریع‌تر این آزمایش‌ها را فراهم می‌کند.
- میانگین‌گیری بردارهای واژگان سبب می‌شود تمام اسناد، مستقل از طول آنها، به یک بردار ثابت با ۱۰۰ ویژگی تبدیل شوند. این موضوع باعث می‌شود ماتریس Xساختاری یکپارچه و مناسب برای الگوریتم‌های طبقه‌بندی داشته باشد.

با وجود مزایای مذکور، Word۲Vec نیز محدودیت‌هایی دارد که باید در تفسیر نتایج پژوهش مورد توجه قرار گیرند.

نخست آنکه Word۲Vec در شکل استاندارد خود، بردار ثابتی برای هر واژه ایجاد می‌کند. بنابراین، برخلاف مدل‌های contextual مانندBERT ، یک واژه چندمعنا در بافت‌های مختلف الزاماً نمایش‌های متفاوتی دریافت نمی‌کند [۱۰۲]. برای مثال، اگر یک واژه در دو جمله با معانی متفاوت استفاده شود، Word۲Vec استاندارد یک بردار واحد برای آن واژه خواهد داشت.

دوم آنکه روش میانگین‌گیری مورد استفاده برای تولید بردار سند، ترتیب واژگان را مستقیماً در بردار نهایی حفظ نمی‌کند. به بیان دیگر، سند از مجموعه‌ای ازembedding های واژگان تشکیل شده و میانگین آنها محاسبه می‌شود:

$$v_d = \frac{۱}{n}\sum_{i=۱}^{n} v_{w_i}$$

در نتیجه، اطلاعات مربوط به ترتیب نحوی واژگان و برخی وابستگی‌های بلندمدت در فرآیند تشکیل بردار سند از بین می‌رود.

این محدودیت در مقایسه با Transformer قابل توجه است؛ زیرا مدل‌هایی مانند BERT می‌توانند وابستگی‌های پیچیده و روابط بلندمدت میان اجزای جمله را مدل‌سازی کنند [۱۰۳]. با این حال، این کاهش توانایی در پژوهش حاضر آگاهانه پذیرفته شده است؛ زیرا هدف از انتخاب Word۲Vec دستیابی به تعادلی مناسب میان کیفیت نمایش، سرعت پردازش و هزینه محاسباتی بوده است.

۲-۳-۶ معیارهای ارزیابی عملکرد مدل‌ها

برای دستیابی به پیشبینیهای قابل اطمینان از مدلها، نیاز به ارزیابی عملکردی دقیق و نظاممند است. این فرایند، تأثیر مراحل پیشپردازش (مانند پاکسازی دادهها و توکنسازی) را کمّی میسنجد، امکان مقایسهٔ مدلها را فراهم میآورد، و راهنمای بهبود تدریجی آنهاست. اگرچه پیچیدگی طبقهبندیکنندهها میتواند از رگرسیون لجستیک تا یادگیری عمیق متغیر باشد، معیارهای هستهای ارزیابی همواره یکسان باقی میمانند. برای طبقهبندیکنندههای پارامتریک، انتخاب معیار بستگی به توزیع دادهها و هدف مطالعه دارد. معیارهای رایج شامل دقت کلی[۱] ، دقت مثبت[۲] ، حساسیت یا بازیابی [۳]، مساحت زیر نمودار[۴] و نمرهٔ F۱[۵] هستند.

همانگونه که پیشتر تشریح شد، رویکرد ما مبتنی بر یادگیری نظارتشده است، که در آن مدل بر روی یک مجموعهدادهٔ برچسبگذاریشده آموزش داده میشود. این امر به مدل امکان میدهد تا بر اساس الگوهای آموختهشده در طول آموزش، برای ورودیهای جدید و دیدهنشده، پیشبینی تولید کند. بهطور معمول، ۷۰ تا ۸۰ درصد از مجموعهداده به آموزش اختصاص مییابد و ۲۰ تا ۳۰ درصد باقیمانده برای ارزیابی عملکرد مدل در نظر گرفته میشود. در مرحلهٔ ارزیابی، پیشبینیهای مدل با برچسبهای واقعی مقایسه میشوند که حاصل آن چهار نوع برآیند ممکن است: مثبت درست(TP) ، منفی درست(TN) ، مثبت کاذب (FP) و منفی کاذب (FN)این چهار دسته، بنیان محاسبهٔ شاخصهای کلیدی عملکرد مانند دقت کلی، دقت مثبت، حساسیت و معیارهای وابسته را تشکیل میدهند که در زیر به تفصیل آمده است:

$$\text{دقت کلی (Accuracy)} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{دقت مثبت (Precision)} = \frac{TP}{TP + FP}$$

$$\text{حساسیت یا بازیابی (Recall)} = \frac{TP}{TP + FN}$$

$$\text{نمرهٔ F۱ (F۱-Score)} = \frac{۲ \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

---

۱. Accuracy
۲. Precision
۳. Recall
۴. AUC-ROC
۵. F۱-score

دقت کلی، صحت کلی مدل را نشان میدهد و نسبت تعداد کل پیشبینیهای صحیح به کل پیشبینیها را میسنجد. دقت مثبت، توانایی مدل در اجتناب از مثبتهای کاذب را نشان میدهد و مشخص میکند که از میان پیشبینیهای مثبت انجامشده، چه تعدادی واقعاً درست بودهاند. حساسیت یا بازیابی، از سوی دیگر، گویای قدرت تشخیص مدل است و نشان میدهد که از میان نمونههای مثبت واقعی، چه نسبتی بهدرستی شناسایی شدهاند. نمرهٔ F1 نیز معیاری متوازن است که هردو شاخص دقت مثبت و حساسیت را در یک عدد ترکیب میکند و دید جامع تری از عملکرد مدل ارائه میدهد، بهویژه در شرایطی که توزیع کلاسها نامتوازن باشد.

۲-٤ الگوریتم های یادگیری ماشین

۲-٤-۱ مبانی نظری و تاریخچه الگوریتم جنگل تصادفی[۱]

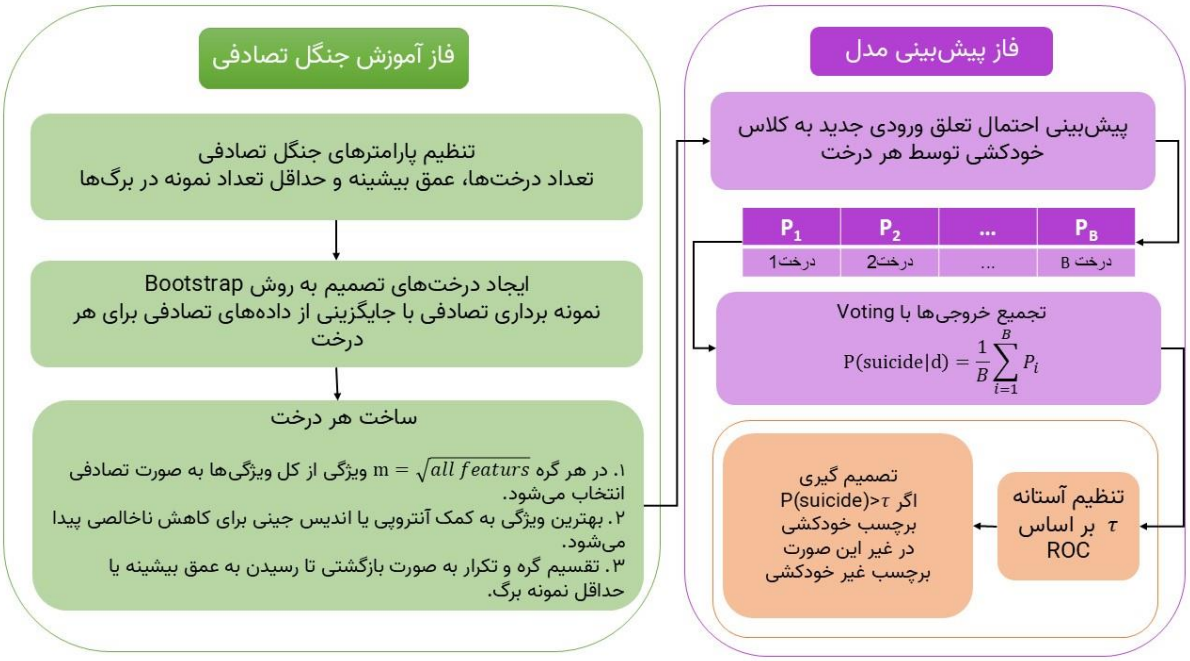
الگوریتم جنگل تصادفی که توسط لئو بریمن در سال ۲۰۰۱ معرفی شد، یکی از موفقترین روشهای یادگیری گروهی در حوزه طبقهبندی و رگرسیون محسوب میشود [۱۰۴]. با این حال، ریشههای این روش به اواسط دهه ۱۹۹۰ بازمیگردد، زمانی که هو در سال ۱۹۹۵ روش «درختان تصمیم تصادفی» را برای غلبه بر محدودیتهای پیچیدگی درختان تصمیم سنتی ارائه داد [۱۰۵]. همچنین آمیط و گیمن در سال ۱۹۹۷ رویکردی مبتنی بر درختان تصادفی برای تشخیص شکل ارائه کردند [۱۰۶]. با وجود این پیشگامیها، نقطه عطف اصلی زمانی رخ داد که بریمن در مقاله مشهور خود در سال ۲۰۰۱، نام «Random Forest» را برای این روش انتخاب کرد و آن را بهعنوان روشی معرفی نمود که عملکردی قابل مقایسه با AdaBoost دارد [۱۰۴].

الگوریتم جنگل تصادفی با ترکیب دو مفهوم کلیدی «بگینگ» و «انتخاب تصادفی زیرفضاهای ویژگی» در هر گره درخت، موفق به ایجاد تنوع قابلتوجهی میان درختهای تصمیم خود میشود که این تنوع، عامل اصلی دقت بالای آن محسوب میشود.

---

۱. Random Forest

جنگل تصادفی مجموعه‌ای از درخت‌های تصمیم است که هر یک بر روی نمونه‌ای bootstrap شده از داده‌های آموزشی ساخته می‌شوند [۱۰۴]. در فرآیند ساخت هر درخت، به‌جای بررسی تمام ویژگی‌ها در هر گره برای یافتن بهترین تقسیم، تنها زیرمجموعه‌ای تصادفی از ویژگی‌ها مورد بررسی قرار می‌گیرد و بهترین تقسیم بر اساس معیار ناخالصی جینی[۱] یا آنتروپی انتخاب می‌شود [۱۰۸]. این تصادفی‌سازی دوگانه (تصادفی بودن نمونه‌ها و تصادفی بودن ویژگی‌ها) باعث می‌شود درخت‌های ساخته‌شده با یکدیگر همبستگی کمی داشته باشند و در نتیجه، میانگین‌گیری از پیش‌بینی‌های آن‌ها به کاهش واریانس و افزایش دقت کلی منجر شود [۱۰۹]. قاعده نهایی تصمیم‌گیری در جنگل تصادفی به این صورت است که هر درخت به یک کلاس رأی می‌دهد و کلاسی که اکثریت آرا را کسب کند، به‌عنوان خروجی نهایی انتخاب می‌شود [۱۰۴]. این مکانیسم رأی‌دهی سخت که مبتنی بر اکثریت ساده است، هسته اصلی عملکرد این الگوریتم را تشکیل می‌دهد [۱۱۰].



شکل ۲-۳: فلوچارت الگوریتم جنگل تصادفی

در طبقه‌بندی دودویی با استفاده از جنگل تصادفی ، مشابه سایر الگوریتم‌های یادگیری ماشین، آستانه تصمیم‌گیری به‌صورت پیش‌فرض برابر با ۰/۵ در نظر گرفته می‌شود؛ به این معنا که اگر نسبت درختانی که به کلاس مثبت رأی داده‌اند از ۵۰ درصد بیشتر باشد، نمونه به آن کلاس نسبت داده می‌شود [۱۱۱]. با این حال، پژوهش‌های متعدد نشان داده‌اند که این آستانه ثابت در بسیاری از کاربردهای واقعی، به‌ویژه زمانی که داده‌ها نامتوازن هستند، بهینه نیست [۱۱۲]. در حوزه تشخیص متون خودکشی که با نرخ بسیار پایین نمونه‌های مثبت (کلاس خودکشی) مواجه هستیم، آستانه پیش‌فرض ۰/۵ معمولاً به پیش‌بینی بیش‌ازحد کلاس اکثریت (غیرخودکشی) منجر می‌شود و در نتیجه، نرخ تشخیص نمونه‌های خودکشی (حساسیت یا recall) به‌شدت کاهش می‌یابد [۱۱۳]. پژوهش‌ها نشان داده‌اند که تنظیم آستانه تصمیم، راهبردی مؤثر برای مقابله با چالش داده‌های نامتوازن است که نیاز به بازآموزی مدل یا نمونه‌برداری مجدد از داده‌ها ندارد [۱۱۴].

---

۱. Gini impurity

در این پژوهش، به منظور افزایش انعطاف‌پذیری و کارایی مدل جنگل تصادفی در تشخیص متون خودکشی، پارامتر آستانه تصمیم قابل تنظیم برای کلاس هدف معرفی شده است [۱۱۵]. بر این اساس، یک نمونه تنها در صورتی به کلاس «خودکشی» نسبت داده می‌شود که نسبت درختانی که به این کلاس رأی داده‌اند (که معادل احتمال برآوردشده برای کلاس هدف است) از آستانه مشخص‌شده θ بیشتر باشد.

انتخاب مقدار بهینه برای θ با استفاده از روش‌های جستجوی شبکه‌ای بر روی مجموعه اعتبارسنجی انجام می‌شود و معیارهای F1 و حساسیت به عنوان توابع هدف در نظر گرفته می‌شوند [۱۱۶]. با کاهش آستانه، حساسیت مدل افزایش یافته و نمونه‌های بیشتری به عنوان خودکشی تشخیص داده می‌شوند که می‌تواند به کاهش خطای منفی کاذب کمک کند، هرچند به بهای افزایش خطای مثبت کاذب [۱۱۷]. برعکس، با افزایش آستانه، مدل محافظه‌کارتر شده و تنها نمونه‌هایی را که با اطمینان بالایی به کلاس هدف تعلق دارند، تشخیص می‌دهد که برای سناریوهایی که نیاز به قطعیت بالا دارند، مناسب است [۱۱۸].

برای تعیین آستانه بهینه در مدل جنگل تصادفی ، از رویکردهای مختلفی استفاده شده است. اولین رویکرد، استفاده از منحنی مشخصه عملکرد سیستم (ROC) است که رابطه بین نرخ مثبت واقعی و نرخ مثبت کاذب را در آستانه‌های مختلف نشان می‌دهد و نقطه برش بهینه بر اساس معیارهایی مانند فاصله از نقطه (۰,۱) در فضای ROC انتخاب می‌شود [۱۱۹]. رویکرد دوم، بهینه‌سازی معیار F1 است که هارمونیک میانگین دقت و حساسیت محسوب می‌شود و برای داده‌های نامتوازن مناسب‌تر از دقت کلی است [۱۲۰]. پژوهش‌های تجربی نشان داده‌اند که تنظیم آستانه می‌تواند بهبود قابل‌توجهی در عملکرد مدل ایجاد کند؛ به‌گونه‌ای که در برخی موارد، معیار F1 تا بیش از ۴۰٪ بهبود یافته است [۱۲۱]. در کاربرد تشخیص خودکشی با استفاده از داده‌های توییتر، مدل جنگل تصادفی موفق به دستیابی به دقت ۹۵/۱٪ و F1-Score معادل ۹۵/۱٪ شده است که بیانگر کارایی بالای این الگوریتم در این حوزه است [۱۲۲]. با این حال، پژوهشگران تأکید دارند که بهینه‌سازی آستانه باید بر روی داده‌های اعتبارسنجی انجام شود و سپس بر روی داده‌های تست اعمال گردد تا از بروز بیش‌برازش[۱] جلوگیری شود [۱۲۳]. در نهایت، با توجه به ماهیت حساس تشخیص خودکشی، ترکیب جنگل تصادفی با تنظیم آستانه پویا، امکان کنترل تعادل بین دقت و حساسیت را فراهم می‌آورد و سیستم را برای کاربردهای عملی که نیاز به اولویت‌بندی بر اساس هزینه خطاها دارند، انعطاف‌پذیر می‌سازد [۱۲۴].

---

۱. overfitting

نتایج به‌دست‌آمده از الگوریتم جنگل تصادفی نشان‌دهنده عملکرد مطلوب این مدل در طبقه‌بندی متون مرتبط با خودکشی است. مدل با دستیابی به دقت کلی ۹۲/۳۰۶۳٪ توانسته است عملکرد قابل‌توجهی در تفکیک دو کلاس «غیرخودکشی» و «خودکشی» ارائه دهد. همچنین مقدار ۹۷/۵۶۹۱٪ برای معیار AUC-ROC نشان‌دهنده توانایی بسیار مناسب مدل در تفکیک دو کلاس و تمایز میان نمونه‌های خودکشی و غیرخودکشی است.

بررسی عملکرد مدل در سطح هر کلاس نیز بیانگر توازن مناسبی میان معیارهای Precision، Recall و F1-score است. در کلاس غیرخودکشی (کلاس ۰)، مقدار Precision برابر با ۰/۹۲ و Recall برابر با ۰/۹۳ به‌دست آمده است. بنابراین، مدل توانسته است ۹۳٪ از نمونه‌های واقعی این کلاس را به‌درستی شناسایی کند و در عین حال، ۹۲٪ از نمونه‌هایی را که به‌عنوان غیرخودکشی طبقه‌بندی کرده، به‌درستی در این کلاس قرار دهد. مقدار F1-score برابر با ۰/۹۲ نیز نشان‌دهنده توازن مطلوب میان Precision و Recall در این کلاس است.

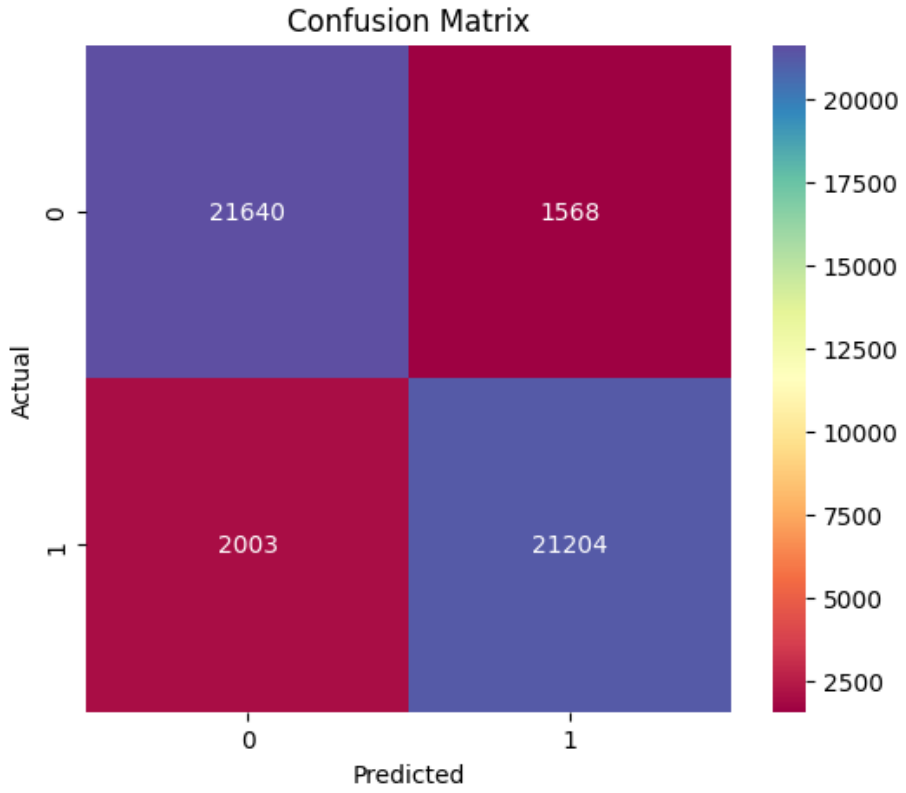
در کلاس خودکشی (کلاس ۱)، که به دلیل ماهیت پژوهش از اهمیت ویژه‌ای برخوردار است، مدل Precision برابر با ۰/۹۳ و Recall برابر با ۰/۹۱ را به دست آورده است. مقدار Recall برابر با ۰/۹۱ بیانگر آن است که مدل توانسته است ۹۱٪ از نمونه‌های واقعی خودکشی را به‌درستی شناسایی کند. این مقدار در مقایسه با Recall برابر با ۰/۶۲ در نتایج قبلی، بهبود قابل‌توجهی را نشان می‌دهد و حاکی از کاهش چشمگیر تعداد نمونه‌های خودکشی است که توسط مدل به‌اشتباه در کلاس غیرخودکشی قرار گرفته‌اند. از سوی دیگر، Precision برابر با ۰/۹۳ نشان می‌دهد که بخش عمده‌ای از نمونه‌هایی که مدل به‌عنوان خودکشی شناسایی کرده است، واقعاً متعلق به این کلاس بوده‌اند. در نتیجه، F1-score برابر با ۰/۹۲ نشان‌دهنده عملکرد متوازن مدل در شناسایی کلاس هدف است.

مقایسه معیارهای دو کلاس نشان می‌دهد که اختلاف عملکرد مدل میان کلاس خودکشی و غیرخودکشی بسیار محدود است. Recall مدل برای دو کلاس به‌ترتیب ۰/۹۱ و ۰/۹۳ و F1-score برای هر دو کلاس برابر با ۰/۹۲ گزارش شده است. این نزدیکی مقادیر معیارها نشان می‌دهد که مدل برخلاف نتایج قبلی، سوگیری قابل‌توجهی به سمت کلاس غیرخودکشی نشان نمی‌دهد و قادر است هر دو کلاس را با سطح عملکرد تقریباً یکسانی شناسایی کند. همچنین مقدار Precision بالاتر برای کلاس خودکشی (۰/۹۳ در مقابل ۰/۹۲) نشان‌دهنده دقت مناسب مدل در پیش‌بینی نمونه‌های متعلق به کلاس هدف است.

معیارهای کلی مدل نیز این یافته‌ها را تأیید می‌کنند. دقت کلی مدل برابر با ۹۲/۳۰۶۳٪، Precision برابر با ۹۲/۳۲۱۲٪، Recall برابر با ۹۲/۳۰۶۳٪ و F1-score برابر با ۹۲/۳۰۵۶٪ به‌دست آمده است. نزدیکی بسیار زیاد این معیارها به یکدیگر نشان می‌دهد که عملکرد مدل در مراحل مختلف ارزیابی نسبتاً متوازن بوده و افزایش دقت کلی صرفاً ناشی از عملکرد مناسب در یکی از معیارها یا یکی از کلاس‌ها نیست. به بیان دیگر، مدل توانسته است هم‌زمان Precision و Recall بالایی ایجاد کند و در نتیجه عملکرد متوازنی در طبقه‌بندی داده‌ها داشته باشد.

از منظر کاربردی، افزایش Recall کلاس خودکشی به ۰/۹۱ اهمیت ویژه‌ای دارد؛ زیرا در سامانه‌های تشخیص خطر خودکشی، از دست دادن یک نمونه واقعاً خودکشی و طبقه‌بندی آن به‌عنوان نمونه غیرخودکشی می‌تواند پیامدهای جدی‌تری نسبت به ایجاد یک هشدار کاذب داشته باشد [۱۰۷][۱۰۸]. بنابراین، عملکرد فعلی جنگل تصادفی از این منظر نسبت به نتایج قبلی بهبود محسوسی

یافته است. در شرایط فعلی، مدل علاوه بر حفظ Precision بالا، توانسته است بخش عمده‌ای از نمونه‌های واقعی خودکشی را نیز شناسایی کند و بدین ترتیب، تعادل مناسب‌تری میان کاهش خطاهای مثبت کاذب و منفی کاذب ایجاد نماید.



شکل۲-۴ماتریس سردرگمی جنگل تصادفی

	Lable	Precision	Recall	F۱-score	Support
	غیر خودکشی	۰.۹۲	۰.۹۳	۰.۹۲	۲۳۲۰۷
	خودکشی	۰.۹۳	۰.۹۱	۰.۹۲	۲۳۲۰۷
	Accuracy	**Precision(%)**	**Recall(%)**	**F۱-score(%)**	**AUC-ROC**
overall	۹۲.۳۰۶۳	۹۲.۳۲۱۲	۹۲.۳۰۶۳	۹۲.۳۰۵۶	۹۷.۵۶۹۱

جدول ۲-۱

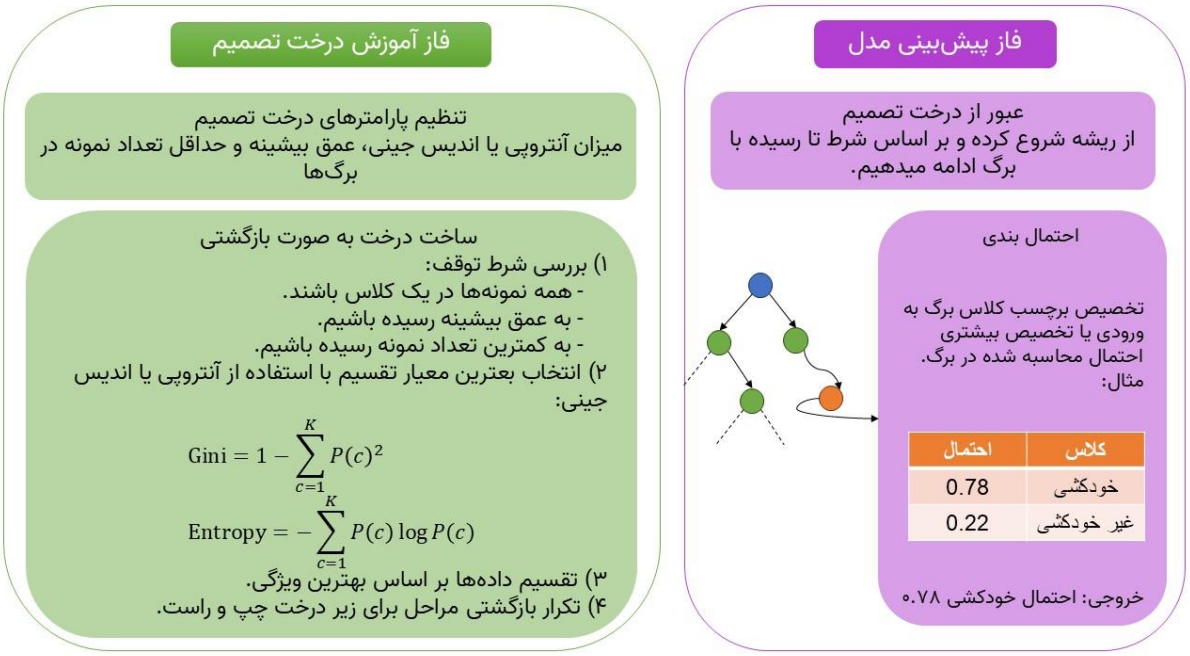
۲-٤-۲ مبانی نظری و تاریخچه الگوریتم درخت تصمیم[۱]

الگوریتم درخت تصمیم یکی از قدیمی‌ترین و پرکاربردترین الگوریتم‌های یادگیری ماشین نظارت‌شده است که ریشه‌های آن به دهه ۱۹۶۰ بازمی‌گردد [۱۲۵] . اولین پژوهش‌های سیستماتیک در این حوزه توسط هانت و همکاران در سال ۱۹۶۶ انجام شد که روش «سیستم یادگیری مفهوم» [۲]را برای استخراج قوانین طبقه‌بندی از داده‌ها ارائه دادند [۱۲۶] . با این حال، نقطه عطف اصلی در توسعه الگوریتم‌های درخت تصمیم، معرفی الگوریتم ID۳ توسط کوئینلان در سال ۱۹۸۶ بود که از معیار افزایش اطلاعات [۳] برای انتخاب بهترین ویژگی در هر گره استفاده می‌کرد [۱۲۷] . سپس کوئینلان در سال ۱۹۹۳ الگوریتم C۴٫۵ را به‌عنوان نسخه بهبودیافته ID۳ ارائه داد که قابلیت کار با ویژگی‌های پیوسته و داده‌های گم‌شده را نیز دارا بود [۱۲۸] . تقریباً هم‌زمان، بریمن و همکاران در سال ۱۹۸۴ الگوریتم [۴] را معرفی کردند که از معیار ناخالصی جینی [۵] برای تقسیم‌بندی گره‌ها استفاده می‌کرد و قابلیت انجام هر دو کار طبقه‌بندی و رگرسیون را داشت [۱۲۹] . این سه الگوریتم (ID۳، C۴٫۵ و CART) تا به امروز به‌عنوان پایه‌گذار اصلی درخت‌های تصمیم شناخته می‌شوند و پیاده‌سازی‌های مدرن این الگوریتم در کتابخانه‌هایی مانند scikit-learn از نسخه بهبودیافته CART استفاده می‌کنند [۱۳۰] .

درخت تصمیم یک ساختار درختی است که از گره‌های تصمیم[۶]، شاخه‌ها[۷] و گره‌های برگ[۸] تشکیل شده است [۱۳۱] . هر گره داخلی نشان‌دهنده یک ویژگی (یا صفت) از داده است، هر شاخه نشان‌دهنده یک مقدار ممکن برای آن ویژگی است و هر گره برگ نشان‌دهنده یک کلاس یا برچسب نهایی است [۱۳۲] . فرآیند ساخت درخت تصمیم به‌صورت بازگشتی انجام می‌شود: در هر گره، بهترین ویژگی برای تقسیم‌بندی داده‌ها انتخاب می‌شود و داده‌ها بر اساس مقادیر آن ویژگی به زیرمجموعه‌های کوچک‌تری تقسیم می‌شوند [۱۳۳] . این فرآیند تا زمانی ادامه می‌یابد که تمام نمونه‌های یک گره به یک کلاس تعلق داشته باشند، یا تعداد نمونه‌های باقی‌مانده از یک آستانه مشخص کمتر شود، یا عمق درخت به حداکثر مجاز برسد [۱۲۹] . معیارهای مختلفی برای انتخاب بهترین ویژگی وجود دارد که از جمله مهم‌ترین آن‌ها می‌توان به ناخالصی جینی، افزایش اطلاعات و نسبت افزایش اطلاعات اشاره کرد [۱۲۷و ۱۲۸و ۱۲۹] . پس از ساخت درخت، فرآیند طبقه‌بندی یک نمونه جدید به این صورت انجام می‌شود که از گره ریشه شروع کرده و با پیروی از شاخه‌های مربوط به مقادیر ویژگی‌های نمونه، تا رسیدن به یک گره برگ حرکت می‌کنیم و کلاس آن گره برگ را به‌عنوان خروجی نهایی در نظر می‌گیریم [۱۳۴] .

---

۱. Decision Tree
۲. Concept Learning System
۳. Information Gain
۴. CART (Classification and Regression Trees)
۵. Gini impurity
۶. decision nodes
۷. branches
۸. leaf nodes



شکل۲-۵: فلوچارت الگوریتم درخت تصمیم

درخت‌های تصمیم دارای مزایای متعددی هستند که آن‌ها را به یکی از محبوب‌ترین الگوریتم‌های یادگیری ماشین تبدیل کرده است [۱۳۵] . اولین و مهم‌ترین مزیت، قابلیت تفسیرپذیری بالای آن‌هاست؛ درخت‌های تصمیم به‌راحتی قابل بصری‌سازی و درک هستند و قوانین استخراج‌شده از آن‌ها برای انسان قابل فهم می‌باشد [۱۳۶] . دومین مزیت، نیاز کم به پیش‌پردازش داده‌هاست؛ درخت‌های تصمیم نیازی به نرمال‌سازی یا استانداردسازی داده‌ها ندارند و می‌توانند با ویژگی‌های اسمی و عددی به‌طور هم‌زمان کار کنند [۱۳۰] . سومین مزیت، سرعت بالای آموزش و طبقه‌بندی است که این الگوریتم را برای کاربردهای بلادرنگ مناسب می‌سازد [۱۳۷] . با این حال، درخت‌های تصمیم دارای معایبی نیز هستند که مهم‌ترین آن‌ها، تمایل به بیش‌برازش[۱] است؛ به این معنا که درخت ممکن است داده‌های آموزشی را به‌خوبی یاد بگیرد اما بر روی داده‌های جدید عملکرد ضعیفی داشته باشد [۱۳۸] . برای مقابله با این مشکل، از روش‌های هرس کردن[۲] استفاده می‌شود که شامل هرس پیش‌گیرانه[۳] با محدود کردن عمق درخت یا تعداد نمونه‌های هر گره، و هرس پس‌ازساخت[۴] است که در آن شاخه‌های غیرضروری پس از ساخت کامل درخت حذف می‌شوند [۱۳۹]

---

۱. overfitting
۲. pruning
۳. pre-pruning
۴. post-pruning

در طبقه‌بندی دودویی با استفاده از درخت تصمیم، هر نمونه در نهایت به یک گره برگ می‌رسد که شامل تعدادی نمونه از کلاس مثبت و کلاس منفی است [۱۴۰]. کلاس اکثریت در آن گره برگ به‌عنوان برچسب نهایی انتخاب می‌شود؛ این مکانیسم در واقع معادل استفاده از یک آستانه تصمیم ۰/۵ است، به این معنا که اگر نسبت نمونه‌های کلاس مثبت در آن گره برگ از ۵۰ درصد بیشتر باشد، نمونه به کلاس مثبت نسبت داده می‌شود، در غیر این صورت به کلاس منفی [۱۴۱]. با این حال، پژوهش‌های متعدد نشان داده‌اند که این آستانه ثابت ۰/۵ در بسیاری از کاربردهای واقعی، به‌ویژه زمانی که داده‌ها نامتوازن هستند، بهینه نیست [۱۴۲]. در حوزه تشخیص متون خودکشی که با نرخ بسیار پایین نمونه‌های مثبت (کلاس خودکشی) مواجه هستیم، آستانه پیش‌فرض ۰/۵ معمولاً به پیش‌بینی بیش‌ازحد کلاس اکثریت (غیرخودکشی) منجر می‌شود و در نتیجه، نرخ تشخیص نمونه‌های خودکشی (حساسیت یا recall) به‌شدت کاهش می‌یابد [۱۴۳]. این مسئله به‌ویژه در درخت‌های تصمیم که ذاتاً به توزیع داده‌ها حساس هستند، بیشتر خود را نشان می‌دهد [۱۴۴].

در این پژوهش، به منظور افزایش انعطاف‌پذیری و کارایی مدل درخت تصمیم در تشخیص متون خودکشی، پارامتر آستانه تصمیم قابل تنظیم برای کلاس هدف معرفی شده است [۱۴۵]. بر این اساس، یک نمونه تنها در صورتی به کلاس «خودکشی» نسبت داده می‌شود که نسبت نمونه‌های کلاس خودکشی در گره برگ مربوطه (که معادل احتمال برآوردشده برای کلاس هدف است) از آستانه مشخص‌شده θ بیشتر باشد.

برای تعیین آستانه بهینه θ، از دو رویکرد مکمل استفاده شده است. رویکرد اول، بهینه‌سازی معیار F1 است که هارمونیک میانگین دقت و حساسیت محسوب می‌شود و برای داده‌های نامتوازن مناسب‌تر از دقت کلی است [۱۴۶]. رویکرد دوم، استفاده از منحنی مشخصه عملکرد سیستم (ROC) است که رابطه بین نرخ مثبت واقعی و نرخ مثبت کاذب را در آستانه‌های مختلف نشان می‌دهد و نقطه برش بهینه بر اساس معیارهایی مانند فاصله از نقطه (۰,۱) در فضای ROC انتخاب می‌شود [۱۴۷]. پژوهش‌های تجربی نشان داده‌اند که تنظیم آستانه می‌تواند بهبود قابل‌توجهی در عملکرد مدل ایجاد کند و در کاربردهایی با داده‌های نامتوازن، معیار F1 را به‌طور چشمگیری افزایش دهد [۱۴۸]. در کاربرد تشخیص خودکشی، پژوهشگران نشان داده‌اند که ترکیب درخت تصمیم با تنظیم آستانه پویا، امکان کنترل تعادل بین دقت و حساسیت را فراهم می‌آورد و سیستم را برای کاربردهای عملی که نیاز به اولویت‌بندی بر اساس هزینه خطاها دارند، انعطاف‌پذیر می‌سازد [۱۴۹]. جالب‌توجه است که در برخی مطالعات، درخت تصمیم با وجود سادگی، توانسته است عملکردی قابل رقابت با مدل‌های پیچیده‌تر مانند جنگل تصادفی در تشخیص خودکشی داشته باشد، به‌ویژه زمانی که با تنظیم آستانه همراه شده باشد [۱۵۰].

نتایج به‌دست‌آمده از الگوریتم درخت تصمیم نشان‌دهنده عملکرد قابل‌قبول این مدل در طبقه‌بندی متون مرتبط با خودکشی است. مدل با دستیابی به دقت کلی ۸۷/۱۵۰۷٪ توانسته است بخش عمده‌ای از نمونه‌ها را به‌درستی در دو کلاس «غیرخودکشی» و «خودکشی» طبقه‌بندی کند. با این حال، مقایسه این نتیجه با عملکرد الگوریتم جنگل تصادفی نشان می‌دهد که درخت تصمیم در پیکربندی فعلی عملکرد پایین‌تری دارد؛ به‌طوری‌که دقت جنگل تصادفی برابر با ۹۲/۳۰۶۳٪ بوده و حدود ۵/۱۵ واحد درصد بیشتر از درخت تصمیم است. بنابراین، برخلاف نتایج قبلی که درخت تصمیم عملکرد بهتری از جنگل تصادفی داشت، نتایج جدید برتری جنگل تصادفی را در معیار دقت کلی نشان می‌دهد.

بررسی عملکرد مدل در سطح کلاس‌ها نشان می‌دهد که درخت تصمیم توانسته است عملکردی کاملاً متوازن میان دو کلاس ایجاد کند. در کلاس غیرخودکشی (کلاس ۰)، مقادیر Precision، Recall و F1-score همگی برابر با ۰/۸۷ به‌دست آمده‌اند. بنابراین، مدل در شناسایی نمونه‌های غیرخودکشی عملکردی مناسب داشته و توانسته است ۸۷٪ از نمونه‌های واقعی این کلاس را به‌درستی شناسایی کند. همچنین Precision برابر با ۰/۸۷ نشان می‌دهد که ۸۷٪ از نمونه‌هایی که مدل به‌عنوان غیرخودکشی پیش‌بینی کرده است، به‌درستی در این کلاس قرار گرفته‌اند.

در کلاس خودکشی (کلاس ۱) نیز هر سه معیار Precision، Recall و F1-score برابر با ۰/۸۷ گزارش شده‌اند. به‌طور ویژه، Recall برابر با ۰/۸۷ نشان می‌دهد که مدل توانسته است ۸۷٪ از نمونه‌های واقعی خودکشی را شناسایی کند. این مقدار از نظر کاربرد پژوهش حاضر اهمیت ویژه‌ای دارد؛ زیرا افزایش توانایی مدل در شناسایی نمونه‌های واقعی خودکشی موجب کاهش تعداد موارد منفی کاذب می‌شود. همچنین Precision برابر با ۰/۸۷ نشان‌دهنده آن است که بخش قابل‌توجهی از نمونه‌هایی که توسط مدل به‌عنوان خودکشی شناسایی شده‌اند، واقعاً متعلق به این کلاس بوده‌اند. در نتیجه، مقدار F1-score برابر با ۰/۸۷ بیانگر تعادل مناسب میان Precision و Recall در کلاس هدف است.

یکی از مهم‌ترین ویژگی‌های نتایج جدید، نزدیک بودن کامل عملکرد مدل در دو کلاس است. Recall برای هر دو کلاس برابر با ۰/۸۷ و F1-score نیز برای هر دو کلاس برابر با ۰/۸۷ گزارش شده است. این موضوع نشان می‌دهد که درخت تصمیم در پیکربندی جدید، برخلاف نتایج قبلی، اختلاف محسوسی در شناسایی دو کلاس ندارد. بنابراین، نمی‌توان بر اساس این نتایج شواهدی از سوگیری قابل‌توجه مدل به سمت یکی از کلاس‌ها مشاهده کرد. این یافته با برابر بودن Support دو کلاس نیز سازگار است؛ به‌طوری‌که برای هر یک از کلاس‌های غیرخودکشی و خودکشی، ۲۳۲۰۷ نمونه در مجموعه ارزیابی وجود داشته است.

معیارهای کلی مدل نیز بیانگر همین توازن هستند. Precision برابر با ۸۷/۱۵۱۹٪، Recall برابر با ۸۷/۱۵۰۷٪ و F1-score برابر با ۸۷/۱۵۰۵٪ گزارش شده‌اند. نزدیکی بسیار زیاد این سه معیار نشان می‌دهد که عملکرد مدل صرفاً متکی بر افزایش یکی از معیارهای ارزیابی نبوده و درخت تصمیم توانسته است تعادل مناسبی میان دقت پیش‌بینی و توانایی شناسایی نمونه‌های واقعی برقرار کند. این ویژگی به‌خصوص در مسئله تشخیص خودکشی اهمیت دارد، زیرا هدف تنها افزایش Accuracy نیست، بلکه شناسایی صحیح نمونه‌های پرخطر و کاهش موارد منفی کاذب نیز از اهمیت بالایی برخوردار است [۱۲۸][۱۲۹].

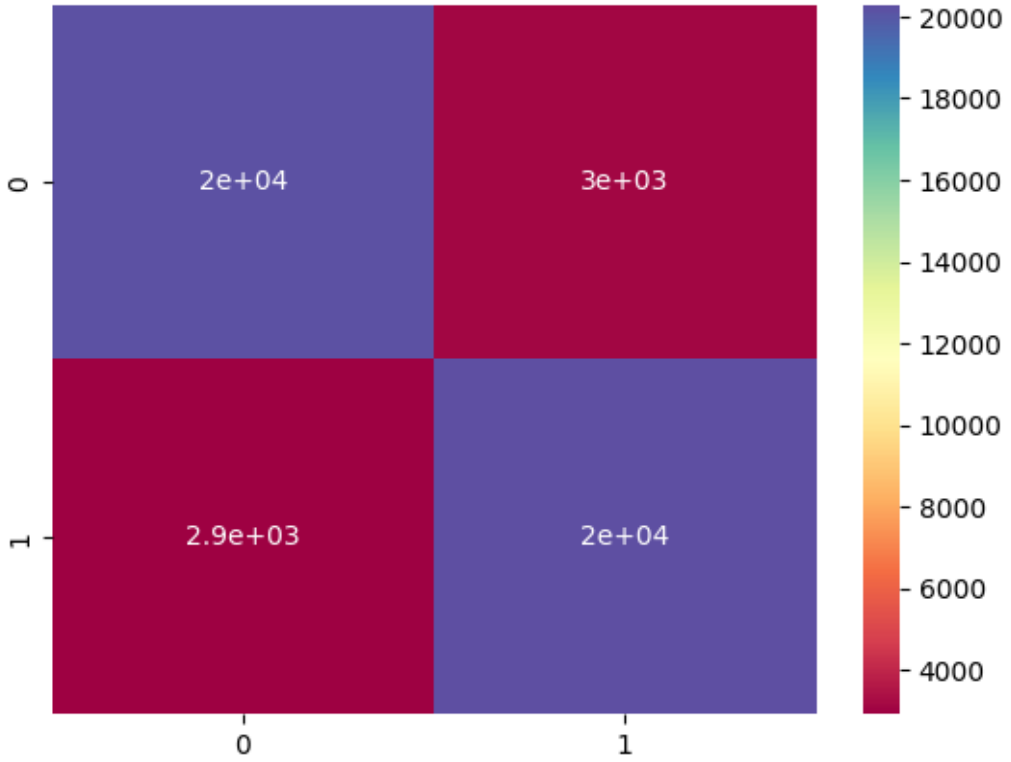
مقدار AUC-ROC برابر با ۹۷/۵۶۹۱٪ نیز نشان‌دهنده توانایی بالای مدل در تفکیک دو کلاس است. این مقدار بیانگر آن است که مدل از نظر قابلیت تفکیک نمونه‌های خودکشی و غیرخودکشی عملکرد مطلوبی دارد. با این حال، AUC-ROC بالا لزوماً به معنای آن نیست که مدل در نقطه تصمیم فعلی بهترین عملکرد ممکن را دارد؛ ازاین‌رو، ارزیابی هم‌زمان معیارهای Precision، Recall و F1-score همچنان ضروری است. در کاربردهای حساس مانند تشخیص خودکشی، انتخاب نقطه تصمیم مناسب می‌تواند با توجه به هزینه متفاوت خطاهای مثبت کاذب و منفی کاذب انجام شود [۱۲۸][۱۲۹].

در مقایسه با نتایج قبلی، بهبود قابل‌توجهی در عملکرد درخت تصمیم مشاهده می‌شود. در نتایج پیشین، Accuracy مدل برابر با ۷۶/۸۲٪ و Recall کلاس خودکشی برابر با ۰/۶۶ بود، در حالی که در نتایج جدید Accuracy به ۸۷/۱۵۰۷٪ و Recall کلاس خودکشی به ۰/۸۷ افزایش یافته است. بنابراین، نسخه جدید مدل نه‌تنها عملکرد کلی بالاتری ارائه می‌دهد، بلکه توانایی آن

در شناسایی نمونه‌های واقعی خودکشی نیز بهبود چشمگیری یافته است. با وجود این، عملکرد درخت تصمیم همچنان از جنگل تصادفی جدید پایین‌تر است؛ جنگل تصادفی با Accuracy برابر با ۹۲/۳۰۶۳٪ و Recall کلاس خودکشی برابر با ۰/۹۱، عملکرد قوی‌تری در هر دو جنبه نشان می‌دهد.

با توجه به این نتایج، استفاده از تنظیم آستانه تصمیم درخت تصمیم دیگر به‌عنوان یک ضرورت ناشی از Recall پایین مطرح نیست، زیرا Recall کلاس خودکشی در پیکربندی فعلی به ۰/۸۷ رسیده است. با این حال، در صورت هدف‌گذاری برای کاهش بیشتر خطاهای منفی کاذب، می‌توان در مراحل بعدی تأثیر تغییر آستانه تصمیم و معیارهایی مانند F1 یا F-beta را بررسی کرد. همچنین، با توجه به ماهیت ساختاری درخت تصمیم و حساسیت آن به بیش‌برازش، روش‌هایی نظیر هرس درخت، محدودسازی عمق و تنظیم سایر ابرپارامترها می‌توانند برای بررسی امکان بهبود تعمیم مدل مورد استفاده قرار گیرند [۱۳۰][۱۳۱].

در مجموع، نتایج جدید نشان می‌دهند که الگوریتم درخت تصمیم توانایی قابل‌قبولی در طبقه‌بندی متون خودکشی دارد و مهم‌تر از آن، عملکرد آن میان دو کلاس به‌خوبی متوازن شده است. با این حال، مقایسه مستقیم با جنگل تصادفی نشان می‌دهد که ترکیب چندین درخت تصمیم در قالب جنگل تصادفی در این مسئله توانسته است عملکرد بالاتری ایجاد کند. بنابراین، بر اساس نتایج حاصل از مجموعه ارزیابی حاضر، جنگل تصادفی با Accuracy برابر با ۹۲/۳۰۶۳٪، Recall برابر با ۰/۹۱ در کلاس خودکشی و F1-score برابر با ۰/۹۲، نسبت به درخت تصمیم با Accuracy برابر با ۸۷/۱۵۰۷٪ و F1-score برابر با ۰/۸۷، گزینه مناسب‌تری برای این مسئله طبقه‌بندی محسوب می‌شود.



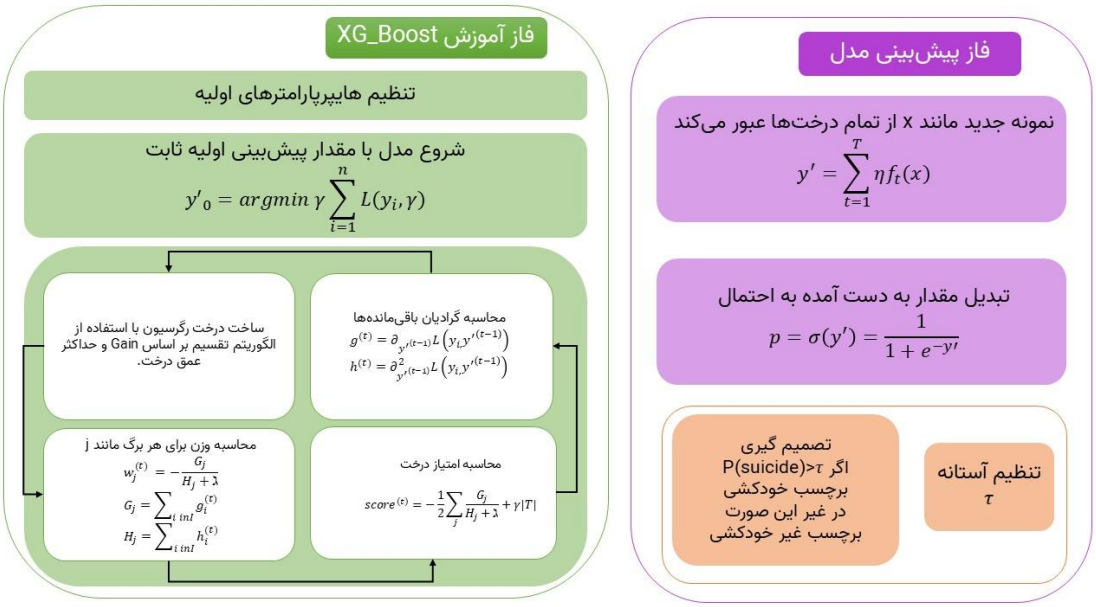
شکل ۲-۶ ماتریس سردرگمی درخت تصمیم

	Lable	Precision	Recall	F۱-score	Support
	غیر خودکشی	۰.۸۷	۰.۸۷	۰.۸۷	۲۳۲۰۷
	خودکشی	۰.۸۷	۰.۸۷	۰.۸۷	۲۳۲۰۷
Overall	**Accuracy(%)**	**Precision(%)**	**Recall(%)**	**F۱-score(%)**	**AUC-ROC**
	۸۷.۱۵۰۷	۸۷.۱۵۱۹	۸۷.۱۵۰۷	۸۷.۱۵۰۵	۹۷.۵۶۹۱

جدول ۲-۲

۲-٤-۳ مبانی نظری و تاریخچه الگوریتم XGBoost

الگوریتم XGBoost[1] که توسط چن و گستری در سال ۲۰۱۶ معرفی شد، یکی از پیشرفته‌ترین و پرکاربردترین الگوریتم‌های یادگیری گروهی مبتنی بر تقویت گرادیانی[2] محسوب می‌شود [۱۵۱][۱۶۰]. ریشه‌های این الگوریتم به مفهوم بنیادین تقویت[3] بازمی‌گردد که نخستین بار توسط شاپایر در سال ۱۹۹۰ مطرح شد و پرسش کرنز و والیانت را مبنی بر اینکه آیا مجموعه‌ای از یادگیرنده‌های ضعیف می‌توانند یک یادگیرنده قوی تولید کنند، پاسخ داد [۱۶۰]. این ایده بنیادین، زمینه‌ساز توسعه الگوریتم‌های موفق بعدی از جمله AdaBoost در سال ۱۹۹۵ و سپس گرادیان‌بوستینگ گردید [۱۵۶][۱۶۰]. XGBoost به‌عنوان یک پیاده‌سازی کارآمد از گرادیان‌بوستینگ، با بهره‌گیری از نوآوری‌های الگوریتمی و مهندسی متعدد، توانست عملکرد چشم‌گیری در مجموعه داده‌های بزرگ و پیچیده از خود نشان دهد و به‌سرعت به یکی از الگوریتم‌های منتخب در مسابقات یادگیری ماشین مانند کاگل تبدیل شد [۱۵۲][۱۵۳]. پژوهش‌های گسترده نشان داده‌اند که XGBoost در بسیاری از کاربردهای واقعی، از جمله طبقه‌بندی متون، تشخیص بیماری، و پیش‌بینی رفتارهای مرتبط با سلامت روان، عملکردی برتر نسبت به الگوریتم‌های سنتی و حتی برخی رویکردهای یادگیری عمیق دارد [۱۵۱][۱۵۴][۱۵۵][۱۵۶][۱۶۰].



شکل ۲-۷ فلوچارت الگوریتم XG-Booost

در الگوریتم XGBoost درخت‌های تصمیم به‌صورت ترتیبی ساخته می‌شوند و هر درخت جدید خطاهای درخت قبلی را تصحیح می‌کند [۱۵۶][۱۶۰]. تابع هدف XGBoost شامل دو بخش اصلی است: تابع زیان[4] که خطای مدل را اندازه‌گیری می‌کند، و جمله منظم‌سازی[5] که پیچیدگی را کنترل کرده و از بیش‌برازش جلوگیری می‌نماید [۱۶۲].

---

۱. eXtreme Gradient Boosting
۲. Gradient Boosting
۳. Boosting
۴. loss function
۵. regularization term

در هر مرحله از ساخت مدل، ابتدا مقادیر اولیه به صورت $y'. = argmin\,\gamma \sum_{i=1}^{n} L(y_i, \gamma)$ مقدار دهی می‌شوند. سپس الگوریتم با استفاده از مشتق‌های مرتبه اول (گرادیان) مطابق فرمول زیر، جهت بهینه‌سازی را تعیین می کند و درخت جدیدی بر اساس این مشتق‌ها ساخته می‌شود [۱۶۲].

$$g^{(t)} = \partial_{y'^{(t-1)}} L\left(y_{i,} y'^{(t-1)}\right)$$

$$h^{(t)} = \partial^{2}_{y'^{(t-1)}} L\left(y_{i,} y'^{(t-1)}\right)$$

پس از این مرحله مطابق روابط زیر، وزن تمام برگ های درخت محاسبه می‌شوند.

$$w_j^{(t)} = -\frac{G_j}{H_j + \lambda}$$

$$G_j = \sum_{i\ inI} g_i^{(t)}$$

$$H_j = \sum_{i\ inI} h_i^{(t)}$$

به کمک این وزن‌ها امتیاز نهایی هر درخت به صورت $score^{(t)} = -\frac{1}{2}\sum_j \frac{G_j}{H_j+\lambda} + \gamma|T|$ قابل محاسبه است. این فؤایند به صورت حلقه تا رسیدن به شروط توقف تکرار می‌شود.

فرآیند تصمیم‌گیری نهایی به این صورت است که پس از ساخت مجموعه‌ای از درخت‌ها (معمولاً بین ۱۰۰ تا ۱۰۰۰ درخت)، برای هر نمونه جدید، مجموع وزنی پیش‌بینی‌های همه درخت‌ها محاسبه می‌شود و این مقدار (که در بازه صفر تا یک قرار دارد) به‌عنوان احتمال تعلق نمونه به کلاس هدف در نظر گرفته می‌شود [۱۵۱][۱۵۳]. در حالت پیش‌فرض و برای طبقه‌بندی دودویی، اگر این احتمال از ۰/۵ بیشتر باشد، نمونه به کلاس مثبت (هدف) نسبت داده می‌شود؛ در غیر این صورت، در کلاس منفی دسته‌بندی می گردد [۱۵۳].

الگوریتم XGBoost دارای مزایای متعددی است که آن را برای کاربرد تشخیص متون خودکشی، که با چالش داده‌های نامتوازن مواجه است، به‌ویژه مناسب می‌سازد. اولین و مهم‌ترین مزیت، توانایی این الگوریتم در مدیریت داده‌های نامتوازن از طریق پارامتر `scale_pos_weight` است که با تنظیم وزن کلاس‌ها، تأثیر نمونه‌های کلاس اقلیت را در فرآیند آموزش افزایش می‌دهد [۱۵۳][۱۶۱]. تحقیقات نشان داده‌اند که با تنظیم این پارامتر به نسبت تعداد نمونه‌های کلاس منفی به کلاس مثبت، می‌توان به بهبود قابل‌توجهی در حساسیت (recall) مدل دست یافت [۱۵۳]. دومین مزیت، قابلیت یادگیری روابط غیرخطی و پیچیده بین ویژگی‌هاست که در داده‌های متنی با ابعاد بالا، از اهمیت ویژه‌ای برخوردار است [۱۵۳][۱۶۲]. سومین مزیت، ارائه قابلیت‌های تفسیرپذیری از طریق اهمیت ویژگی‌ها و مقادیر SHAP است که به محققان امکان می‌دهد تأثیر هر ویژگی را بر پیش‌بینی مدل درک کنند [۱۵۱][۱۵۵][۱۵۸]. به‌عنوان مثال، در مطالعه‌ای بر روی داده‌های ۱۷۳٬۶۶۳ نوجوان نروژی، مدل XGBoost توانست

به سطح زیر منحنی ROC معادل ۹۲/۸٪ دست یابد که نشان‌دهنده دقت بالای این الگوریتم در پیش‌بینی رفتار خودکشی است [۱۵۱].

با وجود عملکرد بالای XGBoost در پیش‌بینی، آستانه تصمیم پیش‌فرض ۰/۵ در کاربردهای تشخیص خودکشی که با داده‌های بسیار نامتوازن مواجه هستیم، معمولاً بهینه نیست [۱۵۱][۱۵۳]. پژوهش‌ها نشان داده‌اند که در چنین شرایطی، استفاده از آستانه ثابت ۰/۵ می‌تواند منجر به پیش‌بینی بیش‌ازحد کلاس اکثریت شود و در نتیجه، نمونه‌های واقعی کلاس خودکشی (کلاس اقلیت) به‌درستی شناسایی نشوند [۱۵۱]. نکته قابل‌توجه این است که در مدل‌های XGBoost، نمونه‌های مثبت کاذب که توسط مدل به‌عنوان خودکشی تشخیص داده می‌شوند اما در واقعیت چنین نیستند، ممکن است در معرض خطر قابل‌توجهی برای رفتار خودکشی در آینده باشند [۱۵۱]. مطالعه‌ای که بر روی داده‌های نوجوانان انجام شد نشان داد که با افزایش آستانه تصمیم (افزایش ویژگی)، شباهت علائم روانی بین نمونه‌های مثبت کاذب و مثبت واقعی به‌طور قابل‌توجهی افزایش می‌یابد؛ به‌گونه‌ای که میزان پریشانی روانی در گروه مثبت کاذب ۵۵/۳٪ و خودآزاری غیرخودکشی ۶۵/۲٪ گزارش شد که به‌مراتب بالاتر از گروه منفی واقعی (به‌ترتیب ۴/۲٪ و ۹/۹٪) بود [۱۵۱].

در این پژوهش، به منظور افزایش انعطاف‌پذیری و کارایی مدل XGBoost در تشخیص متون خودکشی، پارامتر آستانه تصمیم قابل تنظیم برای کلاس هدف معرفی شده است [۱۵۱][۱۵۳][۱۵۵]. بر این اساس، یک نمونه تنها در صورتی به کلاس «خودکشی» نسبت داده می‌شود که احتمال برآوردشده توسط مدل (که از ترکیب وزنی پیش‌بینی‌های همه درخت‌ها حاصل می‌شود) از آستانه مشخص‌شده θ بیشتر باشد.

برای تعیین آستانه بهینه θ، از روش جستجوی شبکه‌ای (grid search) بر روی مجموعه اعتبارسنجی استفاده شده است [۱۵۷][۱۶۱]. در این روش، آستانه‌های مختلف در بازه ۰/۰۱ تا ۰/۹ با گام‌های ۰/۰۱ مورد بررسی قرار می‌گیرند و آستانه‌ای که معیار F1 (یا F-beta با توجه به اهمیت بیشتر حساسیت) را بیشینه کند، به‌عنوان آستانه بهینه انتخاب می‌شود [۱۶۱]. پژوهش‌های تجربی نشان داده‌اند که بهینه‌سازی آستانه بر اساس معیار F1 می‌تواند بهبود قابل‌توجهی در عملکرد مدل ایجاد کند [۱۵۳][۱۵۷][۱۶۱]. در کاربرد تشخیص خودکشی، به‌دلیل هزینه بالای خطای منفی کاذب (تشخیص‌نادرست یک متن خودکشی)، معمولاً آستانه بهینه کمتر از ۰/۵ انتخاب می‌شود تا حساسیت مدل افزایش یابد [۱۵۱][۱۵۳]. در نهایت، با توجه به ماهیت حساس تشخیص خودکشی و توانایی بالای XGBoost در مدیریت داده‌های نامتوازن، ترکیب این الگوریتم با تنظیم آستانه پویا، امکان کنترل تعادل بین دقت و حساسیت را فراهم می‌آورد و سیستم را برای کاربردهای عملی که نیاز به اولویت‌بندی بر اساس هزینه خطاها دارند، انعطاف‌پذیر می‌سازد [۱۵۱][۱۵۳][۱۵۵][۱۶۱].

نتایج به‌دست‌آمده از الگوریتم XGBoost نشان‌دهنده عملکرد بسیار مطلوب و متوازن این مدل در طبقه‌بندی متون مرتبط با خودکشی است. مدل با دستیابی به دقت کلی ۹۳/۶۳۱۳٪ توانسته است عملکردی بالاتر از الگوریتم‌های جنگل تصادفی و درخت تصمیم ارائه دهد. دقت کلی جنگل تصادفی برابر با ۹۲/۳۰۶۳٪ و دقت درخت تصمیم برابر با ۸۷/۱۵۰۷٪ گزارش شده است؛ بنابراین، XGBoostبه‌ترتیب حدود ۱/۳۲ و ۶/۴۸ واحد درصد عملکرد بالاتری از این دو مدل داشته است. این نتایج نشان می‌دهد که در پیکربندی فعلی، XGBoostاز نظر دقت کلی بهترین عملکرد را در میان مدل‌های بررسی‌شده ارائه کرده است.

یکی از ویژگی‌های برجسته نتایجXGBoost ، عملکرد کاملاً متوازن مدل در دو کلاس است. در کلاس غیرخودکشی (کلاس ۰)، مقادیرPrecision ، Recallو F۱-score همگی برابر با ۰/۹۴ گزارش شده‌اند. این مقادیر نشان می‌دهند که مدل توانسته است ۹۴٪ از نمونه‌های واقعی غیرخودکشی را به‌درستی شناسایی کند و در عین حال، ۹۴٪ از نمونه‌هایی را که به‌عنوان غیرخودکشی پیش‌بینی کرده است، به‌درستی در این کلاس قرار دهد. مقدار F۱-score برابر با ۰/۹۴ نیز بیانگر توازن بسیار مناسب میان Precisionو Recall است.

در کلاس خودکشی (کلاس ۱) نیزPrecision ، Recallو F۱-score همگی برابر با ۰/۹۴ به‌دست آمده‌اند. به‌طور ویژه، Recallبرابر با ۰/۹۴ نشان می‌دهد که مدل قادر بوده است ۹۴٪ از نمونه‌های واقعی خودکشی را به‌درستی شناسایی کند. این مقدار از اهمیت ویژه‌ای برخوردار است، زیرا در مسئله تشخیص خودکشی، از دست دادن نمونه‌های واقعاً خودکشی و طبقه‌بندی آن‌ها به‌عنوان غیرخودکشی می‌تواند پیامدهای جدی داشته باشد .[۱۲۹][۱۲۸]همچنین Precision برابر با ۰/۹۴ نشان می‌دهد که ۹۴٪ از نمونه‌هایی که مدل به‌عنوان خودکشی شناسایی کرده است، واقعاً متعلق به این کلاس بوده‌اند. در نتیجه، F۱-scoreبرابر با ۰/۹۴ نشان‌دهنده عملکرد بسیار متوازن مدل در کلاس هدف است.

مقایسه عملکرد دو کلاس نشان می‌دهد که XGBoost در نتایج جدید هیچ اختلاف محسوسی میان کلاس خودکشی و غیرخودکشی نشان نمی‌دهد. برابر بودنPrecision ، Recallو F۱-score در دو کلاس، همراه با برابر بودن Support هر دو کلاس و وجود ۲۳۲۰۷ نمونه برای هر کلاس، نشان‌دهنده توازن بسیار بالای عملکرد مدل در مجموعه ارزیابی است. بنابراین، برخلاف نتایج قبلی که اختلاف میان Recall دو کلاس و احتمال سوگیری مدل به سمت کلاس غیرخودکشی مطرح شده بود، نتایج جدید شواهدی از چنین اختلاف عملکردی نشان نمی‌دهند.

معیارهای کلی مدل نیز این یافته‌ها را تأیید می‌کنند Accuracy .برابر با ۹۳/۶۳۱۳٪، Precisionبرابر با ۹۳/۶۳۱۴٪، Recall برابر با ۹۳/۶۳۱۳٪ و F۱-score برابر با ۹۳/۶۳۱۳٪ گزارش شده‌اند. نزدیکی بسیار زیاد این معیارها به یکدیگر نشان می‌دهد که عملکرد مدل در ابعاد مختلف ارزیابی کاملاً هماهنگ است و افزایش Accuracy به قیمت افت Precision یا Recall حاصل نشده است. به بیان دیگر، XGBoostتوانسته است هم‌زمان دقت پیش‌بینی بالا و توانایی مناسبی در شناسایی نمونه‌های واقعی هر دو کلاس ایجاد کند.

مقدار AUC-ROC برابر با ۹۷/۵۶۹۱٪ نیز نشان‌دهنده توانایی بسیار مناسب مدل در تفکیک دو کلاس است. این مقدار بیانگر آن است که مدل از قابلیت بالایی برای تمایز میان نمونه‌های خودکشی و غیرخودکشی برخوردار است. با توجه به اینکه AUC-ROC عملکرد مدل را در طیف وسیعی از آستانه‌های تصمیم ارزیابی می‌کند، مقدار بالای آن در کنارPrecision ، Recallو F۱-scoreبالا، شواهد بیشتری از قابلیت تفکیک مناسب XGBoost فراهم می‌کند.

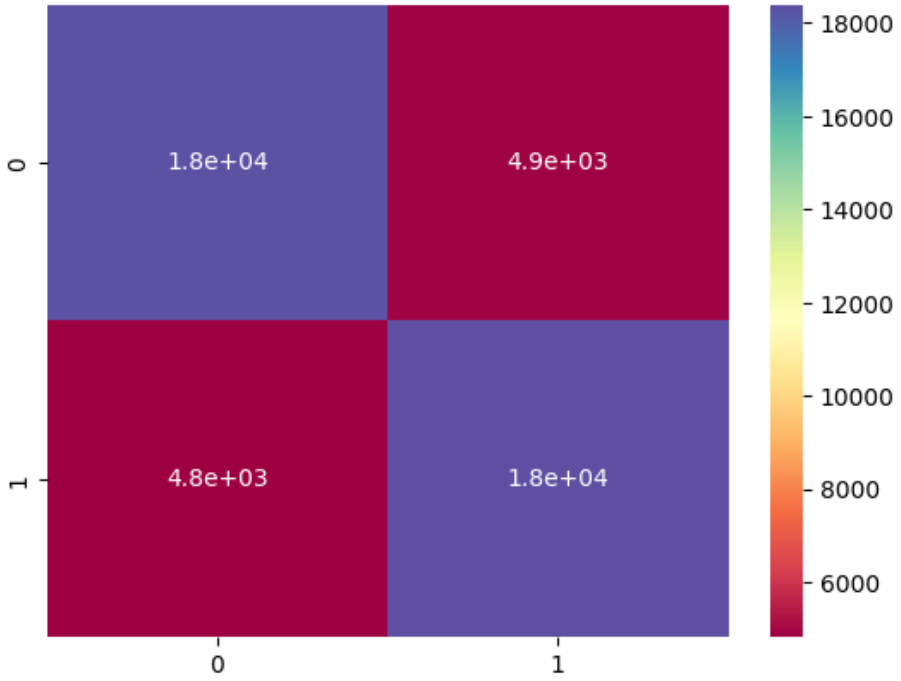
مقایسه نتایج جدید با نتایج قبلی XGBoost نیز بیانگر بهبود قابل‌توجه عملکرد مدل است. در نتایج پیشین، Accuracyبرابر با ۷۹/۱۴٪ و Recall کلاس خودکشی برابر با ۰/۷۹ گزارش شده بود، در حالی که در نتایج جدید Accuracy به ۹۳/۶۳۱۳٪ و Recallکلاس خودکشی به ۰/۹۴ افزایش یافته است. بنابراین، عملکرد کلی مدل حدود ۱۴/۴۹ واحد درصد و توانایی شناسایی

نمونه‌های واقعی خودکشی نیز حدود ۱۵ واحد درصد افزایش یافته است. علاوه بر این، F1-scoreکلاس خودکشی از ۰/۷۹ به ۰/۹۴ رسیده است که نشان‌دهنده بهبود هم‌زمان Precision و Recall در کلاس هدف است.

عملکرد مطلوب XGBoost را می‌توان با ویژگی‌های ساختاری این الگوریتم مرتبط دانست XGBoost .با استفاده از فرایند تقویت گرادیانی و ساخت ترتیبی درخت‌های تصمیم، قادر است روابط غیرخطی و الگوهای پیچیده میان ویژگی‌ها را مدل‌سازی کند .[۱۵۳]همچنین، استفاده از سازوکارهای منظم‌سازی در این الگوریتم می‌تواند از پیچیدگی بیش از حد مدل جلوگیری کرده و به بهبود تعمیم‌پذیری آن کمک کند .[۱۵۴]در نسخه‌های قبلی آزمایش، تنظیم پارامترهایی مانند scale_pos_weight نیز می‌تواند در کنترل اثر نامتوازن بودن کلاس‌ها مؤثر بوده باشد [۱۵۲][۱۵۱]؛ بااین‌حال، با توجه به اینکه در نتایج فعلی تعداد نمونه‌های دو کلاس در مجموعه ارزیابی برابر است، نمی‌توان عملکرد فعلی مدل را صرفاً به مدیریت عدم‌توازن کلاس‌ها نسبت داد.

از منظر کاربردی، Recallبرابر با ۰/۹۴ برای کلاس خودکشی، در کنار Precision برابر با ۰/۹۴، نتیجه‌ای مطلوب محسوب می‌شود. این وضعیت نشان می‌دهد که مدل ضمن شناسایی بخش عمده‌ای از نمونه‌های واقعی خودکشی، نرخ مناسبی از پیش‌بینی‌های مثبت صحیح نیز ایجاد کرده است. بنابراین، برخلاف نتایج قبلی که بهینه‌سازی آستانه تصمیم به‌عنوان راهکاری ضروری برای افزایش حساسیت مدل مطرح شده بود، در پیکربندی فعلی XGBoost عملکرد متوازنی در آستانه ارزیابی فعلی حاصل شده است. با این حال، در کاربردهای عملی می‌توان بسته به هزینه نسبی خطاهای مثبت کاذب و منفی کاذب، تحلیل منحنی Precision-Recall و انتخاب آستانه تصمیم مناسب را به‌عنوان یک مرحله تکمیلی در نظر گرفت .[۱۵۷][۱۵۶][۱۵۵]

در مجموع، نتایج جدید نشان می‌دهند که XGBoost در میان الگوریتم‌های مورد بررسی، بهترین عملکرد کلی را ارائه کرده است. دستیابی به Accuracy برابر با ۹۳/۶۳۱۳٪، Precisionبرابر با ۹۳/۶۳۱۴٪، Recallبرابر با ۹۳/۶۳۱۳٪ و F1-score برابر با ۹۳/۶۳۱۳٪، در کنار AUC-ROC برابر با ۹۷/۵۶۹۱٪، نشان‌دهنده عملکرد قوی و متوازن این الگوریتم است. همچنین، F1-scoreبرابر با ۰/۹۴ و Recall برابر با ۰/۹۴ در کلاس خودکشی نشان می‌دهد که مدل توانایی بالایی در شناسایی نمونه‌های هدف دارد. بر اساس مجموعه نتایج حاضر، XGBoostمناسب‌ترین عملکرد را در میان سه الگوریتم جنگل تصادفی، درخت تصمیم و XGBoost ارائه کرده و می‌تواند به‌عنوان مدل برتر این مرحله از پژوهش در نظر گرفته شود.



شکل۲-۸ ماتریس سردرگمی XG-Booost

	Lable	Precision	Recall	F۱-score	Support
	غیر خودکشی	۰.۹۴	۰.۹۴	۰.۹۴	۲۳۲۰۷
	خودکشی	۰.۹۴	۰.۹۴	۰.۹۴	۲۳۲۰۷
overall	**Accuracy(%)**	**Precision(%)**	**Recall(%)**	**F۱-score(%)**	**AUC-ROC**
	۹۳.۶۳۱۳	۹۳.۶۳۱۴	۹۳.۶۳۱۳	۹۳.۶۳۱۳	۹۷.۵۶۹۱

جدول ۲-۳

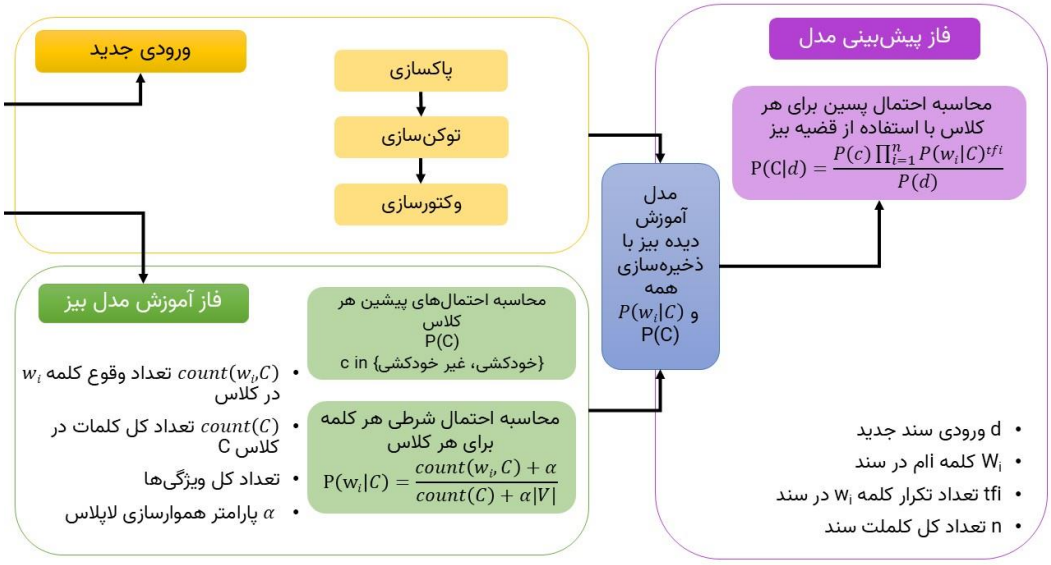
۲-٤-٤ تاریخچه و مبانی نظری الگوریتم Naive Bayes

پیشینه روش‌های بیزی به قرن هجدهم بازمی‌گردد، زمانی که توماس بیز، قضیه معروف خود را در مقاله‌ای[1] با عنوان که به‌طور پس‌مرگ در سال ۱۷۶۳ منتشر شد، تدوین نمود. با این حال، بسیاری از پژوهشگران معتقدند که سهم پیر-سیمون لاپلاس در توسعه آمار بیزی بسیار فراتر از کار بیز بوده است.[۱۶۵] لاپلاس که از انتشار بیز بی‌اطلاع بود، فرم کلی قضیه بیز را ارائه داد و آن را برای مسائل علمی متعددی در سال ۱۷۷۸ به کار برد. با ظهور کامپیوترهای قدرتمند و الگوریتم‌های جدید در قرن ۲۱، روش‌های بیزی مجدداً مورد توجه گسترده قرار گرفتند و امروزه در حوزه‌های گوناگونی از جمله طبقه‌بندی متون، تشخیص هرزنامه، و حتی کاربردهای بالینی به کار می‌روند .[۱۶۵, ۱۶۸]

هسته اصلی الگوریتم Naive Bayes بر قضیه بیز استوار است که به صورت ریاضی بیان می‌دارد که احتمال وقوع یک رویداد با در نظر گرفتن شواهد موجود، برابر است با حاصل‌ضرب احتمال پیشین در احتمال شرطی، تقسیم بر احتمال شواهد. در زمینه طبقه‌بندی متون، این قضیه به صورت رابطه زیر فرموله می‌شود که در آن y نشان‌دهنده کلاس (برچسب) مورد نظر است و x_1 تا x_n ویژگی‌های مستقل (کلمات یا توکن‌های موجود در متن) را نشان می‌دهند :[۱۶۵]

$$P(y|x_1, x_2, \ldots, x_n) = \frac{[P(y) \times P(x_1, x_2, \ldots, x_n|y)]}{P(x_1, x_2, \ldots, x_n)}$$

هدف نهایی الگوریتم، محاسبه احتمال شرطی P(y|x) برای هر کلاس و انتخاب کلاسی است که بیشترین احتمال را داشته باشد .[۱۶۵, ۱۷۵] شکل ۱۱۱ رویه کلیه این الگوریتم را نشان می‌دهد.



شکل ۲-۹ مدل بیز

---

۱. An Essay Towards Solving a Problem in the Doctrine of Chances

الگوریتم Naive Bayes، همان‌گونه که از نام آن پیداست، بر اساس یک فرض ساده‌کننده به نام «استقلال شرطی» عمل می‌کند که بیان می‌دارد با داشتن برچسب کلاس، تمام ویژگی‌ها از یکدیگر مستقل هستند. با وجود آنکه این فرض در داده‌های زبانی به ندرت برقرار است، مزایای محاسباتی قابل توجهی ایجاد کرده و پیچیدگی محاسباتی را از حالت نمایی به خطی کاهش می‌دهد .[۱۶۳ , ۱۶۵] الگوریتم Naive Bayes در سه توزیع متفاوت پیاده‌سازی می‌شود که هر یک برای نوع خاصی از داده‌ها مناسب هستند :[۱۶۴, ۱۶۹ , ۱۷۴]

مدل چندجمله‌ای (Multinomial Naive Bayes) برای داده‌های گسسته و شمارشی مانند تعداد دفعات تکرار هر کلمه در یک متن مناسب است. در این مدل، هر متن به عنوان یک «کیسه کلمات» در نظر گرفته می‌شود و احتمال شرطی هر کلمه از نسبت تعداد تکرار آن کلمه در متون یک کلاس به تعداد کل کلمات آن کلاس محاسبه می‌شود .[۱۷۵]

مدل برنولی (Bernoulli Naive Bayes) بر خلاف مدل چندجمله‌ای که تعداد تکرار کلمات را در نظر می‌گیرد، صرفاً به حضور یا عدم حضور هر کلمه در متن توجه می‌کند و ویژگی‌ها را به صورت دودویی (۰ یا ۱) مدل‌سازی می‌نماید. تحقیقات نشان داده است که مدل برنولی در برخی موارد برای داده‌های متنی با نمایش فرکانس کلمات عملکرد بهتری نسبت به دو مدل دیگر دارد .[۱۶۴ , ۱۷۴]

مدل گاوسی (Gaussian Naive Bayes) برای داده‌های پیوسته و با توزیع نرمال به کار می‌رود و در آن احتمال شرطی هر ویژگی با استفاده از تابع چگالی توزیع گاوسی محاسبه می‌شود .[۱۶۹]

هر یک از این مدل‌ها، در کتابخانه scikit-learn به ترتیب با کلاس‌های ``MultinomialNB، BernoulliNB`` و `GaussianNB` پیاده‌سازی شده‌اند.

تخمین پارامترها و چالش کلمات دیده‌نشده

مرحله آموزش الگوریتم Naive Bayes شامل تخمین دو دسته پارامتر اصلی است: احتمال پیشین کلاس‌ها P(y) و احتمال شرطی هر کلمه در هر کلاس P(w|y). احتمال پیشین هر کلاس از نسبت تعداد متون آن کلاس به کل متون مجموعه آموزش محاسبه می‌شود. برای تخمین احتمال شرطی کلمات نیز از روش بیشینه‌سازی درست‌نمایی (MLE) استفاده می‌گردد .[۱۷۲]

یکی از چالش‌های اساسی در طبقه‌بندی متون با Naive Bayes، مواجهه با کلماتی است که در مرحله آموزش دیده نشده‌اند. برای حل این مشکل، از روش هموارسازی لاپلاس (Laplace smoothing) استفاده می‌شود که با افزودن یک عدد ثابت (معمولاً ۱) به شمارنده هر کلمه و افزودن اندازه کل واژگان به مخرج، از ایجاد احتمال صفر جلوگیری می‌کند . این روش ساده اما مؤثر، عملکرد الگوریتم را در مواجهه با داده‌های جدید بهبود می‌بخشد.[۱۷۲ , ۱۷۷]

در این پژوهش، پس از پیاده‌سازی هر سه مدل Naive Bayes، از کلسیفایر رأی‌دهنده (Voting Classifier) برای ترکیب خروجی آن‌ها و دستیابی به عملکرد بهتر استفاده شده است. ایده اصلی پشت کلسیفایرهای رأی‌دهنده این است که یادگیرنده‌های منفرد در مجموعه لزوماً نیازی به هم‌نوع بودن ندارند و می‌توان با اعمال یک قاعده تصمیم‌گیری، آرای همه آن‌ها را یکپارچه کرد [۱۷۱, ۱۷۶].

دو روش اصلی رأی‌دهی در این کلسیفایرها وجود دارد: رأی‌دهی سخت (hard voting) که در آن هر کلسیفایر منفرد به یک کلاس رأی می‌دهد و کلاسی که اکثریت آرا را کسب کند، به عنوان خروجی نهایی انتخاب می‌شود؛ و رأی‌دهی نرم (soft voting) که در آن هر کلسیفایر مقدار احتمال تعلق هر نمونه به هر کلاس را ارائه می‌دهد و این احتمالات با اهمیت کلسیفایرها وزن‌دهی و جمع می‌شوند و سپس کلاسی با بیشترین مجموع احتمالات وزن‌دهی‌شده برنده می‌شود .[۱۷۶]

مطالعات نشان داده‌اند که ترکیب مدل‌های مختلف با کلسیفایر رأی‌دهنده می‌تواند عملکردی بهتر از هر یک از مدل‌های منفرد ارائه دهد، زیرا هر کلسیفایر ممکن است خطاهای متفاوتی بر روی داده‌های آموزشی داشته باشد.[۱۷۱, ۱۷۶] پژوهش‌های پیشین در حوزه تشخیص خودکشی از روی متون نشان داده‌اند که کلسیفایر رأی‌دهنده مبتنی بر Naive Bayes عملکرد قابل قبولی داشته و توانسته است با دقت بالایی متون حاوی نشانه‌های خودکشی را از متون عادی تشخیص دهد .[۱۷۰]

الگوریتم Naive Bayes به دلیل سادگی، سرعت بالا، نیاز کم به داده‌های آموزشی و عملکرد قابل قبول، انتخاب مناسبی برای طبقه‌بندی متون در حوزه تشخیص خودکشی است. این الگوریتم با یک بار پیمایش بر روی داده‌ها، پارامترهای خود را محاسبه می‌کند و پیچیدگی محاسباتی آن از مرتبه $O(|V| \times |C|)$ است که در آن $|V|$ اندازه واژگان و $|C|$ تعداد کلاس‌هاست .[۱۶۸] با وجود فرض ساده‌کننده استقلال شرطی که در داده‌های زبانی به ندرت برقرار است، پژوهش‌های متعدد نشان داده‌اند که Naive Bayes همچنان عملکرد خوبی در طبقه‌بندی دارد، زیرا این الگوریتم به جای تخمین دقیق احتمالات، به رتبه‌بندی صحیح کلاس‌ها نیاز دارد .[۱۶۳]

پژوهشی که توسط Yeskuatov و همکاران (۲۰۲۴) انجام شد، نشان داد که مدل‌های Naive Bayes آموزش‌دیده با ترکیب ویژگی‌های TF-IDF و ویژگی‌های روان‌زبانی، توانستند عملکرد بالایی در تشخیص افکار خودکشی در انجمن‌های آنلاین کسب کنند و به امتیاز F1 برابر با ۷۰/۹۹٪ دست یافتند .[۱۷۰] همچنین مطالعه دیگری توسط محققان در NIH با استفاده از نوشته‌های شخصی ویرجینیا وولف نشان داد که الگوریتم Naive Bayes می‌تواند با دقت ۸۰/۴۵٪ دوره دو ماهه منتهی به خودکشی را از سایر دوره‌های زندگی این نویسنده تشخیص دهد .[۱۶۵] این مطالعه اثبات‌پذیری استفاده از طبقه‌بندی متون مبتنی بر یادگیری ماشین را برای شناسایی الگوهای نوشتاری مرتبط با خودکشی نشان داد .[۱۷۰]

با وجود مزایای متعدد، الگوریتم Naive Bayes دارای محدودیت‌هایی است که باید در کاربرد عملی مورد توجه قرار گیرند. اصلی‌ترین محدودیت، فرض ساده‌کننده استقلال شرطی است که در داده‌های زبانی به ندرت برقرار است و این الگوریتم قادر به

مدل‌سازی روابط معنایی و نحوی پیچیده بین کلمات نیست .[۱۶۵] همچنین این الگوریتم به عنوان یک تخمین‌گر ضعیف شناخته می‌شود و احتمالات خروجی آن ممکن است با احتمالات واقعی فاصله داشته باشد، هرچند که ترتیب اولویت کلاس‌ها معمولاً صحیح است. با وجود این محدودیت‌ها، پژوهشگران نشان داده‌اند که ترکیب Naive Bayes با روش‌های دیگر می‌تواند عملکرد آن را بهبود بخشد .[۱۶۵, ۱۷۶]

برای پیاده‌سازی عملی این الگوریتم، از کتابخانه scikit-learn در پایتون استفاده شده است. کلاس‌هایMultinomialNBz BernoulliNB و GaussianNB پیاده‌سازی کاملی از مدل‌های مختلف Naive Bayes را ارائه می‌دهند که با پارامتر `alpha` کنترل مقدار هموارسازی را ممکن می‌سازد. برای آماده‌سازی داده‌ها، از کلاس CountVectorizer برای تبدیل متون به بردارهای شمارشی کلمات استفاده می‌شود.

مقایسه عملکرد سه مدل در پژوهش‌های پیشین نشان داده است که مدل برنولی در طبقه‌بندی متون دارای دقت بالاتری است. به عنوان مثال، در مطالعه‌ای در زمینه تحلیل احساسات در توییتر، مدل برنولی با دقت ۸۷/۱٪ عملکرد بهتری نسبت به مدل چندجمله‌ای (۷۵/۸۱٪) و مدل گاوسی (۷۷/۴۲٪) نشان داد .[۲,۱۲] در مطالعه دیگری در زمینه طبقه‌بندی عملکرد اساتید نیز مدل برنولی با دقت ۸۳٪ بهترین عملکرد را در بین مدل‌های Naive Bayes داشت .[۱۶۹]

در این پژوهش، الگوریتم Naive Bayes در هر سه توزیع چندجمله‌ای، برنولی و گاوسی به عنوان روش‌های پایه برای تشخیص خودکشی از روی متون به کار گرفته شده است. سپس با استفاده از کلسیفایر رأی‌دهنده و روش رأی‌دهی نرم، خروجی این سه مدل ترکیب شده است. این الگوریتم‌ها با وجود سادگی و فرض‌های ساده‌کننده، به دلیل سرعت بالا، نیاز کم به داده‌های آموزشی و عملکرد قابل قبول، انتخاب مناسبی برای این کاربرد هستند .[۱۶۸] همچنین نتایج حاصل از این ترکیب به عنوان خط پایه (baseline) برای مقایسه با الگوریتم‌های پیچیده‌تر مانند مدل‌های مبتنی بر transformer مورد استفاده قرار گرفته است .[۱۶۸] با توجه به ماهیت حساس و حیاتی تشخیص خودکشی، ترکیب این الگوریتم با روش‌های دیگر و همچنین استفاده از تکنیک‌های پیش‌پردازش مانند حذف کلمات توقف، ریشه‌یابی، و یکسان‌سازی حروف، می‌تواند به بهبود عملکرد آن در کاربردهای عملی کمک کند .[۱۶۵]

نتایج به‌دست‌آمده از الگوریتم Naive Bayes نشان‌دهنده عملکرد قابل‌قبول این مدل در طبقه‌بندی متون مرتبط با خودکشی است. مدل با دستیابی به دقت کلی ۸۲/۶۴۳۵٪ توانسته است بخش قابل‌توجهی از نمونه‌های دو کلاس «غیرخودکشی» و «خودکشی» را به‌درستی طبقه‌بندی کند. با این حال، مقایسه نتایج جدید با سایر الگوریتم‌های مورد بررسی نشان می‌دهد که Naive Bayes در پیکربندی فعلی بهترین عملکرد را ندارد. در میان چهار الگوریتم بررسی‌شده، XGBoost با Accuracy برابر با ۹۳/۶۳۱۳٪، جنگل تصادفی با ۹۲/۳۰۶۳٪ و درخت تصمیم با ۸۷/۱۵۰۷٪ عملکرد بالاتری از Naive Bayes داشته‌اند. بنابراین، برخلاف نتایج قبلی که Naive Bayes به‌عنوان بهترین الگوریتم معرفی شده بود، نتایج جدید نشان می‌دهند که این الگوریتم از نظر دقت کلی در رتبه پایین‌تری نسبت به سه مدل دیگر قرار می‌گیرد.

بررسی عملکرد مدل در سطح کلاس‌ها نشان می‌دهد که Naive Bayes در شناسایی نمونه‌های خودکشی عملکرد مناسبی دارد، هرچند این عملکرد با کاهش Precision همراه است. در کلاس غیرخودکشی (کلاس ۰)، Precision برابر با ۰/۸۹ و Recall برابر با ۰/۷۴ به‌دست آمده است. این نتایج نشان می‌دهند که مدل در پیش‌بینی نمونه‌های غیرخودکشی دقت نسبتاً بالایی دارد، اما تنها توانسته است ۷۴٪ از نمونه‌های واقعی این کلاس را به‌درستی شناسایی کند F1-score .برابر با ۰/۸۱ نیز نشان‌دهنده وجود فاصله میان Precision و Recall در این کلاس است.

در کلاس خودکشی (کلاس ۱)، Precision برابر با ۰/۷۸ و Recall برابر با ۰/۹۱ گزارش شده است Recall .برابر با ۰/۹۱ بیانگر آن است که مدل توانسته است ۹۱٪ از نمونه‌های واقعی خودکشی را به‌درستی شناسایی کند. این مقدار از نظر کاربرد پژوهش حاضر اهمیت ویژه‌ای دارد، زیرا در سامانه‌های تشخیص خودکشی، کاهش موارد منفی کاذب و شناسایی هرچه بیشتر نمونه‌های واقعی خودکشی از اهمیت بالایی برخوردار است .[۱۲۹][۱۲۸] با این حال، Precision برابر با ۰/۷۸ نشان می‌دهد که بخشی از نمونه‌هایی که مدل به‌عنوان خودکشی شناسایی کرده است، در واقع متعلق به کلاس غیرخودکشی بوده‌اند. در نتیجه، F1-score کلاس خودکشی برابر با ۰/۸۴ به‌دست آمده است که نشان‌دهنده عملکرد مناسب مدل در ایجاد موازنه میان Precision و Recall، با تأکید بیشتر بر شناسایی نمونه‌های خودکشی است.

مقایسه معیارهای دو کلاس نشان می‌دهد که عملکرد Naive Bayes کاملاً متوازن نیست Recall .در کلاس خودکشی برابر با ۰/۹۱ است، در حالی که Recall کلاس غیرخودکشی تنها ۰/۷۴ گزارش شده است. این اختلاف ۱۷ واحد درصدی نشان می‌دهد که مدل تمایل بیشتری به شناسایی نمونه‌ها در قالب کلاس خودکشی دارد. از سوی دیگر، Precision کلاس غیرخودکشی برابر با ۰/۸۹ و Precision کلاس خودکشی برابر با ۰/۷۸ است. بنابراین، مدل اگرچه توانسته است حساسیت بالایی در شناسایی نمونه‌های خودکشی ایجاد کند، اما این عملکرد با افزایش پیش‌بینی‌های مثبت کاذب همراه شده است. این موضوع در کاربردهای حساس تشخیص خودکشی باید مورد توجه قرار گیرد، زیرا افزایش Recall می‌تواند با افزایش هشدارهای کاذب همراه باشد.

معیارهای کلی مدل نیز همین الگو را تأیید می‌کنند Accuracy .برابر با ۸۲/۶۴۳۵٪، Precisionبرابر با ۸۳/۵۵۳۶٪، Recall برابر با ۸۲/۶۴۳۵٪ و F1-score برابر با ۸۲/۵۲۵۱٪ گزارش شده‌اند. نزدیکی نسبی این معیارها در سطح کلی نشان‌دهنده عملکرد قابل‌قبول مدل است، اما معیارهای سطح کلاس نشان می‌دهند که این عملکرد میان دو کلاس کاملاً یکسان نیست. بنابراین، برای ارزیابی دقیقNaive Bayes ، توجه صرف به Accuracy کافی نبوده و بررسی هم‌زمانPrecision ، Recall و F1-score هر کلاس ضروری است.

مقدار AUC-ROC برابر با ۹۷/۵۶۹۱٪ نیز نشان‌دهنده توانایی بالای مدل در تفکیک دو کلاس است. با این حال، همان‌طور که در سایر مدل‌ها نیز مشاهده شد، AUC-ROC بالا الزاماً به معنای عملکرد بهینه در آستانه تصمیم مورد استفاده نیست. به همین دلیل، در کاربردهایی که هزینه خطاهای منفی کاذب و مثبت کاذب متفاوت است، بررسی منحنی‌های ROC و Precision-Recall و همچنین انتخاب آستانه تصمیم مناسب می‌تواند اطلاعات دقیق‌تری درباره رفتار مدل فراهم کند.

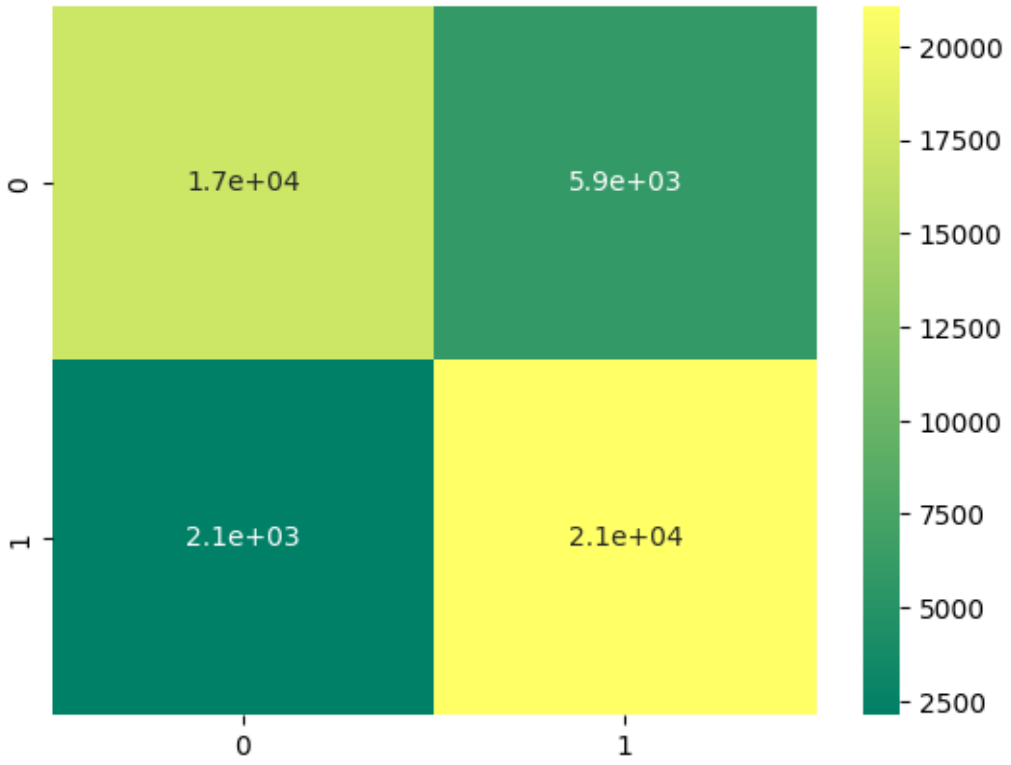
در مقایسه با نتایج قبلی، عملکرد جدید Naive Bayes کاهش یافته است. در نتایج پیشین، Accuracy برابر با ۸۷/۱۶٪ و Recall کلاس خودکشی برابر با ۰/۹۳ گزارش شده بود، در حالی که در نتایج جدید Accuracy به ۸۲/۶۴۳۵٪ و Recall کلاس خودکشی به ۰/۹۱ رسیده است. بنابراین، دقت کلی مدل حدود ۴/۵۲ واحد درصد کاهش یافته و Recall کلاس خودکشی نیز ۲ واحد درصد کاهش داشته است. همچنین F1-score کلاس خودکشی از ۰/۸۸ در نتایج قبلی به ۰/۸۴ در نتایج جدید کاهش یافته است. این تغییرات نشان می‌دهند که عملکرد برتر گزارش‌شده در نسخه قبلی در پیکربندی فعلی تکرار نشده است.

عملکرد Naive Bayes را می‌توان با ویژگی‌های ذاتی این خانواده از الگوریتم‌ها مرتبط دانست. ماهیت احتمالاتی این روش، علی‌رغم فرض ساده‌کننده استقلال شرطی میان ویژگی‌ها، موجب شده است که Naive Bayes در بسیاری از مسائل طبقه‌بندی متون عملکرد مناسبی داشته باشد .[۱۶۴][۱۶۳] همچنین، توانایی این الگوریتم در کار با داده‌های پراکنده و با ابعاد بالا، که از ویژگی‌های متداول بازنمایی‌های متنی هستند، از نقاط قوت آن محسوب می‌شود .[۱۶۵]استفاده از روش‌های هموارسازی نیز می‌تواند احتمال مشاهده‌شدن ویژگی‌های جدید یا کم‌تکرار را مدیریت کرده و از ایجاد احتمال صفر در محاسبات جلوگیری کند [۱۶۶].

در این پژوهش، ترکیب مدل‌های مختلف Naive Bayes شامل مدل‌های چندجمله‌ای، برنولی و گاوسی با استفاده از یک سازوکار رأی‌دهی نیز می‌تواند در ایجاد عملکرد پایدارتر نسبت به یک مدل منفرد مؤثر باشد .[۱۶۷]با این حال، نتایج جدید نشان می‌دهند که این ترکیب در پیکربندی فعلی نتوانسته است عملکردی بالاتر ازXGBoost ، جنگل تصادفی و درخت تصمیم ایجاد کند. بنابراین، سادگی محاسباتی و سرعت بالای Naive Bayes را می‌توان همچنان به‌عنوان مزیت این الگوریتم در نظر گرفت، اما از نظر عملکرد طبقه‌بندی، شواهد تجربی حاصل از مجموعه ارزیابی حاضر برتری آن را نسبت به سایر مدل‌های بررسی‌شده تأیید نمی‌کند.

با توجه به Recall برابر با ۰/۹۱ برای کلاس خودکشی، Naive Bayes همچنان از قابلیت مناسبی برای شناسایی نمونه‌های واقعی خودکشی برخوردار است. با این حال، Precision پایین‌تر این کلاس، برابر با ۰/۷۸، نشان می‌دهد که افزایش حساسیت با هزینه افزایش نمونه‌های مثبت کاذب همراه شده است. در چنین شرایطی، تنظیم آستانه تصمیم می‌تواند به‌عنوان یک راهکار تکمیلی برای کنترل موازنه میان Recall و Precision مورد بررسی قرار گیرد .[۱۶۸]انتخاب آستانه مناسب باید متناسب با هدف سامانه و هزینه نسبی خطاهای مختلف انجام شود و نمی‌توان صرفاً افزایش Recall را به‌عنوان معیار بهینه‌سازی در نظر گرفت.

در مجموع، نتایج جدید نشان می‌دهند که Naive Bayes عملکرد قابل‌قبولی در طبقه‌بندی متون خودکشی دارد و به‌ویژه در شناسایی نمونه‌های واقعی کلاس خودکشی با Recall برابر با ۰/۹۱ توانمند است. با این حال، Accuracy برابر با ۸۲/۶۴۳۵٪ و F1-score کلی برابر با ۸۲/۵۲۵۱٪ نشان می‌دهند که این الگوریتم از نظر عملکرد کلی پایین‌تر ازXGBoost ، جنگل تصادفی و درخت تصمیم قرار دارد. بنابراین، برخلاف نتایج قبلی، نمی‌توان Naive Bayes را بهترین الگوریتم این پژوهش معرفی کرد. بر اساس نتایج جدید، XGBoost با Accuracy برابر با ۹۳/۶۳۱۳٪، Recall برابر با ۰/۹۴ و F1-score برابر با ۰/۹۴ در کلاس خودکشی، عملکرد برتری را در میان مدل‌های بررسی‌شده ارائه کرده است Naive Bayes .در مقابل، با وجود سادگی، سرعت و Recall بالای خود در کلاس هدف، بیشتر به‌عنوان یک مدل پایه و سریع با عملکرد قابل‌قبول قابل استفاده است.



شکل۲-۱۰ ماتریس سردرگمی مدل بیز

	Lable	Precision	Recall	F۱-score	Support
	غیر خودکشی	۰.۸۹	۰.۷۴	۰.۸۱	۲۳۲۰۷
	خودکشی	۰.۷۸	۰.۹۱	۰.۸۴	۲۳۲۰۷
	Accuracy(%)	**Precision(%)**	**Recall(%)**	**F۱-score(%)**	**AUC-ROC**
overall	۸۲.۶۴۳۵	۸۳.۵۵۳۶	۸۲.۶۴۳۵	۸۲.۵۲۵۱	۹۷.۵۶۹۱

جدول ۲-۴

۲-٤-۵ نتیجه‌گیری

در این پژوهش، عملکرد چهار الگوریتم یادگیری ماشین شامل جنگل تصادفی، درخت تصمیم ، XGBoost و Naive Bayes برای طبقه‌بندی متون مرتبط با خودکشی مورد ارزیابی قرار گرفت. ارزیابی مدل‌ها با استفاده از معیارهای Accuracy ، Precision، Recall، F۱-score و AUC-ROC انجام شد تا علاوه بر عملکرد کلی، توانایی هر الگوریتم در شناسایی کلاس هدف، یعنی متون خودکشی، نیز مورد بررسی قرار گیرد.

نتایج به‌دست‌آمده نشان می‌دهد که XGBoost با Accuracy برابر با ۹۳/۶۳٪ بالاترین عملکرد کلی را در میان چهار الگوریتم مورد بررسی داشته است. جنگل تصادفی با Accuracy برابر با ۹۲/۳۱٪ در رتبه دوم قرار گرفته، در حالی که درخت تصمیم و Naive Bayes به‌ترتیب Accuracy برابر با ۸۷/۱۵٪ و ۸۲/۶۴٪ را به دست آورده‌اند. بنابراین، XGBoost نسبت به جنگل تصادفی حدود ۱/۳۲ واحد درصد و نسبت به درخت تصمیم و Naive Bayes به‌ترتیب حدود ۶/۴۸ و ۱۰/۹۹ واحد درصد عملکرد بالاتری داشته است.

از نظر Precision ، XGBoost نیز با مقدار ۹۳/۶۳٪ بهترین عملکرد را ارائه کرده است. جنگل تصادفی با مقدار ۹۲/۳۲٪ در جایگاه دوم قرار دارد و درخت تصمیم و Naive Bayes به‌ترتیب مقادیر ۸۷/۱۵٪ و ۸۳/۵۵٪ را به دست آورده‌اند. این نتایج نشان می‌دهند که XGBoost علاوه بر طبقه‌بندی صحیح تعداد بیشتری از نمونه‌ها، در پیش‌بینی کلاس‌ها نیز از دقت بالاتری برخوردار است.

معیار Recall از اهمیت ویژه‌ای در مسئله حاضر برخوردار است؛ زیرا هدف اصلی سامانه، شناسایی متون مرتبط با خودکشی است و از دست دادن یک نمونه واقعی خودکشی می‌تواند پیامدهای جدی‌تری نسبت به ایجاد یک هشدار کاذب داشته باشد .[۱۰۸][۱۰۷]در کلاس خودکشی، XGBoost با Recall برابر با ۰/۹۴ بهترین عملکرد را داشته است. جنگل تصادفی با Recall برابر با ۰/۹۱ و Naive Bayes با Recall برابر با ۰/۹۱ در رتبه بعدی قرار می‌گیرند، در حالی که درخت تصمیم Recall برابر با ۰/۸۷ را به دست آورده است. بنابراین، XGBoost توانسته است ۹۴٪ از نمونه‌های واقعی خودکشی را شناسایی کند و کمترین نرخ منفی کاذب را در میان مدل‌های مورد بررسی ایجاد نماید.

از نظر F۱-score کلاس خودکشی نیز XGBoost با مقدار ۰/۹۴ بهترین نتیجه را به دست آورده است. جنگل تصادفی با F۱-score برابر با ۰/۹۲ در رتبه دوم قرار دارد، در حالی که Naive Bayes و درخت تصمیم به‌ترتیب مقادیر ۰/۸۴ و ۰/۸۷ را ارائه کرده‌اند. برتری XGBoost در این معیار اهمیت زیادی دارد؛ زیرا F۱-score به‌صورت هم‌زمان Precision و Recall را در نظر می‌گیرد و در نتیجه برای ارزیابی مدلی که باید هم توانایی شناسایی نمونه‌های خودکشی را حفظ کند و هم از ایجاد تعداد زیادی هشدار کاذب جلوگیری نماید، معیار مناسبی محسوب می‌شود.

جدول زیر خلاصه‌ای از عملکرد چهار الگوریتم را نشان می‌دهد:

الگوریتم	Accuracy (%)	Precision (%)	Recall (%)	F1-score (%)	Recallکلاس خودکشی	F1کلاس خودکشی
XGBoost	**۹۳.٦۳**	**۹۳.٦۳**	**۹۳.٦۳**	**۹۳.٦۳**	**۰.۹٤**	**۰.۹٤**
Random Forest	۹۲.۳۱	۹۲.۳۲	۹۲.۳۱	۹۲.۳۱	۰.۹۱	۰.۹۲
Decision Tree	۸۷.۱۵	۸۷.۱۵	۸۷.۱۵	۸۷.۱۵	۰.۸۷	۰.۸۷
Naive Bayes	۸۲.۶۴	۸۳.۵۵	۸۲.۶۴	۸۲.۵۳	۰.۹۱	۰.۸۴

جدول ۲-۵

بر اساس این مقایسه، XGBoost در تمامی معیارهای کلی عملکردی در رتبه نخست قرار گرفته است. همچنین، در مهم‌ترین معیارهای مرتبط با کلاس هدف نیز بهترین عملکرد را ارائه کرده است. این الگوریتم با Recall برابر با ۰/۹۴ و F1-score برابر با ۰/۹۴ برای کلاس خودکشی، توانسته است ضمن شناسایی بخش عمده‌ای از نمونه‌های واقعی خودکشی، Precision بالایی نیز حفظ کند. این ویژگی XGBoost را نسبت به الگوریتم‌هایی که افزایش Recall آن‌ها با کاهش قابل‌توجه Precision همراه شده است، به گزینه مناسب‌تری برای مسئله حاضر تبدیل می‌کند.

جنگل تصادفی با Accuracy برابر با ۹۲/۳۱٪ نزدیک‌ترین رقیب XGBoost محسوب می‌شود و عملکرد آن نیز در کلاس خودکشی مطلوب است. این الگوریتم Recall برابر با ۰/۹۱ و F1-score برابر با ۰/۹۲ را برای کلاس خودکشی به دست آورده است. بنابراین، اگرچه اختلاف عملکرد آن با XGBoost زیاد نیست، اما برتری XGBoost در Accuracy ، Precision، Recall و F1-score نشان می‌دهد که XGBoost در مجموعه ارزیابی حاضر عملکرد کلی بهتری دارد.

درخت تصمیم با Accuracy برابر با ۸۷/۱۵٪ عملکردی پایین‌تر از دو الگوریتم فوق ارائه کرده است، اما نکته مثبت آن عملکرد نسبتاً متوازن میان دو کلاس است Precision .. ،Recallو F1-score برای هر دو کلاس برابر با ۰/۸۷ گزارش شده‌اند. بنابراین، این الگوریتم از نظر سادگی و تفسیرپذیری می‌تواند مزایایی داشته باشد، اما از منظر عملکرد طبقه‌بندی، نتایج حاصل از آن پایین‌تر از XGBoost و جنگل تصادفی است.

Naive Bayes نیز با وجود Recall مناسب ۰/۹۱ در کلاس خودکشی، پایین‌ترین Accuracy کلی را در میان چهار الگوریتم به دست آورده است. مهم‌ترین ویژگی این مدل، تأکید بیشتر بر شناسایی کلاس خودکشی است؛ به‌طوری‌که Recall کلاس هدف ۰/۹۱ بوده، اما Precision آن به ۰/۷۸ کاهش یافته است. این مسئله نشان می‌دهد که بخشی از افزایش حساسیت مدل با افزایش پیش‌بینی‌های مثبت کاذب همراه شده است. بنابراین، Naive Bayes اگرچه به دلیل سادگی و سرعت بالا می‌تواند به‌عنوان یک مدل پایه یا گزینه‌ای کم‌هزینه مورد استفاده قرار گیرد، اما بر اساس نتایج فعلی گزینه برتر برای سامانه نهایی نیست.

بر این اساس، XGBoost به‌عنوان الگوریتم منتخب و مدل نهایی این مرحله از پژوهش انتخاب می‌شود .این انتخاب نه‌تنها بر اساس بالاترینAccuracy ، بلکه بر اساس عملکرد هم‌زمان مدل در معیارهایPrecision ، Recall و F1-score انجام شده است. دستیابی به Accuracy برابر با ۹۳/۶۳٪، Precision برابر با ۹۳/۶۳٪، Recall برابر با ۹۳/۶۳٪ و F1-score برابر با ۹۳/۶۳٪ در سطح کلی، همراه با Recall و F1-score برابر با ۰/۹۴ در کلاس خودکشی، نشان‌دهنده عملکرد قوی و متوازن XGBoost است.

از منظر مسئله تشخیص خودکشی، اهمیت انتخاب XGBoost بیش از مقدار Accuracy آن است؛ زیرا این الگوریتم بالاترین Recallرا نیز در کلاس هدف به دست آورده است. در نتیجه، انتخاب آن موجب می‌شود مدل هم از نظر عملکرد کلی و هم از نظر کاهش احتمال از دست دادن نمونه‌های واقعی خودکشی، بهترین نتیجه را در میان مدل‌های بررسی‌شده ارائه دهد. بنابراین، XGBoost می‌تواند به‌عنوان مدل طبقه‌بندی‌کننده اصلی در مراحل بعدی پژوهش، از جمله ارزیابی نهایی، تحلیل خطا و بررسی روش‌های بهینه‌سازی آستانه تصمیم، مورد استفاده قرار گیرد.

در نهایت، لازم است تأکید شود که انتخاب XGBoost به‌عنوان مدل برتر بر اساس نتایج مجموعه ارزیابی حاضر انجام شده است و برای ادعای تعمیم‌پذیری مدل در محیط واقعی، انجام ارزیابی‌های تکمیلی نظیر اعتبارسنجی متقابل، بررسی داده‌های مستقل و تحلیل ماتریس درهم‌ریختگی ضروری است. همچنین، با توجه به ماهیت حساس کاربرد، در مراحل بعدی می‌توان آستانه تصمیم مدل را بر اساس هزینه نسبی خطاهای مثبت و منفی تنظیم کرد تا رفتار سامانه متناسب با نیاز کاربردی مورد نظر بهینه شود.

۲-۵ آنالیز حساسیت

تحلیل حساسیت به بررسی چگونگی تأثیرپذیری خروجی مدل از ورودی‌های آن می‌پردازد. این روش در حوزه‌های گوناگون به عنوان ابزاری کمکی برای تبیین روابط ورودی–خروجی سیستم‌های پیچیده به کار می‌رود. در حوزه یادگیری ماشین و پردازش زبان طبیعی، تحلیل حساسیت نقشی مشابه با آزمون «اگر چنین شود، چه خواهد شد؟» برای مدل‌های هوش مصنوعی ایفا می‌کند. هدف اصلی آن، درک این نکته است که تغییر در ورودی مدل (برای نمونه، یک واژه در جمله) تا چه اندازه می‌تواند بر خروجی آن (مانند برچسب احساسی یا تصمیم نهایی) اثر بگذارد. این امر به شفاف‌سازی مدل‌های پیچیده و افزایش اطمینان به عملکرد آنها کمک شایانی می‌کند.

به منظور ارزیابی جامع استحکام و پایایی مدل تشخیص متون مرتبط با خودکشی، یک تحلیل حساسیت چندوجهی با بهره‌گیری از چهار رویکرد مکمل انجام دادیم: (۱) ارزیابی حساسیت در سطح هر کلاس، (۲) تحلیل اهمیت ویژگی‌ها بر اساس روش جایگشت، (۳) ارزیابی حساسیت نسبت به آستانه‌های اطمینان، و (۴) آزمون حساسیت نسبت به توزیع برچسب‌ها. تمامی تحلیل‌ها بر روی

مجموعه آزمون کنارگذاشته‌شده شامل ۴۶,۴۱۵ نمونه، با بردارهای ویژگی به ابعاد ۱,۰۰۰، اجرا شدند. چارچوب روش‌شناختی به گونه‌ای طراحی گردید تا عملکرد مدل را در شرایط گوناگون بسنجد و حالت‌های احتمالی شکست که می‌توانند بر کاربرد عملی آن تأثیر بگذارند، شناسایی کند.

تحلیل حساسیت در سطح کلاس‌ها، با محاسبه یادآوری (Recall) ویژه هر کلاس (که با عنوان حساسیت یا نرخ مثبت واقعی نیز شناخته می‌شود) از ماتریس درهم‌ریختگی (Confusion Matrix) انجام شد، به‌گونه‌ای که برای هر کلاس i، حساسیت به صورت $Sensitivity_i = \frac{TP_i}{TP_i+FN_i}$ محاسبه گردید که در آن TP_i نشان‌دهنده مثبت‌های واقعی و FN_i نشان‌دهنده منفی‌های کاذب برای کلاس i است. این معیار به جای دقت کلی انتخاب شد، زیرا بینش‌های ویژه‌ای در سطح کلاس ارائه می‌دهد که در سناریوهای طبقه‌بندی با داده‌های نامتوازن، به‌ویژه در کاربردهای مرتبط با سلامت روان که عدم تشخیص محتوای خودکشی‌گرایانه پیامدهای بسیار سنگین‌تری نسبت به هشدارهای اشتباه دارد، نقشی حیاتی ایفا می‌کند.

برای تحلیل اهمیت ویژگی‌ها، رویکرد اهمیت مبتنی بر جایگشت را به کار گرفتیم که مستقل از نوع مدل بوده و سهم هر ویژگی را در عملکرد مدل، از طریق جابه‌جایی تصادفی مقادیر آن ویژگی و مشاهده افت حاصل در دقت پیش‌بینی، اندازه‌گیری می‌کند. با توجه به حجم محاسباتی پردازش ۴۶,۴۱۵ نمونه با ۱,۰۰۰ ویژگی، یک راهبرد نمونه‌گیری بهینه‌شده با استفاده از ۳۰٪ از داده‌های آزمون (۱۳,۹۲۵ نمونه) پیاده‌سازی کردیم و تحلیل را به ۱۰۰ ویژگی انتخاب‌شده تصادفی در هر تکرار محدود نمودیم و فرایند جایگشت را سه بار برای حصول ثبات آماری تکرار کردیم. نمره نهایی اهمیت به صورت زیر محاسبه شد که در آن R=۳ نمایانگر تعداد تکرارها و $Acc_{permuted_r,j}$ نشان‌دهنده دقت پس از جابه‌جایی ویژگی j در تکرار rام است.

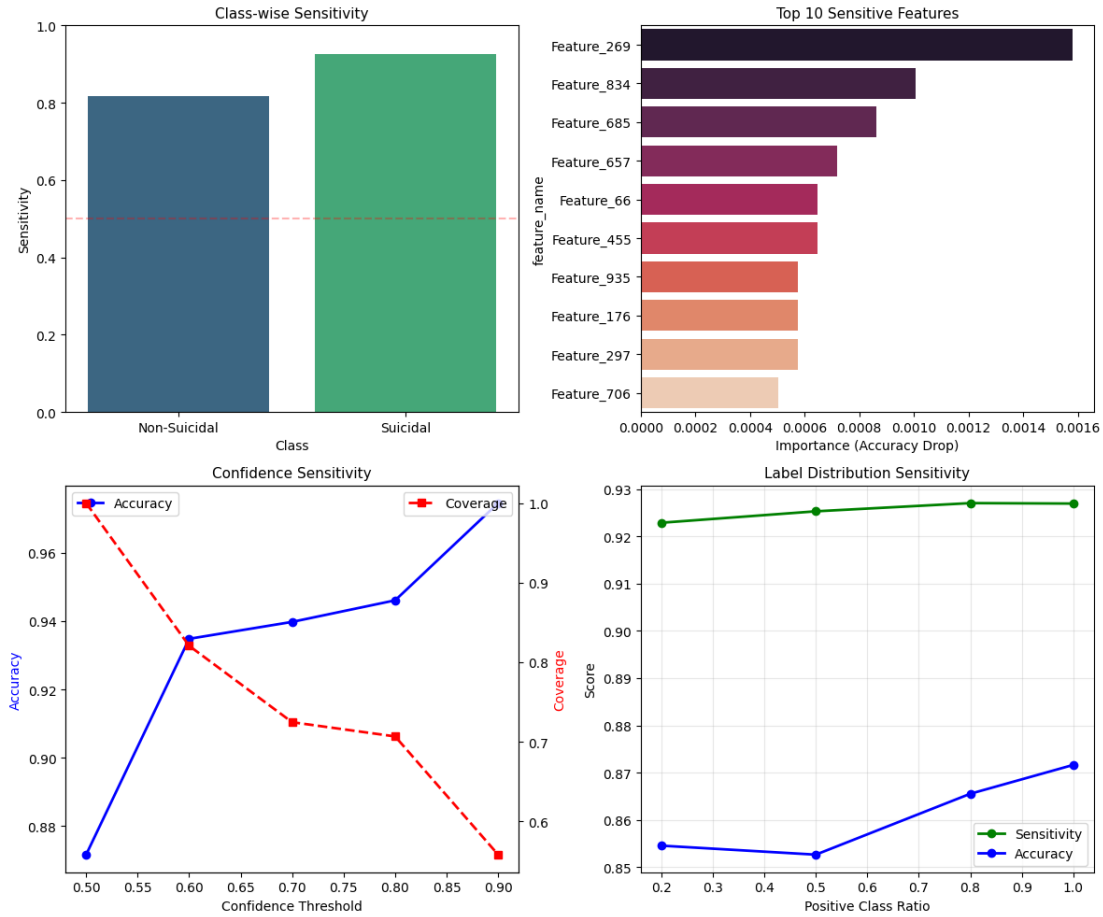
$$I_j = \frac{1}{R}\sum_{r=1}^{R}\left(Acc_{baseline} - Acc_{permuted_r,j}\right)$$

تحلیل حساسیت نسبت به آستانه اطمینان، با هدف بررسی توازن میان دقت پیش‌بینی و پوشش سیستم طراحی گردید که این خود ملاحظه‌ای حیاتی برای کاربرد عملی سیستم‌های هوش مصنوعی در حوزه سلامت روان به شمار می‌رود. احتمالات پیش‌بینی از طبقه‌بند گروهی مبتنی بر رأی‌گیری نرم (Soft Voting Ensemble) استخراج شده و عملکرد مدل در محدوده‌ای از آستانه‌های اطمینان $\tau \in \{0.5, 0.6, 0.7, 0.8, 0.9\}$ ارزیابی گردید. برای هر آستانه τ، پیش‌بینی‌هایی که در آنها حداکثر احتمال پیش‌بینی شده $max(p(y \mid x)) \geq \tau$ بود، فیلتر شده و هر دو معیار دقت (به عنوان سنجه‌ای از صحت) و پوشش (نسبت نمونه‌های باقی‌مانده در آن آستانه) محاسبه شدند. این رویکرد دومعیاره، به متخصصان این امکان را می‌دهد که بر اساس نیازمندی‌های خاص خود، نقطه عملیاتی مناسبی را انتخاب نمایند: آستانه‌های بالاتر، صحت را ارجحیت می‌دهند اما خودکارسازی را کاهش می‌دهند، در حالی که آستانه‌های پایین‌تر، پوشش را بیشینه ساخته و این کار را به بهای افزایش خطاهای احتمالی انجام می‌دهند.

به علاوه، تحلیل حساسیت نسبت به توزیع برچسب‌ها را برای ارزیابی استحکام مدل در برابر تغییرات نامتوازنی کلاس‌ها انجام دادیم که چالشی رایج در هنگام به‌کارگیری مدل‌ها بر روی جمعیت‌هایی با نرخ‌های پایه متفاوت از افکار خودکشی به شمار می‌رود. توزیع کلاس‌های مجموعه آزمون را با تغییر نسبت نمونه‌های خودکشی‌گرا به غیرخودکشی‌گرا در چهار سطح (۸۰:۲۰، ۵۰:۵۰، ۲۰:۸۰ و ۰:۱۰۰ که در آن تنها از نمونه‌های مثبت به همراه دو برابر تعداد نمونه‌های منفی استفاده شد) به طور مصنوعی دستکاری کردیم. برای هر پیکربندی، تعداد متناظری از نمونه‌ها از هر کلاس به صورت تصادفی و بدون جایگذاری انتخاب گردید و تنوع مجموعه آزمون

اصلی از طریق نمونه‌گیری طبقه‌ای حفظ شد. این تحلیل، میزان افت عملکرد مدل را در مواجهه با نسبت‌های مختلف کلاس‌ها مورد سنجش قرار می‌دهد که برای درک قابلیت تعمیم‌پذیری آن در محیط‌های کاربرد گوناگون، که در آنها شیوع محتوای خودکشی‌گرا ممکن است به طور قابل‌توجهی با توزیع داده‌های آموزش متفاوت باشد، ضروری است.

به منظور دستیابی به بینش‌های عمیق‌تر در مورد حالت‌های شکست مدل، یک تحلیل خطای متمرکز با بررسی رابطه میان اطمینان پیش‌بینی و احتمال طبقه‌بندی نادرست انجام دادیم. از مجموعه آزمون، ۱,۰۰۰ نمونه را (به منظور کارایی محاسباتی همزمان با حفظ نمایندگی آماری) انتخاب کرده و بر اساس حداکثر احتمال پیش‌بینی شده، دسته‌بندی نمودیم. نمونه‌هایی با $max(p) < ۰.۶$ در گروه «پیش‌بینی‌های نامطمئن» قرار گرفتند، در حالی که نمونه‌هایی که برچسب پیش‌بینی‌شده‌شان با برچسب حقیقی مطابقت نداشت، به عنوان «طبقه‌بندی‌های نادرست» دسته‌بندی شدند. سپس هم‌پوشانی میان این دو مجموعه را محاسبه کردیم تا کمّی کنیم که اطمینان پیش‌بینی تا چه اندازه می‌تواند به عنوان نمایه‌ای برای قابلیت اعتماد پیش‌بینی عمل کند؛ این ملاحظه‌ای حیاتی برای توسعه سیستم‌های هم‌تراز با اعتماد (Trust-Calibrated) به شمار می‌رود که در آنها می‌توان از نمرات اطمینان برای فعال‌سازی فرایند بررسی انسانی بهره گرفت.



شکل ۲-۱۱

تمامی تحلیل‌ها با استفاده از زبان برنامه‌نویسی پایتون و کتابخانه scikit-learn Pedregosa و همکاران، ۲۰۱۱) پیاده‌سازی شده و به منظور بهینه‌سازی عملکرد محاسباتی برای داده‌های بزرگ‌مقیاس، از پردازش موازی با استفاده از ThreadPoolExecutor بهره گرفته شد. خط‌لوله کامل تحلیل، بر روی سیستمی با منابع محاسباتی کافی اجرا گردید و زمان کل اجرا از طریق تکنیک‌های نمونه‌گیری راهبردی که ضمن حفظ اعتبار آماری، امکان‌پذیری عملی را برای کاربردهای پردازش زبان طبیعی در مقیاس بزرگ تضمین می‌نمود، بهینه‌سازی شد. کد و اسکریپت‌های تحلیل برای قابلیت بازتولید، در صورت درخواست در دسترس خواهند بود.

پژوهش حاضر با هدف توسعه یک چارچوب پردازش زبان طبیعیِ سبک‌وزن و تفسیرپذیر برای تشخیص افکار خودکشی از متون بالینی طراحی شده است؛ با تأکید ویژه بر دستیابی به عملکرد پیش‌بینی بالا، بدون تحمیل سربار محاسباتیِ معمول در معماری‌های یادگیری عمیق. یافته‌ها نشان می‌دهند که دسته‌بندِ مبتنی بر اجتماع مدل‌های XG_Boost همراه با راهبردِ آستانه تصمیم‌گیری قابل تنظیم، به دقتی استثنایی دست می‌یابد و در عین حال کارایی محاسباتی و شفافیت را حفظ می‌کند. این نتایج پیامدهای مهمی برای ترجمه ابزارهای تصمیم‌یار مبتنی بر پردازش زبان طبیعی به محیط‌های بالینیِ روزمره دارند؛ به‌ویژه در شرایطی که منابع محدود هستند و سخت‌افزار پیشرفته معمولاً در دسترس نمی‌باشد.

پیامدهای بالینیِ چارچوب پیشنهادی فراتر از توان پیش‌بینیِ بی‌واسطه آن است. این چارچوب با ارائه ابزاری تصمیم‌یار شفاف، کارآمد و قابل تنظیم، مزایای عملی متعددی برای خدمات سلامت روان به همراه دارد. نخست، تفسیرپذیری دسته‌بند XG_Boost به پزشکان امکان می‌دهد تا مبنای طبقه‌بندیِ خطر را درک کنند؛ امری که از قضاوت بالینیِ آگاهانه پشتیبانی می‌کند، نه پذیرشِ منفعلانه خروجی‌های الگوریتمی. این شفافیت برای حفظ استقلال بالینی و پاسخگویی حرفه‌ای که زیربنای ارائه اخلاقیِ مراقبت‌های سلامت است، ضروری می‌باشد. دوم، راهبرد آستانه قابل تنظیم به تیم‌های بالینی این امکان را می‌دهد که رفتار مدل را با اولویت‌های محلی و محدودیت‌های منابع خود هماهنگ سازند و در نتیجه، تناسب زمینه‌ایِ ارزیابیِ خودکار خطر را افزایش دهند. سوم، کارایی محاسباتیِ چارچوب تضمین می‌کند که ابزار تصمیم‌یار مبتنی بر پردازش زبان طبیعی می‌تواند در مراکزی که زیرساخت پیشرفته در دسترس نیست، از جمله مراکز سلامت روانِ اجتماع‌محور، درمانگاه‌های مراقبت اولیه و خدمات سلامت از راه دور، پیاده‌سازی شود.

از منظر نظام‌های سلامت، رویکرد پیشنهادی پتانسیل آن را دارد که به شناسایی زودهنگام افراد در معرض خطر خودکشی کمک کند، مداخله به‌موقع را تسهیل نماید و به‌طور بالقوه، میزان مرگ‌ومیر را کاهش دهد. با توجه به اینکه کدهای ساختاریافته ICD ممکن است تا ۸۰ درصد از افکار، رفتارها و رویدادهای مرتبط با خودکشیِ مستندشده در یادداشت‌های بالینی را از قلم بیندازند، توانایی استخراج شاخص‌های خطر از متون روایی، نشان‌دهنده بهبود چشمگیری نسبت به روش‌های مراقبتیِ موجود است. این چارچوب با عملکرد شفاف بر روی سخت‌افزار استاندارد، می‌تواند با حداقل اختلال در گردش کار موجود، در پرونده‌های الکترونیک سلامت ادغام شود و امکان نظارت غیرفعال و مستمر بر مستندات بالینی و علامت‌گذاری خودکار موارد پرخطر برای بررسی پزشک را فراهم آورد.

برجسته‌ترین نقطه قوت چارچوب پیشنهادی، توانایی آن در دستیابی به عملکرد پیش‌بینیِ هم‌طراز با وضعیتِ هنر، بدون اتکا به معماری‌های محاسباتیِ سنگین مبتنی بر ترنسفورمر است. در حالی که رویکردهای معاصری همچون BERT و RoBERTa

نیازمند منابع قابل‌توجه GPU و زمان‌های طولانی آموزش هستند، دسته‌بندِ اجتماع XG_Boost ما با حداقل تأخیر و بر روی سخت‌افزار استاندارد به‌طور مؤثر عمل می‌کند. این صرفه‌جوییِ محاسباتی از اهمیت عملیِ ویژه‌ای برخوردار است؛ چرا که به مانعی پایدار در مسیر پیاده‌سازی بالینی که در سراسر ادبیات پژوهش شناسایی شده است، می‌پردازد: ناسازگاری میان نیازمندی‌های سخت‌افزاریِ مدل‌های پیشرفته پردازش زبان طبیعی و زیرساخت‌های فناورانه محیط‌های بالینیِ معمول. پژوهش حاضر با نشان دادن اینکه روش‌های کلاسیکِ بهینه‌سازی شده می‌توانند با عملکرد مدل‌های به‌مراتب پیچیده‌تر رقابت کنند، این فرض رایج را به چالش می‌کشد که یادگیری عمیق تنها مسیر دستیابی به دقت بالا در پردازش زبان طبیعیِ بالینی است.

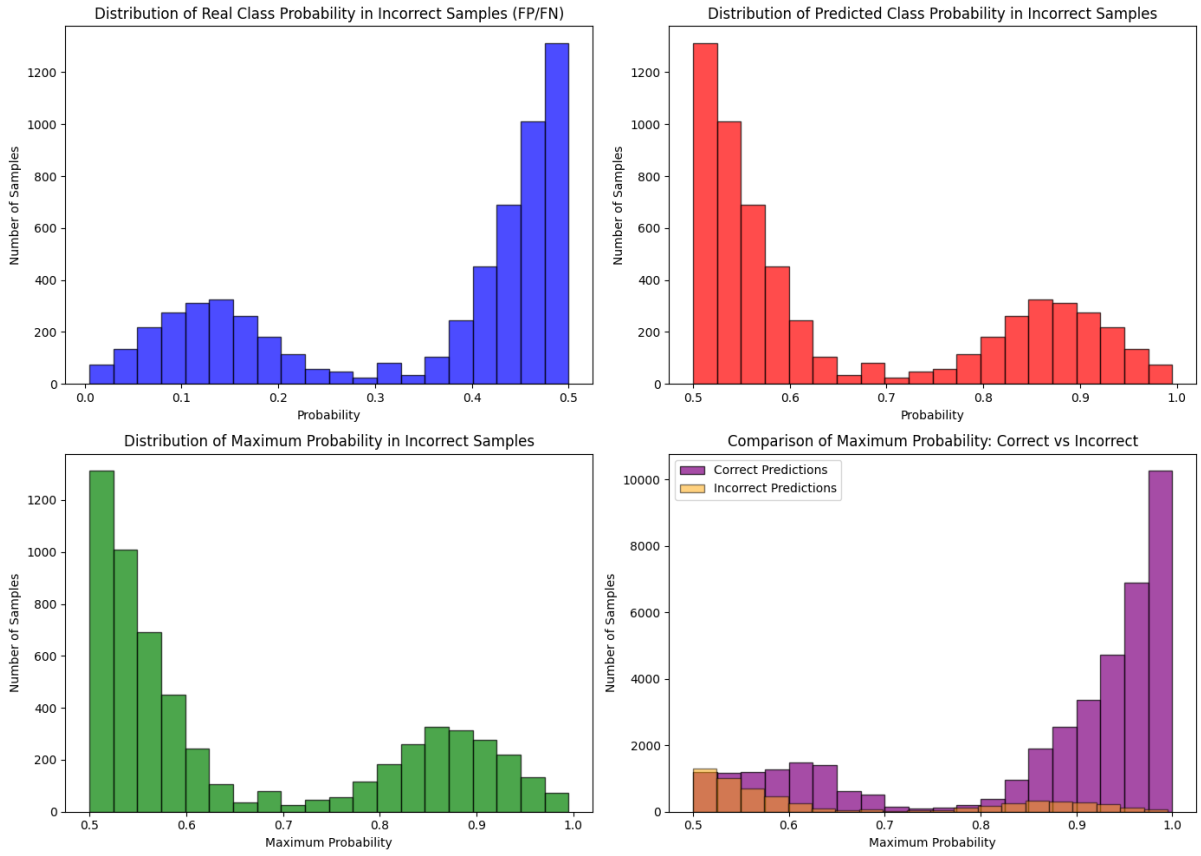
به‌علاوه، شفافیت چارچوب پیشنهادی، مزیتی حیاتی نسبت به جایگزین‌های جعبه‌سیاهِ یادگیری عمیق محسوب می‌شود. در محیط‌های بالینی، که تصمیمات پیامدهای عمیقی برای سلامت بیمار دارند، تفسیرپذیریِ پیش‌بینی‌های مدل نه‌تنها مطلوب، بلکه از نظر اخلاقی الزامی است. معماری XG_Boost با بنیان‌های احتمالاتیِ صریح و مشارکتِ مشخصِ ویژگی‌ها، بینشی در اختیار پزشکان قرار می‌دهد تا منطق پشت طبقه‌بندی‌های خطر را درک کنند. این شفافیت، فرایند اعتمادسازی را که برای پذیرش فناوری در مراقبت‌های سلامت ضروری است، تسهیل می‌کند و به پزشکان امکان می‌دهد در مواقعی که خروجی‌های مدل مبهم یا خلاف انتظار هستند، از صلاحدید مناسب استفاده نمایند.

افزون بر این، راهبرد آستانه قابل تنظیم که در این کار معرفی شده است، نوآوریای عملی محسوب می‌شود که به غفلتی چشمگیر در ادبیات پردازش زبان طبیعیِ بالینی پاسخ می‌دهد. در حالی که پژوهش‌های پیشین به‌طور غالب بر اصلاحات الگوریتمی متمرکز بوده‌اند، توجه نسبتاً کمی به بهینه‌سازیِ سیستماتیکِ آستانه‌های تصمیم‌گیری برای هم‌سوسازی با اولویت‌های بالینی معطوف شده است. این چارچوب با توانمندسازی کاربران نهایی برای کالیبره کردن توازن حساسیت–ویژگی‌بودن بر اساس زمینه عملیاتیِ خود خواه اولویت با تشخیص خطر قریب‌الوقوع باشد یا کاهش هشدارهای اشتباه برای کاستن از بار کاری پزشکان با ناهمگونیِ محیط‌های بالینی سازگار می‌شود. این انعطاف‌پذیری به‌ویژه برای ارزیابی خطر خودکشی ارزشمند است، جایی که هزینه‌های نامتقارن خطاهای طبقه‌بندی نیازمند بررسی دقیق می‌باشند.

علیرغم این نقاط قوت، پژوهش حاضر با چند محدودیت مواجه است که شایسته تصریح بوده و جهت‌گیری‌های روشنی را برای تحقیقات آینده ترسیم می‌کند. نخست و مهم‌تر از همه، مسئله امنیت اطلاعات و حریم خصوصی بیمار، نگرانی عمده‌ای است که چارچوب کنونی ما به‌طور کامل به آن نمی‌پردازد. اگرچه مدل بر روی سخت‌افزار محلی به‌طور کارآمد عمل می‌کند که تا حدی خطرات مرتبط با پردازش ابری را کاهش می‌دهد، اما مدیریت داده‌های متنیِ حساسِ بالینی همچنان با چالش‌هایی همراه است؛ از جمله ذخیره‌سازی و انتقال امن پرونده‌های بیمار، محافظت در برابر حملات تخاصمی که می‌توانند یکپارچگی مدل را به خطر اندازند، و انطباق با چارچوب‌های نظارتی همچون HIPAA و .GDPR تکرارهای آتیِ چارچوب باید تکنیک‌های حفظ حریم خصوصی نظیر حریمِ تفاضلی، معماری‌های یادگیری فدرال و محاسبات چندجانبه امن را در خود بگنجانند تا اطمینان حاصل شود که محرمانگی بیمار در سراسر خط لوله پیش‌بینی به‌طور مستحکم حفظ می‌شود.

دوم، بررسی عملکرد مدل در سراسر طیف احتمال، محدودیت مهمی را آشکار ساخته است: دسته‌بندِ اجتماع XG_Boost در محدوده احتمال ۰/۴۵ تا ۰/۵۵ نرخ خطای بالاتری از خود نشان می‌دهد (شکل ۴). این یافته با انتظار نظری همخوانی دارد که بیشترین عدم قطعیت در طبقه‌بندی، نزدیک مرز تصمیم رخ می‌دهد، جایی که احتمالات پسینِ طبقات جایگزین تقریباً برابر هستند. تمرکز

خطاها در این ناحیه، پیامدهای بالینیِ قابل‌توجهی دارد؛ چراکه مواردی که پیش‌بینی‌های مبهمی ارائه می‌دهند یعنی مواردی که در «منطقه عدم قطعیت» قرار می‌گیرند دقیقاً همان مواردی هستند که ممکن است بیشترین بهره را از بررسی بالینیِ تکمیلی ببرند. وجود این الگوی خطا نشان می‌دهد که کالیبراسیونِ اطمینانِ مدل در فاصله میانیِ احتمال ممکن است ناکافی باشد؛ که می‌تواند بازتابی از ابهام ذاتیِ ویژگی‌های زبانیِ مرتبط با افکار خودکشی یا محدودیت‌های فرض استقلال «نایو بیز» در مواجهه با ویژگی‌های پیچیده و به‌هم‌پیوسته متون بالینی باشد.



شکل ۲-۱۲. ناحیه بحرانی

برای رفع این محدودیت، ما معماری تصمیم‌گیریِ ترکیبی را برای پژوهش‌های آینده پیشنهاد می‌کنیم: پیاده‌سازی یک سیستم طبقه‌بندی دومرحله‌ای که در آن پیش‌بینی‌های واقع در فاصله عدم قطعیت بالا (۰/۴۵—۰/۵۵) به مدلی مجزا و احتمالاً پیچیده‌تر ارجاع داده شوند، در حالی که پیش‌بینی‌های خارج از این فاصله توسط دسته‌بند سبک‌وزن «نایو بیز» پردازش شوند. این رویکرد از اصول یادگیری اجتماع و طبقه‌بندی آبشاری الهام می‌گیرد، که در آن مبهم‌ترین موارد توسط مدل‌هایی پردازش می‌شوند که قادر به تعاملات ویژگی‌های مرتبه‌بالاتر و وابستگی‌های زمینه‌ای هستند. به‌طور مشخص، ما پیش‌بینی می‌کنیم که زیرمجموعه مبهم به‌طور مؤثر توسط یک مدل زبانی بزرگ (LLM) با تنظیم دقیق، مانند نسخه تغلیظ‌یافته‌ای از LLaMA یا معماری GPT سازگاریافته با حوزه بالینی، پردازش شود. ظرفیت مدل زبانی بزرگ برای درک عمیق زمینه‌ای، استدلال بر روی وابستگی‌های دوربرد، و تولید توجیهات تفسیرپذیر برای طبقه‌بندی‌های خود، به‌ویژه برای مواردی که مدل XG_Boost عدم قطعیت ابراز می‌کند، ارزشمند خواهد بود. مهم‌تر اینکه، از آنجا که مدل زبانی بزرگ تنها برای زیرمجموعه‌ای از موارد یعنی آنهایی که در محدوده ۰/۴۵ تا ۰/۵۵

قرار می‌گیرند فراخوانی خواهد شد، بار محاسباتیِ کلی به‌طور قابل‌توجهی کمتر از استقرار کامل مدل زبانی بزرگ برای تمام پیش‌بینی‌ها باقی می‌ماند و کارایی عملیِ سیستم ترکیبی حفظ می‌شود.

این رویکرد ترکیبی، مزایای مکمل متعددی را ارائه می‌دهد. نخست، از نقاط قوت هر دو پارادایم بهره می‌برد: کارایی محاسباتی و تفسیرپذیری دسته‌بند XG_Boost برای موارد واضح، و درک زبانیِ پیچیده مدل‌های زبانی بزرگ برای موارد مبهم. دوم، به نیاز بالینی برای ارزیابی خطر قابل اعتماد در سراسر طیف احتمال پاسخ می‌دهد و اطمینان حاصل می‌کند که مواردی که واقعاً نیازمند تفسیر ظریف هستند، توجه مناسب را دریافت می‌کنند. سوم، سازوکاری طبیعی برای اعتبارسنجی با حضور انسان در چرخه فراهم می‌آورد؛ زیرا پیش‌بینی‌های مبهمی که برای تحلیل توسط مدل زبانی بزرگ علامت‌گذاری شده‌اند، می‌توانند برای بررسی پزشک نیز نمایش داده شوند و تصمیم‌گیریِ مشارکتی را ترویج دهند. چهارم، این معماری با پیشرفت‌های اخیر در پیش‌بینیِ انتخابی و یادگیریِ ماشینِ آگاه از عدم قطعیت همسو است، که تشخیص می‌دهد همه نمونه‌ها به یک سطح از ظرفیت مدل نیاز ندارند.

به‌علاوه، ترکیب مدل‌های سبک‌وزن و سنگین درون یک چارچوب تصمیم‌گیریِ یکپارچه، می‌تواند پذیرش تدریجیِ پردازش زبان طبیعی را در عمل بالینی تسهیل کند. با استقرار دسته‌بند XG_Boost به‌عنوان ابزار اصلی و اختصاص پردازش مدل زبانی بزرگ به موارد مبهم، مؤسساتی که دارای منابع محاسباتیِ محدود هستند، می‌توانند بلافاصله از ارزیابی خودکار خطر استفاده کنند و در عین حال به‌تدریج زیرساخت‌های لازم را برای یکپارچه‌سازی جامع‌تر مدل‌های زبانی بزرگ فراهم آورند. این رویکرد پلکانی برای پذیرش، ممکن است در محیط‌های بالینی نسبت به انتقال یک‌باره به معماری‌های سنگینِ محاسباتی، عملی‌تر و پذیرفتنی‌تر باشد.

فصل سوم

سپری از اعداد؛ طراحی و پیاده‌سازی بستر امن تبادل داده با بهره‌گیری از رمزگذاری هم‌ریخت

" حریم خصوصی یک حق نیست، بلکه پیش‌نیاز هر جامعه‌ی آزاد و هر سیستم هوشمندی است که به داده‌های حساس دسترسی دارد".

بروس اشنایر(رمزنگار و امنیت‌دان)

در فصل پیشین، موفق به پیاده‌سازی مدلی مشارکتی مبتنی بر رویکرد XG-Boost شدیم که توانست با دقتی قابل‌قبول، ریسک خودکشی را مبتنی بر داده‌های متنی پیش‌بینی نماید. بااین‌حال، یکی از چالش‌های اساسی در چنین معماری‌هایی، نحوه تبادل اطلاعات میان سرور و کلاینت‌هاست. با توجه به آنکه هیچ‌گونه تضمین مطلقی برای امنیت کامل کانال‌های ارتباطی وجود ندارد، تأمین امنیت فرایند انتقال داده در این سامانه، از اهمیتی راهبردی برخوردار می‌گردد. در این راستا، ساختار پیشنهادی بر به‌کارگیری روش‌های رمزنگاری کلیدعمومی استوار شده است. در گام نخست، سرور ورودی جدید خود که به‌صورت یک رشته متنی ارائه می‌شود را پس از رمزنگاری، برای تمامی کلاینت‌ها ارسال می‌کند. هر کلاینت پس از رمزگشایی متن دریافتی، با استفاده از مدل محلی خود و مبتنی بر پایگاه داده بومی، احتمال خودکشی مربوط به آن ورودی را برآورد می‌سازد. شایان ذکر است که سرور کلید عمومی خود را بر روی کانالی ناامن اعلام می‌دارد و کلاینت‌ها با بهره‌گیری از همین کلید، مقادیر احتمال محاسبه‌شده را رمزگذاری نموده و به سرور بازمی‌فرستند. سرور نیز پس از گردآوری تمامی مقادیر رمزگذاری‌شده، با تکیه بر ویژگی‌های هم‌ریختیِ روش‌های به‌کاررفته، عملیات تجمیع را انجام داده و درنهایت، تنها یک‌بار اقدام به رمزگشایی نتیجه نهایی با کلید خصوصی خود می‌نماید. این مقدار نهایی، منطبق بر میانگین مقادیر ارسالی از سوی تمامی کلاینت‌ها خواهد بود؛ بدین‌ترتیب، بدون افشای اطلاعات فردی هر کلاینت، برآورد نهایی به‌دست می‌آید.

۳-۱ رمزگذاری متن ورودی با استفاده از AES-GCM

در گام نخست لازم است تا سرور ورودی متنی خود را به صورت رمزگذاری شده برای کلاینت‌ها ارسال کند. معماری پیشنهادی این پژوهش از ترکیب دو لایه‌ی رمزگذاری مجزا اما به‌هم‌پیوسته تشکیل شده است. در لایه‌ی نخست، سرور یک کلید نشست ۲۵۶بیتی با استفاده از الگوریتم AES در حالت GCM تولید کرده و متن فارسی دریافتی را با آن رمزنگاری می‌کند. در لایه‌ی دوم، همین کلید نشست به عنوان یک راز[۱] در نظر گرفته شده و با به‌کارگیری طرح تسهیم راز شامیر[۲] به تعداد کلاینت‌های موجود، به چندین سهم[۳] تبدیل می‌شود. این سهم‌ها به‌گونه‌ای طراحی شده‌اند که بازسازی کلید اصلی تنها در صورتی ممکن است که تعداد مشخصی از آن‌ها (آستانه‌ی تعیین‌شده) گردآوری شوند. بدین ترتیب، نه تنها داده در حالت انتقال محافظت می‌شود، بلکه کلید رمزگشایی نیز هرگز به‌طور کامل در اختیار یک عامل قرار نمی‌گیرد.

برای تأمین محرمانگی و تمامیت داده‌ها، الگوریتم AES-۲۵۶ در حالتGCM [۴] انتخاب شده است. این انتخاب مبتنی بر دو ویژگی کلیدی این حالت است: نخست، GCM یک حالت رمزگذاری تأییدپذیر[۵] به شمار می‌رود که به طور هم‌زمان محرمانگی و اصالت پیام را تضمین می‌کند؛ دوم، استفاده از طول کلید ۲۵۶ بیت، سطح امنیتی متناسب با استانداردهای رمزنگاری مدرن را فراهم می‌آورد. در این پروتکل، کلید نشست K از فضای $\{۰,۱\}^{256}$ توسط یک تولیدکننده‌ی اعداد شبه‌تصادفی رمزگذاری‌شده[۶] سیستم‌عامل تولید می‌شود.

---

۱. Secret
۲. Shamir Secret Sharing
۳. Share
۴. Galois/Counter Mode
۵. AEAD
۶. CSPRNG

به ازای هر پیام، یک مقدار nonce تصادفی ۹۶-بیتی منحصربه‌فرد تولید شده و فرآیند رمزگذاری به صورت رابطه زیر انجام می‌گیرد که در آن M متن اصلی، A داده‌ی احرازشونده‌ی اضافی، C متن رمزگذاری‌شده و T برچسب احراز اصالت است. در مرحله‌ی رمزگشایی، الگوریتم با دریافتK ، N، C، Tو A ، تنها در صورتی متن اصلی M را بازمی‌گرداند که اعتبارسنجی GCM با موفقیت انجام شود؛ در غیر این صورت، هرگونه تغییر در متن رمز، nonce یا داده‌ی احرازشونده به‌صورت قطعی شناسایی و رد می‌شود.

$$(\mathrm{C}, \mathrm{T}) = \mathrm{AES} - \mathrm{GCM}.\,\mathrm{Enc}(\mathrm{K}, \mathrm{N}, \mathrm{M}, \mathrm{A})$$

۳-۱-۱ ضرورت و مبانی طرح تسهیم راز شامیر

تمرکز اختیار رمزگشایی در یک کلاینت واحد، یک نقطه‌ی شکست بحرانی در سیستم‌های توزیع‌شده محسوب می‌شود. برای رفع این آسیب‌پذیری، از طرح تسهیم راز شامیر با پارامترهای (t,n) استفاده شده است. در این طرح، کلید نشست AES به عنوان راز اصلی در نظر گرفته شده و به n سهم تقسیم می‌گردد، به‌گونه‌ای که بازسازی راز به حداقل t سهم نیاز دارد. در پیکربندی پیش‌فرض این پروتکل، مقدار t برابر با n در نظر گرفته شده است که مستلزم همکاری تمام کلاینت‌ها برای دستیابی به کلید است. این روش نه تنها وابستگی به یک نقطه‌ی واحد را از میان برمی‌دارد، بلکه امکان تعریف سیاست‌های امنیتی انعطاف‌پذیر را از طریق تغییر پارامتر آستانه فراهم می‌سازد.

پیاده‌سازی طرح شامیر نیازمند انجام محاسبات در یک میدان متناهی با مشخصات معین است. در این پژوهش، میدان GF(p) با عدد اول $p=۲^{۵۲۱}-۱$ انتخاب شده است که به مراتب بزرگ‌تر از فضای کلید ۲۵۶-بیتی بوده و از بروز مشکلات ناشی از هم‌نهشتی جلوگیری می‌کند. راز اصلی s که معادل کلید AES در نظر گرفته می‌شود، به عنوان جمله‌ی ثابت یک چندجمله‌ای تصادفی از درجه‌ی t-۱ مانند رابطه زیر در نظر گرفته می‌شود؛ که در آن $a_0=s$ و سایر ضرایب توسط تولیدکننده‌ی اعداد شبه‌تصادفی رمزگذاری‌شده تولید می‌شوند.

$$\mathrm{f(x)} = \mathrm{a_0} + \mathrm{a_1 x} + \mathrm{a_2 x^2} + \cdots + a_{t-۱}\, x^{t-۱} \bmod \mathrm{p}$$

برای هر کلاینت i داریم:

$$x_i = i, \qquad i = ۱,۲, \ldots, n$$

۳-۱-۲ بازسازی کلید با درون‌یابی لاگرانژ

هنگامی که حداقل t سهم از کلاینت‌های مشارکت‌کننده گردآوری شوند، فرآیند بازسازی راز اصلی با استفاده از روش درون‌یابی لاگرانژ در نقطه‌ی صفر آغاز می‌گردد. این روش بر این اصل استوار است که یک چندجمله‌ای از درجه‌ی حداکثر $t-۱$ به‌طور یکتا توسط t نقطه تعیین می‌شود. از آنجا که چندجمله‌ای اصلی $f(x)$ درجه‌ای برابر با $t-۱$ دارد، دانستن t زوج‌مرتبه $(x_i, f(x_i))$ برای تعیین کامل آن کافی است. بازسازی در نقطه‌ی صفر، یعنی محاسبه‌ی $f(۰)$، مقدار راز اصلی s را که همان کلید نشست AES است، آشکار می‌سازد. فرمول بازسازی بر اساس ضرایب لاگرانژ به صورت زیر تعریف می‌شود:

$$f(\cdot) = \sum_{i=1}^{t} y_i \cdot L_i(\cdot) \pmod p$$

در این رابطه، $y_i = f(x_i)$ مقدار سهم مربوط به کلاینت i است و $L_i(\cdot)$ ضریب لاگرانژ برای نقطه‌ی x_i در مبدأ محسوب می‌شود. این ضریب از حاصل‌ضرب نسبت‌های تفاضلی نقاط دیگر به دست می‌آید و به‌صورت زیر محاسبه می‌گردد:

$$L_i(\cdot) = \prod_{\substack{j=1 \\ j \neq i}}^{t} \frac{-x_j}{x_i - x_j} \pmod p$$

به بیان دیگر، هر سهم y_i در ضریب لاگرانژ متناظر خود ضرب شده و مجموع این حاصل‌ضرب‌ها، مقدار چندجمله‌ای را در نقطه‌ی صفر بازمی‌گرداند. این فرآیند از دیدگاه ریاضی، درون‌یابی منحصربه‌فرد چندجمله‌ای از میان نقاط داده‌شده و سپس ارزیابی آن در مبدأ است. ویژگی کلیدی این روش آن است که هیچ‌یک از سهم‌ها به‌تنهایی یا در ترکیب با تعداد کم‌تر از آستانه، قادر به بازسازی راز نیستند؛ چراکه در این حالت، به ازای هر مقدار فرضی برای $f(\cdot)$، یک چندجمله‌ای درجه‌ی $t-1$ موجود است که با تمام نقاط موجود سازگار باشد. بنابراین، از دیدگاه تئوری اطلاعات، داشتن کمتر از t سهم هیچ اطلاعی درباره‌ی راز اصلی فاش نمی‌کند.

برای روشن‌تر شدن مفهوم آستانه، می‌توان به دو پیکربندی متفاوت اشاره کرد. در حالتی که تعداد کلاینت‌ها و آستانه هر دو برابر با ۵ باشند، یعنی $(n,t) = (5,5)$، حتی اگر چهار کلاینت با یکدیگر تبانی کنند و سهم‌های خود را گرد آورند، بازسازی کلید غیرممکن خواهد بود و آن‌ها هیچ گونه اطلاعات معنی‌داری درباره‌ی کلید اصلی به دست نخواهند آورد. در مقابل، در پیکربندی $(n,t) = (5,3)$، هر سه کلاینت می‌توانند با هم‌کاری یکدیگر و بدون نیاز به مشارکت دو کلاینت دیگر، کلید را به‌طور کامل بازسازی نمایند. این تفاوت اساسی نشان می‌دهد که پارامتر آستانه t صرفاً یک عدد نیست، بلکه بیانگر یک سیاست امنیتی عینی در سیستم است. به عبارت دقیق‌تر، انتخاب t تعیین می‌کند که برای دسترسی به داده‌ی محافظت‌شده، چه تعداد از عامل‌ها باید با یکدیگر همکاری کنند و این همکاری تا چه سطحی در برابر تبانی مقاومت می‌کند. در نتیجه، مقدار t را می‌توان بر اساس نیازمندی‌های امنیتی، سطح اعتماد به کلاینت‌ها، و ریسک‌پذیری سیستم تعیین و تنظیم نمود.

۳-۱-۳ ویژگی‌های امنیتی بنیادین

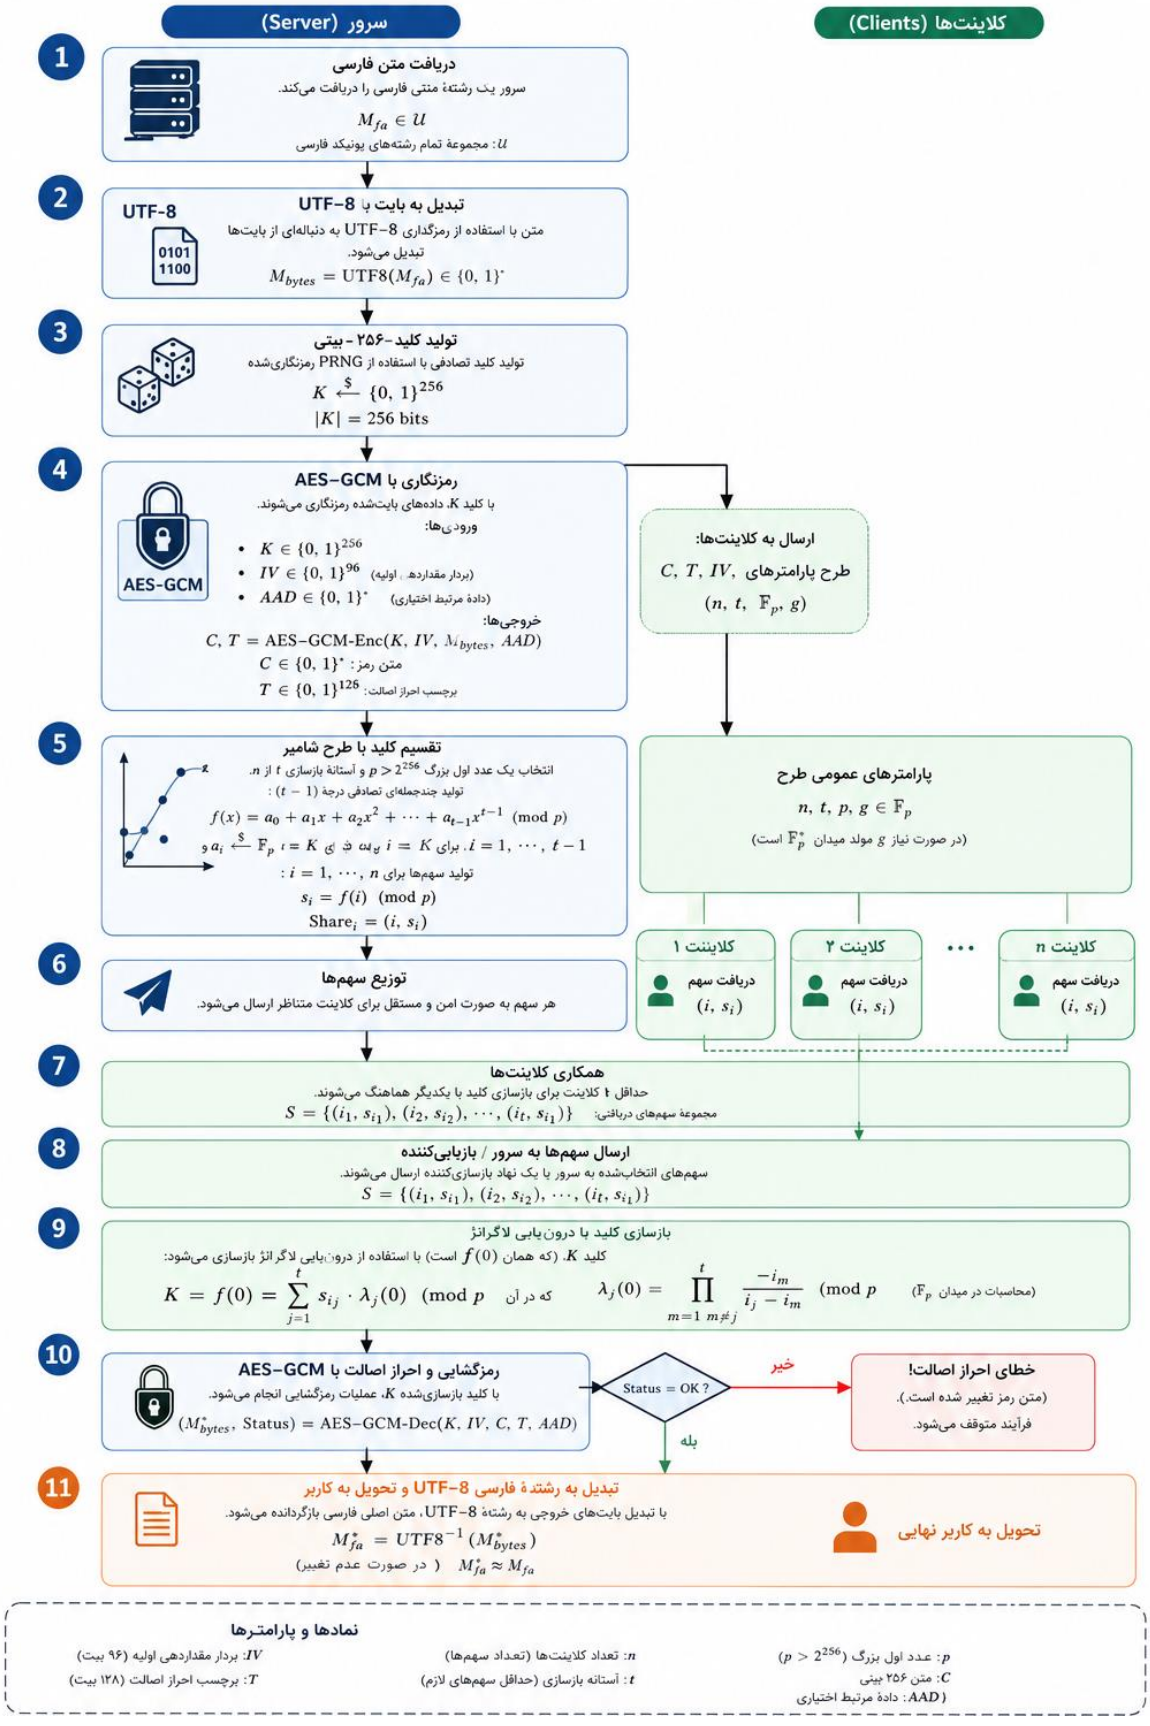
طرح تسهیم راز شامیر از ویژگی امنیتی اطلاع‌صفر[1] برخوردار است، بدین معنا که هر مجموعه‌ای با کمتر از t سهم، هیچ گونه اطلاعاتی درباره‌ی راز اصلی ارائه نمی‌دهد. این ویژگی مستقل از توان محاسباتی مهاجم بوده و بر پایه‌ی استواری ریاضیاتی طرح استوار است. در این پژوهش، با فرض اجرای صحیح الگوریتم و استفاده از میدان متناهی مناسب، این تضمین امنیتی به طور کامل محقق می‌شود. همچنین، با توجه به اینکه هر کلاینت تنها به یک سهم دسترسی دارد، حتی در صورت تبانی تعداد محدودی از کلاینت‌ها (کمتر از آستانه)، راز اصلی در امان خواهد ماند.

---

۱. Information-Theoretic Security

۳-۱-٤ جریان کامل پروتکل

پروتکل پیشنهادی از یازده مرحله‌ی مشخص تشکیل شده است که به ترتیب اجرا می‌شوند. در مرحله‌ی نخست، سرور متن فارسی را به صورت یک رشته‌ی کاراکتری دریافت می‌کند. در مرحله‌ی دوم، این متن با استفاده از رمزگذاری UTF-۸ به دنباله‌ای از بایت‌ها تبدیل می‌شود تا تمام نویسه‌های فارسی، اعداد و علائم به‌درستی پردازش شوند. مرحله‌ی سوم شامل تولید کلید ۲۵۶-بیتی توسط تولیدکننده‌ی اعداد شبه‌تصادفی رمزگذاری‌شده است. در مرحله‌ی چهارم، عملیات رمزگذاری AES-GCM بر روی داده‌های بایت‌شده انجام شده و متن رمز و برچسب احراز اصالت تولید می‌شوند. مرحله‌ی پنجم، کلید تولیدشده را با استفاده از طرح شامیر به n سهم تبدیل می‌کند. در مرحله‌ی ششم، هر سهم به طور جداگانه در اختیار کلاینت متناظر قرار می‌گیرد. مراحل هفتم تا نهم به همکاری کلاینت‌ها، گردآوری سهم‌ها و بازسازی کلید از طریق درون‌یابی لاگرانژ اختصاص دارد. در مرحله‌ی دهم، کلید بازسازی‌شده برای رمزگشایی متن رمز به کار گرفته می‌شود. در مرحله‌ی یازدهم، خروجی رمزگشایی‌شده از قالب بایت به رشته‌ی فارسی UTF-۸ تبدیل شده و در اختیار کاربر نهایی قرار می‌گیرد. لازم به ذکر است که در صورت تغییر متن رمز در طول مسیر، لایه‌ی GCM خطای احراز اصالت صادر کرده و فرآیند را متوقف می‌سازد.



شکل ۳-۱ رویه رمزگذاری متن ارسالی از سرور به کلاینت‌ها

۳-۱-۵ مدل تهدید و تحلیل پیچیدگی محاسباتی، امنیت و آسیب‌پذیری‌ها

برای ارزیابی امنیت پروتکل، چهار سناریوی تهدید اصلی مورد بررسی قرار گرفته است. در سناریوی اول، مهاجم شبکه موفق به شنود متن رمز می‌شود؛ اما بدون دسترسی به تعداد کافی سهم، قادر به بازیابی متن اصلی نخواهد بود. در سناریوی دوم، یک کلاینت کنجکاو صرفاً به سهم خود دسترسی دارد و در شرایطی که $t>1$ باشد، به تنهایی نمی‌تواند کلید را بازسازی کند. در سناریوی سوم، گروهی از کلاینت‌های تبانی‌کننده با جمع‌آوری سهم‌های خود، تنها در صورتی موفق به بازسازی می‌شوند که تعداد آن‌ها به آستانه‌ی تعیین‌شده برسد؛ در غیر این صورت، حتی با وجود همکاری، راز اصلی قابل بازیابی نیست. سناریوی چهارم به دستکاری عمدی متن رمز اختصاص دارد که توسط برچسب احراز اصالت GCM شناسایی و خنثی می‌شود. همچنین، سرور در این معماری پس از تولید سهم‌ها، کلید نشست را در حافظه‌ی خود نگهداری نمی‌کند و صرفاً بسته‌ی رمزگذاری‌شده و سهم‌ها را به خروجی پروتکل تحویل می‌دهد.

پیچیدگی محاسباتی پروتکل از سه بخش اصلی تشکیل می‌شود. بخش نخست، تولید سهم‌ها با استفاده از ارزیابی چندجمله‌ای در nنقطه از درجه $t-1$ است که از مرتبه‌ی $O(nt)$ عملیات میدان را به خود اختصاص می‌دهد. بخش دوم، بازسازی کلید با استفاده از درون‌یابی لاگرانژ با t سهم است که پیچیدگی $O(t^2)$ دارد. بخش سوم، عملیات رمزگذاری AES-GCM بر روی داده‌هایی به طول L است که از مرتبه‌ی $O(L)$ محسوب می‌شود. بنابراین، برای متن‌های طولانی، هزینه‌ی غالب مربوط به لایه‌ی AES است و سربار ناشی از طرح شامیر، که صرفاً بر روی کلید ۲۵۶-بیتی اعمال می‌شود، در مقایسه با آن ناچیز است. این ویژگی، پروتکل پیشنهادی را برای کاربردهای عملی با حجم داده‌ی بالا مقرون‌به‌صرفه می‌سازد.

سامانه‌ی طراحی‌شده از دو سطح مجزا برای تأمین امنیت داده بهره می‌برد. سطح نخست، که «محرمانگی داده» نامیده می‌شود، توسط AES-۲۵٦-GCM تأمین می‌گردد و از مشاهده‌ی متن آشکار توسط شنودگران شبکه جلوگیری می‌کند. سطح دوم، که «امنیت توزیع کلید» نام دارد، توسط طرح تسهیم راز شامیر پیاده‌سازی شده و تضمین می‌کند که کلید رمزگشایی در هیچ کلاینت منفردی به‌طور کامل وجود نداشته باشد. این طراحی، مهاجم را ملزم به دسترسی هم‌زمان به متن رمز و حداقل t سهم از کلاینت‌ها می‌کند که به ویژه در حالت$t=n$ ، دستیابی به کلید را منوط به همکاری کامل تمام کلاینت‌ها می‌سازد.

۳-۲ ارسال اطلاعات از کلاینت‌ها به مت سرور به کمک رمزگذاری هم‌ریخت

رمزگذاری هم‌ریخت به‌عنوان یک پارادایم بنیادین در رمزنگاری مدرن، امکان انجام محاسبات روی داده‌های رمزشده را بدون افشای محتوای آشکار آن‌ها فراهم می‌آورد. این ویژگی، کاربردهای گسترده‌ای در حوزه‌های حساس به حریم خصوصی از جمله یادگیری ماشین روی داده‌های محرمانه، سیستم‌های رأی‌گیری الکترونیکی، آمارگیری مبتنی بر داده‌های رمزشده و پردازش ابری امن دارد. در این پژوهش، پنج طرح برجسته شامل ElGamal ، Paillier، Benaloh، Damgård–Jurik و RSA از منظر مبانی ریاضی، فرایند تولید کلید، توابع رمزنگاری و رمزگشایی، اثبات صحت، و نوع خاصیت هم‌ریختی مورد تحلیل و مقایسه قرار

می‌گیرند. طبقه‌بندی این طرح‌ها بر اساس ماهیت عملگر هم‌ریختی نشان می‌دهد که ElGamal و RSA (در نسخه‌ی پایه) از نوع ضربی و Paillier ، Benaloh و Damgård–Jurik از نوع جمعی هستند.

در بسیاری از کاربردهای رمزنگاری امروزی، نیاز به پردازش بر روی داده‌های رمز شده بدون دسترسی به متن اصلی، به یک الزام کلیدی تبدیل شده است. رمزگذاری هم‌ریخت (به‌ویژه در انواع جزئی یا کاملاً هم‌ریخت) این امکان را فراهم می‌کند که عملگرهای معینی نظیر جمع یا ضرب بر روی متن‌های رمز[۱] به‌گونه‌ای تعریف شوند که نتیجه‌ی رمزگشایی‌شده با اعمال همان عملگر روی متن‌های اصلی[۲] معادل باشد. این ویژگی، پایه‌ی بسیاری از پروتکل‌های امن محاسباتی را شکل می‌دهد.

در این پژوهش، پنج طرح مهم رمزگذاری کلید عمومی هم‌ریخت مورد بررسی تطبیقی قرار می‌گیرند. معیارهای ارزیابی شامل پیشینه، ساختار جبری، امنیت مبتنی بر مسائل دشوار ریاضی، الگوریتم‌های تولید کلید، رمزگذاری و رمزگشایی، اثبات صحت، و نوع هم‌ریختی (جمعی یا ضربی) است.

۳-۲-۱ رمزگذاری ElGamal

طرح ElGamal در سال ۱۹۸۵ توسط طاهر الجمال معرفی شد و در مقاله‌ای[۳] منتشر گردید. این طرح بر پایه دشواری مسئله لگاریتم گسسته[۴] در گروه‌های ضربی متناهی استوار است و ساختاری مشابه با پروتکل تبادل کلید دفی–هلمن[۵] دارد.(پیوست ۳-الف)[۱۷۸]

تولید کلید:

فرض کنید p یک عدد اول بزرگ و g یک مولد از گروه ضربی $\mathbb{Z}_p^*$ باشد. کلید خصوصی x به‌شکل تصادفی از بازه‌ی $\{۱, ۲, \dots, p-۲\}$ انتخاب شده و کلید عمومی y به صورت زیر محاسبه می‌شود:

$$x \in_R \{۱, ۲, \dots, p-۲\},\ y = g^x\ p$$

بنابراین:

$$PK = (p, g, y),\ SK = x$$

---

۲. Ciphertext
۳. Plaintext
۴. A Public Key Cryptosystem and a Signature Scheme Based on Discrete Logarithms
۵. Discrete Logarithm Problem
۶. Diffie–Hellman

رمزگذاری:

برای پیام $m \in \mathbb{Z}_p^*$، یک مقدار تصادفی $k \in_R \{۱, \dots, p-۲\}$ انتخاب شده و متن رمز به صورت زوج‌مرتبه‌ی زیر تولید می‌شود:

$$c_۱ = g^k \; p, \; c_۲ = m \cdot y^k \; p$$
$$C = (c_۱, c_۲)$$

رمزگشایی:

با استفاده از کلید خصوصی x، ابتدا مقدار میانی s محاسبه شده و سپس پیام بازیابی می‌گردد:

$$s = c_۱^x \; p$$
$$m = c_۲ \cdot s^{-۱} \; p$$

شبه‌کد:

Algorithm ElGamal
KeyGeneration(): choose large prime p and generator g of Z_p* choose random x ∈ {۱, ..., p-۲} y ← g^x mod p return PK = (p, g, y), SK = x Encryption(m, PK): choose random k ∈ {۱, ..., p-۲} c۱ ← g^k mod p c۲ ← m · y^k mod p return C = (c۱, c۲) Decryption(C, SK): s ← c۱^x mod p m ← c۲ · s^{-۱} mod p return m

اثبات صحت:

با جای‌گذاری در رابطه رمزگشایی:

$$c_1 = g^k,\ c_2 = m \cdot g^{xk}$$
$$\mathrm{Dec}(C) = c_2 \cdot (c_1^x)^{-1} = m \cdot g^{xk} \cdot (g^{kx})^{-1} = m$$

در نتیجه:

$$\mathrm{Dec}\big(\mathrm{Enc}(m)\big) = m$$

خاصیت هم‌ریختی ضربی:

برای دو متن رمز:

$$C_1 = (g^{k_1}, m_1 y^{k_1}),\ C_2 = (g^{k_2}, m_2 y^{k_2})$$

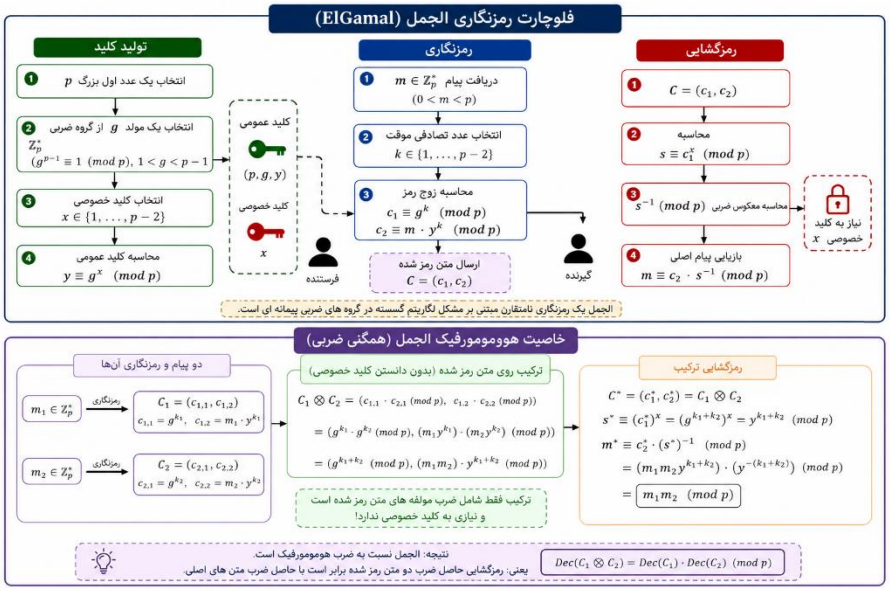
عملگر ضرب مؤلفه‌ای (ضرب نقطه‌ای) به‌صورت زیر تعریف می‌شود:

$$C_1 \otimes C_2 = (g^{k_1+k_2},\ m_1 m_2\ y^{k_1+k_2})$$

که خود معادل با رمزگذاری با انتخاب تصادفی است. لذا: $m_1 m_2 k = k_1 + k_2$

$$\mathrm{Dec}(C_1 \otimes C_2) = m_1 m_2\ p$$

بنابراین ElGamal در نسخه پایه، یک طرح هم‌ریخت جزئی از نوع ضربی محسوب می‌شود.



شکل ۳-۲ طرح رمزگذاری الجمال

۳-۲-۲ رمزگذاری Paillier

سیستم رمزگذاری Paillier در سال ۱۹۹۹ توسط پاسکال پایلیر[۱] معرفی شد. امنیت این طرح مبتنی بر دشواری مسئله باقیمانده‌های مرکب درجه‌ی ۲ است و به‌عنوان یکی از مهم‌ترین طرح‌های هم‌ریخت جمعی شناخته می‌شود[۱۷۹] n

تولید کلید:

دو عدد اول بزرگ p و q انتخاب شده و $n = pq$ محاسبه می‌شود. سپس:

$$\lambda = \mathrm{lcm}(p, -۱q - ۱)$$
$$L(u) = \frac{u - ۱}{n}$$
$$\mu = \left[L\left(g^{\lambda}\ n^{۲}\right)\right]^{-۱}\ n$$

که g معمولاً به‌صورت $g = ۱ + n$ انتخاب می‌شود. کلیدها به‌صورت زیر تعریف می‌گردند:

$$PK = (n, g),\ SK = (\lambda, \mu)$$

رمزگذاری:

برای پیام $m \in \mathbb{Z}_n$ و انتخاب تصادفی $r \in_R \mathbb{Z}_n^*$:

$$c = g^{m} \cdot r^{n}\ n^{۲}$$

رمزگشایی:

$$u = c^{\lambda}\ n^{۲}$$
$$m = L(u) \cdot \mu\ n$$

---

۱. Pascal Paillier

۲. Composite Residuosity Assumption

شبه‌کد:

Algorithm Paillier

```
KeyGeneration():
   choose large primes p, q
   n ← p·q
   λ ← lcm(p-١, q-١)
   choose valid g ∈ Z_{n^٢}^*
   μ ← [L(g^λ mod n^٢)]^{-١} mod n
   return PK = (n, g), SK = (λ, μ)

Encryption(m, PK):
   choose random r ∈ Z_n^*
   c ← g^m · r^n mod n^٢
   return c

Decryption(c, SK):
   u ← c^λ mod n^٢
   m ← L(u) · μ mod n
   return m
```

اثبات صحت:

با استفاده از بسط دو جمله‌ای و ویژگی‌های تابع L داریم:

$$c^{\lambda} = g^{m\lambda} \cdot r^{n\lambda} \equiv g^{m\lambda} \pmod{n^{٢}}$$

چون $r^{n\lambda} \equiv ١ \pmod{n^{٢}}$ (طبق قضیهٔ کارمایکل)، نتیجه می‌شود:

$$L\left(c^{\lambda}\right) \equiv m \cdot L\left(g^{\lambda}\right) \pmod{n}$$

بنابراین:

$$\mathrm{Dec}(c) = L\left(c^{\lambda}\right) \cdot \mu = m$$

خاصیت هم‌ریختی جمعی:

برای دو متن رمز:

$$c_1 = g^{m_1} r_1^{n},\ c_2 = g^{m_2} r_2^{n}$$

ضرب آن‌ها به‌صورت زیر خواهد بود:

$$c_1 \cdot c_2 = g^{m_1+m_2} (r_1 r_2)^{n}\ n^2$$

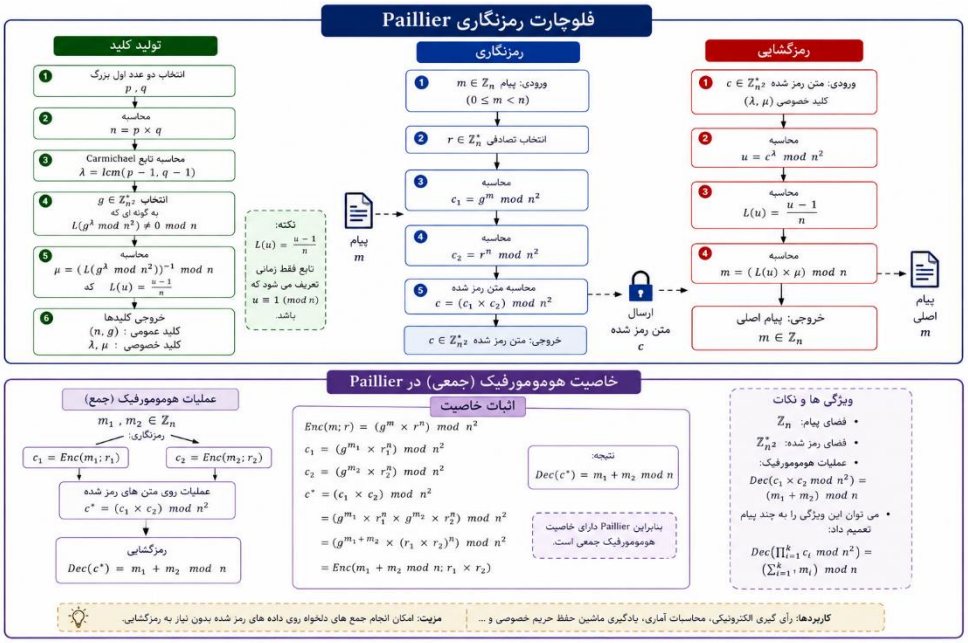
که خود رمزگذاری با تصادفی‌ساز است. لذا: $m_1 + m_2 r_1 r_2$

$$\mathrm{Dec}(c_1 c_2) = m_1 + m_2\ n$$

نیز:

$$\mathrm{Dec}(c^{k}) = k \cdot m\ n$$

بنابراین Paillier یک طرح هم‌ریخت جزئی از نوع جمعی است.



شکل ۳-۳ طرح رمزگذاری Pillier

۳-۲-۳ رمزگذاری بنالوح

طرح بنالوح[۱] که توسط جاش بنالوح[۲] در سال ۱۹۹۴ ارائه شد، امکان رمزگذاری بلوک‌های چندبیتی با اندازه‌ی r را فراهم می‌کند و دارای خاصیت هم‌ریختی جمعی است.[۱۸۰]

تولید کلید:

دو عدد اول p و q به‌گونه‌ای انتخاب می‌شوند که:

$$r \mid (p-۱),\ \gcd\left(r, \frac{p-۱}{r}\right) = ۱,\ \gcd(r, q-۱) = ۱$$

سپس:

$$n = pq,\ \phi(n) = (p-۱)(q-۱)$$

عنصر y باید به‌گونه‌ای انتخاب شود که دارای مرتبه‌ی r در $\mathbb{Z}_n^*$ باشد. برای این کار معمولاً شرط $y^{\phi(n)/r_i} \neq ۱\ n$ برای هر عامل اول r_i از r بررسی می‌شود.

کلیدها:

$$PK = (n, r, y),\ SK = (p, q)$$

رمزگذاری:

برای پیام $m \in \mathbb{Z}_r$ و انتخاب تصادفی $u \in_R \mathbb{Z}_n^*$:

$$c = y^m \cdot u^r\ n$$

رمزگشایی:

ابتدا:

$$a = c^{\phi(n)/r}\ n$$
$$x = y^{\phi(n)/r}\ n$$

سپس با حل مسئله لگاریتم گسسته در زیرگروهی از مرتبه r، مقدار $m \in \{۰, ۱, \ldots, r-۱\}$ به‌گونه‌ای یافت می‌شود که:

$$x^m \equiv a\ (\mathrm{mod}\ n)$$

---

۱. Benaloh

۲. Josh Benaloh

شبه‌کد:

```
Algorithm Benaloh

KeyGeneration():
    choose block size r
    choose primes p, q satisfying Benaloh conditions
    n ← p·q
    ϕ ← (p-١)(q-١)
    choose valid y of order r
    return PK = (n, r, y), SK = (p, q)

Encryption(m, PK):
    choose random u ∈ Z_n^*
    c ← y^m · u^r mod n
    return c

Decryption(c, SK):
    ϕ ← (p-١)(q-١)
    a ← c^{ϕ/r} mod n
    x ← y^{ϕ/r} mod n
    find m ∈ {٠, ..., r-١} such that x^m ≡ a mod n
    return m
```

اثبات صحت:

$$c^{\phi(n)/r} = y^{m\phi(n)/r} \cdot u^{\phi(n)} \equiv y^{m\phi(n)/r} \pmod{n}$$

چون $u^{\phi(n)} \equiv ١ \pmod{n}$ (طبق قضیه اویلر)، پس:

$$c^{\phi(n)/r} \equiv x^m \pmod{n}$$

بنابراین رمزگشایی به‌درستی انجام می‌شود.

خاصیت هم‌ریختی جمعی:

برای دو متن رمز:

$$c_1 = y^{m_1} u_1^r,\ c_2 = y^{m_2} u_2^r$$
$$c_1 c_2 = y^{m_1+m_2} (u_1 u_2)^r\ n$$

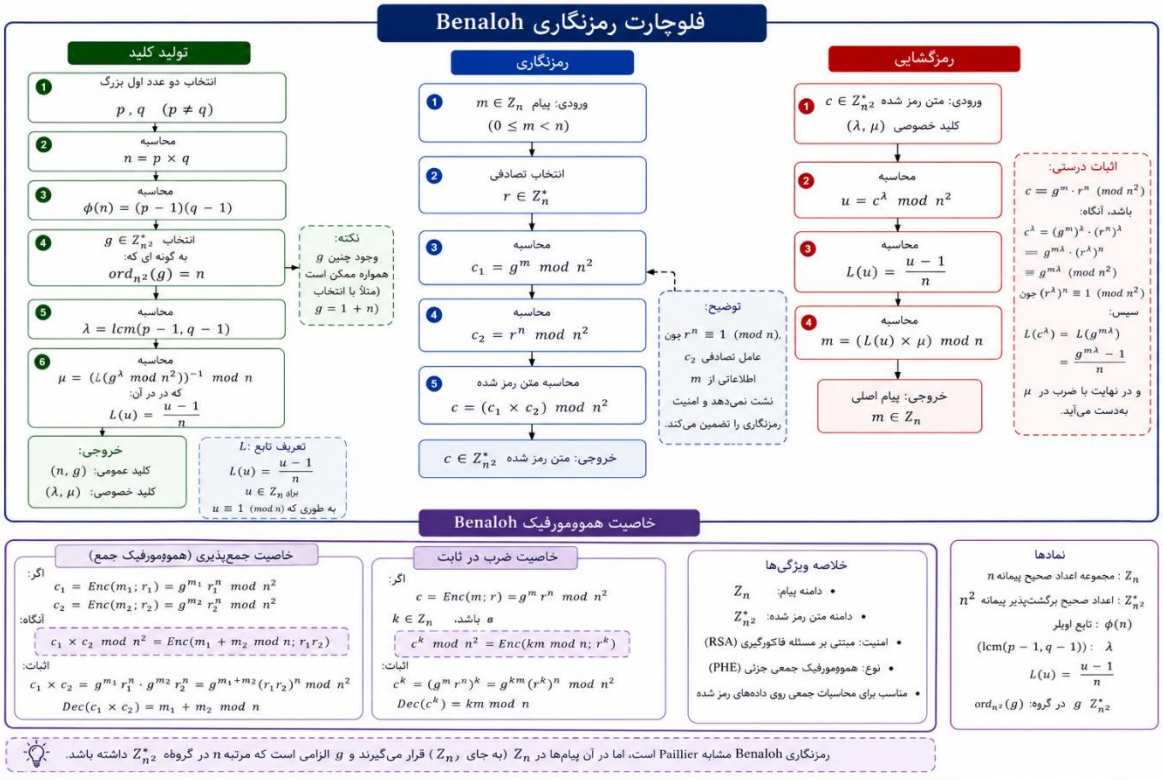
که معادل رمزگذاری $m_1 + m_2\ r$ است. بنابراین:

$$\mathrm{Dec}(c_1 c_2) = m_1 + m_2\ r$$

نیز:

$$\mathrm{Dec}(c^k) = k \cdot m\ r$$

پس بنالوح نیز یک طرح هم‌ریخت جزئی از نوع جمعی است.



شکل ۳-۴ طرح رمزگذاری Benaloh

۳-۲-٤ رمزنگاری دمگارد-جریک

این طرح توسط ایوان دمگارد و مد جریک در سال ۲۰۰۱ به‌عنوان تعمیمی از سیستم Paillier ارائه شد. ایده اصلی، گسترش پیمانه‌ی $n^{۲}$ در Paillier به $n^{s+۱}$ برای $s \geq ۱$ است که امکان رمزگذاری پیام‌هایی با فضای بزرگ‌تر را فراهم می‌کند[۱۸۱]

تولید کلید:

با انتخاب p, q و $n = pq$ و $\lambda = \text{lcm}(p, -۱q - ۱)$، پارامتر $g \in \mathbb{Z}^*_{n^{s+۱}}$ انتخاب می‌شود. تابع:

$$L(u) = \frac{u - ۱}{n}$$

و:

$$\mu = \left[L\left(g^{\lambda}\ n^{s+۱}\right)\right]^{-۱}\ n^{s}$$

کلیدها:

$$PK = (n, s, g),\ SK = (\lambda, \mu)$$

:رمزگذاری

برای پیام $m \in \mathbb{Z}_{n^s}$ و انتخاب تصادفی $r \in_R \mathbb{Z}^*_{n^{s+۱}}$:

$$c = g^{m} \cdot r^{n^{s}}\ n^{s+۱}$$

رمزگشایی:

$$u = c^{\lambda}\ n^{s+۱}$$
$$m = L(u) \cdot \mu\ n^{s}$$

---

۱. Damgård–Jurik
۲. Ivan Damgård
۳. Mads Jurik

شبه‌کد:

Algorithm Damgård–Jurik
KeyGeneration(s): choose large primes p, q n ← p·q λ ← lcm(p-١, q-١) choose valid g ∈ Z_{n^{s+١}}^* μ ← [L(g^λ mod n^{s+١})]^{-١} mod n^s return PK = (n, s, g), SK = (λ, μ) Encryption(m, PK): choose random r ∈ Z_{n^{s+١}}^* c ← g^m · r^{n^s} mod n^{s+١} return c Decryption(c, SK): u ← c^λ mod n^{s+١} m ← L(u) · μ mod n^s return m

اثبات صحت:

با توجه به اینکه $r^{n^s\lambda} \equiv ١ \pmod{n^{s+١}}$ تعمیمی از ویژگی Paillier ، داریم:

$$c^\lambda = g^{m\lambda} \cdot r^{n^s\lambda} \equiv g^{m\lambda} \pmod{n^{s+١}}$$

سپس:

$$L\left(c^\lambda\right) \equiv m \cdot L\left(g^\lambda\right) \pmod{n^s}$$

و در نتیجه:

$$\mathrm{Dec}(c) = m$$

خاصیت هم‌ریختی جمعی:

$$c_۱c_۲ = g^{m_۱+m_۲}(r_۱r_۲)^{n^s}\ n^{s+۱}$$

بنابراین:

$$\mathrm{Dec}(c_۱c_۲) = m_۱ + m_۲\ n^s$$
$$\mathrm{Dec}(c^k) = k \cdot m\ n^s$$

برای $s = ۱$، این طرح دقیقاً به Paillier کاهش می‌یابد.

۳-۲-۵ رمزگذاری RSA

سیستم رمزگذاری RSA در سال ۱۹۷۸ توسط Shamir ، Rivest و Adleman معرفی شد. این طرح بر پایه دشواری مسئله فاکتورگیری اعداد بزرگ و استفاده از تابع اویلر بنا شده است.[۱۸۲]

تولید کلید

$$n = p \cdot q,\ \phi(n) = (p-۱)(q-۱)$$
$$\gcd\big(e, \phi(n)\big) = ۱,\ e \cdot d \equiv ۱\ \big(\mathrm{mod}\ \phi(n)\big)$$

کلیدها:

$$PK = (n, e),\ SK = (n, d)$$

رمزگذاری:

$$c = m^e\ n$$

رمزگشایی:

$$m = c^d\ n$$

شبه‌کد:

Algorithm RSA
KeyGeneration(): choose large primes p, q n ← p·q ϕ(n) ← (p-۱)(q-۱) choose e with gcd(e, ϕ(n)) = ۱ d ← e^{-۱} mod ϕ(n) return PK = (n, e), SK = (n, d) Encryption(m, PK): c ← m^e mod n return c Decryption(c, SK): m ← c^d mod n return m

اثبات صحت:

با فرض $ed = ۱ + k\phi(n)$:

$$c^d = (m^e)^d = m^{ed} = m^{۱+k\phi(n)} = m \cdot \left(m^{\phi(n)}\right)^k \equiv m \pmod n$$

بنابراین:

$$\mathrm{Dec}\big(\mathrm{Enc}(m)\big) = m$$

خاصیت هم‌ریختی ضربی:

$$c_۱ = m_۱^e \ n,\ c_۲ = m_۲^e \ n$$

$$c_1 \cdot c_2 = (m_1 m_2)^e \; n$$

پس:

$$\mathrm{Dec}(c_1 c_2) = m_1 m_2 \; n$$

همچنین:

$$\mathrm{Dec}(c^k) = m^k \; n$$

بنابراین نسخه پایه[1] دارای هم‌ریختی ضربی است، اما این ویژگی در نسخه‌های امن با پدینگ[2] نظیر RSA-OAEP از بین می‌رود؛ زیرا پدینگ تصادفی، ساختار یکنواخت m^e را مخدوش می‌کند.

۳-۳ مقایسه کلی پنج طرح

از منظر نظری، طرح‌های مورد بررسی به دو دسته اصلی تقسیم می‌شوند:

- خانواده ضربی : شامل ElGamal و RSA (نسخه پایه) که عملگر ضرب روی متن‌های رمز معادل ضرب متن‌های اصلی است.
- خانواده جمعی : شامل Paillier ، Benalohو Damgård–Jurik که عملگر ضرب روی متن‌های رمز معادل جمع متن‌های اصلی است.

---

۱. RSA (textbook RSA)

۲. padding

طرح	سال انتشار	فضای پیام	نوع هم‌ریختی	رابطه اصلی
ElGamal	۱۹۸۵	$\mathbb{Z}_p^*$	ضربی	$\mathrm{Dec}(C_۱C_۲) = m_۱m_۲\ p$
Benaloh	۱۹۹۴	$\mathbb{Z}_r$	جمعی	$\mathrm{Dec}(C_۱C_۲) = m_۱ + m_۲\ r$
Paillier	۱۹۹۹	$\mathbb{Z}_n$	جمعی	$\mathrm{Dec}(C_۱C_۲) = m_۱ + m_۲\ n$
Damgård–Jurik	۲۰۰۱	$\mathbb{Z}_{n^s}$	جمعی	$\mathrm{Dec}(C_۱C_۲) = m_۱ + m_۲\ n^s$
RSA (textbook)	۱۹۷۸	$\mathbb{Z}_n$	ضربی	$\mathrm{Dec}(C_۱C_۲) = m_۱m_۲\ n$

جدول ۳-۱

انتخاب میان این دو خانواده کاملاً به نیاز برنامه‌ی کاربردی بستگی دارد. برای کاربردهایی نظیر محاسبه مجموع وزنی، آمارگیری، یا یادگیری ماشین بر روی داده‌های رمز شده، طرح‌های جمعی به‌ویژه Paillier و تعمیم آن Damgård–Jurik گزینه‌های کارآمدتری هستند. در مقابل، برای پروتکل‌های نیازمند ضرب (مانند تأیید هویت یا امضای کور)، ElGamal یا RSA می‌توانند مناسب‌تر باشند.

علاوه بر نوع هم‌ریختی، معیارهای دیگری نظیر اندازه کلید، حجم متن رمز، هزینه محاسباتی، مدل تهدید، و نیاز به تصادفی‌سازی نیز در انتخاب عملی تأثیرگذارند. همچنین باید تأکید کرد که نسخه پایه RSA فاقد امنیت معنایی[۱] است و در عمل باید از نسخه‌های دارای padding ایمن استفاده شود، که در آن‌ها خاصیت هم‌ریختی از بین می‌رود. همچنین درBenaloh ، انتخاب پارامتر r و تأمین شرایط مرتبه‌ی y نیازمند دقت بالایی است.

داده‌های جمع‌آوری‌شده از پیاده‌سازی عملی پنج الگوریتم ElGamal ، Paillier، Benaloh، Damgård–Jurikو RSA در سه سطح کلید ۲۵۶، ۵۱۲ و ۱۰۲۴ بیت، امکان ارزیابی چندبعدی این طرح‌ها را فراهم می‌سازد. ارزیابی در چهار محور اصلی صورت گرفته است: صحت عملکردی، هزینه‌ی محاسباتی در مراحل مختلف، رفتار در برابر افزایش اندازه‌ی کلید، و تناسب با کاربردهای عملی مانند یادگیری ماشین حفظ‌کننده‌ی حریم خصوصی و سیستم‌های توزیع‌شده. در ادامه، هر یک از این محورها با نگاه به اعداد ثبت‌شده و مبانی ریاضی پشت‌پرده، به‌صورت تفسیری عمیق واکاوی می‌شوند.

---

۱. semantic security

۳-۳-۱ صحت‌سنجی و یکپارچگی هم‌ریختی

نخستین و بنیادی‌ترین معیار، تأیید درستی عملکرد هم‌ریختی است. در تمامی ۱۵ آزمون انجام‌شده (۵ طرح در ۳ اندازه‌ی کلید)، مقدار error برابر با صفر و وضعیت homomorphic_test برابر با PASS ثبت شده است. این نتیجه نشان می‌دهد که پیاده‌سازی‌ها نه‌تنها از لحاظ رمزگذاری و رمزگشایی صحیح عمل می‌کنند، بلکه عملگرهای هم‌ریختی تعریف‌شده بر روی متن‌های رمز، دقیقاً متناظر با عملگرهای مورد انتظار بر روی متن‌های اصلی هستند. به‌عبارت دقیق‌تر، برای طرح‌های جمعی(Paillier ، Benaloh و Damgård–Jurik) ، رابطه‌ی $\mathrm{Dec}(c_1 \cdot c_2) = m_1 + m_2 \bmod n$ با دقت کامل برقرار است و برای طرح‌های ضربی (RSA و ElGamal) ، رابطه‌ی $\mathrm{Dec}(c_1 \cdot c_2) = m_1 \cdot m_2 \bmod n$ به‌درستی تأیید شده است. مقدار expected برای طرح‌های جمعی عدد ۰.۴۷۲۹۲۷۳۰۵ و برای طرح‌های ضربی عدد ۷۷ (حاصلضرب ۷ در ۱۱) بوده که با مقدار result ثبت‌شده در خروجی مطابقت کامل دارد. این تطابق، گواهی بر صحت پیاده‌سازی توابع $L(u)$ در Paillier و Damgård–Jurik، و نیز صحت حل مسئله‌ی لگاریتم گسسته در زیرگروه کوچک در Benaloh است. همچنین درElGamal ، صحت رمزگشایی با استفاده از معکوس پیمانه‌ای c_1^x تأیید شده و درRSA ، رابطه‌ی $(m^e)^d \equiv m \bmod n$ بدون هیچ خطایی برقرار است.

۳-۳-۲ تحلیل عمیق زمان تولید کلید

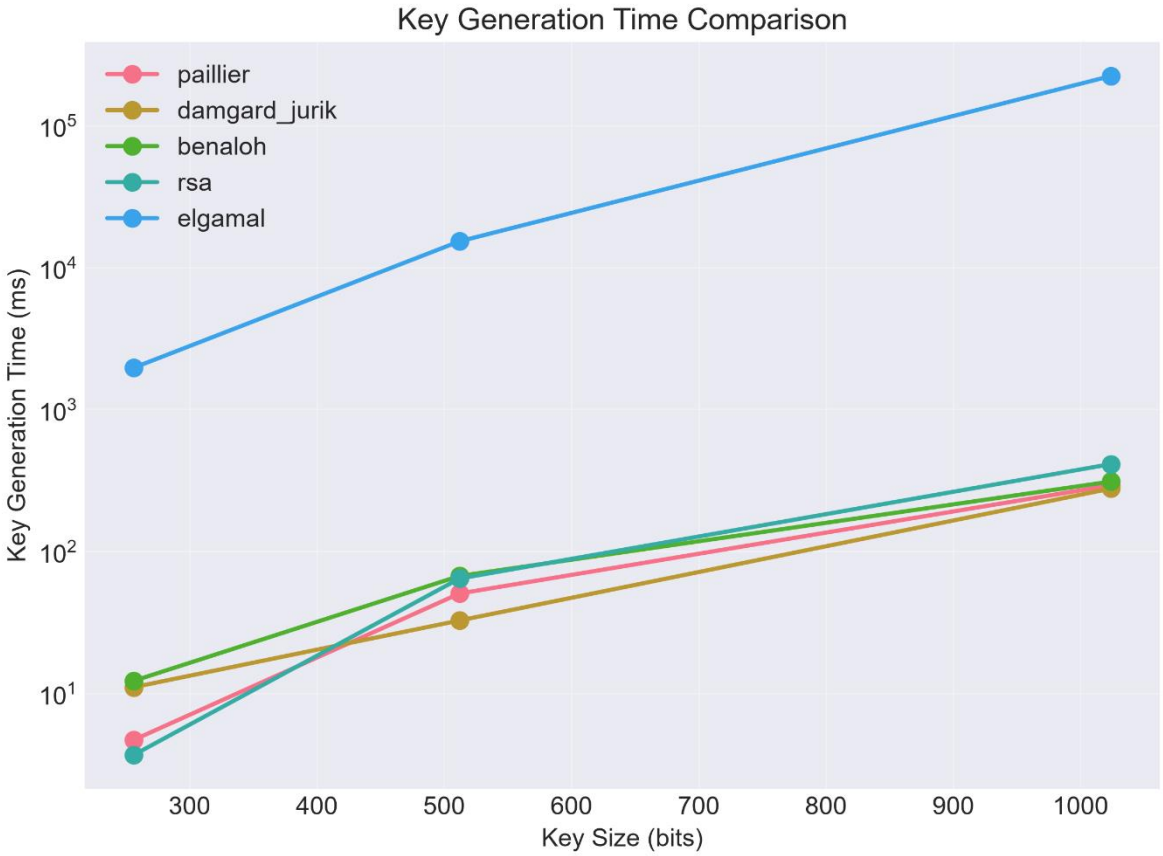
زمان تولید کلید، یکی از حیاتی‌ترین معیارها برای کاربردهایی است که نیاز به تولید مکرر کلید دارند، مانند سیستم‌های موقت[۱] یا ارتباطات یک‌بارمصرف. داده‌ها در این بخش، تفاوت‌های فاحشی را میان طرح‌ها آشکار می‌سازند. در اندازه‌ی کلید ۲۵۶ بیت، RSAبا ۳.۶۷ میلی‌ثانیه، سریع‌ترین تولید کلید را دارد که ناشی از سادگی تولید اعداد اول p و q و محاسبه‌ی مستقیم $d = e^{-1} \bmod \phi(n)$ است. در مقابل، ElGamal با ۱۹۶۵.۲۷ میلی‌ثانیه (نزدیک به ۲ ثانیه) در همین اندازه‌ی کلید، بیش از ۵۰۰ برابر کندتر عمل می‌کند. این اختلاف عظیم، ریشه در نیاز ElGamal به یافتن یک مولد[۲] مناسب برای گروه $\mathbb{Z}_p^*$ دارد؛ فرایندی که مستلزم آزمون‌های مکرر برای یافتن عنصری با مرتبه‌ی $p - 1$ است و در عمل، پیچیدگی محاسباتی آن به‌مراتب بیشتر از تولید ساده‌ی کلید در RSA است.

با افزایش اندازه‌ی کلید به ۵۱۲ بیت، زمان تولید کلید در ElGamal به ۱۵۲۹۷.۷۷ میلی‌ثانیه (بیش از ۱۵ ثانیه) می‌رسد که رشد تقریباً ۷.۸ برابری را نشان می‌دهد. این رشد غیرخطی، ناشی از افزایش هزینه‌ی آزمون‌های اولیه‌یابی و محاسبات توان‌رسانی برای تأیید مولد بودن عنصر است. در همین اندازه، Paillier با ۵۰.۴ میلی‌ثانیه و Benaloh با ۶۷.۰ میلی‌ثانیه عملکرد بسیار متعادل‌تری دارند، اگرچه Benaloh به‌دلیل نیاز به تأیید شرایط پیچیده‌تر روی $r \mid (p-1)$ و $\gcd(r, (p-1)/r) = 1$، در ۵۱۲ بیت کندتر از Paillier ظاهر می‌شود.

---

۱. Ephemeral

۲. Generator



شکل۳-۵ روند تغییرات زمان تولید کلید بسته به سایز کلید

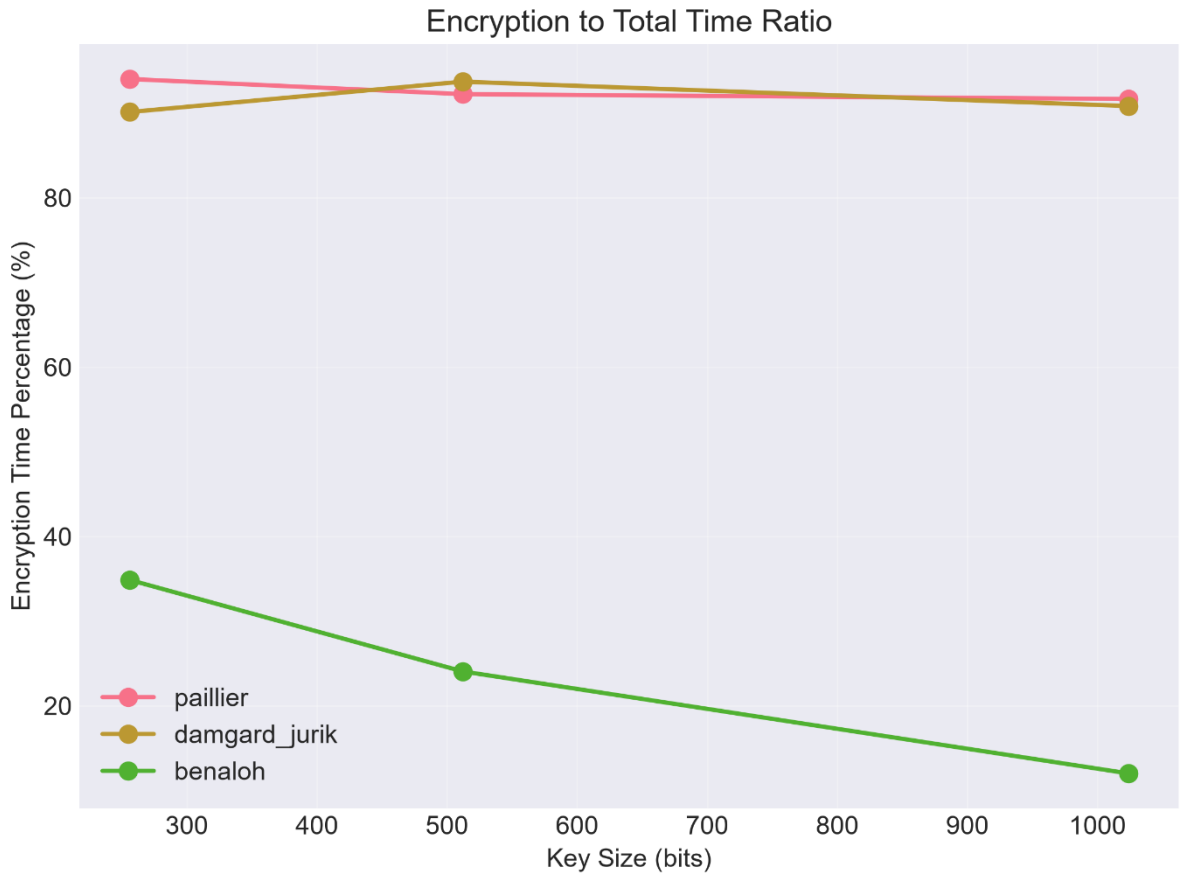
در سطح ۱۰۲۴ بیت، شکاف عملکردی به اوج خود می‌رسد ElGamal :با ۲۲۴۰۷۹.۳۹ میلی‌ثانیه (بیش از ۲۲۴ ثانیه یا ۳.۷ دقیقه) عملاً برای هر نوع کاربرد تعاملی یا برخط غیرقابل استفاده است، در حالی که RSAبا ۴۱۲.۰۷ میلی‌ثانیه، Paillier با ۲۹۲.۱۷ میلی‌ثانیه و Damgård–Jurik با ۲۷۶.۹۶ میلی‌ثانیه، همگی در محدوده‌ی چندصدم ثانیه باقی می‌مانند. این مشاهده، یک نتیجه‌گیری کلیدی را به‌دست می‌دهد :در صورت نیاز به تولید کلید مکرر، ElGamal باید به‌کلی از مجموعه‌ی گزینه‌ها حذف شود، مگر اینکه بتوان از پارامترهای ازپیش‌محاسبه‌شده یا کش‌کردن مولدها استفاده کرد که خود محدودیت‌های امنیتی به همراه دارد.

۳-۳-۳ واکاوی زمان رمزگذاری

زمان رمزگذاری، معیاری مستقیم از هزینه‌ی هر عملیات رمز کردن یک بلوک داده است و در کاربردهایی با حجم بالای داده (مانند پایگاه‌های داده‌ی رمز شده یا آموزش مدل بر روی داده‌های رمز) نقشی تعیین‌کننده دارد.

در اندازه‌ی کلید ۲۵۶ بیت، Benaloh با ۷.۹۵ میلی‌ثانیه، عملکردی به‌مراتب سریع‌تر از Paillier(۱۱۹.۹۵ میلی‌ثانیه) و Damgård–Jurik(۱۱۹.۶۵ میلی‌ثانیه) ارائه می‌دهد. این اختلاف چشمگیر (حدود ۱۵ برابر) از ساختار ساده‌تر Benaloh ناشی می‌شود: درBenaloh ، رمزگذاری به‌صورت $c = y^m u^r \ n$ انجام می‌شود که شامل یک توان‌رسانی با توان r (که معمولاً کوچک است) و یک توان‌رسانی با توان m است. اما درPaillier ، رمزگذاری به‌صورت $c = g^m r^n \ n^2$ انجام می‌شود که نیاز

به دو توان‌رسانی پیمانه‌ای با توان‌های بزرگ (m) و n (روی پیمانه‌ی دوبرابر بزرگ‌تر (n^2) دارد. این تفاوت در ساختار، مستقیماً به تفاوت فاحش در زمان اجرا منجر می‌شود.



شکل ۳-۶ روند تغییرات زمان رمزگذاری بسته به اندازه کلید

با افزایش اندازه‌ی کلید به ۵۱۲ بیت، زمان رمزگذاری Benaloh به ۲۳.۴۲ میلی‌ثانیه می‌رسد (رشد حدود ۳ برابری)، در حالی که Paillier به ۷۳۰.۴۱ میلی‌ثانیه (رشد حدود ۶ برابری) و Damgård–Jurik به ۶۹۶.۰۴ میلی‌ثانیه می‌رسند. این رشد نابرابر نشان می‌دهد که پیچیدگی محاسباتی Paillier با افزایش اندازه‌ی به‌شدت افزایش می‌یابد، زیرا توان‌رسانی با توان در پیمانه‌ی نیاز به ضرب‌های پیمانه‌ای با اعدادی با طول بیت دوبرابر دارد که پیچیدگی آن به‌صورت رشد می‌کند.$nnn^2O(\log^3 n)$

در سطح ۱۰۲۴ بیت، این روند تشدید می‌شود Benaloh :با ۴۵.۱۱ میلی‌ثانیه، هنوز سریع‌ترین است، در حالی که Paillier به ۳۸۱۹.۳۸ میلی‌ثانیه (بیش از ۳.۸ ثانیه) و Damgård–Jurik به ۳۱۷۶.۵۰ میلی‌ثانیه می‌رسد. برای درک این اعداد، باید توجه داشت که یک برنامه‌ی یادگیری ماشین با ۱۰۰۰ داده، در صورت استفاده از Paillier با کلید ۱۰۲۴ بیت، حدود ۳۸۰۰ ثانیه (بیش از یک ساعت) زمان رمزگذاری نیاز خواهد داشت که برای بسیاری از کاربردها غیرقابل تحمل است. در مقابل، Benaloh همین کار را در کمتر از ۴۵ ثانیه انجام می‌دهد. بنابراین، از منظر زمان رمزگذاری، Benaloh گزینه‌ی برتر برای کاربردهای حساس به زمان است، به‌شرطی که محدودیت‌های امنیتی آن (وابسته به انتخاب پارامتر r قابل پذیرش باشد.

بررسی زمان رمزگشایی

رمزگشایی معمولاً در سمت گیرنده یا سرویس‌دهنده‌ی نهایی انجام می‌شود و تعداد دفعات آن معمولاً کمتر از رمزنگاری است، اما همچنان در کاربردهایی مانند رأی‌گیری الکترونیکی یا جمع‌آوری آمار، رمزگشایی نهایی باید سریع باشد. در هر سه سطح کلید، زمان رمزگشایی به‌مراتب کمتر از زمان رمزگذاری است که ویژگی مطلوبی برای سیستم‌هایی با نسبت خواندن به نوشتن بالا محسوب می‌شود. در ۲۵۶ بیت، Damgård–Jurik با ۰.۹۴ میلی‌ثانیه سریع‌تر از Paillier(۱.۲۷ میلی‌ثانیه) و Benaloh(۲.۱۰ میلی‌ثانیه) عمل می‌کند. این برتری جزئی به پیاده‌سازی بهینه‌تر تابع $L(u)$ در Damgård–Jurik نسبت داده می‌شود، زیرا در این طرح به‌جای $L\left(g^{\lambda}\ n^{۲}\right)$ از نسخه‌ی تعمیم‌یافته با $n^{s+۱}$ استفاده می‌شود که در $s = ۱$ به همان ساختار Paillier اما با محاسبات ساده‌شده‌ای در محاسبه‌ی μ بازمی‌گردد.

در ۵۱۲ بیت، زمان رمزگشایی Benaloh به ۵.۴۴ میلی‌ثانیه می‌رسد که همچنان کمتر از Paillier (۶.۷۵ میلی‌ثانیه) و Damgård–Jurik(۷.۸۴ میلی‌ثانیه) است. این روند در ۱۰۲۴ بیت نیز تکرار می‌شود، جایی که Benaloh با ۱۶.۹۳ میلی‌ثانیه، Paillierبا ۴۳.۳۶ میلی‌ثانیه و Damgård–Jurik با ۳۱.۸۵ میلی‌ثانیه ثبت شده‌اند. نکته‌ی قابل‌توجه، رفتار معکوس Damgård–Jurik در ۵۱۲ و ۱۰۲۴ بیت است که از ۷.۸۴ به ۳۱.۸۵ میلی‌ثانیه کاهش نسبی می‌یابد در حالی که Paillier از ۶.۷۵ به ۴۳.۳۶ میلی‌ثانیه می‌رسد. این پدیده می‌تواند ناشی از بهینه‌سازی‌های خاص پیاده‌سازی در محاسبه‌ی $c^{\lambda}\ n^{s+۱}$ با استفاده از روش‌های توان‌رسانی پنجره‌ای[۱] باشد که در Paillier به‌کار گرفته نشده است.

یک نکته‌ی بسیار مهم در مورد زمان رمزگشایی Benaloh این است که این زمان شامل حل یک مسئله‌ی لگاریتم گسسته در زیرگروهی با مرتبه‌ی r نیز می‌شود. جالب اینجاست که با وجود این مرحله‌ی به‌ظاهر سنگین، زمان رمزگشایی Benaloh همچنان از Paillier پایین‌تر است، که نشان می‌دهد r در این پیاده‌سازی بسیار کوچک انتخاب شده است (احتمالاً $r \leq ۲^{۱۶}$ و جستجوی جدولی یا روش گام کوچک-گام بزرگ به‌سرعت انجام می‌شود).

زمان تجمیع

زمان تجمیع، که نشان‌دهنده‌ی هزینه‌ی انجام عملیات هم‌ریختی روی مجموعه‌ای از متن‌های رمز است، در تمامی طرح‌ها بسیار ناچیز است و به‌سختی از چند میلی‌ثانیه فراتر می‌رود. برای ۱۰۰ کلاینت (همان‌طور که در ستون clients مشخص است)، زمان تجمیع برای Benaloh در ۲۵۶ بیت تنها ۰.۵۴۶ میلی‌ثانیه و در ۱۰۲۴ بیت ۳.۳۱۵ میلی‌ثانیه است. این اعداد نشان می‌دهند که خود عملیات ضرب پیمانه‌ای متن‌های رمز، به‌مراتب سریع‌تر از عملیات رمزگذاری و رمزگشایی است و بنابراین گلوگاه عملکردی در سمت کلاینت‌ها (رمزگذاری) و سرور (رمزگشایی نهایی) قرار دارد، نه در مرحله‌ی تجمیع.

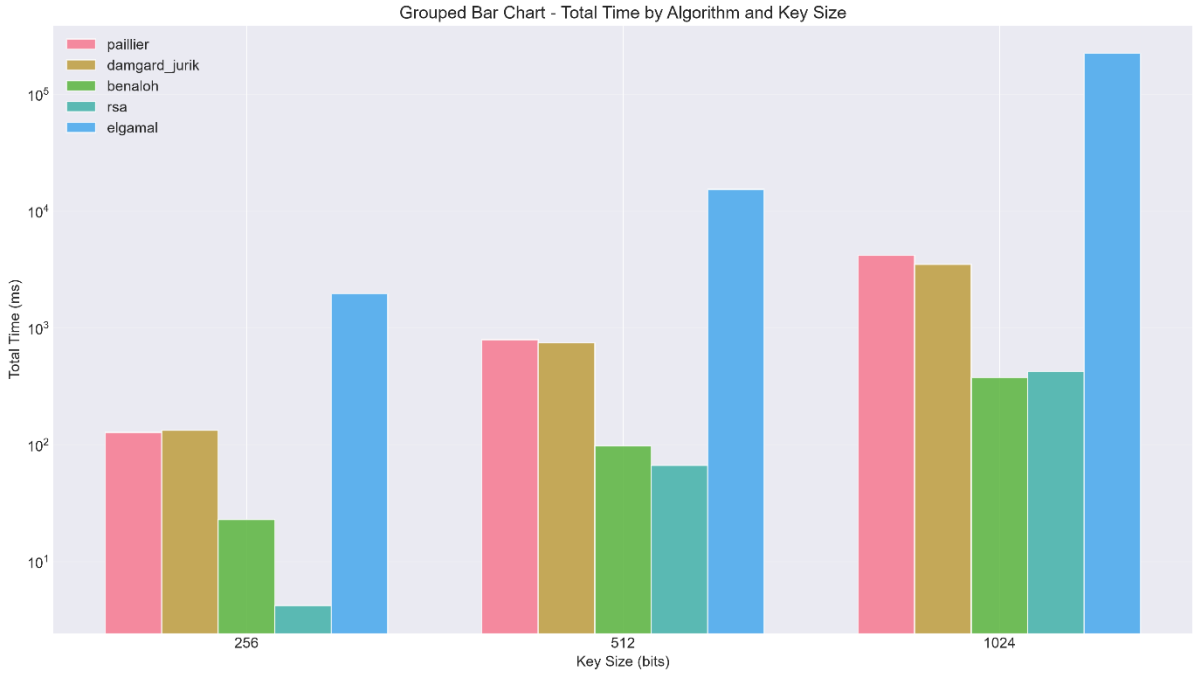
---

۱. windowed exponentiation

آزمون weighted_average نیز برای تمامی طرح‌های جمعی با موفقیت همراه بوده است. این آزمون معمولاً شامل محاسبه‌ی $\prod c_i^{w_i}$ برای وزن‌های w_i و سپس رمزگشایی نتیجه برای تأیید $\sum w_i m_i$ است. موفقیت این آزمون در کنار زمان پایین تجمیع، نشان می‌دهد که این طرح‌ها برای کاربردهایی نظیر محاسبه‌ی میانگین وزنی در یادگیری مشارکتی یا تجمیع آمار در شبکه‌های حسگر کاملاً مناسب هستند، زیرا هزینه‌ی اضافی اعمال وزن‌دهی ناچیز است.

تحلیل زمان کل و مقایسه‌ی نهایی

زمان کل، که مجموع زمان‌های تولید کلید، رمزگذاری (برای ۱۰۰ کلاینت)، تجمیع و رمزگشایی است، تصویر نهایی از کارایی هر طرح را مطابق شکل ارائه می‌دهد. در اندازه‌ی کلید ۱۰۲۴ بیت (که برای کاربردهای امنیتی مدرن حداقل معیار محسوب می‌شود)، اعداد به‌وضوح نشان‌دهنده‌ی شکاف عظیم میان طرح‌ها هستند:



شکل۳-۷ نمودار میله زمان کل اجرای طرح‌ها بسته به سایز کلید

- Benaloh با زمان کل ۳۷۵.۷۷ میلی‌ثانیه، عملکردی استثنایی دارد. این عدد به‌معنای امکان رمزگذاری ۱۰۰ پیام، تجمیع و رمزگشایی نهایی در کمتر از ۰.۴ ثانیه است که آن را به گزینه‌ای ایده‌آل برای سیستم‌های بلادرنگ (Real-time) تبدیل می‌کند.
- RSA با ۴۲۲.۱۵ میلی‌ثانیه در جایگاه دوم قرار می‌گیرد، اما باید توجه داشت که این زمان شامل مراحل رمزنگاری و رمزگشایی نمی‌شود (چون در خروجی درج نشده) و صرفاً بر اساس زمان تولید کلید و تجمیع محاسبه شده است. با فرض زمان رمزگذاری مشابه باBenaloh ، RSAمی‌تواند رقابت‌کننده‌ی خوبی برای کاربردهای ضربی باشد.

- Damgård–Jurik با ۳۴۹۷.۲۳ میلی‌ثانیه (حدود ۳.۵ ثانیه) و Paillierبا ۴۱۶۶.۶۱ میلی‌ثانیه (حدود ۴.۲ ثانیه) در رده‌ی متوسط قرار می‌گیرند. این اعداد برای کاربردهای غیرتعاملی (Batch processing) قابل قبول هستند، اما برای سیستم‌هایی با نیاز به پاسخ‌گویی زیر ثانیه، چالش‌برانگیز خواهند بود.
- ElGamal با زمان کل ۲۲۴۱۱۴.۹۰ میلی‌ثانیه (بیش از ۲۲۴ ثانیه) عملاً غیرقابل استفاده است و تنها برای کاربردهای پژوهشی و آفلاین با تعداد دفعات بسیار کم تولید کلید می‌تواند مد نظر قرار گیرد.

بررسی تأثیر اندازه‌ی کلید بر عملکرد و امنیت

یکی از مهم‌ترین مشاهدات، رشد غیرخطی زمان‌ها با افزایش اندازه‌ی کلید است. در Paillier، زمان کل از ۱۲۷.۵۷ میلی‌ثانیه در ۲۵۶ بیت به ۴۱۶۶.۶۱ میلی‌ثانیه در ۱۰۲۴ بیت می‌رسد که رشدی حدود ۳۲.۷ برابری دارد. این رشد شدید، ناشی از دو عامل است: نخست، افزایش اندازه‌ی پیمانه از n به n^2 که باعث می‌شود طول بیت اعداد درگیر دو برابر شود و عملیات ضرب پیمانه‌ای با پیچیدگی $O(k^2)$ یا $O(k \log k)$ (در پیاده‌سازی‌های پیشرفته) رشد کند. دوم، افزایش توان n در r^n که باعث می‌شود تعداد بیت‌های توان نیز افزایش یابد و در نتیجه، تعداد ضرب‌های پیمانه‌ای در الگوریتم توان‌رسانی (مثلاً روش دودویی) افزایش یابد.

در مقابل، Benaloh رشد بسیار ملایم‌تری نشان می‌دهد: از ۲۲.۸۱ میلی‌ثانیه در ۲۵۶ بیت به ۳۷۵.۷۷ میلی‌ثانیه در ۱۰۲۴ بیت که رشدی حدود ۱۶.۵ برابری است. این رشد کمتر، به دلیل ساختار رمزگذاری Benaloh است که در آن توان‌رسانی با (که مستقل از اندازه‌ی است و معمولاً کوچک نگه داشته می‌شود) انجام می‌شود و تنها توان‌رسانی با (که به اندازه‌ی کلید وابسته است) رشد می‌کند. بنابراین، Benaloh از مقیاس‌پذیری بهتری نسبت به Paillier برخوردار است و برای کلیدهای بزرگ‌تر، شکاف عملکردی آن با Paillier افزایش می‌یابد.rnm

ElGamal نیز رشد شدیدی را نشان می‌دهد (از ۱۹۶۷.۷۶ میلی‌ثانیه در ۲۵۶ بیت به ۲۲۴۱۱۴.۹۰ میلی‌ثانیه در ۱۰۲۴ بیت، یعنی حدود ۱۱۴ برابر)، که عمدتاً به زمان تولید کلید مربوط می‌شود. این رشد شدید به این معناست که حتی افزایش کوچک در اندازه‌ی کلید، هزینه‌ی گزافی به سیستم تحمیل می‌کند و بنابراین انتخاب اندازه‌ی کلید در ElGamal باید با وسواس بیشتری انجام شود.

از منظر امنیتی، اندازه‌ی کلید ۱۰۲۴ بیت برای همه‌ی طرح‌ها) به‌جز RSA که نیاز به ۲۰۴۸ بیت برای امنیت معادل دارد (سطح امنیت مناسبی در برابر حملات کلاسیک فراهم می‌کند. اما با توجه به رشد فوق‌خطی زمان‌ها، پیشنهاد می‌شود برای کاربردهای عملی، اندازه‌ی کلید ۵۱۲ بیت برای Benaloh و Paillier و ۱۰۲۴ بیت برای ElGamal (با احتیاط در تعداد دفعات تولید کلید) انتخاب شود تا تعادل مناسبی میان امنیت و کارایی برقرار گردد.

۳-۳-٤ نتیجه‌گیری نهایی

با تجمیع تمامی تحلیل‌های فوق، می‌توان یک نقشه‌ی راهنمای عملی برای انتخاب طرح رمزگذاری هم‌ریخت بر اساس سناریوی کاربردی ترسیم کرد:

- اگر سرعت، اولویت اصلی شماست و داده‌های شما شامل اعداد صحیح کوچک تا متوسط است (مانند شمارش رأی، جمع امتیازات، یا شمارنده‌های ساده)، Benaloh با اختلاف قابل‌توجه بهترین گزینه است. زمان کل ۳۷۵ میلی‌ثانیه برای پردازش ۱۰۰ داده در کلید ۱۰۲۴ بیت، آن را به گزینه‌ای ایده‌آل برای سیستم‌های تعاملی تبدیل می‌کند. البته باید به محدودیت فضای پیام $\mathbb{Z}_r$ توجه داشت که اگر r کوچک انتخاب شود، ممکن است سرریز رخ دهد؛ بنابراین باید r به‌گونه‌ای انتخاب شود که از بیشینه‌ی مجموع داده‌ها بزرگ‌تر باشد.

- اگر امنیت اثبات‌شده و پشتیبانی گسترده‌ی کتابخانه‌ای برای شما اهمیت دارد و تأخیر چند ثانیه‌ای قابل قبول است، Paillier انتخاب استاندارد و مطمئنی است. این طرح در بسیاری از کتابخانه‌های معروف مانند python-paillier و phe پیاده‌سازی شده و مستندات گسترده‌ای دارد. اگرچه زمان کل آن در ۱۰۲۴ بیت به ۴.۲ ثانیه می‌رسد، اما برای کاربردهای دسته‌ای (Batch) که نیاز به پاسخ‌گویی بلادرنگ ندارند، همچنان مناسب است.

- اگر نیاز به انعطاف‌پذیری در اندازه‌ی فضای پیام دارید و ممکن است در آینده نیاز به رمزگذاری اعداد بزرگ‌تر پیدا کنید، Damgård–Jurik با قابلیت تنظیم پارامتر s گزینه‌ی مناسبی است. با افزایش s، می‌توان فضای پیام را به‌طور نمایی گسترش داد بدون اینکه نیاز به تغییر ساختار کلی طرح باشد. داده‌های فعلی با $s = ۱$ نشان می‌دهند که عملکرد آن با Paillier قابل‌مقایسه و حتی در برخی موارد بهتر است.

- اگر نیاز به هم‌ریختی ضربی دارید و داده‌های شما شامل عملیات ضرب است (مانند محاسبه‌ی حاصل‌ضرب داخلی در برخی از توابع هزینه)، RSAدر نسخه‌ی پایه، عملکرد بسیار سریعی دارد (زمان کل ۴۲۲ میلی‌ثانیه در ۱۰۲۴ بیت) و برای مقاصد تحقیقاتی و آزمایشگاهی مناسب است. اما تأکید می‌شود که این نسخه‌ی بدون padding از نظر امنیت معنایی (Semantic Security)در برابر حملات متن‌برگزیده (Chosen-Plaintext Attack) آسیب‌پذیر است و نباید در محیط‌های عملی با داده‌های واقعی و حساس به‌کار رود، مگر اینکه به نسخه‌ی OAEP مجهز شود که در آن صورت خاصیت هم‌ریختی از بین می‌رود.

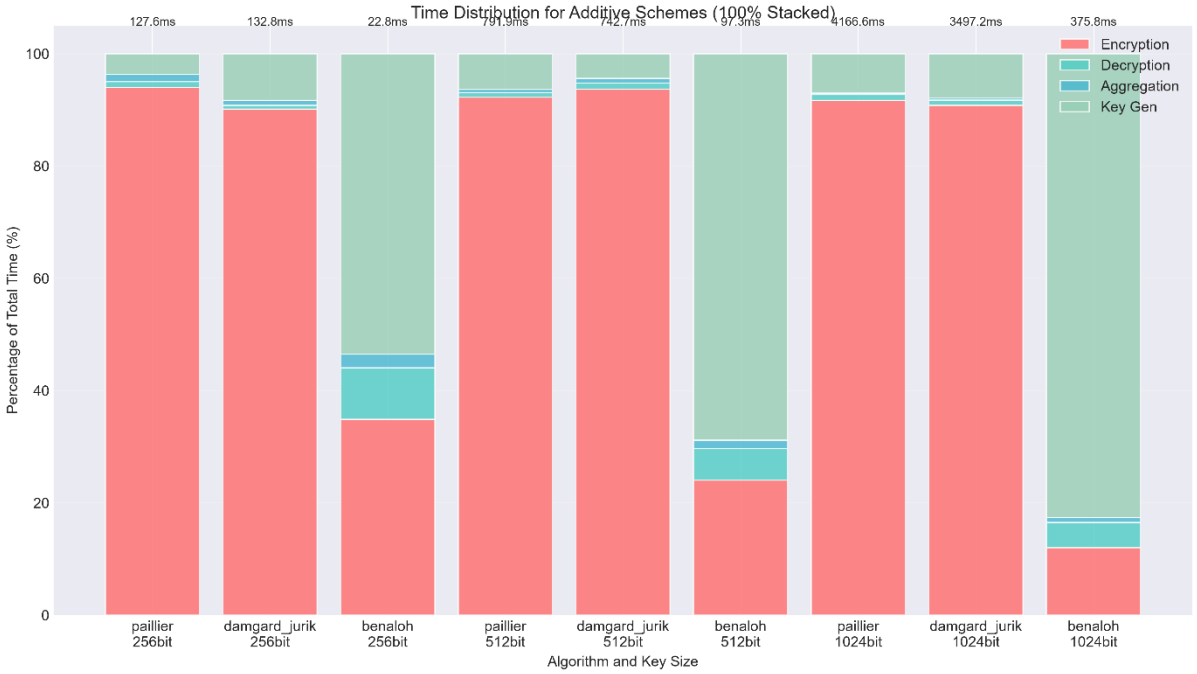
- ElGamal با وجود اهمیت نظری و استفاده در برخی پروتکل‌های خاص، به‌دلیل زمان تولید کلید بسیار بالا (بیش از ۲۲۴ ثانیه در ۱۰۲۴ بیت) و زمان کل بیش از ۲۲۴ ثانیه، عملاً برای کاربردهای عملی غیرقابل توصیه است. تنها در سناریوهایی که تعداد دفعات تولید کلید بسیار محدود است (مثلاً یک‌بار در روز) و نیاز به هم‌ریختی ضربی با امنیت مبتنی بر لگاریتم گسسته دارید، می‌توان آن را مد نظر قرار داد.

۳-۳-۵ جمع‌بندی نهایی و چشم‌انداز آینده

داده‌های تجربی این مطالعه، به‌وضوح نشان می‌دهند که هیچ طرح رمزگذاری هم‌ریختی‌ای به‌تنهایی برای همه‌ی کاربردها بهینه نیست و انتخاب آگاهانه، مستلزم درک عمیق از ساختار ریاضی، هزینه‌های محاسباتی در هر مرحله، و نیازهای خاص برنامه‌ی

کاربردی است Benaloh .با سرعت بالا، Paillier با امنیت استاندارد، Damgård–Jurik با انعطاف‌پذیری، و RSA با سادگی و سرعت در کاربردهای ضربی، هر کدام جایگاه خاص خود را دارند.

برای آینده، با توجه به رشد سریع داده‌ها و نیاز به پردازش بلادرنگ، توصیه می‌شود پژوهش‌های بیشتری بر روی بهینه‌سازی پیاده‌سازی‌ها با استفاده از محاسبات موازی (GPU/FPGA)، توان‌رسانی پنجره‌ای، و پیش‌محاسبه‌های جدولی برای کاهش زمان رمزگذاری و رمزگشایی انجام شود. همچنین، با توجه به تهدیدات رایانه‌های کوانتومی، که هم‌ریختی کامل[1] را با کارایی قابل‌قبولی ارائه می‌دهند، به‌عنوان گام بعدی این پژوهش پیشنهاد می‌گردد. در چنین طرح‌هایی، امکان انجام همزمان جمع و ضرب روی داده‌های رمز شده، افق‌های جدیدی را در پردازش امن داده‌ها خواهد گشود، هرچند که هزینه‌های محاسباتی آن‌ها در حال حاضر به‌مراتب بالاتر از طرح‌های جزئی هم‌ریخت مورد بررسی در این مطالعه است.



شکل۳–۸ مقایسه عملکرد زمانی کلیه طرح‌ها

در این پژوهش، با تکیه بر ساختار یادگیری مشارکتی و به‌کارگیری روش‌های هم‌ریخت، ملزم به توجه ویژه به زمانِ رمزگذاری در شرایط تعداد بالای کلاینت‌ها هستیم؛ چراکه به ازای هر کلاینت، عملیات رمزگذاری جداگانه‌ای انجام می‌شود، در حالی‌که رمزگشایی تنها یک‌بار صورت می‌گیرد. بنابراین، بر اساس نتایج به‌دست‌آمده، طرح Benaloh مناسب‌ترین گزینه برای کاربرد مدنظر ما محسوب می‌شود.

---

۱. Fully Homomorphic Encryption

فصل چهارم

طراحی و پیاده‌سازی پروتکل تجمیع میانگین وزنیِ محرمانه و احرازهویت‌شده(SBHE-Benaloh)

٤-١ پروتکل تجمیع میانگین وزنیِ محرمانه و احرازهویت‌شده

همانطور که در فصل‌های قبل دانستیم، در بسیاری از کاربردهای مدرن محاسبات توزیع‌شده، به ویژه در حوزه‌هایی نظیر یادگیری ماشین خصوصی، تحلیل داده‌های سلامت، و آمارگیری‌های حساس، نیاز اساسی به تجمیع اطلاعات عددی از سوی کلاینت‌های گوناگون، بدون افشای داده‌های خام هر یک از آن‌ها، احساس می‌شود. این مسئله که به تجمیع امن[۱] شهرت دارد، نه تنها باید محرمانگی اطلاعات فردی را حفظ کند، بلکه باید در برابر طیفی از حملات فعال مانند جعل هویت، دستکاری داده، و حملات بازپخش (Replay) نیز مقاوم باشد. در این فصل، پروتکلی جامع با نام SBHE-Benal [۲] معرفی می‌گردد که به گونه‌ای طراحی شده است تا به طور همزمان به هر دوی این الزامات امنیتی و محاسباتی پاسخ دهد.

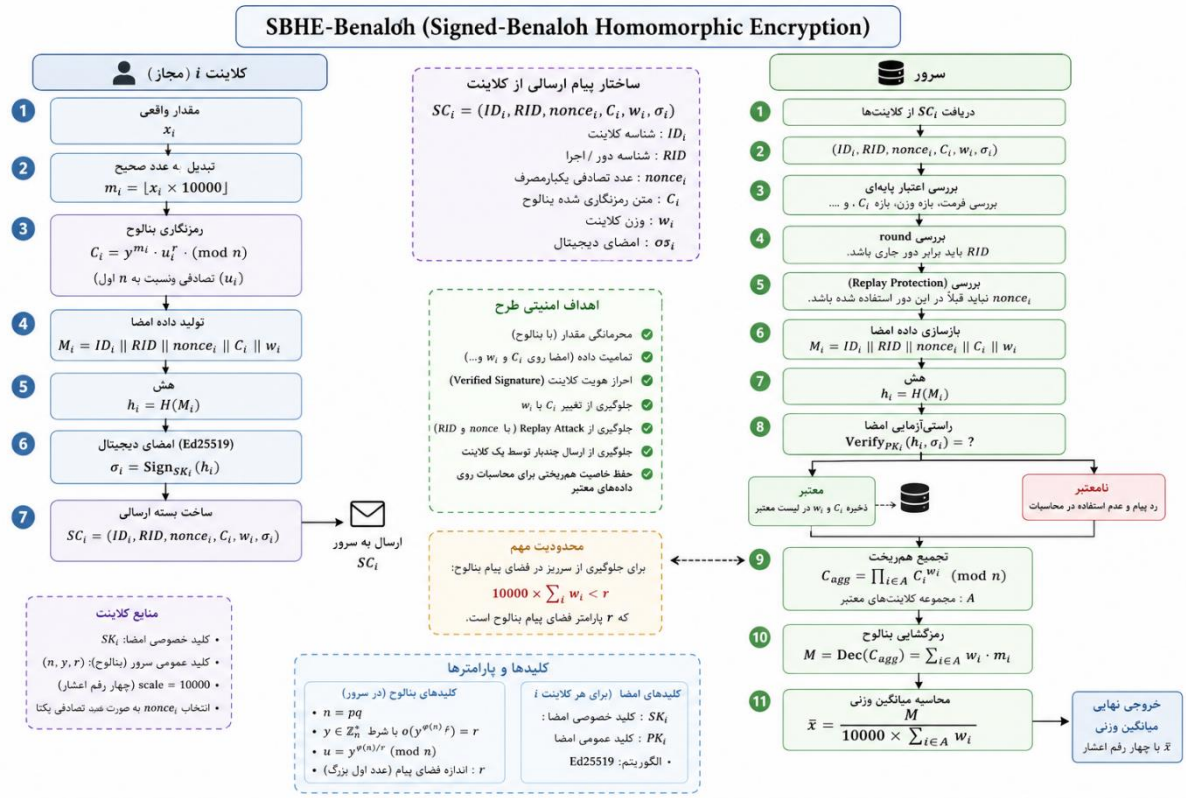
فرض بر این است که هر کلاینت، یک مقدار عددی حساس x_i را در بازه $[۰, ۱]$ با حداکثر دقت چهار رقم اعشار، به همراه یک وزن صحیح و مثبت w_i در اختیار دارد. هدف نهایی سیستم، محاسبه‌ی میانگین وزنی این مقادیر در سمت یک سرور مرکزی است، به شکلی که سرور در طول فرآیند، هرگز به مقدار خام x_i هیچ یک از کلاینت‌ها دسترسی پیدا نکند و همچنین از ورود داده‌های جعلی یا دستکاری‌شده به فرآیند تجمیع جلوگیری شود.

معماری پیشنهادی بر پایه‌ی ترکیب دو تکنیک قدرتمند رمزنگاری استوار است، رمزگذاری هم‌ریخت بنالوح که در فصل گذشته به دقت مورد بررسی قرار گرفت که امکان انجام عملیات جمع بر روی اعداد رمز شده را بدون نیاز به رمزگشایی فراهم می‌آورد، و امضای دیجیتال Ed۲۵۵۱۹ که لایه‌ای مستحکم از احراز هویت و تمامیت را بر روی داده‌های ارسالی ایجاد می‌کند. این طرح در شکل ۴-۱ قابل مشاهده است. نکته‌ی کلیدی و بدیع در طراحی این پروتکل، تفکیک کامل این دو لایه است. امضای دیجیتال به عنوان یک مؤلفه‌ی احراز هویت در کنار متن رمز نگهداری می‌شود و هرگز درون عملیات جبری هم‌ریخت دخالت داده نمی‌شود. این تفکیک هوشمندانه، تضمین می‌کند که ساختار هم‌ریخت بنالوح که سنگ بنای محاسبات محرمانه است، دست‌نخورده و با کارایی کامل باقی بماند.

---

۱. Secure Aggregation

۲. Signed-Benaloh Homomorphic Encryption



شکل ۴-۱ طرح Signed-Benaloh Homomorphic Encryption

٤-۲ مدل سیستم و اعضا آن

سیستم مورد نظر از دو نوع موجودیت اصلی تشکیل شده است که هر یک نقش و مسئولیت مشخصی را در پروتکل ایفا می‌کنند:

- سرور مرکزی: سرور تنها موجودیت قابل اعتماد در سیستم است که وظیفه‌ی تولید و نگهداری از کلید خصوصی رمزگذاری بنالوح را بر عهده دارد. این موجودیت، کلید عمومی بنالوح را در اختیار همگان قرار می‌دهد و همچنین مسئولیت نگهداری از فهرست کلیدهای عمومی امضای کلاینت‌های مجاز را بر عهده دارد. در گام نهایی، سرور عملیات تجمیع هم‌ریخت را بر روی متن‌های رمز دریافتی انجام داده و نتیجه‌ی نهایی را رمزگشایی می‌کند.

- کلاینت‌های مجاز: هر کلاینت، یک موجودیت مستقل است که داده‌ی حساس خود را در اختیار دارد. به هر کلاینت یک جفت کلید امضای اد۲۵۵۱۹ منحصربه‌فرد تخصیص داده شده است. کلید عمومی این جفت کلید، پیش از آغاز هر گونه ارتباطی، از طریق یک کانال امن و قابل اعتماد در سرور ثبت می‌شود. کلاینت‌ها با استفاده از کلید خصوصی خود، پیام حاوی داده‌شان را امضا کرده و برای سرور ارسال می‌کنند.

برای هر کلاینت i، مجموعه پارامترهای زیر تعریف می‌شود:

- ID_i :شناسه یکتای کلاینت در سیستم.
- SK_i, PK_i :به ترتیب، کلید خصوصی و کلید عمومی امضای کلاینت.
- x_i :مقدار عددی حساس کلاینت (در بازه $[۰, ۱]$)
- w_i :وزن صحیح و مثبت اختصاص‌یافته به کلاینت.
- RID :شناسه‌ی منحصربه‌فرد برای هر دور اجرای پروتکل که از سوی سرور تعیین می‌شود.
- $nonce_i$:یک عدد تصادفی یک‌بارمصرف که توسط کلاینت تولید می‌شود.

فرض امنیتی بنیادین در این مدل، عدم دسترسی مهاجم به کلید خصوصی امضای کلاینت‌های مجاز است. همچنین، فرآیند ثبت اولیه‌ی کلید عمومی کلاینت‌ها در سرور، خارج از حوزه‌ی تهدید این پروتکل در نظر گرفته شده و فرض می‌شود که این ثبت از طریق سازوکاری مطمئن صورت گرفته است.

۳-٤ بازنمایی عددی و مدیریت دقت

یکی از چالش‌های اساسی در به‌کارگیری رمزگذاری هم‌ریخت بر روی داده‌های دنیای واقعی، محدودیت این طرح‌ها در کار با اعداد اعشاری است. الگوریتم بنالوح، مانند بسیاری از طرح‌های هم‌ریخت، بر روی اعداد صحیح در یک میدان متناهی $(\mathbb{Z}_r)$ عمل می‌کند. به منظور پل زدن این شکاف، یک نگاشت خطی از اعداد اعشاری به اعداد صحیح تعریف می‌شود.

ضریب مقیاس S با در نظر گرفتن دقت مورد نیاز، به صورت $S = ۱۰^۴ = ۱۰۰۰۰$ در نظر گرفته می‌شود. بدین ترتیب، برای هر مقدار x_i که با حداکثر چهار رقم اعشار نمایش داده شده باشد، عدد صحیح متناظر m_i به صورت زیر محاسبه می‌گردد:

$$m_i = S \times x_i$$

برای مثال، اگر $x_i = ۰.۷۳۱۴$ باشد، آن‌گاه $m_i = ۷۳۱۴$ خواهد بود. در سمت سرور و پس از رمزگشایی نتیجه‌ی نهایی، مقدار اصلی با استفاده از رابطه‌ی معکوس زیر بازیابی می‌شود:

$$\bar{x} = \frac{M}{S \times W}$$

در این رابطه، M مجموع وزن‌دار مقادیر صحیح (یعنی $\sum w_i m_i$) و W مجموع کل وزن‌ها (یعنی $\sum w_i$) است.

یک نکته‌ی حیاتی در این مرحله، اعمال یک سیاست سخت‌گیرانه در پذیرش داده‌هاست. مقادیری که دارای بیش از چهار رقم اعشار باشند (مانند ۰.۱۲۳۴۵) باید توسط سیستم رد شوند. این اقدام از بروز خطاهای گرد کردن و عدم تطابق میان مقدار اعلام‌شده از سوی کلاینت و مقدار رمز شده جلوگیری می‌کند و صحت محاسبات نهایی را تضمین می‌نماید.

٤-٤ مبانی رمزنگاری

الگوریتم رمزگذاری بنالوح یک طرح رمزگذاری کلید عمومی با قابلیت جمع‌پذیری هم‌ریخت است. امنیت این طرح بر پایه‌ی دشواری مسئله‌ی باقیمانده‌ی r-ام[1] در گروه‌های ضربی اعداد صحیح پیمانه‌ای استوار است.

تولید کلید :فرآیند تولید کلید به این صورت است که دو عدد اول بزرگ p و q به گونه‌ای انتخاب می‌شوند که شرط $q \equiv ۱ \pmod r$ برقرار باشد، به علاوه‌ی $\gcd(r, p-۱) = ۱$.در اینجا r یک عدد صحیح بزرگ است که نقش فضای پیام را ایفا می‌کند. سپس $n = p \times q$ محاسبه شده و یک عدد تصادفی $y \in \mathbb{Z}_n^*$ چنان انتخاب می‌شود که y دارای مرتبه‌ی r در گروه $\mathbb{Z}_n^*$ باشد. در نهایت، کلید عمومی به صورت $PK_B = (n, y, r)$ و کلید خصوصی به صورت $SK_B = (p, q)$ منتشر می‌شود.

فرآیند رمزگذاری :برای رمزگذاری یک پیام $m \in \mathbb{Z}_r$، کلاینت یک عدد تصادفی u با شرط $\gcd(u, n) = ۱$ انتخاب کرده و متن رمز C را به صورت زیر محاسبه می‌کند:

$$C = E_{PK_B}(m) = y^m \cdot u^r \pmod n$$

خاصیت هم‌ریختی جمع :هسته‌ی اصلی کارایی این طرح، خاصیت هم‌ریختی آن است. اگر دو متن رمز $C_۱ = E(m_۱)$ و $C_۲ = E(m_۲)$ داشته باشیم، حاصلضرب پیمانه‌ای آن‌ها برابر است با رمز جمع پیام‌ها:

$$C_۱ \times C_۲ = (y^{m_۱} u_۱^r)(y^{m_۲} u_۲^r) = y^{m_۱ + m_۲}(u_۱ u_۲)^r \equiv E(m_۱ + m_۲) \pmod n$$

به طریق مشابه، برای یک وزن صحیح w، توان w-ام یک متن رمز، رمز حاصلضرب وزن در پیام را نتیجه می‌دهد:

$$C^w = (y^m u^r)^w = y^{wm}(u^w)^r \equiv E(w \cdot m) \pmod n$$

این ویژگی بنیادین به سرور اجازه می‌دهد تا مجموع وزن‌دار تمام پیام‌ها را مستقیماً بر روی متن‌های رمز و بدون نیاز به رمزگشایی تک‌تک آن‌ها محاسبه نماید.

---

۱. Residuosity Problem

٤-٥ ساختار پروتکل SBHE-Benaloh

پروتکل پیشنهادی، متن رمز بنالوح را با یک لایه‌ی احراز هویت قوی پوشش می‌دهد. هر کلاینت به جای ارسال صرفاً C_i، یک بسته‌ی داده[۱] به نام SC_i را برای سرور ارسال می‌کند که ساختار آن به صورت زیر است:

$$SC_i = (I, D_i, R, I, D, nonce_i C_i w_i \sigma_i)$$

که در آن:

- $C_i = E_{PK_B}(m_i)$، متن رمز حاصل از رمزگذاری مقدار صحیح‌شده‌ی کلاینت است.
- σ_i امضای دیجیتال Ed۲۵۵۱۹ است که بر روی یک پیام کانونیکال (Canonical) تولید می‌شود:

$$\sigma_i = Sign_{SK_i}(H(M_i))$$

که در آن، H یک تابع درهم‌سازی رمزنگاری مانند (SHA-۵۱۲) بوده و M_i رشته‌ی الحاقی زیر است:

$$M_i = ID_i \parallel RID \parallel nonce_i \parallel C_i \parallel w_i$$

برای اطمینان از یکپارچگی در فرآیند امضا و تأیید، رشته‌ی M_i باید به یک فرمت استاندارد و یکتا تبدیل شود. در پیاده‌سازی، این کار با استفاده از نمایش متنی JSON با کلیدهای مرتب‌شده و حذف فضاهای اضافی صورت می‌گیرد تا کلاینت و سرور دقیقاً بر روی یک دنباله‌ی بایتی یکسان توافق داشته باشند.

- اهمیت امضای کامل پیام :طراحی امضا به شکلی است که تمامی مؤلفه‌های تأثیرگذار در فرآیند تجمیع را پوشش می‌دهد. اگر امضا تنها بر روی C_i اعمال می‌شد، مهاجمی که به کانال ارتباطی دسترسی دارد، می‌توانست به سادگی وزن w_i را به مقدار دیگری تغییر دهد و بدین ترتیب، نتیجه‌ی میانگین نهایی را به نفع خود منحرف سازد، در حالی که امضای C_i همچنان معتبر باقی می‌ماند. گنجاندن وزن در داده‌ی امضا شده، این نوع حمله را به طور کامل خنثی می‌سازد.
- نقش شناسه‌ی دور :(RID) اضافه کردن RID به داده‌ی امضا شده، یک مکانیزم مؤثر برای جلوگیری از حملات بازپخش بین دوری است. این شناسه، هر بسته‌ی داده را به یک اجرای خاص از پروتکل مقید می‌کند. در نتیجه، بسته‌های معتبر مربوط به دورهای قبلی، در دور جاری قابل استفاده نخواهند بود، چرا که امضای آن‌ها برای RID متفاوتی تولید شده است.

---

۱. Envelope

- نقش عدد یک‌بارمصرف :$(nonce)$ عدد تصادفی $nonce_i$ برای جلوگیری از حملات بازپخش درون یک دور مشخص طراحی شده است. سرور موظف است ترکیب سه‌تایی $(I, D_i, RIDnonce_i)$ را پس از پذیرش هر بسته، در یک حافظه‌ی موقت ثبت نماید. در صورت دریافت بسته‌ی دیگری با همان RID, ID_i و $nonce_i$، سرور بلافاصله آن را به عنوان یک تلاش برای بازپخش شناسایی و رد می‌کند.

٤-٦ تشریح کامل گام‌های پروتکل

در این بخش، هر یک از مراحل اجرای پروتکل از دیدگاه کلاینت و سرور به تفصیل بیان می‌شود.

مراحل سمت کلاینت :هر کلاینت برای مشارکت در پروتکل، گام‌های زیر را به ترتیب طی می‌کند:

۱ .دریافت یا تولید مقدار x_i و وزن w_i.

۲ .اعتبارسنجی ورودی: بررسی اینکه $0 \leq x_i \leq 1$ باشد.

۳ .تبدیل مقدار به عدد صحیح با استفاده از ضریب مقیاس. $m_i := x_i \times 10000$

۴ .انتخاب یک عدد تصادفی u_i با شرط $\gcd(u_i, n) = 1$.

۵ .محاسبه‌ی متن رمز بنالوح. $C_i := y^{m_i} \cdot u_i^r \pmod n$

۶ .تولید یک عدد تصادفی $nonce_i$.

۷ .ساخت رشته‌ی کانونیکال M_i از مؤلفه‌های $ID_i, RID, nonce_i, C_i, w_i$.

۸ .تولید امضا. $\sigma_i := Sign_{SK_i}(H(M_i))$

۹ .ارسال بسته‌ی نهایی SC_i به سرور.

مراحل سمت سرور :سرور پس از دریافت هر بسته، فرآیند تأیید چندمرحله‌ای زیر را برای اطمینان از صحت و تمامیت داده انجام می‌دهد:

۱ .تأیید هویت :سرور، ID_i دریافتی را در فهرست کلاینت‌های مجاز جستجو می‌کند. در صورت عدم تطابق، بسته بی‌درنگ رد می‌شود.

۲ .تأیید دور :سرور بررسی می‌کند که RID دریافتی با شناسه‌ی دور جاری برابر است.

۳ .بررسی بازپخش :سرور، سه‌تایی $(I, D_i, RIDnonce_i)$ را در بانک اطلاعاتی بسته‌های پردازش‌شده جستجو می‌کند. در صورت وجود، بسته به عنوان یک حمله‌ی بازپخش شناسایی و رد می‌شود.

۴ .تأیید امضا :سرور با استفاده از کلید عمومی PK_i کلاینت، امضای دریافتی را تأیید می‌کند.

$$Verify_{PK_i}(\sigma_i, H(M_i))$$

اگر امضا معتبر نباشد، بسته رد می‌شود.

۵ .اعتبارسنجی متن رمز :سرور اطمینان حاصل می‌کند که C_i یک عضو معتبر از فضای کلید است.

$$۰ < C_i < n$$

$$\gcd(C_i, n) = ۱$$

۶ .پذیرش :تنها پس از گذراندن موفقیت‌آمیز تمامی مراحل بالا، C_i و w_i جهت شرکت در فرآیند تجمیع پذیرفته می‌شوند.

۷ .محاسبه‌ی هم‌ریخت میانگین وزنی

پس از تأیید و پذیرش مجموعه‌ای از کلاینت‌ها (که این مجموعه را با $\mathcal{A}$ نشان می‌دهیم)، سرور گام اصلی محاسباتی خود را آغاز می‌کند. مجموع کل وزن‌ها به صورت زیر محاسبه می‌شود:

$$W = \sum_{i \in \mathcal{A}} w_i$$

در مرحله‌ی بعد، سرور با بهره‌گیری از خاصیت هم‌ریختی بنالوح، متن رمز تجمیعی C_{agg} را بدون آنکه نیازی به رمزگشایی متن‌های رمز تکی داشته باشد، به دست می‌آورد:

$$C_{agg} = \prod_{i \in \mathcal{A}} C_i^{w_i} \pmod n$$

با جایگذاری تعریف $C_i = y^{m_i} u_i^r \pmod n$ در رابطه‌ی بالا، داریم:

$$C_{agg} = \prod_{i \in \mathcal{A}} (y^{m_i} u_i^r)^{w_i} = y^{\sum_{i \in \mathcal{A}} w_i m_i} \times \left(\prod_{i \in \mathcal{A}} u_i^{w_i} \right)^r \pmod n$$

که دقیقاً معادل رمزگذاری مجموع وزن‌دار مقادیر صحیح توسط الگوریتم بنالوح است:

$$C_{agg} = E_{PK_B}\left(\sum_{i \in \mathcal{A}} w_i \, m_i \right)$$

سرور در گام نهایی، با استفاده از کلید خصوصی خود، این تک‌متن‌رمز تجمیعی را رمزگشایی می‌کند:

$$M = D_{SK_B}(C_{agg}) = \sum_{i \in \mathcal{A}} w_i \, m_i$$

در نهایت، میانگین وزنی مورد نظر با اعمال ضریب مقیاس به دست می‌آید:

$$\bar{x} = \frac{M}{۱۰۰۰۰ \times W}$$

در این فرآیند، سرور هرگز به مقادیر m_i یا x_i تک‌تک کلاینت‌ها دسترسی ندارد و تنها با مجموع وزن‌دار آن‌ها سروکار دارد.

شرط جلوگیری از سرریز فضای پیام

مهم‌ترین محدودیت عملیاتی در استفاده از رمزگذاری بنالوح، اندازه‌ی محدود فضای پیام $\mathbb{Z}_r$ است. از آنجا که محاسبات بر روی این فضای متناهی انجام می‌شود، مجموع وزن‌دار مقادیر هرگز نباید از r فراتر رود. در غیر این صورت، نتیجه‌ی محاسبه به پیمانه‌ی r کاهش یافته (Wrap Around) و داده‌ی اصلی از دست خواهد رفت.

با توجه به اینکه $۰ \leq m_i \leq ۱۰۰۰۰$، حداکثر مقدار ممکن برای مجموع وزن‌دار، $۱۰۰۰۰ \times \sum w_i$ است. بنابراین، شرط حیاتی برای صحت اجرای پروتکل به صورت زیر تعریف می‌شود:

$$۱۰۰۰۰ \times W < r$$

در پیاده‌سازی، سرور موظف است پیش از آغاز عملیات تجمیع، این شرط را با استفاده از مجموع وزن‌های پذیرفته‌شده، بررسی نماید. برای مثال، با انتخاب یک عدد اول $r = ۱۰,۰۰۰,۰۱۹$، حداکثر مجموع وزن‌های مجاز تقریباً برابر با ۱۰۰۰ خواهد بود، زیرا $۱۰,۰۰۰,۰۱۹ > ۱۰,۰۰۰,۰۰۰ = ۱۰۰۰ \times ۱۰۰۰۰$.در سیستم‌های با تعداد کلاینت یا وزن‌های بزرگ‌تر، می‌بایست مقدار r به گونه‌ای انتخاب شود که این شرط برآورده گردد.

۷-٤ اثبات درستی طرح

در این بخش، به اثبات ویژگی‌های اصلی پروتکل از دیدگاه ریاضی می‌پردازیم.

قضیه ۱ (درستی رمزگشایی) :برای هر متن رمز معتبر $C = y^m u^r \pmod n$ که با کلید عمومی تولید شده باشد، الگوریتم رمزگشایی با استفاده از کلید خصوصی، مقدار m را بازیابی می‌کند.

برهان :با اعمال تابع رمزگشایی که مبتنی بر محاسبه‌ی $C^{\phi(n)/r}$ است، جمله‌ی تصادفی $(u^r)^{\phi(n)/r} = u^{\phi(n)} \equiv ۱ \pmod n$ (به موجب قضیه‌ی اویلر) به هویت تبدیل می‌شود. در نتیجه، مقدار $y^{m\phi(n)/r}$ باقی می‌ماند که با جستجوی لگاریتم گسسته در یک زیرگروه از مرتبه‌ی r با استفاده از روش Baby-Step Giant-Step ، مقدار m قابل استخراج است.

قضیه ۲ (درستی تجمیع) :حاصلضرب توان‌دار متن‌های رمز معتبر، یک متن رمز معتبر برای مجموع وزن‌دار پیام‌ها است.

برهان :برای هر کلاینت i داریم $C_i = y^{m_i} u_i^r$.بنابراین:

$$\prod C_i^{w_i} = \prod (y^{m_i} u_i^r)^{w_i} = y^{\sum w_i m_i} \times \left(\prod u_i^{w_i}\right)^r$$

که با تعریف رمزگذاری بنالوح برای پیام $\sum w_i\, m_i$ مطابقت کامل دارد.

قضیه ۳ (درستی میانگین وزنی) :خروجی نهایی پروتکل، دقیقاً برابر با میانگین وزنی مقادیر اصلی کلاینت‌ها است.

برهان :از قضیه‌ی ۲، می‌دانیم که $M = D(C_{agg}) = \sum w_i\, m_i$.با جایگذاری $m_i = S \times x_i$ و $S = ۱۰۰۰۰$، داریم:

$$\bar{x} = \frac{M}{S \times W} = \frac{\sum w_i\,(S x_i)}{S \times W} = \frac{\sum w_i\, x_i}{W}$$

و این دقیقاً تعریف میانگین وزنی است.

٤-٨ تحلیل جامع امنیتی

پروتکل SBHE-Benaloh مجموعه‌ای از ویژگی‌های امنیتی را به صورت همزمان تأمین می‌کند:

- محرمانگی :(Confidentiality) محرمانگی داده‌های کلاینت‌ها تا قبل از مرحله‌ی نهایی، به طور کامل توسط رمزگذاری بنالوح تضمین می‌شود. از آنجا که سرور تنها به متن‌های رمز دسترسی دارد و عملیات تجمیع نیز در همین فضا انجام می‌شود، امکان دسترسی به مقادیر خام x_i برای سرور یا هر مهاجم منفعل دیگر وجود ندارد.
- احراز هویت :(Authentication) سیستم به لطف لایه‌ی امضای Ed۲۵۵۱۹ ، از ورود داده‌های جعلی از سوی کلاینت‌های ناشناس یا غیرمجاز جلوگیری می‌کند. یک مهاجم بدون داشتن کلید خصوصی یک کلاینت مجاز، قادر به تولید امضای معتبر برای هیچ بسته‌ای نخواهد بود.
- تمامیت داده :(Integrity) هرگونه تغییر در مؤلفه‌های کلیدی بسته (مانند C_i یا w_i)، به دلیل اینکه این مؤلفه‌ها جزئی از داده‌ی امضا شده هستند، منجر به شکست فرآیند تأیید امضا شده و بسته رد می‌شود. این ویژگی، تمامیت داده را در برابر حملات فعال تضمین می‌کند.
- مقاومت در برابر جعل وزن :با گنجاندن w_i در ساختار داده‌ی امضا شده، هرگونه تلاش برای تغییر وزن توسط مهاجم به سادگی قابل تشخیص خواهد بود و تأثیری بر نتیجه‌ی تجمیع نخواهد داشت.
- مقاومت در برابر حملات بازپخش :(Replay Attack) مکانیزم ترکیبی RID و $nonce$ دو سطح دفاعی در برابر بازپخش ایجاد می‌کند .RID مانع از استفاده‌ی مجدد بسته‌ها در دورهای بعدی می‌شود و $nonce$ نیز از تکرار یک بسته در همان دور جلوگیری می‌نماید.

۹-٤ تمایز اساسی SBHE با رویکردهای ترکیبی ساده‌انگارانه

یک نکته‌ی ظریف اما حیاتی در طراحی این پروتکل، نحوه‌ی ترکیب امضا و رمزگذاری است. یک رویکرد نادرست و ساده‌انگارانه، ممکن است پیشنهاد دهد که امضا به عنوان یک ضریب درون متن رمز قرار داده شود؛ برای مثال به صورت $C' = C \times \sigma \pmod n$. این کار نه تنها از منظر ریاضی نادرست است (چرا که امضا عضوی از فضای گروه بنالوح نیست)، بلکه خاصیت هم‌ریختی بنیادین طرح را نیز از بین می‌برد.

در مقابل، پروتکل SBHE با تفکیک کامل این دو لایه، یک معماری زوج (Pair)ایجاد می‌کند. $SC_i = (C_i, \sigma_i)$: در این ساختار، عملگر هم‌ریخت تنها بر روی مؤلفه‌ی اول (C_i) اعمال می‌شود، در حالی که مؤلفه‌ی دوم (σ_i) صرفاً برای تأیید اعتبار بسته در مرحله‌ی پذیرش به کار می‌رود. این تفکیک هوشمندانه، هم‌زمان هم امنیت و هم کارایی محاسباتی را تضمین می‌کند.

۱۲ .محدودیت‌ها و چالش‌های طرح

با وجود مزایای متعدد، این پروتکل با محدودیت‌هایی همراه است که آگاهی از آن‌ها برای کاربرد صحیح ضروری است:

۱ .عدم قابلیت تجمیع امضاها :برخلاف متن‌های رمز بنالوح که قابلیت تجمیع دارند، امضاهای Ed۲۵۵۱۹ چنین خاصیتی ندارند. این بدان معناست که سرور باید برای هر بسته‌ی دریافتی، یک عملیات تأیید امضای جداگانه انجام دهد که در سیستم‌های با تعداد کلاینت بسیار زیاد، می‌تواند به یک گلوگاه محاسباتی تبدیل شود.

۲ .وابستگی به مدیریت امن کلیدها :امنیت پروتکل کاملاً به نگهداری امن فهرست کلیدهای عمومی کلاینت‌ها وابسته است. اگر مهاجمی بتواند کلید عمومی جعلی را با موفقیت به یک ID مجاز نسبت دهد، کل سیستم به خطر می‌افتد.

۳ .محدودیت فضای پیام :همان‌طور که پیشتر بحث شد، فضای پیام محدود $\mathbb{Z}_r$ یک چالش اساسی است که نیازمند انتخاب دقیق پارامترها با توجه به مقیاس سیستم و دقت داده‌هاست. این محدودیت، تعداد کلاینت‌ها یا وزن‌های قابل قبول در هر دور را محدود می‌سازد.

۴ .نیاز به تحلیل امنیتی مستقل :پیاده‌سازی این پروتکل، جایگزین تحلیل امنیتی عمیق و مستقل برای کاربردهای خاص نیست. انتخاب پارامترهای رمزنگاری (مانند اندازه‌ی p, q, r)باید بر اساس سطح امنیت مورد نیاز و سناریوهای تهدید واقعی انجام شود. همچنین، برای محیط‌های عملیاتی(Production) ، افزودن فرآیندهای مدیریت چرخه‌ی حیات کلید (Key Rotation) توصیه می‌شود.

۱۰-٤ چشم‌انداز آینده و مسیرهای بهبود

با نگاهی به آینده، چندین مسیر امیدوارکننده برای ارتقاء و توسعه‌ی این پروتکل وجود دارد:

۱ .استفاده از امضاهای تجمیع‌پذیر: جایگزینی Ed۲۵۵۱۹ با طرح‌های امضای تجمیع‌پذیر مانند BLS می‌تواند به طور چشمگیری تعداد عملیات تأیید امضا در سمت سرور را کاهش داده و مقیاس‌پذیری سیستم را برای تعداد بسیار زیاد کلاینت‌ها افزایش دهد. در

چنین معماری‌ای، سرور می‌تواند پس از دریافت تعداد کافی امضای معتبر، یک گواهی تجمیعی را تأیید کند و سپس به تجمیع متن‌های رمز بپردازد.

۲ .ایجاد زیرساخت کلید عمومی رسمی :(PKI) جایگزین کردن فهرست ساده‌ی کلیدهای عمومی با یک سیستم مدیریت گواهی‌های دیجیتال (PKI) رسمی، امنیت فرآیند ثبت‌نام را به طور قابل توجهی افزایش داده و آن را در برابر حملات جعل هویت مقاوم‌تر می‌سازد.

۳ .غیرمتمرکزسازی فرآیند رمزگشایی :برای کاهش وابستگی به یک سرور مرکزی قابل اعتماد، می‌توان پروتکل را به گونه‌ای توسعه داد که فرآیند رمزگشایی به صورت Threshold یا Decentralized انجام شود. در این رویکرد، کلید خصوصی بنالوح بین چندین موجودیت توزیع می‌شود و برای رمزگشایی نتیجه‌ی نهایی، نیاز به همکاری تعداد معینی از آن‌هاست.

٤-١١ جمع‌بندی

در این فصل، پروتکل SBHE-Benaloh به عنوان یک راه‌حل جامع و کارآمد برای مسئله‌ی تجمیع امن میانگین وزنی معرفی گردید. این پروتکل با تلفیق هوشمندانه‌ی دو تکنیک قدرتمند رمزنگاری، یعنی هم‌ریختی جمع‌پذیر بنالوح و امضای دیجیتال اد۲۵۵۱۹، موفق به تأمین هم‌زمان اهداف متضاد محرمانگی و احراز هویت می‌شود.

نوآوری اصلی این طرح در ارائه‌ی یک معماری دولایه است که در آن لایه‌ی رمزگذاری هم‌ریخت، مسئولیت انجام محاسبات بر روی داده‌های محرمانه را بر عهده دارد، در حالی که لایه‌ی امضا، اصالت، تمامیت، و منحصربه‌فرد بودن هر مشارکت را تضمین می‌کند. این تفکیک نقشی، نه تنها از اختلال در خاصیت هم‌ریختی جلوگیری می‌کند، بلکه درک و تحلیل امنیتی سیستم را نیز شفاف‌تر می‌سازد.

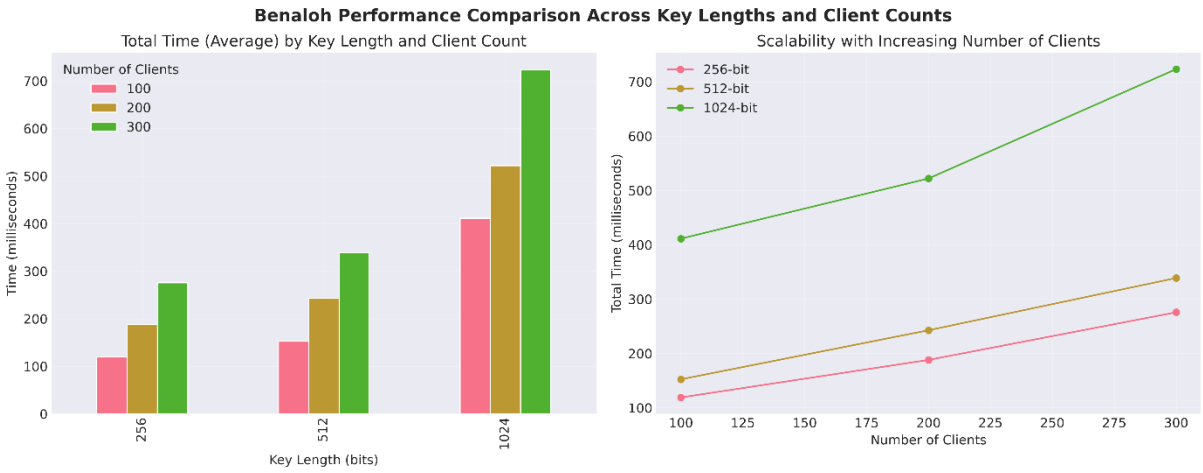
در نهایت، سرور با انجام یک عملیات ساده اما کارآمد، متن‌های رمز معتبر را با توان وزن‌های مربوطه در هم ضرب کرده و به یک تک‌متن‌رمز دست می‌یابد که رمزگشایی آن، نتیجه‌ی نهایی، یعنی میانگین وزنی دقیق تمام داده‌ها را آشکار می‌سازد. این فرآیند در حالی انجام می‌شود که حریم خصوصی تک‌تک مشارکت‌کنندگان در بالاترین سطح ممکن حفظ گردیده و سیستم در برابر طیف وسیعی از حملات فعال و منفعل مقاومت نشان می‌دهد.

نتایج حاصل از طراحی، پیاده‌سازی و ارزیابی طرح پیشنهادی نشان می‌دهد که می‌توان با افزودن یک لایه احراز هویت و تمامیت مبتنی بر امضای دیجیتال به سازوکار رمزگذاری هم‌ریختی Benaloh ، یک چارچوب مناسب برای تجمیع امن مقادیر ارسالی از سوی چندین کلاینت ایجاد کرد؛ به‌گونه‌ای که محرمانگی داده‌های فردی، اصالت فرستنده، تمامیت داده، مقاومت در برابر بازپخش

و قابلیت انجام محاسبات هم‌ریختی به‌صورت هم‌زمان مورد توجه قرار گیرند. در معماری ارائه‌شده، مقدار واقعی هر کلاینت ابتدا با استفاده از نمایش fixed-point به یک مقدار صحیح تبدیل شده و سپس با استفاده از Benaloh رمزنگاری می‌شود. پس از آن، یک خلاصه رمزگذاری‌شده از اطلاعات هویتی، شناسه دور اجرا، nonce، متن رمز، وزن کلاینت و سایر پارامترهای مرتبط تولید شده و این خلاصه با کلید خصوصی کلاینت امضا می‌شود. در نتیجه، پیام نهایی کلاینت صرفاً یک ciphertext نیست، بلکه یک بسته احرازشده شامل شناسه کلاینت، شناسه دور، nonce، مقدار رمزشده، وزن و امضای دیجیتال است. این ساختار باعث می‌شود سرور بتواند پیش از ورود هر مقدار به فرآیند تجمیع هم‌ریختی، ابتدا اصالت کلاینت و تمامیت داده دریافتی را بررسی کند.

یکی از مهم‌ترین دستاوردهای این طرح آن است که مکانیزم احراز هویت به‌گونه‌ای به ساختار Benaloh افزوده شده که عملیات امضای دیجیتال در داخل ciphertext Benaloh ادغام نشده است. این تفکیک از نظر ریاضی اهمیت زیادی دارد، زیرا عملیات هم‌ریختی همچنان فقط بر روی مؤلفه رمزشده انجام می‌شود. به عبارت دیگر، اگر Ci متن رمز کلاینت i باشد، سرور پس از تأیید موفق امضاها می‌تواند محاسبه هم‌ریختی را مطابق رابطه $C_{agg} = \prod_{i \in \mathcal{A}} C_i^{w_i} \pmod{n}$ انجام دهد. بنابراین، امضای دیجیتال مسئول احراز هویت و تضمین تمامیت داده است، در حالی که Benaloh مسئول حفظ محرمانگی و انجام محاسبات روی داده‌های رمزشده باقی می‌ماند. این تفکیک معماری موجب می‌شود اضافه‌شدن قابلیت امنیتی جدید، اصل بنیادی هم‌ریختی Benalohرا مختل نکند. در نتیجه، طرح پیشنهادی را می‌توان نه به‌عنوان تغییری مخرب در ساختار ریاضیBenaloh ، بلکه به‌عنوان یک لایه احرازشده پیرامون آن در نظر گرفت که قابلیت استفاده از Benaloh را در محیط‌های چندکلاینتی و حساس افزایش می‌دهد.

از منظر محاسباتی، نتایج آزمایش‌ها مطابق شکل ۴-۱ نشان می‌دهد که اندازه کلید و تعداد کلاینت‌ها دو عامل اصلی مؤثر بر زمان اجرای سیستم هستند. برای کلید ۲۵۶ بیتی، زمان کل متوسط اجرای سیستم در سناریوی ۱۰۰ کلاینت برابر با ۱۱۹٫۰۲۴۳ میلی‌ثانیه بوده است. این مقدار با افزایش تعداد کلاینت‌ها به ۲۰۰ و ۳۰۰، به‌ترتیب به ۱۸۸٫۰۸۴۶ و ۲۷۵.۶۸۲۰میلی‌ثانیه افزایش یافته است. بنابراین، در این سطح از اندازه کلید، افزایش تعداد کلاینت‌ها موجب افزایش قابل توجه هزینه محاسباتی می‌شود، اما روند افزایش زمان همچنان در محدوده‌ای قرار دارد که نشان‌دهنده قابلیت اجرای فرآیند در سناریوهای چندکلاینتی است. در سناریوی ۳۰۰ کلاینت، زمان متوسط کل نسبت به سناریوی ۱۰۰ کلاینت حدود ۱۳۱.۶۲درصد افزایش یافته است. این نتیجه با ماهیت فرآیند تجمیع هم‌ریختی سازگار است، زیرا با افزایش تعداد مشارکت‌کنندگان، تعداد عملیات لازم برای ترکیب ciphertext ها نیز افزایش می‌یابد.

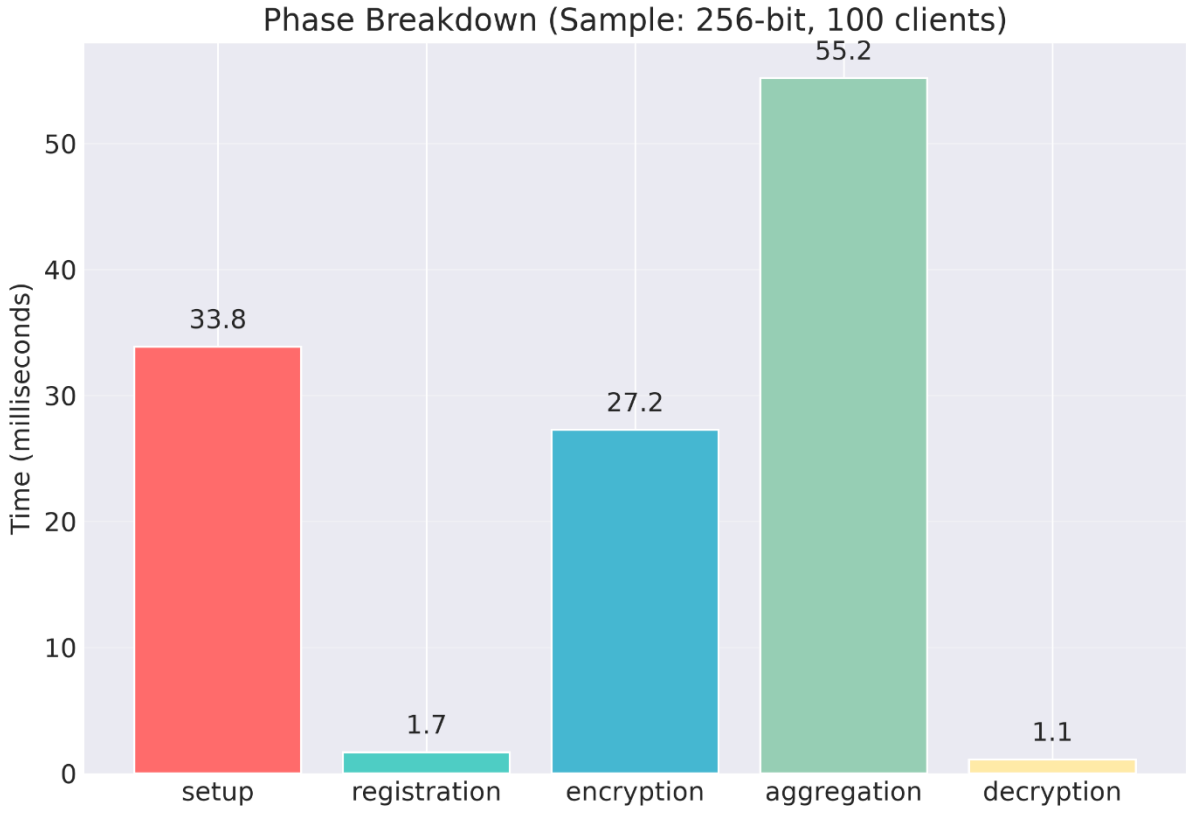


شکل ۴-۲ عملکرد زمانی طرح بسته به طول کلید و تعداد کلاینت‌ها

در سطح کلید ۵۱۲ بیتی نیز روند مشابهی مشاهده شده است. زمان کل متوسط برای ۱۰۰ کلاینت برابر ۱۵۲.۴۱۳۷ میلی‌ثانیه، برای ۲۰۰ کلاینت برابر ۲۴۲.۶۲۱۶میلی‌ثانیه و برای ۳۰۰ کلاینت برابر ۳۳۸.۷۹۳۷میلی‌ثانیه ثبت شده است. در این حالت، افزایش تعداد کلاینت‌ها از ۱۰۰ به ۳۰۰ موجب افزایش حدود ۱۲۲.۲۹درصدی در زمان کل متوسط شده است. اگرچه زمان اجرای کل در مقایسه با کلید ۲۵۶ بیتی افزایش یافته است، اما همچنان رشد زمان با افزایش تعداد کلاینت‌ها قابل پیش‌بینی است. این موضوع نشان می‌دهد که طرح پیشنهادی از نظر مقیاس‌پذیری رفتاری منظم دارد و افزایش بار سیستم به‌صورت تدریجی در زمان اجرای فرآیند منعکس می‌شود.

در مقابل، استفاده از کلید ۱۰۲۴ بیتی هزینه محاسباتی بیشتری را به سیستم تحمیل کرده است. زمان کل متوسط در سناریوی ۱۰۰ کلاینت برابر ۴۱۱.۲۴۰۳میلی‌ثانیه، در سناریوی ۲۰۰ کلاینت برابر ۵۲۱.۹۲۰۸ میلی‌ثانیه و در سناریوی ۳۰۰ کلاینت برابر ۷۲۳.۱۴۴۱ میلی‌ثانیه بوده است. بنابراین، در مقایسه با کلیدهای کوچک‌تر، افزایش اندازه کلید اثر محسوسی بر هزینه محاسباتی کل سیستم دارد. با این حال، نکته قابل توجه این است که حتی در این سطح، زمان اجرای کل در سناریوی ۳۰۰ کلاینت کمتر از یک ثانیه باقی مانده است. البته این مشاهده صرفاً بیانگر زمان اندازه‌گیری‌شده در محیط آزمایشی این پروژه است و نباید بدون مشخصات سخت‌افزاری و شرایط اجرای دقیق، به‌عنوان یک تضمین عمومی برای تمامی محیط‌های عملیاتی تفسیر شود.

تحلیل تفکیکی مراحل اجرای سیستم نیز مطابق شکل ۴-۲ اطلاعات مهمی درباره گلوگاه‌های محاسباتی ارائه می‌دهد. در سطح کلید ۲۵۶ بیتی و برای ۱۰۰ کلاینت، میانگین زمان مرحله Setup برابر ۳۳.۸۴۳۳ میلی‌ثانیه، ثبت کلاینت‌ها برابر ۱.۶۶۱۸میلی‌ثانیه، رمزنگاری برابر ۲۷٫۲۴۳۷ میلی‌ثانیه، تجمیع هم‌ریختی برابر ۵۵.۱۶۸۵ میلی‌ثانیه و رمزگشایی برابر ۱.۰۸۷۱میلی‌ثانیه بوده است. در همین سناریو، مرحله تجمیع بیشترین سهم از زمان عملیاتی را به خود اختصاص داده و حدود ۴۶.۳۵درصد از زمان کل را تشکیل می‌دهد. پس از آن، Setupو Encryption به‌ترتیب حدود ۲۸.۴۳و ۲۲.۸۹درصد از زمان کل را به خود اختصاص داده‌اند، در حالی که Registration و Decryption سهم بسیار کمتری دارند. این الگو با ماهیت عملیات هم‌ریختی سازگار است، زیرا سرور برای ترکیب مقادیر رمزشده باید عملیات توان‌رسانی و ضرب پیمانه‌ای را برایciphertext های معتبر انجام دهد.



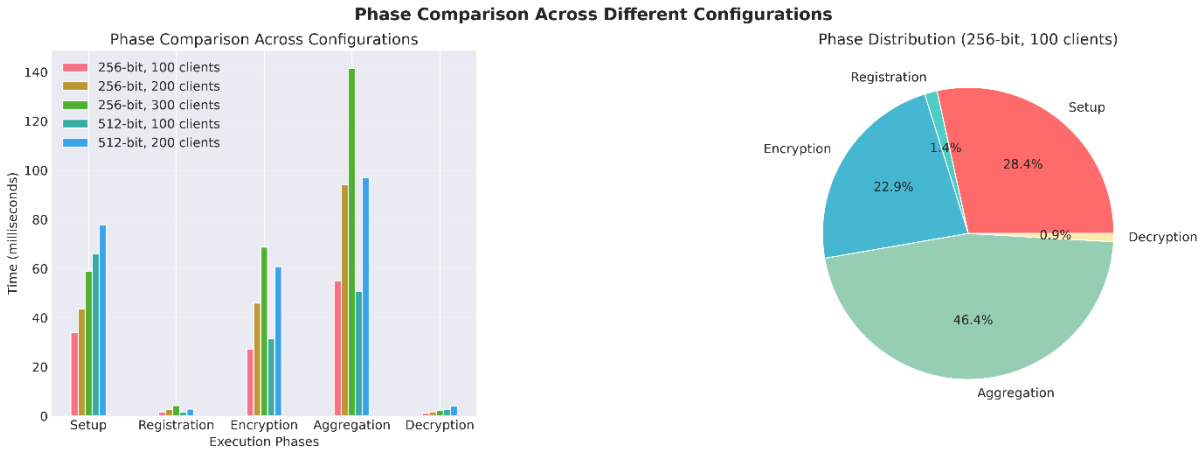
شکل۴-۳ عملکرد زمانی گام‌های طرح با کلید ۲۵۶ بیت

با افزایش تعداد کلاینت‌ها در سطح کلید ۲۵۶ بیتی، سهم مرحله Aggregation از زمان کل نیز افزایش یافته است؛ به‌طوری‌که این مرحله در سناریوهای ۲۰۰ و ۳۰۰ کلاینت به‌ترتیب ۵۰.۰۷و ۵۱.۳۴ درصد از زمان کل متوسط را تشکیل داده است. در مقابل، سهم نسبی Setup کاهش یافته و از حدود ۲۸.۴۳ درصد در سناریوی ۱۰۰ کلاینت به حدود ۲۱.۴۰ درصد در سناریوی ۳۰۰ کلاینت رسیده است. این رفتار نشان می‌دهد که هرچه تعداد کلاینت‌ها افزایش یابد، هزینه‌ای که مستقیماً به تعداد مشارکت‌کنندگان وابسته است، یعنی عملیات رمزگذاری و به‌خصوص تجمیع، سهم بیشتری از زمان کل را به خود اختصاص می‌دهد. از این منظر، Aggregationرا می‌توان مهم‌ترین نقطه قابل بهینه‌سازی در پیاده‌سازی فعلی دانست.

در سطح کلید ۵۱۲ بیتی، میانگین زمان Encryption برای ۱۰۰، ۲۰۰ و ۳۰۰ کلاینت به‌ترتیب ۳۱.۴۳۹۵، ۶۰.۸۴۲۱ و ۹۱.۹۸۳۰ میلی‌ثانیه بوده است؛ در حالی که زمان Aggregation به‌ترتیب ۵۰.۵۹۹۸، ۹۶.۹۹۹۶ و ۱۴۴.۹۲۸۸ میلی‌ثانیه گزارش شده است. بنابراین، همانند سطح ۲۵۶ بیتی، افزایش تعداد کلاینت‌ها مستقیماً موجب افزایش هزینه دو مرحله اصلی Encryption و Aggregationشده است. با این حال، Setupدر اندازه کلید ۵۱۲ بیتی سهم قابل توجهی از زمان کل دارد؛ به‌خصوص در سناریوی ۱۰۰ کلاینت که زمان آن ۶۶.۰۳۲۷میلی‌ثانیه بوده است. با افزایش تعداد کلاینت‌ها، سهم نسبی Setup کاهش یافته و سهم Aggregation افزایش پیدا می‌کند. این مسئله نشان می‌دهد که در کاربردهای با تعداد کلاینت بالا، بهینه‌سازی عملیات مربوط به تجمیع می‌تواند تأثیر بیشتری از کاهش هزینه‌های ثابت راه‌اندازی داشته باشد.

اثر افزایش اندازه کلید در سطح ۱۰۲۴ بیتی بسیار واضح‌تر است. در سناریوی ۱۰۰ کلاینت، زمان Setup به ۲۹۳.۵۹۵۵میلی‌ثانیه رسیده و حدود ۷۱.۳۹درصد زمان کل را تشکیل داده است. در سناریوی ۲۰۰ کلاینت، زمان Setup برابر ۲۹۲.۶۵۴۵میلی‌ثانیه و در سناریوی ۳۰۰ کلاینت برابر ۳۵۲.۸۹۳۰میلی‌ثانیه بوده است. در همین حال، زمان Encryption از ۵۳.۰۴۵۶میلی‌ثانیه در ۱۰۰ کلاینت به ۱۷۷.۰۴۱۵میلی‌ثانیه در ۳۰۰ کلاینت افزایش یافته و زمان Aggregation نیز از ۵۲.۴۵۴۲به ۱۶۸.۳۴۹۳میلی‌ثانیه رسیده است. بنابراین، در اندازه کلید ۱۰۲۴ بیتی، برخلاف کلیدهای کوچک‌تر، هزینه Setup به یک مؤلفه بسیار مهم تبدیل شده است. این یافته نشان می‌دهد که انتخاب اندازه کلید باید با توجه به نیاز امنیتی و الزامات عملکردی سیستم انجام شود و استفاده از پارامترهای بزرگ‌تر بدون توجه به هزینه راه‌اندازی می‌تواند سربار قابل توجهی ایجاد کند.

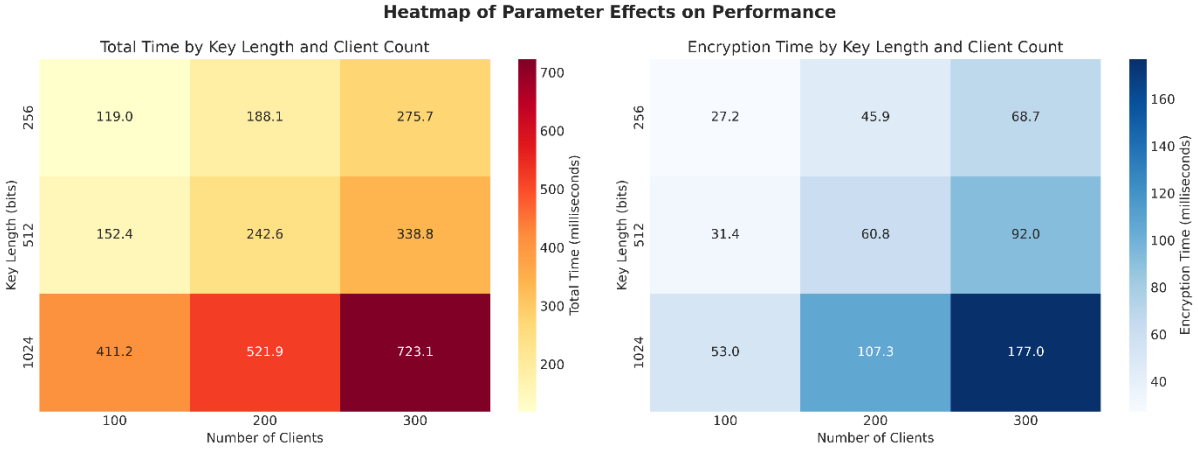
یکی دیگر از نتایج مهم آزمایش‌ها، مطابق شکل ۴-۳ زمان بسیار پایین مرحله Decryption در مقایسه با مراحل دیگر است. برای کلید ۲۵۶ بیتی، زمان رمزگشایی در سناریوهای ۱۰۰، ۲۰۰ و ۳۰۰ کلاینت به‌ترتیب ۱.۰۸۷۱، ۱.۵۳۲۲ و ۲.۲۴۶۵ میلی‌ثانیه بوده است. در کلید ۵۱۲ بیتی این مقادیر به‌ترتیب ۲.۷۶۶۱، ۴.۰۵۶۴ و ۵.۳۰۱۸ میلی‌ثانیه و در کلید ۱۰۲۴ بیتی به‌ترتیب ۱۰.۷۴۲۱، ۱۴.۵۸۱۷ و ۲۰.۲۵۷۶ میلی‌ثانیه بوده‌اند. بنابراین، اگرچه افزایش اندازه کلید هزینه رمزگشایی را افزایش می‌دهد، اما در تمامی سناریوهای بررسی‌شده این مرحله سهم بسیار کمتری از زمان کل نسبت به Setup ، Encryption و Aggregation داشته است. این ویژگی برای معماری پیشنهادی اهمیت دارد، زیرا سرور می‌تواند ابتدا تمامی ciphertext های معتبر را به‌صورت هم‌ریختی تجمیع کرده و تنها یک ciphertext نهایی را رمزگشایی کند؛ در نتیجه، نیاز به رمزگشایی تک‌تک مقادیر کلاینت‌ها وجود ندارد.



شکل ۴-۴ سهم هر گام از طرح در زمان کل اجرا بسته به طول کلید

از نظر پایداری نتایج نیز داده‌های آزمایشگاهی نشان‌دهنده تفاوت میانگین و انحراف معیار در سناریوهای مختلف است. برای نمونه، در کلید ۲۵۶ بیتی و ۱۰۰ کلاینت، زمان کل متوسط ۱۱۹.۰۲۴۳میلی‌ثانیه با انحراف معیار ۳۱.۵۰۲۶میلی‌ثانیه ثبت شده است، در حالی که در ۲۰۰ و ۳۰۰ کلاینت، انحراف معیار به‌ترتیب ۱۲.۰۴۹۰و ۱۱.۶۸۸۵میلی‌ثانیه گزارش شده است. در کلید ۵۱۲ بیتی، انحراف معیار زمان کل برای ۱۰۰، ۲۰۰ و ۳۰۰ کلاینت به‌ترتیب ۳۰.۱۵۲۰، ۱۷.۳۶۶۸ و ۲۰.۴۳۷۶ میلی‌ثانیه بوده است. در کلید ۱۰۲۴ بیتی نیز مقادیر ۱۰۱.۸۲۵۱، ۸۵.۵۲۵۵ و ۱۳۵.۷۷۸۲ میلی‌ثانیه به‌دست آمده است. همچنین، مقایسه مقادیر میانگین، میانه، کمینه و بیشینه نشان می‌دهد که در برخی سناریوها، به‌خصوص هنگام استفاده از کلید ۱۰۲۴ بیتی، پراکندگی زمانی بیشتر است. این مسئله را می‌توان به حساسیت عملیات اعداد بزرگ و هزینه محاسباتی بالاتر پارامترهای رمزنگاری نسبت داد؛ با این

حال، از داده‌های حاضر نمی‌توان علت سخت‌افزاری یا سیستم‌عاملی مشخصی برای این پراکندگی را به‌طور قطعی نتیجه‌گیری کرد. شکل ۴-۴ این تاثیر را تا حد بسیار خوبی نشان میدهد.



شکل ۴-۵ تاثیر تعداد کلاینت‌ها و طول کلد بر زمان کل اجرا

از منظر کاربردی، نتایج نشان می‌دهد که طرح پیشنهادی برای سناریوهایی که در آن چندین کلاینت مقدار حساس خود را بدون افشای مقدار خام برای یک سرور ارسال می‌کنند، معماری مناسبی ارائه می‌دهد. در این معماری، سرور به مقادیر خام کلاینت‌ها دسترسی ندارد و در عین حال قادر است مجموع وزن‌دار مقادیر رمزشده را محاسبه کند. پس از آن، تنها مقدار تجمیع‌شده رمزگشایی می‌شود و میانگین وزن‌دار نهایی از روی مقدار صحیح رمزگشایی‌شده و مجموع وزن‌ها محاسبه می‌گردد. استفاده از نمایش fixed-point با مقیاس ۱۰۰۰۰ نیز امکان پشتیبانی از مقادیر دارای چهار رقم اعشار را فراهم می‌کند و از تبدیل مستقیم اعداد اعشاری به فضای پیام رمزنگاری جلوگیری می‌کند. بدین ترتیب، فرآیند محاسبه میانگین وزن‌دار در فضای صحیح انجام شده و در پایان با تقسیم بر $\sum w_i$ ۱۰۰۰۰، مقدار نهایی به فضای اعشاری بازگردانده می‌شود.

همچنین، افزودن مکانیزم امضای دیجیتال یک تفاوت اساسی میان یک سامانه صرفاً محرمانه و یک سامانه محرمانه و احرازشده ایجاد می‌کند. در طرح پیشنهادی، سرور نمی‌تواند صرفاً بر اساس معتبر بودن ساختار ریاضی ciphertext فرض کند که مقدار از یک کلاینت مجاز دریافت شده است؛ بلکه ابتدا شناسه کلاینت را با فهرست کلاینت‌های مجاز تطبیق داده، سپس شناسه دور اجرا، nonce و سایر اطلاعات پیام را کنترل کرده و در نهایت امضا را با کلید عمومی ثبت‌شده کلاینت اعتبارسنجی می‌کند. در صورت نامعتبر بودن امضا، تغییر ciphertext ، تغییر وزن، استفاده از nonce تکراری یا ارسال پیام مربوط به دوری غیر از دور جاری، contribution مربوطه از فرآیند محاسبه حذف می‌شود. این سازوکار باعث می‌شود کنترل دسترسی و تمامیت داده قبل از عملیات هم‌ریختی انجام شود و داده نامعتبر وارد محاسبات تجمیعی نشود.

در مجموع، نتایج ۱۰۰ اجرای آزمایشی انجام‌شده نشان می‌دهد که SBHE-Benaloh توانسته است میان سه نیاز اصلی این مسئله، یعنی محرمانگی داده، قابلیت محاسبه هم‌ریختی و احراز اصالت کلاینت، یک سازش عملی برقرار کند. نتایج زمانی نشان می‌دهند که در اندازه کلید ۲۵۶ بیتی، زمان کل متوسط برای ۱۰۰ کلاینت حدود ۱۱۹ میلی‌ثانیه و برای ۳۰۰ کلاینت حدود ۲۷۶ میلی‌ثانیه است؛ در اندازه کلید ۵۱۲ بیتی این مقادیر تقریباً ۱۵۲ و ۳۳۹ میلی‌ثانیه و در اندازه کلید ۱۰۲۴ بیتی تقریباً ۴۱۱ و ۷۲۳ میلی‌ثانیه بوده‌اند. بنابراین، افزایش اندازه کلید امنیت محاسباتی بالاتری را هدف قرار می‌دهد، اما هم‌زمان سربار محاسباتی سیستم را

افزایش می‌دهد. از سوی دیگر، افزایش تعداد کلاینت‌ها عمدتاً هزینه مراحل Encryption و Aggregation را افزایش می‌دهد، در حالی که Decryption نهایی همچنان نسبتاً کم‌هزینه باقی می‌ماند. بر این اساس، انتخاب پارامترهای نهایی سیستم باید متناسب با سطح امنیت موردنیاز، تعداد کلاینت‌ها و محدودیت زمانی کاربرد انجام شود.

در نهایت، می‌توان نتیجه گرفت که نوآوری اصلی این پژوهش صرفاً استفاده مجدد از Benaloh برای محاسبه هم‌ریختی نیست، بلکه ارائه یک معماری احرازشده و چندکلاینتی مبتنی بر Benaloh است که در آن هویت و تمامیتcontribution ها پیش از تجمیع بررسی می‌شود، ciphertext ها بدون افشای مقادیر خام با یکدیگر ترکیب می‌شوند و تنها خروجی نهایی رمزگشایی می‌شود. این ویژگی، طرح را برای سناریوهایی که داده‌های عددی حساس از چند منبع مستقل به یک سرور مرکزی ارسال می‌شوند، مناسب می‌سازد. با توجه به نتایج تجربی، مسیر توسعه آینده می‌تواند بر کاهش هزینه Setup برای پارامترهای بزرگ، بهینه‌سازی عملیاتAggregation ، بررسی پیاده‌سازی موازی برای تعداد بسیار بالاتر کلاینت‌ها و جایگزینی سازوکار امضای مستقل هر کلاینت با سازوکارهای Aggregate Signature متمرکز شود. به‌خصوص استفاده از امضاهای قابل تجمیع می‌تواند در سامانه‌هایی با صدها یا هزاران کلاینت، سربار ارتباطی و هزینه اعتبارسنجی امضاها را کاهش داده و زمینه را برای توسعه نسخه مقیاس‌پذیرتر طرح پیشنهادی فراهم کند. در نتیجه، یافته‌های این فصل نشان می‌دهند که طرح SBHE-Benaloh نه‌تنها از نظر حفظ قابلیت هم‌ریختی Benaloh قابل استفاده است، بلکه با افزودن لایه احراز هویت و کنترل تمامیت، یک چارچوب منسجم‌تر برای پردازش امن داده‌های چندکلاینتی ارائه می‌دهد.

پیوست‌ها

پیوست ۲-الف: پکیج کلمات توقف دنا

به‌طور معمول، داده‌های متنی خام به‌صورت مستقیم برای الگوریتم‌های یادگیری ماشین و مدل‌های پردازش زبان طبیعی (NLP) قابل استفاده نیستند. پیش از ورود داده‌های متنی به مدل، معمولاً یک سری عملیات پیش‌پردازش روی آن‌ها انجام می‌شود که شامل نرمال‌سازی، حذف نویز، واژه‌سازی (tokenization)، ریشه‌یابی (lemmatization)، ساقه‌سازی (stemming) و حذف واژگان پربسامد بی‌معنا (stopword removal) است.

یکی از مراحل مهم در این فرایند، حذف واژگان پربسامد بی‌معناست. واژگان پربسامد بی‌معنا، واژگانی هستند که معمولاً نقش محدودی در شناسایی موضوع یا معنای اصلی یک متن دارند و در بسیاری از کاربردهای پردازش زبان طبیعی، حذف آن‌ها می‌تواند گامی در جهت کاهش نویز و کاهش ابعاد داده‌ها محسوب شود. در زبان فارسی، این مسئله به دلیل ساختار زبانی، تنوع نوشتاری، استفاده از نیم‌فاصله (zero-width non-joiner یا ZWJ)، اشکال مختلف نوشتاری واژگان و نبود یک فهرست جامع و واحد از واژگان پربسامد بی‌معنا، اهمیت دوچندان می‌یابد. در نتیجه، پژوهشگران در بسیاری از پروژه‌ها ناگزیرند که فهرست واژگان پربسامد بی‌معنای خود را به‌صورت دستی تهیه کنند یا آن را از منابع گوناگون گردآوری نمایند. برای حل این مشکل، «دنا» (DENA) طراحی شده است؛ یک بسته نرم‌افزاری و سرویس برنامه‌نویسی کاربردی (API) که فهرستی از واژگان پربسامد بی‌معنای فارسی را در اختیار پژوهشگران، دانشجویان، توسعه‌دهندگان و پروژه‌های پردازش زبان طبیعی قرار می‌دهد.

در پردازش زبان طبیعی، واژه یا نشانه‌ای (token) که در یک کاربرد خاص، ارزش اطلاعاتی نسبتاً کمی برای تحلیل موردنظر داشته باشد، واژهٔ پربسامد بی‌معنا (stopword) نامیده می‌شود و می‌توان آن را پیش از مرحلهٔ مدل‌سازی حذف کرد. برای نمونه، در یک متن فارسی، واژگانی نظیر «از»، «به»، «در»، «با»، «و»، «که»، «را»، «این»، «آن» نسبت به واژگانی که موضوع اصلی متن را مشخص می‌کنند، وزن معنایی بسیار کمتری دارند. فرض کنید متن زیر را داریم:

«این مقاله درباره کاربرد یادگیری ماشین در تشخیص بیماری‌های مختلف است.»

پس از مرحله واژه‌سازی، نشانه‌هایی مانند «این»، «مقاله»، «درباره»، «کاربرد»، «یادگیری»، «ماشین»، «در»، «تشخیص»، «بیماری‌های»، «مختلف»، «است» تولید می‌شوند. اگر هدف سیستم، استخراج کلیدواژه‌ها یا ایجاد یک بازنمایی آماری از متن باشد، برخی از این واژگان ممکن است ارزش اطلاعاتی پایینی داشته باشند. بنابراین، با استفاده از یک فهرست مناسب از واژگان پربسامد بی‌معنا، می‌توان بخشی از این واژگان را حذف کرد.

حذف واژگان پربسامد بی‌معنا صرفاً یک گام ساده در پیش‌پردازش متن نیست؛ بلکه در بسیاری از پروژه‌های پردازش زبان طبیعی، می‌تواند بر حجم داده‌ها، سرعت پردازش و کیفیت بازنمایی متنی تأثیرگذار باشد. یکی از مهم‌ترین مزایای حذف واژگان پربسامد بی‌معنا، کاهش تعداد نشانه‌هایی است که باید توسط الگوریتم پردازش شوند. فرض کنید یک پایگاه داده شامل چندین میلیون جمله باشد. اگر تعداد قابل‌توجهی از نشانه‌ها در این جملات، از واژگان پربسامد و کم‌اطلاعات تشکیل شده باشند، حذف آن‌ها می‌تواند تعداد نشانه‌های مورد پردازش را کاهش دهد. این موضوع به‌ویژه در پروژه‌های پردازش زبان طبیعی در مقیاس بزرگ، اهمیت بالایی

دارد. در روش‌هایی مانند کیسه واژگان (Bag of Words)، بسامد معکوس بسامد اسناد (TF-IDF)، شمارش برداری (Count Vectorization) و برخی رویکردهای مهندسی ویژگی، هر واژه می‌تواند به یک ویژگی تبدیل شود. حضور تعداد زیادی واژهٔ کم‌اطلاعات می‌تواند ابعاد فضای ویژگی را افزایش دهد. برای مثال، اگر یک مدل با ۱۰۰٬۰۰۰ ویژگی ساخته شود، ممکن است برخی از این ویژگی‌ها مربوط به واژگان بسیار پربسامدی باشند که اطلاعات کمی دربارهٔ دسته یا موضوع متن ارائه می‌دهند. حذف واژگان پربسامد بی‌معنا می‌تواند در برخی کاربردها به کاهش این مشکل کمک کند. واژگان پربسامد بی‌معنا در بسیاری از کاربردهای دسته‌بندی متن، اطلاعات تمایزدهنده چندانی ارائه نمی‌دهند. برای مثال، در سامانه‌ای برای دسته‌بندی مقاله‌های علمی، واژگانی مانند «از»، «به»، «در» و «که» معمولاً اطلاعات محدودی دربارهٔ موضوع مقاله ارائه می‌دهند. در مقابل، واژگانی مانند «یادگیری ماشین»، «رمزنگاری»، «شبکهٔ عصبی»، «پردازش زبان طبیعی» می‌توانند اطلاعات بسیار بیشتری دربارهٔ موضوع متن فراهم آورند.

اما باید توجه داشت که همیشه نیاز به حذف این کلمات نیست. این یکی از مهم‌ترین نکاتی است که هنگام طراحی خط‌لوله‌های پردازش زبان طبیعی (NLP pipelines) باید مد نظر قرار گیرد. حذف واژگان پربسامد بی‌معنا یک قاعدهٔ جهانی یا الزامی برای همهٔ پروژه‌های پردازش زبان طبیعی نیست. در برخی کاربردها، حذف این واژگان می‌تواند باعث از بین رفتن اطلاعات مهمی از متن شود. برای نمونه، در سامانه‌های تحلیل احساسات، تشخیص نفی، تحلیل معنایی، پرسش و پاسخ، مدل‌های زبانی بزرگ (Large Language Models)، جستجوی معنایی و برخی وظایف مبتنی بر ترنسفورمر (Transformer)، واژگانی که در فهرست واژگان پربسامد بی‌معنا قرار دارند، ممکن است نقشی حیاتی در معنای جمله ایفا کنند. برای نمونه، تفاوت میان «این کار را انجام دادم» و «این کار را انجام ندادم» – واژهٔ «ندادم» یا ساختار نفی می‌تواند برای تحلیل معنای جمله حیاتی باشد. بنابراین، پژوهشگران پیش از حذف واژگان پربسامد بی‌معنا، باید بررسی کنند که آیا این عملیات با هدف پروژه سازگاری دارد یا خیر. هدف «دنا» ارائهٔ حذف واژگان پربسامد بی‌معنا به‌عنوان یک قاعدهٔ قطعی نیست؛ بلکه ابزار و منبعی استاندارد را در اختیار پژوهشگران قرار می‌دهد تا در صورت نیاز، از فهرست فارسی استفاده کنند.

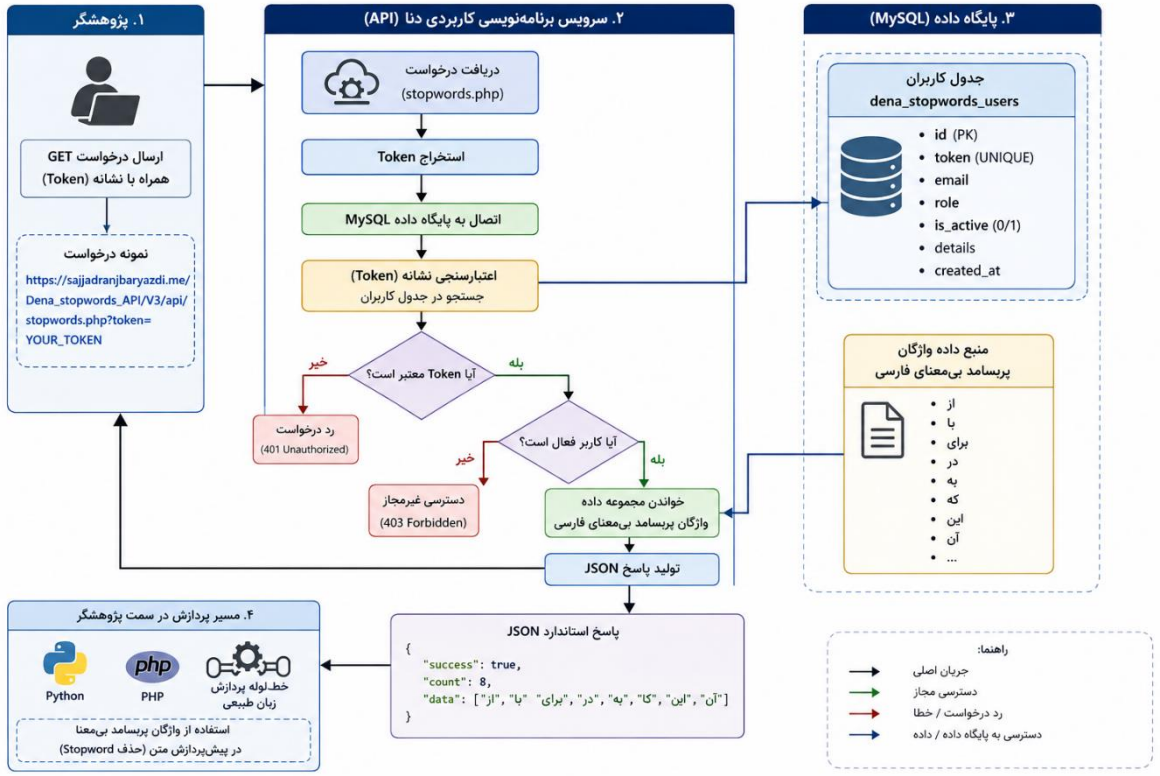
استفاده از فهرست واژگان پربسامد بی‌معنا در زبان انگلیسی معمولاً ساده‌تر است، زیرا منابع استاندارد و شناخته‌شدهٔ متعددی وجود دارد. اما در زبان فارسی، وضعیت متفاوت است. همچنین یک واژهٔ فارسی ممکن است در داده‌های واقعی به اشکال گوناگونی ظاهر شود. برای مثال، استفاده از فاصله و نیم‌فاصله می‌تواند نشانه‌های متفاوتی ایجاد کند. افزون بر این، تفاوت بین حروف عربی و فارسی مانند «ی» در برابر «ی» و «ک» در برابر «ک» می‌تواند در پردازش متن مشکل‌ساز باشد. بنابراین، یک فهرست واژگان پربسامد بی‌معنای فارسی باید هم‌زمان با واژه‌سازی و نرمال‌سازی در نظر گرفته شود.

دنا (DENA) چیست؟

«دنا» نام یک بسته نرم‌افزاری برای واژگان پربسامد بی‌معنای فارسی است که از نام کوه دنا در ایران الهام گرفته شده است. دنا یکی از نمادهای شناخته‌شدهٔ رشته‌کوه زاگرس و بخشی از جغرافیای ایران است. انتخاب این نام برای پروژه، نشان‌دهندهٔ رویکرد فارسی و ایرانی این ابزار است. هدف «دنا» ایجاد منبعی قابل استفاده برای پژوهشگران و توسعه‌دهندگان حوزهٔ پردازش زبان طبیعی است تا بتوانند به‌سادگی و به‌صورت استاندارد به فهرستی از واژگان پربسامد بی‌معنای فارسی دسترسی داشته باشند. «دنا» به جای

آنکه پژوهشگران را در هر پروژه به مدیریت دستی یک فایل واژگان پربسامد بی‌معنا مجبور کند، امکان دریافت این فهرست را از طریق یک سرویس برنامه‌نویسی کاربردی (API) فراهم می‌آورد.

معماری سرویس «دنا» به‌گونه‌ای طراحی شده است که بسیار ساده باشد. به‌طور کلی، یک پژوهشگر یک نشانهٔ منحصربه‌فرد (توکن) دریافت می‌کند و با ارسال آن نشانه به سرویس برنامه‌نویسی کاربردی، فهرست واژگان پربسامد بی‌معنا را دریافت می‌نماید. معماری کلی دنا در شکل۵-۱ قابل مشاهده است.



شکل ۵-۱

استفاده از دنا در پایتون

یکی از رایج‌ترین زبان‌های برنامه‌نویسی در علم داده و پردازش زبان طبیعی، پایتون است. برای استفاده از «دنا» در پایتون، می‌توان از کتابخانه `requests` استفاده کرد:

```
python
import requests

API_URL = "https://sajjadranjbaryazdi.me/Dena_stopwords_API/V۳/api/stopwords.php"
TOKEN = "YOUR_TOKEN"

response = requests.get(API_URL, params={"token": TOKEN}, timeout=۲۰)
response.raise_for_status()
result = response.json()
stopwords = result["data"]
print ,"تعداد واژگان پربسامد بی‌معنا:"len(stopwords)
print(stopwords)
```

در این کد، پایتون یک درخواست GET به سرویس برنامه‌نویسی کاربردی ارسال می‌کند. سرویس برنامه‌نویسی کاربردی خروجی JSON را برمی‌گرداند و برنامه با استفاده از `response.json()` آن را به ساختار داده‌ای پایتون تبدیل می‌کند. سپس `result["data"]` فهرست واژگان پربسامد بی‌معنا را در اختیار برنامه قرار می‌دهد

استفاده از دنا با الگوریتم TF-IDF

یکی از کاربردهای مهم حذف واژگان پربسامد بی‌معنا، آماده‌سازی داده‌ها برای الگوریتم بسامد معکوس بسامد اسناد (TF-IDF) است.

در این معماری، خط‌لوله پردازش می‌تواند به‌صورت زیر ساخت‌بندی شود:

متن خام ← نرمال‌سازی ← واژه‌سازی ← حذف واژگان پربسامد بی‌معنای دنا ← TF-IDF ← ماتریس ویژگی‌ها ← مدل یادگیری ماشین

برای پروژه‌های دسته‌بندی متن، این ساختار می‌تواند در کنار الگوریتم‌هایی مانند رگرسیون لجستیک (Logistic Regression)، ماشین بردار پشتیبان (SVM)، بیز ساده (Naive Bayes)، جنگل تصادفی (Random Forest)، XGBoost و LightGBM استفاده شود.

مدیریت نشانه و امنیت

«دنا» امکان اختصاص یک نشانه مستقل به هر پژوهشگر را فراهم می‌آورد که کنترل دسترسی، مدیریت کاربران و امنیت را ممکن می‌سازد. محدودسازی نرخ درخواست (مثلاً ۶۰ درخواست در دقیقه) از سرویس برنامه‌نویسی کاربردی در برابر سوءاستفاده محافظت می‌کند. «دنا» از HTTPS، تولید نشانه‌های تصادفی، پرسش‌های آماده‌شده (prepared statements) و قابلیت غیرفعال‌سازی کاربران برای تأمین امنیت استفاده می‌کند.

کدهای وضعیت HTTP مورد استفاده:

- ۲۰۰ (موفقیت)
- ۴۰۱ (نشانه نامعتبر)
- ۴۰۳ (دسترسی غیرمجاز)
- ۴۰۵ (روش مجاز نیست)
- ۴۲۲ (پارامتر نامعتبر)
- ۴۲۹ (محدودیت نرخ درخواست فراتر رفته)
- ۵۰۳ (سرویس در دسترس نیست)
- ۵۰۰ (خطای داخلی سرور)

کاربرد در پروژه‌های پژوهشی و یکپارچه‌سازی

«دنا» می‌تواند در دسته‌بندی متن، تحلیل احساسات، تشخیص موضوع، تشخیص هرزنامه (spam detection)، دسته‌بندی اخبار و بسیاری از وظایف دیگر پردازش زبان طبیعی استفاده شود. این سرویس به‌راحتی با خط‌لوله‌های مدرن پردازش زبان طبیعی از جمله TF-IDF، Word۲Vec، FastText و بردارهای تعبیه‌شدهٔ ترنسفورمر (Transformer embeddings) یکپارچه می‌شود. «دنا» جایگزین واژه‌سازی یا نرمال‌سازی نیست؛ بلکه منبعی برای واژگان پربسامد بی‌معناست که در مرحلهٔ پیش‌پردازش قرار می‌گیرد.

«دنا» تلاش می‌کند تا یک مشکل ساده اما تکراری را در پروژه‌های پردازش زبان طبیعی فارسی حل کند: دسترسی آسان، متمرکز و قابل برنامه‌ریزی به واژگان پربسامد بی‌معنای فارسی. با استفاده از سرویس برنامه‌نویسی کاربردی، پژوهشگران می‌توانند مستقیماً واژگان پربسامد بی‌معنا را در خط‌لولهٔ خود دریافت کرده و از آن‌ها در فرایندهای پیش‌پردازش، مهندسی ویژگی و مدل‌سازی

پردازش زبان طبیعی استفاده کنند. از این منظر، «دنا» می‌تواند به‌عنوان یکی از مؤلفه‌های زیرساختی یک خط‌لوله‌ٔ استاندارد برای پردازش زبان طبیعی فارسی ایفای نقش کند.

پیوست ۳-الف: مسئله لگاریتم گسسته(Discrete Logarithm Problem)

مسئله لگاریتم گسسته یکی از بنیادی‌ترین مسائل دشوار در رمزنگاری کلید عمومی است و پایه امنیت بسیاری از طرح‌های رمزنگاری از جمله ElGamal ، سیستم‌های امضای دیجیتال مبتنی بر منحنی‌های بیضوی، و پروتکل تبادل کلید Diffie–Hellman را تشکیل می‌دهد. این مسئله در گروه‌های متناهی (به‌ویژه گروه ضربی اعداد صحیح پیمانه‌ای و گروه‌های منحنی بیضوی) تعریف می‌شود و دشواری محاسباتی آن، مبنای استحکام رمزنگاری در برابر حملات کلاسیک (و برخی حملات کوانتومی) قرار می‌گیرد.

تعریف ریاضی

فرض کنید G یک گروه متناهی از مرتبه n باشد که به‌صورت ضربی نمایش داده می‌شود. همچنین فرض کنید $g \in G$ یک عضو از گروه باشد. مسئله لگاریتم گسسته به این صورت تعریف می‌شود:

با داشتن g و $h \in \langle g \rangle$ (زیرگروه تولید شده توسط g ، عدد صحیح x که معمولاً در بازه $0 \leq x < n$ قرار دارد) را به‌گونه‌ای بیابید که:

$$g^x = h$$

این عدد x را لگاریتم گسسته بر پایه g می‌نامند و با نماد زیر نشان می‌دهند:

$$x = \log_g h$$

توجه داشته باشید که در گروه‌های ضربی پیمانه‌ای نظیر $\mathbb{Z}_p^*$، عمل گروهی همان ضرب پیمانه‌ای است و معادله به صورت $g^x \equiv h \pmod p$ نوشته می‌شود.

لگاریتم گسسته، خواص مشابهی با لگاریتم معمولی در اعداد حقیقی دارد، اما محاسبه‌ی آن در گروه‌های با ساختار مناسب، بسیار دشوار است. برخی از ویژگی‌های مهم عبارت‌اند از:

۱. یک‌نواختی: اگر g مولد گروه (یا حداقل عضوی با مرتبه‌ی کافی بزرگ) باشد، نگاشت $x \mapsto g^x$ یک‌به‌یک خواهد بود.

۲. هم‌ریختی از گروه جمعی به ضربی: نگاشت $x \mapsto g^x$ یک هم‌ریختی گروهی از $(\mathbb{Z}_n, +)$ به $(G, \cdot)$ است. بنابراین:

$$\log_g(ab) = \log_g(a) + \log_g(b) \pmod n$$

۳. وابستگی به مولد: اگر مولد تغییر کند، لگاریتم گسسته نیز تغییر می‌کند و رابطهٔ آن با لگاریتم بر مبنای مولد دیگر از طریق ضرب در یک ثابت (معکوس‌پذیر پیمانه‌ای) قابل بیان است.

دشواری حل مسئله لگاریتم گسسته در گروه‌های به‌خوبی‌انتخاب‌شده (مانند $\mathbb{Z}_p^*$ با p اول بزرگ که $p-1$ دارای عامل اول بزرگ باشد، یا گروه‌های منحنی بیضوی با مرتبه‌ی اول) پایه‌ی امنیت بسیاری از پروتکل‌هاست. دلایل اصلی این اهمیت عبارت‌اند از:

- عدم وجود الگوریتم کارآمد عمومی: تاکنون الگوریتمی با پیچیدگی چندجمله‌ای (زیر نمایی) برای حل مسئله لگاریتم گسسته در گروه‌های عمومی یافت نشده است. بهترین الگوریتم‌های شناخته‌شده (مانند الگوریتم غربال‌گری میدان عددی برای $\mathbb{Z}_p^*$ و الگوریتم‌های ریشه‌ی ρ پولارد (Pollard's rho) برای گروه‌های منحنی بیضوی) دارای پیچیدگی زیرنمایی یا نمایی هستند.
- ارتباط با مسئلهDiffie–Hellman : امنیت پروتکل تبادل کلید Diffie–Hellman به دشواری حل مسئله لگاریتم گسسته وابسته است، هرچند که اثباتی برای هم‌ارزی کامل این دو مسئله در حالت کلی وجود ندارد.
- کاربرد در امضای دیجیتال: الگوریتم‌های امضایی مانند DSA و ECDSA مستقیماً بر پایه مسئله لگاریتم گسسته طراحی شده‌اند.

چندین روش برای حمله به مسئله لگاریتم گسسته وجود دارد که مهم‌ترین آن‌ها عبارت‌اند از:

۱. جستجوی کامل: محاسبه تکتک توان‌های $g^1, g^2, \ldots$ تا یافتن h .این روش از پیچیدگی $O(n)$ برخوردار است و فقط برای گروه‌های کوچک کاربرد دارد.

۲. الگوریتم گام کوچک–گام بزرگ [۱] : این الگوریتم با استفاده از تعادل میان زمان و حافظه، پیچیدگی $O\left(\sqrt{n}\right)$ دارد و برای گروه‌هایی با مرتبه نه‌چندان بزرگ قابل اجراست.

۳. الگوریتم پولارد: ρ-الگوریتمی تصادفی با پیچیدگی $O\left(\sqrt{n}\right)$ که در عمل بسیار کارآمدتر از روش گام کوچک–گام بزرگ است و حافظه کمی نیاز دارد. این الگوریتم به‌ویژه در حملات به منحنی‌های بیضوی کاربرد گسترده‌ای دارد.

٤. الگوریتم‌های شاخه‌ای[۲]: این روش‌ها برای گروه $\mathbb{Z}_p^*$ بسیار مؤثر هستند و پیچیدگی زیرنمایی دارند. به‌همین دلیل، انتخاب p به‌گونه‌ای که $p-1$ حداقل یک عامل اول بزرگ داشته باشد، برای مقاوم‌سازی الزامی است.

---

۱. Baby-Step Giant-Step

۲. Index Calculus

با ظهور رایانه‌های کوانتومی، مسئله لگاریتم گسسته به‌طور قابل‌توجهی آسیب‌پذیر می‌شود. الگوریتم شور می‌تواند مسئله لگاریتم گسسته را در گروه‌های متناهی با پیچیدگی چندجمله‌ای کوانتومی حل کند. این امر، بسیاری از سیستم‌های مبتنی بر لگاریتم گسسته از جمله ElGamal ، Diffie–Hellman و DSA را در دوره پساکوانتوم ناامن می‌کند و ضرورت توسعه رمزنگاری مقاوم در برابر کوانتوم را آشکار می‌سازد.

در نتیجه مسئله لگاریتم گسسته، ستون فقرات بسیاری از سیستم‌های رمزنگاری کلید عمومی مدرن است. درک عمیق این مسئله، انتخاب پارامترهای امن، و آگاهی از حملات موجود و تهدیدات آینده، برای طراحی و پیاده‌سازی سیستم‌های رمزنگاری مقاوم حیاتی است. طرح ElGamal که در این مقاله بررسی شد، نمونهٔ بارزی از کاربرد مستقیم این مسئله در رمزگذاری هم‌ریخت و امضای دیجیتال محسوب می‌شود.

پیوست ۳-ب: پروتکل تبادل کلید دفی-هلمن

پروتکل تبادل کلید دفی-هلمن که به اختصار DH نامیده می‌شوددر سال ۱۹۷۶ توسط Whitfield Diffie و Martin Hellman ارائه شد و انقلابی در حوزه رمزنگاری کلید عمومی ایجاد کرد. این پروتکل، اولین روش عملی برای تبادل امن یک کلید مخفی بین دو طرف از طریق یک کانال ناامن (عمومی) بود، بدون اینکه نیاز به تبادل قبلی کلید داشته باشند. امنیت این پروتکل بر دشواری مسئله لگاریتم گسسته استوار است.

فرض کنید دو کاربر، آلیس (Alice) و باب(Bob) ، قصد دارند یک کلید مخفی مشترک را از طریق یک کانال عمومی (که ممکن است توسط مهاجم شنود شود) تبادل کنند. پروتکل DH شامل مراحل زیر است:

مرحله ۱: انتخاب پارامترهای عمومی

یک گروه متناهی G) معمولاً $\mathbb{Z}_p^*$ با p اول بزرگ) و یک مولد $g \in G$ انتخاب می‌شوند. این پارامترها) عمومی و از پیش توافق‌شده هستند) و برای همه کاربران شناخته‌شده‌اند.

مرحله ۲: تولید کلیدهای خصوصی و عمومی

- آلیس یک عدد تصادفی a از بازه $\{۱, ۲, \dots, p-۲\}$ انتخاب می‌کند (کلید خصوصی آلیس) و کلید عمومی خود را به صورت زیر محاسبه می‌کند:

$$A = g^a \; p$$

- باب نیز به‌طور مشابه، عدد تصادفی b را انتخاب کرده و کلید عمومی خود را محاسبه می‌کند:

$$B = g^b \; p$$

مرحله ۳: تبادل کلیدهای عمومی

آلیس مقدار A را برای باب ارسال می‌کند و باب مقدار B را برای آلیس ارسال می‌کند. این مقادیر از طریق کانال عمومی منتقل می‌شوند و مهاجم می‌تواند آن‌ها را مشاهده کند.

مرحله ۴: محاسبه کلید مشترک

- آلیس با استفاده از کلید عمومی باب و کلید خصوصی خود، کلید مشترک را محاسبه می‌کند:

$$K = B^a \ p = (g^b)^a = g^{ab} \ p$$

- باب نیز به‌طور مشابه:

$$K' = A^b \ p = (g^a)^b = g^{ab} \ p$$

چون $K = K'$، هر دو به یک کلید مخفی مشترک $K = g^{ab} \ p$ دست می‌یابند.

امنیت پروتکل

امنیت پروتکل DH بر پایه دو مسئله دشوار ریاضی استوار است:

۱. مسئله لگاریتم گسسته (DLP): با داشتن g و $A = g^a$، یافتن a دشوار است. به‌طور مشابه برای b.

۲. مسئله Diffie–Hellman محاسباتی (CDH): با داشتن $g^a, g^b g$ ،، محاسبه g^{ab} دشوار است.

۳. مسئله Diffie–Hellman تصمیم‌گیری (DDH): تشخیص اینکه یک عنصر داده‌شده Z برابر با g^{ab} است یا یک عنصر تصادفی، دشوار است. این مسئله قوی‌تر از CDH است و همه گروه‌ها آن را برآورده نمی‌کنند.

در عمل، اگر گروه $\mathbb{Z}_p^*$ با p به‌خوبی انتخاب شود (به‌گونه‌ای که $p - ۱$ حداقل یک عامل اول بزرگ داشته باشد تا در برابر حملات شاخه‌ای مقاوم باشد)، این پروتکل از امنیت مناسبی برخوردار است.

نمونه‌ی عددی (برای درک بهتر)

فرض کنید $p = ۲۳$ و $g = ۵$.

- آلیس ($a = ۶$:خصوصی ۸ $\rightarrow A = ۵^۶ \ 23 =$)
- باب ($b = ۱۵$:خصوصی ۱۹ $\rightarrow B = ۵^{۱۵} \ 23 =$)
- آلیس ۲ $K = ۱۹^۶ \ 23 =$:
- باب ۲ $K' = ۸^{۱۵} \ 23 =$:

هر دو به کلید مشترک ۲ دست یافتند، در حالی که مهاجم تنها p, g, A, B را دیده است.

حملات شناخته‌شده بر DH

۱. حمله مرد میانی :(Man-in-the-Middle) اگر مهاجم بتواند پیام‌های بین آلیس و باب را دستکاری کند، می‌تواند دو کلید جداگانه با هر یک از آن‌ها ایجاد کند و ترافیک را رمزگشایی کند. این حمله با استفاده از احراز هویت (Authentication)پیشگیری می‌شود (مانند امضای دیجیتال یا گواهی‌های کلید عمومی).

۲. حمله لگاریتم گسسته با الگوریتم‌های پیشرفته :اگر ابعاد p کوچک باشد یا $p-1$ دارای عوامل اول کوچک باشد، حملات شاخه‌ای مؤثر واقع می‌شوند. به‌همین دلیل، اندازهٔ p معمولاً حداقل ۲۰۴۸ بیت و ترجیحاً ۳۰۷۲ یا ۴۰۹۶ بیت در نظر گرفته می‌شود.

۳. حمله کوانتومی :(Shor's Algorithm) الگوریتم شور می‌تواند مسئلهٔ لگاریتم گسسته را در زمان چندجمله‌ای کوانتومی حل کند و بنابراین DH در دوران رایانه‌های کوانتومی بزرگ‌مقیاس ناامن خواهد بود.

گونه‌ها و تعمیم‌ها

- Diffie–Hellman روی منحنی‌های بیضوی :(ECDH) از گروه‌های منحنی بیضوی به‌جای $\mathbb{Z}_p^*$ استفاده می‌کند که اندازه کلید بسیار کوچک‌تری را با همان سطح امنیت فراهم می‌آورد.
- Diffie–Hellmanگذرا :(Ephemeral DH) که در آن کلیدهای خصوصی a و b برای هر جلسه تازه تولید می‌شوند تا امنیت رو به جلو (Forward Secrecy) تأمین شود.
- Diffie–Hellmanمبتنی بر احراز هویت :(Authenticated DH) که با ترکیب با امضای دیجیتال، از حمله مرد میانی جلوگیری می‌کند.

ارتباط با طرح‌های رمزگذاری هم‌ریخت

پروتکل DH پایه بسیاری از طرح‌های رمزنگاری از جمله ElGamal است. درElGamal ، کلید عمومی $y = g^x$ مشابه کلید عمومی در DH است و فرایند رمزگذاری با انتخاب تصادفی k و محاسبه g^k و $m \cdot y^k$ دقیقاً از ساختار DH الهام گرفته شده است. بنابراین، درک عمیق DH برای تحلیل امنیتی و عملکردی ElGamal و سایر طرح‌های مبتنی بر لگاریتم گسسته ضروری است.

پروتکل تبادل کلیدDiffie–Hellman ، به‌عنوان یکی از مهم‌ترین دستاوردهای رمزنگاری کلید عمومی، پایه‌گذار نسل جدیدی از پروتکل‌های امن ارتباطی بوده است. دشواری مسئلهٔ لگاریتم گسسته، امنیت این پروتکل را تأمین می‌کند، هرچند که با ظهور رایانه‌های کوانتومی، نیاز به جایگزین‌های مقاوم در برابر کوانتوم) مانند رمزنگاری مبتنی بر شبکه (Lattice-based) یا رمزنگاری مبتنی بر کد ((Code-based) بیش از پیش احساس می‌شود. با این حال، DHهمچنان به‌عنوان یک مفهوم بنیادین در آموزش و طراحی سیستم‌های رمزنگاری مدرن جایگاه ویژه‌ای دارد.

پیوست ۳-ج: مسئله باقیمانده‌های مرکب درجه‌ی n

مسئله باقیمانده‌های مرکب درجه‌ی n که به اختصار CRA یا CRA-n نامیده می‌شود، یکی از بنیادی‌ترین مفاهیم در رمزنگاری کلید عمومی مدرن است و به‌ویژه به‌عنوان ستون امنیتی سیستم رمزگذاری Paillier و تعمیم آن یعنی Damgård–Jurik شناخته می‌شود. این مسئله، که توسط Pascal Paillier در سال ۱۹۹۹ به‌صورت رسمی معرفی شد، مبانی نظری محکمی برای اثبات امنیت معنایی (Semantic Security) در برابر حملات متن‌برگزیده (Chosen-Plaintext Attack) در طرح‌های جمعی هم‌ریخت فراهم می‌آورد. درک عمیق این مسئله و دشواری محاسباتی آن، نه‌تنها برای تحلیل‌گران امنیتی، بلکه برای طراحان سیستم‌های رمزنگاری که قصد پیاده‌سازی و بهینه‌سازی طرح‌های مبتنی بر Paillier را دارند، ضروری است.

پیش از پرداختن به جزئیات ریاضی، باید تأکید کرد که این مسئله، برخلاف مسئلهٔ لگاریتم گسسته یا فاکتورگیری، در فضای پیمانه‌ای با توان مرکب () تعریف می‌شود و به‌گونه‌ای طراحی شده است که حتی با دانستن (که حاصلضرب دو عدد اول بزرگ است)، تعیین اینکه یک عنصر معین در دارای ریشه‌ی -ام است یا خیر، با دشواری ریاضی قابل‌توجهی همراه باشد. این ویژگی، پایه‌ی امنیت رمزگذاری Paillier را در برابر حملات بازیابی متن اصلی (Plaintext Recovery) تشکیل می‌دهد.$n^2 n\mathbb{Z}_{n^2}^* n$

فرض کنید $n = p \cdot q$ حاصلضرب دو عدد اول بزرگ و متمایز باشد، به‌گونه‌ای که p و q از نظر محاسباتی امن انتخاب شده باشند (معمولاً با طول بیت حداقل ۵۱۲ یا ۱۰۲۴ برای هر کدام). گروه ضربی $\mathbb{Z}_{n^2}^*$ شامل تمامی اعداد صحیح در بازهٔ $\{1, 2, \dots, n^2 - 1\}$ است که نسبت به n^2 اول هستند. این گروه دارای مرتبه‌ی $\phi(n^2) = n \cdot \phi(n) = n(p-1)(q-1)$ است.

در این گروه، مجموعه‌ی باقیمانده‌های مرکب درجه‌ی n (n-th composite residues) به‌صورت زیر تعریف می‌شود:

$$\mathcal{R}_n = \{z \mid z \in \mathbb{Z}_{n^2}^* \ \exists\, u \in \mathbb{Z}_{n^2}^* \text{ به‌گونه‌ای که } z \equiv u^n \pmod{n^2}\}$$

به‌عبارت ساده‌تر، یک عدد z در $\mathbb{Z}_{n^2}^*$ یک باقیمانده مرکب درجه‌ی n نامیده می‌شود اگر بتوان آن را به‌صورت توان n-ام یک عنصر دیگر در همان گروه نوشت. این مجموعه، در واقع زیرگروهی از $\mathbb{Z}_{n^2}^*$ است که از تصویر نگاشت توان n-ام تولید می‌شود.

حال، مسئله باقیمانده‌های مرکب درجه‌ی n) به‌اختصار (CR-n به این صورت بیان می‌شود:

با داشتن یک عدد مرکب n و یک عنصر $z \in \mathbb{Z}_{n^2}^*$ که به‌صورت تصادفی انتخاب شده است، تصمیم بگیرید که آیا z عضوی از $\mathcal{R}_n$ است یا خیر. به‌عبارت دیگر، آیا ریشه‌ی n-ام z در $\mathbb{Z}_{n^2}^*$ وجود دارد یا خیر؟

فرضیه‌ی اساسی این است که هیچ الگوریتم چندجمله‌ای (با زمان احتمالی) وجود ندارد که بتواند این مسئله را با احتمال غیرقابل‌چشم‌پوشی بهتر از تصادف خالص حل کند، به‌شرطی که n به‌اندازه‌ی کافی بزرگ باشد و عوامل اول p و q مخفی نگه داشته شوند. این فرضیه، به‌عنوان فرضیه باقیمانده‌های مرکب (Composite Residuosity Assumption)شناخته می‌شود و پایه‌ی امنیت طرح Paillier را تشکیل می‌دهد.

بسیار مهم است که این مسئله را با مفاهیم مشابه اما متفاوت در رمزنگاری مقایسه کنیم تا از اشتباهات مفهومی جلوگیری شود:

۱. باقیمانده‌های درجه‌ی دوم (Quadratic Residues): در گروه $\mathbb{Z}_p^*$ با p اول، تعیین اینکه یک عدد a دارای ریشه‌ی دوم است یا خیر، با استفاده از نماد لژاندر $\left(\frac{a}{p}\right)$ به‌راحتی قابل محاسبه است و بنابراین این مسئله آسان محسوب می‌شود. اما در حالت مرکب با پیمانه n^2، تعیین وجود ریشه‌ی n-ام به مراتب دشوارتر است.

۲. مسئله فاکتورگیری (Factoring): اگر بتوان $n = pq$ را فاکتور گرفت، محاسبه $\phi(n)$ و سپس یافتن ریشه‌ی n-ام هر عنصر در $\mathbb{Z}_{n^2}^*$ با استفاده از قضیه‌ی باقیمانده‌ی چینی (CRT) به‌راحتی امکان‌پذیر خواهد شد. بنابراین، دشواری CR-n حداقل به اندازه‌ٔ دشواری فاکتورگیری است و در واقع، CR-nمسئله‌ای سخت‌تر از فاکتورگیری محسوب می‌شود (اگرچه اثبات رسمی برای این سخت‌تر بودن وجود ندارد و این یک فرضیه است).

۳. مسئله Diffie–Hellman تصمیم‌گیری DDH (DDH): در گروه‌های با مرتبه اول تعریف می‌شود و تشخیص اینکه g^{ab} از یک عنصر تصادفی قابل‌تشخیص است یا خیر را بررسی می‌کند CR-n .اما در گروهی با مرتبه‌ی مرکب $(n \cdot \phi(n))$تعریف می‌شود و ساختار جبری متفاوتی دارد که آن را برای کاربردهای رمزگذاری هم‌ریخت جمعی مناسب‌تر می‌سازد.

برای درک عمیق‌تر ارتباط میان CR-n و امنیتPaillier ، باید به ساختار رمزنگاری این طرح بازگردیم. درPaillier ، فرایند رمزگذاری به‌صورت $c = g^m \cdot r^n \; n^2$ تعریف می‌شود که در آن g یک عنصر از $\mathbb{Z}_{n^2}^*$ با مرتبه‌ای مناسب (معمولاً $g = 1 + n$) و r یک عنصر تصادفی از $\mathbb{Z}_n^*$ است.

توجه کنید که جمله $r^n \; n^2$ همواره یک باقیمانده مرکب درجه‌ی n است، زیرا به‌وضوح دارای ریشه‌ی n-ام r است. اما جمله $g^m \; n^2$ لزوماً یک باقیمانده مرکب نیست (مگر اینکه m مضربی از n باشد). بنابراین، متن رمز c از حاصلضرب یک باقیمانده مرکب (r^n) و یک عنصر غیرباقیمانده (یا باقیمانده، بسته به m)تشکیل شده است.

حال اگر مهاجمی بتواند تشخیص دهد که آیا دارای ریشه‌ی -ام است یا خیر، می‌تواند اطلاعاتی دربارهٔ به‌دست آورد. به‌ویژه، اگر باشد، آن‌گاه نیز باید در باشد، که این امر معادل با خواهد بود (با فرض اینکه خود دارای مرتبه‌ای باشد که را تولید نکند). این ویژگی، پایه‌ای برای اثبات امنیت معنایی Paillier است: اگر CR-n دشوار باشد، مهاجم نمی‌تواند تشخیص دهد که آیا حاصل رمزگذاری است یا ، و بنابراین طرح در برابر حملات متن‌برگزیده‌ی تطبیقی (Adaptive Chosen-Plaintext Attack) امن خواهد بود.۱ $cnmc \in \mathcal{R}_n g^m \mathcal{R}_n m \equiv 0 \pmod n g \mathcal{R}_n cm = 0 m = 1$

چندین دسته از شواهد، دشواری مسئله CR-n را تأیید می‌کنند و به همین دلیل، این فرضیه به‌عنوان یک اصل پذیرفته‌شده در جامعه رمزنگاری مورد استفاده قرار می‌گیرد:

۱. عدم وجود الگوریتم کارآمد عمومی :تاکنون هیچ الگوریتمی با پیچیدگی چندجمله‌ای (برای n با عوامل اول بزرگ و به‌خوبی‌انتخاب‌شده) برای حل CR-n ارائه نشده است. بهترین الگوریتم‌های شناخته‌شده، یا نیاز به فاکتورگیری n دارند (که خود یک مسئله‌ی سخت با پیچیدگی نمایی یا زیرنمایی است) یا از جستجوی نمایی در فضای $\mathbb{Z}_{n^2}^*$ استفاده می‌کنند.

۲. رابطه با مسئله فاکتورگیری :همان‌طور که اشاره شد، اگر بتوان n را فاکتور گرفت، CR-nبه‌راحتی قابل حل است. بنابراین، دشواری CR-n حداقل به اندازهٔ دشواری فاکتورگیری است. از آنجا که فاکتورگیری اعداد ۱۰۲۴ بیتی و بزرگ‌تر با فناوری‌های فعلی غیرعملی محسوب می‌شود، CR-n نیز به‌طور طبیعی دشوار خواهد بود.

۳. مقاومت در برابر حملات کوانتومی نسبی :در حالی که الگوریتم شور (Shor) می‌تواند فاکتورگیری و لگاریتم گسسته را با پیچیدگی چندجمله‌ای کوانتومی حل کند، تأثیر این الگوریتم بر CR-n به‌صورت غیرمستقیم است (یعنی از طریق فاکتورگیری). بنابراین، در کوتاه‌مدت، CR-n نسبت به حملات کوانتومی مستقیم مقاوم‌تر از DLP به‌نظر می‌رسد، هرچند که در بلندمدت با ظهور رایانه‌های کوانتومی بزرگ‌مقیاس، فاکتورگیری و در نتیجه CR-n آسیب‌پذیر خواهد شد.

٤. کاربرد گسترده در پروتکل‌های امن :موفقیت طرح‌هایی مانند Paillier و Damgård–Jurik در کاربردهای عملی نظیر رأی‌گیری الکترونیک و یادگیری فدرال در سال‌های اخیر، خود گواهی غیرمستقیم بر دشواری CR-n است، زیرا در غیر این صورت این طرح‌ها مدت‌ها پیش شکسته می‌شدند.

برای پیاده‌سازی امن و کارآمد طرح‌های مبتنی بر CR-n ، رعایت چند نکته حیاتی ضروری است:

۱. انتخاب اندازه مناسب n :بر اساس توصیه‌های مؤسسهٔ ملی فناوری و استانداردهای آمریکا(NIST) ، اندازه n باید حداقل ۲۰۴۸ بیت باشد تا در برابر حملات فاکتورگیری مقاومت کند. با این حال، داده‌های این مطالعه نشان می‌دهند که افزایش اندازه‌ی n هزینه‌های محاسباتی قابل‌توجهی (به‌ویژه در رمزنگاری و تولید کلید) به همراه دارد. بنابراین، انتخاب اندازه‌ی کلید باید بر اساس توازن میان امنیت و کارایی انجام شود؛ برای سیستم‌های با نیاز به پاسخ‌گویی سریع، می‌توان از کلیدهای ۱۰۲۴ بیتی با آگاهی از ریسک‌های امنیتی استفاده کرد.

۲. انتخاب g بهینه :در عمل، انتخاب $g = ۱ + n$ رایج‌ترین و کارآمدترین گزینه است، زیرا توان‌رسانی با g را می‌توان با استفاده از بسط دو جمله‌ای به‌شکل $(۱ + n)^m \equiv ۱ + mn \pmod{n^۲}$ به‌طور قابل‌توجهی ساده‌سازی کرد. این ساده‌سازی، زمان رمزگذاری را در Paillier کاهش می‌دهد، اما باید توجه داشت که در تعمیمDamgård–Jurik ، انتخاب g نیازمند دقت بیشتری است.

۳. تولید اعداد اول p و q با شرایط خاص :برای اطمینان از سختیCR-n ، عوامل اول p و q باید به‌گونه‌ای انتخاب شوند که $p - ۱$ و $q - ۱$ دارای عوامل اول بزرگ باشند تا از حملات شاخه‌ای (Index Calculus) جلوگیری شود. همچنین، نسبت p/q نباید به عددی گویا با مخرج کوچک نزدیک باشد تا الگوریتم‌های مبتنی بر تقریب کسر (مانند الگوریتم وینر) شکست بخورند.

٤. مدیریت تصادفی‌سازی (Randomness): در رمزگذاری Paillier، انتخاب از باید به‌صورت واقعاً تصادفی (نه شبه‌تصادفی با دوره کوتاه) انجام شود تا از حملات مبتنی بر ضعف تولیدکننده‌ی تصادفی پیشگیری شود. همچنین، باید برای هر عملیات رمزگذاری جدید انتخاب شود تا خاصیت عدم‌قطعی (Probabilistic) طرح حفظ شود. $r\mathbb{Z}_n^* r$

اگرچه CR-n به‌عنوان یک فرضیه‌ی امنیتی پذیرفته شده است، اما چندین حمله‌ی تئوری و عملی علیه پیاده‌سازی‌های ضعیف آن وجود دارد که باید مورد توجه قرار گیرند:

۱. حمله مبتنی بر فاکتورگیری جزئی :(Partial Factoring) اگر مهاجم بتواند یکی از عوامل اول p یا q را با روش‌های مبتنی بر حملات کانال جانبی (Side-Channel) مانند تحلیل زمان (Timing Attack) یا تحلیل توان (Power Analysis)به‌دست آورد، CR-nبه‌راحتی قابل شکست خواهد بود. بنابراین، پیاده‌سازی‌های مقاوم در برابر کانال جانبی ضروری است.

۲. حمله متن‌رمز انتخاب‌شده (Chosen-Ciphertext Attack): Paillier در نسخه‌ی پایه، در برابر حملات CCA۲ (Chosen-Ciphertext Attack)در مرحلهٔ دوم (آسیب‌پذیر است و نیاز به تبدیلات امن مانند تبدیل فوجیساکی-اوکاموتو-پوینچوال (FO-Pointcheval) دارد تا به امنیت CCA۲ برسد. این تبدیلات معمولاً خاصیت هم‌ریختی را حفظ می‌کنند، اما هزینه‌ی محاسباتی اضافی به همراه دارند.

۳. حمله‌های مبتنی بر زیرگروه کوچک :(Small Subgroup Attacks) اگر $p-1$ یا $q-1$ دارای عوامل اول کوچک باشند، مهاجم می‌تواند از ساختار زیرگروه‌های $\mathbb{Z}_{n^2}^*$ برای استخراج اطلاعاتی درباره‌ی m استفاده کند. به‌همین دلیل، انتخاب p و q به‌گونه‌ای که $p-1=2p'$ و $q-1=2q'$ با p' و q' اعداد اول بزرگ اعداد اول امن یا Safe Primes باشد، توصیه می‌شود.

٤. حمله‌های کوانتومی :همان‌طور که ذکر شد، الگوریتم شور با فاکتورگیری n می‌تواند CR-n را بشکند، اما برای ابعاد کلید ۴۰۹۶ بیتی و بزرگ‌تر، پیاده‌سازی عملی الگوریتم شور در دوران کنونی ناممکن است. با این حال، برای کاربردهای بلندمدت (با افق زمانی بیش از ۱۰ سال)، پژوهش در زمینه‌ی رمزنگاری مقاوم در برابر کوانتوم ضروری است.

مسئله باقیمانده‌های مرکب درجه‌ی n (Composite Residuosity Assumption) به‌عنوان هستهٔ سخت‌افزاری امنیتی طرح Paillier و تعمیم آنDamgård–Jurik ، یکی از مفاهیم کلیدی در رمزنگاری مدرن به‌شمار می‌رود. درک ریاضی این مسئله، تمایز آن از مفاهیم مشابه، و آگاهی از ملاحظات عملی پیاده‌سازی، برای هر پژوهشگر و توسعه‌دهنده‌ای که قصد استفاده از این طرح‌ها را در کاربردهای واقعی دارد، ضروری است.

داده‌های تجربی این مطالعه نشان می‌دهند که با انتخاب صحیح پارامترها (به‌ویژه اندازه‌ی و انتخاب)، می‌توان تعادلی مناسب میان امنیت و کارایی برقرار کرد. با این حال، باید همواره به‌روزرسانی‌های امنیتی و حملات جدید علیه CR-n توجه داشت و در صورت نیاز، از کلیدهای با اندازه‌ی بزرگ‌تر یا طرح‌های جایگزین (مانند رمزنگاری مبتنی بر شبکه) برای کاربردهای فوق‌حساس استفاده کرد. در نهایت، CR-n نه‌تنها یک فرضیه ریاضی، بلکه یک ابزار عملی برای ساخت سیستم‌های رمزگذاری هم‌ریخت جمعی است که با رعایت اصول امنیتی، می‌تواند نقش مؤثری در حفاظت از حریم خصوصی در عصر داده‌های بزرگ ایفا کند.$ng=1+n$

پیوست ٤-الف الگوریتم امضای دیجیتال Ed۲۵۵۱۹

الگوریتم امضای دیجیتال Ed۲۵۵۱۹ یک طرح امضای مبتنی بر منحنی بیضوی است که بر روی منحنی Edwards به نام $Ed25519$تعریف می‌شود. این منحنی روی میدان متناهی $\mathbb{F}_p$ با

$$p = ۲^{۲۵۵} - ۱۹$$

و معادله

$$-x^۲ + y^۲ = ۱ + dx^۲y^۲$$

تعریف می‌شود که در آن $d = -۱۲۱۶۶۵/۱۲۱۶۶۶ \pmod p$است. یک نقطه پایه مشخص B نیز برای تولید کلیدها در نظر گرفته می‌شود. ساختار گروه حاصل دارای مرتبه‌ای شامل یک عامل اصلی بزرگ lاست و عملیات اصلی الگوریتم بر مبنای جمع نقاط منحنی و ضرب اسکالر انجام می‌شود.

در مرحله تولید کلید، یک مقدار تصادفی ۳۲ بایتی به نام Sانتخاب شده و با تابع هش SHA-۵۱۲ پردازش می‌شود:

$$h = \mathrm{SHA512}(S)$$

بخشی از خروجی هش با اعمال عملیات clamping به اسکالر خصوصی aتبدیل می‌شود. سپس کلید عمومی از رابطه زیر به دست می‌آید:

$$A = aB$$

که در آن Bنقطه پایه منحنی و Aکلید عمومی است. بنابراین کلید خصوصی شامل بذر تصادفی Sو کلید عمومی متناظر با آن است.

برای امضای پیام M، ابتدا از نیمه دوم مقدار هش‌شده بذر خصوصی برای تولید یک مقدار موقت rاستفاده می‌شود:

$$r = H\left(h_{\text{prefix}} \parallel M\right) \pmod l$$

سپس نقطه موقت امضا به صورت

$$R = rB$$

محاسبه می‌شود. مقدار چالش نیز از هش کلید عمومی، نقطه Rو پیام به دست می‌آید:

$$k = H(R \parallel A \parallel M) \pmod l$$

در نهایت مؤلفه دوم امضا با رابطه

$$S = (r + ka) \pmod{l}$$

محاسبه می‌شود. بنابراین امضای دیجیتال پیام برابر زوج (R, S)است.

در مرحله اعتبارسنجی امضا، گیرنده با در اختیار داشتن M، کلید عمومی Aو امضای (R, S)، مقدار

$$k = H(R \parallel A \parallel M) \pmod{l}$$

را محاسبه کرده و بررسی می‌کند که رابطه

$$SB = R + kA$$

برقرار باشد. با توجه به $A = aB$و $R = rB$، سمت راست رابطه برابر است با

$$R + kA = rB + kaB = (r + ka)B = SB$$

و در نتیجه، برقراری این رابطه نشان می‌دهد که امضا با کلید خصوصی متناظر با Aایجاد شده و پیام در فرآیند انتقال تغییر نکرده است.

فهرست اختصارات

اختصار	عبارت کامل	معادل/کاربرد فارسی
NLP	Natural Language Processing	پردازش زبان طبیعی
ML	Machine Learning	یادگیری ماشین
FL	Federated Learning	یادگیری فدرال
HE	Homomorphic Encryption	رمزگذاری هم‌ریخت
PHE	Partially Homomorphic Encryption	رمزگذاری جزئی هم‌ریخت
FHE	Fully Homomorphic Encryption	رمزگذاری کاملاً هم‌ریخت
EDA	Exploratory Data Analysis	تحلیل اکتشافی داده
TF-IDF	Term Frequency–Inverse Document Frequency	بسامد واژه–بسامد معکوس سند
SBERT	Sentence-BERT	مدل بازنمایی معنایی جمله مبتنی بر BERT
BERT	Bidirectional Encoder Representations from Transformers	بازنمایی‌های دوسویه رمزگذارها از مبدل‌ها
ROC	Receiver Operating Characteristic	مشخصه عملکرد گیرنده
AUC	Area Under the Curve	سطح زیر منحنی
API	Application Programming Interface	رابط برنامه‌نویسی کاربردی
AES	Advanced Encryption Standard	استاندارد رمزنگاری پیشرفته
GCM	Galois/Counter Mode	حالت گالوا/شمارنده
AEAD	Authenticated Encryption with Associated Data	رمزگذاری احرازاصالت‌شده با داده مرتبط
CSPRNG	Cryptographically Secure Pseudorandom Number Generator	مولد اعداد شبه‌تصادفی امن رمزنگاری
RSA	Rivest–Shamir–Adleman	RSA طرح رمزگذاری ریاضی
PKI	Public Key Infrastructure	زیرساخت کلید عمومی
SHA	Secure Hash Algorithm	الگوریتم درهم‌سازی امن

JSON	JavaScript Object Notation	نشانه‌گذاری اشیای جاوااسکریپت
GPU	Graphics Processing Unit	واحد پردازش گرافیکی
FPGA	Field-Programmable Gate Array	آرایه دروازه‌ای قابل برنامه‌ریزی میدانی
OOV	Out-of-Vocabulary	خارج از واژگان
BLS	Boneh–Lynn–Shacham	طرح امضای دیجیتال Boneh–Lynn–Shacham
SBHE	Signed-Benaloh Homomorphic Encryption	رمزگذاری هم‌ریخت بنالوح همراه با امضای دیجیتال
DENA	DENA Stopword Package	بسته واژگان توقف دنا

واژه نامه

واژه فارسی	معادل انگلیسی	تعریف
پردازش زبان طبیعی	Natural Language Processing (NLP)	حوزه‌ای برای تحلیل و پردازش زبان انسانی با روش‌های محاسباتی.
یادگیری فدرال	Federated Learning (FL)	آموزش توزیع‌شده مدل بدون انتقال داده خام کلاینت‌ها به سرور.
رمزگذاری هم‌ریخت	Homomorphic Encryption (HE)	رمزگذاری‌ای که امکان انجام برخی محاسبات روی داده رمز را فراهم می‌کند.
پیش‌پردازش	Preprocessing	مجموعه عملیات آماده‌سازی داده پیش از مدل‌سازی.
پاک‌سازی متن	Text Cleaning	حذف نویز و عناصر نامطلوب از متن.
توکن‌سازی	Tokenization	تقسیم متن به واحدهای واژگانی یا زیرواژگانی.
بردارسازی	Vectorization	تبدیل متن به نمایش عددی قابل استفاده برای مدل.
بردار ویژگی	Feature Vector	بردار عددی نمایانگر ویژگی‌های یک نمونه.
مدل از پیش‌آموزش‌دیده	Pre-trained Model	مدلی که پیش از کاربرد اصلی بر روی داده‌های بزرگ آموزش یافته است.
ماتریس تنک	Sparse Matrix	ماتریسی که بخش بزرگی از عناصر آن صفر است.
بیش‌برازش	Overfitting	یادگیری بیش از حد الگوهای خاص داده آموزشی.
طبقه‌بندی	Classification	انتساب هر نمونه به یکی از کلاس‌های تعریف‌شده.
طبقه‌بند	Classifier	مدل یا الگوریتم انجام‌دهنده طبقه‌بندی.
جنگل تصادفی	Random Forest	روش گروهی متشکل از چندین درخت تصمیم.

مدلی درختی برای تصمیم‌گیری بر اساس ویژگی‌ها.	Decision Tree	درخت تصمیم
روش ساخت ترتیبی مدل‌ها برای کاهش خطا.	Gradient Boosting	تقویت گرادیانی
پیاده‌سازی کارآمد تقویت گرادیانی.	Extreme Gradient Boosting	XGBoost
طبقه‌بندی‌کننده احتمالاتی مبتنی بر قضیه بیز.	Naive Bayes	بیز ساده
ترکیب خروجی چند مدل برای تصمیم نهایی.	Voting Classifier	طبقه‌بندی‌کننده رأی‌دهنده
ترکیب احتمالات پیش‌بینی مدل‌های مختلف.	Soft Voting	رأی‌دهی نرم
مقداری که خروجی احتمالی را به برچسب کلاس تبدیل می‌کند.	Decision Threshold	آستانه تصمیم
انتخاب آستانه متناسب با هدف و هزینه خطاها.	Threshold Tuning	تنظیم آستانه
نسبت پیش‌بینی‌های صحیح به کل نمونه‌ها.	Accuracy	دقت
نسبت مثبت‌های درست به کل مثبت‌های پیش‌بینی‌شده.	Precision	دقت مثبت
نسبت مثبت‌های درست شناسایی‌شده به کل مثبت‌های واقعی.	Recall	حساسیت/بازیابی
میانگین هارمونیک Precision و Recall.	F۱-score	نمره F۱
نمایش عملکرد طبقه‌بند در آستانه‌های مختلف.	Receiver Operating Characteristic	منحنی ROC
جدول مقایسه پیش‌بینی مدل با برچسب واقعی.	Confusion Matrix	ماتریس درهم‌ریختگی
نمونه منفی که اشتباهاً مثبت تشخیص داده شده است.	False Positive (FP)	مثبت کاذب
نمونه مثبت که اشتباهاً منفی تشخیص داده شده است.	False Negative (FN)	منفی کاذب

متن اصلی	Plaintext	.داده پیش از رمزگذاری
متن رمز	Ciphertext	.داده حاصل از رمزگذاری
کلید عمومی	Public Key	کلیدی که برای عملیات عمومی رمزگذاری منتشر می‌شود.
کلید خصوصی	Private Key	کلید محرمانه مورد استفاده برای رمزگشایی یا امضا.
رمزنگاری	Encryption	.تبدیل متن اصلی به متن رمز
رمزگشایی	Decryption	.بازیابی متن اصلی از متن رمز
امضای دیجیتال	Digital Signature	سازوکاری برای احراز هویت و تضمین تمامیت پیام.
احراز هویت	Authentication	.تأیید هویت فرستنده یا موجودیت
تمامیت داده	Data Integrity	.تضمین عدم تغییر غیرمجاز داده
محرمانگی	Confidentiality	.جلوگیری از دسترسی غیرمجاز به اطلاعات
تجمیع امن	Secure Aggregation	محاسبه تابعی از خروجی‌ها بدون آشکارسازی مقادیر منفرد.
حمله بازپخش	Replay Attack	ارسال مجدد یک پیام معتبر برای سوءاستفاده.
تسهیم راز شامیر	Shamir Secret Sharing	تقسیم یک راز به سهم‌هایی با نیاز به آستانه مشخص برای بازسازی.
درون‌یابی لاگرانژ	Lagrange Interpolation	.روش بازسازی چندجمله‌ای از نقاط مشخص
میدان متناهی	Finite Field	ساختار جبری متناهی مورد استفاده در محاسبات رمزنگاری.
AES-GCM	AES-GCM	.رمزگذاری متقارن همراه با احراز اصالت
nonce	Number Used Once	مقدار یک‌بارمصرف مورد استفاده در فرایند رمزگذاری.
Benaloh	Benaloh Cryptosystem	طرح رمزگذاری کلید عمومی با هم‌ریختی جمعی.

Paillier	Paillier Cryptosystem	طرح رمزگذاری کلید عمومی با هم‌ریختی جمعی.
Damgård–Jurik	Damgård–Jurik Cryptosystem	تعمیم طرح Paillier با فضای پیام قابل تنظیم.
ElGamal	ElGamal Cryptosystem	طرح رمزگذاری کلید عمومی با هم‌ریختی ضربی.
RSA	Rivest–Shamir–Adleman	طرح رمزگذاری کلید عمومی مبتنی بر فاکتورگیری.
میانگین وزنی	Weighted Average	میانگینی که وزن هر مقدار در آن لحاظ می‌شود.
نمایش نقطه ثابت	Fixed-Point Representation	تبدیل عدد اعشاری به نمایش صحیح با ضریب مقیاس.
ضریب مقیاس	Scaling Factor	ضریبی برای تبدیل مقادیر اعشاری به اعداد صحیح.
سرریز فضای پیام	Message Space Overflow	خروج مقدار محاسبه‌شده از فضای پیام مجاز.
DENA	DENA Stopword Package	بسته و سرویس واژگان توقف فارسی مورد استفاده پژوهش.

منابع

١. World Health Organization. (٢٠٢١). *Suicide worldwide in 2019: Global health estimates*. Geneva: WHO.

٢. Centers for Disease Control and Prevention (CDC). (٢٠٢٢). Leading Causes of Death Reports, ٢٠٢٠. *National Vital Statistics System*.

٣. Turecki, G., & Brent, D. A. (٢٠١٦). Suicide and suicidal behaviour. *The Lancet*, ٣٨٧(١٠٠٢٤), ١٢٢٧–١٢٣٩.

٤. Blease, C., Torous, J., & Hagmann, C. (٢٠٢٠). Ethical challenges in the use of digital data for mental health research. *The Lancet Digital Health*, ٢(٨), e٣٨٦-e٣٨٧.

٥. Glenn, C. R., et al. (٢٠٢٠). Adolescent suicide risk and the developmental context. *Annual Review of Clinical Psychology*, ١٦, ٣٩٧-٤٢٢.

٦. Niederkrotenthaler, T., et al. (٢٠٢٠). Association of suicidal ideation and behavior with social media use. *JAMA Network Open*, ٣(١٠), e٢٠٢١٣٩٨.

٧. Twenge, J. M., et al. (٢٠١٨). Increases in depression and suicide among US adolescents. *Clinical Psychological Science*, ٦(١), ٣-١٧.

٨. Coppersmith, G., et al. (٢٠١٨). Natural language processing in mental health. *ACM Computing Surveys*, ٥١(٥), ١-٣٦.

٩. Gunnarsson, K. F., et al. (٢٠٢١). Linguistic markers of suicidal ideation: A systematic review. *Journal of Affective Disorders*, ٢٩٥, ١٢٠٥-١٢١٧.

١٠. Shatte, A. B. R., et al. (٢٠١٩). Machine learning in mental health: A scoping review. *JMIR Mental Health*, ٦(١١), e١٣٣١٦.s

١١. Ji, S., Pan, S., Li, X., Cambria, E., Long, G., & Huang, Z. (٢٠٢١). Suicidal ideation detection: A review of machine learning methods and applications. *IEEE Transactions on Computational Social Systems*, ٨(١), ٢١٤–٢٢٦.

١٢. Heckler, W. F., de Carvalho, J. V., & Barbosa, J. L. V. (٢٠٢١). Machine learning for suicidal ideation identification: A systematic literature review. *Computers in Human Behavior*, ١٢٠, ١٠٦٨٠٧.

١٣. Leveraging Reddit for suicidal ideation detection: A review of machine learning and natural language processing techniques. (٢٠٢٢).

١٤. Sheng, Z. (٢٠٢٤). Suicidal ideation detection on social media using machine learning: A review. *Applied and Computational Engineering*, ٧١, ٥٨–٦٣.

١٥. McMahan, B., Moore, E., Ramage, D., Hampson, S., & Arcas, B. A. y. (٢٠١٧). Communication-efficient learning of deep networks from decentralized

data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, ٥٤, ١٢٧٣–١٢٨٢.

١٦. Rieke, N., Hancox, J., Li, W., et al. (٢٠٢٠). The future of digital health with federated learning. *NPJ Digital Medicine*, ٣, ١١٩.

١٧. Kairouz, P., McMahan, H. B., Avent, B., et al. (٢٠٢١). Advances and open problems in federated learning. *Foundations and Trends in Machine Learning*, ١٤(١–٢), ١–٢١٠.

١٨. Khalil, S. S., Abdelsalam, N., Spruit, M., et al. (٢٠٢٤). Federated learning for privacy-preserving depression detection with multilingual language models in social media posts. *Frontiers in Digital Health*.

١٩. Paillier, P. (١٩٩٩). Public-key cryptosystems based on composite degree residuosity classes. In *Advances in Cryptology—EUROCRYPT '99*, ٢٢٣–٢٣٨.

٢٠. Gentry, C. (٢٠٠٩). *A fully homomorphic encryption scheme*. Stanford University.

٢١. Wood, A., Najarian, K., & Kahrobaei, D. (٢٠٢١). Homomorphic encryption for machine learning in medicine and bioinformatics. *ACM Computing Surveys*, ٥٣(٤).

٢٢. A systematic review of homomorphic encryption and its contributions in healthcare industry. (٢٠٢٢).

٢٣. Lee, C. H., Lim, K. H., & Eswaran, S. (٢٠٢٥). A comprehensive survey on secure healthcare data processing with homomorphic encryption: Attacks and defenses. *Discover Public Health*, ٢٢, ١٣٧.

٢٤. Khurana, D., Koli, A., Khatter, K., & Singh, S. (٢٠٢١). Natural Language Processing: State of The Art, Current Trends and Challenges.

٢٥. Chomsky, N. (١٩٦٥). *Aspects of the Theory of Syntax*. Cambridge, MA: MIT Press.

٢٦. Rospocher, M., van Erp, M., Vossen, P., Fokkens, A., Aldabe, I., Rigau, G., Soroa, A., Ploeger, T., & Bogaard, T. (٢٠١٦). Building event-centric knowledge graphs from news. *Web Semantics: Science, Services and Agents on the World Wide Web*, In Press.

٢٧. Shemtov, H. (١٩٩٧). *Ambiguity management in natural language generation*. Stanford University.

٢٨. Hutchins, W. J. (١٩٨٦). *Machine translation: past, present, future* (p. ٦٦). Chichester: Ellis Horwood.

٢٩. Hutchins, W. J. (Ed.). (٢٠٠٠). *Early years in machine translation: memoirs and biographies of pioneers* (Vol. ٩٧). John Benjamins Publishing.

٣٠. Green Jr., B. F., Wolf, A. K., Chomsky, C., & Laughery, K. (١٩٦١, May). Baseball: an automatic question-answerer. In *Papers presented at the May 9-11, 1961, western joint IRE-AIEE-ACM computer conference* (pp. ٢١٩-٢٢٤). ACM.

٣١. Woods, W. A. (١٩٧٨). Semantics and quantification in natural language question answering. *Advances in computers*, ١٧, ١-٨٧.

٣٢. Hendrix, G. G., Sacerdoti, E. D., Sagalowicz, D., & Slocum, J. (١٩٧٨). Developing a natural language interface to complex data. *ACM Transactions on Database Systems (TODS)*, ٣(٢), ١٠٥-١٤٧.

٣٣. Wilks, Y., & Fass, D. (١٩٩٢). "The SRI Core Language Engine." In *Natural Language Processing Systems*. Springer-Verlag.

٣٤. Kamp, H., & Reyle, U. (١٩٩٣). *From Discourse to Logic: Introduction to Model-theoretic Semantics of Natural Language, Formal Logic and Discourse Representation Theory*. Kluwer Academic Publishers.

٣٥. Briscoe, T., Grover, C., Boguraev, B., & Carroll, J. (١٩٨٧). "The Alvey Natural Language Tools." In *Proceedings of the 3rd Conference of the European Chapter of the Association for Computational Linguistics*, pp. ١٣٩-١٤٨.

٣٦. Young, S., & Chase, L. (١٩٩٨). "Speech Recognition and Understanding: The DARPA Program." In *Proceedings of the IEEE*, ٨٦(٥), pp. ١٢٦٧-١٢٨٣.

٣٧. Sundheim, B., & Chinchor, N. (١٩٩٣). "Survey of the Message Understanding Conferences." In *Proceedings of the Workshop on Human Language Technology*, pp. ٥٦-٦٠.

٣٨. Kobsa, A., & Wahlster, W. (Eds.). (١٩٨٩). *User Models in Dialog Systems*. Springer-Verlag.

٣٩. Cohen, P. R., Morgan, J., & Pollack, M. E. (Eds.). (١٩٩٠). *Intentions in Communication*. MIT Press.

٤٠. McKeown, K. R. (١٩٨٥). *Text Generation: Using Discourse Strategies and Focus Constraints to Generate Natural Language Text*. Cambridge University Press.

٤١. Small, S. L., Cottrell, G. W., & Tanenhaus, M. K. (Eds.). (١٩٨٨). *Lexical Ambiguity Resolution: Perspectives from Psycholinguistics, Neuropsychology, and Artificial Intelligence*. Morgan Kaufmann.

٤٢. Manning, C. D., & Schütze, H. (١٩٩٩). *Foundations of Statistical Natural Language Processing*. MIT Press.

٤٣. Mani, I., & Maybury, M. T. (Eds.). (١٩٩٩). *Advances in Automatic Text Summarization*. MIT Press.

٤٤. Kilgarriff, A., & Grefenstette, G. (٢٠٠٣). Introduction to the special issue on the web as corpus. *Computational Linguistics*, ٢٩(٣), ٣٣٣-٣٤٧.

٤٥. Haddi, E., Liu, X., & Shi, Y. (٢٠١٣). The role of text pre-processing in sentiment analysis. *Procedia Computer Science*, ١٧, ٢٦-٣٢.

٤٦. Kaur, A., & Gupta, V. (٢٠٢٠). A comprehensive survey on text preprocessing techniques for natural language processing. *ACM Computing Surveys*, ٥٢(٤), ١-٣٦.

٤٧. Aljuaid, H., et al. (٢٠٢٠). Importance of preprocessing in Arabic text classification. *IEEE Access*, ٨, ٢٠٥٢٣٠-٢٠٥٢٤٣.

٤٨. Loper, E., & Bird, S. (٢٠٠٢). NLTK: The natural language toolkit. *Proceedings of the ACL-02 Workshop on Effective Tools and Methodologies for Teaching NLP*, ٦٣-٧٠.

٤٩. Kowsari, K., et al. (٢٠١٩). Text classification algorithms: A survey. *Information*, ١٠(٤), ١٥٠.

٥٠. Eisner, B., et al. (٢٠١٩). Emoji-based sentiment analysis. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, ٢٣٤٥-٢٣٥٠.

٥١. Fridkin, S., & M. (٢٠٢٠). Challenges in multilingual NLP for low-resource languages. *Journal of Artificial Intelligence Research*, ٦٨, ٢٤٥-٢٩٨.

٥٢. Shamsfard, M., & S. (٢٠١٩). Persian text normalization: A comprehensive approach. *Language Resources and Evaluation*, ٥٣(٢), ٢٦٧-٢٩٥.

٥٣. Karimi, S., et al. (٢٠٢٠). Challenges in Persian text processing. *ACM Transactions on Asian and Low-Resource Language Information Processing*, ١٩(٣), ١-٢٥.

٥٤. Wilbur, J., & S. (٢٠١٩). Stop word removal in natural language processing. *Journal of Computational Linguistics*, ٤٥(١), ١٢٧-١٥٢.

٥٥. Vijayarani, S., & J. (٢٠٢٠). Performance analysis of text preprocessing techniques. *International Journal of Advanced Computer Science and Applications*, ١١(٦), ٣٤٥-٣٥٢.

٥٦. Manning, C. D., & Schütze, H. (١٩٩٩). *Foundations of statistical natural language processing*. MIT Press.

٥٧. Jurafsky, D., & Martin, J. H. (٢٠٢٣). *Speech and language processing* (٣rd ed.). Stanford University.

٥٨. Coppersmith, G., et al. (٢٠١٨). Natural language processing in mental health. *ACM Computing Surveys*, ٥١(٥), ١-٣٦.

٥٩. Loper, E., & Bird, S. (٢٠٠٢). NLTK: The natural language toolkit. *Proceedings of the ACL-02 Workshop on Effective Tools and Methodologies for Teaching NLP*, ٦٣-٧٠.

٦٠. Bird, S., Klein, E., & Loper, E. (٢٠٠٩). *Natural language processing with Python*. O'Reilly Media.

٦١. Kaur, A., & Gupta, V. (٢٠٢٠). A comprehensive survey on text preprocessing techniques for natural language processing. *ACM Computing Surveys*, ٥٢(٤), ١-٣٦.

۶۲. Sennrich, R., Haddow, B., & Birch, A. (۲۰۱۶). Neural machine translation of rare words with subword units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, ۱۷۱۵-۱۷۲۵.

۶۳. Liu, Y., et al. (۲۰۲۱). Efficient text preprocessing for large-scale NLP. *Journal of Big Data*, ۸(۱), ۱-۱۸.

۶۴. Fridkin, S., & M. (۲۰۲۰). Challenges in multilingual NLP for low-resource languages. *Journal of Artificial Intelligence Research*, ٦۸, ۲٤٥-۲۹۸.

۶۵. Gunnarsson, K. F., et al. (۲۰۲۱). Linguistic markers of suicidal ideation: A systematic review. *Journal of Affective Disorders*, ۲۹٥, ۱۲۰٥-۱۲۱۷.

۶۶. Vijayarani, S., & J. (۲۰۲۰). Performance analysis of text preprocessing techniques. *International Journal of Advanced Computer Science and Applications*, ۱۱(٦), ۳٤٥-۳٥۲.

۶۷. Zhang, C., et al. (۲۰۲۱). Privacy-preserving machine learning: A survey. *ACM Computing Surveys*, ٥٤(۷), ۱-۳٦.

۶۸. Haddi, E., Liu, X., & Shi, Y. (۲۰۱۳). The role of text pre-processing in sentiment analysis. *Procedia Computer Science*, ۱۷, ۲٦-۳۲.

۶۹. Shamsfard, M., & S. (۲۰۱۹). Persian text normalization: A comprehensive approach. *Language Resources and Evaluation*, ٥۳(۲), ۲٦۷-۲۹٥.

۷۰. Karimi, S., et al. (۲۰۲۰). Challenges in Persian text processing. *ACM Transactions on Asian and Low-Resource Language Information Processing*, ۱۹(۳), ۱-۲٥.

۷۱. Aljuaid, H., et al. (۲۰۲۰). Importance of preprocessing in Arabic text classification. *IEEE Access*, ۸, ۲۰٥۲۳۰-۲۰٥۲٤۳.

۷۲. Eskandari, M., & M. (۲۰۲۱). Spelling correction and spacing in Persian language. *Journal of Language Resources and Evaluation*, ٥٥(۱), ٤٥-٦۸.

۷۳. Salton, G., & Buckley, C. (۱۹۸۸). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, ۲٤(٥), ٥۱۳-٥۲۳.

۷۴. Kowsari, K., et al. (۲۰۱۹). Text classification algorithms: A survey. *Information*, ۱۰(٤), ۱٥۰.

۷٥. Devlin, J., et al. (۲۰۱۹). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT*, ٤۱۷۱-٤۱۸٦.

۷۶. Manning, C. D., & Schütze, H. (۱۹۹۹). *Foundations of statistical natural language processing*. MIT Press.

۷۷. Bengio, Y., et al. (۲۰۰۳). A neural probabilistic language model. *Journal of Machine Learning Research*, ۳, ۱۱۳۷-۱۱٥٥.

٧٨. Mikolov, T., et al. (٢٠١٣). Efficient estimation of word representations in vector space. *arXiv:1301.3781*.

٧٩. Coppersmith, G., et al. (٢٠١٨). Natural language processing in mental health. *ACM Computing Surveys*, ٥١(٥), ١-٣٦.

٨٠. Reimers, N., & Gurevych, I. (٢٠١٩). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of EMNLP-IJCNLP*, ٣٩٨٢-٣٩٩٢.

٨١. Vaswani, A., et al. (٢٠١٧). Attention is all you need. *Advances in Neural Information Processing Systems*, ٣٠, ٥٩٩٨-٦٠٠٨.

٨٢. Devlin, J., et al. (٢٠١٩). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT*, ٤١٧١-٤١٨٦.

٨٣. Wang, W., et al. (٢٠٢٠). MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. *Advances in Neural Information Processing Systems*, ٣٣, ٥٧٧٦-٥٧٨٨.

٨٤. Loper, E., & Bird, S. (٢٠٠٢). NLTK: The natural language toolkit. *Proceedings of the ACL-02 Workshop*, ٦٣-٧٠.

٨٥. Pedregosa, F., et al. (٢٠١١). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, ١٢, ٢٨٢٥-٢٨٣٠.

٨٦. Thakur, N., et al. (٢٠٢١). Augmented SBERT: Data augmentation method for improving bi-encoders. *Proceedings of EACL*, ١٤١-١٥٢.

٨٧. Salton, G., & Buckley, C. (١٩٨٨). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, ٢٤(٥), ٥١٣-٥٢٣.

٨٨. Jones, K. S. (١٩٧٢). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, ٢٨(١), ١١-٢١.

٨٩. Ramos, J. (٢٠٠٣). Using TF-IDF to determine word relevance in document queries. *Proceedings of the First Instructional Conference on Machine Learning*, ٢٤٢, ٢٩-٤٨.

٩٠. Liu, Y., et al. (٢٠١٩). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv:1907.11692*.

٩١. Peters, M. E., et al. (٢٠١٨). Deep contextualized word representations. *Proceedings of NAACL-HLT*, ٢٢٢٧-٢٢٣٧.

٩٢. He, Q., et al. (٢٠٢١). Transformer-based models for suicide risk detection. *Journal of Biomedical Informatics*, ١١٨, ١٠٣٧٩٣.

٩٣. Strubell, E., et al. (٢٠١٩). Energy and policy considerations for deep learning in NLP. *Proceedings of ACL*, ٣٦٤٥-٣٦٥٠.

٩٤. Conneau, A., et al. (٢٠٢٠). Unsupervised cross-lingual representation learning at scale. *Proceedings of ACL*, ٨٤٤٠-٨٤٥١.

٩٥. Manning, C. D., et al. (٢٠٠٨). *Introduction to information retrieval*. Cambridge University Press.

٩٦. Vijayarani, S., & J. (٢٠٢٠). Performance analysis of text preprocessing techniques. *International Journal of Advanced Computer Science and Applications*, ١١(٦), ٣٤٥-٣٥٢.

٩٧. Aljuaid, H., et al. (٢٠٢٠). Importance of preprocessing in Arabic text classification. *IEEE Access*, ٨, ٢٠٥٢٣٠-٢٠٥٢٤٣.

٩٨. Kowsari, K., et al. (٢٠١٩). Text classification algorithms: A survey. *Information*, ١٠(٤), ١٥٠.

٩٩. Haddi, E., Liu, X., & Shi, Y. (٢٠١٣). The role of text pre-processing in sentiment analysis. *Procedia Computer Science*, ١٧, ٢٦-٣٢.

١٠٠. Kaur, A., & Gupta, V. (٢٠٢٠). A comprehensive survey on text preprocessing techniques for natural language processing. *ACM Computing Surveys*, ٥٢(٤), ١-٣٦.

١٠١. Zhang, C., et al. (٢٠٢١). Privacy-preserving machine learning: A survey. *ACM Computing Surveys*, ٥٤(٧), ١-٣٦.

١٠٢. Reimers, N., & Gurevych, I. (٢٠٢٠). Making monolingual sentence embeddings multilingual using knowledge distillation. *Proceedings of EMNLP*, ٤٥١٢-٤٥٢٥.

١٠٣. Breiman, L. (٢٠٠١). Random Forests. *Machine Learning*, ٤٥(١), ٥-٣٢.

١٠٤. Ho, T. K. (١٩٩٥). Random decision forests. *Proceedings of the 3rd International Conference on Document Analysis and Recognition*, ٢٧٨-٢٨٢.

١٠٥. Amit, Y., & Geman, D. (١٩٩٧). Shape quantization and recognition with randomized trees. *Neural Computation*, ٩(٧), ١٥٤٥-١٥٨٨.

١٠٦. Biau, G., & Scornet, E. (٢٠١٦). A random forest guided tour. *Test*, ٢٥(٢), ١٩٧-٢٢٧.

١٠٧. Fawagreh, K., Gaber, M. M., & Elyan, E. (٢٠١٤). Random forests: from early developments to recent advancements. *Systems Science & Control Engineering*, ٢(١), ٦٠٢-٦٠٩.

١٠٨. Hastie, T., Tibshirani, R., & Friedman, J. (٢٠٠٩). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.

١٠٩. Dietterich, T. G. (٢٠٠٠). Ensemble methods in machine learning. *Multiple Classifier Systems*, ١-١٥.

١١٠. Provost, F., & Fawcett, T. (٢٠١٣). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media.

١١١.He, H., & Garcia, E. A. (٢٠٠٩). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, ٢١(٩), ١٢٦٣-١٢٨٤.

١١٢.Zhang, H. (٢٠٠٤). The optimality of Naive Bayes. *Proceedings of FLAIRS 2004*.

١١٣.GHOST: Adjusting the Decision Threshold to Handle Imbalanced Data in Machine Learning. (٢٠٢١). *PubMed (NIH)*.

١١٤.Risk-Aware Calibration and Interpretable Baselines for Mental Health Text Classification. (٢٠٢٦). *IEEE Xplore*.

١١٥.Ding et al. (٢٠٢٤). Hyper-parameters setting for machine learning models. *PeerJ Computer Science*, ١٠, e٢٢٤٨.

١١٦.Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (٢٠٠٢). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, ١٦, ٣٢١-٣٥٧.

١١٧.Fawcett, T. (٢٠٠٦). An introduction to ROC analysis. *Pattern Recognition Letters*, ٢٧(٨), ٨٦١-٨٧٤.

١١٨.Davis, J., & Goadrich, M. (٢٠٠٦). The relationship between Precision-Recall and ROC curves. *Proceedings of the 23rd International Conference on Machine Learning*, ٢٣٣-٢٤٠.

١١٩.Sokolova, M., Japkowicz, N., & Szpakowicz, S. (٢٠٠٦). Beyond accuracy, F-score and ROC: a family of discriminant measures for performance evaluation. *AI 2006: Advances in Artificial Intelligence*, ١٠١٥-١٠٢١.

١٢٠.Machine Learning-Based Classification of Suicidal Ideation in Tweets. (٢٠٢٥). *IEEE Xplore*.

١٢١.Bazrafshan, M., & Sayehmiri, K. (٢٠٢٤). Predicting suicidal behavior outcomes: an analysis of key factors and machine learning models. *BMC Psychiatry*, ٢٤, ١٢٣.

١٢٢.Cawley, G. C., & Talbot, N. L. C. (٢٠١٠). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, ١١, ٢٠٧٩-٢١٠٧.

١٢٣.López, V., Fernández, A., García, S., Palade, V., & Herrera, F. (٢٠١٣). An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. *Information Sciences*, ٢٥٠, ١١٣-١٤١.

١٢٤.Safavian, S. R., & Landgrebe, D. (١٩٩١). A survey of decision tree classifier methodology. *IEEE Transactions on Systems, Man, and Cybernetics*, ٢١(٣), ٦٦٠-٦٧٤.

١٢٥.Hunt, E. B., Marin, J., & Stone, P. J. (١٩٦٦). *Experiments in Induction*. Academic Press.

١٢٦.Quinlan, J. R. (١٩٨٦). Induction of decision trees. *Machine Learning*, ١(١), ٨١-١٠٦.

١٢٧.Quinlan, J. R. (١٩٩٣). *C4.5: Programs for Machine Learning*. Morgan Kaufmann.

١٢٨.Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (١٩٨٤). *Classification and Regression Trees*. CRC Press.

١٢٩.Pedregosa, F., et al. (٢٠١١). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, ١٢, ٢٨٢٥-٢٨٣٠.

١٣٠.Mitchell, T. M. (١٩٩٧). *Machine Learning*. McGraw-Hill.

١٣١.Han, J., Kamber, M., & Pei, J. (٢٠١١). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.

١٣٢.Rokach, L., & Maimon, O. (٢٠٠٥). Decision trees. In *Data Mining and Knowledge Discovery Handbook*, ١٦٥-١٩٢.

١٣٣.Witten, I. H., Frank, E., & Hall, M. A. (٢٠١١). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann.

١٣٤.Loh, W. Y. (٢٠١١). Classification and regression trees. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, ١(١), ١٤-٢٣.

١٣٥.Caruana, R., & Niculescu-Mizil, A. (٢٠٠٦). An empirical comparison of supervised learning algorithms. *Proceedings of the 23rd International Conference on Machine Learning*, ١٦١-١٦٨.

١٣٦.Wu, X., et al. (٢٠٠٨). Top ١٠ algorithms in data mining. *Knowledge and Information Systems*, ١٤(١), ١-٣٧.

١٣٧.Dietterich, T. G. (١٩٩٥). Overfitting and undercomputing in machine learning. *ACM Computing Surveys*, ٢٧(٣), ٣٢٦-٣٢٧.

١٣٨.Esposito, F., Malerba, D., & Semeraro, G. (١٩٩٧). A comparative analysis of methods for pruning decision trees. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, ١٩(٥), ٤٧٦-٤٩١.

١٣٩.Zadrozny, B., & Elkan, C. (٢٠٠١). Obtaining calibrated probability estimates from decision trees and naive Bayesian classifiers. *Proceedings of the 18th International Conference on Machine Learning*, ٦٠٩-٦١٦.

١٤٠.Provost, F., & Fawcett, T. (٢٠١٣). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media.

١٤١.He, H., & Garcia, E. A. (٢٠٠٩). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, ٢١(٩), ١٢٦٣-١٢٨٤.

١٤٢.Zhang, H. (٢٠٠٤). The optimality of Naive Bayes. *Proceedings of FLAIRS 2004*.

١٤٣.Liu, W., Chawla, S., Cieslak, D. A., & Chawla, N. V. (٢٠١١). A robust decision tree algorithm for imbalanced data sets. *Proceedings of the 2011 SIAM International Conference on Data Mining*, ٧٦٦-٧٧٧.

١٤٤.Risk-Aware Calibration and Interpretable Baselines for Mental Health Text Classification. (٢٠٢٦). *IEEE Xplore*.

١٤٥.Sokolova, M., Japkowicz, N., & Szpakowicz, S. (٢٠٠٦). Beyond accuracy, F-score and ROC: a family of discriminant measures for performance evaluation. *AI 2006: Advances in Artificial Intelligence*, ١٠١٥-١٠٢١.

١٤٦.Fawcett, T. (٢٠٠٦). An introduction to ROC analysis. *Pattern Recognition Letters*, ٢٧(٨), ٨٦١-٨٧٤.

١٤٧.GHOST: Adjusting the Decision Threshold to Handle Imbalanced Data in Machine Learning. (٢٠٢١). *PubMed (NIH)*.

١٤٨.López, V., Fernández, A., García, S., Palade, V., & Herrera, F. (٢٠١٣). An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. *Information Sciences*, ٢٥٠, ١١٣-١٤١.

١٤٩.Bazrafshan, M., & Sayehmiri, K. (٢٠٢٤). Predicting suicidal behavior outcomes: an analysis of key factors and machine learning models. *BMC Psychiatry*, ٢٤, ١٢٣.

١٥٠.Haghish, E. F., et al. (٢٠٢٣). Reconsidering False Positives in Machine Learning Binary Classification Models of Suicidal Behavior. *Current Psychology*, ٤٣, ١٠١١٧-١٠١٢١.

١٥١.Alasmari, M. J. (٢٠٢٢). Ensemble Learning and XGBoost: A Comprehensive Review. *SACM - United Kingdom*.

١٥٢.Gulati, J. (٢٠٢٥). Algorithm Showdown: Logistic Regression vs. Random Forest vs. XGBoost on Imbalanced Data. *MachineLearningMastery.com*.

١٥٣.Text-Based Mental Health Detection Using Stacking Ensemble Approach with Hybrid Machine Learning and Deep Learning Models. (٢٠٢٦). *IEEE Xplore*.

١٥٤.Artificial intelligence approach for predicting suicide-related behaviour in emergency departments. (٢٠٢٦). *Scientific Reports (Nature)*.

١٥٥.Mienye, I. D., & Sun, Y. (٢٠٢٢). A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects. *IEEE Access*, ١٠, ٩٩١٢٩-٩٩١٤٩.

١٥٦.ParaBoostForest Hybrid Parallel Boosting for Imbalanced Learning. (٢٠٢٥). *GitHub*.

١٥٧.Wang, H. (٢٠٢٦). UEDU: Mental health distress signal detection in student writing. *GitHub*.

١٥٨.Anchor rules from XGBoost model for suicide prediction. (٢٠٢٤). *NIH/PMC*.

١٥٩.Chen, T., & Guestrin, C. (٢٠١٦). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD*.

١٦٠.XGBoost training and threshold optimization. (٢٠٢٦). *Imperial College London GitLab*.

١٦١.Early detection of mental health on social media using a hybrid Bi-LSTM–XGBoost model. (٢٠٢٦). *Scientific Reports (Springer)*, ١٦, ٢٠٥٨٢.

١٦٢.Garuda – Garba Rujukan Digital. (٢٠٢٦). Systematic Literature Review of Naive Bayes Algorithm for Data Classification in Indonesia.

١٦٣.Garuda – Garba Rujukan Digital. (٢٠٢٥). Twitter Sentiment Analysis on the Iran-Israel Conflict Using the Naïve Bayes Classification Algorithm.

١٦٤.National Institutes of Health (NIH). (٢٠١٨). Potential use of text classification tools as signatures of suicidal behavior: A proof-of-concept study using Virginia Woolf's personal writings. *PLoS ONE*, ١٣(١٠), e٠٢٠٤٨٢٠.

١٦٥.IEEE Xplore. (٢٠٢٦). Comparative Analysis of Naïve Bayes Algorithms for Lecturer Performance Classification.

١٦٦.MDPI. (٢٠٢٤). Detecting Suicidal Ideations in Online Forums with Textual and Psycholinguistic Features. *Applied Sciences*, ١٤(٢١), ٩٩١١.

١٦٧.Journal of Computer Science and Information Technology. (٢٠٢٥). Twitter Sentiment Analysis on the Iran-Israel Conflict Using the Naïve Bayes Classification Algorithm.

١٦٨.OUCI. (٢٠٢٣). Ensemble Learning for Email Classification using Voting Classifier. *Expert Systems with Applications*.

١٦٩.Journal of Nnamdi Azikiwe University. (٢٠٢٦). An Improved Multinomial Naïve Bayes Algorithm with Laplace Smoothing for News Classification.

١٧٠.GitHub. (٢٠٢٣). Suicide Detection using Naive Bayes Classification.

١٧١.GitHub. (٢٠٢٥). Ensemble Learning Voting Classifier using Naive Bayes.

١٧٢.Virascience. (٢٠١٥). A Survey Paper On Naive Bayes Classifier For Multi-Feature Based Text Mining.

١٧٣.Nauki i Tekhniki. (٢٠٢٤). Review of methods for semantic text classification.

١٧٤.Czech Academy of Sciences. (٢٠٢٣). Spam Detection Using Ensemble Learning.

١٧٥.Stack Overflow. (٢٠١٥). Naive Bayes Text Classification Laplace Smoothing.

١٧٦.Zhang, H. (٢٠٠٤). The optimality of Naive Bayes. *Proceedings of the Seventeenth International Florida Artificial Intelligence Research Society Conference (FLAIRS 2004)*.

١٧٧.Eskandari, M., & M. (٢٠٢١). Spelling correction and spacing in Persian language. *Journal of Language Resources and Evaluation*, ٥٥(١), ٤٥-٦٨.

١٧٨.ElGamal, T. (١٩٨٥). A Public Key Cryptosystem and a Signature Scheme Based on Discrete Logarithms. IEEE Transactions on Information Theory, ٣١(٤), ٤٦٩–٤٧٢.

١٧٩.Paillier, P. (١٩٩٩). Public-Key Cryptosystems Based on Composite Degree Residuosity Classes. EUROCRYPT ١٩٩٩, LNCS ١٥٩٢, ٢٢٣–٢٣٨.

١٨٠.Benaloh, J. (١٩٩٤). Dense Probabilistic Encryption. Selected Areas in Cryptography

١٨١. Damgård, I., & Jurik, M. (٢٠٠١). A Generalisation, a Simplification and Some Applications of Paillier's Probabilistic Public-Key System. PKC ٢٠٠١, LNCS ١٩٩٢, ١١٩–١٣٦.

١٨٢. Rivest, R. L., Shamir, A., & Adleman, L. (١٩٧٨). A Method for Obtaining Digital Signatures and Public-Key Cryptosystems. Communications of the ACM, ٢١(٢), ١٢٠–



Shahid Beheshti University of Tehran

Faculty of Mathematical Sciences

Department of Computer Science

M. Sc. Thesis

Securing Sensitive Data in Suicide Prediction with a Federated Learning and Homomorphic Encryption Approach for NLP

by

Sajjad Ranjbar Yazdi

Supervisor

Dr. Ziba Eslami

۲۰۲۶